

DQN方法 (一)：为什么从Q表升级到DQN

表格式Q-learning的局限

$$Q \text{ 表规模} = |\mathcal{S}| \times |\mathcal{A}|$$

- 1 状态必须离散化：难以直接接入连续物理特征
- 2 状态维度升高：Q表规模迅速膨胀
- 3 缺少泛化能力：未访问状态难以给出可靠动作价值

$$S_t = [\sigma_{\tau,t}, \sigma_{RSSI,t}^2, D_{RF-PDR,t}, \omega_{t-1}]^T$$

该状态包含连续物理与历史决策特征，已不适合直接建表。

DQN的核心思想

$$Q(S_t, a_t) \approx Q(S_t, a_t; \theta)$$

$$Q(S_t; \theta) = [Q(S_t, a_1; \theta), \dots, Q(S_t, a_{|\mathcal{A}|}; \theta)]^T$$

- 1 用神经网络替代Q表
- 2 输入连续状态特征
- 3 一次前向传播输出所有动作Q值

升级动机： DQN 保留 Q-learning 的长期价值学习思想，同时解决物理感知状态下 Q 表难扩展、难泛化的问题。