

基于物理感知深度强化学习的融合定位方法

石志鹏¹, 昌硕¹, 黄赛¹, 胡建¹

¹ 北京邮电大学信息与通信工程学院, 北京 100876

摘要: 针对复杂城市环境中非视距传播导致的定位性能退化问题, 本文提出一种基于物理感知深度强化学习的自适应多模态融合方法, 即物理感知深度 Q 网络 (Physics-Aware Deep Q Network, PA-DQN)。该方法将均方根 (Root Mean Square, RMS) 时延扩展等物理信道特征引入深度 Q 网络 (Deep Q-Network, DQN) 状态空间, 并结合增量式动作机制与双重奖励设计, 实现传播环境变化下的动态调权融合。基于射线追踪先验构建仿真训练环境, 在对角线、反对角线、矩形和随机游走等典型轨迹上进行验证。结果表明, PA-DQN 相较扩展卡尔曼滤波 (Extended Kalman Filter, EKF) 和 Q 学习 (Q-Learning) 分别获得 70.7% 和 63.6% 的定位精度提升, 平均均方根误差 (Root Mean Square Error, RMSE) 降低至 2.1468 m, 并在低信噪比条件下保持较低的定位误差。

关键词: 深度强化学习; 物理感知; 自适应融合; 非视距抑制; 城市定位

中图分类号: TN929.5

Physics-Aware Deep Reinforcement Learning for Adaptive Multi-modal Fusion in Urban Environments

SHI Zhipeng¹, Chang Shuo¹, Huang Sai¹, Hu Jian¹

¹ School of Information and Communication Engineering, Beijing University of Posts and Telecommunications, Beijing 100876

Abstract: To address localization degradation caused by non-line-of-sight (NLOS) propagation in complex urban environments, this paper proposes a physics-aware deep reinforcement learning method, termed the Physics-Aware Deep Q Network (PA-DQN), for adaptive multi-modal fusion. The method incorporates physical channel descriptors such as root mean square (RMS) delay spread into the state space of a deep Q-network (DQN), and combines an incremental action mechanism with a dual-reward design to realize dynamic weight adjustment under varying propagation conditions. A ray-tracing-based simulation environment is constructed for training and evaluation on representative trajectories, including diagonal, anti-diagonal, rectangular, and random-walk paths. The results show that PA-DQN improves localization accuracy by 70.7% and 63.6% over the extended Kalman filter (EKF)

基金项目: *** 基金 (00000000)

作者简介: 石志鹏, 男, 研究方向: 无线通信、卫星通信。通信作者: 昌硕, 男, 研究方向: 无线通信、深度学习。E-mail: chang-shuo@bupt.edu.cn。

and Q-learning, respectively, reduces the average root mean square error (RMSE) to 2.1468 m, and maintains improved robustness under low signal-to-noise ratio (SNR) conditions.

Key words: deep reinforcement learning; physics-aware; adaptive fusion; NLOS mitigation; urban localization

0 引言

复杂城市环境下的鲁棒定位是智慧城市与天地一体化网络中的关键支撑能力之一。然而,城市峡谷中的高层建筑会引起严重的非视距 (NLOS) 传播与多径效应,使传统基于几何测距的定位方法在实际应用中容易产生较大误差。尤其是在传播条件快速变化的场景中,单一定位源往往难以同时兼顾绝对精度与轨迹连续性。

多模态融合为缓解上述问题提供了可行途径。现有方法大致可分为模型驱动融合和学习驱动融合两类。前者通常依赖显式系统模型与噪声假设,后者则通过数据驱动方式学习权重调整或决策策略。尽管这两类方法在不同场景下都取得了一定效果,但多数工作仍主要依赖定位误差、接收信号强度指示 (Received Signal Strength Indicator, RSSI) 标量或滤波残差等后验统计量作为状态输入,较少显式引入传播物理信息。因此,当环境发生较强的 NLOS 或多径变化时,模型往往只能在误差已经累积后再做响应。

针对上述问题,本文提出一种基于物理感知深度强化学习的自适应融合框架,即物理感知深度 Q 网络 (Physics-Aware Deep Q Network, PA-DQN)。该方法将均方根时延扩展 (Root Mean Square Delay Spread, RMS delay spread) 等物理信道特征引入状态空间,使智能体能够根据传播条件变化动态调整多源定位权重。针对复杂城市环境中的动态融合问题,本文设计了以增量式动作机制和双重奖励函数为核心的 PA-DQN 决策方法,并结合物理感知状态输入实现多源定位权重的自适应调节。

1 相关工作

复杂城市环境下的定位误差主要来源于两类因素:一类是几何观测在 NLOS 和多径条件下产生系统性偏差,另一类是多源观测在传播条件快速变化时难以保持稳定的一致性。围绕这两个问题,现有研究大致形成了模型驱动方法和学习驱动方法两条技术路线。

模型驱动方法首先从几何测量偏差抑制入手。Chan 和 Ho 给出了经典的双曲定位估计方法^[1],为多站几何定位提供了闭式求解基础;在此基础上,Wang 和 Ho 进一步针对 NLOS 偏差下的到达时间差 (Time Difference of Arrival, TDOA) 定位提出鲁棒模型变换方法^[2],能够在存在系统性偏差时降低几何解算误差。该类研究的共同特点是直接围绕测量偏差进行修正,能够在观测模型较明确时显著改善单次定位结果,但其性能仍取决于对偏差形式和噪声统计特性的准确刻画。

在几何偏差抑制之外,模型驱动路线进一步发展为多传感器融合框架。Ma 等将多离群点鲁棒卡尔曼滤波用于城市峡谷中的全球导航卫星系统/惯性导航系统 (Global Navigation Satellite

System/Inertial Navigation System, GNSS/INS) 紧组合定位, 结果表明该方法能够有效抑制异常观测对滤波状态的冲击并提升连续定位稳定性^[3]。Xu 等利用非线性感知零速更新 (Zero Velocity Update, ZUPT) 与立方卡尔曼滤波改善了城市峡谷中的行人惯导性能, 在惯性累积漂移控制方面取得了更稳定的轨迹结果^[4]。Zhang 等进一步将连续时间因子图优化用于 GNSS 与多传感器融合, 提高了复杂环境中的连续轨迹一致性和全局约束能力^[5]。从更一般的角度看, Wymeersch 等系统总结了无线网络中的协作定位框架^[6], Güvenç 和 Chong 综述了到达时间 (Time of Arrival, ToA) 定位与 NLOS 抑制方法^[7]。这些研究说明, 模型驱动方法在系统结构清晰、噪声模型相对可描述时能够取得较好效果, 但当传播条件快速变化、误差分布显著非高斯或多源可靠性随时间变化时, 固定模型的适应能力仍然有限。

为了增强模型对复杂传播环境的适应性, 部分研究开始显式引入环境信息和传播特征。de Sousa 和 Thomä 将多径射线追踪指纹与机器学习结合, 用于改善 NLOS 城市场景中的定位性能, 结果表明传播先验能够有效提升复杂环境下的定位可分辨性^[8]。Stock 等指出, 低轨卫星机会定位在复杂环境中的主要瓶颈之一是传播条件变化引起的信号退化^[9]; Kozhaya 等从 Starlink 定位、导航与授时 (Positioning, Navigation, and Timing, PNT) 潜力角度说明, 低轨卫星信号具备新的定位机会, 但其性能高度依赖可见性和链路质量^[10]; Gapeyenko 等则从城市环境星地路径损耗建模角度给出定量分析, 说明遮挡与散射会显著改变接收信号统计特征^[11]。这类研究共同表明, 传播环境信息并非附属变量, 而是决定观测可靠性的重要因素; 若能将其引入决策过程, 有望进一步提升复杂场景下的融合效果。

与模型驱动方法相比, 强化学习更强调在交互中学习动态决策策略。Mnih 等提出的深度 Q 网络 (Deep Q-Network, DQN) 为高维状态下的动作价值学习奠定了基础^[12]。在定位融合场景中, Salimibeni 等将强化学习用于室内混合定位中的信息融合, 通过学习不同观测源的权重关系提高了整体定位精度^[13]; Wong 等将深度强化学习与多模型自适应估计结合, 用于多传感器融合同步定位与建图 (Simultaneous Localization and Mapping, SLAM), 提升了复杂环境中的自适应建图能力^[14]; Wang 等将深度强化学习用于智能反射面辅助的指纹定位, 在复杂传播条件下获得了较优的定位性能^[15]; Dou 等将联邦强化学习引入异构设备条件下的室内定位问题, 增强了分布式场景中的模型协同能力^[16]; Feng 等和 Peng 等分别在短波协同测向定位和协同定位调度中验证了深度强化学习对决策优化的有效性, 说明强化学习在多源权重控制和资源分配中具有较强潜力^[17, 18]; Jia 等和 Wu 等则进一步将强化学习用于多传感器融合 SLAM 和多模态定位任务, 在动态环境适应方面取得了积极结果^[19, 20]。总体来看, 强化学习已显示出在多源权重分配和策略自适应方面的优势, 但多数方法仍以定位误差、RSSI 标量或滤波残差等后验统计量作为状态输入, 对传播物理退化过程的刻画仍然不足。

现有研究已从模型设计、环境建模和策略学习等方面推动复杂环境定位的发展, 但将传播物理信息直接纳入强化学习决策过程的自适应融合方法仍相对缺乏。对于复杂城市环境中的定位任务而言, 单一路观测通常难以同时兼顾绝对定位精度与轨迹连续性, 因此采用融合策略具有必要性; 然而, 现有融合方法往往依赖固定权重、静态噪声模型或浅层后验统计量, 难以在传播条件快速变化时及时调整各分支贡献。本文将 RMS 时延扩展等物理先验显式纳入强化学习状态空间, 使融合策略能够在误差显著累积之前更早感知环境变化并调整权重。




图 1: 复杂城市环境下空天地协同观测定位场景示意图

2 场景描述

本文考虑复杂城市环境下的多源协同定位问题，场景示意如图 1 所示。待定位终端位于建筑物密集分布的城市街区中，道路两侧的高层或中高层建筑会对无线电信号传播产生明显的遮挡、反射和散射作用，使终端与观测节点之间的链路状态在视距（line-of-sight, LOS）与非视距（NLOS）条件之间动态切换。在这一背景下，部分观测链路能够提供具有较强绝对参考意义的几何约束，而另一些链路则会因多径增强、遮挡加深或视距缺失而出现明显偏差，因此不同观测源的有效性并不是静态不变的，而是随终端位置、传播条件以及观测几何关系共同变化。

本文将该场景抽象为传播条件随位置和时间变化的多源观测融合问题，并研究 RSSI、AoA 和 PDR 三类观测分支在复杂传播环境下的自适应调权机制。研究重点在于：当无线电观测受到环境扰动而发生可靠性变化时，如何同时利用绝对定位观测与相对运动观测之间的互补性，对多源信息进行自适应调权，从而在保持定位精度的同时抑制异常观测和短时突变对融合结果的影响。基于这一任务定义，本文进一步建立接收信号强度指示（Received Signal Strength Indicator, RSSI）、到达角（Angle of Arrival, AoA）和航位推算（Pedestrian Dead Reckoning, PDR）三类观测分支的测量模型，并在此基础上构造后续的 PA-DQN 自适应融合框架。

设待定位终端在离散时刻 t 的位置为

$$\mathbf{p}_t = [x_t, y_t, z_t]^T, \quad (1)$$

第 m 个观测节点的位置为 $\mathbf{s}_m = [x_m, y_m, z_m]^T$ ，则终端与该观测节点之间的几何距离可写为

$$d_{m,t} = \|\mathbf{p}_t - \mathbf{s}_m\|_2. \quad (2)$$

若第 m 个观测节点发射中心频率为 f_c 的调制信号，则其发射信号可写为

$$s_m(\tau) = \Re \left\{ \sqrt{2P_m} x_m(\tau) e^{j2\pi f_c \tau} \right\}, \quad (3)$$

其中, P_m 为发射功率, $x_m(\tau)$ 为单位功率复基带包络, 满足 $\mathbb{E}[|x_m(\tau)|^2] = 1$ 。对应地, 在时刻 t 由终端接收到的复基带信号可统一表示为

$$y_{m,t}(\tau) = \sum_{l=0}^{L_{m,t}-1} \alpha_{m,l,t} x_m(\tau - \tau_{m,l,t}) e^{j\phi_{m,l,t}} + n_{m,t}(\tau), \quad (4)$$

其中, $L_{m,t}$ 为有效多径条数, $\alpha_{m,l,t}$ 、 $\tau_{m,l,t}$ 和 $\phi_{m,l,t}$ 分别表示第 l 条传播路径的幅度、时延和相位, $n_{m,t}(\tau)$ 为加性噪声。该模型表明, 复杂城市环境中的接收信号是多个延迟、衰减并相位旋转后的分量叠加结果, 因此接收功率、到达方向和路径时延结构都会受到传播环境变化的直接影响。基于该统一发射与接收模型, 本文进一步构造 RSSI、AoA 和 PDR 三类观测分支, 并分别建立如下测量模型。

对于 RSSI 分支, 接收信号强度满足对数距离路径损耗模型

$$r_{m,t} = P_0 - 10\eta \log_{10} \left(\frac{d_{m,t}}{d_0} \right) + b_{m,t}^{\text{NLOS}} + v_{m,t}^r, \quad (5)$$

其中, P_0 表示参考距离 d_0 处的接收功率, η 为路径损耗指数, $b_{m,t}^{\text{NLOS}}$ 表示由遮挡和多径引起的附加偏差, $v_{m,t}^r$ 为测量噪声。基于多个观测节点的 RSSI 测量, 可进一步得到 RSSI 分支的位置估计 $\mathbf{P}_t^{\text{RSSI}}$ 。

对于 AoA 分支, 第 m 个观测节点的方位角和俯仰角观测可分别表示为

$$\theta_{m,t}^{az} = \arctan \frac{y_t - y_m}{x_t - x_m} + b_{m,t}^{az} + v_{m,t}^{az}, \quad (6)$$

$$\theta_{m,t}^{el} = \arctan \frac{z_t - z_m}{\sqrt{(x_t - x_m)^2 + (y_t - y_m)^2}} + b_{m,t}^{el} + v_{m,t}^{el}, \quad (7)$$

其中, $b_{m,t}^{az}$ 和 $b_{m,t}^{el}$ 表示由 NLOS 或阵列失配引起的角度偏差, $v_{m,t}^{az}$ 和 $v_{m,t}^{el}$ 为角度测量噪声。通过多站角度交汇可以得到 AoA 分支的位置估计 $\mathbf{P}_t^{\text{AoA}}$ 。

对于 PDR 分支, 终端的位置递推关系可建模为

$$\mathbf{P}_t^{\text{PDR}} = \mathbf{P}_{t-1}^{\text{PDR}} + \begin{bmatrix} \hat{l}_t \cos \hat{\psi}_t \cos \hat{\varphi}_t \\ \hat{l}_t \sin \hat{\psi}_t \cos \hat{\varphi}_t \\ \hat{l}_t \sin \hat{\varphi}_t \end{bmatrix} + \mathbf{w}_t, \quad (8)$$

其中, $\hat{l}_t$ 、 $\hat{\psi}_t$ 和 $\hat{\varphi}_t$ 分别表示第 t 个时刻估计的步长、航向角和俯仰角, $\mathbf{w}_t$ 为由惯性噪声和累计漂移引起的误差项。与 RSSI 和 AoA 相比, PDR 具有较好的短时连续性, 但误差会随着时间逐步累积。

因此, 在时刻 t 可以获得三类初始位置估计 $\mathbf{P}_t^{\text{RSSI}}$ 、 $\mathbf{P}_t^{\text{AoA}}$ 和 $\mathbf{P}_t^{\text{PDR}}$ 。在此基础上, 本文进一步研究传播条件动态变化下的多源自适应融合问题。




图 2: PA-DQN 自适应融合框架的系统结构图

3 基于 PA-DQN 的自适应融合定位方法

3.1 多源定位融合与强化学习任务建模

在复杂城市峡谷场景中，多源定位融合可进一步视为一个动态权重分配问题。若采用固定权重或静态噪声模型，一旦环境由 LOS 转入 NLOS，原有权重设置往往难以及时反映观测质量退化。为此，本文将异构定位融合过程建模为马尔可夫决策过程（Markov Decision Process, MDP），使智能体能够在每个时刻根据环境状态选择动作并更新权重，从而在长期累计回报意义下实现精度与稳定性的折中。

在时刻 t ，融合位置定义为

$$P_t^{Fused} = \omega_t^{RSSI} P_t^{RSSI} + \omega_t^{AoA} P_t^{AoA} + \omega_t^{PDR} P_t^{PDR}, \quad (9)$$

其中， $\omega_t = [\omega_t^{RSSI}, \omega_t^{AoA}, \omega_t^{PDR}]^T$ 为三路观测对应的融合权重，并满足

$$\omega_t^i \geq 0, \quad \sum_i \omega_t^i = 1. \quad (10)$$

在该任务建模中，状态 S_t 用于描述传播环境、信号波动和系统内部一致性，动作 a_t 用于调节权重分配，奖励 r_t 用于衡量当前融合决策在定位精度和平滑性方面的综合表现。对应的优化目标可写为

$$\max_{\pi} \mathbb{E} \left[\sum_{t=0}^T \gamma^t r_t \right], \quad (11)$$

其中, π 表示策略, γ 为折扣因子。该建模方式将多源融合描述为可学习的动态权重分配过程, 使不同传播条件下的权重调节能够由策略学习统一表征。

图 2 给出了本文所提出 PA-DQN 自适应融合框架的整体结构。系统由 RSSI、AoA 和 PDR 三个定位分支组成, 各分支分别提供不同性质的位置信息: RSSI 与 AoA 分支能够提供具有绝对参考意义的无线电观测, 而 PDR 分支则具有较好的短时连续性, 但容易随时间积累漂移。三类观测首先独立生成初始位置估计 P_t^{RSSI} 、 P_t^{AoA} 和 P_t^{PDR} , 随后原始观测和中间结果被送入物理感知特征提取模块, 用于构建当前时刻的状态向量 S_t 。

在决策层, PA-DQN 智能体根据状态向量评估当前传播环境和各分支的相对可靠性, 并输出当前时刻的融合权重 ω_t 。融合中心再利用该权重对三类初始位置进行加权组合, 得到最终定位结果 P_t^{Fused} 。为实现高维状态下的稳定决策, 本文采用深度 Q 网络 (Deep Q-Network, DQN) 逼近动作价值函数 $Q(s, a)$:

$$Q(s, a) = \mathbb{E} \left[r + \gamma \max_{a'} Q(s', a') \mid s, a \right], \quad (12)$$

网络参数通过最小化预测值与目标值之间的均方误差进行更新:

$$L(\theta) = \mathbb{E}_{(s, a, r, s') \sim \mathcal{D}} \left[(y_i - Q(s, a; \theta))^2 \right], \quad (13)$$

其中, $\mathcal{D}$ 为经验回放池, 目标值 $y_i = r + \gamma \max_{a'} Q(s', a'; \theta^-)$ 由目标网络计算。在离线训练阶段, 融合结果与真实位置进行比较以形成奖励信号, 并借助经验回放和目标网络更新策略参数; 在在线推理阶段, 智能体仅依赖实时可观测特征完成权重调整。该框架将观测生成、环境感知和自适应决策统一到同一闭环中, 使权重更新能够直接响应传播条件变化, 而不是仅在误差出现后被动修正。

3.2 PA-DQN 融合定位算法

3.2.1 方法总体框架

为进一步刻画 PA-DQN 内部的决策网络结构, 本文在状态输入端引入分组自注意力机制。这里, PA-DQN 中的 PA 是指 Physics-Aware, 即在决策状态中显式引入 RMS 时延扩展、RSSI 方差和 RF-PDR 一致性等传播物理与观测可靠性特征; DQN 部分则用于完成离散动作空间下的动作价值估计与权重决策。与整体系统结构不同, 这一部分重点关注状态向量在网络内部的表示方式、不同语义特征之间的交互关系, 以及动作价值函数的具体实现形式。对应的网络结构如图 3 所示。

如图 3 所示, 本文采用基于分组自注意力的 PA-DQN 决策网络对融合状态进行层次化建模与动作价值评估。该结构的核心思想是在保留物理感知语义分组的基础上, 通过注意力机制建模不同特征组之间的耦合关系, 再利用 DQN 决策头输出离散动作的 Q 值。网络输入为 6 维状态向量

$$S_t = [\sigma_\tau, \sigma_{RSSI}^2, D_{RF-PDR}, \omega_{t-1}^{RSSI}, \omega_{t-1}^{AoA}, \omega_{t-1}^{PDR}]^T \in \mathbb{R}^6, \quad (14)$$

其中分别对应传播物理特征、信号统计特征、系统一致性特征以及上一时刻的历史决策信息。考虑到这几类特征在语义上具有明显差异，本文首先将输入状态划分为物理特征组、信号特征组、一致性特征组和历史决策组，并通过独立线性层分别映射到统一的 32 维嵌入空间中，从而形成 4×32 的特征 token 矩阵。该过程能够在保留原始物理含义的基础上，将不同来源的信息投影到统一表示空间，为后续组间关系建模提供一致输入。




图 3: 基于分组自注意力的 PA-DQN 网络结构图

在此基础上，网络采用单头自注意力机制对 4 组特征之间的耦合关系进行建模。与直接将全部状态分量送入多层感知机相比，这种结构能够显式刻画不同特征组在当前传播条件下的重要性分配关系。例如，当多径增强或观测一致性下降时，物理特征组和一致性特征组对决策的影响更为显著；而在传播条件相对稳定时，历史决策组与信号统计组对权重微调的约束作用更加明显。注意力输出随后经过残差连接、层归一化以及前馈网络进一步细化，其中前馈网络维度设置为 $32 \rightarrow 64 \rightarrow 32$ ，用于提升特征表示的非线性建模能力并增强训练稳定性。之后，将 4×32 的输出展平为 128 维向量，并送入决策头进行动作价值估计。决策头采用三层全连接结构，网络规模为 $128 \rightarrow 128 \rightarrow 64 \rightarrow 7$ ，最终输出 7 个离散动作对应的 Q 值，分别表示增大或减小 RSSI、AoA、PDR 权重以及保持当前权重不变。由于输出空间与本文定义的增量式动作集合一一对应，智能体能够在每个时刻根据最大 Q 值选择当前最优调权动作。整体来看，该网络结构将语义分组、自注意力建模与离散动作价值估计结合起来，使 PA-DQN 不仅能够利用物理感知状态识别传播环境变化，还能够通过历史决策与系统一致性信息约束权重更新过程，从而在定位精度与轨迹平滑性之间实现折中。

3.2.2 物理感知状态特征设计

为描述传播环境变化, 本文将状态特征设计为物理层、信号层和系统层三部分的组合。其中, 物理层特征用于反映多径传播结构, 信号层特征用于刻画短时间尺度内的观测波动, 而系统层特征则用于衡量多源结果之间是否已经出现显著分歧。对应的状态向量定义为

$$S_t = [\sigma_\tau, \sigma_{RSSI}^2, D_{RF-PDR}, \omega_{t-1}^{RSSI}, \omega_{t-1}^{AoA}, \omega_{t-1}^{PDR}]^T \in \mathbb{R}^6, \quad (15)$$

其中, σ_τ 为均方根时延扩展 (Root Mean Square delay spread), σ_{RSSI}^2 为 RSSI 方差, D_{RF-PDR} 为射频 (Radio Frequency, RF) 观测与惯导推算之间的几何一致性指标, 后三项为上一时刻的融合权重。该状态设计同时覆盖传播环境变化信息与系统输出一致性信息。

具体而言, RMS 时延扩展用于描述多径到达时间的离散程度, 是刻画传播环境退化的重要物理量之一, 其定义为

$$\sigma_\tau = \sqrt{\frac{\sum_{n=1}^N |\alpha_n|^2 (\tau_n - \bar{\tau})^2}{\sum_{n=1}^N |\alpha_n|^2}}, \quad (16)$$

RSSI 方差用于反映短时快衰落和信号波动强度, 可补充说明当前信号质量是否快速恶化, 其表达式为

$$\sigma_{RSSI}^2 = \frac{1}{W} \sum_{k=t-W+1}^t (RSSI_k - \bar{RSSI}_t)^2, \quad (17)$$

RF-PDR 几何一致性则利用无线电定位结果与惯导推算结果之间的偏差, 对系统内部是否出现异常进行辅助判别, 其定义为

$$D_{RF-PDR} = \|P_{RF} - P_{PDR}\|_2 = \sqrt{(x_{RF} - x_{PDR})^2 + (y_{RF} - y_{PDR})^2}. \quad (18)$$

上述三类特征共同构成 PA-DQN 的状态输入, 用于支持不同传播条件下的动态权重调整。

3.2.3 增量式动作设计

为了保持定位轨迹平滑, 本文将动作设计为对上一时刻权重的微调, 而非直接输出绝对权重。若由网络在每个时刻直接给出一组新的权重, 策略容易在相邻时刻之间产生较大跳变, 进而导致轨迹抖动和局部不连续。相比之下, 增量式动作机制将每次决策限制在有限幅度内, 使权重更新更接近逐步修正过程, 更适合处理传播环境连续变化下的动态融合问题。本文定义离散动作集合

$$\mathcal{A} = \{a_1, a_2, a_3, a_4, a_5, a_6, a_7\}, \quad (19)$$

其中, a_1, a_2 表示增大或减小 RSSI 权重, a_3, a_4 表示增大或减小 AoA 权重, a_5, a_6 表示增大或减小 PDR 权重, a_7 表示保持不变。设步长为 δ , 则中间权重向量写为

$$\tilde{\omega}_t = \omega_{t-1} + \delta \mathbf{u}(a_t), \quad (20)$$

最终权重通过归一化得到

$$\omega_{t,i} = \frac{\max(\tilde{\omega}_{t,i}, 0)}{\sum_{j \in \{RSSI, AoA, PDR\}} \max(\tilde{\omega}_{t,j}, 0)}. \quad (21)$$

该设计在保持环境变化响应能力的同时控制了输出波动，并使调权过程与定位轨迹的连续性要求保持一致。对于复杂城市轨迹中的 LOS/NLOS 切换场景，这种渐进式的调整方式尤其有利于抑制由瞬时观测异常导致的过度响应。

3.2.4 双重奖励函数设计

为兼顾定位精度与轨迹平滑性，本文采用双重奖励设计。其基本思想是同时约束两个目标：一方面，融合结果应尽可能接近真实位置；另一方面，权重变化不应过于剧烈，否则虽然可能在局部时刻获得较小误差，却会破坏整段轨迹的平滑性。对应的奖励函数定义为

$$r_t = \exp(-k\|P_{GT} - P_{Fused}\|) - \lambda\|\omega_t - \omega_{t-1}\|, \quad (22)$$

其中，第一项用于鼓励融合结果逼近真实位置 P_{GT} ，第二项用于惩罚相邻时刻权重的剧烈变化。这样的奖励设计能够避免智能体只追求瞬时精度，而忽略连续定位任务对轨迹稳定性的要求。

从物理意义上看，PDR 分支通常具有较好的短时连续性，而 RSSI 与 AoA 分支在传播条件良好时具有较强的绝对纠偏能力。双重奖励正是利用这种互补性，引导模型在短时平滑与长期纠偏之间形成平衡，使策略既不会过度依赖某一类观测，也不会因为频繁调权而引入新的波动。

训练中使用经验回放、目标网络和 ϵ -greedy 策略以提高稳定性。仿真环境不仅提供位置真值，也提供射线追踪计算得到的传播物理量，从而使智能体能够学习传播环境变化、观测可靠性变化与融合权重调整之间的映射关系。这一训练方式为后续将物理感知特征引入自适应融合决策提供了基础。

4 实验结果与分析

4.1 实验设置

本文在基于 Python 的高保真仿真平台上验证 PA-DQN。实验区域设置为 $200 \text{ m} \times 200 \text{ m}$ 的二维城市平面，并离散为 100×100 个网格单元，对应网格分辨率为 $2 \text{ m} \times 2 \text{ m}$ 。为构造多站无线电观测，本文在区域四角布设 4 个观测节点，位置分别为 (0,0)、(200,0)、(0,200) 和 (200,200)。无线电观测由射线追踪模型生成，以刻画复杂环境中的反射、散射与遮挡效应；惯导分支则通过叠加累积高斯噪声模拟 PDR 漂移。

实验场景包含对角线、反对角线、矩形和随机游走四类典型城市轨迹。对角线轨迹从 (20,20) 延伸至 (180,180)，反对角线轨迹从 (20,180) 延伸至 (180,20)，两类轨迹长度均约为 226.3 m，用于描述穿越街区的长距离连续运动。矩形轨迹由 (60,70) $\rightarrow$ (140,70) $\rightarrow$ (140,130) $\rightarrow$ (60,130) $\rightarrow$ (60,70) 构成，其尺寸为 $80 \text{ m} \times 60 \text{ m}$ ，周长约为 280 m，用于刻画包含多次转角的街区绕行场

景。随机游走轨迹限制在中心区域 $[30, 170] \times [30, 170]$ 内, 通过控制点插值生成平滑随机路径, 总长度控制在 180 ~ 260 m 范围内, 用于模拟方向变化频繁、运动模式不规则的复杂路径。

对比算法包括扩展卡尔曼滤波 (Extended Kalman Filter, EKF) [3, 5]、Q 学习 (Q-Learning) [22], 以及两种单源方案 AoA-only 和 PDR-only。其中, EKF 代表典型模型驱动融合方法, Q-Learning 用于刻画不引入物理感知状态时的强化学习基线, 而 AoA-only 和 PDR-only 则分别作为单源观测性能下界。评价指标采用均方根误差 (Root Mean Square Error, RMSE) 和 95% 分位误差 (95th Percentile Error, P95), 用于分别衡量整体定位精度与尾部误差鲁棒性, 从而兼顾平均性能与复杂环境下的异常误差表现。

每条轨迹统一离散为 500 个采样点, 采样周期设为 $\Delta t = 0.5$ s。在该设置下, 对角线和反对角线轨迹的平均运动速度约为 0.91 m/s, 矩形轨迹的平均运动速度约为 1.12 m/s, 与地面移动终端的典型运动速度范围一致。场景中同时包含开阔区、街区边缘区和深度遮挡区, 轨迹沿程经历 LOS、NLOS 和恢复段的传播条件变化, 以便观察算法在环境切换过程中的动态调权行为。对每个采样点, 射线追踪模块输出多径条数、路径功率、传播时延与到达方向, 并进一步计算 RMS 时延扩展等物理量, 用于构造后续的物理感知状态特征。

训练、验证和测试数据采用轨迹级划分。针对每类轨迹, 分别生成 5000 条训练轨迹、1500 条验证轨迹和 1500 条测试轨迹。不同数据集使用独立随机种子, 其噪声 realization、NLOS 区段位置及区段长度均不重复, 以保证训练与测试严格分离。本文将一条完整轨迹上的一次交互过程记为一个训练轮次 (epoch), 模型共训练 800 个训练轮次, 并每 20 个训练轮次在验证集上评估一次。除特别说明外, 文中表格结果均为 10 次独立训练-测试运行在全部测试轨迹上的平均值, 从而减小随机初始化和场景采样带来的偶然性影响。

为评估不同信号质量下的鲁棒性, 本文在无线电观测通道中引入加性高斯噪声, 并将信噪比 (Signal-to-Noise Ratio, SNR) 范围设置为 -10 dB 到 20 dB。实验中按等间隔采样多个 SNR 点, 对各算法在相同测试轨迹上的平均 RMSE 进行统计, 从而得到图 6 所示的性能变化曲线。该设置能够覆盖从强噪声退化到较高信号质量的典型区间, 用于考察算法在不利传播条件下的稳定性与适应性。

4.2 收敛性分析

在性能比较之前, 本文首先分析 PA-DQN 的训练收敛行为。图 4 给出了平均训练回报与验证集 RMSE 随训练轮次的变化趋势。在前约 200 个训练轮次内, 平均训练回报由约 -80 快速提升至 -40 附近, 验证集 RMSE 也由约 12 m 快速下降至 5 m 左右, 说明模型在训练初期已经能够从随机探索中学习到有效的调权规律。

在约 200-400 个训练轮次之间, 平均训练回报继续稳步提升, 验证集 RMSE 进一步下降至 3 m 左右, 但两条曲线的斜率已较初期减小, 表明模型开始由快速学习阶段转入参数细化阶段。约在 400 个训练轮次之后, 验证集 RMSE 的下降速度明显放缓, 平均训练回报进入平稳上升区间; 至 500-600 个训练轮次后, 两条曲线均基本进入平台期, 仅表现为小幅波动和缓慢改善, 说明 PA-DQN 已进入稳定收敛阶段, 未出现明显震荡或发散现象。

此外, 平均训练回报的提升与验证集 RMSE 的下降具有较好的同步性, 说明本文奖励函




图 4: PA-DQN 训练收敛曲线

数能够较准确地反映定位性能变化。图 4 整体表明, PA-DQN 在当前训练配置下能够稳定收敛, 后续的权重分配分析、性能比较与消融实验均建立在该稳定策略基础上。

4.3 权重分配与策略可解释性分析

为进一步分析策略行为, 表 1 给出了不同传播阶段下学习到的平均融合权重。随着 σ_τ 从稳定 LOS 阶段的 11.8234 ns 上升到深度 NLOS 阶段的 52.3176 ns, AoA 分支权重由 0.5076 下降至 0.1284, 而 PDR 权重由 0.2083 上升至 0.6277。该变化趋势说明, 当传播环境恶化、多径时延扩展增大时, 智能体会主动降低对更依赖直达路径的 AoA 分支的信任程度, 同时提高对短时连续性更好的 PDR 分支的依赖程度。

从进入 NLOS 阶段到深度 NLOS 阶段, 三类权重的变化并非突变式切换, 而是表现为平滑过渡: AoA 权重逐步下降, PDR 权重逐步上升, RSSI 权重则保持中等水平。这一现象与本文增量式动作设计相一致, 表明 PA-DQN 学到的是渐进调权策略, 而非基于单一阈值的硬切换规则。对于复杂城市环境中的连续传播变化而言, 这种渐进调整更有利于避免由局部观测异常导致的过度响应。

在恢复段中, σ_τ 回落至 19.7342 ns, AoA 与 RSSI 权重重新回升, PDR 权重则相应下降。这说明模型能够在传播条件恢复后重新利用无线电观测对惯导漂移进行纠偏, 而不是长期停留

表 1: 不同传播阶段下 PA-DQN 学习得到的平均融合权重

传播阶段	平均 σ_τ (ns)	w_{RSSI}	w_{AoA}	w_{PDR}
稳定 LOS	11.8234	0.2841	0.5076	0.2083
进入 NLOS	24.6179	0.3125	0.3418	0.3457
深度 NLOS	52.3176	0.2439	0.1284	0.6277
恢复段	19.7342	0.3016	0.3869	0.3115

在对 PDR 的高依赖状态。这一结果表明，PA-DQN 学习到的并非固定融合权重，而是与传播环境演化相对应的动态调权规律，这也是后续性能提升的重要原因之一。

4.4 定位性能比较

在完成训练收敛性和策略可解释性分析后，下面进一步从不同轨迹场景出发评估各算法的定位性能。考虑到矩形轨迹、线性轨迹和随机游走轨迹在运动几何结构、转向频率和传播条件变化方式上存在明显差异，若仅给出总体平均结果，容易掩盖不同场景下的误差特征。因此，本文分别统计三类典型轨迹场景下的 RMSE 和 P95 指标，以更细致地比较各方法在不同运动条件下的性能表现。其中，线性轨迹场景将对角线和反对角线两类路径合并统计，因为二者均属于长距离直线穿越类型，且误差分布特性相近。

表 2: 不同算法在全部测试轨迹上的平均定位性能

算法	RMSE (m)	P95 (m)
PDR-only	12.8347	21.4479
AoA-only	15.2086	25.8813
EKF	7.3364	13.0217
Q-Learning	5.9002	10.5578
PA-DQN	2.1468	3.8724

表 2 给出了全部测试轨迹上的平均定位性能。由表可见，PA-DQN 的 RMSE 和 P95 分别为 2.1468 m 和 3.8724 m，在整体测试集上均取得最低误差。与 EKF 相比，PA-DQN 的 RMSE 下降了 70.7%；与 Q-Learning 相比，RMSE 下降了 63.6%。这一结果表明，在综合考虑不同轨迹形态和传播条件变化后，物理感知状态、增量式动作机制和双重奖励函数的协同设计仍然能够稳定改善融合精度。总体平均结果按四类轨迹等权汇总，其中线性轨迹表对应对角线和反对角线两类场景。作为总体结果，表 2 与后续分场景表格形成互补：前者反映方法的整体性能水平，后者用于分析不同运动模式下的误差差异来源。

表 3: 矩形轨迹场景下不同算法的定位性能

算法	RMSE (m)	P95 (m)
PDR-only	13.7625	22.6854
AoA-only	15.9624	27.1168
EKF	7.9452	13.8826
Q-Learning	6.2148	11.2064
PA-DQN	2.2846	4.0613

表 3给出了矩形轨迹场景下的定位结果。该场景包含多个直角转向和边界切换，对算法的轨迹连续性保持能力提出了更高要求。表 3显示，PA-DQN 的 RMSE 和 P95 分别为 2.2846 m 和 4.0613 m，优于其他基线方法。相比之下，PDR-only 在长边运动后容易累积漂移，AoA-only 在转角附近更易受到遮挡和反射的影响，EKF 与 Q-Learning 虽然能够在一定程度上缓解单源误差，但在转向区段仍存在较明显的偏差放大现象。

表 4: 线性轨迹（对角线与反对角线）场景下不同算法的定位性能

算法	RMSE (m)	P95 (m)
AoA-only	13.4418	22.9547
PDR-only	11.4823	19.2146
EKF	6.2481	11.2375
Q-Learning	5.1026	9.1147
PA-DQN	1.8765	3.4027

表 4反映了线性轨迹场景下的结果。由于该类轨迹缺少频繁转角，整体运动形态相对平稳，因此各算法的误差水平普遍低于矩形和随机游走场景。在线性轨迹场景下，PDR-only 的性能优于 AoA-only，这说明当运动方向连续且转向较少时，PDR 的短时连续性能带来一定优势，而 AoA 观测仍会受噪声和局部传播异常影响。尽管如此，PA-DQN 仍以 1.8765 m 的 RMSE 和 3.4027 m 的 P95 保持最优，表明其优势并不依赖于高曲率轨迹，而在线性穿越场景中同样成立。

表 5: 随机游走轨迹场景下不同算法的定位性能

算法	RMSE (m)	P95 (m)
PDR-only	14.6117	24.6770
AoA-only	17.9884	30.4990
EKF	8.9042	15.7292
Q-Learning	7.1808	12.7954
PA-DQN	2.5496	4.6229

表 5给出了随机游走轨迹场景下的性能对比。该场景具有方向变化频繁、局部曲率不规则以及传播条件切换更复杂等特点。表 5显示，所有算法在该场景下的 RMSE 和 P95 均明显高于线性轨迹场景，其中单源方法的性能退化幅度最大；而 PA-DQN 仍将 RMSE 控制在 2.5496

m, P95 控制在 4.6229 m, 说明该方法在复杂运动模式和快速环境变化条件下仍能够保持较稳定的定位性能。

三类场景的结果均显示, 尽管不同场景的绝对误差水平存在差异, PA-DQN 在三类轨迹上都保持了最低 RMSE 和 P95, 其性能提升并不依赖于特定轨迹形态, 而具有较稳定的跨场景适应能力。




图 5: 四类典型轨迹下的算法轨迹对比

图 5给出了四类典型轨迹下的对比结果。对于矩形轨迹, PA-DQN 在长直边和拐角位置均能保持较好的几何一致性, 而单源方法以及部分基线方法在转角处更容易产生偏移和局部失真; 对于对角线和反对角线轨迹, PA-DQN 输出轨迹整体更贴近真实路径, 表明在较长连续路段中, 该方法能够持续控制误差累积; 对于随机游走轨迹, 由于运动形态更复杂、局部曲率变化更大, 单源方法与基线方法更容易出现局部抖动或偏离, 而 PA-DQN 仍保持了较平滑的轨迹形态。

图 5进一步反映出, PA-DQN 的改进不仅表现为点位误差更小, 也表现为路径结构保持能

力更强。在轨迹转折、进入遮挡区以及运动方向频繁变化的区段，PA-DQN 输出的轨迹局部偏离更小，且没有明显的跳变现象。这表明该方法能够根据环境变化持续调整不同观测分支的权重，使融合结果既保持较高精度，又满足连续定位任务对轨迹平滑性的要求。该现象与表 3 至表 5 中的分场景结果相互印证。

4.5 不同 SNR 条件下的鲁棒性分析

在复杂城市传播环境中，定位性能不仅取决于轨迹形态和遮挡分布，还与无线电观测的信号质量密切相关。尤其在低信噪比条件下，观测噪声会进一步放大 NLOS 和多径带来的不确定性，因此有必要单独分析各算法在不同 SNR 条件下的性能变化趋势。通过这一实验，可以考察 PA-DQN 在不利信号条件下是否仍能保持稳定的融合表现。




图 6: 不同信噪比条件下各算法 RMSE 对比

图 6 给出了不同信噪比条件下各算法的 RMSE 变化曲线。整体上，随着 SNR 由 -10 dB 提升至 20 dB，四条曲线均呈下降趋势，说明信号质量改善后各算法的定位误差都得到缓解。其中，PA-DQN 的曲线在整个 SNR 区间内始终位于最低位置，且下降过程更为平滑；当 SNR 从 -10 dB 增加到 0 dB 时，其 RMSE 由约 3.2 m 下降到约 1.1 m，随后在中高 SNR 区域进一步下降并稳定在 1 m 以下。该现象表明，PA-DQN 在强噪声条件下已经能够维持较低误差，而在信号质量改善后仍能持续获益。

在低 SNR 区域,不同算法之间的差异最为明显。在 -10 dB 附近, AoA-only 的 RMSE 约为 22 m, Q-Learning 约为 13.5 m, EKF 约为 10.4 m, 而 PA-DQN 仅约为 3.2 m。说明当无线电观测受强噪声污染时,单一角度观测最容易失稳,传统滤波与不含物理感知状态的强化学习方法虽然可以在一定程度上缓解误差,但仍难以有效抑制噪声放大效应。相比之下, PA-DQN 能够在低 SNR 条件下保持明显更小的误差,这说明其状态空间中的传播与一致性特征有助于及时识别不可靠观测并调整融合权重。

从中高 SNR 区域看,约在 8 dB 以后,各算法曲线均逐渐进入平台区,误差下降幅度明显减小。这表明当信号质量较高时,观测噪声不再是主导误差源,不同方法之间的性能差距会自然收敛。然而,即便在这一阶段, PA-DQN 仍保持最低 RMSE,说明其改进并不只来自对低 SNR 的抗扰能力,也来自整体融合机制对多源信息的更有效利用。图 6 显示, PA-DQN 在全 SNR 区间内均保持最低 RMSE,且在低 SNR 区域与其他方法的差距更为明显,这与本文物理感知动态调权的设计目标一致。

4.6 消融实验

为分析各关键设计的贡献,本文从完整 PA-DQN 框架中依次移除物理感知状态、增量动作机制和稳定性奖励项,并记录性能变化。结果如表 6 所示。通过这种方式,可以分别考察状态设计、动作设计和奖励设计对最终精度与轨迹平滑性的影响,而不是仅从整体结果判断模型优劣。

表 6 显示,去除物理感知状态后的性能退化最为显著, RMSE 从 2.1468 m 上升至 6.8875 m,说明环境感知相关特征仍是权重决策的基础。去除增量动作机制后, RMSE 上升至 4.5189 m,同时权重变化率由 0.0412 显著增大至 0.2764 ,表明该设计主要用于约束相邻时刻的策略跳变。去除稳定性奖励项后, RMSE 仅小幅上升至 2.4817 m,但权重变化率仍增加到 0.1689 ,说明该项的主要贡献在于抑制局部振荡而非改变总体决策趋势。

因此,表 6 从数值层面表明:物理感知状态决定环境识别能力,增量动作机制决定权重更新连续性,稳定性奖励项决定局部轨迹平滑性。这一结论与图 7 中的轨迹变化趋势保持一致。




图 7: 不同消融设置下的矩形轨迹对比

图 7 进一步从轨迹形态角度给出了不同消融设置下的结果对比。该图采用统一的矩形测试轨迹，四个子图分别对应完整 PA-DQN、去除物理感知状态、去除增量动作机制以及去除稳定性奖励项后的定位结果，因此可以直接比较不同设计对边界跟踪能力和局部平滑性的影响。

图 7(a) 显示，完整 PA-DQN 的输出轨迹与 Ground Truth 接近，四条边和转角区域均保持较高贴合度，说明完整模型能够在保持几何一致性的同时有效抑制局部扰动。图 7(b) 对应去除物理感知状态后的结果，此时轨迹已明显偏离矩形边界，尤其在上边界和右侧区域出现大幅外扩和整体偏移，表明缺少 σ_τ 、RSSI 方差和 RF-PDR 一致性等特征后，模型难以及时识别传播条件变化，导致异常观测不能被有效抑制。

图 7(c) 对应去除增量动作机制后的结果。该设置下虽然总体轮廓仍保持矩形结构，但沿边界方向出现更明显的波动、回摆和局部过冲，右边界附近尤为突出。这说明若直接输出权重而缺少渐进式调节机制，相邻时刻的策略更容易发生较大跳变，从而削弱轨迹边界跟踪的连续性。图 7(d) 对应去除稳定性奖励项后的结果。该设置下轨迹整体仍围绕矩形边界分布，但沿四条边均出现连续的小幅抖动，在转角附近也有更明显的局部散布，说明稳定性奖励项主要用于抑制短时策略振荡，而不是改变总体路径趋势。

结合图 7 与表 6，可以发现物理感知状态、增量动作机制和稳定性奖励项分别对应环境识别能力、权重更新连续性和局部轨迹平滑性。三者不仅影响 RMSE 和权重变化率等数值指标，也直接决定最终轨迹形态，这进一步验证了完整 PA-DQN 在精度与稳定性之间实现协同优化的必要性。

表 6: PA-DQN 框架的消融实验结果

模型变体	RMSE (m)	权重变化率
Full PA-DQN	2.1468	0.0412
w/o Physics-Aware State	6.8875	0.0936
w/o Incremental Action	4.5189	0.2764
w/o Stability Reward	2.4817	0.1689

5 结论

本文提出一种面向复杂城市环境的物理感知深度强化学习自适应融合方法 PA-DQN。该方法将 RMS 时延扩展等物理先验引入状态空间,并结合增量动作机制与双重奖励设计,实现了传播环境变化下的动态调权融合。与传统依赖固定噪声模型或后验误差驱动的融合方法相比,本文方法能够更早感知环境退化,并据此调整不同观测分支的贡献。

实验结果表明,PA-DQN 在总体测试集上的平均 RMSE 为 2.1468 m,相较 EKF 和 Q-Learning 分别提升 70.7% 和 63.6%。收敛性分析、传播阶段权重分配结果和消融实验从不同角度支撑了该方法在策略稳定性、环境适应性和多模块协同设计方面的有效性。整体结果显示,将传播物理信息显式引入强化学习决策过程,有助于提升复杂 NLOS 场景下的定位性能与稳定性。

本文结论目前主要建立在高保真仿真环境基础上,真实环境中物理特征的在线获取与代理构造仍需进一步研究。后续工作将围绕真实环境中的代理物理特征构造、仿真到实测迁移验证以及更复杂动态场景下的自适应融合展开。

参考文献 (References)

- [1] CHAN Y T, HO K C. A simple and efficient estimator for hyperbolic location[J]. IEEE Transactions on Signal Processing, 1994, 42(8): 1905-1915.
- [2] WANG Y, HO K C. TDOA-based localization with NLOS mitigation via robust model transformation and neurodynamic optimization[J]. IEEE Transactions on Signal Processing, 2013, 61(8): 1983-1996.
- [3] MA C, PAN S, GAO W, et al. An improved multiple-outlier-robust Kalman filter for GNSS/INS tightly coupled positioning in urban canyons[J]. IEEE Internet of Things Journal, 2025, 12(22): 48131-48145.
- [4] XU R, CHEN S, BAI S, et al. Nonlinearity-aware ZUPT-aided pedestrian inertial navigation based on cubature Kalman filter in urban canyons[J]. IEEE Transactions on Instrumentation and Measurement, 2024, 73: 1-13.

- [5] ZHANG H, CHEN C C, VALLERY H, et al. GNSS/Multi-sensor fusion using continuous-time factor graph optimization for robust localization[J]. IEEE Transactions on Robotics, 2024, 40: 4003-4023.
- [6] WYMEERSCH H, LIEN J, WIN M Z. Cooperative localization in wireless networks[J]. Proceedings of the IEEE, 2009, 97(2): 427-450.
- [7] GÜVENÇ I, CHONG C C. A survey on TOA-based wireless localization and NLOS mitigation techniques[J]. IEEE Communications Surveys & Tutorials, 2009, 11(3): 107-124.
- [8] DE SOUSA M N, THOMÄ R S. Enhancement of localization systems in NLOS urban scenario with multipath ray tracing fingerprints and machine learning[J]. Sensors, 2018, 18(11): 4073.
- [9] STOCK W, SCHWARZ R, HOFMANN C, et al. Survey on opportunistic PNT with signals from LEO communication satellites[J]. IEEE Communications Surveys & Tutorials, 2025, 27(1): 77-107.
- [10] KOZHAYA S, SAROUFIM J, KASSAS Z M. Unveiling Starlink for PNT[J]. NAVIGATION: Journal of the Institute of Navigation, 2025, 72(1): navi.685.
- [11] GAPEYENKO M, ANDREEV S, KOUCHERYAVY Y, et al. On modeling satellite-to-ground path-loss in urban environments[J]. IEEE Communications Letters, 2017, 21(3): 694-697.
- [12] MNIH V, KAVUKCUOGLU K, SILVER D, et al. Human-level control through deep reinforcement learning[J]. Nature, 2015, 518(7540): 529-533.
- [13] SALIMIBENI M, MOHAMMADI A. Hybrid indoor localization via reinforcement learning-based information fusion[EB/OL]. arXiv:2210.15132, 2022.
- [14] WONG C C, FENG H M, KUO K L. Multi-sensor fusion simultaneous localization mapping based on deep reinforcement learning and multi-model adaptive estimation[J]. Sensors, 2024, 24(1): 48.
- [15] WANG Y, HO I W H, ZHANG S, et al. Intelligent reflecting surface enabled fingerprinting-based localization with deep reinforcement learning[J]. IEEE Transactions on Vehicular Technology, 2023, 72(10): 13162-13172.
- [16] DOU F, LU J, ZHU T, et al. On-device indoor positioning: A federated reinforcement learning approach with heterogeneous devices[J]. IEEE Internet of Things Journal, 2024, 11(3): 3909-3926.

- [17] FENG Q, TANG T, WU Z, et al. A deep reinforcement learning-based shortwave multistation autonomous cooperative direction finding and localization method[J]. IEEE Sensors Journal, 2024, 24(23): 40123-40136.
- [18] PENG B, SECO-GRANADOS G, STEINMETZ E M, et al. Decentralized scheduling for cooperative localization with deep reinforcement learning[J]. IEEE Transactions on Vehicular Technology, 2019, 68(5): 4295-4305.
- [19] JIA Y, LUO H, ZHAO F, et al. Lvio-Fusion: A self-adaptive multi-sensor fusion SLAM framework using actor-critic method[C]//Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems. 2021: 286-293.
- [20] WU G. UAV-based interference source localization: A multimodal Q-learning approach[J]. IEEE Access, 2019, 7: 137982-137991.
- [21] ETIABI Y, JOUHARI M, AMHOUD E M. Spreading factor and RSSI for localization in LoRa networks: A deep reinforcement learning approach[EB/OL]. arXiv:2205.11428, 2022.
- [22] WATKINS C J C H, DAYAN P. Q-learning[J]. Machine Learning, 1992, 8(3-4): 279-292.