

密级： 保密期限：

北京邮电大学

博士学位论文



题目： 基于稀疏表征的多源定位技术研究

学 号： 2016010069

姓 名： 游 康 勇

专 业： 信息与通信工程

导 师： 郭 文 彬

学 院： 信息与通信工程学院

2020 年 12 月 29 日

**Research on Multiple Co-channel Sources Localization
Based on Sparse Representation**

**A DISSERTATION
SUBMITTED TO THE FACULTY OF THE GRADUATE
SCHOOL OF BEIJING UNIVERSITY OF POSTS AND
TELECOMMUNICATIONS**

**BY
DOCTOR
You Kangyong**

**FOR THE DEGREE OF
DOCTOR OF PHILOSOPHY IN
INFORMATION AND COMMUNICATIONS ENGINEERING**

**PROF. Guo Wenbin, PH.D. ADVISOR
BEIJING, CHINA
DEC. 2020**

独创性（或创新性）声明

本人声明所呈交的论文是本人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京邮电大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

本人签名：_____ 日期：_____

关于论文使用授权的说明

本人完全了解并同意北京邮电大学有关保留、使用学位论文的规定，即：北京邮电大学拥有以下关于学位论文的无偿使用权，具体包括：学校有权保留并向国家有关部门或机构送交学位论文，有权允许学位论文被查阅和借阅；学校可以公布学位论文的全部或部分内容，有权允许采用影印、缩印或其它复制手段保存、汇编学位论文，将学位论文的全部或部分内容编入有关数据库进行检索。（保密的学位论文在解密后遵守此规定）

本人签名：_____ 日期：_____

导师签名：_____ 日期：_____

基于稀疏表征的多源定位技术研究

摘 要

辐射源定位技术在国防军事等诸多领域发挥着重要作用。随着辐射环境日益复杂,传统的单源定位已难以满足实际需求,共信道多源定位技术的重要性日益凸显。然而,共信道多源定位问题高度非凸非线性,难以直接求解。近年来,稀疏表征方法为共信道多源定位问题的求解提供了一个崭新的视角。本文在综述了多源定位的最新研究进展的基础上,针对基于稀疏表征的多源定位中存在的结构信息挖掘问题、基不匹配问题、维数灾难问题及阴影衰落信道下的多源定位问题等四个方面展开较为系统和深入的研究。本文的主要内容如下:

1. 从能量域、角度域、时间域多源定位模型中归纳出广义多源定位模型,抽象出广义多源定位问题。提出的广义多源定位模型不仅能够表示具体的多源定位模型,也能够表示信道估计、频谱感知、MIMO 雷达、语音信号处理等诸多应用中的相关模型。本文的研究基于广义多源定位模型展开,提出的算法具有一定的普适性。

2. 针对多源定位中的结构信息挖掘的问题,提出了一种新颖的层级贪婪匹配算法 HGMP,证明了文献中广泛采用的正交化预处理操作降低信噪比。HGMP 算法由全局估计层和稀疏恢复层组成。其中,全局估计层利用残差投影聚簇结构分离出信号子空间,稀疏恢复层在信号子空间中利用正交匹配追踪算法实现鲁棒性贪婪定位。理论分表明, HGMP 算法具有渐进线性复杂度 $\mathcal{O}(KMN)$, 具有比 OMP 更强的噪声鲁棒性。仿真表明,提出的 HGMP 算法以远低于 BP 算法的计算复杂度,实现了比 BP 算法和 OMP 算法更优越的定位性能。

3. 针对多源定位中由网格失配和模型参数误差带来的基不匹配问题,提出了一种参数化稀疏贝叶斯字典学习算法 PSBDL。相比传统基于稀疏表征的多源定位算法, PSBDL 算法补全了字典学习和稀疏恢复的闭环优化逻辑。此外,我们详细推导了 PSBDL 算法在实信号/复信号、SMV/MMV 观测模型下的四种表现形式。理论分析表明, PSBDL 算法的复杂度为 $\mathcal{O}(MN^2)$ 。仿真表明所提算法具有比传统算法更优越的参数估计性能,能够有效解决基不匹配下的多源定位问题。

4. 针对大规模高维场景中的"维数灾难"问题给稀疏重建算法在计算效率、存储需求、系统辨识能力上带来的挑战,提出了一种快速证据下界最大化稀疏贝叶斯学习算法 FEMSBL。理论分析表明, FEMSBL 算将传统的 EMSBL 算法的计算复杂度从 $\mathcal{O}(MN^2)$ 降低到 $\mathcal{O}(MN)$ 。数值仿真表明 FEMSBL 能够高效可靠地求解大规模稀疏恢复问题,有效缓解"维数灾难"问题带来的挑战。将 FEMSBL 算法与 PSBDL 算法

结合, 我们提出一种参数化稀疏贝叶斯字典学习快速算法 FPSBDL。理论分析表明, FPSBDL 算法将 PSBDL 算法的计算复杂度从 $\mathcal{O}(MN^2)$ 降低到 $\mathcal{O}(MN)$ 。仿真验证了 FPSBDL 算法相对于 PSBDL 算法在计算复杂度和系统辨识能力上的显著提升。

5. 针对阴影衰落信道下的多源定位问题, 提出了一种新颖的两阶段最大似然多源定位算法 TSML。在 TSML 算法的辐射源参数捕获阶段, 通过对观测模型进行泰勒级数展开, 我们将初值捕获问题转化为稀疏恢复问题, 并对恢复系数进行聚类加权, 快速捕获辐射源参数的初值。在 TSML 算法的辐射源参数跟踪阶段, 我们采用 Fenton-Wilkinson 方法对观测变量的分布进行逼近, 提出一种最大似然估计器并采用贯序二次规划方法 (SQP) 进行求解。我们对 TSML 算法的时间复杂度和全局收敛性作出了理论分析, 并通过数值仿真验证了 TSML 算法的相对传统的 MMSE 算法的性能提升。

关键词: 多源定位 稀疏表征 结构信息挖掘 基不匹配 维数灾难 阴影衰落

Research on Multiple Co-channel Sources Localization Based on Sparse Representation

ABSTRACT

Source localization plays an important role in many fields such as defense and military applications. With the increasingly complex radiation environment, traditional single-source localization technology has been difficult to meet actual requirements, and the importance of co-channel multiple sources localization (MSL) technology has become more and more prominent. However, the MSL problem is highly non-convex and nonlinear, and thus is hard to solve directly. In recent years, sparse representation has provided a novel perspective for MSL. Based on the review of the latest research progress, this paper addresses the four main challenges in sparse representation based MSL, i.e., structural information mining problems, basis mismatch problems, dimensionality disaster problems, and MSL problem in shadow fading channels. Systematic and in-depth research has been conducted in these four aspects. The main content and contributions of the thesis are summarized as follows:

1. A novel generalized MSL model is summarized from the energy-, angle-, and time-domain MSL models, and a generalized MSL problem is proposed. The proposed generalized MSL model can represent related models in many applications such as channel estimation, spectrum sensing, MIMO radar, and speech signal processing, not limited to the specific MSL model. Since the research is based on the generalized MSL model, thus algorithms proposed in the thesis can be also applied to many other applications.

2. A novel hierarchical greedy matching pursuit algorithm (HGMP) is proposed to solve the problem of structural information mining, and we also prove that the widely-used orthogonalization preprocessing operation reduces the signal-to-noise ratio. The HGMP algorithm is composed of a global estimation layer and a sparse recovery layer, where the global estimation layer exploits the cluster structure of the residual projection to separate the signal subspace, and the sparse recovery layer use orthogonal matching pursuit algorithm in the signal subspace to achieve robust greedy localization. Theoretical analysis shows that the progressive complexity of HGMP is $\mathcal{O}(KMN)$, and that HGMP has stronger noise robustness than OMP. Simulation results show that HGMP achieves better localization performance than BP and OMP algorithm, while the computational complexity is much lower than BP.

3. A parameterized sparse Bayesian dictionary learning algorithm (PSBDL) is proposed to address the basis mismatch problem caused by grid mismatch and model parameter error. Compared with the traditional sparsity based MSL methods, PSBDL completes the closed-loop optimization logic of dictionary learning and sparse recovery. Besides, we deduced in detail the four manifestations of the PSBDL algorithm under the real /complex signal model and SMV/MMV observation models. Theoretical analysis shows that the complexity of the PSBDL algorithm is $\mathcal{O}(MN^2)$. Simulation results show that the proposed algorithm has superior parameter estimation performance than traditional algorithms, and can effectively solve the basis mismatch problem in MSL.

4. A novel sparse Bayesian learning algorithm (FEMSBL) based on fast evidence lower bound maximization is proposed to tackle the challenges of traditional sparse Bayesian learning methods, brought by the "curse of dimensionality" problem in large-scale high-dimensional scenarios, in terms of computational efficiency, storage requirements, and system identification. Theoretical analysis shows that FEMSBL algorithm reduces the computational complexity of the traditional EMSBL algorithm from $\mathcal{O}(MN^2)$ to $\mathcal{O}(MN)$. Numerical simulation shows that FEMSBL can solve the large-scale sparse recovery problem efficiently, and can alleviate the challenges effectively. Combining the FEMSBL algorithm with the PSBDL algorithm, we propose a fast parameterized sparse Bayesian dictionary learning algorithm (FPSBDL). Theoretical analysis shows that the FPSBDL algorithm reduces the computational complexity of the PSBDL algorithm from $\mathcal{O}(MN^2)$ to $\mathcal{O}(MN)$. Simulation results verify the significant improvement of FPSBDL algorithm in computational complexity and system identification, compared with the PSBDL algorithm.

5. A novel two-stage maximum likelihood algorithm (TSML) is proposed to handle the MSL problem in shadow fading channels. In the capture stage of the TSML algorithm, by performing Taylor series expansion on the observation model, we convert the initial source parameter capture problem into a sparse recovery problem, and perform clustering and weighting on the recovery coefficient to quickly capture the initial value of the source parameter. In the tracking stage of the TSML algorithm, we use the Fenton-Wilkinson method to approximate the distribution of the observed variables, and propose a maximum likelihood estimator solved with the sequential quadratic programming (SQP) method. Theoretical analysis of the computational complexity and global convergence property of the TSML algorithm is conducted, and simulation results verify the performance improvement of the TSML algorithm compared to the traditional MMSE algorithm.

KEY WORDS: Mutiple source localization Sparse representation Structural information mining Basis mismatch Curse of dimensionality Shadow fading channel

目 录

摘 要	i
ABSTRACT	iii
目 录	v
图目录	ix
表目录	xi
符号列表	xiii
第一章 绪论	1
1.1 研究背景与意义	1
1.2 多源定位技术研究现状	4
1.2.1 能量域多源定位	5
1.2.2 角度域多源定位	7
1.2.3 时间域多源定位	9
1.2.4 多域测量融合的混合定位	10
1.2.5 研究现状分析和总结	10
1.3 论文主要内容及结构安排	12
1.3.1 论文主要内容	12
1.3.2 论文结构安排	13
第二章 数学基础和系统建模	15
2.1 引言	15
2.2 预备数学基础知识	15
2.2.1 重要不等式	15
2.2.2 矩阵运算相关定理	16
2.2.3 概率分布和概率推理	18
2.2.4 克拉美罗下界	20
2.3 基于稀疏表征的多源定位	21

2.3.1	具体的多源定位问题	22
2.3.2	广义的多源定位问题	29
2.3.3	基于稀疏表征的多源定位问题	30
2.4	稀疏恢复算法	31
2.4.1	贪婪类方法	32
2.4.2	优化类方法	34
2.4.3	概率类方法	35
2.4.4	各类算法的优势与局限	39
2.5	本章小结	39
第三章	基于层级贪婪匹配追踪的多源定位	41
3.1	引言	41
3.2	基于正交化预处理的多源定位模型	42
3.2.1	多源定位模型中的约束关系	42
3.2.2	正交化预处理模型及其不足	43
3.2.3	研究动机和目的	44
3.3	多源定位中的结构信息	45
3.3.1	聚簇特征	46
3.3.2	冗余信息	47
3.4	层级贪婪匹配追踪算法	47
3.4.1	算法流程	47
3.4.2	算法复杂度分析	49
3.4.3	收敛性和鲁棒性分析	49
3.5	算法性能仿真	50
3.5.1	德劳内三角网格剖分	50
3.5.2	仿真设置	51
3.5.3	仿真结果和分析	52
3.6	证明	54
3.6.1	定理 3.2 的证明	54
3.6.2	定理 3.3 的证明	55
3.7	本章小结	55
第四章	基于参数化稀疏贝叶斯字典学习的多源定位	57
4.1	引言	57
4.2	多源定位中的参数化字典学习问题	58

4.2.1	多源定位中的基不匹配问题	58
4.2.2	基于字典学习和稀疏表征的多源定位问题	59
4.3	实信号模型下的参数化稀疏贝叶斯字典学习算法	59
4.3.1	SMV 实信号模型下的参数化稀疏贝叶斯字典学习算法	60
4.3.2	MMV 实信号模型下的参数化稀疏贝叶斯字典学习算法	63
4.4	复信号模型的参数化稀疏贝叶斯字典学习算法	65
4.4.1	SMV 复信号模型下的参数化稀疏贝叶斯字典学习算法	65
4.4.2	MMV 复信号模型下的参数化稀疏贝叶斯字典学习算法	67
4.5	算法小结	69
4.6	算法性能仿真	69
4.6.1	网格失配下的 SMV 能量域多源定位	69
4.6.2	网格失配下的 MMV DOA 估计	71
4.6.3	不确定路损指数下的 MMV 能量域多源定位	74
4.7	证明和推导	77
4.7.1	定理 4.1 的证明	77
4.7.2	式(4-15)的推导	77
4.7.3	SMV 模型下能量域多源定位的 CRLB 推导	78
4.7.4	不确定传播参数下能量域多源定位的 CRLB 推导	79
4.8	本章小结	80
第五章	面向大规模高维场景的快速多源定位	81
5.1	引言	81
5.2	快速证据下界最大化稀疏贝叶斯学习算法	83
5.2.1	MMV 实信号稀疏贝叶斯学习	83
5.2.2	证据下界的性质	84
5.2.3	快速证据下界最大化算法	87
5.2.4	算法复杂度与收敛性分析	88
5.3	参数化稀疏贝叶斯字典学习快速算法	90
5.4	算法性能仿真	92
5.4.1	仿真结果和分析	92
5.5	证明和推导	94
5.5.1	式(5-16)的推导	94
5.5.2	引理 5.1 的证明	95
5.5.3	引理 5.2 的证明	95

5.6 本章小结	95
第六章 阴影衰落信道下的多源定位	97
6.1 引言	97
6.2 阴影衰落下的能量域多源定位模型	98
6.3 基于稀疏表征和分布逼近的两阶段最大似然多源定位	99
6.3.1 基于 F-W 逼近方法的 MMSE 多源定位	100
6.3.2 两阶段最大似然多源定位	101
6.3.3 算法流程	104
6.3.4 算法复杂度和收敛性分析	105
6.4 算法性能仿真	105
6.4.1 仿真设置	105
6.4.2 仿真结果和分析	106
6.5 推导过程	107
6.5.1 式(6-6)的推导	107
6.5.2 目标函数梯度和约束函数 Jacobi 矩阵的推导	108
6.6 本章小结	108
第七章 总结与展望	109
7.1 本文工作总结	109
7.2 本文工作展望	110
参考文献	111
附录一 缩略语列表	131
致 谢	135
攻读学位期间发表的学术论文目录	137

图目录

1-1	目标定位技术分类	1
1-2	典型的定位节点能耗示意图	3
1-3	全文组织结构图	13
2-1	基于 WSN 的多源定位示意图	22
2-2	均匀线阵 DOA 估计模型	24
2-3	基于纯方位角的多源定位示意图	26
2-4	二维情况下的条件分布和边缘分布	36
3-1	层级贪婪匹配追踪架构	45
3-2	多源定位中的聚簇特征	46
3-3	感知空间的均匀矩形剖分和德劳内三角剖分	50
3-4	噪声对定位性能的影响	52
3-5	不同噪声水平下的平均运行时间	53
3-6	定位节点个数对定位性能的影响	53
4-1	SMV 情况下的层级概率图模型	60
4-2	MMV 情况下的层级概率图模型	63
4-3	网格点集合 $\mathcal{G}^{(l)}$ 的学习过程	70
4-4	不同噪声水平和能量定位节点数目下的定位性能	71
4-5	不同信噪比和快拍数下的归一化空间谱	72
4-6	不同信噪比、快拍数、网格间距下的 DOA 估计性能	73
4-7	不同网格密度、信噪比、快拍数、定位节点数目下的均方根定位误差	76
5-1	不同原子数目下 FEMSBL 算法和 EMSBL 算法的稀疏恢复性能对比	89
5-2	不同网格密度、信噪比、快拍数、定位节点数目下的均方根定位误差	93
6-1	阴影衰落下能量域多源定位示意图	98
6-2	基于聚类加权的辐射源位置捕获结果	103
6-3	不同阴影衰落标准差下的辐射源定位误差 ($M = 100$)	106
6-4	不同定位节点数目下的辐射源定位误差	107

表目录

1-1 不同观测量的定位性能比较	2
2-1 广义多源定位模型与具体模型的联系	30
4-1 不同定位场景中的模型参数	59
4-2 SMV 模型和 MMV 模型下实信号、复信号参数化字典学习算法的对比	68
4-3 不同网格密度、信噪比、快拍数、定位节点数目下路损指数 γ 的均方根估计误差	75
5-1 不同原子数目下 FEMSBL 算法和 EMSBL 算法的平均运行时间	90
5-2 不同网格密度、信噪比、快拍数、定位节点数目下路损指数 γ 的均方根估计误差	92
5-3 不同网格密度和定位节点数目下的平均运行时间（单位：秒）	94

符号列表

$\emptyset$	空集
$\{\cdot\}$	向量或矩阵的共轭运算
$\{\cdot\}^H$	向量或矩阵的共轭转秩运算
$\{\cdot\}^T$	向量或矩阵的转秩运算
$\{\cdot\}^\dagger$	矩阵的 Moore-Penrose 逆
$\circ$	Hadamard 乘积 (逐元素乘积)
$\otimes$	Kronecker 乘积
$\text{vec}\{\cdot\}$	矩阵矢量化算子 (按矩阵元素的字典序排列)
$\text{ivec}\{\cdot\}$	逆矩阵矢量化算子
$\text{diag}\{\mathbf{x}\}$	由向量 $\mathbf{x}$ 构成的对角矩阵
$\text{diag}\{\mathbf{X}\}$	由矩阵 $\mathbf{X}$ 主对角线元素构成的列向量
$\text{tr}\{\cdot\}$	矩阵的迹
$\det\{\cdot\}$	矩阵的行列式
$\text{Rank}(\cdot)$	方阵的秩
$\text{eig}(\cdot)$	求矩阵的所有特征值
x_i	向量 $\mathbf{x}$ 的第 i 个元素
$[\mathbf{X}]_{ij}$ 或 X_{ij}	矩阵 $\mathbf{X}$ 的第 i 行第 j 列元素
$\mathbf{X}^i$	矩阵 $\mathbf{X}$ 的第 i 行元素
$\mathbf{X}(i:j, p:q)$	MATLAB 语法表示的矩阵切片
$\mathbf{X}_j$	矩阵 $\mathbf{X}$ 的第 j 列元素
$\mathbf{X}_{M \times N}$	$M \times N$ 的矩阵 $\mathbf{X}$
$\mathbf{1}_N$	N 维全 1 列向量
$\mathbf{0}_{M \times N}$	$M \times N$ 维全 0 矩阵
$\mathbf{I}_N$	N 维单位矩阵
$\ \mathbf{x}\ _0$	向量 $\mathbf{x}$ 的 ℓ_0 伪范数
$\ \mathbf{x}\ _1$	向量 $\mathbf{x}$ 的 ℓ_1 范数
$\ \mathbf{x}\ _2$	向量 $\mathbf{x}$ 的 ℓ_2 范数
$\ \mathbf{x}\ _p$	向量 $\mathbf{x}$ 的 ℓ_p 范数
$\ \mathbf{X}\ _F$	矩阵 $\mathbf{X}$ 的 Frobenius 范数
$ x $	实数 x 的绝对值
$\text{var}(\cdot)$	求序列的方差
$\text{Re}\{\cdot\}$ 和 $\text{Im}\{\cdot\}$	分别指取实部和取虚部

$\mathbb{R}^{M \times N}$	$M \times N$ 实矩阵集合
$\mathbb{C}^{M \times N}$	$M \times N$ 复矩阵集合
$\mathbb{R}_{++}^{N \times N}$	N 阶实对称正定矩阵
$\mathbb{E}\{\cdot\}$	求期望算子
$\mathbb{D}\{\cdot\}$	求方差算子
$:=$	表示变量或函数的定义
∇	Nabla 算子
$\succeq$ 和 $\preceq$	广义不等式
(u, v)	2D 感知区域的笛卡尔坐标系
$\forall$	对任意集合元素
$\exists$	存在一个集合元素
$\langle \cdot, \cdot \rangle$	内积算子
$\cap$ 和 $\cup$	集合的交和并操作
$\mathbb{A} \setminus \mathbb{B}$	集合 $\mathbb{A}$ 和集合 $\mathbb{B}$ 的差集
$(\cdot)_+$	取正算子 $(x)_+ = \max\{0, x\}$
$\text{card}(\cdot)$	集合的基数 (集合中元素的数目)

第一章 绪论

1.1 研究背景与意义

众所周知，定位技术(即获取目标物体的空间位置参数)一直是信号处理领域中的热点问题，其发展最早可追溯到第一次世界大战中发明的声波定位器和二十世纪三十年代问世的军用雷达^[1]。几十年来，伴随着电子通信技术的进步，定位技术在雷达^[1]、声呐^[2]、导航^[3]、遥感遥测^[4]、射电天文^[5]、无线通信网络^[6]、认知无线电^[7]、无线传感器网络(Wireless Sensor Network, WSN)^[8]等诸多领域获得广泛应用和迅猛发展，在工业生产、商业应用和国防军事领域中发挥着重要作用^[9-11]。

如图1-1所示，站在己方定位平台的角度，获取目标定位技术可分为有源定位技术和无源定位技术。有源定位系统依靠己方传感器平台主动向外发射声波、电磁波、激光等定位信号，该信号遇到目标物体后在接触面发生反射，有源定位系统通过测量和处理反射信号来精确定位目标位置。有源定位技术具有全天候、高精度等优点。然而，其经受双程传播衰减，对定位设备的发送功率要求高，设备体积庞大，定位距离有限。因反射信号的强弱依赖于目标的反射面积，所以其对具有隐身性能的目标探测能力较弱。同时，因其向外辐射信号，容易被侦测和反向定位，进而受到敌对势力的干扰和打击，从而大幅降低定位性能甚至威胁自身安全^[9,12]；与之相对，无源定位系统对外不发送定位信号，依靠测量和处理目标物体主动辐射或者被动散射的信号(电磁波，声波等)准确提取出目标物体的位置参数^[9,13-17]。无源定位系统只经受单程传播衰减，作用距离远高于有源定位系统。因其不对外发射定位信号，无需建造庞大且昂贵的大功率发射机，所以重量轻，体积小，同时也难以被对方侦测到，隐蔽性好，生存能力强，具有较高的抗干扰能力。此外，无源定位系统不存在有源定位系统中遇到的地、海杂波干扰问题，对低空目标具有较强的探测能力。更重要的是，无源定位系统空域覆盖范围广，工作频带宽，能以较高的信号截获概率对多种类型的辐射源进行定位。因此，无源定位技术作为有源定位技术的有力补充，受到国内外学者和相关机构的广泛关注和深入研究。




图 1-1 目标定位技术分类

一般而言,无源定位系统具有两类工作方式^[9]。第一类工作方式是利用目标物体自身的辐射信号进行定位,简称为辐射源定位^[16,18-25];第二类利用外辐射源(合作或非合作)通过目标物体反射或散射的辐射信号进行定位^[26-28],简称为外辐射源定位。本文重点关注第一类无源定位技术,即辐射源定位技术。

通常,辐射源定位体制由可用观测量决定,而定位系统的构成决定观测量的可用性。用于获取辐射源位置信息的观测量主要有:能量域观测,如接收信号强度(Received Signal Strength, RSS)^[16,29-33];角度域观测,如波达方向角(Direction of Arrival, DOA)^[23-24,34-37];时间域观测,如波达时间(Time of Arrival, TOA)、波达时间差(Time Difference of Arrival, TDOA)^[25,38-39];频率域观测,如波达频率差(Frequency Difference of Arrival, FDOA)(又称差分多普勒)^[40-42]。如表1-1所示,不同观测量对定位系统感知设备的构成要求不同,能获得的定位精度也有区别。比如,DOA 测量需要定位节点具备方向性天线或阵列天线,TDOA, FDOA 观测需要各定位节点具有精确时间同步、可靠相干解调、高速模数转换(Analog-to-Digital Convention, ADC),通常基于这些观测量的定位方法具有较高的定位精度,被广泛应用于国防军事等对定位精度要求严格的领域。相对而言,RSS 测量无需复杂的额外硬件设备,很容易从已有电子系统中获得,因而在通信、物联网(Internet of Things, IoT)^[43]、传感器网络等对定位精度要求相对较低的领域中得到大量应用。

按照定位方式,辐射源定位可分为直接定位方式^[18-20]和两步定位方式^[16,21-25]。直接定位的基本思想是信息融合中心利用各定位节点采集的原始数据对目标辐射源进行定位。其直接从原始的波形域中提取目标位置参数,能够利用所有的测量信息。从信息论角度来看,该方法能够减少由中间处理步骤所带来的信息损失,在理论上能够获得最优的定位精度。但是,在具体实现中,直接定位方法需要将各定位节点的原始数据回传中心节点集中处理,对系统的通信带宽、存储能力、计算资源要求严格^[44]。与之相对,两步定位中各定位节点首先对原始观测波形从能量、时间、角度、频率域上进行信息提取,获得上述 RSS、DOA、TOA、TDOA、FDOA 等观测量,然后再从这些观测量中获取目标物体的位置参数。虽然较直接定位方式略有定位精度损失,但两步定位方式无需回传所有原始数据,对定位系统的通信带宽、存储能力、计算资源要求较为宽松,易于工程实现,因而在实际中得到广泛应用。

表 1-1 不同观测量的定位性能比较

观测量	成本	对硬件的要求	定位精度
RSS	低	低	低
DOA	较高	较高	中
TOA/TDOA	高	高	很高
FDOA	高	高	高

步入二十一世纪,无线传感器网络 (WSN)^[8] 作为信息科学领域中一个全新的发展方向,在过去的十多年中受到学术界、工业界和各国政府的广泛关注,成为在国防军事、环境、医疗、智能家居、复杂机械监控、智慧城市、深空探索、工业 4.0 等众多领域中最有竞争力的应用技术之一^[45]。其中,基于 WSN 的辐射源定位技术受到国内相关机构和专家学者的深切关注,其在无线位置服务、搜索救援、安全防卫、监测监管等领域中被广泛应用,并在诸如自动驾驶、物联网、车联网、5G 应用^[46-47] 等新兴场景中展现出巨大潜力。通常,基于 WSN 的辐射源定位在感知区域内部署大量的定位节点(分布式多站定位),这些定位节点被动感知目标辐射源的辐射信号(电磁波,声波等),然后通过对感知信号的协同处理获取目标辐射源的空间位置参数,并为相关态势感知和决策功能提供支持。WSN 中的定位节点一般由传感器模块、微控制器模块、无线电收发模块、供能模块组成。其中传感器模块负责测量辐射信号,微控制器负责节点的本地计算,无线电收发模块负责与其他节点通信,供能模块通过电池或者能量采集 (Energy Harvesting, EH) 电路为整个定位节点提供能量支持。在实际应用中,WSN 往往被部署在无人值守的环境中。WSN 的一个重要目标即尽可能地节省能量消耗,以期长时间工作。图 1-2 展示了典型的定位节点能耗分布情况^[48]。由图可知,定位节点的能耗主要由无线通信模块的无线数据发送、无线数据接收、空闲等待决定。所以,为提高 WSN 的生存时间,一般倾向于对采集的数据进行预处理或压缩,然后再回传给中心节点。由此可见,基于 WSN 的辐射源定位是一个能量供应、通信带宽、计算资源受限的系统。所以在实际应用中,基于 WSN 的辐射源定位一般采取两步定位方式,很少采用直接定位方式。因此,本文从基于 WSN 的辐射源定位应用背景出发,重点研究基于两步定位模式的辐射源定位技术。

值得注意的是,传统的基于 WSN 的辐射源定位方法只考虑单源定位问题。然而,感知区域内可能存在多个共信道辐射源,每个定位节点的观测信号是多个共信道辐射源辐射信号的叠加耦合,且因传感器功能的限制该叠加不可被定位节点解耦接收。如: 1) 在基于声音传感器网络的低空无人机预警及定位、枪声定位、敌方坦克车辆定位等应用中,多个声源在同一频段内同时发声,定位节点的接收信号是多个声源信号在能量域、角度域、时间域的耦合^[44]; 2) 在认知无线电中,主用户和从用户共享相




图 1-2 典型的定位节点能耗示意图

同的时间和频率资源，定位节点感知到的信号是主用户和从用户在时频域的叠加信号^[7,33]；3) 在无线电频谱监控中，非法电台或干扰源占用合法用户的时频资源，定位节点的接收数据是多种电磁信号的叠加；4) 在电子对抗中，敌方从多个地点同时对我方设备进行电磁干扰和压制，我方设备接收的信号是多种相同或不同干扰信号的混叠^[9]。此外，随着 5G 通信的快速商用化、非正交多址接入 (Non-orthogonal Multiple Access, NOMA) 技术^[49] 和 5G 使能的 IoT 应用将使这种现象更加普遍。本文将同时获取多个共信道辐射源的位置参数简称为多源定位 (Multiple Sources Localization, MSL)。

由此可见，在日益复杂的辐射场环境下，传统的单源定位技术已经难以满足实际需求。随着无线通信技术和信号处理理论的发展，多源定位问题已经引起了国内外学者的广泛关注。和传统的单源定位相比，多源定位问题更加棘手，更具挑战性，而传统的单源定位方法无法适用于多源定位应用。多源定位的挑战在于定位节点无法对多个辐射源的信号进行解耦，同时易受随机噪声和未知传播信道参数的影响。此外，多源定位的结果来源于计算处理，是典型的多参数估计问题。从数学上来看，多源定位问题高度非凸非线性，难以直接求解。近些年来，稀疏表征方法为多源定位提供了一个全新的信号解耦和辐射源定位视角，获得了较好的定位性能。然而，多源定位问题的特殊性对稀疏恢复算法提出更加严苛的要求，同时也提供了定位场景所额外具备的特殊结构信息。如何利用好定位场景中蕴含的结构性信息，妥善解决相应的挑战，不仅有利于解决多源定位问题，而且能为相关稀疏表征问题提供一些新方法和新思路。

综上所述，随着辐射场环境日益复杂，多源定位技术的重要性日益凸显，稀疏表征方法为我们提供了一种全新且有效的视角去处理多源定位问题。本文主要从基于无线传感器网络的辐射源定位应用背景出发，研究基于两步定位模式和稀疏表征方法的多源定位关键技术，为解决多源定位精度受限、计算复杂度过高的问题提供新的理论基础和技术支撑，同时也为稀疏表征和稀疏恢复相关理论和算法提供一些新的见解和助力。

1.2 多源定位技术研究现状

在过去几十年中，在无线传感器网络能量、计算、存储、通信带宽等资源受限的前提下，国内外学者对辐射源定位技术展开了广泛而深入的研究，提出了一些重要的辐射源定位算法。通过对大量文献进行综述和总结，本文依据定位系统所使用的观测量的不同，将基于 WSN 的多源定位算法分为能量域多源定位算法、角度域多源定位算法、时间域多源定位算法、多域测量融合的混合定位算法。下面分别介绍这四部分的国内外研究现状并作分析总结。

1.2.1 能量域多源定位

近些年来, 基于 IoT 和 WSN 的民用定位技术蓬勃发展, 引起学术界和工业界的热切关注。这些应用非常关注定位系统的成本、复杂度和可行性, 力求在定位精度合理放松的条件下尽可能地降低定位系统的硬件要求。与角度域测量和时间域测量相比, 能量域测量对硬件要求最低, 无需阵列天线, 也不要求严格的时间同步、相干解调、高速 ADC。在此背景下, 能量域定位方法是中低定位距离场景下最具成本效益的定位解决方案, 被广泛应用于声源定位和跟踪、电磁辐射源定位等诸多场景, 同时提供可比的定位精度^[50-53]。

能量域定位的早期研究集中于单源定位场景。经典的单源定位算法是三边测量定位和多边测量定位方法^[54-55], 其依据一定的传播模型, 将接收的 RSS 值转化成辐射源和定位节点间的距离测量, 然后依据几何方法确定辐射源的位置。三边测量定位或多边测量定位方法过于简单, 其精度易受噪声、传播模型误差、传感器误差的影响。为解决该问题, 研究人员在优化框架中直接考虑未知传播参数和未知噪声的影响, 并提出了一些更加全面的定位算法^[56-76]。Li 等人^[56-57]利用各定位节点的能量比值来消除未知辐射源功率的影响, 提出了基于最小二乘法 (Least-Squares Method, LSM) 的单源定位算法。为降低 LSM 算法的复杂度, Meesookho 等人^[58]提出加权最小二乘方法, 取得定位精度和计算复杂度的折中。通过对未知噪声进行建模, Patwari^[59]和 Coluccia 等人^[60]提出了基于最大似然估计 (Maximum Likelihood Estimate, MLE) 的单源定位方法, 增强了定位算法的噪声鲁棒性。然而, 能量域单源定位问题是一个高度非凸非线性的参数估计问题, 基于 MLE 的定位算法需要对辐射源参数空间进行穷举搜索来找到全局最大值点。针对 MLE 方法复杂度过高的问题, 研究人员对 MLE 松弛技术的兴趣日益浓厚, 如基于半定规划 (Semidefinite Programming, SDP) 的单源定位算法^[61-63]、基于凸集投影 (Projection onto Convex Sets, POCS) 的单源定位算法^[64-65]、基于二阶锥规划 (Second-Order Cone Programming, SOCP) 的单源定位算法^[66]等。此外, 为降低模拟数据传输带来的能量、带宽消耗, 文献^[67-71]研究了基于量化数据的能量域辐射源定位方法。为进一步节省系统的能量和带宽资源, Masazade 等人^[72]提出了一种定位节点的迭代选择方法, 其通过激活最具信息性的部分定位节点来参与定位过程, 从而取得能量效率和定位性能之间的折中。

众所周知, 能量域辐射源定位方法高度依赖于传播模型。上述研究^[54-72]均假设传播参数精确已知。然而, 在实际应用中传播模型难以精确获得。通常, 传播模型由相关传播参数刻画, 如路损指数 (Path Loss Exponent, PLE)、发射功率、介质中的传播速度等。一方面, 通过对传播模型的建模, 可在估计辐射源位置参数的同时对传播参数的联合估计。文献^[73-76]研究了传播参数未知情况下的辐射源定位问题。Hu 等人^[73]提出了一种线性回归模型来建模 PLE, 并利用最小二乘法来推断未知 PLE。Sari 等人^[74]提出了贝叶斯最小均方误差估计器来定位未知 PLE 情况下的辐

射源。Vaghefi^[75] 等人采用 SDP 松弛技术来估计辐射源的发射功率。Gholami 等人^[76] 采用广义信赖域方法来求解未知 PLE 和发射功率情况下的辐射源定位问题。另一方面,研究者通过观察辐射能量随距离而衰减的一般事实,提出了不依赖于传播模型的辐射源定位方法,并取得了可接受的定位精度^[77-79]。

随着辐射场环境日益复杂,传统的单源定位方法已难以满足实际需求。最近,研究人员对能量域多源定位技术展现出愈发浓厚的兴趣。与单源定位相比,多源定位因能量测量值是多个辐射源能量的耦合叠加,能量强度和辐射信号收发距离之间不再具有清晰的对应关系,使得能量域多源定位问题变得更加困难、更具挑战。为对叠加的能量测量进行解耦,通常对连续的辐射源位置空间进行网格离散化,用离散网格空间去逼近原始的连续位置空间,从而在一定程度上降低多源定位问题的难度。但网格离散化后的多源定位问题仍然是一个高度非凸非线性的组合优化问题。针对该问题,Sheng 等人^[80] 最早提出了基于最大似然估计的多源定位算法。其通过多分辨率搜索算法和类期望最大化 (Expectation-Maximum, EM) 算法在离散网格空间中进行详尽的坐标搜索。随后,Sheng 等人又提出了基于高斯混合逼近和分布式粒子滤波器的多源定位和跟踪算法^[81]。Chen 等人^[82] 提出了交替投影多分辨率算法来解决文献^[80] 中相同的最大似然估计问题。然而,不论是 Sheng 还是 Chen 的方法都需要在每一个坐标维度上对所有网格点进行遍历搜索。显然,上述方法^[80-82] 因其过高的计算复杂度而难以处理大规模高维定位问题。近十年来,随着压缩感知理论 (Compressive Sensing, CS) 的出现,稀疏表征理论和算法^[83] 成为信号处理的热点问题,并在机器学习、图像处理^[84-86]、语音信号处理^[87-89], 计算机视觉^[90] 等领域得到深入研究和广泛应用。稀疏表征方法能够有效降低坐标搜索的复杂度,提高有噪和小样本观测情况下多源定位的鲁棒性,因而使用稀疏表征方法求解多源定位问题已成为研究共识^[91-95]。Cevher 等人^[91] 提出了基于稀疏表征的多源定位原始框架。在此框架下,Zhang 等人^[92] 证明定位字典满足有限等距性质 (Restricted Isometry Property, RIP),并基于正交匹配追踪 (Orthogonal Matching Pursuit, OMP) 提出了用于辐射源定位的贪婪匹配追踪算法。何风行等人^[93] 基于多分辨率分析思想,设计了用于多源定位的迭代回溯的压缩感知算法。该算法本质上是多次使用一般的稀疏恢复算法,然后根据上一次的稀疏恢复结果重新对辐射源位置空间进行网格离散化。Lin 等人^[94] 提出了基于德劳内 (Delaunay) 三角剖分的网格化方法,并将三角网格上的定位结果与传统均匀矩形网格上的定位结果进行融合,提高了多源定位的精度。孙保明等人^[95] 在假设辐射源的运动服从一定规律的前提下,通过定位字典的设计,将动态辐射源定位问题转化为稀疏信号恢复问题,并使用了不同稀疏恢复算法来对辐射源的位置进行求解。

上述基于稀疏表征的多源定位方法^[91-93,95] 的主要思想是假设辐射源位置从属于预定的离散网格集合 (on-grid),利用辐射源位置在网格空间中的稀疏性,可将多源定位问题转化成稀疏编码问题。在特定条件下^[96],可通过一般的稀疏恢复方法获得辐射源在网格空间中的位置。实际中,辐射源的位置可能偏离预定的网格集合 (off-grid),

这将大幅降低基于稀疏表征的多源定位算法性能。最近已有文献^[97-98]研究 off-grid 情况下的能量域多源定位问题，但其定位性能仍有待提升。

1.2.2 角度域多源定位

随着天线技术的发展和微电子技术的进步，定位节点配备阵列天线的成本越来越低，处理接收信号的能力越来越强。所以如今的定位节点能够较为轻松地获得角度域测量，基于角度域测量的辐射源定位系统同样得到了广泛应用，如加州理工大学开发的 Acoustic ENSBox 系统^[99-100]和 VoxNet 系统^[101]、浙江大学和中科院声学研究所^[44]联合开发的基于传声器阵列网络的声源实时定位和跟踪系统、Kaplan 等人开发的基于声音传播延时补偿的阵列系统^[102-103]等。角度域辐射源定位一般分为 DOA 估计和纯方位角定位 (Bearings-Only Target Localization, BOTL) 两部分。前者旨在获取辐射源的角度域测量，在角度域上对目标定位。后者旨在进一步根据角度域测量定位辐射源的空间位置。

在诸如 5G 波束赋形、麦克风阵列应用等热点商业场景中，获取用户 (辐射源) 的 DOA 估计即达到系统需求，即在角度域上对用户完成定位即可。定位节点的角度测量一般借助阵列天线完成。传统的阵列信号处理包括阵列结构设计、辐射源个数估计、DOA 估计三大部分。其中，DOA 估计是阵列信号处理的重点，阵列结构的设计和辐射源个数的估计是传统 DOA 估计方法的前提^[104-105]。在合适阵列结构和准确辐射源计数的前提下，研究人员提出诸多经典的 DOA 超分辨率估计方法。一类是基于子空间的非参数化 DOA 估计方法，如 Capon 方法^[106]、多重信号分类方法 (Multiple Signal Classification Algorithm, MUSIC)^[107-108]、Root-MUSIC 方法^[109]、基于旋转不变技术的信号参数估计方法 (Estimating Signal Parameter via Rotational Invariance Techniques, ESPRIT)^[110] 等。另一类是参数化 DOA 估计方法，如随机最大似然方法 (Stochastic Maximum Likelihood, SML)^[111] 和确定最大似然方法 (Deterministic Maximum Likelihood, DML)^[112-113] 等。然而，基于子空间的非参数化 DOA 估计方法需要获得大量的观测数据来估计接收数据协方差矩阵，需要正确已知辐射源的个数来分离信号子空间和噪声子空间，且只有在较高的信噪比、不同辐射源信号是弱相关的情况下才能获得高分辨率的空间谱估计。而参数化的 DOA 估计方法 SML 和 DML 需要具有较为准确的初始化参数才能获得好的估计性能。

最近十年来，研究人员利用辐射源在离散化的 DOA 空间上的稀疏性，发展了基于稀疏表征的 DOA 估计技术^[114-120]。该技术突破了传统阵列信号处理方法和局限，不需要准确初始化，能够在小样本观测、低信噪比接收、辐射源信号相关性较强的情况下同时实现对辐射源的计数和对 DOA 的超分辨率估计^[114-117]。基于稀疏表征的 DOA 估计一般采用多测量向量模型 (Multiple Measurement Vector, MMV)，用于 DOA 估计的典型稀疏恢复方法有基于正交匹配追踪的 MMV-OMP 算法^[118-119]、基

于 $\ell_{p \leq 1, q \geq 1}$ 混合范数正则的 ℓ_1 -SVD(Singular Value Decomposition, SVD) 算法^[114] 和 M-FOCUSS(MMV Focal Underdetermined System Solution, M-FOCCUS) 算法^[118]、基于稀疏贝叶斯推断的 M-SBL(Multiple Sparse Bayesian Learning, M-SBL) 算法^[120]。此外, Hyder 等人^[117] 通过近似 $\ell_{2,0}$ 范数, 提出了 JLZA(Joint $\ell_{2,0}$ Approximation, JLZA) 算法来迭代估计 DOA。Stoica 等人^[121] 基于最小协方差矩阵拟合准则, 提出了基于协方差的稀疏迭代估计方法 SPICE(Sparse Iterative Covariance-based Estimation, SPICE)。

基于稀疏表征的 DOA 估计方法同样面临网格失配问题(即 off-grid 问题)。近几年来, off-grid DOA 估计问题受到研究人员的热切关注。针对该问题, 主要有两类解决方案。第一类方案是网格演进类算法^[122-127]。Yang 等人^[122] 基于稀疏贝叶斯学习提出了 OGSBI 算法(Off-grid Sparse Bayesian Inference, OGSBI), 其利用稀疏贝叶斯学习方法推断真实 DOA 与网格点的偏差距离, 以此对估计的 DOA 进行补偿修正, 获得了较好的估计性能。OGSBI 奠定了此类方案的基础, 后续研究从计算复杂度和网格点动态采样等角度对 OGSBI 进行改进, 提出了诸多重要的网格演进算法^[123-127]; 第二类方案是基于原子范数^[128] 和范德蒙分解^[129] 的无网格 DOA 估计算法^[130-135], 该方法无需对 DOA 空间进行网格离散化。Tang 等人最先将原子范数正则引入 DOA 估计中, 提出了基于 SDP 的稀疏 DOA 估计方法^[130-131]。Yang 等人提出了基于加权原子范数最小化的 DOA 估计方法^[132]。Pal 等人提出了基于核范数最小化的 DOA 估计方法^[133]。Yang 等人基于协方差拟合准则提出了稀疏与参数化方法(Sparse and Parametric Approach, SPA)^[134] 和无网格 SPICE 方法^[135]。

在部分应用场景中, 在角度域获得辐射源的 DOA 参数后, 还需根据多个定位节点的 DOA 测量进行交叉定位, 进而获得辐射源在实际空间中的坐标位置, 即纯方位角定位^[9,136]。传统的纯方位角定位算法主要针对单辐射源定位, 如以 Stansfield 估计器^[137] 和正交向量算法(Orthogonal Vector, OV)^[138] 为代表的线性算法, 以工具变量法(Instrumental Variable, IV)^[139]、约束最小二乘法(Constrained Least Squares, CLS)^[140] 和总体最小二乘法(Total Least Square, TLS)^[141] 等为代表的非线性算法。然而, 在多源定位场景中, 每个定位节点获得的是 DOA 估计序列, 而无法得知该序列与真实的辐射源次序的对应关系, 即无法进行数据关联(Data Association, DA)。在此基础上, 应用上述单源定位方法将面临严重的鬼点(虚假定位点)(ghost points) 消除问题。针对鬼点消除问题, Reed 等人^[142] 提出了基于统计聚类的鬼点消除方法和基于信号循环平稳特性的鬼点消除方法。Klein 等人^[143] 提出了基于信号谱相关的鬼点消除方法。文献^[144-145] 研究了基于倾斜角的鬼点消除方法。Bishop 等人^[146] 提出了一种真实位置的贯序判决方案。盛丹等人^[136] 提出了基于 Hough 变换的鬼点去除方法。刘梅等人^[147] 提出了基于多模神经网络的鬼点去除方法。

1.2.3 时间域多源定位

时间域测量主要指 TOA 和 TDOA 测量。和角度域测量相比,时间域测量不要求定位节点配备阵列天线,但对定位节点间的时间同步要求很高,同时 TOA 测量还需辐射源与定位节点之间保持严格的时间同步。基于时间域测量的辐射源定位方法通常能够实现高的定位精度,在国防军事等对定位精度敏感的场景中得到广泛应用。一般认为辐射源与定位节点之间处于非合作状态,所以本文主要对基于 TDOA 的辐射源定位进行调研。早期的 TDOA 定位方法主要针对单源定位场景。若 TDOA 被精确测量,则可通过计算 TDOA 双曲线的交点估计单辐射源的位置参数^[9]。但在实际应用中,获得的往往是有噪 TDOA 测量。针对有噪 TDOA 单辐射源定位,主要有基于最大似然^[148-150]和基于伪最小二乘^[151-153]的 TDOA 单源定位方法。基于最大似然的 TDOA 单源定位的目标优化式是一个非凸优化问题,现有研究主要通过半定松弛 (Semidefinite Relaxation, SDR) 方法来近似求解^[148-150]。基于伪最小二乘的典型方法有两步加权最小二乘法 (Two-Step Weighted Least-Squares, TSWLS)^[151]和约束加权最小二乘法 (Constrained Weighted Least Squares, CWLS)^[152-153]。前者引入辅助变量将非线性的 TDOA 测量方程转化为伪线性方程,然后通过加权最小二乘方法得到辐射源位置与辅助变量的初步估计,最后利用辐射源位置和辅助变量之间的非线性关系对最终的估计结果进行修正;后者直接将辐射源位置与辅助变量之间的联系作为非线性约束加入到目标优化式中,有效提高了单源定位的精度。

如前所述,在日益复杂的辐射场环境中,多源定位问题受到了国内外学者的广泛关注。同纯方位角定位问题一样,基于 TDOA 的多源定位同样面临数据关联问题,即无法得知各定位节点得到的 TDOA 测量序列与真实的辐射源次序的对应关系。同样地,使用没有经过恰当数据关联的 TDOA 测量序列会带来大量的鬼点。不同的是,在基于 TDOA 的多源定位中,研究人员提出了多种有效的数据关联算法。如 2015 年, Xiu 等人^[154]提出了一种基于双向互选和最近邻算法的 TDOA 序列数据关联算法。2018 年, Sundar 等人^[155]提出了一种基于反向延迟间隔区域 (Inverse Delay Interval Region, IDIR) 的 TDOA 序列数据关联算法。在 TDOA 序列已正确关联的条件下, Yang 等人^[156]将两步加权最小二乘法推广到基于 TDOA 的多源定位中, Comsa 等人^[157]将稀疏表征框架用于基于 TDOA 的多源定位。但本质上,经过数据关联后, Yang 等人^[156]和 Comsa 等人^[157]所提算法仍然是基于 TDOA 的单源定位方法。有意思的是,受基于稀疏表征的能量域多源定位方法的启发, Jamali-Rad 等人^[158]提出了基于稀疏表征的 TDOA 多源定位算法,直接跳过了复杂的数据关联步骤,实现了对多个辐射源位置的同时定位。其将定位节点的 TDOA 序列进行累加,通过感知区域的网格离散化将 TDOA 多源定位问题转化成稀疏编码问题。

1.2.4 多域测量融合的混合定位

在实际系统中,为了更好地定位和追踪辐射源,一方面,单个定位节点可能集成多种感知功能的传感器,能够独立实现多域观测。另一方面,定位网络可能由具备不同感知功能的定位节点构成,能够联合所有定位节点获得多域观测。基于多域测量融合的辐射源混合定位技术能够有效利用各观测量的优势,减少单一测量所需的传感器个数,同时能在很大程度上消除单测量定位产生的鬼点,极大地提高定位精度和复杂环境下的定位鲁棒性。

在过去十几年中,研究者们提出了许多基于多域测量融合的单源定位技术^[159-180]。首先,基于 TDOA 和 FDOA 的单源混合定位技术因其能够对移动目标实现高精度定位和追踪而受到深入研究。基于 TDOA 和 FDOA 的混合单源定位方法主要分为闭式解法和迭代解法。前者包括著名的两步加权最小二乘法^[159]、约束加权最小二乘法^[160]、基于半定松弛的方法^[161-163]。后者包括泰勒级数法^[164]、基于牛顿下降的约束最小二乘法^[165]、基于双向交替优化的方法^[166]、拉格朗日乘子法^[167]等。其次,辐射源常使用有向传输和功率控制来实现低拦截率。为定位低拦截率辐射源,基于 TDOA-DOA 的混合单源定位技术被广泛使用。Cong 等人^[168]提出了基于两步最小二乘的 TDOA-DOA 混合单源定位方法。在此基础上,Liu 等人^[169]研究了基于直角坐标和极坐标表示的 TDOA-DOA 混合单源定位方法。Bishop 等人^[170]通过添加几何约束提高了 TDOA-DOA 混合单源定位算法的性能。Yin 等人^[171]提出了 TDOA-DOA 混合单源定位的闭式解法。Wang 等人^[172]将基于高斯-牛顿迭代的最大似然的纯方位角定位算法推广到 TDOA-DOA 混合单源定位中。最后,鉴于 RSS 和 DOA 是相对容易获取的观测量,为提高基于 RSS 或 DOA 的定位系统的性能,研究人员提出了基于 RSS-DOA 的混合单源定位技术。Wang 等人^[173]通过非线性约束优化,提出了基于最小二乘估计和最大似然估计的差分 RSS-DOA 混合单源定位算法。Gazzah 等人^[174]提出了针对 RSS-DOA 混合定位问题的选择性加权最小二乘估计器。Biswas 等人^[175]提出了一种基于半定松弛技术的估计方法。Tomic 等人^[176]提出了基于 SOCP 的估计方法。随后,Tomic 等人^[177]又提出了具有闭式解的线性估计方法。Chang 等人^[178]基于加权最小二乘推导了一种新颖的非凸目标函数,然后将其转化为 SOCP 问题。

然而到目前为止,我们在文献调研中尚未见到已发表的基于多域测量融合的混合多源定位方法。

1.2.5 研究现状分析和总结

研究现状综述显示,辐射源定位问题是一个典型的高度非凸非线性的参数估计问题,共信道多辐射源的存在使得该问题更加棘手。不论是能量域多源定位,还是角度域、时间域多源定位,都能通过对辐射源参数空间进行网格离散化,利用真实参数在网格空间上的稀疏性,将原始的非凸连续优化问题转化成离散线性的稀疏编码问

题,进而通过稀疏恢复算法进行解码,获得多源定位问题的近似求解。研究表明,在一定条件下,基于稀疏表征的多源定位算法突破了传统多源定位方法的框架,能够获得更加优越的性能。

然而通过对现有研究的总结可以看出,尽管国内外学者提出了诸多具有重要价值的多源定位方法,但现有文献中基于稀疏表征的多源定位方法仍存在如下不足:

(1) **未能充分利用多源定位模型中的结构信息。**现有基于稀疏表征的多源定位方法在完成了对原始问题的稀疏编码近似后,采用一般化的稀疏恢复算法进行求解。然而,多源定位问题不同于一般的稀疏编码问题,其具有明确的物理结构。网格点在物理空间上的有序性和近邻特征映射到过完备定位字典上是相邻列之间的强相关性。

因此,针对多源定位中的结构信息挖掘问题,如何通过恰当的算法设计,充分利用多源定位模型提供的物理结构信息,进一步提高基于稀疏表征的多源定位算法的性能是一个值得研究的方向。

(2) **未能充分解决由网格失配和模型参数误差带来的基不匹配问题。**定位字典由网格参数和模型参数刻画。首先,当真实辐射源参数偏离人为划定的离散网格时(网格失配),将导致观测信号无法由定位字典稀疏表出,进而带来基不匹配问题(basis mismatch)。其次,实际应用中诸如传播速度、传感器位置、路损指数等模型参数可能存在误差,这同样会导致基不匹配问题。文献^[181]指出,基不匹配情况下稀疏恢复算法的重建性能将大幅降低,由网格离散化带来基不匹配问题无法通过更精细的网格划分粒度来消除。虽然在DOA估计问题中,利用信号协方差的Toeplitz结构,基于原子范数和范德蒙分解定理提出了无网格稀疏参数估计方法^[130-135]。但该方法无法拓展到能量域、时间域多源定位等问题中。相对而言,基于网格离散化的方法只依赖参数化的信号模型,更具一般性和普适性。虽然国内外研究者提出了诸多网格演进类算法^[97-98,123-127]来处理网格失配问题,但这些方法无法形成稀疏恢复与网格点自适应调整的闭环优化逻辑,因而其对off-grid的稀疏参数的估计能力有限。

因此,针对多源定位中基不匹配问题,通过合适的系统建模和算法设计,完成稀疏恢复和字典参数推理的闭环优化逻辑,有效提高基不匹配情况下的参数估计性能,对提升基于稀疏表征的多源定位算法的性能具有重要意义,对研究基不匹配情况下的稀疏恢复技术具有普适价值。

(3) **未能充分解决大规模高维场景中的多源定位问题。**稀疏恢复算法主要分为贪婪类算法、优化类算法、贝叶斯类算法。其中,优化类算法和贝叶斯类算法具有优越的参数估计能力,被广泛应用于基于稀疏表征的多源定位。然而,现有优化类和贝叶斯类算法的最低复杂度分别为 $\mathcal{O}(N^3)$ 和 $\mathcal{O}(MN^2)$,其中 M 为定位节点数目, N 为辐射源参数域的网格点个数。对于 D 维参数空间,假设每一个维度上有 q 个网格点,则整个参数空间的网格点数为 $N = q^D$,应用上述算法的复杂度则可达 $\mathcal{O}(q^{3D})$ 和 $\mathcal{O}(Mq^{2D})$ 。当处理大规模高维定位问题时,如高维大范围参数域下细密的网格划

分场景, 达 $\mathcal{O}(q^{3D})$ 和 $\mathcal{O}(Mq^{2D})$ 的计算复杂度远超现有一般消费级高性能计算机的运算能力, 从而使得定位问题无法实际求解, 即带来多源定位中的“维数灾难”问题 (curse of dimensionality)。

因此, 针对大规模高维场景带来的维数灾难问题, 研究具有低计算复杂度的快速算法, 对实现基于稀疏表征的多源定位具有重要的实际价值, 对求解大规模高维稀疏恢复问题具有重要的理论价值。

(4) 未能充分解决阴影衰落下的多源定位问题。现有多源定位研究采用加性噪声模型, 适用于角度域和时间域多源定位, 也适用无障环境中的能量域多源定位。然而在有障环境中的能量域多源定位中, 障碍物的随机遮挡造成阴影衰落效应, 数学上对应对数正态模型, 属于乘性噪声干扰模型。针对单源定位, 可以通过在对数域中表示能量测量, 将乘性噪声转化为加性噪声。然而, 对于多源定位而言, 各定位节点的能量测量是多个对数正态随机变量的线性叠加, 数学上为求和对数正态随机变量 (Sum-of-log-normal, SLN)。鉴于 SLN 随机变量的概率分布无显式表达, 所以无法提出基于最大似然估计、最小方差无偏估计、贝叶斯估计等经典估计准则的多源定位算法, 这也是目前国内外鲜有关于阴影衰落下的能量域多源定位研究成果的主要原因。

因此, 针对阴影衰落下的多源定位问题, 如何对观测模型进行恰当建模, 并结合稀疏表征方法设计多源定位算法, 是一个具有理论难度和实际意义的研究方向。

1.3 论文主要内容及结构安排

1.3.1 论文主要内容

本文从基于无线传感器网络的辐射源定位背景出发, 研究基于两步定位模式和稀疏表征的多源定位技术。针对现有研究的不足, 本文的主要工作有以下四个方面:

第一, 针对多源定位中的结构信息挖掘问题, 利用贪婪算法中残差投影的聚簇特征, 提出一种层级贪婪匹配追踪算法 (Hierarchical Greedy Matching Pursuit, HGMP)。该算法首先在全局估计层中获得辐射源在网格化空间中的可能位置, 然后稀疏恢复层在可能位置集合中重构稀疏位置矢量。HGMP 算法通过全局估计层预先排除了不可能的网格点, 等效于从网格空间中分离出信号子空间, 从而降低了观测噪声的影响。通过与传统的贪婪类和优化类稀疏恢复算法进行对比, 说明所提算法能以更低的计算复杂度实现更高的定位精度和更好的抗噪声性能。

第二, 针对多源定位中由网格失配和模型参数误差带来的基不匹配问题, 通过将多源定位建模成字典学习和稀疏恢复的联合优化问题, 提出一种参数化稀疏贝叶斯字典学习算法 (Parametric Sparse Bayesian Dictionary Learning, PSBDL), 实现稀疏恢复与字典学习的闭环优化逻辑。本部分工作将对实信号/复信号、SMV/MMV 观测模型下的 PSBDL 算法进行详细推导。为验证所提算法的定位性能, 将对具体定位问题




图 1-3 全文组织结构图

中的克拉美罗下界 (Cramér–Rao Lower Bound, CRLB) 进行推导。通过与 CRLB 及最新的定位算法进行对比, 说明所提算法能有效解决多源定位中的基不匹配问题。

第三, 针对大规模高维场景带来的维数灾难问题, 通过对稀疏贝叶斯学习超参数更新的证据下界进行深入分析, 基于“网格甄别”思想提出一种快速证据下界最大化稀疏贝叶斯学习算法 (Fast EM for SBL, FEMSBL)。通过将 FEMSBL 算法与 PSBDL 算法结合, 提出一种参数化稀疏贝叶斯字典学习快速算法 (Fast PSBDL, FPSBDL)。理论分析表明, 所提算法具有线性渐进复杂度。分别通过与传统的 EMSBL 算法和提出的 PSBDL 进行对比, 说明 FEMSBL 算法和 FPSBDL 算法能够有效解决大规模高维场景中的多源定位问题, 带来计算效率和系统辨识能力上的显著提升。

第四, 针对阴影衰落下的多源定位问题, 通过 Fenton-Wilkinson 方法对 SLN 随机变量的分布函数进行逼近, 提出一种基于稀疏表征的两阶段最大似然多源定位算法 (Two-Stage Maximum Likelihood, TSML), 对所提算法的计算复杂度和全局收敛性作出理论分析。通过与阴影衰落下最新的多源定位算法进行对比, 说明所提算法的具有更高的定位精度。

1.3.2 论文结构安排

根据本文的研究内容, 论文的结构安排如图1-3所示。

第一章为绪论部分, 第二章介绍相关数学基础知识, 并对多源定位进行系统建模, 为后文的进一步研究奠定数学基础。第三章针对多源定位中的结构信息挖掘问题, 提出一种基于层级贪婪匹配追踪的多源定位算法。第四章针对多源定位中的基不

匹配问题，提出一种基于参数化稀疏贝叶斯字典学习的多源定位方法。第五章针对大规模高维场景中的多源定位问题，提出一种基于快速证据下界最大化稀疏贝叶斯学习算法和一种参数化稀疏贝叶斯字典学习快速算法。第六章针对阴影衰落信道下的多源定位问题，提出了一种新颖的两阶段最大似然多源定位算法。第七章总结全文，给出本文的创新点，并指出未来相关的研究方向。

第二章 数学基础和系统建模

2.1 引言

为方便后续章节的算法推导和理论分析，本章对论文涉及的重要数学基础知识进行介绍，并通过总结归纳能量域、角度域、时间域多源定位模型和问题，抽象出广义多源定位模型和问题。在第三章到第五章中，本文将研究基于稀疏表征的广义多源定位问题，并在具体多源定位场景中验证所提算法的性能。为表述的简洁性，本章对相关模型、证明、算法进行了详尽的推导，在后续章节的表述、推导和证明中将不再赘述这些基础知识。

本章的创新点有：(1) 提出了一种新颖的纯方位角多源定位模型；(2) 建立了能统一表示能量域、角度域、时间域多源定位模型的广义多源定位模型；(3) 从 Kullback-Leibler 散度和证据下界的角度重新解释了期望最大化算法。

本章内容安排如下：2.2 节介绍论文所需的预备数学基础知识；2.3 节通过分析具体的多源定位模型，建立广义多源定位模型，并基于参数域网格离散化近似引出基于稀疏表征的多源定位问题；2.4 节介绍三类经典的稀疏恢复算法；2.5 节对本章进行小结。

2.2 预备数学基础知识

2.2.1 重要不等式

命题 2.1 (Jensen 不等式) 对于任意点集 $\{x_i\}$ ，若 $\lambda_i \geq 0$ 且 $\sum_i \lambda_i = 1$ ，则对于凸函数 $f(x)$ ，有如下 Jensen 不等式成立

$$f\left(\sum_i \lambda_i x_i\right) \leq \sum_i \lambda_i f(x_i) \quad (2-1)$$

命题 2.2 (Cauchy-Schwarz 不等式) 记标量域 $\mathbb{F}$ 表示实数域 $\mathbb{R}$ 或复数域 $\mathbb{C}$ ，在向量空间 $\mathbb{V}$ 上定义的内积为 $\langle \cdot, \cdot \rangle := \mathbb{V} \times \mathbb{V} \rightarrow \mathbb{F}$ ，相应的范数为 $\|x\| = \sqrt{\langle x, x \rangle}$ 。则对任意 $x, y \in \mathbb{V}$ ，满足如下 Cauchy-Schwarz 不等式

$$|\langle x, y \rangle| \leq \|x\| \|y\| \quad (2-2)$$

等式成立条件为 x, y 同向，即线性相关且内积为正。Cauchy-Schwarz 不等式中常用的内积定义有 $\langle x, y \rangle = x^T y$ ，此时 $\|x\| = \|x\|_2$ 。

命题 2.3 (Chebyshev 总和不等式) 若序列 $\{a_1, a_2, \dots, a_n\}$ 和 $\{b_1, b_2, \dots, b_n\}$ 是异步的, 即对任意 $i, j \in \{1, 2, \dots, n\}$, 满足 $(a_i - a_j)(b_i - b_j) \leq 0$, 则满足如下 Chebyshev 总和不等式

$$\sum_{i=1}^n a_i \sum_{i=1}^n b_i \geq n \sum_{i=1}^n a_i b_i \quad (2-3)$$

2.2.2 矩阵运算相关定理

命题 2.4 对任意 $\mathbf{v}, \mathbf{u} \in \mathbb{R}^N$, 有

$$\mathbf{v}^T \text{diag}(\mathbf{u}) = \mathbf{u}^T \text{diag}(\mathbf{v}) \quad (2-4)$$

命题 2.5 对任意 $\mathbf{v} \in \mathbb{C}^M$, $\mathbf{u} \in \mathbb{C}^N$, $\mathbf{M} \in \mathbb{C}^{M \times N}$, 有

$$\text{diag}(\mathbf{v}) \mathbf{M} \text{diag}(\mathbf{u})^H = \mathbf{M} \circ \mathbf{v} \mathbf{u}^H \quad (2-5)$$

命题 2.6 对任意 $\mathbf{v} \in \mathbb{C}^M$, $\mathbf{u} \in \mathbb{C}^N$, $\mathbf{Q}, \mathbf{R} \in \mathbb{C}^{M \times N}$, 有

$$\text{tr} \left\{ \text{diag}(\mathbf{v})^H \mathbf{Q} \text{diag}(\mathbf{u}) \mathbf{R}^T \right\} = \mathbf{v}^H (\mathbf{Q} \circ \mathbf{R}) \mathbf{u} \quad (2-6)$$

命题 2.7 对任意矩阵 $\mathbf{B}_{M \times N}$, $\mathbf{C}_{N \times M}$ 以及非奇异矩阵 $\mathbf{A}_{M \times M}$, 有

$$\det(\mathbf{A} + \mathbf{BC}) = \det(\mathbf{A}) \det(\mathbf{I}_M + \mathbf{A}^{-1} \mathbf{BC}) = \det(\mathbf{A}) \det(\mathbf{I}_N + \mathbf{CA}^{-1} \mathbf{B}) \quad (2-7)$$

定义 2.1 (SVD 分解) 对于矩阵 $\mathbf{A} \in \mathbb{C}^{M \times N}$, 其 SVD 分解定义为 $\mathbf{A} = \mathbf{U} \mathbf{\Sigma} \mathbf{V}^H$ 。其中, $\mathbf{U} \in \mathbb{C}^{M \times M}$ 为 $\mathbf{A} \mathbf{A}^H$ 的单位特征向量组成的酉矩阵, 称为左奇异矩阵。 $\mathbf{V} \in \mathbb{C}^{N \times N}$ 为 $\mathbf{A}^H \mathbf{A}$ 的单位特征向量组成的酉矩阵, 称为右奇异矩阵。非负实数对角矩阵 $\mathbf{\Sigma} = \begin{bmatrix} \mathbf{D}_{r \times r} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \in \mathbb{R}^{M \times N}$ 为奇异值矩阵, 其中 $\mathbf{D}_{r \times r} = \sqrt{\text{diag}(\text{eig}(\mathbf{A} \mathbf{A}^H))}$, $r = \text{Rank}(\mathbf{A} \mathbf{A}^H)$ 。去掉 $\mathbf{\Sigma}$ 中全零行全零列对应的项, 可得 SVD 分解的紧凑表达形式 $\mathbf{A} = \mathbf{U}_{M \times r} \mathbf{\Sigma}_{r \times r} (\mathbf{V}_{N \times r})^H$, 其中, $\mathbf{U}_{M \times r} = \mathbf{U}(:, 1:r)$, $\mathbf{V}_{N \times r} = \mathbf{V}(:, 1:r)$, $\mathbf{\Sigma}_{r \times r} = \mathbf{D}_{r \times r}$ 。

引理 2.1 (矩阵求逆引理) 对任意 $\mathbf{A} \in \mathbb{C}^{N \times N}$, $\mathbf{U} \in \mathbb{C}^{N \times K}$, $\mathbf{C} \in \mathbb{C}^{K \times K}$, $\mathbf{V} \in \mathbb{C}^{K \times N}$, 若 $\mathbf{A} + \mathbf{UCV}$ 可逆, 则有

$$(\mathbf{A} + \mathbf{UCV})^{-1} = \mathbf{A}^{-1} - \mathbf{A}^{-1} \mathbf{U} (\mathbf{C}^{-1} + \mathbf{V} \mathbf{A}^{-1} \mathbf{U})^{-1} \mathbf{V} \mathbf{A}^{-1} \quad (2-8)$$

本引理亦称 Woodbury 矩阵恒等式 (Woodbury identity)。

定义 2.2 (正交化算子) 矩阵 $\mathbf{A} \in \mathbb{R}^{M \times N}$ 的正交化算子 $\mathbf{T}_\mathbf{A} \in \mathbb{R}^{M \times M}$ 定义为

$$\mathbf{T}_\mathbf{A} = \arg \min_{\mathbf{T}_\mathbf{A}} \left\| (\mathbf{T}_\mathbf{A} \mathbf{A})^T (\mathbf{T}_\mathbf{A} \mathbf{A}) - \mathbf{I}_N \right\|_F^2 \quad (2-9)$$

即经过 $\mathbf{T}_\mathbf{A}$ 的处理后, $\mathbf{T}_\mathbf{A} \mathbf{A}$ 的列将尽可能地相互正交。

定理 2.1 (正交化算子定理^[158]) 若矩阵 $\mathbf{A} \in \mathbb{R}^{M \times N}$ 有 SVD 分解 $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$, 则

$$\mathbf{T}_{\mathbf{A}} = \begin{cases} \mathbf{\Sigma}^\dagger(1:M,:) \mathbf{U}^T, & \text{若 } M \leq N; \\ \begin{bmatrix} \mathbf{\Sigma}^\dagger \\ \mathbf{0}_{(M-N) \times M} \end{bmatrix} \mathbf{U}^T, & \text{若 } M > N \end{cases} \quad (2-10)$$

证明: 不妨将式(2-9)中的优化问题重新表述为

$$\min_{\mathbf{T}_{\mathbf{A}}} \left\| (\mathbf{T}_{\mathbf{A}} \mathbf{A})^T (\mathbf{T}_{\mathbf{A}} \mathbf{A}) - \mathbf{I}_N \right\|_F^2 = \min_{\mathbf{\Gamma}} \left\| \mathbf{A}^T \mathbf{\Gamma} \mathbf{A} - \mathbf{I}_N \right\|_F^2, \quad (2-11)$$

其中, $\mathbf{\Gamma} = \mathbf{T}_{\mathbf{A}}^T \mathbf{T}_{\mathbf{A}}$ 为对称矩阵。由 $\text{vec}(\mathbf{ABC}) = (\mathbf{C}^T \otimes \mathbf{A}) \text{vec}(\mathbf{B})$, 有

$$\text{vec}(\mathbf{A}^T \mathbf{\Gamma} \mathbf{A}) = (\mathbf{A}^T \otimes \mathbf{A}^T) \boldsymbol{\gamma} \quad (2-12)$$

其中, $\boldsymbol{\gamma} = \text{vec}(\mathbf{\Gamma})$ 。因而, 问题(2-11)可以转换成如下最小二乘问题

$$\min_{\boldsymbol{\gamma}} \left\| (\mathbf{A}^T \otimes \mathbf{A}^T) \boldsymbol{\gamma} - \text{vec}(\mathbf{I}_N) \right\|_2^2 \quad (2-13)$$

该问题的最小二乘解为 $\boldsymbol{\gamma} = [\mathbf{A}^T \otimes \mathbf{A}^T]^\dagger \text{vec}(\mathbf{I}_N)$ 。

由 $(\mathbf{A} \otimes \mathbf{B})^\dagger = \mathbf{A}^\dagger \otimes \mathbf{B}^\dagger$ 和 $(\mathbf{B}^T)^\dagger = (\mathbf{B}^\dagger)^T$, 可得 $\boldsymbol{\gamma} = [(\mathbf{A}^\dagger)^T \otimes (\mathbf{A}^\dagger)^T] \text{vec}(\mathbf{I}_N)$ 所以, 有

$$\mathbf{\Gamma} = \text{ivec}(\boldsymbol{\gamma}) = \text{ivec} \left([(\mathbf{A}^\dagger)^T \otimes (\mathbf{A}^\dagger)^T] \text{vec}(\mathbf{I}_N) \right) = (\mathbf{A}^\dagger)^T \mathbf{I}_N \mathbf{A}^\dagger = (\mathbf{A}^\dagger)^T \mathbf{A}^\dagger \quad (2-14)$$

其中, $\mathbf{A}^\dagger = (\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \in \mathbb{R}^{N \times M}$ 。由于 $\mathbf{T}_{\mathbf{A}}$ 需满足 $\mathbf{\Gamma} = \mathbf{T}_{\mathbf{A}}^T \mathbf{T}_{\mathbf{A}}$ 且 $\mathbf{T}_{\mathbf{A}} \in \mathbb{R}^{M \times M}$, 故 $\mathbf{A}^\dagger$ 不是 $\mathbf{T}_{\mathbf{A}}$ 的解。

对 $\mathbf{A}$ 进行 SVD 分解, 有 $\mathbf{A} = \mathbf{U}\mathbf{\Sigma}\mathbf{V}^T$ 。故 $\mathbf{A}^\dagger = \mathbf{V}\mathbf{\Sigma}^\dagger \mathbf{U}^T$ 。代入式(2-14)中可得,

$$\mathbf{\Gamma} = \mathbf{U} (\mathbf{\Sigma}^\dagger)^T \mathbf{V}^T \mathbf{V} \mathbf{\Sigma}^\dagger \mathbf{U}^T = (\mathbf{\Sigma}^\dagger \mathbf{U}^T)^T \mathbf{\Sigma}^\dagger \mathbf{U}^T \quad (2-15)$$

其中, $\mathbf{\Sigma}^\dagger = (\mathbf{\Sigma}^T \mathbf{\Sigma})^{-1} \mathbf{\Sigma}^T = \begin{bmatrix} \mathbf{D}_{r \times r}^{-1} & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \in \mathbb{R}^{N \times M}$, $\mathbf{D} = \sqrt{\text{diag}(\text{eig}(\mathbf{A}\mathbf{A}^H))}$ 。因为 $r \leq \min\{M, N\}$, $\mathbf{\Sigma}^\dagger \mathbf{U}^T \in \mathbb{R}^{N \times M}$ 的最后 $N - r$ 行为全零行。

当 $M \leq N$ 时, 删去 $\mathbf{\Sigma}^\dagger \mathbf{U}^T$ 最后的 $N - M$ 行全零行不改变 $(\mathbf{\Sigma}^\dagger \mathbf{U}^T)^T \mathbf{\Sigma}^\dagger \mathbf{U}^T$ 的值。此时有

$$\mathbf{\Gamma} = (\mathbf{\Sigma}^\dagger(1:M,:) \mathbf{U}^T)^T \mathbf{\Sigma}^\dagger(1:M,:) \mathbf{U}^T = \mathbf{T}_{\mathbf{A}}^T \mathbf{T}_{\mathbf{A}} \quad (2-16)$$

其中, $\mathbf{T}_{\mathbf{A}} = \mathbf{\Sigma}^\dagger(1:M,:) \mathbf{U}^T \in \mathbb{R}^{M \times M}$ 。

当 $M > N$ 时, 在 $\mathbf{\Sigma}^\dagger \mathbf{U}^T$ 后面增加 $M - N$ 行全零行不影响 $(\mathbf{\Sigma}^\dagger \mathbf{U}^T)^T \mathbf{\Sigma}^\dagger \mathbf{U}^T$ 的值。此时有

$$\mathbf{\Gamma} = \left(\begin{bmatrix} \mathbf{\Sigma}^\dagger \\ \mathbf{0}_{(M-N) \times M} \end{bmatrix} \mathbf{U}^T \right)^T \begin{bmatrix} \mathbf{\Sigma}^\dagger \\ \mathbf{0}_{(M-N) \times M} \end{bmatrix} \mathbf{U}^T = \mathbf{T}_{\mathbf{A}}^T \mathbf{T}_{\mathbf{A}} \quad (2-17)$$

其中, $\mathbf{T}_A = \begin{bmatrix} \Sigma^\dagger \\ \mathbf{0}_{(M-N) \times M} \end{bmatrix} \mathbf{U}^T \in \mathbb{R}^{M \times M}$ 。

综上所述, 可知式(2-10)即为满足问题(2-9)的解。进一步分析可以看出, 不论 $M \geq N$ 或 $M < N$, 利用 $r \leq \min\{M, N\}$, 均有

$$\mathbf{T}_A \mathbf{A} = \begin{bmatrix} \mathbf{V}(:, 1:r) & \mathbf{0}_{N \times (M-r)} \end{bmatrix}^T \quad (2-18)$$

□

2.2.3 概率分布和概率推理

定义 2.3 (多元实高斯分布) 若实随机变量 $\mathbf{x} \in \mathbb{R}^N$ 的概率密度函数 (Probability Density Function, PDF) 为

$$p(\mathbf{x}) = \frac{\exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)}{\sqrt{(2\pi)^N \det(\boldsymbol{\Sigma})}} \quad (2-19)$$

则称 $\mathbf{x}$ 服从均值为 $\boldsymbol{\mu} = \mathbb{E}\{\mathbf{x}\}$, 协方差为 $\boldsymbol{\Sigma} = \mathbb{E}\{(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^T\}$ 的 N 维实高斯分布, 简记为 $\mathbf{x} \sim \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 。

定义 2.4 (多元复高斯分布) 若复随机变量 $\mathbf{x} \in \mathbb{C}^N$ 的概率密度函数为

$$p(\mathbf{x}) = \frac{\exp\left(-(\mathbf{x} - \boldsymbol{\mu})^H \boldsymbol{\Sigma}^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)}{\pi^N \det(\boldsymbol{\Sigma})} \quad (2-20)$$

则称 $\mathbf{x}$ 服从均值为 $\boldsymbol{\mu} = \mathbb{E}\{\mathbf{x}\}$, 协方差为 $\boldsymbol{\Sigma} = \mathbb{E}\{(\mathbf{x} - \boldsymbol{\mu})(\mathbf{x} - \boldsymbol{\mu})^H\}$ 的 N 维复高斯分布, 简记为 $\mathbf{x} \sim \mathcal{CN}(\mathbf{x}|\boldsymbol{\mu}, \boldsymbol{\Sigma})$ 。

定义 2.5 (Student's t 分布) 若实随机变量 x 的概率密度函数为

$$p(x) = \frac{\Gamma\left(\frac{v+1}{2}\right)}{\sqrt{v\pi}\Gamma\left(\frac{v}{2}\right)} \left(1 + \frac{x^2}{v}\right)^{-\frac{v+1}{2}} \quad (2-21)$$

其中, $v > 0$ 。则称 x 服从自由度为 v 的 Student's t 分布, 简记为 $x \sim \text{St}(x|v)$ 。

定义 2.6 (Laplace 分布) 若实随机变量 x 的概率密度函数为

$$p(x) = \frac{1}{2b} \exp\left(-\frac{|x - \mu|}{b}\right) \quad (2-22)$$

其中, $b > 0$ 。则称 x 服从位置参数为 μ , 尺度参数为 b 的 Laplace 分布, 简记为 $x \sim \text{Laplace}(x|\mu, b)$ 。

定义 2.7 (Gamma 分布) 若实随机变量 x 的概率密度函数为

$$p(x) = \frac{b^a}{\Gamma(a)} x^{a-1} \exp(-bx) \quad (2-23)$$

其中, $a > 0, b > 0$ 。则称 x 满足形状参数为 a , 尺度参数为 b 的 Gamma 分布, 简记为 $x \sim \text{Gamma}(x|a, b)$ 。

命题 2.8 (高斯分布的性质) 若 $\mathbf{x} \sim \mathcal{N}(\boldsymbol{\mu}_x, \boldsymbol{\Sigma}_x)$, $\mathbf{y} \sim \mathcal{N}(\boldsymbol{\mu}_y, \boldsymbol{\Sigma}_y)$, 则

$$\mathbf{Ax} + \mathbf{By} + \mathbf{c} \sim \mathcal{N}(\mathbf{A}\boldsymbol{\mu}_x + \mathbf{B}\boldsymbol{\mu}_y + \mathbf{c}, \mathbf{A}\boldsymbol{\Sigma}_x\mathbf{A}^T + \mathbf{B}\boldsymbol{\Sigma}_y\mathbf{B}^T) \quad (2-24)$$

$$\mathbb{E}\{\mathbf{x}^T \mathbf{Ax}\} = \boldsymbol{\mu}_x^T \mathbf{A}\boldsymbol{\mu}_x + \text{tr}(\mathbf{A}\boldsymbol{\Sigma}_x) \quad (2-25)$$

定义 2.8 (Kullback-Leibler 散度) 在统计学中, Kullback-Leibler 散度 (也称为相对熵) 是一种概率分布与参考概率分布有何不同的度量。对于定义在相同概率空间 $\mathcal{X}$ 上的离散概率分布 $P(\mathbf{x})$ 和 $Q(\mathbf{x})$, 从 Q 到 P 的 Kullback-Leibler 散度定义为

$$D_{\text{KL}}(P\|Q) = - \sum_{\mathbf{x} \in \mathcal{X}} P(\mathbf{x}) \ln \frac{Q(\mathbf{x})}{P(\mathbf{x})} \quad (2-26)$$

对定义在相同概率空间 $\mathcal{X}$ 上的连续随机变量的概率分布 $P(\mathbf{x})$ 和 $Q(\mathbf{x})$, 从 Q 到 P 的 Kullback-Leibler 散度定义为

$$D_{\text{KL}}(P\|Q) = - \int_{\mathcal{X}} p(\mathbf{x}) \ln \frac{q(\mathbf{x})}{p(\mathbf{x})} d\mathbf{x} \quad (2-27)$$

其中, $p(\mathbf{x})$ 和 $q(\mathbf{x})$ 分别指 $P(\mathbf{x})$ 和 $Q(\mathbf{x})$ 的概率密度函数。由 Jensen 不等式易得 Kullback-Leibler 散度总是非负的, 即 $D_{\text{KL}}(P\|Q) \geq 0$, 当且仅当 $P(\mathbf{x}) = Q(\mathbf{x})$ 时等号成立。

定义 2.9 (最大似然估计) 从统计的角度来看, 一组给定的观测数据 $\mathbf{y} = (y_1, y_2, \dots, y_n)$ 是来自未知总体的随机样本。最大似然估计旨在对最有可能生成该随机样本的总体进行推断, 尤其是对随机变量的联合概率密度函数进行推断。每一个概率密度函数都由参数空间 Θ 中的向量 $\boldsymbol{\theta} = [\theta_1, \theta_2, \dots, \theta_k]^T$ 在概率密度族 $\{p(\mathbf{y}; \boldsymbol{\theta}) \mid \boldsymbol{\theta} \in \Theta\}$ 中唯一确定。通过观测数据可以评估联合概率密度, 得到实值似然函数 (likelihood function) $L(\boldsymbol{\theta}) = L(\mathbf{y}; \boldsymbol{\theta}) = p(\mathbf{y}; \boldsymbol{\theta})$, 最大似然估计的目标是在参数空间 Θ 中找到使似然函数最大的模型参数 $\hat{\boldsymbol{\theta}}_{\text{ML}}$

$$\hat{\boldsymbol{\theta}}_{\text{ML}} = \arg \max_{\boldsymbol{\theta} \in \Theta} L(\mathbf{y}; \boldsymbol{\theta}) \quad (2-28)$$

直观地, 这选择了使观测数据最可能出现的参数值。在实践中, 往往通过对目标优化式中的似然函数取自然对数来简化计算, 得到对数似然函数 $\ell(\boldsymbol{\theta}) = \ln L(\mathbf{y}; \boldsymbol{\theta})$ 。

定义 2.10 (最大后验估计) 在贝叶斯统计中, 最大后验 (Maximum a Posteriori, MAP) 估计与最大似然估计密切相关, 其通过对目标参数 $\boldsymbol{\theta}$ 施加先验约束来增强优化目标函数, 相当于对最大似然估计进行正则化。在最大似然估计中, $\boldsymbol{\theta}$ 被认为是未知确定性参量。在最大后验估计中, $\boldsymbol{\theta}$ 被认为是未知随机变量。假设 $\boldsymbol{\theta}$ 服从一定的先验分布 (prior distribution) $p(\boldsymbol{\theta})$, 根据 Bayes 准则可以计算 $\boldsymbol{\theta}$ 的后验分布

$$p(\boldsymbol{\theta} \mid \mathbf{y}) = \frac{p(\mathbf{y} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta})}{\int_{\Theta} p(\mathbf{y} \mid \boldsymbol{\theta}) p(\boldsymbol{\theta}) d\boldsymbol{\theta}} \quad (2-29)$$

式(2-29)等号右边项的分母被称为边缘概率密度函数，其恒定为正且与 θ 无关。选择后验分布 $p(\theta|\mathbf{y})$ 的最大后验估计 $\hat{\theta}_{\text{MAP}}$ 作为 θ 的估计，即

$$\hat{\theta}_{\text{MAP}} = \arg \max_{\theta \in \Theta} p(\theta|\mathbf{y}) = \arg \max_{\theta \in \Theta} \frac{p(\mathbf{y}|\theta)p(\theta)}{\int_{\Theta} p(\mathbf{y}|\theta)p(\theta) d\theta} = \arg \max_{\theta \in \Theta} p(\mathbf{y}|\theta)p(\theta) \quad (2-30)$$

当先验分布 $p(\theta)$ 是均匀分布时，MAP 估计和 ML 估计一致。

定义 2.11 (期望最大化方法) 在统计推理中，EM 算法是一种被广泛应用于含有隐变量的 ML 估计和 MAP 估计的迭代方法。不同于^[182]中的推导，本文从 Kullback-Leibler 散度的角度导出 EM 算法，为后续章节的论述提供基础。在含有隐变量 z 的情况下，引入 z 的概率密度函数 $q(z)$ ，则 ML 估计中的对数似然函数可以表达为

$$\ell(\theta) = \ln p(\mathbf{y}; \theta) = \int q(z) \ln p(\mathbf{y}; \theta) dz = \int q(z) \ln \left(\frac{p(\mathbf{y}, z; \theta)}{p(z|\mathbf{y}; \theta)} \right) dz \quad (2-31a)$$

$$= \int q(z) \ln \left(\frac{p(\mathbf{y}, z; \theta)}{q(z)} \right) dz - \int q(z) \ln \left(\frac{p(z|\mathbf{y}; \theta)}{q(z)} \right) dz \quad (2-31b)$$

$$= D_{\text{KL}}(q(z) \| p(z|\mathbf{y}; \theta)) - D_{\text{KL}}(q(z) \| p(\mathbf{y}, z; \theta)) \quad (2-31c)$$

$$\geq -D_{\text{KL}}(q(z) \| p(\mathbf{y}, z; \theta)) \quad (2-31d)$$

当 $q(z) = p(z|\mathbf{y}; \theta)$ 时， $D_{\text{KL}}(q(z) \| p(z|\mathbf{y}; \theta)) = 0$ ，式(2-31d)取得等号。由上式可知，可将 $-D_{\text{KL}}(q(z) \| p(\mathbf{y}, z; \theta))$ 视为 $\ell(\theta)$ 的下界，该下界也称为证据下界 (Evidence Lower Bound, ELBO)。所以，关于 θ 最大化 $\ell(\theta)$ 等效于最大化 ELBO。从迭代算法的角度，由当前估计 $\theta^{(i)}$ 获得下一步估计 $\theta^{(i+1)}$ 的步骤为

1) 固定 $\theta^{(i)}$ ，计算后验概率密度 $q(z) = p(z|\mathbf{y}; \theta^{(i)})$;

2) 固定后验概率 $q(z) = p(z|\mathbf{y}; \theta^{(i)})$ ，通过最大化 ELBO 计算 $\theta^{(i+1)}$ 。此时，有

$$\text{ELBO} = \int p(z|\mathbf{y}; \theta^{(i)}) \ln p(\mathbf{y}, z; \theta) dz - \int p(z|\mathbf{y}; \theta^{(i)}) \ln p(z|\mathbf{y}; \theta^{(i)}) dz \quad (2-32)$$

式(2-32)右端第一项为 $Q(\theta, \theta^{(i)}) := \mathbb{E}_{p(z|\mathbf{y}; \theta^{(i)})} \{\ln p(\mathbf{y}, z; \theta)\}$ ，表示完全数据 $(\mathbf{y}, z)$ 的对数似然函数 $\ln p(\mathbf{y}, z; \theta)$ 对隐函数的后验分布 $p(z|\mathbf{y}; \theta^{(i)})$ 求期望，式(2-32)右端第二项为与 θ 无关的常数项。所以对 θ 最大化 ELBO 等价于最大化 $Q(\theta, \theta^{(i)})$ 。故本步骤包含如下两个子步骤：**(E-Step)** 求期望 $Q(\theta, \theta^{(i)})$ ；**(M-Step)** 最大化 $Q(\theta, \theta^{(i)})$ ： $\theta^{(i+1)} = \arg \max_{\theta} Q(\theta, \theta^{(i)})$ 。

EM 算法保证收敛到局部最优点，相关证明参考文献^[182]。

2.2.4 克拉美罗下界

多源定位问题本质上是一个多参数估计问题。在统计学和估计理论中，克拉美罗下界 (Cramér-Rao Lower Bound, CRLB) 提供了关于确定性参数的无偏估计量方差的下限，指出任何此类无偏估计量的方差至少不低于 Fisher 信息的逆。记确定性未知参数为 $\theta = [\theta_1, \theta_2, \dots, \theta_K]^T \in \mathbb{R}^K$ ，其在概率函数族中定义了观测数据 $\mathbf{y}$ 的概率密度函

数 $p(\mathbf{y}; \boldsymbol{\theta})$, 对 $\boldsymbol{\theta}$ 的估计子记为 $\hat{\boldsymbol{\theta}}$ 。在正式引入克拉美罗界之前先介绍 Fisher 信息矩阵 (Fisher Information Matrix, FIM) $\mathbf{J}(\boldsymbol{\theta})$ 和如下正则化条件。

定义 2.12 (Fisher 信息矩阵) 对于由 $\boldsymbol{\theta}$ 定义的概率密度函数 $p(\mathbf{y}; \boldsymbol{\theta})$, 其 Fisher 信息矩阵 $\mathbf{J}(\boldsymbol{\theta}) \in \mathbb{R}^{K \times K}$ 定义为

$$\mathbf{J}(\boldsymbol{\theta}) = \mathbb{E} \left\{ -\Delta_{\boldsymbol{\theta}}^{\boldsymbol{\theta}} \ln p(\mathbf{y}; \boldsymbol{\theta}) \right\} \quad (2-33)$$

其中, $\Delta_{\boldsymbol{\theta}}^{\boldsymbol{\theta}} = \nabla_{\boldsymbol{\theta}} \nabla_{\boldsymbol{\theta}}^T$ 为 Hessian (二阶偏微分) 算子, $\nabla_{\boldsymbol{\theta}}$ 为 Nabla 算子, 这里表示关于 $\boldsymbol{\theta}$ 的梯度算子。

定义 2.13 (正则化条件) 关于 $p(\mathbf{y}; \boldsymbol{\theta})$ 和 $\hat{\boldsymbol{\theta}}$ 定于如下正则化条件:

1) Fisher 信息始终有定义, 即对所有 $\mathbf{y}$, 满足 $p(\mathbf{y}; \boldsymbol{\theta}) > 0$, $\partial \ln p(\mathbf{y}; \boldsymbol{\theta}) / \partial \boldsymbol{\theta}$ 存在且有界。

2) 在关于 $\hat{\boldsymbol{\theta}}$ 的期望中, 对 $\mathbf{y}$ 的积分和对 $\boldsymbol{\theta}$ 的微分是可互换的, 即

$$\frac{\partial}{\partial \boldsymbol{\theta}} \left[\int p(\mathbf{y}; \boldsymbol{\theta}) \hat{\boldsymbol{\theta}} d\mathbf{y} \right] = \int \hat{\boldsymbol{\theta}} \left[\frac{\partial}{\partial \boldsymbol{\theta}} p(\mathbf{y}; \boldsymbol{\theta}) \right] d\mathbf{y} \quad (2-34)$$

基于上述定义, 克拉美罗下界定理表述如下。

定理 2.2 (克拉美罗下界^[183]) 假设 $p(\mathbf{y}; \boldsymbol{\theta})$ 和 $\hat{\boldsymbol{\theta}}$ 满足定义 2.13 中的正则化条件, 记 $\boldsymbol{\psi}(\boldsymbol{\theta}) = \mathbb{E}_{p(\mathbf{y}; \boldsymbol{\theta})} \left\{ \hat{\boldsymbol{\theta}} \right\} = \int \hat{\boldsymbol{\theta}} p(\mathbf{y}; \boldsymbol{\theta}) d\mathbf{y}$, 对任意估计子 $\hat{\boldsymbol{\theta}}$, 其协方差满足

$$\text{cov}(\hat{\boldsymbol{\theta}}) = \mathbb{E}_{p(\mathbf{y}; \boldsymbol{\theta})} \left\{ (\hat{\boldsymbol{\theta}} - \boldsymbol{\psi}(\boldsymbol{\theta})) (\hat{\boldsymbol{\theta}} - \boldsymbol{\psi}(\boldsymbol{\theta}))^T \right\} \succeq \frac{\partial \boldsymbol{\psi}(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}^T} \mathbf{J}(\boldsymbol{\theta})^{-1} \left(\frac{\partial \boldsymbol{\psi}(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}^T} \right)^T \quad (2-35)$$

其中, $\partial \boldsymbol{\psi}(\boldsymbol{\theta}) / \partial \boldsymbol{\theta}^T$ 为 Jacobian 矩阵, $[\partial \boldsymbol{\psi}(\boldsymbol{\theta}) / \partial \boldsymbol{\theta}^T]_{i,j} = \partial \psi_i(\boldsymbol{\theta}) / \partial \theta_j$ 。

推论 2.1 (无偏估计的 CRLB) 若 $\hat{\boldsymbol{\theta}}$ 为无偏估计, 即 $\boldsymbol{\psi}(\boldsymbol{\theta}) = \boldsymbol{\theta}$, 则 CRLB 退化为

$$\text{cov}(\hat{\boldsymbol{\theta}}) \succeq \mathbf{J}(\boldsymbol{\theta})^{-1} \quad (2-36)$$

若不方便计算 FIM 的逆, 则可以简单地取相应对角元素的倒数来计算 CRLB (可能略有放松)

$$\text{var}(\hat{\theta}_m) = [\text{cov}(\hat{\boldsymbol{\theta}})]_{mm} \geq [\mathbf{J}(\boldsymbol{\theta})^{-1}]_{mm} \geq ([\mathbf{J}(\boldsymbol{\theta})]_{mm})^{-1} \quad (2-37)$$

2.3 基于稀疏表征的多源定位

基于无线传感器网络的多源定位场景如图 2-1 所示。假设在感知区域内存在多个共信道辐射源, 传感器网络由感知区域内具有能量域/角度域/时间域测量功能的定位节点组成。本文假设在信号测量时间内, 辐射源和各定位节点的相对位移均可忽略不计, 即认为定位节点和辐射源均保持相对静止。本小节先介能量域、角度域、时间域多源定位问题。然后通过归纳, 总结出能够统一表示这些具体模型的广义的多源定位模型。最后针对广义多源定位模型, 通过参数域网格离散化近似, 引出基于稀疏表征的多源定位问题。




图 2-1 基于 WSN 的多源定位示意图

2.3.1 具体的多源定位问题

2.3.1.1 基于能量域测量的多源定位

设感知区域中无线传感器网络由 M 个具有能量测量功能的定位节点组成，其笛卡尔坐标集合为 $\mathcal{S} = \{\mathbf{s}_i, i=1, 2, \dots, M\}$ 。存在 K 个辐射源，其坐标集合为 $\mathcal{T} = \{\mathbf{q}_k, k=1, 2, \dots, K\}$ 。辐射源能量随距离的传播过程取决于辐射源的大小形状、传播环境、传播路径上的障碍物、辐射信号的频率等诸多因素。为简化该问题，考虑文献^[53,56-58,64,66,80-82,97-98]中采用的能量衰减模型，对基于 WSN 的能量域多源定位作如下假设：

假设 2.1 感知区域大小合适，辐射源的信号能被感知区域内的所有定位节点有效观测到。

假设 2.2 相对于感知区域大小，辐射源可被视为全向辐射的点源，定位节点可被视为一个忽略物理尺寸的点。

假设 2.3 传播介质是各向同性的，传播路径上的障碍物可以忽略不计，多径传播可以忽略不计。

假设 2.4 辐射信号与定位节点的测量噪声统计无关，不同辐射源之间的信号统计无关，不同定位节点间的测量噪声统计无关，噪声幅度和辐射信号幅度的均值为零。

基于前三条假设，研究表明辐射信号（如声信号，电磁信号等）的幅度随距离按照幂律衰减^[9,184]。诸如声信号，电磁信号等波形信号是可加的，第 i 个定位节点测量的辐射信号幅度可以表示为

$$r_i(n) = s_i(n) + v_i(n), i = 1, 2, \dots, M \quad (2-38)$$

其中, $s_i(n) = \rho_i \sum_{k=1}^K (a_k(n - t_{ki})/d_{ik}^{\gamma/2})$, ρ_i 为表示定位节点的传感器增益因子, $d_{ik} = \|\mathbf{s}_i - \mathbf{p}_k\|_2$ 为第 k 个辐射源到第 i 个定位节点的欧氏距离, γ 为路径损耗指数, $a_k(n - t_{ki})$ 是第 k 个辐射源的辐射信号, t_{ki} 为第 k 个辐射源到第 i 个定位节点的传播时延, $r_i(n)$ 为第 i 个定位节点的匹配滤波器在第 n 个采样间隔 $[1/f_s]$ 内的输出幅值 (f_s 为采样频率), $v_i(n)$ 是在第 n 个采样间隔内的零均值加性高斯白噪声 (Additive White Gaussian Noise, AWGN), 其方差为 ζ_i^2 。

基于第四条假设可得

$$\mathbb{E}\{r_i^2(n)\} = \mathbb{E}\{s_i^2(n)\} + \mathbb{E}\{v_i^2(n)\} \quad (2-39)$$

其中, $\mathbb{E}\{s_i^2(n)\} = g_i \sum_{k=1}^K (S_k(n - t_{ki})/d_{ik}^{\gamma})$, $S_k(n - t_{ki}) = \mathbb{E}\{a_k^2(n - t_{ki})\}$, $g_i = \rho_i^2$ 为定位节点的传感器增益。基于第一条假设, 可知传播时延带来幅度的变化可以忽略不计, 即 $a_k(n - t_{ki}) \approx a_k(n)$, $S_k(n - t_{ki}) \approx S_k(n)$ 。

在实际测量中, 式(2-39)中的期望操作可用时间窗 $[t - T/2, t + T/2]$ 内的数值平均来实现, 这里 $T = L/f_s$ 为时间窗长度, L 为时间窗内采样点的总个数。令 $y_i(t) = \mathbb{E}\{r_i^2(n)\}$, $t = \frac{T}{2}, \frac{3T}{2}, \frac{5T}{2}, \dots$, 表示 $[t - T/2, t + T/2]$ 内的数值平均, 则有

$$y_i(t) = \frac{1}{Tf_s} \sum_{n=(t-T/2)f_s}^{(t+T/2)f_s} r_i^2(n) = \underbrace{\frac{1}{Tf_s} \sum_{n=(t-T/2)f_s}^{(t+T/2)f_s} s_i^2(n)}_{:=y_{si}(t)} + \underbrace{\frac{1}{Tf_s} \sum_{n=(t-T/2)f_s}^{(t+T/2)f_s} v_i^2(n)}_{:=\varepsilon_i(t)} \quad (2-40)$$

$$= y_{si}(t) + \varepsilon_i(t) = g_i \sum_{k=1}^K \frac{S_k(t)}{d_{ik}^{\gamma}} + \varepsilon_i(t) \quad (2-41)$$

其中, $S_k(t) = \frac{1}{Tf_s} \sum_{n=(t-T/2)f_s}^{(t+T/2)f_s} a_k^2(n - t_{ki}) \approx \frac{1}{Tf_s} \sum_{n=(t-T/2)f_s}^{(t+T/2)f_s} a_k^2(n)$ 。因测量噪声 $v_i(n)$ 是零均值、方差为 ζ_i^2 的独立加性高斯白噪声, 从而 $v_i^2(n)$ 服从均值为 ζ_i^2 , 方差为 $\frac{2\zeta_i^4}{L}$ 的独立 χ^2 分布。若 L 足够大 (实际中 $L > 30$), 由中心极限定理 (central limit theorem) 可知, $\varepsilon_i(t)$ 近似服从正态分布: $\varepsilon_i(t) \sim \mathcal{N}(\varepsilon_i(t) | \zeta_i^2, \frac{2\zeta_i^4}{L})$ 。由于能量测量的底噪可由历史数据估计, 进而可在测量数据中去除底噪的影响。

因此, 上述能量域多源定位模型可等效为

$$y_i(t) = g_i \sum_{k=1}^K \frac{1}{d_{ik}^{\gamma}} S_k(t) + \varepsilon_i(t) \quad (2-42)$$

$$\varepsilon_i(t) \sim \mathcal{N}(\varepsilon_i(t) | 0, \sigma_i^2) \quad (2-43)$$

对所有定位节点 $i = 1, 2, \dots, M$, 令 $\mathbf{y}(t) = [y_1(t), y_2(t), \dots, y_M(t)]^T$, $[\Psi]_{ik} = g_i/d_{ik}^{\gamma}$, $\mathbf{w}(t) = [S_1(t), S_2(t), \dots, S_K(t)]^T$, $\mathbf{n}(t) = [n_1(t), n_2(t), \dots, n_M(t)]^T$, 则矩阵-矢量表示的能量域多源定位模型为

$$\mathbf{y}(t) = \Psi(\mathcal{T})\mathbf{w}(t) + \mathbf{n}(t) \quad (2-44)$$




图 2-2 均匀线阵 DOA 估计模型

在模型(2-44)中，感兴趣的未知量为辐射源的位置 $\mathcal{T}$ 和功率 $\mathbf{w}(t)$ 。其中，第 k 个辐射源的位置 $\mathbf{q}_k$ 由 Ψ 中的第 k 列 Ψ_k 唯一确定。

能量域多源定位问题指：在观测噪声 $\mathbf{n}(t)$ 未知的情况下，通过观测向量 $\mathbf{y}(t)$ 来估计多个辐射源的位置集合 $\mathcal{T}$ 和功率向量 $\mathbf{w}(t)$ 。数学上，可表示成如下优化问题

$$\min_{\mathbf{w}(t), \mathcal{T}} \|\mathbf{y}(t) - \Psi(\mathcal{T})\mathbf{w}(t)\|_2 \quad (2-45)$$

因辐射源位置集合 $\mathcal{T}$ 与能量测量 $\mathbf{y}$ 之间的非线性关系，式(2-45)表示的多源定位问题是一个高度非凸的非线性最小二乘问题，存在多个局部极值，无法直接求解。

2.3.1.2 基于角度域测量的多源定位

角度域多源定位包括 DOA 估计和纯方位角定位两部分。下面分别针对这两部分介绍相应的多源定位模型。

一、基于阵列天线的 DOA 估计^[185]

考虑感知空间中有 K 个辐射源，图2-1中的定位节点由具有 M 个全向阵元的均匀线性阵列 (Uniform Linear Array, ULA) 传感器组成。对辐射源信号作出如下假设：

假设 2.5 辐射源信号为窄带信号。

假设 2.6 辐射源信号为远场信号。

由第一条假设可知窄带信号包络变化缓慢，ULA 各阵元接收信号的包络相同。由第二条假设可知，辐射源与阵元距离足够远，辐射信号到达各阵元的波前为平面波。据此可知，第 k 个远场窄带信号到达各阵元的直射线与阵列法线之间的夹角相同，记为 θ_k ，称为波达方向角 (DOA)。

如图2-2所示，以阵元 1 为参考阵元，记第 t 个采样时刻（也称快拍）第 k 个辐射信号在阵元 1 上的接收信号为 $w_k(t)$ 。相对于参考阵元，该辐射信号到达其它阵元的时间存在延迟或超前。令 ω_k 为相对于阵元 1，阵元 2 上接收信号 $w_k(t)$ 因传播延迟

引起的相位差，则波达方向 θ_k 与 ω_k 之间存在如下关系

$$\omega_k = 2\pi \frac{d}{\lambda_k} \sin \theta_k \quad (2-46)$$

其中， λ_k 为第 k 个辐射信号的波长， d 为相邻阵元间隔。由于各窄带辐射源共信道，所以有 $\lambda_k = \lambda$ ， $k = 1, 2, \dots, K$ 。为避免“相位模糊”问题，即因 $\omega_k > \pi$ 时无法区分 θ_k 和 $\pi + \theta_k$ 的问题，阵元间距 d 需满足“半波长”条件，即 $d \leq \lambda/2$ 。显而易见，对于第 i 个阵元，其与参考阵元的相位差为 $(i-1)\omega_k$ 。信号 $w_k(t)$ 到达各阵元的相位差所组成的向量

$$\mathbf{a}(\theta_k) = [1, e^{j\omega_k}, \dots, e^{j(M-1)\omega_k}]^T = [a_1(\theta_k), a_2(\theta_k), \dots, a_M(\theta_k)]^T \quad (2-47)$$

称为信号 $w_k(t)$ 的导向矢量 (steering vector)，几何上表示指向第 k 个辐射源的矢量 (即波束)。对于感知区域内的所有的 K 个辐射源，第 i 个阵元上的观测信号 $y_i(t)$ 为

$$y_i(t) = \sum_{k=1}^K a_i(\theta_k) w_k(t) + \varepsilon_i(t), \quad i = 1, 2, \dots, M \quad (2-48)$$

式(2-48)中， $\varepsilon_i(t)$ 为加性测量噪声。令 $\boldsymbol{\theta} = \{\theta_1, \theta_2, \dots, \theta_K\}$ 表示 K 个辐射源的 DOA 序列， $\mathbf{y}(t) = [y_1(t), y_2(t), \dots, y_M(t)]^T$ 表示 M 个阵元上的观测数据组成的观测信号向量， $\mathbf{w}(t) = [w_1(t), w_2(t), \dots, w_K(t)]^T$ 表示信号向量， $\mathbf{n}(t) = [\varepsilon_1(t), \varepsilon_2(t), \dots, \varepsilon_M(t)]^T$ 表示测量噪声矢量， $[\Psi]_{ik} = a_i(\theta_k)$ ，则式(2-48)所代表的 DOA 估计模型的矩阵-向量表示形式为

$$\mathbf{y}(t) = \boldsymbol{\Psi}(\boldsymbol{\theta})\mathbf{x}(t) + \mathbf{n}(t) \quad (2-49)$$

在模型(2-49)中，感兴趣的未知量为辐射源的 DOA，其中第 k 个辐射源的波达角度 θ_k 由 $\boldsymbol{\Psi}(\boldsymbol{\theta})$ 中的第 k 列 $\boldsymbol{\Psi}_k$ 唯一确定。同时，辐射源的幅度也提供了一定信息，第 k 个辐射源的幅度 $w_k(t)$ 由 $\mathbf{w}(t)$ 的第 k 个元素表示。

DOA 估计问题指：给定阵列天线传感器的观测向量 $\mathbf{y}(t)$ ，寻找最符合该观测的 DOA 序列 $\boldsymbol{\theta}$ 。经典的 DOA 估计方法有基于子空间的空间谱估计方法，如 MUSIC 算法及其衍生算法等。

二、纯方位角多源定位

考虑多定位节点多辐射源的纯方位角定位问题。图2-3展示了二维情况下由三个具备阵列传感器的定位节点定位三个辐射源的情况。设感知区域内存在 K 个辐射源和 M_0 个测向定位节点，其位置集合分别为 $\mathcal{T} = \{\mathbf{q}_k, k=1, 2, \dots, K\}$ 和 $\mathcal{S} = \{\mathbf{s}_i, i=1, 2, \dots, M_0\}$ 。记第 i 个定位节点测得第 k 个辐射源的方位角为 $\theta_{i,k}$ ，本文假设对于所有传感器节点， $\theta_{i,k}$ 是在统一坐标系下已经校正了阵列天线法向方向影响的结果。




图 2-3 基于纯方位角的多源定位示意图

对于所有定位节点，若各辐射源可被定位节点唯一识别，则有统一按照辐射源次序排列的方位角序列 $\{\theta_{i,1}, \theta_{i,2}, \dots, \theta_{i,K}\}$, $i=1, 2, \dots, M_0$ 。在精确已知各定位节点的该序列后，要定位第 k 个辐射源，可取所有定位节点的关于第 k 个辐射源的方位角 $\{\theta_{i,k}, i=1, 2, \dots, M_0\}$ 按照几何方法获得这些方位线交点，求出第 k 个辐射源最可能的位置。在此情况下，多源定位问题退化成 K 个单源定位问题。

然而，在定位节点无法区分各辐射源的情况下，第 i 个定位节点不能从实际的方位角测量序列 $\{\theta_i^{(1)}, \theta_i^{(2)}, \dots, \theta_i^{(K)}\}$ 中获得按照辐射源次序排列的序列 $\{\theta_{i,1}, \theta_{i,2}, \dots, \theta_{i,K}\}$ ，也就无法将多源定位问题转化为单源定位问题来求解。现有基于纯方位角的多源定位通过定位节点两两分组交叉定位，得到如图2-3所示的虚假位置交叉点（鬼点）和真实辐射源位置交叉点的位置集合，然后再依据一定的判断准则排除鬼点，留下真实的辐射源位置交叉点，从而定位多个辐射源的位置^[136,144-146]。然而，实际中的方位角测量往往受噪声干扰，测向交叉算法无法在真实辐射源位置处得到交叉点，上述方法无法有效定位多个辐射源。

一方面，受能量域多源定位模型的启发，本章提出一种新颖的纯方位角多源定位模型。不妨以 2D 感知区域为例，设辐射源位置 $\mathbf{q}_k = (u_k^t, v_k^t)$ ，定位节点位置 $\mathbf{s}_i = (u_i^s, v_i^s)$ ，真实方位角 $\theta_{i,k}$ 之间满足

$$\theta_{i,k} = f_i(\mathbf{q}_k) = \arctan \frac{u_k^t - u_i^s}{v_k^t - v_i^s} \quad (2-50)$$

其次，虽然 $\theta_i^{(k)} \neq \theta_{i,k}$ ，但对于序列 $\{\theta_{i,1}, \theta_{i,2}, \dots, \theta_{i,K}\}$ 和序列 $\{\theta_i^{(1)}, \theta_i^{(2)}, \dots, \theta_i^{(K)}\}$ 之间存在如下的恒等式

$$\sum_{k=1}^K \theta_i^{(k)} = \sum_{k=1}^K \theta_{i,k} = f_i(\mathbf{q}_k), \quad i=1, 2, \dots, M_0 \quad (2-51)$$

对定位节点 i 的方位角测量序列 $\{\theta_i^{(1)}, \theta_i^{(2)}, \dots, \theta_i^{(K)}\}$ 按上式进行等比例混叠得到转换后的测量值 $y_i = \sum_{k=1}^K \theta_i^{(k)}$ ，则有

$$y_i = \sum_{k=1}^K \theta_{i,k} + n_i = \sum_{k=1}^K f_i(\boldsymbol{\varrho}_k) + n_i \quad (2-52)$$

其中, n_i 表示测量噪声和建模误差。

另一方面, 纯方位角多源定位又不同于能量域多源定位。在能量域多源定位中, 测量结果 y_i 是实际的能量混叠值。而在模型(2-52)表示的纯方位角多源定位中, 测量结果 y_i 是实际测量序列 $\{\theta_i^{(1)}, \theta_i^{(2)}, \dots, \theta_i^{(K)}\}$ 的等比例人工混叠。从信息论的角度来看, 序列 $\{\theta_i^{(1)}, \theta_i^{(2)}, \dots, \theta_i^{(K)}\}$ 中含有的信息要远远大于单个 y_i 含有的信息。为充分利用序列的信息, 可对 $\{\theta_i^{(1)}, \theta_i^{(2)}, \dots, \theta_i^{(K)}\}$ 做不同变换下的等比例混叠, 获取更多的变换测量结果, 有以下恒等式成立

$$\sum_{k=1}^K h_n(\theta_i^{(k)}) = \sum_{k=1}^K h_n(\theta_{i,k}), \quad i = 1, 2, \dots, M_0 \quad (2-53)$$

其中, 变换函数 $h_n: \mathbb{R} \mapsto \mathbb{R}$ 为一一映射。为尽可能地增加有效测量, 可取正交函数族作为变换函数, 如多项式函数族 $\{h_n(x) = x^n \mid x \in [-\infty, +\infty], n = 1, 2, \dots\}$, 或三角函数族 $\{h_n(x) = \sin(nx) \mid x \in [-\pi, \pi], n = 1, 2, \dots\}$ 。实际上, 式(2-51)中的变换函数为多项式函数族 $n = 1$ 的特例。

取 L 个正交函数 $\{h_l(\cdot) \mid l = 1, 2, \dots, L\}$ 作为变换函数, 有 $y_{li} = \sum_{k=1}^K h_l(\theta_i^{(k)})$ 。令 $M = LM_0$, $\mathbf{n} = [n_1, n_2, \dots, n_M]^T$, $\mathbf{y} = [y_{11}, \dots, y_{1M_0}, y_{21}, \dots, y_{2M_0}, \dots, y_{L1}, \dots, y_{LM_0}]^T$, $[\Psi]_{lik} = h_l(f_i(\boldsymbol{\varrho}_k))$, 则本章提出的纯方位角多源定位模型可表示为

$$\mathbf{y} = \Psi(\mathcal{T})\mathbf{1}_K + \mathbf{n} \quad (2-54)$$

在模型(2-54)中, 感兴趣的未知量为辐射源的位置 $\mathcal{T}$, 其中第 k 个辐射源的位置 $\boldsymbol{\varrho}_k$ 由 Ψ 中的第 k 列 Ψ_k 唯一确定。在模型(2-54)下, 纯方位角多源定位问题指: 给定变换后的方位角混叠测量 $\mathbf{y}$, 寻找最符合该测量的辐射源位置集合 $\mathcal{T}$ 。数学上, 可表示为

$$\min_{\mathcal{T}} \|\mathbf{y} - \Psi(\mathcal{T})\mathbf{1}_K\|_2 \quad (2-55)$$

同样, 该问题是一个高度非凸的非线性最小二乘问题, 难以直接求解。

2.3.1.3 基于时间域测量的多源定位

时间域多源定位和角度域多源定位类似, 分为 TOA 或 TDOA 估计、TOA 或 TDOA 定位两部分。因为所考虑问题为非合作的多源定位, 所以本文不研究 TOA 相关的定位方法。下面分别介绍 TDOA 估计和基于 TDOA 的多源定位问题。设感知区域内存在 K 个辐射源和 M_0 个具备时间域测量功能的定位节点, 其位置集合分别为 $\mathcal{T} = \{\boldsymbol{\varrho}_k, k = 1, 2, \dots, K\}$ 和 $\mathcal{S} = \{\mathbf{s}_i, i = 1, 2, \dots, M_0\}$ 。

一、TDOA 估计

记第 k 个辐射源的辐射信号为 $a_k(t)$ ，第 i 定位节点的接收信号为 $r_i(t)$ ，测量噪声为 $n_i(t)$ 。为简化模型，本文作出如下假设：

假设 2.7 传播环境各向同性，传播路径上无障碍物遮挡，多径传播可被忽略。

假设 2.8 辐射信号和噪声均为遍历的、互不相关的序列。

基于第一条假设， $r_i(t)$ 可表示为

$$r_i(t) = \sum_{k=1}^K h_{i,k} a_k(t - \tau_{i,k}) + n_i(t) \quad (2-56)$$

其中， $h_{i,k}$ 为单抽头平坦衰落信道的信道系数， $\tau_{i,k} = \|\mathbf{p}_k - \mathbf{s}_i\|/c$ 为第 k 个辐射源到第 i 个定位节点的传播时延， c 为介质中辐射信号的传播速度。

基于第二条假设有

$$\int a_k(t) a_{k'}(t - \tau) dt = \begin{cases} 0, & k \neq k' \\ \delta(\tau), & k = k' \end{cases}, \int n_i(t) n_j(t - \tau) dt = \begin{cases} 0, & i \neq j \\ \delta(\tau), & i = j \end{cases}, \int n_i(t) a_k(t) dt = 0 \quad (2-57)$$

在非合作的定位方式下，通过求各定位节点接收信号与参考节点接收信号的互相关是计算 TDOA 的最优方式。不妨以第一个定位节点作为参考节点，则由式(2-57)可知第 i 个定位节点与参考节点的互相关 $R_i(\tau), i = 2, 3, \dots, M_0$ 为

$$\begin{aligned} R_i(\tau) &= \int r_i(t) r_1(t - \tau) dt \\ &= \int \left(\sum_{k=1}^K h_{i,k} a_k(t - \tau_{i,k}) + n_i(t) \right) \left(\sum_{k'=1}^K h_{1,k'} a_{k'}(t - \tau - \tau_{1,k'}) + n_1(t - \tau) \right) dt \\ &= \sum_k^K \sum_{k'}^K \int \left(h_{i,k} a_k(t - \tau_{i,k}) + n_i(t) \right) \left(h_{1,k'} a_{k'}(t - \tau - \tau_{1,k'}) + n_1(t - \tau) \right) dt \\ &= \sum_{k=1}^K h_{i,k} h_{1,k} \delta(\tau - \theta_{i,k}) \end{aligned} \quad (2-58)$$

其中， $\theta_{i,k}$ 为相对参考节点，第 k 个辐射源到第 i 个定位节点的 TDOA 值，定义为

$$\theta_{i,k} = \tau_{1,k} - \tau_{i,k} = f_i(\mathbf{p}) = \frac{\|\mathbf{p}_k - \mathbf{s}_1\| - \|\mathbf{p}_k - \mathbf{s}_i\|}{c} \quad (2-59)$$

通过对互相关函数进行峰值搜索，可获得第 i 个定位节点的 TDOA 测量序列 $\{\theta_i^{(1)}, \theta_i^{(2)}, \dots, \theta_i^{(K)}\}$ 。

二、基于 TDOA 的多源定位

同基于纯方位角的多源定位一样，对于所有定位节点，若各辐射源可被定位节点唯一识别，则有按辐射源次序排列的 TDOA 序列 $\{\theta_{i,1}, \theta_{i,2}, \dots, \theta_{i,K}\}, i = 1, 2, \dots, M_0$ 。在精确已知各定位节点的该序列后，要定位第 k 个辐射源，可取所有的定位节点的

关于第 k 个辐射源的 TDOA 测量 $\{\theta_{i,k}, i = 1, 2, \dots, M_0\}$ ，然后用传统的 TDOA 单源定位方法求出第 k 个辐射源最可能的位置。在此情况下，多源定位问题退化成 K 个单源定位问题。

在定位节点无法区分各辐射源的情况下，第 i 个定位节点不能从实际的 TDOA 测量序列中获得按辐射源次序排列 $\{\theta_{i,1}, \theta_{i,2}, \dots, \theta_{i,K}\}$ ，也就无法将多源定位问题转化为单源定位问题来求解。同在纯方位角多源定位中提出的方法一样，取 L 个正交函数 $\{h_l(\cdot) | l = 1, 2, \dots, L\}$ 作为变换函数对定位节点 i 的 TDOA 测量序列 $\{\theta_i^{(1)}, \theta_i^{(2)}, \dots, \theta_i^{(K)}\}$ 按照式(2-51)进行转换，得到转换后的测量 $y_{li} = \sum_{k=1}^K h_l(\theta_i^{(k)})$ ，且有

$$y_{li} = \sum_{k=1}^K h_l(\theta_{i,k}) + n_i = \sum_{k=1}^K h_l(f_i(\boldsymbol{\theta}_k)) + n_i \quad (2-60)$$

其中， n_i 表示测量噪声和建模误差。同式(2-54)一样，得到基于 TDOA 的多源定位模型如下

$$\mathbf{y} = \boldsymbol{\Psi}(\mathcal{T})\mathbf{1}_K + \mathbf{n} \quad (2-61)$$

数学上，基于该模型的 TDOA 多源定位问题可表示为

$$\min_{\mathcal{T}} \|\mathbf{y} - \boldsymbol{\Psi}(\mathcal{T})\mathbf{1}_K\|_2 \quad (2-62)$$

同理，该问题是一个高度非凸的非线性最小二乘问题，难以直接求解。

2.3.2 广义的多源定位问题

科学研究的规律之一是通过总结归纳，发现事物之间的共性和特性，进而总结出一般规律和特殊规律。在2.3.1小节的前三部分中，本文用同样的符号表述体系介绍了能量域、角度域和时间域多源定位问题，其背后的动机是上述模型均可被归纳为一个广义的多源定位模型：

$$y_i = \sum_{k=1}^K f_i(\theta_k)w_k + n_i, \quad i = 1, 2, \dots, M \quad (2-63)$$

其中， y_i 为已知的测量值， $f_i(\theta_k)$ 是目标参数 $\boldsymbol{\theta}$ 的第 k 个分量 θ_k 的变换函数， w_k 是与 θ_k 相关的系数， n_i 表示测量噪声和建模误差。式(2-63)所示的广义多源定位模型与前述的能量域多源定位模型(2-42)、角度域多源定位模型(2-48)和(2-52)、时间域多源定位模型(2-60)的对应关系见表2-1。

令 $\mathbf{y} = [y_1, y_2, \dots, y_M]^T$ ， $\mathbf{w} = [w_1, w_2, \dots, w_K]^T$ ， $\mathbf{n} = [n_1, n_2, \dots, n_M]^T$ ， $[\Psi]_{ik} = f_i(\theta_k)$ ， $\boldsymbol{\theta} = [\theta_1, \theta_2, \dots, \theta_K]^T$ ，则矩阵-向量表示的广义多源定位模型为

$$\mathbf{y} = \boldsymbol{\Psi}(\boldsymbol{\theta})\mathbf{w} + \mathbf{n} \quad (2-64)$$

式(2-63)和式(2-64)中，感兴趣的未知参数 $\boldsymbol{\theta}$ 分布在矩阵 $\boldsymbol{\Psi}(\boldsymbol{\theta})$ 中，且 θ_k 与矩阵 $\boldsymbol{\Psi}(\boldsymbol{\theta})$ 的第 k 列 $\boldsymbol{\Psi}_k$ 唯一对应。由表2-1可知，该对应关系一般为非线性映射。

表 2-1 广义多源定位模型与具体模型的联系

广义多源定位模型(2-63)	$y_i = \sum_{k=1}^K f_i(\theta_k)w_k + n_i$			
具体模型	测量值 y_i	未知参数 θ_k	变换函数 $f_i(\theta_k)$	变换系数 w_k
能量域多源定位(2-42)	能量测量 $y_i(t)$	辐射源位置 $\mathbf{q}_k$	$\frac{g_i}{\ \mathbf{s}_i - \mathbf{q}_k\ _2^\gamma}$	辐射功率 $S_k(t)$
DOA 估计(2-48)	接收信号 $y_i(t)$	辐射源 DOA θ_k	$\exp\left[j2\pi\frac{(i-1)d}{\lambda}\sin\theta_k\right]$	辐射信号 $w_k(t)$
纯方位角定位(2-52)	方位角序列变换后的测量值 y_i	辐射源位置 $\mathbf{q}_k$	$h_{l_i}(\arctan\frac{u_k^t - u_i^s}{v_k^t - v_i^s})$	1
基于 TDOA 的多源定位(2-60)	TDOA 序列变换后的测量值 y_i	辐射源位置 $\mathbf{q}_k$	$h_{l_i}(\frac{\ \mathbf{q}_k - \mathbf{s}_1\ - \ \mathbf{q}_k - \mathbf{s}_i\ }{c})$	1

广义多源定位问题指：由观测矢量 $\mathbf{y}$ 来反演参数空间中最可能的 $\boldsymbol{\theta}$ 。其中，系数向量 $\mathbf{w}$ 和噪声向量 $\mathbf{n}$ 可能已知，也可能未知。数学上，广义多源定位可表示为

$$\min_{\boldsymbol{\theta}, \mathbf{w}} \|\mathbf{y} - \Psi(\boldsymbol{\theta})\mathbf{w}\|_2 \quad (2-65)$$

问题(2-65)所示的广义多源定位问题是一个非线性逆问题 (inverse problem)。对于以 $\mathbf{w}$ 为输入， $\mathbf{y}$ 为输出的系统，其系统结构的构成形式 $f_i(\theta_k)$ 是已知的，而系统构成的参数 $\boldsymbol{\theta}$ 是未知的。故从系统辨识的角度来看，式(2-63)和式(2-64)描述了一个灰盒系统 (gray box)。从应用层面上来看，式(2-63)和式(2-64)表示的广义多源定位模型不仅能表示前述的具体多源定位模型，也能表示语音处理、图像处理等诸多领域中的相关模型。所以，解决广义多源定位问题不仅能够求解具体的多源定位问题，而且对其他领域中的问题求解具有重要适用价值。客观上，这也更加凸显了多源定位问题参数估计和信号处理的本质特征。

2.3.3 基于稀疏表征的多源定位问题

式(2-63)和式(2-64)所刻画的广义多源定位问题是高度非凸非线性的连续优化问题，难以直接求解。一种有效且普适的求解方法是通过对 $\boldsymbol{\theta}$ 所属的参数空间 Θ 进行网格离散化，得到网格化的离散参数空间 $\mathcal{G} = \{\mathbf{g}_j, j = 1, 2, \dots, N\}$ 。假设对 $k = 1, 2, \dots, K$ ，真实参数 $\theta_k \in \mathcal{G}$ ，则可通过变换函数 $f_i(\mathbf{g}_j)$ 构建 $M \times N$ 的过完备表示字典 (或过完备定位字典)

$$\Phi = \begin{bmatrix} f_1(\mathbf{g}_1) & f_1(\mathbf{g}_2) & \cdots & f_1(\mathbf{g}_N) \\ f_2(\mathbf{g}_1) & f_2(\mathbf{g}_2) & \cdots & f_2(\mathbf{g}_N) \\ \vdots & \vdots & \ddots & \vdots \\ f_M(\mathbf{g}_1) & f_M(\mathbf{g}_2) & \cdots & f_M(\mathbf{g}_N) \end{bmatrix} \quad (2-66)$$



在压缩感知语境中,字典 Φ 被称为感知矩阵, Φ 的列 Φ_j 被称为原子。因原子 Φ_j 由网格点 g_j 唯一确定,故原子和网格点具有等价性,文献也直接称原子为网格点。

令 $\mathbf{x} = [x_1, x_2, \dots, x_N]^T$ 为权重向量或系数向量,则式(2-64)中的观测向量 $\mathbf{y}$ 可被过完备字典 Φ 稀疏表出

$$\mathbf{y} = \Phi \mathbf{x} + \mathbf{n}, \quad x_j = \begin{cases} 0, & \forall k \in 1, 2, \dots, K, \text{均有 } g_j \neq \theta_k \\ w_k & \exists k \in 1, 2, \dots, K, \text{满足 } g_j = \theta_k \end{cases}, \quad (2-67)$$

对参数空间的网格离散化是一个人为划定的过程,为获得更精细的估计结果,倾向于进行细密的网格离散化,一般有 $N \gg K$, 所以 $\mathbf{x}$ 是一个 K -稀疏向量。式(2-64)中需要推断的未知参数为 θ 和 $\mathbf{w}$ 。在式(2-67)中,由于参数空间 Θ 已被网格离散化成 $\mathcal{G}$, 且 $\mathbf{x}$ 的支撑集编码了真实参数 θ 在 $\mathcal{G}$ 中的索引,所以可由 $\mathbf{x}$ 确定 θ , 从而需要推断的未知参数只有稀疏向量 $\mathbf{x}$ 。从线性代数的角度来看,方程(2-67)描述了一个欠定系统 (underdetermined linear system)。若不对 $\mathbf{x}$ 施加先验约束,问题(2-67)将是一个病态问题 (ill-posed problem)。

基于稀疏表征的广义多源定位旨在获得尽可能稀疏的解向量 $\mathbf{x}$ (实际上是 K -稀疏向量)。所以,广义多源定位问题可被描述成一个稀疏解码问题

$$\min_{\mathbf{x}} \|\mathbf{x}\|_0, \quad \text{s.t. } \|\mathbf{y} - \Phi \mathbf{x}\|_2 \leq \zeta \quad (2-68a)$$

$$\text{或 } \min_{\mathbf{x}} \|\mathbf{y} - \Phi \mathbf{x}\|_2, \quad \text{s.t. } \|\mathbf{x}\|_0 \leq K \quad (2-68b)$$

$$\text{或 } \min_{\mathbf{x}} \|\mathbf{y} - \Phi \mathbf{x}\|_2 + \lambda \|\mathbf{x}\|_0 \quad (2-68c)$$

其中, ζ 为噪声水平, $\lambda > 0$ 为 Lagrange 乘子。问题(2-68c)是问题(2-68a)和问题(2-68b)基于 Lagrange 乘子法转化后的无约束问题。

式(2-68)所示稀疏解码问题是一个线性逆问题,相对广义多源定位的原始非线性逆问题(2-65)而言,其求解难度已有所衰减。但由组合优化理论可知,最小化非凸的 ℓ_0 范数是一个 NP-hard 问题^[186], 问题(2-68)仍无法直接求解。在过去三十多年中,研究人员针对该问题从不同出发点提出了大量数值上易于求解的逼近算法,并对算法的理论性能保障进行了证明。这些工作开创了信号处理领域中非常重要的一个课题:稀疏恢复理论和算法^[187]。

2.4 稀疏恢复算法

本小节介绍一些典型的稀疏恢复算法,包括以 OMP^[188] 为代表的贪婪类方法、以基追踪降噪 (Basis Pursuit Denoising, BPDN) 算法^[189] 为代表的优化类方法、以稀疏贝叶斯学习 (SBL)(亦称相关向量机)^[190] 为代表的概率类方法。

Algorithm 2.1: 匹配追踪算法 (MP)^[191]**Input:** $\mathbf{y}, \Phi$

- 1 初始化迭代次数 $l = 0$, 残差 $\mathbf{r}^{(0)} = \mathbf{y}$, 支撑集 $\Omega = \emptyset$, $\mathbb{N} = \{1, 2, \dots, N\}$;
- 2 **while** 不满足终止条件 **do**
- 3 从字典 Φ 中寻找与当前残差最相关的原子, 其索引为 $j_0 = \arg \max_j |\langle \Phi_j, \mathbf{r}^{(l)} \rangle|$;
- 4 更新支撑集 $\Omega = \Omega \cup j_0$, 更新残差 $\mathbf{r}^{(l+1)} = \mathbf{r}^{(l)} - \langle \Phi_{j_0}, \mathbf{r}^{(l)} \rangle \Phi_{j_0} / (\Phi_{j_0}^T \Phi_{j_0})$;

Output: Oracle 重建: $\hat{\mathbf{x}}_\Omega = \Phi_\Omega^\dagger \mathbf{y}$, $\hat{\mathbf{x}}_{\mathbb{N} \setminus \Omega} = \mathbf{0}$ **Algorithm 2.2:** 正交匹配追踪算法 (OMP)^[188]**Input:** $\mathbf{y}, \Phi$

- 1 初始化迭代次数 $l = 0$, 残差 $\mathbf{r}^{(0)} = \mathbf{y}$, 支撑集 $\Omega = \emptyset$, $\mathbb{N} = \{1, 2, \dots, N\}$;
- 2 **while** 不满足终止条件 **do**
- 3 从字典 Φ 中寻找与当前残差最相关的原子, 其索引为 $j_0 = \arg \max_j |\langle \Phi_j, \mathbf{r}^{(l)} \rangle|$;
- 4 更新支撑集 $\Omega = \Omega \cup j_0$, 计算 Φ_Ω 列空间的正交投影算子 $\mathbf{P} = \Phi_\Omega (\Phi_\Omega^T \Phi_\Omega)^{-1} \Phi_\Omega^T$;
- 5 更新残差 $\mathbf{r}^{(l+1)} = (\mathbf{I} - \mathbf{P}) \mathbf{r}^{(l)}$;

Output: Oracle 重建: $\hat{\mathbf{x}}_\Omega = \Phi_\Omega^\dagger \mathbf{y}$, $\hat{\mathbf{x}}_{\mathbb{N} \setminus \Omega} = \mathbf{0}$ **2.4.1 贪婪类方法**

对于稀疏编码模型 $\mathbf{y} = \Phi \mathbf{x} + \mathbf{n}$, 贪婪类稀疏恢复算法旨在求解问题(2-68b), 即

$$\min_{\mathbf{x}} \|\mathbf{y} - \Phi \mathbf{x}\|_2, \quad \text{s.t. } \|\mathbf{x}\|_0 \leq K$$

其基本原理是通过贪婪的方式迭代寻找稀疏向量 $\mathbf{x}$ 的支撑集, 并在估计的支撑集上使用最小二乘法来重构信号。虽然 Mallat 等人于 1993 年提出的匹配追踪算法 (Matching Pursuit, MP)^[191] 很少被应用于稀疏重建中, 但其奠定了贪婪类稀疏恢复算法的基础, 并引入了匹配追踪的概念。MP 算法流程如算法2.1所示。在 MP 算法中, 字典原子不是相互正交的向量。因此在算法2.1步骤 (4) 中, 减去投影计算残差的过程中会再次引入与前面使用的原子不正交的成分, 导致同一原子在不同迭代次数中被多次选择。所以, MP 算法收敛慢, 恢复结果的稀疏度差。针对 MP 存在的问题, Tropp 等人于 2007 年提出了正交匹配追踪算法 (OMP)。OMP 算法流程如算法2.2所示。

从算法2.1和算法2.2可以看出, OMP 和 MP 的本质区别在于残差的更新策略不同。每次更新残差时, OMP 算法减去的是残差 $\mathbf{r}^{(l)}$ 在所有被选择过的原子组成的矩阵 Φ_Ω 所张成空间上的正交投影, 而 MP 算法减去的是 $\mathbf{r}^{(l)}$ 在本次选择的原子 Φ_{j_0} 所张成空间上的正交投影。所以, OMP 保证残差总是与已经选择过的原子正交。这意味着一个原子不会被选择两次, 算法会在有限的迭代次数内收敛。

对稀疏编码模型 $\mathbf{y} = \Phi \mathbf{x} + \mathbf{n}$ 定义信噪比 (Signal-to-Noise Ratio, SNR) 和最小平

均比 (Minimum-to-Average Ratio, MAR) 如下

$$\text{SNR} = \frac{\|\Phi \mathbf{x}\|_2^2}{\|\mathbf{n}\|_2^2}, \quad \text{MAR} = \frac{\min_j |x_j|}{\|\mathbf{x}\|_2^2 / K} \quad (2-69)$$

若存在常数 $c \in [0, 1)$, 对于所有的 K -稀疏向量 $\mathbf{x}$ 有

$$(1 - c)\|\mathbf{x}\|_2^2 \leq \|\Phi \mathbf{x}\|_2^2 \leq (1 + c)\|\mathbf{x}\|_2^2 \quad (2-70)$$

则称矩阵 Φ 满足 (K, c) 的 RIP 条件。满足式(2-70)的最小常数 c 称为等距常数 δ_K ^[96]。

对有噪观测下的 OMP 算法, 有关于精确恢复的充分条件和必要条件的定理, 以及率失真恢复定理如下^[192]。

定理 2.3 (精确恢复的充分条件) 设感知矩阵 Φ 的等距常数满足 $\delta_{K+1} \leq \frac{1}{1+\sqrt{K}}$, 若

$$\sqrt{\text{SNR}} > \frac{2\sqrt{K}(1 + \delta_{K+1})}{\left(1 - (\sqrt{K} + 1)\delta_{K+1}\right)\sqrt{\text{MAR}}} \quad (2-71)$$

则 OMP 算法能从有噪观测 $\mathbf{y} = \Phi \mathbf{x} + \mathbf{n}$ 中精确恢复 K -稀疏向量 $\mathbf{x}$ 的支撑集。

定理 2.4 (精确恢复的必要条件) 若要 OMP 算法从有噪观测 $\mathbf{y} = \Phi \mathbf{x} + \mathbf{n}$ 中精确恢复 K -稀疏向量 $\mathbf{x}$ 的支撑集, 则必须满足

$$\sqrt{\text{SNR}} > \frac{\sqrt{K}(1 + \delta_{K+1})}{\left(1 - \sqrt{K}\delta_{K+1}\right)\sqrt{\text{MAR}}} \quad (2-72)$$

定理 2.5 (率失真恢复定理) 令 $\kappa = \max_{i,j} \frac{|x_i|}{|x_j|}$ 。若 $\text{SNR} \geq \kappa^2 \delta_{2K}^{-3/2}$, 则 OMP 算法从有噪观测 $\mathbf{y} = \Phi \mathbf{x} + \mathbf{n}$ 中恢复 K -稀疏向量 $\mathbf{x}$ 的支撑集的误差率 ρ_{error} 满足

$$\rho_{\text{error}} \leq C \kappa^2 \delta_{2K}^{1/2} \quad (2-73)$$

其中, C 为常数。

OMP 算法简单有效, 在稀疏恢复应用中被广泛使用。通过改进 OMP 算法中存在的问题, 启发了后续的一系列贪婪恢复算法。针对 OMP 每次迭代均只选择与残差最相关的一列, 文献^[193]提出广义正交匹配追踪 (Generalized OMP, gOMP) 算法, gOMP 每次迭代选择与内积绝对值最大的 s 列作为本次迭代的支撑集估计。文献^[194]提出了正则化正交匹配追踪算法 (Regularized OMP, ROMP), ROMP 先选出内积绝对值最大的 K 列, 然后再从这 K 列中按正则化标准再选择出若干列作为本次迭代的支撑集估计。针对 OMP 算法中错误的原子一旦加入到估计的支撑集中就无法被剔除的问题, 文献^[195]将回溯思想引入匹配追踪中, 提出了压缩采样匹配追踪算法 (Compressed Sampling Matching Pursuit, CoSaMP)。针对上述算法需要知道稀疏度来终止迭代, 文献^[196]提出了分段正交匹配追踪 (Stagewise OMP, StOMP) 算法, StOMP 算法的独特优势是其无需稀疏度的先验知识。此外, 在 Majorization-Minimization 优化框架下提出的迭代硬阈值 (Iterative Hard Thresholding, IHT) 算法^[197]本质上也是一种贪婪算法。

2.4.2 优化类方法

对于稀疏编码模型 $\mathbf{y} = \Phi \mathbf{x} + \mathbf{n}$ ，优化类方法旨在通过凸优化或者最优化手段逼近问题(2-68c)的解，即逼近

$$\min_{\mathbf{x}} \|\mathbf{y} - \Phi \mathbf{x}\|_2 + \lambda \|\mathbf{x}\|_0$$

最常用的优化类方法是基追踪降噪算法 (BPDN)。鉴于 ℓ_1 范数是范数 ℓ_0 范数的最优凸逼近，BPDN 将目标问题(2-68c)松弛为

$$\min_{\mathbf{x}} \|\mathbf{y} - \Phi \mathbf{x}\|_2 + \lambda \|\mathbf{x}\|_1 \quad (2-74)$$

为去掉 ℓ_1 范数中绝对值的影响，将 $\mathbf{x}$ 分解为

$$\mathbf{x} = \mathbf{u} - \mathbf{v}, \quad \mathbf{u} \succeq \mathbf{0}, \mathbf{v} \succeq \mathbf{0} \quad (2-75)$$

基于以上分解，有如下定理。

定理 2.6 $\min_{\mathbf{x}} \|\mathbf{x}\|_1$ 等价于 $\min_{\mathbf{u}, \mathbf{v}} \mathbf{1}_N^T \mathbf{u} + \mathbf{1}_N^T \mathbf{v}, \text{ s.t. } \mathbf{u} \succeq \mathbf{0}, \mathbf{v} \succeq \mathbf{0}, \mathbf{u} - \mathbf{v} = \mathbf{x}$ 。

证明： 设 $\mathbf{u}_0 \succ \mathbf{0}, \mathbf{v}_0 \succ \mathbf{0}$ 是第二个问题的最优解，则总可以找到一个很小的各项为正的向量 $\mathbf{s} \succ \mathbf{0}$ ，有 $\mathbf{u}_1 = \mathbf{u}_0 - \mathbf{s} \succeq \mathbf{0}, \mathbf{v}_1 = \mathbf{v}_0 - \mathbf{s} \succeq \mathbf{0}$ 。明显地， $\mathbf{u}_1, \mathbf{v}_1$ 满足第二个问题的所有约束，但这组可行解却具有比 $\mathbf{u}_0, \mathbf{v}_0$ 更小的目标函数值，即 $\mathbf{1}_N^T \mathbf{u}_0 + \mathbf{1}_N^T \mathbf{v}_0 - 2\mathbf{1}_N^T \mathbf{s}$ 。这就证明 $\mathbf{u}_0, \mathbf{v}_0$ 不是第二个问题的最优解，与假设矛盾。

所以，对于 $\mathbf{u}$ 和 $\mathbf{v}$ 的每一个分量 u_j 和 v_j ，二者至少有一个为 0。即，要么 $u_j = 0$ ，此时 $x_j = -v_j \leq 0, u_j + v_j = -x_j$ ；要么 $v_j = 0$ ，此时 $x_j = u_j \geq 0, u_j + v_j = x_j$ 。所以，最优解满足 $u_j + v_j = |x_j|, \mathbf{1}_N^T \mathbf{u} + \mathbf{1}_N^T \mathbf{v} = \|\mathbf{x}\|_1$ 。□

由证明可知，对 $j = 1, 2, \dots, N$ ，可取 $u_j = (x_j)_+, v_j = (-x_j)_+$ 。基于此，可将式(2-74)转化为如下的边界约束二次优化 (Bound-constrained Quadratic Programming, BCQP) 问题

$$\min_{\mathbf{u}, \mathbf{v}} \|\mathbf{y} - \Phi(\mathbf{u} - \mathbf{v})\|_2 + \lambda \mathbf{1}_N^T \mathbf{u} + \lambda \mathbf{1}_N^T \mathbf{v}, \quad \text{s.t. } \mathbf{u} \succeq \mathbf{0}, \mathbf{v} \succeq \mathbf{0} \quad (2-76)$$

$$\text{令 } \mathbf{z} = [\mathbf{u}, \mathbf{v}]^T, \mathbf{b} = \Phi^T \mathbf{y}, \mathbf{c} = \lambda \mathbf{1}_{2N} + [-\mathbf{b}, \mathbf{b}]^T,$$

$$\mathbf{B} = \begin{bmatrix} \Phi^T \Phi & -\Phi^T \Phi \\ -\Phi^T \Phi & \Phi^T \Phi \end{bmatrix}$$

可将问题(2-76)写成标准形式的 BCQP 问题

$$\min_{\mathbf{z}} \frac{1}{2} \mathbf{z}^T \mathbf{B} \mathbf{z} + \mathbf{c}^T \mathbf{z}, \quad \text{s.t. } \mathbf{z} \succeq \mathbf{0} \quad (2-77)$$

标准形式的 BCQP 问题是一个具有成熟解法的凸问题，可通过内点法，梯度法等优化方法求解。在求得问题(2-77)的最优解 $\hat{\mathbf{z}}$ 后，可获得原始问题(2-74)的最优解

$$\hat{\mathbf{x}} = \hat{\mathbf{z}}_{1:N} - \hat{\mathbf{z}}_{N+1:2N} \quad (2-78)$$

BPDN 是基于凸优化的稀疏恢复算法中应用最广的一种算法。文献^[198]提出基于近端梯度投影的迭代软阈值算法 (Iterative Soft Thresholding, IST)。另外两种常见的凸松弛方法是梯度投影稀疏重建算法 (Gradient Projection for Sparse Reconstruction, GPSR)^[199] 和基于可分离逼近的稀疏重建算法 (Sparse Reconstruction by Separable Approximation, SpaRSA)^[200]。除此之外, 文献^[201]提出使用非凸的 ℓ_p 范数来逼近 ℓ_0 范数的欠定系统局灶解法 (Focal Undetermined System Solver, FOCUSS)。最近, 研究人员对基于非凸优化的稀疏重建理论与算法的兴趣也愈发浓厚^[187]。

2.4.3 概率类方法

概率推理类算法主要指基于贝叶斯框架的稀疏恢复算法, 该类算法以稀疏贝叶斯学习 (SBL) 框架^[190]为基础。在优化类方法中, $\mathbf{x}$ 的稀疏解是通过对损失函数施加具有稀疏引导效果的范数惩罚项来实现。如对 $\mathbf{x}$ 施加 ℓ_1 范数惩罚, 等价于在 MAP 估计中对 $\mathbf{x}$ 施加 Laplace 先验分布约束。然而, Laplace 先验与高斯似然函数不共轭, 直接使用 Laplace 先验将使后续推导和计算变得很困难, 无法得到解析的迭代公式。所以, SBL 方法是对 $\mathbf{x}$ 施加层级的共轭先验, 兼顾计算可行性和逼近稀疏先验分布 (如 Laplace 分布)。下面对基于第二类最大似然 (Type-II ML) 的 SBL 算法进行介绍和推导。

一、层级概率模型

对于实信号稀疏编码模型 $\mathbf{y} = \Phi\mathbf{x} + \mathbf{n}$, SBL 对其构建层级概率模型如下:

$$\mathbf{y} | \beta \sim \mathcal{N}(\mathbf{y} | \Phi\mathbf{x}, \beta^{-1}\mathbf{I}_M) \quad (2-79a)$$

$$\beta \sim \text{Gamma}(\beta | c, d) \quad (2-79b)$$

$$\mathbf{x} | \boldsymbol{\alpha} \sim \mathcal{N}(\mathbf{x} | 0, \mathbf{A}^{-1}), \mathbf{A} = \text{diag}(\boldsymbol{\alpha}), \boldsymbol{\alpha} = [\alpha_1, \alpha_2, \dots, \alpha_N]^T \quad (2-79c)$$

$$\boldsymbol{\alpha} \sim \prod_{j=1}^N \text{Gamma}(\alpha_j | a, b) \quad (2-79d)$$

其中, 式(2-79a)对观测噪声 $\mathbf{n}$ 进行建模, 即认为 $\mathbf{n} \sim \mathcal{N}(\mathbf{0}, \beta^{-1}\mathbf{I}_M)$ 。式(2-79b)从共轭分布的角度认为超参数 β (方差的倒数, 亦称精度) 服从以 c, d 为超超参数的 Gamma 分布。式(2-79c)认为稀疏矢量 $\mathbf{x}$ 的每一个分量 x_j 服从零均值的以超参数 α_j 为精度的独立高斯分布 $x_j | \alpha_j \sim \mathcal{N}(0, \alpha_j^{-1})$ 。式(2-79d)从共轭分布的角度进一步对超参数 α_j 进行建模, 认为所有的 α_j 均服从以 a, b 为超超参数的独立 Gamma 分布。对于整个 SBL 层级概率模型(2-79)而言, $\mathbf{y}$ 为观测数据, Φ 为字典数据, $\mathbf{x}$ 为参数, $\boldsymbol{\alpha}, \beta$ 为模型的超参数, a, b, c, d 为超参数的参数, 即超超参数。 a, b, c, d 的值越小, Gamma 分布的 PDF 越平坦, SBL 的模型空间越大, 建模能力和泛化能力越强。为获得更宽的先验分布, 一般取 a, b, c, d 为较小的经验值, 如 10^{-4} 。



(a) 条件分布 $p(\mathbf{x}|\boldsymbol{\alpha})$: 高斯分布(b) 边缘分布 $p(\mathbf{x})$: Student's t 分布

图 2-4 二维情况下的条件分布和边缘分布

利用上述层级模型，对于 $\mathbf{x}$ 的每一个分量，有

$$p(x_j) = \int p(x_j | \alpha_j) p(\alpha_j) d\alpha_j = \frac{b^a \Gamma(a + \frac{1}{2})}{(2\pi)^{\frac{1}{2}} \Gamma(a)} \left(b + \frac{x_j^2}{2}\right)^{-(a + \frac{1}{2})} \quad (2-80)$$

式(2-80)表明，边缘分布 $p(x_j)$ 为 Student's t 分布。所以，边缘分布 $p(\mathbf{x})$ 是一系列 Student's t 分布的累乘。可以看出当 $a, b \rightarrow 0$ 时， $p(x_j) \propto 1/|x_j|$ ，其类似被广泛用于稀疏建模的 Laplace 先验分布 $p(x_j) \propto \exp(-|x_j|)$ 。对于每一维度，概率密度主要集中在原点附近，且在原点处急剧上升，而在其他地方又迅速下降，这也是稀疏先验分布的共同特征。图2-4显示了二维情况下高斯条件分布 $p(\mathbf{x}|\boldsymbol{\alpha})$ 和 Student's t 边缘分布 $p(\mathbf{x})$ 的概率密度分布图，可以看出即使条件密度 $p(\mathbf{x}|\boldsymbol{\alpha})$ 是非稀疏的，通过上述的层级概率建模最终仍可得到诱导稀疏的边缘分布 $p(\mathbf{x})$ 。相比直接使用稀疏先验，层级建模能够确保每一层的先验都是共轭的，从而极大地方便了后续推理和计算。

二、概率推断

对于上述模型，未知参数 $\mathbf{x}, \boldsymbol{\alpha}, \beta$ 的后验概率密度函数为

$$p(\mathbf{x}, \boldsymbol{\alpha}, \beta | \mathbf{y}) = p(\mathbf{x} | \boldsymbol{\alpha}, \beta, \mathbf{y}) p(\boldsymbol{\alpha}, \beta | \mathbf{y}) \quad (2-81)$$

对于(2-81)等式右边第一项 $p(\mathbf{x} | \boldsymbol{\alpha}, \beta, \mathbf{y})$ ，利用 Bayes 准则展开得

$$\begin{aligned} p(\mathbf{x} | \boldsymbol{\alpha}, \beta, \mathbf{y}) &= \frac{p(\mathbf{x}, \mathbf{y}, \boldsymbol{\alpha}, \beta)}{p(\mathbf{y}, \boldsymbol{\alpha}, \beta)} = \frac{p(\mathbf{y} | \mathbf{x}, \boldsymbol{\alpha}, \beta) p(\mathbf{x}, \boldsymbol{\alpha}, \beta)}{p(\mathbf{y} | \boldsymbol{\alpha}, \beta) p(\boldsymbol{\alpha}, \beta)} \\ &= \frac{p(\mathbf{y} | \mathbf{x}, \boldsymbol{\alpha}, \beta) p(\mathbf{x} | \boldsymbol{\alpha}, \beta) p(\boldsymbol{\alpha}, \beta)}{p(\mathbf{y} | \boldsymbol{\alpha}, \beta) p(\boldsymbol{\alpha}, \beta)} = \frac{p(\mathbf{y} | \mathbf{x}, \beta) p(\mathbf{x} | \boldsymbol{\alpha})}{p(\mathbf{y} | \boldsymbol{\alpha}, \beta)} \end{aligned} \quad (2-82)$$

式(2-82)是 $\mathbf{x}$ 的分布，所以分母是归一化常数项。分子中 $p(\mathbf{y} | \mathbf{x}, \beta)$ 为观测向量的似然函数， $p(\mathbf{x} | \boldsymbol{\alpha})$ 为权重向量的先验分布，由式(2-79)可知， $p(\mathbf{y} | \mathbf{x}, \beta)$ 和 $p(\mathbf{x} | \boldsymbol{\alpha})$ 均为高斯分布函数。所以， $p(\mathbf{x} | \boldsymbol{\alpha}, \beta, \mathbf{y})$ 为关于 $\mathbf{x}$ 的高斯分布，通过把分子的指数部分按 $\mathbf{x}$ 配成高斯分布的形式，可得

$$p(\mathbf{x} | \boldsymbol{\alpha}, \beta, \mathbf{y}) = \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Sigma}) \quad (2-83)$$

其中, 均值 $\boldsymbol{\mu}$ 和协方差矩阵 $\boldsymbol{\Sigma}$ 为

$$\boldsymbol{\mu} = \beta \boldsymbol{\Sigma} \boldsymbol{\Phi}^T \mathbf{y}, \quad \boldsymbol{\Sigma} = (\beta \boldsymbol{\Phi}^T \boldsymbol{\Phi} + \mathbf{A})^{-1} \quad (2-84)$$

在 SBL 中, 将 $p(\mathbf{x}|\boldsymbol{\alpha}, \beta, \mathbf{y})$ 的均值 $\boldsymbol{\mu}$ 作为稀疏向量 $\mathbf{x}$ 的 MAP 估计, 即 $\hat{\mathbf{x}} = \boldsymbol{\mu}$ 。但计算 $\boldsymbol{\mu}$, 需要已知 $\boldsymbol{\alpha}$ 和 β 。SBL 取式(2-81)等号右边第二项 $p(\boldsymbol{\alpha}, \beta|\mathbf{y})$ 的 MAP 估计作为 $\boldsymbol{\alpha}$ 和 β 的点估计结果, 即 Type-II ML 方法

$$(\hat{\boldsymbol{\alpha}}, \hat{\beta}) = \arg \max_{\boldsymbol{\alpha}, \beta} \ln p(\boldsymbol{\alpha}, \beta|\mathbf{y}) \quad (2-85)$$

由 Bayes 准则有

$$p(\boldsymbol{\alpha}, \beta|\mathbf{y}) = \frac{p(\mathbf{y}|\boldsymbol{\alpha}, \beta)p(\boldsymbol{\alpha})p(\beta)}{p(\mathbf{y})} \propto p(\mathbf{y}|\boldsymbol{\alpha}, \beta)p(\boldsymbol{\alpha})p(\beta) \quad (2-86)$$

对 $p(\mathbf{y}|\boldsymbol{\alpha}, \beta)$ 使用式(2-83)中同样的配平技巧, 并使用 Woodbury 矩阵恒等式来化简协方差矩阵, 有

$$p(\mathbf{y}|\boldsymbol{\alpha}, \beta) = \int p(\mathbf{y}|\mathbf{x}, \beta)p(\mathbf{x}|\boldsymbol{\alpha})d\mathbf{x} = \mathcal{N}(\mathbf{y}|\mathbf{0}, \boldsymbol{\Xi}), \quad \boldsymbol{\Xi} = \beta^{-1}\mathbf{I} + \boldsymbol{\Phi}\mathbf{A}^{-1}\boldsymbol{\Phi}^T \quad (2-87)$$

所以对式(2-85)中的目标优化式, 有

$$\ell(\boldsymbol{\alpha}, \beta) = \ln p(\boldsymbol{\alpha}, \beta|\mathbf{y}) = -\frac{1}{2} [\ln \det(\boldsymbol{\Xi}) + \mathbf{y}^T \boldsymbol{\Xi}^{-1} \mathbf{y}] + \sum_{j=1}^N (a \ln \alpha_j - b \alpha_j) + c \ln \beta - d \beta \quad (2-88)$$

由恒等式(2-7)及 Woodbury 矩阵恒等式有

$$\det(\mathbf{A}) \det(\boldsymbol{\Xi}) = \det(\beta^{-1}\mathbf{I}_N) \det(\boldsymbol{\Sigma}^{-1}) \quad (2-89)$$

$$\boldsymbol{\Xi}^{-1} = \beta \mathbf{I}_M + \beta \boldsymbol{\Phi} (\mathbf{A} + \beta \boldsymbol{\Phi}^T \boldsymbol{\Phi})^{-1} \boldsymbol{\Phi}^T \beta = \beta \mathbf{I}_M + \beta \boldsymbol{\Phi} \boldsymbol{\Sigma} \boldsymbol{\Phi}^T \beta \quad (2-90)$$

利用式(2-89)和式(2-90)可以展开式(2-88)

$$\begin{aligned} \ell(\boldsymbol{\alpha}, \beta) = & -\frac{1}{2} \{ \ln \det(\boldsymbol{\Sigma}^{-1}) - N \ln \beta - \ln \det(\mathbf{A}) + \beta \mathbf{y}^T \mathbf{y} - \beta \mathbf{y}^T \boldsymbol{\Phi} \boldsymbol{\Sigma} \boldsymbol{\Phi}^T \beta \mathbf{y} \} \\ & + \sum_{j=1}^N (a \ln \alpha_j - b \alpha_j) + c \ln \beta - d \beta \end{aligned} \quad (2-91)$$

下面通过求解 $\ell(\boldsymbol{\alpha}, \beta)$ 关于 $\boldsymbol{\alpha}, \beta$ 的驻点方程来获得 $\hat{\boldsymbol{\alpha}}, \hat{\beta}$ 。

对 α_j 求偏导数: 令 $\mathbf{e}_{jj}$ 为主对角线上第 j 个元素为 1, 其它元素均为 0 的方阵, 利用如下中间步骤

$$\frac{\partial \ln \det(\boldsymbol{\Sigma}^{-1})}{\partial \alpha_j} = \frac{1}{\det(\boldsymbol{\Sigma}^{-1})} \frac{\partial (\boldsymbol{\Sigma}^{-1})}{\partial \alpha_j} = \text{tr} \left\{ \boldsymbol{\Sigma} \frac{\partial \boldsymbol{\Sigma}^{-1}}{\partial \alpha_j} \right\} = \Sigma_{jj} \quad (2-92)$$

Algorithm 2.3: 稀疏贝叶斯学习算法 (SBL)^[190]**Input:** $\mathbf{y}, \Phi$

- 1 初始化 $\alpha, \beta, a, b, c, d$;
- 2 **while** 不满足终止条件 **do**
- 3 根据式(2-84)计算 μ 和 Σ ;
- 4 根据式(2-100)更新 α 和 β ;

Output: $\hat{\mathbf{x}} = \mu$

$$\frac{\partial \ln \det(\mathbf{A})}{\partial \alpha_j} = \frac{1}{\alpha_j}, \quad \frac{\partial \Sigma}{\partial \alpha_j} = \frac{\partial (\Sigma^{-1})^{-1}}{\partial \alpha_j} = -\Sigma \frac{\partial \Sigma^{-1}}{\partial \alpha_j} \Sigma = -\Sigma \mathbf{e}_{jj} \Sigma \quad (2-93)$$

$$\frac{\partial \beta \mathbf{y}^T \Phi \Sigma \Phi^T \beta \mathbf{y}}{\partial \alpha_j} = \beta \mathbf{y}^T \Phi \frac{\partial \Sigma}{\partial \alpha_j} \Phi^T \beta \mathbf{y} = -\mu^T \mathbf{e}_{jj} \mu = -\mu_j^2 \quad (2-94)$$

可得

$$\frac{\partial \ell(\alpha, \beta)}{\partial \alpha_j} = \frac{1}{2} \left[\frac{1}{\alpha_j} - (\mu_j^2 + \Sigma_{jj}) \right] + \frac{a}{\alpha_j} - b \quad (2-95)$$

对 β 求偏导数: 利用中间步骤

$$\frac{\partial \ln \det(\Sigma^{-1})}{\partial \beta} = \text{tr} \left(\Sigma \frac{\partial \Sigma^{-1}}{\partial \beta} \right) = \text{tr}(\Sigma \Phi^T \Phi) \quad (2-96)$$

$$\frac{\partial \Sigma}{\partial \beta} = -\Sigma \frac{\partial \Sigma^{-1}}{\partial \beta} \Sigma = -\Sigma \Phi^T \Phi \Sigma \quad (2-97)$$

$$\Sigma \Sigma^{-1} = \Sigma \beta \Phi^T \Phi + \Sigma \mathbf{A}, \quad \text{tr}(\Sigma \Phi^T \Phi) = \text{tr}(\beta^{-1} (\mathbf{I}_N - \Sigma \mathbf{A})) = \beta^{-1} \sum_{j=1}^N (1 - \alpha_j \Sigma_{jj}) \quad (2-98)$$

可得

$$\frac{\partial \ell(\alpha, \beta)}{\partial \beta} = -\frac{1}{2} \left(\text{tr}(\Sigma \Phi^T \Phi) - \frac{N}{\beta} + \|\mathbf{y} - \Phi \mu\|_2^2 \right) + \frac{c}{\beta} - d \quad (2-99)$$

Type-II ML 解: 令式(2-95)和式(2-99)等于 0, 解方程得

$$\hat{\alpha}_j = \frac{1 + 2a}{\mu_j^2 + \Sigma_{jj} + 2b}, \quad \hat{\beta} = \frac{2c + N - \sum_{j=1}^N (1 - \alpha_j \Sigma_{jj})}{\|\mathbf{y} - \Phi \mu\|_2^2 + 2d} \quad (2-100)$$

综上, 可得稀疏贝叶斯学习的算法流程如算法2.3所示。其中, 步骤(1)中的初始化有多种选择, 一种可行的方案为 $a = b = c = d = 10^{-4}$, $\alpha_j = \|\Phi^T \mathbf{y}\|_2 / |\Phi_j^T \mathbf{y}|$, $\beta = \text{var}(\mathbf{y})$ 。

从文献历史来看, SBL 算法奠定了基于概率推理的稀疏恢复基本框架。在 SBL 的基础上衍生出基于 EM 算法的 SBL 算法^[190]、基于变分推断的 SBL^[202]、基于快速边缘似然最大化的 SBL^[203]、贝叶斯压缩感知 (Bayesian Compressive Sensing, BCS)^[204], 基于 Laplace 先验的 BCS^[205], 基于多测量向量模型的 MSBL^[120] 等算法。

2.4.4 各类算法的优势与局限

对于同一个稀疏恢复问题，既可从贪婪和优化的角度进行求解，也可从贝叶斯的视角进行概率推理，这正是信号处理独特的魅力。

对于贪婪类稀疏恢复算法而言，其最大的优势在于简单易懂，计算高效。作为一种启发式算法，贪婪类稀疏恢复算法能够轻松地把人们对稀疏问题的先验认知和直觉整合到算法设计中。然而，其局限在于面对弱稀疏信号和强测量噪声时，贪婪类算法需要更多的测量，且性能要远远弱于优化类算法和概率推理类算法。

对于优化类算法而言，稀疏性约束一般通过具有稀疏诱导能力的范数约束来表达。其优势在于建模时的方便性，能够基于不同范数的特性，整合人们对稀疏问题的直观认识，很方便地提出目标优化式。其设计难点在优化问题的求解，特殊的松弛技巧、转换技术和逼近方法是去求解优化类稀疏恢复算法的关键。

概率推理类算法的独特魅力在于能够通过概率建模的手段整合人们对稀疏问题的先验认识，并通过概率推理来指导问题求解，通过概率积分来化简目标优化式，同时能够提供对噪声的建模能力，给出估计结果的置信度。其局限在于难以设计恰当的共轭层级先验模型。对于很多问题，若感兴趣变量的概率密度函数无显式表达，则很难进行相应的概率推理，若概率分布不是共轭关系，则很可能无法通过概率积分获得相应的边缘概率密度函数。

相对于贪婪类算法，优化类算法和概率推理类算法显示出优越的噪声鲁棒性，但若非特殊设计，其计算复杂度也要远远高于贪婪类算法。

综上所述，各类稀疏恢复算法各有优缺点，在设计算法和实际应用中，应根据应用领域和信号特点进行选择，尽可能在减少测量数目、提升噪声鲁棒性的同时，寻求恢复精度和计算复杂度的合理折中。

2.5 本章小结

本章首先介绍了全文所需的基础数学知识，该内容为后续的算法研究和理论推导奠定了基础。接着，详细推导了能量域、角度域、时间域多源定模型，并通过总结归纳，建立了广义多源定位模型，该模型将作为第三章到第五章研究的基础模型。然后，通过对参数域的网格离散化，引出了基于稀疏表征的多源定位问题。最后，详细介绍了贪婪类、优化类、概率推理类稀疏恢复算法，并对各类算法的优点和缺点进行了分析，后续的算法研究打下基础。

第三章 基于层级贪婪匹配追踪的多源定位

3.1 引言

通过对辐射源参数空间进行网格离散化，多源定位问题可被近似成一个稀疏编码问题并用一般的稀疏恢复算法求解。然而，多源定位模型是一种物理模型，具有明确的物理结构。一方面，物理模型包含了真实物理结构的连续性和局部平滑性。对连续的辐射源参数空间进行网格划分和构建定位字典是一个人为过程。网格点在辐射源参数空间上的有序性和近邻特征映射到定位字典上是相邻列之间的强相关性。这使得观测信号矢量在定位字典上的投影在物理空间上呈现出明显的聚簇特征。另一方面，字典的列间相关性和投影的聚簇特征意味着冗余性，而冗余将增加系统的鲁棒性。即使观测矢量受到较强的噪声干扰，其在定位字典上的投影仍不会过于偏离相应的聚簇中心。本文将聚簇特征和冗余性称为多源定位中的结构信息。

贪婪稀疏恢复算法因其简单有效而被广泛应用于稀疏重建。作为一种启发式算法，其能够轻松地把人们对稀疏问题的先验认知和直觉整合到算法设计中。然而相对于其他算法，贪婪稀疏恢复算法的抗噪声干扰性能较弱，对测量的数目也要求较高。从压缩感知 (CS) 的角度出发，为提高贪婪稀疏恢复算法的重建性能，研究人员^[92,94,158,206]广泛采用正交化算子对定位字典进行预处理，以降低字典的相干性 (coherence)。目前，基于稀疏表征的多源定位研究^[92,94,122,129,132,158]存在如下问题：(1) 求解基于稀疏表征的多源定位问题时，基于概率推理和优化的方法估计精度高但计算复杂，基于贪婪的方法计算简单却估计精度低；(2) 简单使用一般的稀疏恢复算法，忽略了多源定位问题中丰富的结构信息，无法有效提升参数估计的性能；(3) 为提升贪婪稀疏恢复算法的重建性能，文献中广泛采用的正交预处理方法削弱了原始多源定位模型中的信噪比，使得定位算法的抗噪性能大幅降低。

针对现有研究中存在的问题，本章通过挖掘多源定位中的隐含结构信息，提出一种层级贪婪匹配追踪算法 (HGMP)。该算法首先通过全局估计层获得辐射源参数在网格化空间中的可能位置集合，然后稀疏恢复层在该可能位置集合中重构稀疏矢量，实现稀疏解码。

本章的创新点有：(1) 证明了文献中广泛采用的正交化预处理方式实质上降低了信噪比；(2) 提出了一种层级贪婪匹配追踪 (HGMP) 算法。其利用多源定位中的结构信息，通过全局估计预先排除了不可能的位置，等效于从观测子空间中分离出信号子空间，从而降低了观测噪声的影响；(3) 理论分析与计算机仿真表明所提算法具有线性复杂度且在相同信噪比下具有更优越的参数估计性能。

本章内容安排如下：3.2 节介绍基于正交化预处理的多源定位模型，并证明正交

化预处理降低模型信噪比；3.3 节详细分析了多源定位中隐含的结构信息；3.4 节介绍提出的层级贪婪匹配追踪算法；3.5 节讨论算法的仿真结果；3.6 节给出相关证明过程；3.7 节对本章进行小结。

3.2 基于正交化预处理的多源定位模型

3.2.1 多源定位模型中的约束关系

为方便表述，将第二章中基于稀疏表征的广义多源定位模型(2-67)和基于 ℓ_1 范数松弛的广义多源定位问题(2-74)分别重写如下

$$\mathbf{y}_{M \times 1} = \Phi_{M \times N} \mathbf{x}_{N \times 1} + \mathbf{n}_{M \times 1} \quad (3-1)$$

$$\min_{\mathbf{x}} \|\mathbf{y} - \Phi \mathbf{x}\|_2 + \lambda \|\mathbf{x}\|_1 \quad (3-2)$$

模型(3-1)中的约束关系有： $M \leq N$ ，稀疏向量 $\mathbf{x}$ 的稀疏度满足 $K \ll N$ 。一般假设 Φ 是行满秩的，即 $r = \text{Rank}(\Phi) = M$ 。实际上，若 Φ 秩亏 ($r < M$)，说明有些测量结果是重复的，则通过初等行变换消去 $M - r$ 个测量方程后所得模型是行满秩的。

除了上述基本约束关系外，研究者们感兴趣的问题有：

问题 3.1 (系统辨识问题) 测量数 M 需要多大才能通过稀疏恢复算法成功估计出给定的 K 个辐射源参数？

问题 3.2 (网格密度与估计精度的关系) 对辐射源参数空间的网格划分越密集，是否估计精度会越高？

借由压缩感知 (CS) 理论，可以获得关于这两个问题的初步解答。

首先，对于多源定位问题(3-2)，Zhang 等人^[92] 基于文献^[207-209] 的理论证明指出，若 $M \geq \mathcal{O}(K \ln N/K)$ 且 Φ 满足 $(2K, \sigma)$ 的 RIP 条件，则对于 ℓ_1 范数最小化问题 (3-2) 的解 $\mathbf{x}^*$ 有

(1) 无噪情况 $\|\mathbf{n}\|_2 = 0$ ：若 $\mathbf{x}$ 是严格 K -稀疏信号，则 $\mathbf{x}^* = \mathbf{x}$ ；若 $\mathbf{x}$ 非严格 K -稀疏信号，则 $\mathbf{x}^*$ 能重建出 $\mathbf{x}$ 最主要的 K 个系数。

(2) 有噪情况 $\|\mathbf{n}\|_2^2 \leq \epsilon_0$ ：重建误差满足 $\|\mathbf{x}^* - \mathbf{x}\|_2^2 \leq c_0 \epsilon_0 + c_1 \epsilon$ ，其中 c_0, c_1 为很小的正常数， ϵ 为无噪声情况时的重建误差。

通常，能量域、角度域、时间域多源定位中的定位字典能以较大概率满足 RIP 条件^[92,130,158]。由 CS 理论可知，网格划分结果决定了定位字典 Φ 的构成，而 Φ 满足的 RIP 条件确定了由当前字典能够重构出的未知参数数目 K 。为了重构出稀疏矢量 $\mathbf{x}$ ，测量数需满足 $M \geq \mathcal{O}(K \ln N/K)$ ，这里，大 $\mathcal{O}$ 记号表示的是数量级的渐近上界关系。

其次，辐射源参数分布在连续的物理参数空间中。基于稀疏表征的多源定位方法通过辐射源参数空间的网格离散化获得连续空间的网格点近似，然后由这些离散

的网格点构成定位字典 Φ 。网格划分越精细，网格点和真实参数之间的误差就越小。但过密的网格会增强过定位字典中原子间的相干性，进而使得压缩感知的重构性能下降^[130]。定理3.1说明了相干性和重建性能之间的关系。

定理 3.1 ^[209] 令 $\Phi \in \mathbb{R}^{M \times N}$ 为一个过完备表示字典， ϕ_j 为其第 j 列，定义相干性 $\mu(\Phi)$ 为：

$$\mu(\Phi) = \max_{1 \leq i \neq j \leq N} \frac{|\langle \phi_i, \phi_j \rangle|}{\|\phi_i\|_2 \|\phi_j\|_2} \quad (3-3)$$

当 $K \leq 1 + 1/16u$ 且 $M \geq \mathcal{O}(K \ln N/K)$ 时，任何 K -稀疏向量 $\mathbf{x}$ 可以从测量 $\mathbf{y} = \Phi \mathbf{x}$ 中通过求解问题(3-2)以大概率恢复。

Cevher 的研究表明^[91]，在能量域多源定位问题中 $\mu(\Phi)$ 依赖于 $\Delta/2D$ 。其中， Δ 为最小网格间隔， D 为网格点和定位节点间的最大距离(由定位节点部署和网格划分共同决定)。所以，一定程度上 Δ 决定了成功估计的参数数目下界， D 决定其上界。

贪婪稀疏恢复算法因其简单有效和建模灵活而被广泛使用。然而相对于优化类和概率推理类算法，贪婪算法对密集网格划分带来的强相干性更为敏感。为了缓解列间强相干性对贪婪稀疏重建算法的影响，Feng 提出一种基于正交算子的预处理方法来降低列间相干性^[206]。此后，这种预处理方法被研究者们广泛使用^[94,158,206]。

下面详细介绍基于正交算子的预处理方法，并证明其降低了模型信噪比。

3.2.2 正交化预处理模型及其不足

由式(3-3)可知，相干性刻画的是 Φ 的列间相关性。列间相关性越弱，稀疏重建的理论保障越强。一种极端情况是过完备字典退化成正交字典，此时字典的相干性为零，只需把观测结果投影到正交字典上即可重建出 $\mathbf{x}$ 。由正交化算子的定义可知， Φ 的正交化算子 $\mathbf{T}_\Phi$ 能使 $\mathbf{T}_\Phi \Phi$ 的列尽可能地线性无关，从而最小化 $\mathbf{T}_\Phi \Phi$ 的相干性。

由3.2.1小节的讨论，有 $\text{Rank}(\Phi) = M$ 。对 $\Phi \in \mathbb{R}^{M \times N}$ ，有 SVD 分解 $\Phi = \mathbf{U} \Sigma \mathbf{V}^T$ 。由定理2.1可知， $\mathbf{T}_\Phi = \Sigma^\dagger(1:M, :) \mathbf{U}^T$ 。为减弱过完备字典的列相关性，对原始模型(3-1)的等号两端同时左乘正交化算子 $\mathbf{T}_\Phi$ ，

$$\mathbf{T}_\Phi \mathbf{y} = \mathbf{T}_\Phi \Phi \mathbf{x} + \mathbf{T}_\Phi \mathbf{n} = \mathbf{V}^T(1:M, :) \mathbf{x} + \mathbf{T}_\Phi \mathbf{n} \quad (3-4)$$

记 $\mathbf{z} = \mathbf{T}_\Phi \mathbf{y} \in \mathbb{R}^M$ ， $\mathbf{Q} = \mathbf{V}^T(1:M, :) \in \mathbb{R}^{M \times N}$ ， $\mathbf{n}' = \mathbf{T}_\Phi \mathbf{n} \in \mathbb{R}^M$ ，可得正交化预处理多源定位模型如下

$$\mathbf{z} = \mathbf{Q} \mathbf{x} + \mathbf{n}' \quad (3-5)$$

在正交化预处理模型(3-5)中， $\mathbf{Q}$ 为正交化预处理后的字典，是正交矩阵 $\mathbf{V}^T$ 的子矩阵。可以证明，正交矩阵的随机子矩阵满足 RIP 条件^[207]。下文中，简称模型(3-1)为原始模型，模型(3-5)为预处理模型。相应地， Φ 简称为原始字典， $\mathbf{Q}$ 简称为预处理字典。

相对于原始字典 Φ ，预处理字典 $\mathbf{Q}$ 的列间相关性已被大大降低。文献表明^[94,158,206]，贪婪稀疏恢复算法在预处理模型(3-5)上具有比在原始模型(3-1)上更高的重建精度。

然而，本文研究发现，预处理算子 $\mathbf{T}_\Phi$ 并不是一个无损操作，在从原始模型(3-1)转化到预处理模型(3-5)的过程中，相对信号功率，预处理算子 $\mathbf{T}_\Phi$ 放大了噪声水平，即预处理算子 $\mathbf{T}_\Phi$ 削弱了信噪比。在正式表述定理化结果前，先定义信噪比。

设有噪声观测模型为 $\mathbf{y} = \Phi\mathbf{x} + \mathbf{n}$ ，其中真实信号为 $\Phi\mathbf{x}$ ，随机噪声 $\mathbf{n} \sim \mathcal{N}(0, \sigma^2\mathbf{I})$ 。分别考虑 $\mathbf{x}$ 为随机变量和 $\mathbf{x}$ 为确定性变量的情况。定义该模型的信噪比如下。

定义 3.1 若 $\mathbf{x}$ 为确定性变量，则信噪比定义为：

$$\text{SNR} = \frac{\|\Phi\mathbf{x}\|_2^2}{\mathbb{E}\{\|\mathbf{n}\|_2^2\}} \quad (3-6)$$

若 $\mathbf{x}$ 为随机变量，则信噪比定义为：

$$\text{SNR} = \frac{\mathbb{E}\{\|\Phi\mathbf{x}\|_2^2\}}{\mathbb{E}\{\|\mathbf{n}\|_2^2\}} \quad (3-7)$$

定理 3.2 给定有噪声观测模型 $\mathbf{y} = \Phi\mathbf{x} + \mathbf{n}$ ，其中 $\mathbf{y}, \mathbf{n} \in \mathbb{R}^M$ ， $\mathbf{x} \in \mathbb{R}^N$ ， $\Phi \in \mathbb{R}^{M \times N}$ ， $\text{Rank}(\Phi) = M$ ，且 $\mathbf{n} \sim \mathcal{N}(0, \sigma^2\mathbf{I})$ ， $\mathbf{x}$ 为确定性变量。其信噪比为 SNR_Φ 。其对应的预处理模型为 $\mathbf{T}_\Phi\mathbf{y} = \mathbf{T}_\Phi\Phi\mathbf{x} + \mathbf{T}_\Phi\mathbf{n}$ ，相应的信噪比为 $\text{SNR}_{\mathbf{T}_\Phi}$ 。记 Φ 的紧凑型 SVD 分解为 $\Phi = \mathbf{U}_{M \times M}\Sigma_{M \times M}(\mathbf{V}_{N \times M})^T$ ，其中 $\Sigma = \text{diag}(s_1, s_2, \dots, s_M)$ ， $s_1 \geq s_2 \geq \dots \geq s_M > 0$ 为 Φ 的奇异值。令 $\mathbf{V}^T\mathbf{x} = [\nu_1, \nu_2, \dots, \nu_M]^T$ 。若对任意 $i < j$ ， $\frac{\nu_i^2}{\nu_j^2} \geq \frac{s_j^2}{s_i^2}$ ，则有 $\text{SNR}_{\mathbf{T}_\Phi} \leq \text{SNR}_\Phi$ 。

证明： 定理3.2的证明见3.6.1小节。 $\square$

定理3.2表明，对于某一确定的 $\mathbf{x}$ ，若其在过完备字典的右奇异矩阵上的投影满足一定关系，则预处理算子 $\mathbf{T}_\Phi$ 将削弱信噪比。实际上，对于 $\mathbb{R}^N$ 空间中的变量 $\mathbf{x}$ ，总是以概率 $P\left(\frac{\nu_i^2}{\nu_j^2} \geq \frac{s_j^2}{s_i^2}, i < j\right)$ 满足上述关系。下面的定理3.3说明，对于随机变量 $\mathbf{x}$ ，预处理算子 $\mathbf{T}_\Phi$ 在统计平均意义上削弱了信噪比。

定理 3.3 给定有噪声观测模型 $\mathbf{y} = \Phi\mathbf{x} + \mathbf{n}$ ，其中 $\mathbf{y}, \mathbf{n} \in \mathbb{R}^M$ ， $\mathbf{x} \in \mathbb{R}^N$ ， $\Phi \in \mathbb{R}^{M \times N}$ ，且 $\mathbf{n} \sim \mathcal{N}(0, \sigma^2\mathbf{I})$ ， $\mathbf{x}$ 为随机信号且各分量 x_j 是独立同分布的，记其信噪比为 SNR_Φ 。对应的预处理模型为 $\mathbf{T}_\Phi\mathbf{y} = \mathbf{T}_\Phi\Phi\mathbf{x} + \mathbf{T}_\Phi\mathbf{n}$ ，其信噪比为 $\text{SNR}_{\mathbf{T}_\Phi}$ 。若 $\mathbb{E}[x_j^2]$ 存在，则 $\text{SNR}_{\mathbf{T}_\Phi} \leq \text{SNR}_\Phi$ ，等号成立的条件为 Φ 的所有奇异值均相同。

证明： 定理3.3的证明见3.6.2小节。 $\square$

3.2.3 研究动机和目的

从上述分析可以看出，基于贪婪稀疏恢复算法的多源定位存在如下矛盾：从压缩感知角度来看，贪婪稀疏恢复算法对定位字典的列间相关性较为敏感，对原始模型进

行正交化预处理能够有效提升贪婪算法的估计性能。从算法鲁棒性角度来看，正交化预处理操作被证明降低了预处理模型的信噪比，从而降低了算法的估计性能。

如何辩证分析该矛盾，调和压缩感知角度的算法性能提升和鲁棒性角度的算法性能保障，是本章的研究动机和主要内容。

本文通过研究发现，对于多源定位问题，只有真实辐射源参数附近的网格点才会对测量信号产生明显贡献，在远离真实辐射源参数位置的地方进行网格点划分并不会给问题求解带来益处。所以，对于给定的网格化空间和相应的定位字典 Φ ，可以将网格空间视为信号子空间和噪声子空间的叠加。其次，多源定位模型具有明确的物理结构，存在丰富的结构信息。通过恰当的算法设计，利用多源定位中隐含的结构信息，从网格空间中分离出信号子空间，降低测量噪声和网格密集划分所带来的强相关性的影响，将提升多源定位算法的性能。为此，本章设计如图3-1所示层级贪婪匹配追踪架构。




图 3-1 层级贪婪匹配追踪架构

其中，全局估计层旨在利用原始模型(3-1)中隐含的结构信息，从网格化参数空间中分离出信号子空间；稀疏估计层根据全局估计层的输出，旨在利用预处理模型(3-5)在信号子空间中进行正交匹配追踪。通过联合利用原始模型(3-1)和预处理模型(3-5)进行贪婪求解，将获得更好的多源定位参数估计性能。

3.3 多源定位中的结构信息

本小节将详细分析原始模型(3-1)中隐含的结构信息，为全局估计层中的信号子空间分离提供依据。




图 3-2 多源定位中的聚簇特征

3.3.1 聚簇特征

首先, 原始模型(3-1)是对多源定位问题的网格点近似, 真实的辐射源参数可能分布在连续参数空间的任何位置, 不一定精确地在网格点上。其次, 原始字典的相邻列之间具有较强的相关性。所以, 测量信号投影到网格空间上的能量将分散在真实辐射源参数附近的网格点上。在 OMP 算法的每一次迭代中, 残差投影到网格空间上的能量将分散在对当前残差贡献最大的辐射源参数的附近网格点上。具体地, 令 $\hat{x}_j$ 为第 j 个网格点上的压缩感知恢复系数, $\Phi_j^T \mathbf{r}$ 为残差 $\mathbf{r}$ 在第 j 个网格点上的投影。在真实辐射源参数附近的网格点上, 压缩感知恢复系数或残差在网格空间上的投影具有相近的取值, 且幅度明显高于远离辐射源参数的网格点上的值, 称这种特征为聚簇特征。图3-2展示了在能量域多源定位问题中使用 BP 算法和 OMP 算法获得的聚簇特征, 其中参数域为二维的辐射源坐标空间。图3-2(a)和图3-2(b)分别展示的是 BP 算法恢复系数在网格点索引集上和网格空间上的聚簇特征。Yang 等人^[210]注意到了压缩感知恢复系数的聚簇特征, 其在 BP 算法的定位结果上利用 KNN 聚类对恢复位置

进行加权平均，鉴于 BP 算法 $\mathcal{O}(N^3)$ 的计算复杂度，其很难被应用到计算资源受限的实际系统中；图3-2(c)展示的是 OMP 算法在原始字典上的迭代过程中的残差聚簇特征。可以清晰看到，左边的辐射源对当前残差贡献最大，其附近的原子团呈现出明显的聚簇特征；图3-2(d)展示的是 OMP 算法在预处理字典上的迭代过程中残差在网格空间上的投影，由于正交化算子破坏了原始字典的列间相关性，所以其不再具有明显的聚簇特征。

本文研究 OMP 算法在原始字典上的残差聚簇特征。

3.3.2 冗余信息

如前所述，为使基于贪婪稀疏恢复算法的多源定位获得更好的定位性能，文献中常采用正交化算子 $\mathbf{T}_\Phi$ 对原始模型(3-1)进行预处理。然而，前文证明 $\mathbf{T}_\Phi$ 算子会降低信噪比。此外，预处理字典 $\mathbf{Q}$ 是正交矩阵的子矩阵，相对原始字典 Φ 而言，其列间相关性已被大大降低。所以相对原始模型(3-1)，预处理模型(3-5)损失了冗余的信息。对于一个系统来说，虽然冗余带来有效性的降低，但却是系统可靠性的重要保障。在多源定位问题中，这种冗余信息的损失可以从 Φ 和 $\mathbf{Q}$ 的列相关性中得到解释。 Φ 中的每一列 Φ_j 代表所有定位节点对参数空间中第 j 个网格点参数的相应测量，参数域中网格点 i 和网格点 j 距离越近， Φ_i 和 Φ_j 就越相关。所以 Φ 的列间相关性具有清晰的物理意义。作为这种相关性在 OMP 残差投影上的反映，投影结果也会在相应参数域上呈现出清晰的相关性。如图3-2(c)所示，残差在原始字典 Φ 上的投影在二维的辐射源坐标空间中呈现出清晰的聚簇特征。即使观测矢量受到较强的噪声干扰，OMP 算法的残差投影仍不会过于偏离相应的聚簇中心。与此相反，预处理算子降低了原始模型的冗余性，提升了贪婪稀疏恢复算法的性能。但是因为预处理算子破坏了原始字典的结构信息，预处理字典 $\mathbf{Q}$ 的列相关性已经无法直接体现网格点间的相关性。所以如图3-2(d)所示，残差在预处理字典 $\mathbf{Q}$ 上的投影无清晰的聚簇特征。

3.4 层级贪婪匹配追踪算法

基于上一小节分析，本节从算法层面实现图3-1所示的层级贪婪匹配追踪架构，提出了一种层级贪婪匹配追踪算法 (HGMP)，并对所提算法的计算复杂度、收敛性和鲁棒性做出分析。

3.4.1 算法流程

算法流程如算法3.1所示。其中，候选集 Ω 表示网格空间 $\mathbf{N}$ 中的信号子空间，残差相关集 Λ 表示对当前残差贡献最大的原子团，删除集 $\mathbb{D}$ 表示与当前残差无关的原子团。 Φ_Ω 表示 Φ 中由索引集 Ω 表示的列构成的子矩阵。 $\mathbf{N} \setminus \mathbb{D}$ 表示集合 $\mathbf{N}$ 和集合 $\mathbb{D}$

Algorithm 3.1: 层级贪婪匹配追踪算法 (HGMP)

Input: 测量结果矢量 $\mathbf{y}$, 原始字典 Φ , 稀疏度 K

- 1 **初始化:** 候选集 $\Omega = \emptyset$, 残差相关集 $\Lambda = \emptyset$, 删除集 $\mathbb{D} = \emptyset$, 残差 $\mathbf{r} = \mathbf{y}$, 格点索引集 $\mathbb{N} = \{1, 2, \dots, N\}$, $l = 0$ 为;
- 2 **预处理:** 根据正交化算子 $\mathbf{T}_\Phi$ 计算预处理字典 $\mathbf{Q} = \mathbf{T}_\Phi \Phi$, 计算 $\mathbf{z} = \mathbf{T}_\Phi \mathbf{y}$;
- 3 // 全局估计层
- 4 **while** $l < K$ **do**
- 5 寻找对当前残差贡献最大的原子团 $\Lambda = \{j \mid |\langle \mathbf{r}, \Phi_j \rangle| > \text{Th}(\mathbf{r}, \Phi), j \in \mathbb{N} \setminus \mathbb{D}\}$;
- 6 由 $\mathbf{z}$ 和 $\mathbf{Q}$, 在 Λ 中进行局部正交匹配追踪, 获得 Λ 上的恢复系数 $\boldsymbol{\theta}$ 及其支撑集 Π ;
- 7 对 $\boldsymbol{\theta}$ 及其支撑集 Π 正则化, 结果为 $\hat{\Lambda}$;
- 8 迭代更新: $\Omega = \Omega \cup \hat{\Lambda}, \mathbb{D} = \mathbb{D} \cup \Omega, \mathbf{r} = \mathbf{y} - \Phi_\Omega (\Phi_\Omega^T \Phi_\Omega)^{-1} \Phi_\Omega^T \mathbf{y}, l = l + 1$;
- 9 // 稀疏估计层
- 10 扩大候选集. $\Omega = \Omega \cup \{i \mid i \in \text{Neighbor}(j, d), j \in \Omega, i \in \mathbb{N} \setminus \Omega\}$;
- 11 利用 $\mathbf{z}$ 和 $\mathbf{Q}$, 在候选集 Ω 中进行正交匹配追踪, 得到 $\mathbf{x}$ 的 K 稀疏逼近 $\hat{\mathbf{x}}$ 及其在 $\mathbb{N}$ 支撑集 P ;

Output: $\hat{\mathbf{x}}$, 支撑集 P

的差集, 当 $\mathbb{N}$ 为全集时, 表示 $\mathbb{D}$ 在全集中的补集。

全局估计层包括步骤 (4) 到步骤 (8), 旨在从网格空间 $\mathbb{N}$ 中找出信号子空间 Ω 。

步骤 (5) 中, $\text{Th}(\mathbf{r}, \Phi)$ 是自适应动态门限, 定义为

$$\text{Th}(\mathbf{r}, \Phi) = \max\{\Phi_{\mathbb{N} \setminus \mathbb{D}}^T \mathbf{r}\} - \text{std}\{\Phi_{\mathbb{N} \setminus \mathbb{D}}^T \mathbf{r}\} \quad (3-8)$$

动态门限能够自适应地提取对当前残差贡献最大的原子团, 噪声水平高时, 残差投影系数的方差较大, 动态门限自适应地降低门限值来对抗噪声的干扰, 保证网格化参数空间中与当前残差相关的辐射源参数附近的网格点能够被选入残差相关集 Λ 。反之, 当噪声水平低时, 动态门限会提高门限值, 减少选入残差相关集 Λ 中弱相关网格点的数目。

步骤 (7) 中, 正则化^[194] 处理旨在从恢复系数中找出幅度相近且具有最大能量的子集。给定恢复系数 $\boldsymbol{\theta}$ 及其在 $\mathbb{N}$ 中的索引集 Π , 在索引集 Π 中寻找子集 Π_0 , 满足

$$\forall i, j \in \Pi_0, |\theta_i| \leq 2|\theta_j| \quad (3-9)$$

正则化操作选择所有满足要求的子集 Π_0 中具有最大能量 $(\sum_j |\theta_j|^2, j \in \Pi_0)$ 的 Π_0 作为输出。

稀疏估计层包括步骤 (10) 到步骤 (11), 旨在从信号子空间中进行稀疏恢复。步骤 (10) 通过扩大扩选集, 提升强干扰情况下子空间估计的鲁棒性。步骤 (10) 中, $\text{Neighbor}(j, d)$ 指在网格化参数空间中与格点 j 的欧氏距离小于门限值 d 的网格点集合; 步骤 (11) 为子空间上的正交匹配追踪 (OMP) 过程, 以贪婪的方式重建稀疏信号。

所以，HGMP 算法是一种层级贪婪算法，其利用多源定位场景中的结构信息，逐步发掘贪婪匹配中残差投影在原始定位字典中的聚簇特征，进而利用预处理模型获得贪婪恢复。算法特征为：全局估计层获得真实辐射源参数在网格化空间中可能位置的全局估计，稀疏恢复层利用全局估计信息进行稀疏信号的贪婪重建。

3.4.2 算法复杂度分析

步骤 (5) 中投影操作实质是矩阵向量乘法，门限比对操作实质是一个遍历过程，所以步骤 (5) 的复杂度为 $\mathcal{O}(MN)$ ；步骤 (6) 把残差的能量正交投影到残差相关集 Λ 上，实质上是一个 OMP 子问题，复杂度为 $\mathcal{O}(MC_1^2)$ ，其中 $C_1 = \text{card}(\Lambda)$ 且 $C_1 \ll N$ ， $\text{card}(\Lambda)$ 表示集合 Λ 中元素的个数；步骤 (7) 中正则化操作实质上是大小为 C_1 的数集上的排序和二重循环遍历过程，复杂度为 $\mathcal{O}(C_1^2 + K^2)$ ；步骤 (8) 在候选集 Ω 中更新残差涉及一个最小二乘问题，复杂度为 $\mathcal{O}(M^2C_2)$ ，其中 $C_2 = \text{card}(\Omega)$ ，且满足 $C_2 \ll N$ ；步骤 (10) 扩大候选集，包含 C_2 个遍历格点集合的操作，复杂度为 $\mathcal{O}(C_2N)$ ；所以，全局恢复层的复杂度为 $\mathcal{O}(K(MN + MC_1^2 + C_1^2 + K^2 + M^2C_2) + \mathcal{O}(C_2N))$ 。渐进地，当 N 很大时， $\mathcal{O}(KMN)$ 占主导作用，全局估计层的渐进复杂度为 $\mathcal{O}(KMN)$ ；步骤 (10) 的稀疏恢复层是候选集上的稀疏度为 K 的 OMP 操作，其复杂度为 $\mathcal{O}(KMC_2)$ ；

综上所述，HGMP 算法的渐进复杂度为 $\mathcal{O}(KMN)$ 。

3.4.3 收敛性和鲁棒性分析

不同于一般的基于压缩感知算法的多源定位方法，HGMP 通过全局估计层获得辐射源目标参数在网格化参数空间中的可能位置作为候选网格点集合，然后稀疏重建层在候选网格点集合上获得最终的稀疏贪婪重建结果。这等效于从网格空间中分离出信号子空间，然后在信号子空间上进行贪婪正交匹配追踪。在进行全局估计时，利用原始字典 Φ 上残差投影的聚簇模式，筛选出对当前残差贡献最大的原子团，然后利用预处理字典 $\mathbf{Q}$ 易于贪婪恢复的优势获得局部正交匹配追踪恢复结果，最后通过正则化处理从局部恢复结果中挑选出能量最大且贡献类似的原子团。由正则化操作的分析^[194]可知，最终全局估计层的输出原子团中一定包含 OMP 最终估计的 K 个原子，而稀疏重建层算法是子空间上的 OMP 算法。所以，在高信噪比条件下，HGMP 将和 OMP 算法保持一致的收敛性。当信噪比较低时，OMP 算法易受噪声干扰，陷入局部最优解中，而 HGMP 比 OMP 挑选原子的方法比 OMP 更为谨慎，每次挑选出原子团而非单个最相关原子的模式也使得算法对噪声的鲁棒性更强。全局估计层把可能位置从 $\mathbb{N}$ 缩小到候选集 Ω ，已经极大地去除了噪声造成的虚假位置候选点。所以，在此基础上进行贪婪恢复具有明显的抗噪声优势。




图 3-3 感知空间的均匀矩形剖分和德劳内三角剖分

3.5 算法性能仿真

本小节利用提出的层级贪婪匹配追踪方法，研究能量域多源定位问题。不失一般性，设感知区域内随机均匀分布着 M 个定位节点和 K 个辐射源，所有定位节点的位置均精确已知，所有辐射源位置和辐射功率均未知，感知区域被离散成 N 个网格点来表示可能的辐射源位置。关于能量域多源定位问题及基于稀疏表征的多源定位背景知识，请参考2.3.1.1小节和2.3.3小节的详细介绍和推导，在此不再赘述。

3.5.1 德劳内三角网格剖分

空间网格化是构建定位模型的第一步，文献中广泛采用均匀矩形网格划分。理论上，三角形和四面体是二维和三维欧式空间的单纯形，可以剖分任意复杂的几何形状。因三角剖分具有良好的灵活性和稳定性，20 世纪 80 年代后，对三角剖分的研究飞速发展。除了在有限元分析，流体力学等传统领域大放光彩外。在模式识别、虚拟现实、计算机视觉等领域也得到广泛的应用。

在文献^[94]中，我们提出了基于德劳内三角剖分的空间网格化方法 (Delaunay Triangulation Spatial Gridding, DTSG)。DTSG 方法利用定位节点和四个边界点作为原始网格点，对感知区域进行初步的德劳内三角剖分，然后依次添加各个德劳内三角形的重心作为新的网格节点，重新对感知区域进行德劳内三角剖分，如此迭代分裂，直至网格点个数满足预设大小。相比均匀矩形网格，其具有灵活、网格多分辨率、网格密度自适应的特点。图3-3给出了 $M = 50$, $N = 256$ 设定下基于均匀网格划分和 DTSG 网格划分的空间网格化。其中三角形为随机布置的能量传感器定位节点，圆点为划分的网格节点，五角星为辐射源。图3-3中的辐射源用于示意定位模型，网格划分与辐射源无关。

实际中，定位节点的布置符合一定的先验知识，如在无线电监管中，固定监测站点和移动监测平台往往布置在非法电台出现机率大的区域。所以，这种由定位节点位置生成网格的空间划分方法更切合实际应用。

3.5.2 仿真设置

不妨设单位距离为 1，单位功率为 1。令 $d_0 = 1$ ，感知区域设为 10×10 的方形区域，网格点 $N = 21 \times 21$ ，辐射源数 $K = 4$ ，在 d_0 距离处辐射源有效全向辐射功率 $S_k = 10 \text{ dB}$ ， $k = 1, 2, 3, 4$ 。变换函数采用 IEEE802.15.4 标准中的室内传播损耗模型^[94]：

$$10 \lg f_i(\mathbf{g}_j) = \begin{cases} 0, & d_{ij} \leq d_0 \\ -40.2 - 20 \lg \frac{d_{ij}}{d_0}, & d_0 < d_{ij} \leq 8d_0 \\ -58.5 - 33 \lg \frac{d_{ij}}{d_0}, & d_{ij} > 8d_0 \end{cases} \quad (3-10)$$

其中， $d_{i,j} = \|\mathbf{g}_j - \mathbf{s}_i\|_2$ 。测量噪声为高斯白噪声，SNR 按式(3.1)定义。本章仿真的评价度量为平均定位正确率 (Mean Localization Accuracy Rate, MLAR)、平均定位误差距离 (Mean Localization Error Distance, MLED)、平均运行时间 (Mean Run Time, MRT)，分别定义如下。

MRT 为蒙特卡洛仿真中算法运行时间的平均值，以此来评价算法的时间复杂度。

MLAR 为被成功定位的辐射源个数与总辐射源个数 K 的比值

$$\text{MLAR} = \frac{\text{\#Successful_Localized_Source}}{K} \quad (3-11)$$

这里，辐射源 k 被成功定位指在距其单位距离的范围内能找到恢复的位置。

MLED 为辐射源的真实位置 $\mathbf{p}_k$ 与相应的恢复点位置 $\hat{\mathbf{p}}_k$ 之间的平均欧氏距离

$$\text{MLED} = \frac{\sum_{k=1}^K \|\mathbf{p}_k - \hat{\mathbf{p}}_k\|}{K} \quad (3-12)$$

值得注意的是，计算 MLED 涉及一个数据关联问题，即将估计的位置序列与真实的辐射源位置序列匹配起来。为得到最小的 MLED，对于估计的辐射源位置序列和真实的辐射源位置序列，先计算所有 K^2 个距离对 $\|\mathbf{p}_k - \hat{\mathbf{p}}_{k'}\|_2, k, k' = 1, \dots, K$ ，然后选择最小的距离对相应的真实位置和估计位置作为第一个匹配结果，并将二者从相应位置序列中删除。接下来，计算剩余的 $(K-1)^2$ 个距离对，并选择最小的距离对作为第二个匹配结果。重复上述操作，直到最后一个真实辐射源位置和估计的辐射源位置被匹配。

对比算法为 OMP 算法和 BP 算法。取 3000 次蒙特卡洛仿真的均值作为仿真结果。仿真的硬件环境为：Intel Core i7-6700 处理器，主频 3.4GHz，8G 内存；软件环境为：Windows 10 + Matlab R2016a。

3.5.3 仿真结果和分析

下文中均匀矩形网格划分简称为矩形网格，DTSG 网格划分简称为三角网格。

3.5.3.1 抗噪声性能和计算复杂度




图 3-4 噪声对定位性能的影响

图3-4(a)和图3-4(b)分别给出了 $M = 50$ 时，在均匀矩形网格划分和 DTSG 网格划分下各算法的平均定位正确率和平均定位误差距离受信噪比的影响。可以看出：

(i) 随着信噪比的增加，各算法的平均定位正确率不断上升，平均定位误差距离不断下降。在噪声占主要影响因素的前提下 (SNR 小于 25dB)，HGMP 的定位正确率和定位误差距离优于 BP 的，远远优于 OMP 的，显示出良好的抗噪能力。当 SNR = 10 dB 时，HGMP 的平均定位正确率相比 OMP 提升 30%，比 BP 提升 5%，HGMP 的平均定位误差距离在 OMP 的基础上降低了 45%，在 BP 的基础上降低了 18%。

(ii) BP 算法和 HGMP 算法在 DTSG 三角网格划分和均匀矩形网格划分下的定位性能保持一致，OMP 算法在三角网格划分下能实现比均匀矩形划分略高定位性能。

(iii) 当信噪比大于一定程度时，多源定位中的测量噪声不再是主要矛盾。此时，由于基于稀疏表征的多源定位模型是对真实辐射源位置的网格化逼近模型，网格划分密度和测量节点数目是限制 MLAR 继续增加和 MLED 继续降低的主要因素。

图3-5给出不同信噪比下各算法的平均运行时间。可以看出，HGMP 算法的计算复杂度高于 OMP 算法，但显著低于 BP 算法。随着信噪比的提高，HGMP 的平均运行时间降低。这是因为噪声水平越低，残差投影的团块结构越明显，投影方差越小，每次选入残差相关集 Λ 中的格点数目也越少，从而运行时间也越少。同样的噪声水平下，HGMP 算法在三角网格划分上的运行时间要高于矩形网格划分的，近似是矩形网格划分的常数倍。这是因为计算残差相关集采取的动态门限函数和残差投影标准差相关，由于三角网格划分的非均匀性和非规则性，其投影方差大于均匀矩形网




图 3-5 不同噪声水平下的平均运行时间

格划分的，导致三角网格中的残差相关集包含更多的格点，使得三角网格上的运行时间高于矩形网格上的。相对 BP 算法和 HGMP 算法，OMP 只包含是投影、最小二乘、更新残差三个步骤。所以其计算最为简单，但由图 3-4 可以看出，OMP 低计算复杂度的代价是对噪声敏感，使得其抗噪声性能低于 HGMP 和 BP。

3.5.3.2 定位节点个数的影响




图 3-6 定位节点个数对定位性能的影响

图 3-6(a) 和图 3-6(b) 分别给出了 $SNR = 25$ dB 条件下，定位节点数目为 6, 8, 10, 15, 30, 40, 50 时，均匀矩形网格划分和 DTSG 网格划分下各算法的平均定位正确率和平均定位误差距离。可以清晰看出：

(i) 随着定位节点的个数不断增加，各算法的平均定位正确率不断上升，平均定位误差距离不断下降并趋于收敛。对于同一定位节点数目，HGMP 显示出优于其他

算法的定位性能，并在 DTSG 三角网格划分下显示出比在均匀网格划分下更高的定位正确率和更低定位误差距离。

3.6 证明

3.6.1 定理3.2的证明

证明 (定理3.2的证明): 因为 $\text{Rank}(\Phi) = M$ ，对 Φ 进行 SVD 分解并使用紧凑表达形式，有

$$\Phi = \mathbf{U}_{M \times M} \Sigma_{M \times M} (\mathbf{V}_{N \times M})^T \quad (3-13)$$

由正交化算子定理2.1有

$$\mathbf{T}_\Phi = \Sigma^{-1} \mathbf{U}^T, \mathbf{T}_\Phi \Phi = \mathbf{V}^T \quad (3-14)$$

由式(2-24)可知， $\mathbf{T}_\Phi \mathbf{n} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \Sigma^{-1} \Sigma^{-1})$ 。所以，

$$\mathbb{E} \{ \|\mathbf{T}_\Phi \mathbf{n}\|_2^2 \} = \sum_{i=1}^M \frac{\sigma^2}{s_i^2} \quad (3-15)$$

记 $\mathbf{V}^T \mathbf{x} = [\nu_1, \nu_2, \dots, \nu_M]^T$ ，有中间步骤结果如下。

$$\|\Phi \mathbf{x}\|_2^2 = \mathbf{x}^T \mathbf{V} \Sigma^T \mathbf{U}^T \mathbf{U} \Sigma \mathbf{V}^T \mathbf{x} = \sum_{i=1}^M s_i^2 \nu_i^2 \quad (3-16)$$

$$\|\mathbf{T}_\Phi \Phi \mathbf{x}\|_2^2 = \|\mathbf{V}^T \mathbf{x}\|_2^2 = \sum_{i=1}^M \nu_i^2 \quad (3-17)$$

$$\mathbb{E} \{ \mathbf{n}^T \mathbf{n} \} = M \sigma^2 \quad (3-18)$$

根据定义3.1，由式(3-15)，(3-16)，(3-17)，(3-18)可知，对于确定性 $\mathbf{x}$ 的情况有

$$\frac{\text{SNR}_\Phi}{\text{SNR}_{\mathbf{T}_\Phi}} = \frac{\|\Phi \mathbf{x}\|_2^2 \mathbb{E} \{ \|\mathbf{T}_\Phi \mathbf{n}\|_2^2 \}}{\|\mathbf{T}_\Phi \Phi \mathbf{x}\|_2^2 \mathbb{E} \{ \|\mathbf{n}\|_2^2 \}} = \frac{\sum_{i=1}^M s_i^2 \nu_i^2 \sum_{i=1}^M \frac{1}{s_i^2}}{M \sum_{i=1}^M \nu_i^2} \quad (3-19)$$

对于任意 $i, j \in 1, 2, \dots, M$ ，不妨设 $i < j$ ，则有 $s_j^2 - s_i^2 \leq 0$ 。因为 $\frac{\nu_i^2}{\nu_j^2} \geq \frac{s_j^2}{s_i^2}$ ，所以， $s_i^2 \nu_i^2 - s_j^2 \nu_j^2 \geq 0$ 。故对于任意 $i, j \in 1, 2, \dots, M$ ，有

$$(s_i^2 \nu_i^2 - s_j^2 \nu_j^2) \left(\frac{1}{s_i^2} - \frac{1}{s_j^2} \right) \leq 0 \quad (3-20)$$

由 Chebyshev 总和不等式有

$$\sum_{i=1}^M s_i^2 \nu_i^2 \sum_{i=1}^M \frac{1}{s_i^2} \geq M \sum_{i=1}^M \nu_i^2 \quad (3-21)$$

将不等式(3-21)代入式(3-19)，可得 $\text{SNR}_{\mathbf{T}_\Phi} \leq \text{SNR}_\Phi$ 。

□

3.6.2 定理3.3的证明

证明 (定理3.3的证明): 因为 x_j 独立同分布且其二阶矩存在, 记 $\mu = \mathbb{E}[x_j^2]$ 。在小节3.6.1的证明的基础上, 有

$$\mathbb{E}\{v_i^2\} = \mathbb{E}\left\{\sum_{j=1}^N [\mathbf{V}]_{i,j}^2 x_j^2\right\} = \sum_{j=1}^N [\mathbf{V}]_{i,j}^2 \mathbb{E}\{x_j^2\} = \mu \quad (3-22)$$

$$\mathbb{E}\{s_i^2 v_i^2\} = s_i^2 \mathbb{E}\{v_i^2\} = s_i^2 \mu \quad (3-23)$$

则根据定义3.1和式(3-15), (3-18), (3-22), (3-23)有

$$\frac{\text{SNR}_\Phi}{\text{SNR}_{\mathbf{T}_\Phi}} = \frac{\mathbb{E}\{\|\Phi \mathbf{x}\|_2^2\} \mathbb{E}\{\|\mathbf{T}_\Phi \mathbf{n}\|_2^2\}}{\mathbb{E}\{\|\mathbf{T}_\Phi \Phi \mathbf{x}\|_2^2\} \mathbb{E}\{\|\mathbf{n}\|_2^2\}} = \frac{\sum_{i=1}^M s_i^2 \sum_{i=1}^M \frac{1}{s_i^2}}{M^2} \quad (3-24)$$

由 Cauchy-Schwarz 不等式, 有

$$\sum_{i=1}^M s_i^2 \sum_{i=1}^M \frac{1}{s_i^2} \geq \left(\sum_{i=1}^M s_i \frac{1}{s_i}\right)^2 = M^2 \quad (3-25)$$

所以, $\text{SNR}_{\mathbf{T}_\Phi} \leq \text{SNR}_\Phi$, 等号成立的条件为: Φ 的所有奇异值均为同一正常数。

□

3.7 本章小结

针对多源定位中的结构信息挖掘的问题, 本章通过分析多源定位中的聚簇结构信息, 基于贪婪匹配追踪思想提出了一种新颖的层级贪婪匹配定位算法 (HGMP), 并证明了文献中广泛采用的正交化预处理操作降低信噪比。所提算法利用全局估计层从网格空间中分离出信号子空间, 降低了观测噪声的影响, 然后在稀疏恢复层中利用信号子空间进行正交匹配追踪实现鲁棒性贪婪定位。理论分表明, HGMP 定位算法具有渐进线性复杂度 $\mathcal{O}(KMN)$, 具有比 OMP 更强的噪声鲁棒性。仿真表明, 提出的 HGMP 算法以远低于 BP 算法的计算复杂度, 实现了比 BP 算法和 OMP 算法更优越的定位性能。

第四章 基于参数化稀疏贝叶斯字典学习的多源定位

4.1 引言

基不匹配 (basis mismatch)^[181] 是稀疏恢复理论中的一个重要问题, 指给定的表示基与真实的稀疏表示基不匹配, 造成观测矢量无法由给定的字典稀疏表出。基不匹配情况下, 稀疏恢复算法的重建性能将大大降低。在基于稀疏表征的多源定位中, 网格失配和模型参数误差将带来基不匹配问题, 影响多源定位算法性能。具体分析如下:

一方面, 根据一定的先验知识对连续的辐射源参数空间进行网格离散化是将多源定位问题转化为稀疏编码问题的前提。然而, 真实的辐射源参数可能偏离预先划定的离散网格点集合, 即网格失配 (off-grid) 问题。在压缩感知理论中, 网格失配现象带来基不匹配问题。文献^[181]指出, 由固定网格离散化带来基不匹配问题无法通过更精细的网格粒度来消除。虽然在 DOA 估计问题中, 利用信号协方差的 Toeplitz 结构, 基于原子范数和范德蒙分解定理提出了无网格稀疏参数估计方法^[130-135], 但该方法无法直接拓展到能量域、时间域多源定位等诸多问题中。相对而言, 基于网格离散化的方法只依赖于参数化的信号模型, 更具有一般性和普适性。近年来, 虽然国内外学者提出了诸多网格演进类算法^[97-98, 123-127]来处理网格失配问题, 但这些方法无法形成稀疏恢复与网格点调整的闭环优化逻辑, 因而其参数估计的能力有限。

另一方面, 多源定位问题中模型参数的误差同样会带来基不匹配问题。如在能量域多源定位中, 传播环境的路损指数会存在不确定性, 定位节点的位置可能存在误差; 在基于角度域的多源定位中, DOA 估计中信号的波长和阵列天线阵子的间距可能存在误差, 纯方位角定位中的定位节点位置可能存在误差或偏移; 时间域多源定位中, 介质中的传播速度可能偏离给定值。模型参数误差将导致观测矢量无法由构建的定位字典稀疏表出, 进而影响多源定位算法性能。

本章研究表明, 网格失配和模型参数误差带来的基不匹配问题均可被建模成参数化的字典学习问题。针对该问题, 本文将多源定位问题建模成参数化字典学习和稀疏恢复的联合优化问题, 并从概率推理的角度, 提出参数化稀疏贝叶斯字典学习算法 (PSBDL), 实现稀疏恢复和字典学习的闭环逻辑。针对实信号模型, 研究了网格失配条件下和传播参数不确定情况下的能量域多源定位问题。针对复信号模型, 研究了网格失配条件下的 DOA 估计问题。

本章的创新点有: (1) 从参数化字典学习的角度统一建模了网格失配问题和模型参数误差问题; (2) 提出了基于参数化稀疏贝叶斯字典学习的多源定位方法, 实现了稀疏恢复和字典学习的闭环优化逻辑; (3) 针对实信号/复信号、SMV/MMV 观测模型下的多源定位问题, 详细推导了 PSBDL 算法的四种表现形式: PSBDL-ReSMV、

PSBDL-ReMMV、PSDBL-ComSMV、PSBDL-ComMMV。；(4) 基于所提算法分别研究了能量域多源定位和角度域多源定位中的关键问题，推导了相关问题的克拉美罗下界 (CRLB)；(5) 对比理论上的克拉美罗下界和最新算法，通过计算机仿真验证了所提方法的有效性和优越性。

本章内容安排如下：4.2 节介绍参数化的字典学习问题；4.3 针对 SMV 和 MMV 情况，研究实信模型下的参数化稀疏贝叶斯学习算法；4.4 针对 SMV 和 MMV 情况，研究复信号模型下的参数化的稀疏贝叶斯学习算法；4.5 节总结了 SMV 模型和 MMV 模型下的实信号、复信号参数化字典学习算法的区别；4.6 节基于所提算法分别研究能量域和角度域多源定位问题，并讨论算法的性能仿真结果；4.7 节给出相关证明和推导过程；4.8 节对本章进行小结。

4.2 多源定位中的参数化字典学习问题

4.2.1 多源定位中的基不匹配问题

由第二章的分析可知，对于式(2-64)所示的广义多源定位模型

$$\mathbf{y} = \Psi(\boldsymbol{\theta})\mathbf{w} + \mathbf{n} \quad (4-1)$$

根据一定先验知识对辐射源参数 $\boldsymbol{\theta}$ 所在的参数空间 Θ 进行网格划分，得到 Θ 的网格化近似 $\mathcal{G} = \{\mathbf{g}_j, j = 1, 2, \dots, N\}$ ，并通过变换函数 $f_i(\mathbf{g}_j)$ 构建如式(2-66)所示的过完备表示字典 Φ ，得到如式(2-67)所示基于稀疏表征的广义多源定位模型，不妨将式(2-67)重写如下

$$\mathbf{y} = \Phi\mathbf{x} + \mathbf{n}, \quad x_j = \begin{cases} 0, & \forall k \in 1, 2, \dots, K, \text{ 均有 } \mathbf{g}_j \neq \boldsymbol{\theta}_k \\ w_k & \exists k \in 1, 2, \dots, K, \text{ 满足 } \mathbf{g}_j = \boldsymbol{\theta}_k \end{cases}, \quad (4-2)$$

实际上，模型(4-2)的成立包含了如下两条假设。

假设 4.1 对 $k = 1, 2, \dots, K$ ，真实参数 $\boldsymbol{\theta}_k \in \mathcal{G}$ 。

假设 4.2 对于过完备表示字典 Φ ，其构成元素 $[\Phi]_{ij} = f_i(\mathbf{g}_j)$ 精确已知。

第一条假设即真实辐射源参数 $\boldsymbol{\theta}$ 全部落在预先划定的网格点集合 $\mathcal{G}$ 中，文献中称为 on-grid 假设。然而，网格划分是人为选定的过程，实际中该假设难以成立，总存在 $\boldsymbol{\theta}_k$ 满足 $\boldsymbol{\theta}_k \notin \mathcal{G}$ ，即网格失配 (off-grid)。在网格失配的情况下，模型(4-2)中的等号无法成立，只能通过尽量细密的网格来逼近模型(4-2)。数学上，网格失配将导致 $\mathbf{y}$ 无法由 Φ 严格稀疏表出，带来基不匹配问题。

第二条假设是模型参数精确已知。由表2-1可知，对于过完备表示字典的第 i 行，第 j 列元素 $[\Phi]_{ij} = f_i(\mathbf{g}_j)$ ，其变量不仅包含表示辐射源参数的网格点 $\mathbf{g}_j$ ，也包含模型参数 $\mathcal{M}_i$ 。根据表2-1所述广义多源定位模型与具体模型的联系，表4-1分析了在不同定位场景中模型参数 $\mathcal{M}_i$ 的具体含义。实际应用中，模型参数可能存在误差或不确定性，这同样会导致 $\mathbf{y}$ 无法由 Φ 严格稀疏表出，带来基不匹配问题。

由模型参数误差和固定网格划分造成的网格失配现象，将严重影响稀疏恢复算

表 4-1 不同定位场景中的模型参数

广义多源定位模型(2-63)	$y_i = \sum_{k=1}^K f_i(\theta_k, \mathcal{M}_i)w_k + n_i$			
具体模型	基于能量的多源定位 (2-42)	DOA 估计 (2-48)	纯方位角定位 (2-52)	基于 TDOA 的多源定位 (2-60)
模型参数 $\mathcal{M}_i$	传感器位置 s_i 路损指数 γ 传感器增益 g_i	阵列间距 d 信号波长 λ	传感器位置 s_i	传感器位置 s_i 介质中的传播速度 c

法的性能，进而影响基于稀疏表征的多源定位算法的参数估计性能。

4.2.2 基于字典学习和稀疏表征的多源定位问题

由以上分析可见，网格失配和模型参数误差带来的基不匹配问题均源自将网格或者模型参数视为固定值，导致无法在后续推断中继续优化网格和模型参数。令模型参数集合为 $\mathcal{M} = \{\mathcal{M}_1, \mathcal{M}_2, \dots, \mathcal{M}_M\}$ ，本文将网格集合 $\mathcal{G}$ 和 $\mathcal{M}$ 视为多源定位中待学习的未知变量。基于稀疏表征的多源定位模型可显示地表达成

$$\mathbf{y} = \Phi(\mathcal{G}, \mathcal{M})\mathbf{x} + \mathbf{n}, \quad x_j = \begin{cases} 0, & \forall k \in 1, 2, \dots, K, \text{ 均有 } g_j \neq \theta_k \\ w_k & \exists k \in 1, 2, \dots, K, \text{ 满足 } g_j = \theta_k \end{cases} \quad (4-3)$$

不同于模型(4-2)，模型(4-3)的字典 Φ 是字典参数 $\mathcal{G}, \mathcal{M}$ 的函数。更具体地，网格参数 g_j 决定了 Φ 中第 j 列的构成，模型参数 $\mathcal{M}_i$ 决定了 Φ 中第 i 行的构成。所以 Φ 是由字典参数 $\mathcal{G}, \mathcal{M}$ 完全参数化表示的过完备表示字典，简称为参数化字典。

所以，在求解多源定位问题时，需要联合推断稀疏矢量 $\mathbf{x}$ 和字典参数 $\mathcal{G}, \mathcal{M}$ ，即求解如下参数化字典学习和稀疏恢复的联合优化问题

$$\min_{\mathbf{x}, \mathcal{G}, \mathcal{M}} \|\mathbf{y} - \Phi\mathbf{x}\|_2 + \lambda \|\mathbf{x}\|_0 \quad (4-4)$$

和第二章所示的稀疏恢复问题(2-68c)相比，联合优化问题(4-4)构建了稀疏推断和字典学习的闭环优化逻辑，理论上能够有效缓解由网格失配和模型参数误差带来的基不匹配问题。

下文将从稀疏贝叶斯学习的角度，分别针对实信号/复信号、SMV/MMV 观测模型研究问题(4-4)的求解算法。

4.3 实信号模型下的参数化稀疏贝叶斯字典学习算法

本小节针对实信号观测模型，构建具有 Laplace 稀疏先验的层级概率模型，然后从稀疏贝叶斯学习的角度求解问题(4-4)。4.3.1 小节针对单测量矢量 (SMV) 观测模型，提出 SMV 实信号模型下的参数化稀疏贝叶斯字典学习算法 PSBDL-ReSMV。4.3.2 小节将所得算法扩展到多测量矢量 (MMV) 观测模型中，得到 MMV 实信号模型下的参数化稀疏贝叶斯字典学习算法 PSBDL-ReMMV。

4.3.1 SMV 实信号模型下的参数化稀疏贝叶斯字典学习算法

一、层级概率模型




图 4-1 SMV 情况下的层级概率图模型

对 SMV 观测模型 $y = \Phi(\mathcal{G}, \mathcal{M})x + n$ 构建如图 4-1 所示的层级概率图模型。实信号情况下, $y, n \in \mathbb{R}^M$, $\Phi \in \mathbb{R}^{M \times N}$, $x \in \mathbb{R}^N$, 图 4-1 表示的概率模型为

$$\text{观测噪声模型: } y | \beta; \mathcal{G}, \mathcal{M} \sim \mathcal{N}(y | \Phi x, \beta^{-1} \mathbf{I}_M), \beta \sim \text{Gamma}(\beta | a, b) \quad (4-5a)$$

$$\text{稀疏矢量模型: } x | \alpha \sim \mathcal{N}(x | 0, \mathbf{A}), \alpha \sim \prod_{j=1}^N \text{Gamma}\left(\alpha_j \left| 1, \frac{\lambda}{2} \right.\right) \quad (4-5b)$$

其中, y 为观测变量, x, α, n, β 为隐变量, $\mathbf{A} = \text{diag}(\alpha)$, $\alpha = [\alpha_1, \alpha_2, \dots, \alpha_N]^T$ 。 a, b, λ 为给定的概率图参数, $\mathcal{G}, \mathcal{M}$ 为字典参数。为获得较宽的先验分布, 可取 $a = b = 10^{-4}$, $\lambda = 10^{-2}$ 。对这些参数更详细的解释参考第二章。

式(4-5a)和式(4-5b)均为两层的共轭先验建模。层级建模的好处是能够构建出一个较宽的先验分布族, 能更方便地拟合数据分布。共轭先验意味着先验概率和后验概率具有一致的形式, 易于迭代求解。

对于式(4-5b)采用的层级先验模型, 有定理如下。

定理 4.1 若 x 有条件分布 $x | \alpha \sim \mathcal{N}(x | 0, \alpha)$, 方差 α 满足 $\alpha \sim \text{Gamma}(\alpha | 1, \frac{1}{2\lambda^2})$, 则 x 的边缘分布 $p(x)$ 为均值为 0, 尺度参数为 λ 的 Laplace 分布, 即 $p(x) = \text{Laplace}(x | 0, \lambda)$ 。

证明: 定理 4.1 的证明见 4.7.1 小节。 $\square$

由定理 4.1 可知, 虽然式(4-5b)对 x 构建了两层非稀疏的共轭先验分布 $p(x | \alpha)$ 和 $p(\alpha)$, 但 x 的边缘分布满足 $p(x) = \prod_{j=1}^N \text{Laplace}\left(x_j | 0, \frac{1}{\lambda}\right)$ 。即模型(4-5b)等效地对所有 x_j 施加了独立同分布的 Laplace 先验假设。和 2.4.3 小节 SBL 模型所采用 Student's t 分布相比, Laplace 分布的概率密度更加集中在原点附近, 比 Student's t 分布稀疏性约束更强。当稀疏先验为 Laplace 分布时, 最大后验估计等效于最小化 ℓ_1 范数罚项的优化问题, 而 ℓ_1 范数是 ℓ_0 范数的最紧凸松弛, 优化理论中常用 ℓ_1 作为罚项进行稀疏优化, 即著名的 LASSO 回归方法。

二、贝叶斯推断

贝叶斯推断旨在寻求稀疏向量 x 和字典参数的 $\mathcal{G}, \mathcal{M}$ 的 MAP 估计 $\hat{x}$ 和 $\hat{\mathcal{G}}, \hat{\mathcal{M}}$ 。在计算这些估计量的过程中, 需要获得隐变量 α, β 的 MAP 估计 $\hat{\alpha}, \hat{\beta}$ 。

根据概率图模型(4-5), 分别有联合概率密度和后验概率密度如下

$$p(x, y, \alpha, \beta; \mathcal{G}, \mathcal{M}) = p(y | x, \beta; \mathcal{G}, \mathcal{M}) p(x | \alpha) p(\alpha) p(\beta) \quad (4-6)$$

$$p(\mathbf{x}, \boldsymbol{\alpha}, \beta | \mathbf{y}; \mathcal{G}, \mathcal{M}) = p(\mathbf{x} | \boldsymbol{\alpha}, \beta, \mathbf{y}; \mathcal{G}, \mathcal{M}) p(\boldsymbol{\alpha}, \beta | \mathbf{y}; \mathcal{G}, \mathcal{M}) \quad (4-7)$$

基于2.4.3小节的稀疏贝叶斯学习框架, 有

$$p(\mathbf{x} | \boldsymbol{\alpha}, \beta, \mathbf{y}; \mathcal{G}, \mathcal{M}) = \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Sigma}) \quad (4-8)$$

其中, 均值 $\boldsymbol{\mu}$ 和协方差矩阵 $\boldsymbol{\Sigma}$ 为

$$\boldsymbol{\mu} = \beta \boldsymbol{\Sigma} \boldsymbol{\Phi}^T \mathbf{y}, \quad \boldsymbol{\Sigma} = (\beta \boldsymbol{\Phi}^T \boldsymbol{\Phi} + \mathbf{A}^{-1})^{-1} \quad (4-9)$$

因此, 稀疏矢量 $\mathbf{x}$ 的 MAP 估计为

$$\hat{\mathbf{x}} = \arg \max_{\mathbf{x}} p(\mathbf{x} | \boldsymbol{\alpha}, \beta, \mathbf{y}; \mathcal{G}, \mathcal{M}) = \boldsymbol{\mu} \quad (4-10)$$

根据2.4.3小节, 隐变量 $\boldsymbol{\alpha}$, β 和字典参数 $\mathcal{G}, \mathcal{M}$ 的估计为

$$\{\hat{\boldsymbol{\alpha}}, \hat{\beta}, \hat{\mathcal{G}}, \hat{\mathcal{M}}\}_{\text{MAP}} = \arg \max_{\boldsymbol{\alpha}, \beta, \mathcal{G}, \mathcal{M}} p(\boldsymbol{\alpha}, \beta | \mathbf{y}; \mathcal{G}, \mathcal{M}) \quad (4-11)$$

实质上, 式(4-11)是一个 MAP 问题, 由于 $p(\mathbf{y})$ 与隐变量和字典参数无关, 所以 MAP 估计等效于 ML 估计, 有 $\{\hat{\boldsymbol{\alpha}}, \hat{\beta}, \hat{\mathcal{G}}, \hat{\mathcal{M}}\}_{\text{MAP}} = \{\hat{\boldsymbol{\alpha}}, \hat{\beta}, \hat{\mathcal{G}}, \hat{\mathcal{M}}\}_{\text{ML}}$, 其中

$$\{\hat{\boldsymbol{\alpha}}, \hat{\beta}, \hat{\mathcal{G}}, \hat{\mathcal{M}}\}_{\text{ML}} = \arg \max_{\boldsymbol{\alpha}, \beta, \mathcal{G}, \mathcal{M}} p(\mathbf{y}, \boldsymbol{\alpha}, \beta; \mathcal{G}, \mathcal{M}) = \arg \max_{\boldsymbol{\alpha}, \beta, \mathcal{G}, \mathcal{M}} \ln p(\mathbf{y}, \boldsymbol{\alpha}, \beta; \mathcal{G}, \mathcal{M}) \quad (4-12)$$

本章采取期望最大化算法 (EM) 来求解式(4-12)所示 ML 问题:

$$\{\hat{\boldsymbol{\alpha}}, \hat{\beta}, \hat{\mathcal{G}}, \hat{\mathcal{M}}\}_{\text{EM}} = \arg \max_{\boldsymbol{\alpha}, \beta, \mathcal{G}, \mathcal{M}} \mathbb{E}\{\ln p(\mathbf{x}, \mathbf{y}, \boldsymbol{\alpha}, \beta; \mathcal{G}, \mathcal{M})\} \quad (4-13)$$

式(4-13)中, $\mathbb{E}\{\cdot\}$ 表示对隐变量 $\mathbf{x}$ 的后验概率密度 $p(\mathbf{x} | \boldsymbol{\alpha}, \beta, \mathbf{y}; \mathcal{G}, \mathcal{M})$ 求期望。由联合概率密度式(4-6)有

$$\hat{\boldsymbol{\alpha}} = \arg \max_{\boldsymbol{\alpha}} \mathbb{E}\{\ln p(\mathbf{x} | \boldsymbol{\alpha}) + \ln p(\boldsymbol{\alpha})\} \quad (4-14a)$$

$$\hat{\beta} = \arg \max_{\beta} \mathbb{E}\{\ln p(\mathbf{y} | \mathbf{x}, \beta; \mathcal{G}, \mathcal{M}) + \ln p(\beta)\} \quad (4-14b)$$

$$\{\hat{\mathcal{G}}, \hat{\mathcal{M}}\} = \arg \max_{\mathcal{G}, \mathcal{M}} \mathbb{E}\{\ln p(\mathbf{y} | \mathbf{x}, \beta; \mathcal{G}, \mathcal{M})\} \quad (4-14c)$$

求解(4-14), 得

$$\hat{\alpha}_j = \frac{\sqrt{1 + 4\lambda(\Sigma_{jj} + \mu_j^2)} - 1}{2\lambda}, \quad j = 1, \dots, N \quad (4-15a)$$

$$\hat{\beta} = \frac{2a - 2 + M}{2b + \|\mathbf{y} - \boldsymbol{\Phi}\boldsymbol{\mu}\|_2^2 + \beta^{-1} \sum_{j=1}^N (1 - \alpha_j^{-1} \Sigma_{jj})} \quad (4-15b)$$

$$\{\hat{\mathcal{G}}, \hat{\mathcal{M}}\} = \arg \min_{\mathcal{G}, \mathcal{M}} \left\{ (\mathbf{y} - \boldsymbol{\Phi}\boldsymbol{\mu})^T (\mathbf{y} - \boldsymbol{\Phi}\boldsymbol{\mu}) + \text{tr}(\boldsymbol{\Phi}\boldsymbol{\Sigma}\boldsymbol{\Phi}^T) \right\} \quad (4-15c)$$

详细推导过程见4.7.2小节。

式(4-15c)中, $\boldsymbol{\Phi}$ 是字典参数 $\mathcal{G}, \mathcal{M}$ 的函数。记式(4-15c)的优化目标函数为 $F(\mathcal{G}, \mathcal{M})$, 文献^[211]提供了一种基于最速下降的迭代求解方法:

$$\mathbf{g}_j^{(l+1)} = \mathbf{g}_j^{(l)} - \eta_1 \frac{\partial F}{\partial \mathbf{g}_j}, \quad j = 1, 2, \dots, N \quad (4-16a)$$

$$\mathcal{M}_i^{(l+1)} = \mathcal{M}_i^{(l)} - \eta_2 \frac{\partial F}{\partial \mathcal{M}_i}, \quad i = 1, 2, \dots, M \quad (4-16b)$$

Algorithm 4.1: SMV 实信号模型下的参数化稀疏贝叶斯字典学习算法 (PSBDL-ReSMV)

Input: 观测数据 $\mathbf{y}$;

- 1 初始化字典参数 $\mathcal{G}^{(0)}$, $\mathcal{M}^{(0)}$, 隐变量 $\alpha^{(0)}, \beta^{(0)}$, $l = 0$;
- 2 **while** 不满足终止条件 **do**
- 3 根据 $\mathcal{G}^{(l)}$, $\mathcal{M}^{(l)}$ 计算 $\Phi^{(l)}$, 令 $m = 0$;
- 4 // 稀疏信号恢复
- 5 **while** 不满足稀疏恢复终止条件 **do**
- 6 由 $\alpha^{(m)}$, $\beta^{(m)}$, Φ 根据式(4-9)计算 μ , Σ ;
- 7 根据式(4-15a)和(4-15b)更新 $\alpha^{(m+1)}$, $\beta^{(m+1)}$;
- 8 $m = m + 1$;
- 9 // 字典学习
- 10 $\mathcal{G}^{(0)} = \mathcal{G}^{(l)}$, $\mathcal{M}^{(0)} = \mathcal{M}^{(l)}$, $n = 0$;
- 11 **while** 不满足字典学习终止条件 **do**
- 12 求解问题(4-15c), 获得 $\mathcal{G}^{(n+1)}, \mathcal{M}^{(n+1)}$;
- 13 根据 $\mathcal{G}^{(n+1)}, \mathcal{M}^{(n+1)}$ 更新 $\Phi^{(l)}$;
- 14 $n = n + 1$;
- 15 $\mathcal{G}^{(l+1)} = \mathcal{G}^{(n)}$, $\mathcal{M}^{(l+1)} = \mathcal{M}^{(n)}$, $\alpha^{(0)} = \alpha^{(m)}$, $\beta^{(0)} = \beta^{(m)}$, $l = l + 1$;

Output: $\hat{\mathbf{x}} = \mu$, $\hat{\mathcal{G}} = \mathcal{G}^{(l)}$, $\hat{\mathcal{M}} = \mathcal{M}^{(l)}$;

该方法本质上通过目标优化函数 $F(\mathcal{G}, \hat{\mathcal{M}})$ 对字典参数 $\mathcal{G}, \hat{\mathcal{M}}$ 进行一阶展开来更新字典参数。然而从函数复合的角度看, 目标函数 $F(\mathcal{G}, \hat{\mathcal{M}})$ 是字典 Φ 的函数, Φ 是字典参数 $\mathcal{G}, \hat{\mathcal{M}}$ 的函数。所以, 文献^[122,212]中也提出先对字典进行一阶展开

$$\Phi^{(l+1)} = \Phi^{(l)} + \sum_{i=1}^M \frac{\partial \Phi^{(l)}}{\partial \mathcal{M}_i} d\mathcal{M}_i + \sum_{j=1}^N \frac{\partial \Phi^{(l)}}{\partial \mathbf{g}_j} d\mathbf{g}_j \quad (4-17)$$

然后, 将式(4-17)代入问题(4-15c)中, 求解 $\Phi^{(l)}$ 与 $\Phi^{(l+1)}$ 的所有最优步长 $d\mathcal{M}_i, d\mathbf{g}_j$

$$\min_{d\mathcal{G}, d\mathcal{M}} \left\{ (\mathbf{y} - \Phi\mu)^T (\mathbf{y} - \Phi\mu) + \text{tr}(\Phi\Sigma\Phi^T) \right\} \quad (4-18a)$$

$$\text{s.t. } \Phi = \Phi^{(l)} + \sum_{i=1}^M \frac{\partial \Phi^{(l)}}{\partial \mathcal{M}_i} d\mathcal{M}_i + \sum_{j=1}^N \frac{\partial \Phi^{(l)}}{\partial \mathbf{g}_j} d\mathbf{g}_j \quad (4-18b)$$

最后, 更新字典参数

$$\mathbf{g}_j^{(l+1)} = \mathbf{g}_j^{(l)} + d\mathbf{g}_j, \quad j = 1, 2, \dots, N \quad (4-19a)$$

$$\mathcal{M}_i^{(l+1)} = \mathcal{M}_i^{(l)} + d\mathcal{M}_i, \quad i = 1, 2, \dots, M \quad (4-19b)$$

最速下降方法迭代公式(4-16)和字典展开方法迭代公式(4-19)的区别在于, 前者是对目标函数进行最速下降, 后者是对字典进行最速下降。一般而言, 后者具有比前者更快的收敛速度, 而前者具有比后者更精确的收敛性保障。

三、算法总结

基于上述贝叶斯推断结果, 算法4.2总结了 SMV 实信号模型下的参数化稀疏贝

叶斯字典学习算法 PSBDL-ReSMV。

首先，在步骤 (6) 中，若 $N > M$ ，则令 $\Xi = \beta^{-1}\mathbf{I}_M + \Phi\mathbf{A}\Phi^T$ ，通过 Woodbury 矩阵恒等式

$$\Sigma = \mathbf{A} - \mathbf{A}\Phi^T\Xi^{-1}\Phi\mathbf{A} \quad (4-20)$$

可将计算 Σ 所需的矩阵求逆的复杂度从原来的 $\mathcal{O}(N^3)$ 降至 $\mathcal{O}(M^3)$ 。

其次，只有非零的稀疏系数 x_j 对测量信号 $\mathbf{y}$ 具有贡献，所以字典学习步骤可以限制到非零系数 x_j 对应的原子上。或更进一步，限制在最大的 K_0 个非零系数所对应的原子上。在采用的概率模型中，非零的 x_j 由更大的方差 α_j 来刻画。所以可取 α 中最大的 K_0 个元素对应的原子来进行字典学习，从而使原始字典学习问题的维度被大大降低，提高算法的计算速度。

四、算法分析

一般而言，有 $K_0 \leq M < N$ 。所以，PSBDL-ReSMV 算法各主要步骤的计算复杂度为：步骤 (3) 为 $\mathcal{O}(MN)$ ；步骤 (6) 为 $\mathcal{O}(NM^2 + MN^2 + NM + M^3)$ ；步骤 (7) 为 $\mathcal{O}(NM)$ ；步骤 (12) 为 $\mathcal{O}(K_0M^2)$ ；步骤 (13) 为 $\mathcal{O}(K_0M)$ 。所以 PSBDL-ReSMV 算法具有和 SBL 一样的渐进复杂度 $\mathcal{O}(NM^2)$ 。

由 EM 算法的收敛性质可知，PSBDL-ReSMV 算法保证收敛到一个局部平稳点。

4.3.2 MMV 实信号模型下的参数化稀疏贝叶斯字典学习算法

实际应用中，往往能获得多个快拍的测量信号 $\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_T$ 。对于每一快拍 $t = 1, 2, \dots, T$ ，基于稀疏表征的 SMV 模型为 $\mathbf{y}_t = \Phi(\mathcal{G}, \mathcal{M})\mathbf{x}_t + \mathbf{n}_t$ 。本小节将 4.3.1 小节的 SMV 算法推广到 MMV 情况中。令 $\mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_T]$ ， $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T]$ ， $\mathbf{E} = [\mathbf{n}_1, \mathbf{n}_2, \dots, \mathbf{n}_T]$ ，MMV 观测模型为

$$\mathbf{Y} = \Phi(\mathcal{G}, \mathcal{M})\mathbf{X} + \mathbf{E} \quad (4-21)$$

一、层级概率模型




图 4-2 MMV 情况下的层级概率图模型

对 MMV 观测模型(4-21)构建如图4-2所示的层级概率模型。实信号情况下， $\mathbf{Y}, \mathbf{E} \in \mathbb{R}^{M \times T}$ ， $\Phi \in \mathbb{R}^{M \times N}$ ， $\mathbf{X} \in \mathbb{R}^{N \times T}$ ，图4-2表示的概率模型为

$$\mathbf{Y} | \beta; \mathcal{G}, \mathcal{M} \sim \prod_{t=1}^T \mathcal{N}(\mathbf{y}_t | \Phi \mathbf{x}_t, \beta^{-1} \mathbf{I}_M), \quad \beta \sim \text{Gamma}(\beta | a, b) \quad (4-22a)$$

$$\mathbf{X} | \alpha \sim \prod_{t=1}^T \mathcal{N}(\mathbf{x}_t | 0, \mathbf{A}), \quad \alpha \sim \prod_{j=1}^N \text{Gamma}\left(\alpha_j \left| 1, \frac{\lambda}{2} \right.\right) \quad (4-22b)$$

Algorithm 4.2: MMV 实信号模型下的参数化稀疏贝叶斯字典学习算法 (PSBDL-ReMMV)

Input: 观测数据 $\mathbf{Y}$;

- 1 初始化字典参数 $\mathcal{G}^{(0)}$, $\mathcal{M}^{(0)}$, 隐变量 $\alpha^{(0)}, \beta^{(0)}$, $l = 0$;
- 2 **while** 不满足终止条件 **do**
- 3 根据 $\mathcal{G}^{(l)}$, $\mathcal{M}^{(l)}$ 计算 $\Phi^{(l)}$, 令 $m = 0$;
- 4 // 稀疏信号恢复
- 5 **while** 不满足稀疏恢复终止条件 **do**
- 6 由 $\alpha^{(m)}$, $\beta^{(m)}$, Φ 根据式(4-24)计算 $\mathbf{U}$, Σ ;
- 7 根据式(4-27a)和(4-27b)更新 $\alpha^{(m+1)}$, $\beta^{(m+1)}$;
- 8 $m = m + 1$;
- 9 // 字典学习
- 10 $\mathcal{G}^{(0)} = \mathcal{G}^{(l)}$, $\mathcal{M}^{(0)} = \mathcal{M}^{(l)}$, $n = 0$;
- 11 **while** 不满足字典学习终止条件 **do**
- 12 求解问题(4-27c), 获得 $\mathcal{G}^{(n+1)}, \mathcal{M}^{(n+1)}$;
- 13 根据 $\mathcal{G}^{(n+1)}, \mathcal{M}^{(n+1)}$ 更新 $\Phi^{(l)}$;
- 14 $n = n + 1$;
- 15 $\mathcal{G}^{(l+1)} = \mathcal{G}^{(n)}$, $\mathcal{M}^{(l+1)} = \mathcal{M}^{(n)}$, $\alpha^{(0)} = \alpha^{(m)}$, $\beta^{(0)} = \beta^{(m)}$, $l = l + 1$;

Output: $\hat{\mathbf{X}} = \mathbf{U}$, $\hat{\mathcal{G}} = \mathcal{G}^{(l)}$, $\hat{\mathcal{M}} = \mathcal{M}^{(l)}$;

二、贝叶斯推断

由4.3.1小节对 SMV 实信号模型的分析, 有

$$p(\mathbf{X}|\alpha, \beta, \mathbf{Y}; \mathcal{G}, \mathcal{M}) = \prod_{t=1}^T \mathcal{N}(\mathbf{x}_t | \mu_t, \Sigma) \quad (4-23)$$

其中, 均值 μ_t 和协方差矩阵 Σ 为

$$\mu_t = \beta \Sigma \Phi^T \mathbf{y}_t, \quad \Sigma = (\beta \Phi^T \Phi + \mathbf{A}^{-1})^{-1} \quad (4-24)$$

因此, 稀疏矩阵 $\mathbf{X}$ 的 MAP 估计为

$$\hat{\mathbf{X}} = \arg \max_{\mathbf{X}} p(\mathbf{X}|\alpha, \beta, \mathbf{Y}; \mathcal{G}, \mathcal{M}) = [\mu_1, \mu_2, \dots, \mu_T] = \mathbf{U} \quad (4-25)$$

隐变量 α , β 和字典参数 $\mathcal{G}, \mathcal{M}$ 的估计为

$$\hat{\alpha} = \arg \max_{\alpha} \mathbb{E}\{\ln p(\mathbf{X}|\alpha) + \ln p(\alpha)\} \quad (4-26a)$$

$$\hat{\beta} = \arg \max_{\beta} \mathbb{E}\{\ln p(\mathbf{Y}|\mathbf{X}, \beta; \mathcal{G}, \mathcal{M}) + \ln p(\beta)\} \quad (4-26b)$$

$$\{\hat{\mathcal{G}}, \hat{\mathcal{M}}\} = \arg \max_{\mathcal{G}, \mathcal{M}} \mathbb{E}\{\ln p(\mathbf{Y}|\mathbf{X}, \beta; \mathcal{G}, \mathcal{M})\} \quad (4-26c)$$

求解(4-26), 得

$$\hat{\alpha}_j = \frac{\sqrt{T^2 + 4\lambda \sum_{t=1}^T (\Sigma_{jj} + (\mu_t)_j^2)} - T}{2\lambda}, \quad j = 1, \dots, N \quad (4-27a)$$

$$\hat{\beta} = \frac{2a - 2 + MT}{2b + \|\mathbf{Y} - \Phi\mathbf{U}\|_F^2 + T\beta^{-1} \sum_{j=1}^N (1 - \alpha_j^{-1} \Sigma_{jj})} \quad (4-27b)$$

$$\{\hat{\mathcal{G}}, \hat{\mathcal{M}}\} = \arg \min_{\mathcal{G}, \mathcal{M}} \{\|\mathbf{Y} - \Phi\mathbf{U}\|_F^2 + T \text{tr}(\Phi \Sigma \Phi^T)\} \quad (4-27c)$$

三、算法总结

基于上述贝叶斯推断结果，算法4.2总结了 MMV 实信号模型下的参数化稀疏贝叶斯字典学习算法 PSBDL-ReMMV。

四、算法分析

一般而言，有 $K_0 \leq M < N$, $T \ll N$ 。所以，PSBDL-ReMMV 算法各主要步骤的计算复杂度为：步骤 (3) 为 $\mathcal{O}(MN)$ ；步骤 (6) 为 $\mathcal{O}(NM^2 + MN^2 + TNM + M^3)$ ；步骤 (7) 为 $\mathcal{O}(TNM)$ ；步骤 (12) 为 $\mathcal{O}(K_0 M^2)$ ；步骤 (13) 为 $\mathcal{O}(K_0 M)$ 。所以 PSBDL-ReMMV 算法的渐进复杂度为 $\mathcal{O}(NM^2)$ 。同样，由 EM 算法的收敛性质可知，PSBDL-ReMMV 算法保证收敛到一个局部平稳点。

4.4 复信号模型的参数化稀疏贝叶斯字典学习算法

本小节将4.3小节中针对实信号观测模型的相应算法扩展到复信号观测模型中。

4.4.1 SMV 复信号模型下的参数化稀疏贝叶斯字典学习算法

一、层级概率模型

对 SMV 复信号模型 $\mathbf{y} = \Phi(\mathcal{G}, \mathcal{M})\mathbf{x} + \mathbf{n}$, $\mathbf{y}, \mathbf{n} \in \mathbb{C}^M$, $\Phi \in \mathbb{C}^{M \times N}$, $\mathbf{x} \in \mathbb{C}^N$, 图4-1表示的概率模型为

$$\mathbf{y} | \beta; \mathcal{G}, \mathcal{M} \sim \mathcal{CN}(\mathbf{y} | \Phi\mathbf{x}, \beta^{-1} \mathbf{I}_M), \beta \sim \text{Gamma}(\beta | a, b) \quad (4-28a)$$

$$\mathbf{x} | \alpha \sim \mathcal{CN}(\mathbf{x} | 0, \mathbf{A}), \alpha \sim \prod_{j=1}^N \text{Gamma}\left(\alpha_j \left| 1, \frac{\lambda}{2} \right.\right) \quad (4-28b)$$

二、贝叶斯推断

由4.3.1小节对 SMV 实信号观测模型的分析，有

$$p(\mathbf{x} | \alpha, \beta, \mathbf{y}; \mathcal{G}, \mathcal{M}) = \mathcal{CN}(\mathbf{x} | \boldsymbol{\mu}, \boldsymbol{\Sigma}) \quad (4-29)$$

其中，均值 $\boldsymbol{\mu}$ 和协方差矩阵 $\boldsymbol{\Sigma}$ 为

$$\boldsymbol{\mu} = \beta \boldsymbol{\Sigma} \Phi^H \mathbf{y}, \quad \boldsymbol{\Sigma} = (\beta \Phi^H \Phi + \mathbf{A}^{-1})^{-1} \quad (4-30)$$

因此，稀疏向量 $\mathbf{x}$ 的 MAP 估计为

$$\hat{\mathbf{x}} = \arg \max_{\mathbf{x}} p(\mathbf{x} | \alpha, \beta, \mathbf{y}; \mathcal{G}, \mathcal{M}) = \boldsymbol{\mu} \quad (4-31)$$

隐变量 α , β 和字典参数 $\mathcal{G}, \mathcal{M}$ 的估计为

$$\hat{\alpha} = \arg \max_{\alpha} \mathbb{E}\{\ln p(\mathbf{x} | \alpha) + \ln p(\alpha)\} \quad (4-32a)$$

Algorithm 4.3: SMV 复信号模型下的参数化稀疏贝叶斯字典学习算法 (PSBDL-ComSMV)

Input: 观测数据 $\mathbf{y}$;

- 1 初始化字典参数 $\mathcal{G}^{(0)}$, $\mathcal{M}^{(0)}$, 隐变量 $\alpha^{(0)}, \beta^{(0)}$, $l = 0$;
- 2 **while** 不满足终止条件 **do**
- 3 根据 $\mathcal{G}^{(l)}$, $\mathcal{M}^{(l)}$ 计算 $\Phi^{(l)}$, 令 $m = 0$;
- 4 // 稀疏信号恢复
- 5 **while** 不满足稀疏恢复终止条件 **do**
- 6 由 $\alpha^{(m)}$, $\beta^{(m)}$, Φ 根据式(4-30)计算 μ , Σ ;
- 7 根据式(4-33a)和(4-33b)更新 $\alpha^{(m+1)}$, $\beta^{(m+1)}$;
- 8 $m = m + 1$;
- 9 // 字典学习
- 10 $\mathcal{G}^{(0)} = \mathcal{G}^{(l)}$, $\mathcal{M}^{(0)} = \mathcal{M}^{(l)}$, $n = 0$;
- 11 **while** 不满足字典学习终止条件 **do**
- 12 求解问题(4-33c), 获得 $\mathcal{G}^{(n+1)}, \mathcal{M}^{(n+1)}$;
- 13 根据 $\mathcal{G}^{(n+1)}, \mathcal{M}^{(n+1)}$ 更新 $\Phi^{(l)}$;
- 14 $n = n + 1$;
- 15 $\mathcal{G}^{(l+1)} = \mathcal{G}^{(n)}$, $\mathcal{M}^{(l+1)} = \mathcal{M}^{(n)}$, $\alpha^{(0)} = \alpha^{(m)}$, $\beta^{(0)} = \beta^{(m)}$, $l = l + 1$;

Output: $\hat{\mathbf{x}} = \mu$, $\hat{\mathcal{G}} = \mathcal{G}^{(l)}$, $\hat{\mathcal{M}} = \mathcal{M}^{(l)}$;

$$\hat{\beta} = \arg \max_{\beta} \mathbb{E} \{ \ln p(\mathbf{y} | \mathbf{x}, \beta; \mathcal{G}, \mathcal{M}) + \ln p(\beta) \} \quad (4-32b)$$

$$\{\hat{\mathcal{G}}, \hat{\mathcal{M}}\} = \arg \max_{\mathcal{G}, \mathcal{M}} \mathbb{E} \{ \ln p(\mathbf{y} | \mathbf{x}, \beta; \mathcal{G}, \mathcal{M}) \} \quad (4-32c)$$

求解(4-32), 得

$$\hat{\alpha}_j = \frac{\sqrt{1 + 4\lambda(\Sigma_{jj} + |\mu_j|^2)} - 1}{2\lambda}, \quad j = 1, \dots, N \quad (4-33a)$$

$$\hat{\beta} = \frac{a - 1 + M}{b + \|\mathbf{y} - \Phi\mu\|_2^2 + \beta^{-1} \sum_{j=1}^N (1 - \alpha_j^{-1} \Sigma_{jj})} \quad (4-33b)$$

$$\{\hat{\mathcal{G}}, \hat{\mathcal{M}}\} = \arg \min_{\mathcal{G}, \mathcal{M}} \{ \|\mathbf{y} - \Phi\mu\|_F^2 + \text{tr}(\Phi \Sigma \Phi^H) \} \quad (4-33c)$$

三、算法总结

基于上述贝叶斯推断结果, SMV 复信号模型下参数化字典学习和稀疏恢复的联合优化算法 PSBDL-ComSMV 如算法4.3所示。在步骤(6)中, 若 $N > M$, 则令 $\Xi = \beta^{-1} \mathbf{I}_M + \Phi \mathbf{A} \Phi^H$, 通过 Woodbury 矩阵恒等式

$$\Sigma = \mathbf{A} - \mathbf{A} \Phi^H \Xi^{-1} \Phi \mathbf{A} \quad (4-34)$$

将计算 Σ 所示的矩阵求逆的复杂度从原来的 $\mathcal{O}(N^3)$ 降至 $\mathcal{O}(M^3)$ 。

由4.3.1小节的分析可知, 当 $M < N$ 时, PSBDL-ComSMV 算法的复杂度为 $\mathcal{O}(MN^2)$, 算法保证收敛到一个平稳点。

4.4.2 MMV 复信号模型下的参数化稀疏贝叶斯字典学习算法

一、层级概率模型

复信号情况下，对 MMV 观测模型 $\mathbf{Y} = \Phi(\mathcal{G}, \mathcal{M})\mathbf{X} + \mathbf{E}$, $\mathbf{Y}, \mathbf{E} \in \mathbb{C}^{M \times T}$, $\Phi \in \mathbb{C}^{M \times N}$, $\mathbf{X} \in \mathbb{C}^{N \times T}$, 图4-2表示的概率模型为

$$\mathbf{Y} | \beta; \mathcal{G}, \mathcal{M} \sim \prod_{t=1}^T \mathcal{CN}(\mathbf{y}_t | \Phi \mathbf{x}_t, \beta^{-1} \mathbf{I}_M), \quad \beta \sim \text{Gamma}(\beta | a, b) \quad (4-35a)$$

$$\mathbf{X} | \alpha \sim \prod_{t=1}^T \mathcal{CN}(\mathbf{x}_t | 0, \mathbf{A}), \quad \alpha \sim \prod_{j=1}^N \text{Gamma}\left(\alpha_j \left| 1, \frac{\lambda}{2} \right.\right) \quad (4-35b)$$

二、贝叶斯推断

由4.3.2小节对 MMV 实信号模型的分析，有

$$p(\mathbf{X} | \alpha, \beta, \mathbf{Y}; \mathcal{G}, \mathcal{M}) = \prod_{t=1}^T \mathcal{CN}(\mathbf{x}_t | \boldsymbol{\mu}_t, \Sigma) \quad (4-36)$$

其中，均值 $\boldsymbol{\mu}_t$ 和协方差矩阵 Σ 为

$$\boldsymbol{\mu}_t = \beta \Sigma \Phi^H \mathbf{y}_t, \quad \Sigma = (\beta \Phi^H \Phi + \mathbf{A}^{-1})^{-1} \quad (4-37)$$

因此，稀疏矩阵 $\mathbf{X}$ 的 MAP 估计为

$$\hat{\mathbf{X}} = \arg \max_{\mathbf{X}} p(\mathbf{X} | \alpha, \beta, \mathbf{Y}; \mathcal{G}, \mathcal{M}) = [\boldsymbol{\mu}_1, \boldsymbol{\mu}_2, \dots, \boldsymbol{\mu}_T] = \mathbf{U} \quad (4-38)$$

隐变量 α , β 和字典参数 $\mathcal{G}, \mathcal{M}$ 的估计为

$$\hat{\alpha} = \arg \max_{\alpha} \mathbb{E}\{\ln p(\mathbf{X} | \alpha) + \ln p(\alpha)\} \quad (4-39a)$$

$$\hat{\beta} = \arg \max_{\beta} \mathbb{E}\{\ln p(\mathbf{Y} | \mathbf{X}, \beta; \mathcal{G}, \mathcal{M}) + \ln p(\beta)\} \quad (4-39b)$$

$$\{\hat{\mathcal{G}}, \hat{\mathcal{M}}\} = \arg \max_{\mathcal{G}, \mathcal{M}} \mathbb{E}\{\ln p(\mathbf{Y} | \mathbf{X}, \beta; \mathcal{G}, \mathcal{M})\} \quad (4-39c)$$

求解(4-39)，得

$$\hat{\alpha}_j = \frac{\sqrt{T^2 + 4\lambda \sum_{t=1}^T (\Sigma_{jj} + |(\boldsymbol{\mu}_t)_j|^2)} - T}{2\lambda}, \quad j = 1, \dots, N \quad (4-40a)$$

$$\hat{\beta} = \frac{a - 1 + MT}{b + \|\mathbf{Y} - \Phi \mathbf{U}\|_F^2 + T \beta^{-1} \sum_{j=1}^N (1 - \alpha_j^{-1} \Sigma_{jj})} \quad (4-40b)$$

$$\{\hat{\mathcal{G}}, \hat{\mathcal{M}}\} = \arg \min_{\mathcal{G}, \mathcal{M}} \{\|\mathbf{Y} - \Phi \mathbf{U}\|_F^2 + T \text{tr}(\Phi \Sigma \Phi^H)\} \quad (4-40c)$$

三、算法总结

基于上述贝叶斯推断结果，算法4.4所示总结了 MMV 复信号模型下参数化稀疏贝叶斯字典学习算法 PSBDL-ComMMV。由4.3.2小节的分析可知，当 $M < N, T \ll N$ 时，PSBDL-ComMMV 算法的复杂度为 $\mathcal{O}(MN^2)$ ，算法保证收敛到一个平稳点。

Algorithm 4.4: MMV 复信号模型下的参数化稀疏贝叶斯字典学习算法 (PSBDL-ComMMV)

Input: 观测数据 $\mathbf{Y}$;

- 1 初始化字典参数 $\mathcal{G}^{(0)}$, $\mathcal{M}^{(0)}$, 隐变量 $\alpha^{(0)}, \beta^{(0)}$, $l = 0$;
- 2 **while** 不满足终止条件 **do**
- 3 根据 $\mathcal{G}^{(l)}$, $\mathcal{M}^{(l)}$ 计算 $\Phi^{(l)}$, 令 $m = 0$;
- 4 // 稀疏信号恢复
- 5 **while** 不满足稀疏恢复终止条件 **do**
- 6 由 $\alpha^{(m)}$, $\beta^{(m)}$, Φ 根据式(4-37)计算 $\mathbf{U}$, Σ ;
- 7 根据式(4-40a)和(4-40b)更新 $\alpha^{(m+1)}$, $\beta^{(m+1)}$;
- 8 $m = m + 1$;
- 9 // 字典学习
- 10 $\mathcal{G}^{(0)} = \mathcal{G}^{(l)}$, $\mathcal{M}^{(0)} = \mathcal{M}^{(l)}$, $n = 0$;
- 11 **while** 不满足字典学习终止条件 **do**
- 12 求解问题(4-40c), 获得 $\mathcal{G}^{(n+1)}, \mathcal{M}^{(n+1)}$;
- 13 根据 $\mathcal{G}^{(n+1)}$, $\mathcal{M}^{(n+1)}$ 更新 $\Phi^{(l)}$;
- 14 $n = n + 1$;
- 15 $\mathcal{G}^{(l+1)} = \mathcal{G}^{(n)}$, $\mathcal{M}^{(l+1)} = \mathcal{M}^{(n)}$, $\alpha^{(0)} = \alpha^{(m)}$, $\beta^{(0)} = \beta^{(m)}$, $l = l + 1$;

Output: $\hat{\mathbf{X}} = \mathbf{U}$, $\hat{\mathcal{G}} = \mathcal{G}^{(l)}$, $\hat{\mathcal{M}} = \mathcal{M}^{(l)}$;

表 4-2 SMV 模型和 MMV 模型下实信号、复信号参数化字典学习算法的对比

	SMV 模型		MMV 模型	
实信号模型	$\mathbf{y}, \mathbf{x}$	$\mathbf{y} \sim \mathcal{N}(\mathbf{y} \Phi \mathbf{x}, \beta^{-1} \mathbf{I}_M)$ $\mathbf{x} \sim \mathcal{N}(\mathbf{x} 0, \mathbf{A})$	$\mathbf{Y}, \mathbf{X}$	$\mathbf{Y} \sim \prod_{t=1}^T \mathcal{N}(\mathbf{y}_t \Phi \mathbf{x}_t, \beta^{-1} \mathbf{I}_M)$ $\mathbf{X} \sim \prod_{t=1}^T \mathcal{N}(\mathbf{x}_t 0, \mathbf{A})$
	μ, Σ	$\mu = \beta \Sigma \Phi^T \mathbf{y}$ $\Sigma = (\beta \Phi^T \Phi + \mathbf{A}^{-1})^{-1}$	$\mathbf{U}, \Sigma$	$\mu_t = \beta \Sigma \Phi^T \mathbf{y}_t$ $\Sigma = (\beta \Phi^T \Phi + \mathbf{A}^{-1})^{-1}$
	$\hat{\alpha}$	$\hat{\alpha}_j = \frac{\sqrt{1+4\lambda(\Sigma_{jj} + \mu_j^2)} - 1}{2\lambda}$	$\hat{\alpha}$	$\hat{\alpha}_j = \frac{\sqrt{T^2 + 4\lambda \sum_{t=1}^T (\Sigma_{jj} + (\mu_t)_j^2)} - T}{2\lambda}$
	$\hat{\beta}$	$\frac{2a-2+M}{2b + \ \mathbf{y} - \Phi \mu\ _2^2 + \beta^{-1} \sum_{j=1}^N (1 - \alpha_j^{-1} \Sigma_{jj})}$	$\hat{\beta}$	$\frac{2a-2+MT}{2b + \ \mathbf{Y} - \Phi \mathbf{U}\ _F^2 + T \beta^{-1} \sum_{j=1}^N (1 - \alpha_j^{-1} \Sigma_{jj})}$
	$\hat{\mathcal{G}}, \hat{\mathcal{M}}$	$\min_{\mathcal{G}, \mathcal{M}} \{(\ \mathbf{y} - \Phi \mu\ _2^2 + \text{tr}(\Phi \Sigma \Phi^T))\}$	$\hat{\mathcal{G}}, \hat{\mathcal{M}}$	$\min_{\mathcal{G}, \mathcal{M}} \{\ \mathbf{Y} - \Phi \mathbf{U}\ _F^2 + T \text{tr}(\Phi \Sigma \Phi^T)\}$
复信号模型	$\mathbf{y}, \mathbf{x}$	$\mathbf{y} \sim \mathcal{CN}(\mathbf{y} \Phi \mathbf{x}, \beta^{-1} \mathbf{I}_M)$ $\mathbf{x} \sim \mathcal{CN}(\mathbf{x} 0, \mathbf{A})$	$\mathbf{Y}, \mathbf{X}$	$\mathbf{Y} \sim \prod_{t=1}^T \mathcal{CN}(\mathbf{y}_t \Phi \mathbf{x}_t, \beta^{-1} \mathbf{I}_M)$ $\mathbf{X} \sim \prod_{t=1}^T \mathcal{CN}(\mathbf{x}_t 0, \mathbf{A})$
	μ, Σ	$\mu = \beta \Sigma \Phi^H \mathbf{y}$ $\Sigma = (\beta \Phi^H \Phi + \mathbf{A}^{-1})^{-1}$	$\mathbf{U}, \Sigma$	$\mu_t = \beta \Sigma \Phi^H \mathbf{y}_t$ $\Sigma = (\beta \Phi^H \Phi + \mathbf{A}^{-1})^{-1}$
	$\hat{\alpha}$	$\hat{\alpha}_j = \frac{\sqrt{1+4\lambda(\Sigma_{jj} + \mu_j ^2)} - 1}{2\lambda}$	$\hat{\alpha}$	$\hat{\alpha}_j = \frac{\sqrt{T^2 + 4\lambda \sum_{t=1}^T (\Sigma_{jj} + \mu_t _j^2)} - T}{2\lambda}$
	$\hat{\beta}$	$\frac{a-1+M}{b + \ \mathbf{y} - \Phi \mu\ _2^2 + \beta^{-1} \sum_{j=1}^N (1 - \alpha_j^{-1} \Sigma_{jj})}$	$\hat{\beta}$	$\frac{a-1+MT}{b + \ \mathbf{Y} - \Phi \mathbf{U}\ _F^2 + T \beta^{-1} \sum_{j=1}^N (1 - \alpha_j^{-1} \Sigma_{jj})}$
	$\hat{\mathcal{G}}, \hat{\mathcal{M}}$	$\min_{\mathcal{G}, \mathcal{M}} \{(\ \mathbf{y} - \Phi \mu\ _2^2 + \text{tr}(\Phi \Sigma \Phi^H))\}$	$\hat{\mathcal{G}}, \hat{\mathcal{M}}$	$\min_{\mathcal{G}, \mathcal{M}} \{\ \mathbf{Y} - \Phi \mathbf{U}\ _F^2 + T \text{tr}(\Phi \Sigma \Phi^H)\}$

4.5 算法小结

4.3小节和4.4小节详细推导了 SMV 模型和 MMV 模型下的实信号、复信号参数化字典学习算法，表4-2总结了这些算法在建模和参数更新上的不同。从表4-2可以看出，实信号模型与复信号模型的区别在于对 $\mathbf{y}$ (或 $\mathbf{Y}$) 和 $\mathbf{x}$ (或 $\mathbf{X}$) 的概率建模为实高斯分布还是复高斯分布，由此带来 $\hat{\beta}$ 的分子和分母中存在系数 2 的区别，其他相关公式中存在转置和共轭转置的区别。同时也可以发现，SMV 模型可以视为 MMV 模型当 $T = 1$ 时的一种特例，实信号模型可以视为复信号模型的一种特例。

基于4.3小节和4.4小节的详细推导，很容易得到其他情况下的算法变形，如非均匀噪声情况下的参数化字典学习算法等^[213]。下一章中将针对 MMV 实信号模型提出参数化字典学习的快速算法。结合本章的推导过程，容易得到 SMV 模型和复信号模型下的快速算法，故在下一章中将不再赘述这些内容。所以，虽然4.3小节和4.4小节的推导略有重复，但其对参数化字典学习算法的理解和本文的结构是有帮助的。

4.6 算法性能仿真

4.6.1 网格失配下的 SMV 能量域多源定位

本小节基于 PSBDL-ReSMV 算法研究网格失配情况下的能量域多源定位问题。

一、仿真设置


不妨令单位距离为 1，单位功率为 1。令 $d_0 = 1$ ，感知区域设为 10×10 的方形区域，能量定位节点个数为 M ，辐射源个数 $K = 4$ ，在 d_0 距离处辐射源有效全向辐射功率 $S_k = 20$ dB， $k = 1, 2, 3, 4$ 。考虑第二章2.3.1.1小节所示的 SMV 能量定位模型，通过定位网格 $\mathcal{G}$ 对感知空间进行离散化，得到对应的稀疏表征定位模型为 $\mathbf{y} = \Phi(\mathcal{G})\mathbf{x} + \mathbf{n}$ ，其中， $\mathcal{G}$ 为未知的字典参数，设变换函数为

$$[\Phi]_{ij} = f_i(\mathbf{g}_j) = \begin{cases} 1, & d_{ij} \leq d_0 \\ (\frac{d_{ij}}{d_0})^{-3.3}, & d_{ij} > d_0 \end{cases}, \quad (4-41)$$

$d_{i,j} = \|\mathbf{g}_j - \mathbf{s}_i\|_2$ ，测量噪声为高斯白噪声。网格 $\mathcal{G}$ 初始化为 7×7 的均匀网格。SNR 按式(3.1)定义，评价度量为式(3-12)所定义的平均定位误差距离 (MLED)。

对比算法为 BCS^[204]，VBEM^[98]，BCS-Laplace^[205]。其中，BCS 和 BCS-Laplace 均使用初始网格作为固定网格划分，仅进行稀疏推断，无字典学习能力。二者的区别在于 BCS 使用 Student's t 的层级稀疏先验，而 BCS-Laplace 使用本章所示的 Laplace 层级稀疏先验。VBEM 为基于变分推断的能量域多源定位算法，其采用 Student's t 稀疏先验，并调整均匀矩形网格的所有网格线，所以其具有一定的字典学习能力。


4.7.3小节推导了 SMV 模型下能量域多源定位问题(2-45)的 CRLB，作为理论上估计误差的下界来检验所有算法的性能。取 500 次蒙特卡洛仿真的平均值作为仿真结果。仿真的硬件环境为：Intel Core i7-6700 处理器，主频 3.4GHz，8G 内存；软件环境为：Windows 10 + Matlab R2016a。

图 4-3 网格点集合 $\mathcal{G}^{(l)}$ 的学习过程

二、仿真结果和分析

首先, 令 $\text{SNR} = 30 \text{ dB}$, $M = 70$, 图4-3展示了 PSBDL-ReSMV 算法对字典参数 $\mathcal{G}$ 的学习过程, 图中网格点间的连线表示空间剖分的拓扑结构, 以此凸显网格调整带来的拓扑结构变化。从图4-3(a) 可见, 所有的辐射源均偏离初始的 $\mathcal{G}^{(0)}$, 存在网格失配问题。然而从图4-3(b) 到图4-3(d) 可以看出, 随着 PSBDL-ReSMV 算法的迭代, $\mathcal{G}^{(l)}$ 能够迅速收敛到合适的网格集合 $\mathcal{G}$, 使得所有辐射源位置都能被 $\mathcal{G}$ 中的一些网格点精确逼近。此外, 每次迭代中仅有部分网格点被调整, 这是因为在 PSBDL 算法中, 我们将字典学习问题限制在拥有最大方差 α_j 的少数几个网格点上。

接下来, 分别研究 PSBDL-ReSMV 算法在不同噪声水平和不同定位节点数目下定位性能。图4-4(a) 展示了当 $M = 60$, SNR 从 0 dB 增长到 30 dB 时, 不同算法平均定位误差距离 (MLED) 的变化情况。从图4-4(a) 中可以看出, 在不同信噪比下, PSBDL-ReSMV 算法均远优于对比算法, 并且其误差曲线接近理论上的 CRLB。当曲线趋于收敛时, 所提算法的定位误差距离相比 VBEM、BCS-Laplace、BCS 分别降



(a) 不同噪声水平下的平均定位误差距离

(b) 不同定位节点数目下的平均定位误差距离

图 4-4 不同噪声水平和能量定位节点数目下的定位性能

低了 87%、90%、92%。BCS-Laplace 优于 BCS，这说明 Laplace 先验优于 Student's t 先验。PSBDL-ReSMV 和 VBEM 优于 BCS 和 BCS-Laplace，这说明字典学习能够明显提升基于稀疏表征的多源定位算法性能。PSBDL-ReSMV 优于 VBEM，这是因为 PSBDL-ReSMV 算法采用了更优的 Laplace 先验和更灵活的字典学习方法。

图 4-4(b) 显示了当 SNR = 30 dB，定位节点数目从 15 增长到 65 时，不同算法平均定位误差距离 (MLED) 的变化情况。从图 4-4(b) 可见，随着定位节点个数的增加，所有算法的平均定位误差迅速下降，这是因为越多的测量信息越多，估计的不确定性就越小。和其他算法相比，PSBDL-ReSMV 算法在同样的定位节点个数下展现了更低的定位误差距离，达到同样的定位误差距离，需要更少定位节点，且随着定位节点数目的增加，PSBDL-ReSMV 算法的定位误差距离接近 CRLB。

4.6.2 网格失配下的 MMV DOA 估计

本小节基于 PSBDL-ComMMV 算法研究网格失配情况下的 DOA 估计问题。

一、仿真设置

考虑第二章 2.3.1.2 小节所述的均匀线阵 DOA 估计模型。设 $M=8$ ， $d=\lambda/2$ ，快拍数为 T ，真实 DOA 个数为 K 。评价度量为均方根误差 (Root-Mean-Square Error, RMSE)，定义为

$$\text{RMSE} = \sqrt{\frac{1}{K} \sum_{k=1}^K (\theta_k - \hat{\theta}_k)^2} \quad (4-42)$$

其中， $\hat{\theta}_k$ 为对第 k 个真实 DOA θ_k 的估计。这里，计算 RMSE 同样涉及 $\hat{\theta}_k$ 与真实 θ_k 的数据关联问题，本文采用第三章 3.5.2 小节的数据关联方法计算 RMSE。




图 4-5 不同信噪比和快拍数下的归一化空间谱

对比算法为 MUSIC^[107]、TLS-ESPRIT^[110]、OGSBI^[122]。其中，MUSIC 为利用噪声子空间进行空间谱估计的经典算法，TLS-ESPRIT 基于阵列平移不变性和信号子空间旋转不变性通过特征值分解直接求解真实 DOA，OGSBI 为近年提出的基于稀疏表征的 off-grid DOA 估计算法。

取 500 次蒙特卡洛仿真的平均值作为仿真结果。仿真的硬件环境为：Intel Core i7-69750H 处理器，主频 3.5GHz，16G 内存；软件环境为：Windows 10 + Matlab R2019b。

二、仿真结果和分析

首先，令 4 个真实 DOA 为 -53.4° 、 -18.8° 、 30.6° 、 74.3° ，DOA 网格以 1° 为间隔，从 -90° 到 90° 。图 4-5 显示了各算法在不同信噪比和不同快拍数下的归一化空间谱。从图 4-5 可以看出和对比算法相比，PSBDL-ComMMV 算法在低信噪比、低快拍数下具有更清晰更尖锐的谱峰结构，在高信噪比、大快拍数情况下具有类似的空间谱，这验证了所提算法的有效性。其中，MUSIC 算法和 TLS-ESPRIT 算法因为依赖于接收信号的自相关矩阵，所以，其对快拍数较为敏感，当快拍数较低时，其估计的自相关




图 4-6 不同信噪比、快拍数、网格间距下的 DOA 估计性能

矩阵存在较大误差，进而导致空间谱谱峰失真，偏离真实 DOA。

其次，令 3 个真实 DOA 分别随机均匀分布在 $[-30^\circ, -32^\circ]$, $[-2^\circ, 2^\circ]$, $[58^\circ, 62^\circ]$ 三个区间中。图 4-6 展示了不同信噪比、快拍数、网格间距下的各算法的 DOA 估计性能。从图 4-6 可以看出，和对比算法相比，提出的 PSBDL-ComMMV 算法在不同的信噪比、快拍数、网格间距下均具有最佳的性能，验证了所提算法的优越性。图 4-6(c) 显示，在合适的网格间距范围内，PSBDL-ComMMV 算法的 RMSE 与网格间距无关，这是因为其能够通过字典学习自适应地调整 DOA 网格。而 TLS-ESPRIT 算法因为无需 DOA 网格，所以其性能也与网格间距无关。

4.6.3 不确定路损指数下的 MMV 能量域多源定位

本小节基于 PSBDL-ReMMV 算法研究网格不匹配和路损指数不确定情况下的能量域多源定位问题。

一、仿真设置

设单位距离为 1，单位功率为 1。令 $d_0 = 1$ ，设在 25×25 的方形感知区域中随机分布着 $K = 4$ 个辐射源和 M 个定位节点。在 d_0 距离处辐射源有效全向辐射功率 $S_k = 20$ dB, $k = 1, 2, 3, 4$ 。考虑未知路损指数 γ 情况下基于稀疏表征的 MMV 能量域多源定位模型 $\mathbf{Y} = \Phi(\mathcal{G}, \gamma)\mathbf{X} + \mathbf{E}$ ，其中， $\mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_T]$ ， $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T]$ ， $\mathbf{E} = [\mathbf{n}_1, \mathbf{n}_2, \dots, \mathbf{n}_T]$ ， $\gamma \in [2, 4]$ 。对每一快拍，均有 4.6.1 小节的 SMV 测量模型 $\mathbf{y}_t = \Phi(\mathcal{G}, \gamma)\mathbf{x}_t + \mathbf{n}_t$ 成立。这里，未知字典参数为网格集合 $\mathcal{G}$ 和路损指数 γ ，变换函数为

$$[\Phi(\mathcal{G}, \gamma)]_{ij} = f_i(\mathbf{g}_j) = \begin{cases} 1, & d_{ij} \leq d_0 \\ (\frac{d_{ij}}{d_0})^{-\gamma}, & d_{ij} > d_0 \end{cases}, \quad (4-43)$$

$d_{i,j} = \|\mathbf{g}_j - \mathbf{s}_i\|_2$ ， $\mathbf{n}_t \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$ 。对于 MMV 测量模型，其信噪比定义为

$$\text{SNR} = \frac{\sum_{k=1}^K S_k}{K\sigma^2} \quad (4-44)$$

上述 SNR 是距离辐射源 d_0 处的平均信噪比。实际上，因为信号能量随距离迅速衰减，各能量定位节点处的信噪比要远小于上述定义。

对比算法为 M-SBL^[120]，M-GEMTL^[212]。其中，M-SBL 为固定字典下的 MMV 稀疏恢复算法，不具备对网格 $\mathcal{G}$ 和路损指数 γ 的推断能力。M-GEMTL 是 MMV 情况下对网格集合 $\mathcal{G}$ 进行联合推断的稀疏恢复算法，其不能推断路损指数 γ 。各算法求解出 $\mathbf{X}$ 后，按 $P_j = \frac{1}{T} \sum_{t=1}^T [\mathbf{x}_t]_j$ 计算第 j 个网格点上的辐射功率，并取功率最大的前 K 个网格点位置作为 K 个辐射源位置的估计。

4.7.4 小节推导了不确定传播参数下能量域多源定位的 CRLB，作为理论上的估计误差下界来检验所有算法的性能。取 1000 次蒙特卡洛仿真的平均值作为仿真结果。对所有算法， γ 被初始化为 2，网格 $\mathcal{G}$ 被初始化成 $\sqrt{N} \times \sqrt{N}$ 的均匀矩形网格，这里， $\sqrt{N}$ 为网格密度。仿真的硬件环境为：Intel Core i7-9750H 处理器，主频 3.5GHz，16G 内存；软件环境为：Windows 10 + Matlab R2016a。

二、仿真结果和分析

表 4-3 展示了不同网格密度、信噪比、快拍数和定位节点数目下路损指数 γ 估计的 CRLB 和 PSBDL-ReMMV 对 γ 的均方根估计误差。可以看出，提出的 PSBDL-ReMMV 能够对路损指数作出有效估计，且估计的均方根误差逼近理论上的 CRLB。从表 4-3 中可知，随着信噪比、快拍数、定位节点数目的增加，CRLB 和 PSBDL-ReMMV 算法的 RMSE 均降低，这是因为测量信息越多，估计的不确定性越低。CRLB 与网格划分

表 4-3 不同网格密度、信噪比、快拍数、定位节点数目下路损指数 γ 的均方根估计误差

仿真设置	SNR = 20 dB, $M = 50, T = 2$					$\sqrt{N} = 15, M = 50, T = 2$				
	网格密度 $\sqrt{N}$					信噪比 SNR(dB)				
	5	10	15	20	25	10	15	20	25	30
CRLB	0.151	0.143	0.150	0.155	0.152	0.441	0.278	0.154	0.088	0.048
PSBDL- -ReMMV	0.442	0.390	0.333	0.313	0.310	0.615	0.429	0.344	0.206	0.182
仿真设置	SNR = 20 dB, $M = 50, \sqrt{N} = 15$					SNR = 20 dB, $\sqrt{N} = 15, T = 2$				
	快拍数 T					定位节点数目 M				
	1	3	5	7	9	30	40	50	60	70
CRLB	0.243	0.124	0.105	0.073	0.061	0.399	0.268	0.156	0.098	0.028
PSBDL- -ReMMV	0.427	0.325	0.319	0.304	0.293	0.521	0.410	0.303	0.220	0.133

无关, 所以表4-3中 CRLB 不随网格密度增长而明显变化, 但更密的网格划分能够有效提高 PSBDL-ReMMV 算法捕获偏离初始网格点的辐射源的能力, 进而降低其对路损指数的估计误差。当网格密度达到一定程度时, PSBDL-ReMMV 算法已经能够有效捕获偏离初始网格点的辐射源, 所以再提高网格密度对其估计性能的增益不明显。

图4-7展示了不同网格密度、信噪比、快拍数、定位节点数下各算法的均方根定位误差曲线和 PSBDL-ReMMV 均方根定位误差的箱线图。可以看出, PSBDL-ReMMV 算法显示出最优的定位性能, 其定位的均方根误差逼近理论上的 CRLB。

具体地, 图4-7(a)中, 所有算法的 RMSE 都随网格密度的增加而降低, 这是因为网格密度越高, 辐射源偏离初始网格点的距离越小, 各算法捕获这些辐射源的可能性就越大, 从而在一定程度上缓解了由网格失配带来的基不匹配问题, 获得更高的定位精度。在此基础上, M-GEMTL 因为能优化网格 $\mathcal{G}$, 从而具有比 M-SBL 更低的定位误差, 而提出的 PSBDL-ReMMV 算法因能进一步有效学习路损指数 γ , 从而具有最低的定位误差, 且接近理论上的 CRLB。图4-7(a)表明, 所提算法能够有效联合优化网格参数和路损指数 γ , 从而能够在同样的初始网格密度下展示出更好的定位性能。

图4-7(b)中, 因为同样的原因, PSBDL-ReMMV 算法显示出最低的定位 RMSE。当 SNR > 20 dB 时, PSBDL-ReMMV 算法的箱线图的中位数更接近第一个四分位数, 并且 RMSE 的均值更接近第三四分位数, 这说明 PSBDL-ReMMV 的均方根定位误差是左偏的, 即超过一半的蒙特卡洛仿真中 RMSE 要低于 RMSE 的均值。图4-7(b)表明, 提出的 PSBDL-ReMMV 算法通过字典参数学习和稀疏恢复的联合优化, 极大地提高基于稀疏表征的多源定位算法的定位精度和噪声鲁棒性。

图4-7(c), 所提出 PSBD-ReMMV 算法可以有效地利用更多快拍带来的信息增益, 并且在不同快拍数下均表现出最佳的定位性能, 这表明了稀疏恢复过程中联合学习字典参数 $\mathcal{G}$ 、 γ 的重要性。图4-7(d)中, 提出的 PSBDL-ReMMV 算法在相同的定位节点数量下显示出更高的定位精度, 在相同的定位误差下需要更少的定位节点。通过

对比 M-SBL, M-GEMTL 和 PSBDL-ReMMV 可以发现, 不管学习字典参数与否, 更多的定位节点都将带来定位进度的显著提升, 在此基础上, 对字典参数更全面的学习推断, 将带来更进一步的性能提升。图4-7(c)和图4-7(d)的表明, 提出的 PSBDL-ReMMV 算法能够有效地利用更多快拍数和更多定位节点带来的信息增益, 并通过参数化字典学习和稀疏恢复的联合优化, 进一步提升定位精度。





(a) $\text{SNR} = 20 \text{ dB}, M = 50, T = 2$ (b) $\sqrt{N} = 15, M = 50, T = 2$ (c) $\text{SNR} = 20 \text{ dB}, M = 50, \sqrt{N} = 15$ (d) $\text{SNR} = 20 \text{ dB}, T = 2, \sqrt{N} = 15$

图 4-7 不同网格密度、信噪比、快拍数、定位节点数目下的均方根定位误差

4.7 证明和推导

4.7.1 定理4.1的证明

证明 (定理4.1的证明): 借助积分恒等式

$$I(u, v) := \int_0^\infty \exp(-uy^2 - \frac{v}{y^2}) dy = \frac{\sqrt{\pi}}{2\sqrt{u}} e^{-2\sqrt{uv}}, \quad (4-45)$$

有

$$\begin{aligned} p(x) &= \int p(x|\alpha) p(\alpha) d\alpha \\ &= \int_0^\infty \frac{1}{\sqrt{2\pi\alpha}} \exp\left(-\frac{x^2}{2\alpha}\right) \frac{1}{2\lambda^2} \exp\left(-\frac{1}{2\lambda^2}\alpha\right) d\alpha \\ &= \int_0^\infty \frac{\sqrt{2}}{\sqrt{\pi}} \exp\left(-\frac{x^2}{2\alpha}\right) \frac{1}{2\lambda^2} \exp\left(-\frac{1}{2\lambda^2}\alpha\right) d\sqrt{\alpha} \\ &\stackrel{I(u,v)}{=} \frac{1}{2\lambda} \exp\left(-\frac{|x|}{\lambda}\right) \end{aligned}$$

即 $p(x) = \text{Laplace}(x|0, \lambda)$ 。 □

4.7.2 式(4-15)的推导

一、式(4-15a)的推导

令目标函数为 $Q(\alpha) = \mathbb{E} \{\ln p(\mathbf{x}|\alpha) + \ln p(\alpha)\}$, 有

$$\begin{aligned} Q(\alpha) &= \mathbb{E} \left\{ -\frac{1}{2} (\ln \det(\mathbf{A}) + \mathbf{x}^T \mathbf{A}^{-1} \mathbf{x}) + \sum_{j=1}^N \left(\ln \lambda - \frac{\lambda}{2} \alpha_j \right) \right\} + \text{const} \\ &= -\frac{1}{2} \left\{ \sum_{j=1}^N \ln \alpha_j + \sum_{j=1}^N \alpha_j^{-1} (\mu_j^2 + \Sigma_{jj}) \right\} + \sum_{j=1}^N \left(\ln \lambda - \frac{\lambda}{2} \alpha_j \right) + \text{const} \quad (4-46) \end{aligned}$$

其中, const 为与 α 无关的项。求解驻点方程 $\partial Q(\alpha)/\partial \alpha_j = 0$, 得

$$\alpha_j = \frac{\sqrt{1 + 4\lambda(\Sigma_{jj} + \mu_j^2)} - 1}{2\lambda} \quad (4-47)$$

二、式(4-15b)的推导

令目标函数为 $Q(\beta) = \mathbb{E} \{\ln p(\mathbf{y}|\mathbf{x}, \beta; \mathcal{G}, \mathcal{M}) + \ln p(\beta)\}$, 有

$$\begin{aligned} Q(\beta) &= \mathbb{E} \left\{ \frac{1}{2} (\ln \det(\beta \mathbf{I}_M) - (\mathbf{y} - \Phi \mathbf{x})^T \beta \mathbf{I}_M (\mathbf{y} - \Phi \mathbf{x})) + (a-1) \ln \beta - b\beta \right\} + \text{const} \\ &= \frac{1}{2} (M \ln \beta - \beta \mathbb{E} \{\|\mathbf{y} - \Phi \mathbf{x}\|_2^2\}) + (a-1) \ln \beta - b\beta + \text{const} \\ &= \left(a-1 + \frac{M}{2} \right) \ln \beta - \frac{\beta}{2} \mathbb{E} \{\|\mathbf{y} - \Phi \mathbf{x}\|_2^2\} - b\beta + \text{const} \quad (4-48) \end{aligned}$$

其中, const 为与 β 无关的项。求解驻点方程 $dQ(\beta)/d\beta = 0$, 有

$$\beta = \frac{2a - 2 + M}{2b + \mathbb{E} \{\|\mathbf{y} - \Phi \mathbf{y}\|_2^2\}} \quad (4-49)$$

因为 $\mathbf{y} - \Phi \mathbf{x} \sim \mathcal{N}(\mathbf{y} - \Phi \boldsymbol{\mu}, \Phi \Sigma \Phi^T)$, 由式(2-25)有

$$\begin{aligned} & \mathbb{E} \{\|\mathbf{y} - \Phi \mathbf{y}\|_2^2\} \\ &= \|\mathbf{y} - \Phi \boldsymbol{\mu}\|_2^2 + \text{tr}(\Phi \Sigma \Phi^T) = \|\mathbf{y} - \Phi \boldsymbol{\mu}\|_2^2 + \text{tr}(\Sigma \Phi^T \Phi) \\ &= \|\mathbf{y} - \Phi \boldsymbol{\mu}\|_2^2 + \text{tr}(\Sigma (\Sigma^{-1} - \mathbf{A}^{-1})) = \|\mathbf{y} - \Phi \boldsymbol{\mu}\|_2^2 + \beta^{-1} \sum_{j=1}^N (1 - \alpha_j^{-1} \Sigma_{jj}) \end{aligned} \quad (4-50)$$

三、式(4-15c)的推导

令目标函数为 $Q(\mathcal{G}, \mathcal{M}) = \mathbb{E} \{\ln p(\mathbf{y}|\mathbf{x}, \beta; \mathcal{G}, \mathcal{M})\}$, 由式(2-25)有

$$Q(\mathcal{G}, \mathcal{M}) = \mathbb{E} \left\{ (\mathbf{y} - \Phi \mathbf{x})^T (\mathbf{y} - \Phi \mathbf{x}) \right\} = (\mathbf{y} - \Phi \boldsymbol{\mu})^T (\mathbf{y} - \Phi \boldsymbol{\mu}) + \text{tr}(\Phi \Sigma \Phi^T) \quad (4-51)$$

4.7.3 SMV 模型下能量域多源定位的 CRLB 推导

设对于式(2-44)所示 SMV 能量域多源定位模型 $\mathbf{y} = \Psi(\mathcal{T})\mathbf{w} + \mathbf{n}$, 有 $p(\mathbf{y}) = \mathcal{N}(\Psi(\mathcal{T})\mathbf{w}, \sigma^2 \mathbf{I})$ 。在研究的多源定位问题中, 未知参数为噪声方差 σ^2 , 辐射源功率 $\mathbf{w} = [S_1, S_2, \dots, S_K]^T$ 和辐射源位置 $\mathcal{T} = [\boldsymbol{\varrho}_1, \boldsymbol{\varrho}_2, \dots, \boldsymbol{\varrho}_K]$, 其中 $\boldsymbol{\varrho}_k = (u_k^t, v_k^t)$ 。令 $\boldsymbol{\vartheta} = [u_1^t, v_1^t, S_1, u_2^t, v_2^t, S_2, \dots, u_K^t, v_K^t, S_K, \sigma^2]^T \in \mathbb{R}^{3K+1}$ 表示未知参数向量, 则其 Fisher 信息矩阵为

$$\mathbf{J}(\boldsymbol{\vartheta}) = \mathbb{E} \left\{ -\Delta_{\boldsymbol{\vartheta}}^{\boldsymbol{\vartheta}} \ln p(\mathbf{y}; \boldsymbol{\vartheta}) \right\} \quad (4-52)$$

令 $\tilde{\boldsymbol{\mu}} = \Psi(\mathcal{T})\mathbf{w}$, $\mathbf{C} = \sigma^2 \mathbf{I}$ 。由文献^[183]第二章的推导有

$$[\mathbf{J}(\boldsymbol{\vartheta})]_{i,j} = \frac{\partial \tilde{\boldsymbol{\mu}}^T}{\partial \vartheta_i} \mathbf{C}^{-1} \frac{\partial \tilde{\boldsymbol{\mu}}}{\partial \vartheta_j} + \frac{1}{2} \text{tr} \left(\mathbf{C}^{-1} \frac{\partial \mathbf{C}}{\partial \vartheta_i} \mathbf{C}^{-1} \frac{\partial \mathbf{C}}{\partial \vartheta_j} \right) \quad (4-53)$$

其中,

$$\frac{\partial \tilde{\boldsymbol{\mu}}}{\partial \vartheta_i} = \left[\frac{\partial \tilde{\mu}_1}{\partial \vartheta_i}, \dots, \frac{\partial \tilde{\mu}_M}{\partial \vartheta_i} \right]^T, \quad \frac{\partial \mathbf{C}}{\partial \vartheta_i} = \frac{\partial \sigma^2}{\partial \vartheta_i} \mathbf{I}_M \quad (4-54)$$

令 $\gamma = 3.3$ 为研究问题中的路损指数, 对于未知参数 $\vartheta_k, k = 1, \dots, 3K + 1$, 式(4-54)中相应的偏导项为

$$\frac{\partial \tilde{\mu}_i}{\partial u_k^t} = S_k \frac{\partial f_i(\boldsymbol{\varrho}_k)}{\partial u_k^t} = -\gamma S_k \frac{u_k^t - u_i^s}{d_{ik}^{\gamma+2}} \quad (4-55a)$$

$$\frac{\partial \tilde{\mu}_i}{\partial v_k^t} = S_k \frac{\partial f_i(\boldsymbol{\varrho}_k)}{\partial v_k^t} = -\gamma S_k \frac{v_k^t - v_i^s}{d_{ik}^{\gamma+2}} \quad (4-55b)$$

$$\frac{\partial \tilde{\mu}_i}{\partial S_k} = f_i(\boldsymbol{\varrho}_k) = \frac{1}{d_{ik}^{\gamma}}, \quad \frac{\partial \tilde{\mu}_i}{\partial \sigma^2} = 0 \quad (4-55c)$$

$$\frac{\partial \sigma^2}{\partial u_k^t} = 0, \quad \frac{\partial \sigma^2}{\partial v_k^t} = 0, \quad \frac{\partial \sigma^2}{\partial S_k} = 0, \quad \frac{\partial \sigma^2}{\partial \sigma^2} = 1 \quad (4-55d)$$

由(4-55), (4-53), (4-52)有

$$\mathbf{J}(\boldsymbol{\vartheta}) = \frac{1}{\sigma^2} \begin{bmatrix} \frac{\partial \tilde{\boldsymbol{\mu}}^T}{\partial \boldsymbol{\vartheta}_{1:3K}} \frac{\partial \tilde{\boldsymbol{\mu}}}{\partial \boldsymbol{\vartheta}_{1:3K}^T} & \mathbf{0} \\ \mathbf{0} & \frac{M}{2\sigma^2} \end{bmatrix} \quad (4-56)$$

其中,

$$\frac{\partial \tilde{\boldsymbol{\mu}}^T}{\partial \boldsymbol{\vartheta}_{1:3K}} = \left[\frac{\partial \tilde{\boldsymbol{\mu}}}{\partial \boldsymbol{\vartheta}_{1:3K}^T} \right]^T = \begin{bmatrix} \frac{\partial \tilde{\mu}_1}{\partial \vartheta_1} & \cdots & \frac{\partial \tilde{\mu}_M}{\partial \vartheta_1} \\ \vdots & \ddots & \vdots \\ \frac{\partial \tilde{\mu}_1}{\partial \vartheta_{3K}} & \cdots & \frac{\partial \tilde{\mu}_M}{\partial \vartheta_{3K}} \end{bmatrix} \quad (4-57)$$

令 CRLB 矩阵 $\mathbf{F} = \mathbf{J}(\boldsymbol{\vartheta})^{-1}$, 则有

$$\mathbf{F} = \sigma^2 \begin{bmatrix} \left(\frac{\partial \tilde{\boldsymbol{\mu}}^T}{\partial \boldsymbol{\vartheta}_{1:3K}} \frac{\partial \tilde{\boldsymbol{\mu}}}{\partial \boldsymbol{\vartheta}_{1:3K}^T} \right)^{-1} & \mathbf{0} \\ \mathbf{0} & \frac{2\sigma^2}{M} \end{bmatrix}. \quad (4-58)$$

由第二章中关于 CRLB 的介绍可知, 对于 $\boldsymbol{\vartheta}$ 的任何无偏估计子 $\hat{\boldsymbol{\vartheta}}$, 其估协方差矩阵满足

$$\text{cov}(\hat{\boldsymbol{\vartheta}}) \succeq \mathbf{F} \quad (4-59)$$

对于辐射源位置的估计 $\hat{\boldsymbol{\rho}}_k, k = 1, \dots, K$, 其 CRLB 为

$$\text{CRLB}(\hat{\boldsymbol{\rho}}_k) = \sqrt{[\text{diag}(\mathbf{F})]_{3k-2} + [\text{diag}(\mathbf{F})]_{3k-1}} \quad (4-60)$$

4.7.4 不确定传播参数下能量域多源定位的 CRLB 推导

设对于 MMV 能量域多源定位模型 $\mathbf{y}_t = \boldsymbol{\Psi}(\mathcal{T})\mathbf{w}_t + \mathbf{n}_t, t = 1, 2, \dots, T$, 有 $p(\mathbf{Y}) = \prod_{t=1}^T \mathcal{N}(\boldsymbol{\Psi}(\mathcal{T})\mathbf{w}, \sigma^2 \mathbf{I})$. 在研究的多源定位问题中, 未知参数为噪声方差 σ^2 , 辐射源功率 $\mathbf{w} = [S_1, S_2, \dots, S_K]^T$ 、辐射源位置 $\mathcal{T} = [\boldsymbol{\rho}_1, \boldsymbol{\rho}_2, \dots, \boldsymbol{\rho}_K]$ 和未知路损指数 γ , 其中 $\boldsymbol{\rho}_k = (u_k^t, v_k^t)$. 令 $\boldsymbol{\vartheta} = [u_1^t, v_1^t, S_1, u_2^t, v_2^t, S_2, \dots, u_K^t, v_K^t, S_K, \gamma, \sigma^2]^T \in \mathbb{R}^{3K+2}$ 表示未知参数向量. 令 $\tilde{\boldsymbol{\mu}} = \boldsymbol{\Psi}(\mathcal{T})\mathbf{w}$, $\mathbf{C} = \sigma^2 \mathbf{I}$. 对 Fisher 信息矩阵, 由 4.7.4 小节的推导有

$$[\mathbf{J}(\boldsymbol{\vartheta})]_{i,j} = \sum_{t=1}^T \left\{ \frac{\partial \tilde{\boldsymbol{\mu}}^T}{\partial \vartheta_i} \mathbf{C}^{-1} \frac{\partial \tilde{\boldsymbol{\mu}}}{\partial \vartheta_j} + \frac{1}{2} \text{tr} \left(\mathbf{C}^{-1} \frac{\partial \mathbf{C}}{\partial \vartheta_i} \mathbf{C}^{-1} \frac{\partial \mathbf{C}}{\partial \vartheta_j} \right) \right\} \quad (4-61)$$

其中,

$$\frac{\partial \tilde{\boldsymbol{\mu}}}{\partial \vartheta_i} = \left[\frac{\partial \tilde{\mu}_1}{\partial \vartheta_i}, \dots, \frac{\partial \tilde{\mu}_M}{\partial \vartheta_i} \right]^T \quad (4-62a)$$

$$\frac{\partial \mathbf{C}}{\partial \vartheta_i} = \frac{\partial \sigma^2}{\partial \vartheta_i} \mathbf{I}_M \quad (4-62b)$$

对于未知参数 $\vartheta_k, k = 1, \dots, 3K + 1$, 式(4-62)中相应的偏导项为

$$\frac{\partial \tilde{\mu}_i}{\partial u_k^t} = S_k \frac{\partial f_i(\boldsymbol{\rho}_k)}{\partial u_k^t} = -\gamma S_k \frac{u_k^t - u_i^s}{d_{ik}^{\gamma+2}} \quad (4-63a)$$

$$\frac{\partial \tilde{\mu}_i}{\partial v_k^t} = S_k \frac{\partial f_i(\mathbf{q}_k)}{\partial v_k^t} = -\gamma S_k \frac{v_k^t - v_i^s}{d_{ik}^{\gamma+2}}, \quad \frac{\partial \tilde{\mu}_i}{\partial S_k} = f_i(\mathbf{q}_k) = \frac{1}{d_{ik}^\gamma} \quad (4-63b)$$

$$\frac{\partial \tilde{\mu}_i}{\partial \sigma^2} = 0, \quad \frac{\partial \tilde{\mu}_i}{\partial \gamma} = \frac{\partial \sum_{k=1}^K S_k f(\mathbf{s}_i, \mathbf{q}_k, \gamma)}{\partial \gamma} = -\sum_{k=1}^K S_k \frac{\ln d_{ik}}{d_{ik}^\gamma} \quad (4-63c)$$

$$\frac{\partial \sigma^2}{\partial v_k^t} = 0, \quad \frac{\partial \sigma^2}{\partial v_k^t} = 0, \quad \frac{\partial \sigma^2}{\partial S_k} = 0, \quad \frac{\partial \sigma^2}{\partial \sigma^2} = 1, \quad \frac{\partial \sigma^2}{\partial \gamma} = 0 \quad (4-63d)$$

由(4-63), (4-61), 有

$$\mathbf{J}(\boldsymbol{\vartheta}) = \frac{T}{\sigma^2} \begin{bmatrix} \frac{\partial \tilde{\boldsymbol{\mu}}^T}{\partial \boldsymbol{\vartheta}_{1:3K+1}} \frac{\partial \tilde{\boldsymbol{\mu}}}{\partial \boldsymbol{\vartheta}_{1:3K+1}^T} & \mathbf{0} \\ \mathbf{0} & \frac{M}{2\sigma^2} \end{bmatrix} \quad (4-64)$$

其中,

$$\frac{\partial \tilde{\boldsymbol{\mu}}^T}{\partial \boldsymbol{\vartheta}_{1:3K+1}} = \left[\frac{\partial \tilde{\boldsymbol{\mu}}}{\partial \boldsymbol{\vartheta}_{1:3K+1}^T} \right]^T = \begin{bmatrix} \frac{\partial \tilde{\mu}_1}{\partial \vartheta_1} & \cdots & \frac{\partial \tilde{\mu}_M}{\partial \vartheta_1} \\ \vdots & \ddots & \vdots \\ \frac{\partial \tilde{\mu}_1}{\partial \vartheta_{3K+1}} & \cdots & \frac{\partial \tilde{\mu}_M}{\partial \vartheta_{3K+1}} \end{bmatrix} \quad (4-65)$$

令 CRLB 矩阵 $\mathbf{F} = \mathbf{J}(\boldsymbol{\vartheta})^{-1}$, 则有

$$\mathbf{F} = \frac{\sigma^2}{T} \begin{bmatrix} \left(\frac{\partial \tilde{\boldsymbol{\mu}}^T}{\partial \boldsymbol{\vartheta}_{1:3K+1}} \frac{\partial \tilde{\boldsymbol{\mu}}}{\partial \boldsymbol{\vartheta}_{1:3K+1}^T} \right)^{-1} & \mathbf{0} \\ \mathbf{0} & \frac{2\sigma^2}{M} \end{bmatrix}. \quad (4-66)$$

所以, 对于路损指数的估计 $\hat{\gamma}$ 和辐射源位置的估计 $\hat{\mathbf{q}}_k, k = 1, \dots, K$, 其 CRLB 为

$$\text{CRLB}(\hat{\mathbf{q}}_k) = \sqrt{[\text{diag}(\mathbf{F})]_{3k-2} + [\text{diag}(\mathbf{F})]_{3k-1}} \quad (4-67)$$

$$\text{CRLB}(\hat{\gamma}) = \sqrt{[\text{diag}(\mathbf{F})]_{3k+1}} \quad (4-68)$$

4.8 本章小结

本章通过分析基于稀疏表征的多源定位中由网格失配和模型参数误差带来的基不匹配问题, 将多源定位问题建模成参数化字典学习和稀疏恢复的联合优化问题, 并从稀疏贝叶斯学习的角度对该问题进行求解, 最后提出了参数化稀疏贝叶斯字典学习算法 PSBDL, 完成了字典学习和稀疏恢复的闭环优化逻辑。针对实信号/复信号、SMV/MMV 观测模型下的多源定位问题, 我们详细推导了 PSBDL 算法的四种表现形式: PSBDL-ReSMV、PSBDL-ReMMV、PSBDL-ComSMV、PSBDL-ComMMV。最后基于所提算法分别求解了网格失配下的 SMV 能量域多源定位问题、网格失配下的 MMV DOA 估计问题、不确定路损指数下的能量域多源定位问题, 仿真表明所提算法具有比传统算法更优越的参数估计性能, 有效解决了基不匹配下的多源定位问题。

第五章 面向大规模高维场景的快速多源定位

5.1 引言

在第四章中，我们从字典学习和稀疏贝叶斯学习的角度研究了基不匹配下的多源定位问题，提出了参数化稀疏贝叶斯字典学习算法 PSBDL，有效提高了在网格失配和不确定模型参数情况下的定位性能。然而，PSBDL 算法 $\mathcal{O}(MN^2)$ 的计算复杂度阻碍了该算法在大规模高维问题中的实际应用，即面临“维数灾难”问题。接下来，我们将详细分析大规模高维场景中的“维数灾难”问题给稀疏重建算法在计算效率、存储需求、系统辨识能力上带来的挑战。

首先，假设辐射源参数位于一个 D 维的参数空间 Θ 中，基于稀疏表征的多源定位方法对每一维度进行 q 个网格点的离散化，则网格化参数空间 $\mathcal{G}$ 中共有 $N = q^D$ 个网格点。显然，若在 PSBDL 算法的稀疏推断中考虑所有的 N 个网格点，则 PSBDL 算法的计算复杂度为 $\mathcal{O}(Mq^{2D})$ 。当面对高维问题时， D 将变得很大。当面对大尺度的参数空间时，每一维度上的网格点数目 q 也将剧增。例如，对 $1\text{Km} \times 1\text{Km} \times 1\text{Km}$ 的 3 维辐射源位置空间，在每一维度上以 10m 为间隔进行网格划分，则共计有 $N = 1000000$ 个网格。若该空间中存在 $M = 60$ 个定位节点，则在能量域多源定位中构建的定位字典为 $\Phi \in \mathbb{R}^{60 \times 1000000}$ ，以双精度格式表示每个元素，则 Φ 在内存中的大小将达到 458MB。一方面，这对设备的内存造成较大压力。另一方面，在 PSBDL 算法的推断中对 60×1000000 大小的矩阵进行求伪逆、矩阵乘法等运算将对设备的算力带来压力。众所周知，EM 算法的收敛速度较慢，这意味着 PSBDL 算法需要多次迭代才能收敛。因此，在高维大规模场景中运行 PSBDL 算法会给设备的算力和存储带来极大挑战。事实上，在一台装备 i7-6750H 处理器 (主频 3.5GHz)、16G 内存的电脑上，在 Matlab 2016a 软件中用 PSBDL 算法解决上述例子中的多源定位问题将导致软件崩溃。虽然计算机的算力一直在提升，但类似快速傅里叶变换，研究计算复杂度更低的快速算法仍具有重要的现实意义。

其次，大规模高维场景使得离散网格集合 $\mathcal{G}$ 中包含海量的网格点，直接在海量的网格点中推断稀疏的辐射源参数对稀疏重建算法提出了严峻挑战。从系统辨识的角度来看，压缩感知理论表明^[96]，需要 $\mathcal{O}(K \ln N/K)$ 的测量才能以很大概率确保从 N 个候选原子中成功找与真实信号相关的 K 个原子。反过来，对于同样的测量数，模型中原子数 N 越多，则定位 K 个信号原子的概率则越小，稀疏恢复算法将无法分辨出 K 个真实信号成分。所以，直接在大规模高维场景海量的离散网格点中进行稀疏恢复，将大大降低成功恢复的概率。

综上所述，计算效率和系统辨识上的挑战使得 PSBDL 算法无法直接求解的大规

模高维场景中的问题。但通过上述分析可见，困难主要源自算法推断中同时考虑网格集合 $\mathcal{G}$ 中的所有网格点。所以，一种应对上述挑战的思想是分批多次地考虑这些网格点与信号生成的关系。在这种思想的指导下，一类典型方法是多分辨率搜索方法^[80]。该方法首先通过较粗的网格对参数空间进行离散化，然后在粗网格上找出与信号相关的网格点，接着在这些网格点附近对参数空间进行更细的网格离散化。如此迭代，最终通过一系列由粗到细的网格集合来定位真实的辐射源参数。例如，对 $1\text{Km} \times 1\text{Km}$ 的辐射源位置空间各维度按 1m 的网格间隔进行离散化，需要 10000 个网格点。但是对于多分辨率搜索，可以先对每一维度按 100m 间隔进行粗离散化，需要 100 个网格点，接着在对与信号相关的 K 个网格按 10m 间隔进行离散化，需要 $100K$ 个网格点，最后再对该网格中与信号相关的 K 个网格点按 1m 的间隔进行离散化，需要 $100K$ 个网格点。所以，多分辨率搜索达到同样的网格精度搜索结果，只需要 $100(2K + 1)$ 个网格点，远小于原始的 10000 个网格点。

然而，多分辨率搜索无法解决误差传播问题，即在上一次网格空间中对辐射源参数位置的错误估计，将持续地传播到后续网格离散化中，且无法对该错误进行纠正。与多分辨率搜索方法不同，另一类方法是网格甄别方法^[203,205]。该方法将海量的网格点分成模型网格点和候选网格点两类。这里，模型网格点指暂时被选入信号生成模型中的网格点，即参与定位字典构建的网格点，其被用于稀疏重建。候选网格点指暂时未被用来构建字典的网格点。网格甄别方法的巧妙之处在于从一个空模型(字典)开始，依据一定的准则往模型中依次添加相关的网格点成为模型网格点，并根据稀疏推断的结果对模型中的网格点进行删除来纠正历史上的错误。一方面，该方法类似 OMP 算法，以一种经济的方式增量式地扩大模型。另一方面，该方法又提供类似 CoSaMP 算法的“剪枝”操作来剔除历史中错误添加的网格点，防止模型过于臃肿。

受网格甄别方法的启发，本章针对 PSBDL 算法的稀疏推断部分提出一种快速证据下界最大化方法，使该部分的复杂度从 $\mathcal{O}(MN^2)$ 降低至 $\mathcal{O}(MN)$ ，从而可以用 PSBDL 算法来处理大规模高维问题。具体来说，本章通过分析证据下界关于超参数 α 的性质，得到使证据下界快速最大化的方法。该方法首先初始化一个空模型，通过考虑不同网格点对证据下界的贡献，将具有显著贡献的网格点加入模型中，成为模型网格点。然后由模型网格点构建过字典，进而利用该字典进行稀疏推断。根据稀疏推断的结果，在相同的“网格甄别”准则下，对候选网格点(未加入模型中的网格点)进行甄别，判断在下一轮推断中其是否值得被加入模型中，同时也对模型网格点进行判断，确定在下一轮推断中是否需要将其从模型中删除。

本章的创新点有：(1) 深入分析了稀疏贝叶斯学习中证据下界关于超参数更新的相关性质；(2) 提出了一种快速证据下界最大化稀疏贝叶斯学习算法 (Fast EM for SBL, FEMSBL)；(3) 通过理论分析和算法仿真验证了 FEMSBL 算法对计算效率和系统辨识能力的提升，说明其能够有效缓解大规模高维稀疏恢复场景中的“维数灾难”问题带来的影响；(4) 将 FEMSBL 算法与上一章提出的 PSBDL 算法结合，得到能够处理

高维大规模问题的参数化稀疏贝叶斯字典学习快速算法 (Fast PSBDL, FPSBDL); (5) 基于 FPSBDL 算法研究了能量域多源定位中的关键问题, 并通过在仿真与 PSBDL 算法进行对比验证了所提方法的有效性和优越性。

本章内容安排如下: 5.2 节介绍快速证据下界最大化稀疏贝叶斯学习算法 FEMSBL; 5.3 节介绍参数化稀疏贝叶斯字典学习快速算法 FPSBDL; 5.4 基于 FPSBDL 算法研究不确定路损指数下的能量域多源定位问题, 并在仿真中与 PSBDL 算法进行对比; 5.5 节给出相关证明和推导过程; 5.6 节对本章进行小结。

5.2 快速证据下界最大化稀疏贝叶斯学习算法

本小节通过 MMV 实信号模型, 简要回顾稀疏贝叶斯学习框架, 引出超参数 EM 更新中的证据下界最大化问题。然后, 重点分析证据下界的性质。在此基础上, 结合网格甄别思想, 提出快速证据下界最大化方法, 获得 MMV 实信号模型下的快速证据下界最大化稀疏贝叶斯学习算法 FEMSBL-ReMMV, 并对算法复杂度与收敛性进行简要分析, 同时也给出直观的数值仿真结果。

依照本节推导过程易得 SMV 实信号模型、SMV 复信号模型、MMV 复信号模型下的算法变形 FEMSBL-ReSMV、FEMSBL-ComSMV、FEMSBL-ComMMV, 本文在此不再赘述这些算法。

5.2.1 MMV 实信号稀疏贝叶斯学习

首先, 固定字典下的 MMV 实信号观测模型可表示为

$$\mathbf{Y} = \Phi \mathbf{X} + \mathbf{E} \quad (5-1)$$

其中, $\Phi \in \mathbb{R}^{M \times N}$, $\mathbf{Y} = [\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_T] \in \mathbb{R}^{M \times T}$, $\mathbf{X} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T] \in \mathbb{R}^{N \times T}$, $\mathbf{E} = [\mathbf{n}_1, \mathbf{n}_2, \dots, \mathbf{n}_T] \in \mathbb{R}^{M \times T}$ 。考虑共稀疏模型, 即所有的 $\mathbf{x}_t$ 都具有相同的支撑集。模型(5-1)下的稀疏重建问题指由观测矩阵 $\mathbf{Y}$ 推断行最稀疏的稀疏矩阵 $\hat{\mathbf{X}}$, 即

$$\hat{\mathbf{X}} = \arg \min_{\mathbf{X}} \mathcal{R}(\mathbf{X}) \quad \text{s.t.} \quad \|\mathbf{Y} - \Phi \mathbf{X}\|_F < \zeta \quad (5-2)$$

其中, $\mathcal{R}(\mathbf{X})$ 指 $\mathbf{X}$ 的非零行的个数, ζ 为允许的重建误差。

基于 Laplace 稀疏先验的稀疏贝叶斯学习方法在求解问题(5-2)时, 先对模型(5-1)建立如下层级概率模型

$$\mathbf{Y} | \beta \sim \prod_{t=1}^T \mathcal{N}(\mathbf{y}_t | \Phi \mathbf{x}_t, \beta^{-1} \mathbf{I}_M), \quad \beta \sim \text{Gamma}(\beta | a, b) \quad (5-3a)$$

$$\mathbf{X} | \alpha \sim \prod_{t=1}^T \mathcal{N}(\mathbf{x}_t | 0, \mathbf{A}), \quad \alpha \sim \prod_{j=1}^N \text{Gamma}\left(\alpha_j \middle| 1, \frac{\lambda}{2}\right) \quad (5-3b)$$

其中, $\alpha = [\alpha_1, \alpha_2, \dots, \alpha_N]^T$, $\mathbf{A} = \text{diag}(\alpha)$ 。根据贝叶斯准则有

$$p(\mathbf{X} | \alpha, \beta, \mathbf{Y}) = \prod_{t=1}^T \mathcal{N}(\mathbf{x}_t | \mu_t, \Sigma) \quad (5-4)$$

其中, 均值 μ_t 和协方差矩阵 Σ 为

$$\mu_t = \beta \Sigma \Phi^T \mathbf{y}_t, \quad \Sigma = (\beta \Phi^T \Phi + \mathbf{A}^{-1})^{-1} \quad (5-5)$$

在计算 $\mathbf{U} = [\boldsymbol{\mu}_1, \boldsymbol{\mu}_2, \dots, \boldsymbol{\mu}_T]$ 的时候, 需要知道超参数 $\boldsymbol{\alpha}$ 和 β 的具体取值。稀疏贝叶斯学习方法在计算 $\mathbf{U}$ 时取 $\boldsymbol{\alpha}$ 和 β 的最大后验估计值

$$\{\hat{\boldsymbol{\alpha}}, \hat{\beta}\}_{\text{MAP}} = \arg \max_{\boldsymbol{\alpha}, \beta} p(\boldsymbol{\alpha}, \beta | \mathbf{Y}) = \arg \max_{\boldsymbol{\alpha}, \beta} p(\mathbf{Y}, \boldsymbol{\alpha}, \beta) = \arg \max_{\boldsymbol{\alpha}, \beta} \ln p(\mathbf{Y}, \boldsymbol{\alpha}, \beta) \quad (5-6)$$

第四章中我们令 $\mathbf{X}$ 为隐变量, 使用 EM 算法来求解问题(5-6)。由第二章中关于 EM 算法的推导可知, EM 算法旨在最大化关于 $\boldsymbol{\alpha}$ 和 β 的证据下界

$$\text{ELBO}(\boldsymbol{\alpha}, \beta) = \mathbb{E} \{ \ln p(\mathbf{Y}, \mathbf{X}, \boldsymbol{\alpha}, \beta) \} + \text{const} \quad (5-7)$$

式(5-7)中, 求期望操作 $\mathbb{E}(\cdot)$ 指对隐变量 $\mathbf{X}$ 的后验分布式(5-4)求期望, const 为与 $\boldsymbol{\alpha}$ 和 β 无关的项。由4.3.2小节可知, 最大化式(5-7)的 $\boldsymbol{\alpha}$, β 为

$$\hat{\alpha}_j = \frac{\sqrt{T^2 + 4\lambda \sum_{t=1}^T (\Sigma_{jj} + (\mu_t)_j^2)} - T}{2\lambda}, \quad j = 1, \dots, N \quad (5-8a)$$

$$\hat{\beta} = \frac{2a - 2 + MT}{2b + \|\mathbf{Y} - \Phi \mathbf{U}\|_F^2 + T\beta^{-1} \sum_{j=1}^N (1 - \alpha_j^{-1} \Sigma_{jj})} \quad (5-8b)$$

最后根据上述推断, 算法5.1总结了基于 EM 更新的 MMV 实信号稀疏贝叶斯学习算法 EMSBL-ReMMV。在算法5.1步骤(3)中, 若 $N > M$, 则令

$$\boldsymbol{\Xi} = \beta^{-1} \mathbf{I}_M + \Phi \mathbf{A} \Phi^T \quad (5-9)$$

由 Woodbury 矩阵恒等式, 有

$$\boldsymbol{\Sigma} = \mathbf{A} - \mathbf{A} \Phi^T \boldsymbol{\Xi}^{-1} \Phi \mathbf{A} \quad (5-10)$$

可将计算 $\boldsymbol{\Sigma}$ 所示的矩阵求逆的复杂度从原来的 $\mathcal{O}(N^3)$ 降至 $\mathcal{O}(M^3)$ 。由4.3.2小节的分析可知, EMSBL-ReMMV 保证收敛到某一平稳点, 当 $M < N, T \ll N$ 时, EMSBL-ReMMV 的计算复杂度为 $\mathcal{O}(MN^2)$ 。

5.2.2 证据下界的性质

若要基于网格甄别思想提出针对 EMSBL 算法的加速算法, 首先需要依据一定的甄别准则区分模型网格点和候选网格点。本小节通过分析稀疏贝叶斯学习中证据下界关于超参数更新的性质, 分离出单个网格点 (或原子) 对证据下界的贡献, 并以此作为网格点区分甄别的依据。

在概率模型(5-3)中, $\boldsymbol{\alpha}$ 刻画了稀疏向量 $\mathbf{x}_t$ 各元素的取值情况。若 α_j 越趋近于

Algorithm 5.1: 基于 EM 更新的 MMV 实信号稀疏贝叶斯学习算法 (EMSBL-ReMMV)

Input: $\mathbf{Y}, \Phi$

- 1 初始化 $\boldsymbol{\alpha}, \beta$;
- 2 **while** 不满足终止条件 **do**
- 3 根据式(5-5)计算 $\mathbf{U}$ 和 $\boldsymbol{\Sigma}$;
- 4 根据式(5-8)更新 $\boldsymbol{\alpha}$ 和 β ;

Output: $\hat{\mathbf{X}} = \mathbf{U}$

0, 则 $[\mathbf{x}_t]_j$ 的分布函数越趋近于狄拉克 δ 函数, 从而 $[\mathbf{x}_t]_j$ 的概率密度越集中于原点附近, 这说明第 j 个原子或第 j 个网格点对信号的 $\mathbf{y}_t$ 的贡献越小。反之, 若 α_j 越趋近于 $+\infty$, 则 $[\mathbf{x}_t]_j$ 的分布越趋近于均匀分布, 从而 $||[\mathbf{x}_t]_j||$ 取较大值的概率越大, 这说明第 j 个原子或第 j 个网格点对信号的 $\mathbf{y}_t$ 的贡献越显著。因此, α_j 可视为第 j 个网格点可能是模型网格点还是候选网格点的一种度量。通过对式(5-7)中的证据下界进行分析, 分离出与 α_j 相关的成分, 可以量化表示该可能性的大小。

首先, 展开式(5-7), 有

$$\begin{aligned}\mathcal{L}(\boldsymbol{\alpha}) &= \text{ELBO}(\boldsymbol{\alpha}, \beta) = \mathbb{E} \left\{ \ln p(\mathbf{Y}|\mathbf{X}, \beta) + \ln p(\mathbf{X}|\boldsymbol{\alpha}) + \ln p(\boldsymbol{\alpha}) \right\} + \text{const} \\ &= -\frac{1}{2} \sum_{t=1}^T \left\{ \beta(\mathbf{y}_t - \Phi \boldsymbol{\mu}_t)^T (\mathbf{y}_t - \Phi \boldsymbol{\mu}_t) + \boldsymbol{\mu}_t^T \mathbf{A}^{-1} \boldsymbol{\mu}_t + \text{tr}(\beta \Sigma \Phi^T \Phi) + \text{tr}(\mathbf{A}^{-1} \Sigma) \right\} \\ &\quad - \frac{\lambda}{2} \sum_{j=1}^N \alpha_j - \frac{T}{2} \sum_{j=1}^N \ln \alpha_j + \underbrace{\left(a - 1 + \frac{TM}{2} \right) \ln \beta - b\beta + \text{const}}_{\text{const}(\boldsymbol{\alpha})} \end{aligned} \quad (5-11)$$

进一步分析式(5-11)中等号右侧的项, 有

$$\text{tr}(\beta \Sigma \Phi^T \Phi) + \text{tr}(\mathbf{A}^{-1} \Sigma) = \text{tr} \left\{ \Sigma (\beta \Phi^T \Phi + \mathbf{A}^{-1}) \right\} = \text{tr}(\mathbf{I}_N) = N \quad (5-12)$$

$$\boldsymbol{\Xi}^{-1} = [\beta^{-1} \mathbf{I}_M + \Phi \mathbf{A} \Phi^T]^{-1} = \beta \mathbf{I}_M - \beta \Phi (\mathbf{A}^{-1} + \beta \Phi^T \Phi)^{-1} \Phi^T \beta = \beta \mathbf{I}_M - \beta \Phi \Sigma \Phi^T \beta \quad (5-13)$$

$$\begin{aligned}\beta(\mathbf{y}_t - \Phi \boldsymbol{\mu}_t)^T (\mathbf{y}_t - \Phi \boldsymbol{\mu}_t) + \boldsymbol{\mu}_t^T \mathbf{A}^{-1} \boldsymbol{\mu}_t &= \beta \mathbf{y}_t^T \mathbf{y}_t - 2\beta \mathbf{y}_t^T \Phi \boldsymbol{\mu}_t + \boldsymbol{\mu}_t^T (\beta \Phi^T \Phi + \mathbf{A}^{-1}) \boldsymbol{\mu}_t \\ &= \beta \mathbf{y}_t^T \mathbf{y}_t - 2\beta \mathbf{y}_t^T \Phi \boldsymbol{\mu}_t + \beta \mathbf{y}_t^T \Phi \Sigma \Sigma^{-1} \boldsymbol{\mu}_t = \mathbf{y}_t^T (\beta \mathbf{I}_M - \beta \Phi \beta \Sigma \Phi^T) \mathbf{y}_t = \mathbf{y}_t^T \boldsymbol{\Xi}^{-1} \mathbf{y}_t\end{aligned} \quad (5-14)$$

将式(5-12)、式(5-14)代入式(5-11), 化简得

$$\mathcal{L}(\boldsymbol{\alpha}) = -\frac{1}{2} \sum_{t=1}^T \mathbf{y}_t^T \boldsymbol{\Xi}^{-1} \mathbf{y}_t - \frac{\lambda}{2} \sum_{j=1}^N \alpha_j - \frac{T}{2} \sum_{j=1}^N \ln \alpha_j + \text{const}(\boldsymbol{\alpha}) \quad (5-15)$$

基于5.5.1小节的推导, 可以分离出 α_j 对 $\mathcal{L}(\boldsymbol{\alpha})$ 的贡献 $\ell(\alpha_j)$

$$\begin{aligned}\mathcal{L}(\boldsymbol{\alpha}) &= -\frac{1}{2} \underbrace{\left\{ \sum_{t=1}^T \mathbf{y}_t^T \boldsymbol{\Xi}_{-j}^{-1} \mathbf{y}_t + \lambda \sum_{i \neq j} \alpha_i + T \sum_{i \neq j} \ln \alpha_i \right\}}_{\mathcal{L}(\boldsymbol{\alpha}_{-j})} \\ &\quad + \frac{1}{2} \underbrace{\left\{ \sum_{t=1}^T \frac{[q_t]_j^2 \alpha_j}{1 + \alpha_j s_j} - \lambda \alpha_j - T \ln \alpha_j \right\}}_{\ell(\alpha_j)} + \text{const}(\boldsymbol{\alpha}).\end{aligned} \quad (5-16)$$

其中, $\mathcal{L}(\boldsymbol{\alpha}_{-j})$ 为 $\boldsymbol{\alpha}$ 中除去 α_j 之外的其他所有元素的贡献,

$$\boldsymbol{\Xi}_{-j} = \beta^{-1} \mathbf{I}_M + \sum_{i \neq j} \alpha_i \Phi_i \Phi_i^T \quad (5-17)$$

$$s_j = \Phi_j^T \boldsymbol{\Xi}_{-j}^{-1} \Phi_j, \quad [q_t]_j = \Phi_j^T \boldsymbol{\Xi}_{-j}^{-1} \mathbf{y}_t \quad (5-18)$$

可以看出, Ξ_{-j} 、 s_j 、 $[q_t]_j$ 、 $\mathcal{L}(\alpha_{-j})$ 均与 α_j 无关。

所以, 在 EMSBL 算法对超参数 α 的 EM 更新中, 有

$$\hat{\alpha}_j = \arg \max_{\alpha_j} \mathcal{L}(\alpha) = \arg \max_{\alpha_j} l(\alpha_j). \quad (5-19)$$

对式(5-19)进行分析, 令 $\frac{\partial l(\alpha_j)}{\partial \alpha_j} = 0$ 可得关于 $l(\alpha_j)$ 的驻点方程

$$h(\alpha_j) = 0 \quad (5-20)$$

其中,

$$h(x) = a_0 x^3 + a_1 x^2 + a_2 x + a_3 \quad (5-21a)$$

$$a_0 = -\lambda s_j^2, \quad a_1 = -(2\lambda + T s_j) s_j, \quad a_2 = -2T s_j - \lambda + \sum_{t=1}^T [q_t]_j^2, \quad a_3 = -T \quad (5-21b)$$

因为 $\lim_{\alpha_j \rightarrow 0^+} l(\alpha_j) = +\infty$, 所以 $l(\alpha_j)$ 在 $[0, +\infty)$ 上无全局最大值。因此, 我们更关心 $l(\alpha_j)$ 的局部最大值。引理5.1分析了 $l(\alpha_j)$ 局部最大值的存在性。

引理 5.1 (局部最大值的存在性) 若驻点方程 $h(\alpha_j) = 0$ 有两个不同的正实根, 则 $l(\alpha_j)$ 具有唯一的局部最大值, 该局部最大值在较大的正实根处取得; 否则, $l(\alpha_j)$ 无局部最大值。

证明: 引理5.1的证明见5.5.2小节。□

引理5.1表明, $l(\alpha_j)$ 至多有一个局部最大值。下面的引理5.2说明了该局部最大值存在需满足的具体条件。

引理 5.2 若 $\Delta > 0$ 且 $a_2 > 0$, 或者 $\Delta > 0$, $a_2 < 0$ 且 $a_1 > 0$, 则方程 $h(\alpha_j) = 0$ 存在两个不同的正实根, 反之也成立。其中, Δ 是三次方程 $h(\alpha_j) = 0$ 的判别式, 定义为 $\Delta = 18a_0 a_1 a_2 a_3 - 4a_1^3 a_3 + a_1^2 a_2^2 - 4a_0 a_2^3 - 27a_0^2 a_3^2$ 。

证明: 引理5.2的证明见5.5.3小节。□

根据引理5.1和引理5.2, 定理5.1分析了关于 α_j 的最大化问题(5-19)的解。

定理 5.1 当固定 α 中除 α_j 之外的其他元素时, $\mathcal{L}(\alpha)$ 的最大值在 $\hat{\alpha}_j$ 处取得。这里,

$$\hat{\alpha}_j = \begin{cases} \alpha_j^*, & \text{若 } \Delta > 0, a_2 > 0 \\ \alpha_j^*, & \text{若 } \Delta > 0, a_2 < 0, a_1 > 0 \\ 0, & \text{其他} \end{cases} \quad (5-22)$$

α_j^* 为方程 $h(\alpha_j) = 0$ 较大的正实根。

证明: 由引理5.1和引理5.2易证。□

定理5.1表明, 最大化证据下界的 $\hat{\alpha}_j$ 要么为正实数, 要么为 0。根据所构建的概率图模型, 当 $\hat{\alpha}_j = 0$ 时, $[x_t]_j$ 的分布函数退化为狄拉克 δ 函数, 从而 $[x_t]_j = 0$, 这说明第 j 个原子或第 j 个网格对信号 y_t 无贡献, 故可以从模型中暂时删除, 成为候选网格点。反之, 若 $\hat{\alpha}_j > 0$, 则 $[x_t]_j$ 的分布函数为高斯函数, 从而 $[x_t]_j$ 可能取非 0 值, 这说明第 j 个原子对信号信号 y_t 有贡献, 故应该被加入模型中, 成为模型网格点。

Algorithm 5.2: 基于快速证据下界最大化的 MMV 实信号稀疏贝叶斯学习算法 (FEMSBL-ReMMV)

Input: Φ, Y

- 1 初始化 $\alpha = \mathbf{0}, \beta$, 网格点集合 $\mathbb{N} = \{1, 2, \dots, N\}$, 模型网格点集合 $\bar{\mathcal{M}} = \emptyset$, 候选网格点集合 $\mathcal{C} = \mathbb{N} \setminus \bar{\mathcal{M}}$;
- 2 选择一个合适的网格点 j , 将其加入模型网格点中: $\bar{\mathcal{M}} = \bar{\mathcal{M}} \cup j$, $\mathcal{C} = \mathcal{C} \setminus j$, 并设置合适的 α_j 的值;
- 3 根据模型网格点对应的字典 $\Phi_{\bar{\mathcal{M}}}$, 按照式(5-5)计算 Σ 和 $\mathbf{U}$;
- 4 对所有网格点 $j \in \mathbb{N}$, 计算 $s_j, [q_t]_j, t = 1, 2, \dots, T$;
- 5 **while** 不满足稀疏恢复终止条件 **do**
- 6 选择一个网格点 $j \in \mathbb{N}$;
- 7 **if** $(\Delta > 0 \ \& \ a_2 > 0) \mid (\Delta > 0 \ \& \ a_2 < 0 \ \& \ a_1 > 0)$ **then**
- 8 **if** $\alpha_j = 0$ **then**
- 9 按照式(5-22)更新 α_j , 并将原子 Φ_j 加入模型: $\bar{\mathcal{M}} = \bar{\mathcal{M}} \cup j$, $\mathcal{C} = \mathcal{C} \setminus j$;
- 10 **else if** $\alpha_j > 0$ **then**
- 11 按照式(5-22)重新估计 α_j ;
- 12 **else**
- 13 **if** $\alpha_j = 0$ **then**
- 14 不进行任何操作;
- 15 **else if** $\alpha_j > 0$ **then**
- 16 令 $\alpha_j = 0$, 并从模型中删除原子 Φ_j : $\bar{\mathcal{M}} = \bar{\mathcal{M}} \setminus j$, $\mathcal{C} = \mathcal{C} \cup j$;
- 17 根据模型网格点对应的字典 $\Phi_{\bar{\mathcal{M}}}$, 按照式(5-8b)更新 β ;
- 18 根据模型网格点对应的字典 $\Phi_{\bar{\mathcal{M}}}$, 按照式(5-5)更新 Σ 和 $\mathbf{U}$;
- 19 对所有网格点 $j \in \mathbb{N}$, 更新 $s_j, [q_t]_j, t = 1, 2, \dots, T$;

Output: $\hat{\mathbf{X}} = \mathbf{U}$

5.2.3 快速证据下界最大化算法

上一小节分离出了单个网格点对证据下界的贡献 $\ell(\alpha_j)$, 并根据最大化 $\ell(\alpha_j)$ 的 $\hat{\alpha}_j$ 提出了模型网格点和候选网格点的甄别准则。本节根据该准则, 提出基于快速证据下界最大化的稀疏贝叶斯学习算法 FEMSBL-ReMMV, 算法流程如算法5.2所示。

在步骤(1)中, 令 $\alpha = \mathbf{0}$ 表示将所有原子排除在模型之外, 构建一个空模型 $\bar{\mathcal{M}}$ 。

步骤(2)向模型网格点中添加了一个网格点。在具体实现中, 可取与当前信号最相关的网格点

$$j = \arg \max_{j \in \mathbb{N}} \frac{\sum_{t=1}^T \|\Phi_j^T \mathbf{y}_t\|_2^2}{\|\Phi_j\|_2^2} \quad (5-23)$$

α_j 的相应具体取值为

$$\alpha_j = \frac{\frac{1}{\|\Phi_j\|_2^2} \sum_{t=1}^T \|\Phi_j^T \mathbf{y}_t\|_2^2 - \frac{1}{\beta}}{\|\Phi_j\|_2^2} \quad (5-24)$$

在步骤 (3) 中, 因为当前模型网格点集合 $\bar{\mathcal{M}}$ 中只有一个网格点, 所以 Σ 为标量, $\mathbf{U}$ 为 $1 \times T$ 的行向量。

在步骤 (4) 中, 可以按照式(5-18)的定义来对所有 $j \in \mathbb{N}$ 计算 $s_j, [q_t]_j$ 。但这样需对每一个网格点计算相应的 Ξ_{-j} 。通过进一步分析, 本文采取计算效率更高的等效计算方法。首先, 计算

$$S_j = \Phi_j^T \Xi^{-1} \Phi_j, \quad [Q_t]_j = \Phi_j^T \Xi^{-1} \mathbf{y}_t \quad (5-25)$$

然后, 式(5-26)提供了 $s_j, [q_t]_j$ 的等效计算公式:

$$s_j = \frac{S_j}{1 - \alpha_j S_j}, \quad [q_t]_j = \frac{[Q_t]_j}{1 - \alpha_j S_j} \quad (5-26)$$

和原始定义式(5-18)相比, 式(5-26)的计算方法不需要对每个网格点计算单独的 Ξ_{-j} , 从而大大提高了计算效率。

在步骤 (6) 中, 必须选择一个网格点 j (或等效地, 精度 α_j 或原子 Φ_j) 来进行更新。原则上应当从所有网格点中随机均匀选择, 或按照一定的次序遍历所有的模型网格点和候选网格点。本文采用文献^[203]中提出的更加计算有效的方法, 先对每个网格点按照步骤 (7) 到步骤 (16) 进行判断和更新, 然后计算其对证据下界 $\mathcal{L}(\alpha)$ 带来的增益, 选择增益最大的网格点 j 来进行更新。从而在每一次迭代中, 证据下界 $\mathcal{L}(\alpha)$ 均被最大化。因证据下界有上界, 故 FEMSBL-ReMMV 算法关于 α 的估计将迅速收敛。

由定理5.1可知, 若步骤 (7) 中条件成立, 则证据下界 $\mathcal{L}(\alpha)$ 关于 α_j 存在唯一局部最大值。在步骤 (8) 中, 若 $\alpha_j = 0$, 说明当前第 j 个网格点为候选网格点, 但其对信号 $\mathbf{y}_t$ 的构成有贡献。所以, 在步骤 (9) 中, 将该网格加入模型网格中。在步骤 (10) 中, 若 $\alpha_j > 0$, 说明当前第 j 个网格点为模型网格点, 且在当前推断下其对信号 $\mathbf{y}_t$ 的构成依旧有贡献, 故在步骤 (11) 中根据当前推断更新 α_j 的取值。

步骤 (12) 说明若步骤 (7) 中条件不成立, 则证据下界 $\mathcal{L}(\alpha)$ 关于 α_j 不存在局部最大值, 其只能取 $\alpha_j = 0$ 处的全局最大值, 即意味着网格点 j 对信号的生成无贡献, 不应该成为模型网格点。所以在步骤 (13) 中, 若该网格点当前为候选网格点, 则不进行任何操作。在步骤 (15) 中, 若该网格点为模型网格点, 则说明当前统计推断结果认为历史上被加入模型中的网格点 j 是个错误, 所以在步骤 (16) 中令 $\alpha_j = 0$, 并将其从模型网格点中删除以纠正该错误, 防止误差传播。

5.2.4 算法复杂度与收敛性分析

FEMSBL-ReMMV 算法和 EMSBL-ReMMV 算法的唯一不同在于对 α 的更新策略不同。事实上, FEMSBL-ReMMV 算法令候选网格点的 $\alpha = 0$, 并对模型网格点的 α 和相关统计量作出推断, 这等效于对所有的网格点相关的统计量进行了推理。通过5.2.2小节中对证据下界性质的分析和5.2.3小节中关于 FEMSBL-ReMMV 算法实现细节的讨论, 可以看出在每一次迭代中 FEMSBL-ReMMV 算法均能保证实现证据下界的最大化, 等效于 EMSBL-ReMMV 算法中对所有网格点进行证据下界最大化

推理。故 FEMSBL-ReMMV 算法和 EMSBL-ReMMV 算法具有一样的收敛性，保证收敛到某一平稳点。基于文献^[203]的分析可知 FEMSBL-ReMMV 算法的复杂度仅为 $\mathcal{O}(MN)$ ，远低于 EMSBL-ReMMV 算法 $\mathcal{O}(MN^2)$ 的复杂度。

下面通过一个简单的数值仿真例子来比较 FEMSBL-ReMMV 算法和 EMSBL-ReMMV 算法的时间复杂度和估计性能。令 Φ 为各元素服从标准高斯分布的 $M \times N$ 随机矩阵， $\mathbf{X}$ 为非零元素为 1，行稀疏度为 K 的 $M \times T$ 共稀疏系数矩阵， $\mathbf{E}$ 为各元素服从 $\mathcal{N}(0, 0.3^2)$ 的 $M \times T$ 随机误差矩阵，分别使用 FEMSBL-ReMMV 算法和 EMSBL-ReMMV 算法从观测数据 $\mathbf{Y} = \Phi\mathbf{X} + \mathbf{E}$ 中对 $\mathbf{X}$ 进行估计。令 $M = 80$ ， $T = 20$ ， $K = 4$ ，图 5-1 显示了在不同原子数目 N 下两种算法的平均运行时间、相对估计误差 $\frac{\|\hat{\mathbf{X}} - \mathbf{X}\|_F}{\|\mathbf{X}\|_F}$ 、估计的行稀疏度（行向量的均值大于 0.2 的行数）和最终模型中包含的原子数目（行向量绝对值的均值大于 10^{-8} 的行数），表 5-1 给出了具体的平均运行时间值（因计算复杂度的原因，EMSB�-ReMMV 算法运行的最大原子数为 5000。所有结果均为 100 次蒙特卡洛仿真的平均结果）。




图 5-1 不同原子数目下 FEMSBL 算法和 EMSBL 算法的稀疏恢复性能对比

从图 5-1(a) 可以看出 FEMSBL 算法 $\mathcal{O}(MN)$ 的复杂度相对于 EMSBL 算法 $\mathcal{O}(MN^2)$ 的复杂度带来了计算效率的巨大提升。从表 5-1 可以看出当原子数目为 5000 时，FEMSBL

表 5-1 不同原子数目下 FEMSBL 算法和 EMSBL 算法的平均运行时间

	平均运行时间 (秒)									
原子数目	100	200	500	1000	2000	5000	10000	20000	50000	100000
EMSBL	0.003	0.008	0.145	1.207	12.270	851.830	-	-	-	-
FEMSBL	0.009	0.011	0.016	0.028	0.052	0.128	0.240	0.448	1.166	2.319

算法的运行时间比 EMSBL 算法的降低了 6655 倍。原子数目从 100 增大 50 倍到 5000 时, EMSBL 算法的运行时间增大了 283943 倍, 而 FEMSBL 算法只增大了 14 倍, 这充分说明了提出的 FEMSBL 算法在计算效率上的优越性, 所以当原子数为 100000 时, FEMSBL 算法仅需 2.319 秒便能完成稀疏恢复。

从图 5-1(b) 可以看出, EMSBL 算法的相对估计误差始终高于 FEMSBL 算法的, 且当原子数大于 500 后, EMSBL 算法的相对估计误差越来越大。这是因为 EMSBL 算法将所有的 N 个原子都包含在 SBL 模型中 (如图 5-1(d) 所示), 需要计算所有原子的贡献, 造成 $\mathbf{X}$ 的非零行也被赋予了极小的系数, 导致了过拟合现象, 使得当原子数大于 500 后估计的相对误差随着原子数的增多而变大。相比之下, FEMSBL 算法的相对估计误差变化很小。由图 5-1(d) 可以看出, 这是因为其模型中包含的原子数基本和真实行稀疏度保持一致, 所以仅有这些模型中的原子对应的行被赋予非零值, 最终 FEMSBL 算法的相对估计误差不随原子数目增加而明显变化。

图 5-1(c) 表明, FEMSBL 算法估计的行稀疏度稍微略高于真实的行稀疏度, 但基本保持一致, 而 EMSBL 算法当原子数目大于 2000 时, 对行稀疏度出现了欠估计。如引言所述, 这是因为当原子数足够大时, 给定的测量数不足以从包含所有原子的字典中辨识出给定数量的信号成分, 即系统辨识能力受限。与 EMSBL 算法不同, FEMSBL 算法仅从所有原子中选取部分原子加入稀疏推断的字典模型, 从而可以避开该约束, 获得更好的系统辨识能力。

图 5-1(d) 直观展示了 FEMSBL 算法和 EMSBL 算法字典模型中包含的原子数目情况。可以看出, EMSBL 算法将所有给定的原子都加入模型中, 而 FEMSBL 将与真实行稀疏度一致 (或同一数量级) 的原子加入模型中, 这也正是 FEMSBL 算法比 EMSBL 算法具有更低的计算复杂度、更低的估计误差和更高的系统辨识能力的原因。

由该仿真可以看出, 提出的 FEMSBL 算法能够有效求解大规模高维场景中的稀疏恢复问题, 缓解“维数灾难”问题带来的影响。

5.3 参数化稀疏贝叶斯字典学习快速算法

从上一小节可以看出, 利用证据下界最大化的性质, FEMSBL 算法基于网格甄别思想实现了从海量原子中迅速定位信号原子、实现高精度稀疏恢复的效果。由第一章和第四章可知, 字典学习问题是稀疏恢复领域中的一个重要问题, 广泛存在于

Algorithm 5.3: MMV 实信号模型下的参数化稀疏贝叶斯字典学习快速算法 (FPSBDL-ReMMV)

Input: 测量矩阵 $\mathbf{Y}$;

- 1 初始化字典参数 $\mathcal{G}^{(0)}$, $\mathcal{M}^{(0)}$, 并由 $\mathcal{G}^{(0)}$, $\mathcal{M}^{(0)}$ 构造初始字典 $\Phi^{(0)}$;
- 2 初始化网格点集合 $\mathbb{N} = \{1, 2, \dots, \text{card}(\mathcal{G}^{(0)})\}$, 模型网格点集合 $\bar{\mathcal{M}} = \emptyset$, 候选网格点集合 $\mathcal{C} = \mathbb{N} \setminus \bar{\mathcal{M}}$, $\alpha^{(0)} = \mathbf{0}$, $\beta^{(0)}$, $l = 0$;
- 3 选择一个合适的网格点 j , 将其加入模型网格点中: $\bar{\mathcal{M}} = \bar{\mathcal{M}} \cup j$, $\mathcal{C} = \mathcal{C} \setminus j$, 并设置合适的 α_j 的值;
- 4 根据模型网格点对应的字典 $\Phi_{\bar{\mathcal{M}}}^{(0)}$, 按照式(5-5)计算 Σ 和 $\mathbf{U}$;
- 5 对所有网格点 $j \in \mathbb{N}$, 计算 $s_j, [q_t]_j, t = 1, 2, \dots, T$;
- 6 **while** 不满足终止条件 **do**
- 7 令 $m = 0$;
- 8 // 稀疏信号恢复
- 9 按 FEMSBL-ReMMV 算法步骤 (5) 到步骤 (19) 更新 $\alpha^{(m+1)}$, $\beta^{(m+1)}$, Σ , $\mathbf{U}$ 和 $s_j, [q_t]_j, j \in \mathbb{N}, t = 1, 2, \dots, T$;
- 10 // 字典学习
- 11 $\mathcal{G}^{(0)} = \mathcal{G}^{(l)}$, $\mathcal{M}^{(0)} = \mathcal{M}^{(l)}$, $n = 0$;
- 12 **while** 不满足字典学习终止条件 **do**
- 13 求解问题(4-27c), 获得 $\mathcal{G}^{(n+1)}, \mathcal{M}^{(n+1)}$;
- 14 根据 $\mathcal{G}^{(n+1)}, \mathcal{M}^{(n+1)}$ 更新 $\Phi^{(l)}$;
- 15 $n = n + 1$;
- 16 $\mathcal{G}^{(l+1)} = \mathcal{G}^{(n)}$, $\mathcal{M}^{(l+1)} = \mathcal{M}^{(n)}$, $\alpha^{(0)} = \alpha^{(m)}$, $\beta^{(0)} = \beta^{(m)}$, $l = l + 1$;
- 17 根据 $\mathcal{G}^{(l)}, \mathcal{M}^{(l)}$ 计算 $\Phi^{(l)}$;

Output: $\hat{\mathbf{X}} = \mathbf{U}$, $\hat{\mathcal{G}} = \mathcal{G}^{(l)}$, $\hat{\mathcal{M}} = \mathcal{M}^{(l)}$;

多源定位、语音处理、频谱估计等诸多应用场景中。第四章提出的 PSBDL 算法完成了字典学习和稀疏恢复的闭环优化逻辑, 能够有效解决稀疏恢复中的字典学习问题, 具有重要的应用价值。然而, 如 5.1 小节所述, PSBDL 算法无法求解大规模高维问题。

本小节将 FEMSBL 算法与 PSBDL 算法相结合, 针对高维大规模问题提出了一种高效可靠的参数化稀疏贝叶斯字典学习快速算法 FPSBDL。算法 5.3 总结了 MMV 实信号问题下的参数化稀疏贝叶斯字典学习快速算法 FPSBDL-ReMMV。基于同 FEMSBL 算法同样的原因, 本文不再赘述得 SMV 实信号模型、SMV 复信号模型、MMV 复信号模型下的算法变形 FPSBDL-ReSMV、FPSBDL-ComSMV、FPSBDL-ComMMV。

算法 5.3 中各步骤的具体细节参考 5.2.3 小节和 4.3.2 的相关描述。对于字典学习部分, 4.3.2 小节中的 PSBDL-ReMMV 算法限制在 $\mathbf{X}$ 的非零行对应的原子上 (或限制在 $\mathbf{U}$ 中 ℓ_2 范数最大的 K_0 个非零行所对应的原子上)。而在 FPSBDL-ReMMV 算法中, 由于模型网格点集合 $\bar{\mathcal{M}}$ 中仅包含少量的原子, 所以字典学习可以限制在 $\bar{\mathcal{M}}$ 对应的原子上, 或者 $\mathbf{U}$ 中 ℓ_2 范数最大的 K_0 个非零行所对应的原子上。

表 5-2 不同网格密度、信噪比、快拍数、定位节点数目下路损指数 γ 的均方根估计误差

仿真设置	SNR = 20 dB, $M = 50, T = 2$					$\sqrt{N} = 15, M = 50, T = 2$				
	网格密度 $\sqrt{N}$					信噪比 SNR(dB)				
	5	10	15	20	25	10	15	20	25	30
CRLB	0.151	0.143	0.150	0.155	0.152	0.441	0.278	0.154	0.088	0.048
PSBDL	0.442	0.390	0.333	0.313	0.310	0.615	0.429	0.344	0.206	0.182
FPSBDL	0.438	0.401	0.324	0.314	0.315	0.604	0.422	0.319	0.236	0.186
仿真设置	SNR = 20 dB, $M = 50, \sqrt{N} = 15$					SNR = 20 dB, $\sqrt{N} = 15, T = 2$				
	快拍数 T					定位节点数目 M				
	1	3	5	7	9	30	40	50	60	70
CRLB	0.243	0.124	0.105	0.073	0.061	0.399	0.268	0.156	0.098	0.028
PSBDL	0.427	0.325	0.319	0.304	0.293	0.521	0.410	0.303	0.220	0.133
FPSBDL	0.431	0.301	0.307	0.298	0.299	0.530	0.429	0.313	0.190	0.121

由5.2.4小节对 FEMSBL-ReMMV 算法的收敛性分析和4.3.2小节对 PSBDL-ReMMV 算法的收敛性分析可知, FPSBDL-ReMMV 具有和对 PSBDL-ReMMV 算法一样的收敛性, 保证收敛到某一局部平稳点。

由4.3.2小节对 PSBDL-ReMMV 算法的复杂度分析可知, FPSBDL-ReMMV 算法的复杂度主要由稀疏恢复部分主导。所以 FPSBDL-ReMMV 算法的复杂度和 FEMSBL-ReMMV 算法一样为 $\mathcal{O}(MM)$ 。

最后, 由5.1小节的讨论和5.2.4小节的数值仿真可以看出, 当稀疏恢复问题只涉及合适大小的原子数目时, FEMSBL-ReMMV 算法和 EMSBL-ReMMV 算法具有类似的误差精度和收敛性能。当面对海量原子中的稀疏恢复问题时, FEMSBL-ReMMV 算法的系统辨识能力将远超 EMSBL-ReMMV 算法, 同时其计算复杂度也能够较为轻松地处理大规模问题。因此, 基于 FEMSBL-ReMMV 算法的 FPSBDL-ReMMV 算法也具备同样的性质: 在中小规模的参数化稀疏字典学习问题中具有和 PSBDL-ReMMV 类似的性能, 在大规模参数化稀疏字典学习问题中将从计算效率和系统辨识能力方面远超 PSBDL-ReMMV 算法。所以, PSBDL-ReMMV 能够有效处理大规模高维场景下的参数化稀疏字典学习问题。

5.4 算法性能仿真

本节基于提出的 FPSBDL-ReMMV 算法解决4.6.3小节中不确定路损指数下的 MMV 能量域多源定位问题。仿真设置均参照4.6.3小节。

5.4.1 仿真结果和分析

表5-2展示了不同网格密度、信噪比、快拍数和定位节点数目下路损指数 γ 估计的 CRLB 以及 PSBDL-ReMMV 算法和 FPSBDL-ReMMV 算法对路损指数的均方根估




图 5-2 不同网格密度、信噪比、快拍数、定位节点数目下的均方根定位误差

计误差。可以看出，在不同设置下 FPSBDL-ReMMV 算法对路损指数 γ 的估计性能均与 PSBDL-ReMMV 算法保持一致，能够依据观测数据有效估计出未知的路损指数，且估计误差逼近理论上的克拉美罗下界。

图5-2展示了不同网格密度、信噪比、快拍数、定位节点数下各算法的均方根定位误差曲线和 PSBDL-ReMMV 均方根定位误差的箱线图。可以看出，提出的 FPSBDL-ReMMV 算法和 PSBDL-ReMMV 算法具有相同的估计精度，显示出比对比算法更优越的定位性能。同时，二者的均方根误差均逼近理论上的克拉美罗下界。

表5-2和图5-2说明，提出的 FPSBDL-ReMMV 算法具有不弱于 PSBDL-ReMMV 算法的参数估计精度，能够有效解决不确定路损指数下的 MMV 能量域多源定位问题。表5-3展示了不同网格密度和不同定位节点数目下 FPSBDL-ReMMV 算法和 PSBDL-ReMMV 算法的平均运行时间。从表5-3可以看出，PSBDL-ReMMV 算法的平

表 5-3 不同网格密度和定位节点数目下的平均运行时间 (单位: 秒)

仿真设置	SNR = 20 dB, $M = 50, T = 2$					SNR = 20 dB, $\sqrt{N} = 15, T = 2$				
	网格密度 $\sqrt{N}$					定位节点数目 M				
	5	10	15	20	25	30	40	50	60	70
PSBDL	0.085	0.230	0.622	3.941	12.360	2.644	2.588	1.010	0.978	0.790
FPSBDL	0.152	0.199	0.236	0.295	0.375	0.320	0.327	0.312	0.347	0.328

均运行时间按网格密度增长的三次方到四次方增长, 而 FPSBDL-ReMMV 算法的平均运行时间按网格密度的亚线性增长关系变化。所以当网格点数目增大时, FPSBDL-ReMMV 算法的复杂度远远低于 PSBDL-ReMMV 算法的复杂度, 能够处理大规模高维场景中海量网格点下的多源定位问题。值得注意的是, 表 5-3 中随着定位节点个数 M 的增长, PSBDL-ReMMV 算法的复杂度反而略降低, 这是因为对于给定的网格点数目和辐射源数目, 定位节点个数越多, 虽然每一次迭代的运行时间会变长, 但 PSBDL-ReMMV 算法的系统辨识能力也越强, 这意味着 PSBDL-ReMMV 算法将迅速收敛, 迭代的总次数将减小, 总体的运行时间会变小。

5.5 证明和推导

5.5.1 式(5-16)的推导

首先, 从 Ξ 中分离出与第 j 个原子有关的项, 有

$$\Xi = \underbrace{\beta^{-1} \mathbf{I}_M + \sum_{i \neq j} \alpha_i \Phi_i \Phi_i^T}_{\Xi_{-j}} + \alpha_j \Phi_j \Phi_j^T \quad (5-27)$$

对于上述分解, 基于矩阵求逆定理有

$$\Xi^{-1} = \Xi_{-j}^{-1} - \frac{\Xi_{-j}^{-1} \Phi_j \Phi_j^T \Xi_{-j}^{-1}}{\alpha_j^{-1} + \Phi_j^T \Xi_{-j}^{-1} \Phi_j} \quad (5-28)$$

将式(5-27)和式(5-28)代入式(5-15), 化简得

$$\begin{aligned} \mathcal{L}(\alpha) = & \underbrace{-\frac{1}{2} \left\{ \sum_{t=1}^T \mathbf{y}_t^T \Xi_{-j}^{-1} \mathbf{y}_t + \lambda \sum_{i \neq j} \alpha_i + T \sum_{i \neq j} \ln \alpha_i \right\}}_{\mathcal{L}(\alpha_{-j})} \\ & + \underbrace{\frac{1}{2} \left\{ \sum_{t=1}^T \frac{[q_t]_j^2 \alpha_j}{1 + \alpha_j s_j} - \lambda \alpha_j - T \ln \alpha_j \right\}}_{l(\alpha_j)} + \text{const}(\alpha). \end{aligned} \quad (5-29)$$

5.5.2 引理5.1的证明

证明 (引理5.1的证明): 因为 $a_3 = -T < 0$, 所以 $h(0) < 0$ 。因为 $a_0 = -\lambda s_j^2 < 0$, 所以 $h(+\infty) < 0$, $h(-\infty) > 0$ 。基于以上两点, 一元三次方程 $h(\alpha_j) = 0$ 一定有一个负实根, 一元三次方程 $h(\alpha_j) = 0$ 的另外两个根要么均不是正实根, 要么均是正实根 (重根或者不同正实根)。

1) 若另外两个根为不同的正实根, 则 $\ell(\alpha_j)$ 在二者中较大的正实根处取得局部最大值。

2) 否则, 若另外两个根为相同的正实根 (重根) 或非正实根, 则 $\ell(\alpha_j)$ 无局部最大值。□

5.5.3 引理5.2的证明

证明 (引理5.2的证明): 由引理5.1的证明过程可知, $h(\alpha_j) = 0$ 至少有一个负实根。若 $h(\alpha_j) = 0$ 还有两个不同的正实根, 则 $h(\alpha_j) = 0$ 有三个不同的实根, 这要求三次方程的判别式 $\Delta > 0$ 。

假定 $\Delta > 0$, 要获得一个负实根和两个不同的正实根, 则要求函数 $y(x) = h(x)$ 的驻点要么分别落在 y 轴两侧, 要么落在 y 轴右侧。对 $y(x) = h(x)$ 求导有

$$y'(x) = 3a_0x^2 + 2a_1x + a_2 \quad (5-30)$$

所以, 若 $y(x)$ 的两个驻点落在

1) y 轴的两侧, 则有 $\frac{a_2}{3a_0} < 0$, 所以要求 $a_2 > 0$ 。

2) y 轴的右侧, 则有 $\frac{a_2}{3a_0} > 0$, $-\frac{2a_1}{3a_0} < 0$, 所以要求 $a_2 < 0$, $a_1 > 0$ 。□

5.6 本章小结

本章从计算效率、存储需求、系统辨识能力的角度分析了大规模高维场景中的"维数灾难"问题给基于稀疏表征的多源定位算法带来的挑战。针对这些挑战, 我们通过分析稀疏贝叶斯学习中证据下界关于超参数更新的性质, 基于网格甄别思想提出了一种快速证据下界最大化稀疏贝叶斯学习算法 FEMSBL。理论分析和数值仿真表明 FEMSBL 能够高效可靠地求解大规模稀疏恢复问题, 有效缓解"维数灾难"问题带来的挑战。将 FEMSBL 算法与 PSBDL 算法结合, 我们提出一种参数化稀疏贝叶斯字典学习快速算法 FPSBDL。理论分析表明, FPSBDL 算法将 PSBDL 算法的计算复杂度从 $\mathcal{O}(MN^2)$ 降低到 $\mathcal{O}(MN)$ 。仿真验证了 FPSBDL 算法相对于 PSBDL 算法在计算复杂度和系统辨识能力上的显著提升。

第六章 阴影衰落信道下的多源定位

6.1 引言

第三章到第五章主要研究无障碍环境中的多源定位问题，噪声模型为加性噪声。然而有障环境中障碍物的遮挡带来阴影衰落效应，大量研究和实验表明对数正态模型能够有效刻画阴影衰落效应。因此有障环境中能量域多源定位的噪声模型为乘性噪声。本章主要研究阴影衰落信道下的能量域多源定位问题。

首先，对于阴影衰落下的能量域单源定位问题，通过在对数域中表示能量测量，可以将乘性噪声转化为加性噪声^[56-76]。然而，对于共信道多源定位问题而言，各定位节点的能量测量值是多个对数正态分布变量的线性叠加，在概率上是求和对数正态随机变量 (SLN)，在对数域中也无法将真实信号与噪声分离。更重要的是，因为对数正态分布的矩生成函数没有定义^[214]，所以 SLN 随机变量没有明确的概率分布表达式^[215]，进而无法对阴影衰落下的能量域多源定位问题直接提出基于最大似然估计、最小方差无偏估计、贝叶斯估计等经典估计准则的算法。这也是针对阴影衰落下基于能量域测量的多源定位，目前国内外鲜有确信的已发表研究成果的原因。

其次，求和对数正态变量广泛存在于期权定价、精算学、无线通信、大气科学、地质学等诸多领域中，诸多研究者对 SLN 变量的分布函数展开了一系列研究。文献综述表明，Dixon (1932 年) 最早研究 SLN 分布的逼近方法^[216]，Wilkinson (1934 年) 第一次提出用对数正态分布逼近 SLN 分布的思想^[216]。在 Wilkinson 的基础上，Fenton (1960 年) 正式提出基于矩匹配的 SLN 分布逼近方法，即著名的 Fenton-Wilkinson 方法^[215]。随后该方法被跟进研究，提出了 Schwartz-Yeh 方法 (1982 年)^[217]、Beaulieu-Xie 方法^[218]。Mitchell (1968 年) 最早提出了基于级数展开的逼近方法^[219]，启发了一系列后续研究。Dufresne (2004 年) 证明当各对数正态分量的方差趋近于 0 时，依据不同的归一化处理，求和对数正态分布趋近于对数正态分布或正态分布^[220]。Wu 等人 (2005 年) 基于 Laplace 变换提出了用对数正态分布逼近 SLN 分布的方法^[221]，随后该团队又提出了一种更灵活的逼近方法^[222]。Liu 等人 (2008 年) 提出基于对数正态幂律分布的逼近方法^[223]。Li 等人 (2011 年) 提出基于变换的偏态正态分布的逼近方法^[223]。近五年来，诸如 Norman C. Beaulieu 等学者研究了 SLN 分布的一系列数值逼近方法^[224-226]。目前，SLN 分布函数的性质和逼近方法仍是数学领域中的开放问题。

综上所述，处理 SLN 随机变量相关问题的基本范式是先通过合适的逼近方法对 SLN 分布函数进行逼近，然后再基于逼近分布进行后续的处理和推断。在众多逼近方法中，Fenton-Wilkinson 方法简单有效，且具有闭式表达。自 2018 年来，Zandi 等人针对阴影衰落信道下的能量域多源定位问题根据 Fenton-Wilkinson 逼近方法先后




图 6-1 阴影衰落下能量域多源定位示意图

提出了基于混合整数规划和压缩感知的多源定位方法^[227-228]。Zandi 等人工作具有重要的启发意义，但其定位性能仍有待提升。

本章研究指出, Zandi 等人基于最小均方误差 (Minimum Mean Square Error, MMSE) 的估计方法未能充分利用逼近分布的信息, 阻碍了定位精度的进一步提升。为克服该方法的不足, 本章提出一种新颖的两阶段最大似然多源定位方法 (Two-Stage Maximum Likelihood, TSML)。TSML 算法包含捕获阶段和跟踪阶段。在捕获阶段, TSML 算法利用稀疏表征和聚类技术快速捕获辐射源参数的合理初值。在跟踪阶段, TSML 算法基于 Fenton-Wilkinson 方法和最大似然估计准则进一步校正辐射源参数, 并获得多个辐射源的位置和功率的最终估计。

本章的创新点有: (1) 指出了现有方法难以进一步提升定位精度的原因; (2) 针对阴影衰落下的能量域多源定位, 提出了一种新颖的两阶段最大似然多源定位算法 TSML; (3) 分析了 TSML 算法的时间复杂度和算法收敛性; (4) 通过仿真验证了所提算法的有效性和优越性。

本章内容安排如下: 6.2 节介绍阴影衰落下的多源定位模型; 6.3 节介绍提出的两阶段最大似然多源定位算法 TSML; 6.4 节讨论算法性能的仿真结果; 6.5 节给出相关推导过程; 6.6 节对本章进行小结。

6.2 阴影衰落下的能量域多源定位模型

阴影衰落下的能量域多源定位场景如图 6-1 所示。不妨以 $[0, w] \times [0, h]$ 二维感知区域为例, 假设在有障的感知区域内随机分布着 M 个能量定位节点和 K 个辐射源, 定位节点位置集合为 $\mathcal{S} = \{\mathbf{s}_i = (u_i^s, v_i^s), i=1, 2, \dots, M\}$, 辐射源位置集合为 $\mathcal{T} = \{\mathbf{q}_k = (u_k^t, v_k^t), k=1, 2, \dots, K\}$ 。研究表明^[56-76], 当传播路径上出现随机障碍物时, 辐射源 k 传播到第 i 个定位节点处的功率 P_{ik} 可被建模成对数正态阴影衰落模型:

$$10 \lg P_{ik} = 10 \lg P_k - 10\gamma \lg\left(\frac{d_{ik}}{d_0}\right) + n_{ik} \quad (6-1)$$

其中, d_0 为参考距离, P_k 为辐射源 k 在参考距离处的功率, 单位为 mW, γ 为路损指数, $d_{ik} = \|\mathbf{s}_i - \mathbf{q}_k\|_2$ 为辐射源 k 到定位节点 i 的距离, $n_{ik} \sim \mathcal{N}(0, [\sigma_{ik}]_{\text{dB}}^2)$ 表示该传播

路径上的随机阴影衰落，单位为 dB。在无线通信中， γ 的取值视具体传播环境而变化。经验上，自由空间中为 2，全开放环境中为 2 ~ 2.5，半开放环境中为 2.5 ~ 3.0，较封闭的环境为 3.0 ~ 3.5。阴影衰落标准差 $[\sigma_{ik}]_{\text{dB}}$ 的典型值为 4 ~ 10 dB^[229]。

本文研究共信道多源定位问题，这意味着第 i 个定位节点的接收功率 r_i 是多个辐射源功率的线性混叠：

$$r_i = \sum_{k=1}^K \underbrace{c_{ik} P_k \left(\frac{d_{ik}}{d_0} \right)^{-\gamma}}_{r_{ik}} 10^{\frac{n_{ik}}{10}} + \varepsilon_i \quad (6-2)$$

其中， ε_i 表示诸如电子热噪声等的加性测量噪声项，系数 c_{ik} 为^[10]

$$c_0 = \frac{G_t \mathcal{L}_t^{-1} G_r \mathcal{L}_r^{-1} \lambda^2}{(4\pi)^2} \quad (6-3)$$

这里， $G_t(G_r)$ 和 $\mathcal{L}_t(\mathcal{L}_r)$ 分别表示发射天线(接收天线)的天线增益和系统损耗因子， λ 是发射信号的波长。

一方面，定位节点的检测门限一般远高于接收灵敏度。另一方面，一定程度上可通过噪声功率的盲估计方法来消除加性噪声的影响。所以和加性测量噪声相比，阴影衰落对接收信号功率的影响更为显著。在接下来的建模和分析中，本文假设加性噪声项的影响可以被忽略。不失一般性，接下来令 $c_{ik} = 1$ ， $d_0 = 1\text{m}$ 。为进一步简化模型以凸显研究重点，本文假设所有辐射源-定位节点传播路径上的阴影衰落项 n_{ik} 是独立同分布的，即对 $i = 1, 2, \dots, M$ ， $k = 1, 2, \dots, K$ ，有 $[\sigma_{ik}]_{\text{dB}}^2 = \sigma_s^2$ ， $n_{ik} \sim \mathcal{N}(0, \sigma_s^2)$ 。

综上，本章研究的观测模型为

$$r_i = \sum_{k=1}^K r_{ik} = \sum_{k=1}^K P_k d_{ik}^{-\gamma} 10^{\frac{n_{ik}}{10}}, \quad n_{ik} \sim \mathcal{N}(0, \sigma_s^2) \quad (6-4)$$

阴影衰落下的能量域多源定位问题指如何根据已知的定位节点位置集合 $\mathcal{S}$ 和定位节点能量测量 r_i ， $i = 1, 2, \dots, M$ ，求解未知的辐射源位置集合 $\mathcal{T}$ 。

从式(6-4)可以看出， r_i 是 K 个对数正态随机变量 r_{ik} 的累加，数学上称其为求和对数正态 (SLN) 随机变量。如引言所述，SLN 随机变量没有明确的概率分布表达式^[215]，无法对阴影衰落下的能量域多源定位问题直接提出基于最大似然估计、最小方差无偏估计、贝叶斯估计等经典估计准则的算法。

6.3 基于稀疏表征和分布逼近的两阶段最大似然多源定位

文献分析表明，处理 SLN 随机变量相关问题的范式是“逼近-推理”方法，即先找到合适的概率分布逼近 SLN 分布，然后基于逼近分布进行后续的推断和处理。本小节根据“逼近-推理”范式，针对阴影衰落下的共信道多源定位问题，提出基于稀疏表征和 Fenton-Wilkinson (F-W) 逼近方法的两阶段最大似然多源定位方法。下文分别介绍传统的基于 F-W 逼近方法的 MMSE 多源定位算法和提出的两阶段最大似然多源定位算法。

6.3.1 基于 F-W 逼近方法的 MMSE 多源定位

在众多逼近方法中，F-W 方法^[215]简单有效，且具有闭式表达，因此被研究人员广泛使用。F-W 方法旨在用对数正态分布逼近 SLN 分布。虽然 SLN 随机变量的分布函数没有明确表达，但其各阶中心矩均有显式表示。F-W 方法通过匹配 SLN 随机变量的一阶和二阶中心矩来确定对数正态逼近分布的参数。

基于 F-W 方法，本文将 SLN 随机变量 $r_i = \sum_{k=1}^K r_{ik}$ 近似成对数正态随机变量 ζ_i ，其中， $\ln \zeta_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$ 。

首先，对数正态随机变量 ζ_i 的均值 $\mathbb{E}\{\zeta_i\}$ 和方差 $\mathbb{D}\{\zeta_i\}$ 为^[215]

$$\mathbb{E}\{\zeta_i\} = e^{\mu_i + \frac{\sigma_i^2}{2}}, \quad \mathbb{D}\{\zeta_i\} = (e^{\sigma_i^2} - 1)e^{2\mu_i + \sigma_i^2} \quad (6-5)$$

其次，SLN 随机变量 r_i 的均值 $\mathbb{E}\{r_i\}$ 和方差 $\mathbb{D}\{r_i\}$ 为

$$\mathbb{E}\{r_i\} = \beta \sum_{k=1}^K P_k d_{ik}^{-\gamma}, \quad \mathbb{D}\{r_i\} = \bar{\beta} \sum_{k=1}^K (P_k d_{ik}^{-\gamma})^2 \quad (6-6)$$

其中， $\beta = \exp\{\frac{(\ln 10)^2 \sigma_s^2}{200}\}$ ， $\bar{\beta} = \beta^2 (\beta^2 - 1)$ 均为常数。式(6-6)的详细推导见 6.5.1 小节。

最后，基于式(6-5)和式(6-6)，通过匹配均值和协方差：

$$\mathbb{E}\{r_i\} = \mathbb{E}\{\zeta_i\}, \quad \mathbb{D}\{r_i\} = \mathbb{D}\{\zeta_i\} \quad (6-7)$$

可求解出均值 μ_i 和方差 σ_i^2 为

$$\mu_i = 2 \ln \mathbb{E}\{r_i\} - \frac{1}{2} \ln (\mathbb{E}^2\{r_i\} + \mathbb{D}\{r_i\}), \quad \sigma_i^2 = \ln (\mathbb{E}^2\{r_i\} + \mathbb{D}\{r_i\}) - 2 \ln \mathbb{E}\{r_i\} \quad (6-8)$$

综上所述，可知 $\ln r_i$ 近似服从如下正态分布：

$$\ln r_i \sim \mathcal{N}(\mu_i, \sigma_i^2) \quad (6-9)$$

针对阴影衰落下共信道多源定位问题，Zandi 等人基于上述逼近方法和最小均方误差准则提出了一种 MMSE 多源定位算法^[227]。其目标优化式为

$$\min_{\mathcal{T}, \mathcal{P}} \sum_{i=1}^M (\ln r_i - \mu_i)^2 \quad (6-10a)$$

$$\text{s.t. } 0 \leq u_k^t \leq w, \quad 0 \leq v_k^t \leq h, \quad \underline{P} \leq P_k \leq \bar{P}, \quad k = 1, 2, \dots, K \quad (6-10b)$$

$$\mu_i = 2 \ln \mathbb{E}\{r_i\} - \frac{1}{2} \ln (\mathbb{E}^2\{r_i\} + \mathbb{D}\{r_i\}), \quad i = 1, 2, \dots, M \quad (6-10c)$$

$$\mathbb{E}\{r_i\} = \beta \sum_{k=1}^K P_k d_{ik}^{-\gamma}, \quad \mathbb{D}\{r_i\} = \bar{\beta} \sum_{k=1}^K (P_k d_{ik}^{-\gamma})^2, \quad i = 1, 2, \dots, M \quad (6-10d)$$

其中， $\mathcal{P} = \{P_1, P_2, \dots, P_K\}$ 。式(6-10a)中的目标函数为 MMSE 代价函数，约束(6-10b)确保辐射源位置在感知区域内，辐射源功率在已知的功率区间 $[\underline{P}, \bar{P}]$ 内。

通常，在观测模型 $y = x + n$ 中噪声 n 与信号 x 无关，所以对信号 x 的 MMSE 估计 $\hat{x} = \arg \min_x \|x - \mu\|_2^2$ 是有效的。通过分析式(6-8)和式(6-10)可以发现，式(6-9)中的均值 μ_i 和方差 σ_i^2 均是观测数据 $\ln r_i$ 的函数，所以优化问题(6-10)中仅通过最小化 MMSE 匹配均值 μ_i 并不符合 MMSE 估计的一般原理。因为其未充分考虑方差 σ_i^2 中的信息，所以其不能充分利用观测数据提供的信息，致使定位性能受限。接下来，本

章基于逼近分布式(6-9)，提出基于最大似然估计的多源定位算法。

6.3.2 两阶段最大似然多源定位

本节提出基于稀疏表征和分布逼近的两阶段最大似然多源定位方法，其包含辐射源参数捕获阶段和辐射源参数跟踪阶段，前者指对辐射源功率、位置的粗估计，后者指对辐射源功率、位置估计的细调整。下文从优化算法的逻辑先给出辐射源参数跟踪方法，然后由跟踪算法对初值较为敏感引出辐射源参数捕获算法。

6.3.2.1 辐射源参数跟踪阶段

为克服“逼近-MMSE”方法的不足，本小节基于最大似然估计原理利用逼近分布 $\ln r_i \sim \mathcal{N}(\mu_i, \sigma_i^2)$ 提出“逼近-ML”多源定位方法。

首先，令 $\boldsymbol{\theta} = [u_1^t, v_1^t, P_1, u_2^t, v_2^t, P_2, \dots, u_K^t, v_K^t, P_K]^T$ 为待估计的辐射源参数。由式(6-9)可知，观测数据 $[\ln r_1, \ln r_2, \dots, \ln r_M]$ 的对数似然函数 $\ell(\boldsymbol{\theta})$ 为

$$\begin{aligned} \ell(\boldsymbol{\theta}) &= \ln p(\ln r_1, \ln r_2, \dots, \ln r_M | \boldsymbol{\theta}) = \ln \left(\prod_{i=1}^M \frac{1}{\sqrt{2\pi\sigma_i^2}} e^{-\frac{(\ln r_i - \mu_i)^2}{2\sigma_i^2}} \right) \\ &= -\frac{1}{2}M \ln(2\pi) - \frac{1}{2} \sum_{i=1}^M \ln \sigma_i^2 - \sum_{i=1}^M \frac{(\ln r_i - \mu_i)^2}{2\sigma_i^2} \end{aligned} \quad (6-11)$$

所以，关于 $\boldsymbol{\theta}$ 最大化对数似然函数 $\ell(\boldsymbol{\theta})$ 等价于如下最小化问题

$$\min_{\boldsymbol{\theta}} f(\boldsymbol{\theta}) = \sum_{i=1}^M \left(\ln \sigma_i^2 + \frac{(\ln r_i - \mu_i)^2}{\sigma_i^2} \right) \quad (6-12a)$$

$$\text{s.t. } 0 \leq u_k^t \leq w, 0 \leq v_k^t \leq h, \underline{P} \leq P_k \leq \overline{P}, k = 1, 2, \dots, K \quad (6-12b)$$

$$\mu_i = 2 \ln \mathbb{E}\{r_i\} - \frac{1}{2} \ln (\mathbb{E}^2\{r_i\} + \mathbb{D}\{r_i\}), i = 1, 2, \dots, M \quad (6-12c)$$

$$\sigma_i^2 = \ln (\mathbb{E}^2\{r_i\} + \mathbb{D}\{r_i\}) - 2 \ln \mathbb{E}\{r_i\}, i = 1, 2, \dots, M \quad (6-12d)$$

$$\mathbb{E}\{r_i\} = \beta \sum_{k=1}^K P_k d_{ik}^{-\gamma}, \mathbb{D}\{r_i\} = \overline{\beta} \sum_{k=1}^K (P_k d_{ik}^{-\gamma})^2, i = 1, 2, \dots, M \quad (6-12e)$$

优化问题(6-12)和优化问题(6-10)的区别在于优化目标函数，式(6-12a)中的目标函数是观测数据的对数似然函数，不仅考虑了 MMSE 项 $(\ln r_i - \mu_i)^2$ ，也考虑了方差项 $\ln \sigma_i^2$ 。从数值优化的角度来看，式(6-12a)中的方差项 $\ln \sigma_i^2$ 相当于对 MMSE 项 $(\ln r_i - \mu_i)^2$ 引入最小方差正则约束， $(\ln r_i - \mu_i)^2 / \sigma_i^2$ 相当对 MMSE 项 $(\ln r_i - \mu_i)^2$ 引入了权重项 $\frac{1}{\sigma_i^2}$ ，可视为加权最小二乘方法。最后，因为 μ_i 和 σ_i^2 均是目标变量 $\boldsymbol{\theta}$ 的非凸非线性函数，所以式(6-12a)中的目标函数 $f(\boldsymbol{\theta})$ 也是非凸非线性的。优化问题(6-12)是一个边界约束的非凸优化问题。存在诸多成熟的优化算法可求解约束的非线性优化问题(6-12)，如内点法、乘子法、梯度投影法等。

本章基于贯序二次规划原理 (Sequential Quadratic Programming, SQP) 求解问题(6-12)。首先，记 $\underline{\boldsymbol{\theta}} = \mathbf{1}_3 \otimes [0, 0, \underline{P}]^T$ ， $\overline{\boldsymbol{\theta}} = \mathbf{1}_3 \otimes [0, 0, \overline{P}]^T$ 分别表示 $\boldsymbol{\theta}$ 的上下界，

令 $\mathbf{h}(\boldsymbol{\theta}) = [(\bar{\boldsymbol{\theta}} - \boldsymbol{\theta})^T, (\boldsymbol{\theta} - \underline{\boldsymbol{\theta}})^T]^T$ ，则问题(6-12)的边界约束为 $\mathbf{h}(\boldsymbol{\theta}) \succeq \mathbf{0}$ 。问题(6-12)的拉格朗日函数为

$$L(\boldsymbol{\theta}, \boldsymbol{\lambda}) = f(\boldsymbol{\theta}) - \boldsymbol{\lambda}^T \mathbf{h}(\boldsymbol{\theta}) \quad (6-13)$$

其中， $\boldsymbol{\lambda} = [\lambda_1, \lambda_2, \dots, \lambda_{3K}]^T \succeq \mathbf{0}$ 为不等式约束的拉格朗日乘子向量。

给定当前估计点 $(\boldsymbol{\theta}^{(l)}, \boldsymbol{\lambda}^{(l)})$ ，令 $\mathbf{A}(\boldsymbol{\theta}) = [\nabla_{\boldsymbol{\theta}} h_1(\boldsymbol{\theta}), \dots, \nabla_{\boldsymbol{\theta}} h_{3K}(\boldsymbol{\theta})]^T$ 为约束函数 $\mathbf{h}(\boldsymbol{\theta})$ 关于 $\boldsymbol{\theta}$ 的 Jacobi 矩阵，则基于迭代下降方法最小化拉格朗日函数 $L(\boldsymbol{\theta}, \boldsymbol{\lambda})$ 的更新步骤为

$$\boldsymbol{\theta}^{(l+1)} = \boldsymbol{\theta}^{(l)} + \alpha_l \mathbf{d}^{(l)} \quad (6-14a)$$

$$\boldsymbol{\lambda}^{(l+1)} = \arg \min_{\boldsymbol{\lambda}} \|\nabla_{\boldsymbol{\theta}} f(\boldsymbol{\theta}^{(l+1)}) - \mathbf{A}(\boldsymbol{\theta}^{(l+1)})^T \boldsymbol{\lambda}\| \quad (6-14b)$$

为避免式(6-14a)中因计算拉格朗日函数 $L(\boldsymbol{\theta}, \boldsymbol{\lambda})$ 关于 $\boldsymbol{\theta}$ 的 Hessian 矩阵 $\nabla_{\boldsymbol{\theta}\boldsymbol{\theta}}^2 L(\boldsymbol{\theta}, \boldsymbol{\lambda})$ 带来的复杂度，本文采用拟牛顿下降方法确定下降方向 $\mathbf{d}^{(l)}$ ：

$$\begin{aligned} \mathbf{d}^{(l)} &= \arg \min_{\mathbf{d}} \frac{1}{2} \mathbf{d}^T \mathbf{B}^{(l)} \mathbf{d} + \nabla_{\boldsymbol{\theta}} f(\boldsymbol{\theta}^{(k+1)})^T \mathbf{d} \\ \text{s.t. } &\mathbf{h}(\boldsymbol{\theta}^{(l)}) + \mathbf{A}(\boldsymbol{\theta}^{(l)}) \mathbf{d} \succeq \mathbf{0} \end{aligned} \quad (6-15)$$

其中， $\mathbf{B}^{(l)} \in \mathbb{R}_{++}^{3K \times 3K}$ 为对 $\nabla_{\boldsymbol{\theta}\boldsymbol{\theta}}^2 L(\boldsymbol{\theta}, \boldsymbol{\lambda})$ 的近似，且为对称正定矩阵。问题(6-15)为严格凸二次规划问题，局部最优解即全局最优点，且能在多项式时间复杂度内求解。

本文采用 Armijio 准则对步长因子 α_l 进行非精确线搜索，即对于选定的价值函数 $\phi(\boldsymbol{\theta}, \sigma)$ ，选择罚参数 σ_l ，使得 $\mathbf{d}^{(l)}$ 是价值函数在 $\boldsymbol{\theta}^{(l)}$ 处的下降方向，然后设 m_l 是满足如下不等式的最小非负整数 m

$$\phi(\boldsymbol{\theta}^{(l)} + \rho^m \mathbf{d}^{(l)}, \sigma_l) - \phi(\boldsymbol{\theta}^{(l)}, \sigma_l) \leq \eta \rho^m \phi'(\boldsymbol{\theta}^{(l)}, \sigma_l; \mathbf{d}^{(l)}) \quad (6-16)$$

则步长因子 $\alpha_l = \rho^{m_l}$ 。式中， $\eta \in (0, 0.5)$ ， $\rho \in (0, 1)$ 。

式(6-14b)中的优化问题为最小二乘问题，其最优解为

$$\boldsymbol{\lambda}^{(l+1)} = [\mathbf{A}(\boldsymbol{\theta}^{(l+1)})^T]^\dagger \nabla_{\boldsymbol{\theta}} f(\boldsymbol{\theta}^{(l+1)}) \quad (6-17)$$

获得 $\mathbf{d}^{(l)}$ ， α_l ， $\boldsymbol{\theta}^{(l+1)}$ ， $\boldsymbol{\lambda}^{(l+1)}$ 后，本文基于 BFGS 算法校正矩阵 $\mathbf{B}^{(l)}$

$$\mathbf{B}^{(l+1)} = \mathbf{B}^{(l)} - \frac{\mathbf{B}^{(l)} \mathbf{s}_l \mathbf{s}_l^T \mathbf{B}^{(l)}}{\mathbf{s}_l^T \mathbf{B}^{(l)} \mathbf{s}_l} + \frac{\mathbf{z}_l \mathbf{z}_l^T}{\mathbf{s}_l^T \mathbf{z}_l} \quad (6-18)$$

其中， $\mathbf{s}_l = \alpha_l \mathbf{d}_l$ ， $\mathbf{y}_l = \nabla_{\boldsymbol{\theta}} L(\boldsymbol{\theta}^{(l+1)}, \boldsymbol{\lambda}^{(l+1)}) - \nabla_{\boldsymbol{\theta}} L(\boldsymbol{\theta}^{(l)}, \boldsymbol{\lambda}^{(l+1)})$ ， $\mathbf{z}_l = \omega_l \mathbf{y}_l + (1 - \omega_l) \mathbf{B}^{(l)} \mathbf{s}_l$ ，

$$\omega_l = \begin{cases} 1, & \mathbf{s}_l^T \mathbf{y}_l \geq 0.2 \mathbf{s}_l^T \mathbf{B}^{(l)} \mathbf{s}_l \\ \frac{0.8 \mathbf{s}_l^T \mathbf{B}^{(l)} \mathbf{s}_l}{\mathbf{s}_l^T \mathbf{B}^{(l)} \mathbf{s}_l - \mathbf{s}_l^T \mathbf{y}_l}, & \mathbf{s}_l^T \mathbf{y}_l < 0.2 \mathbf{s}_l^T \mathbf{B}^{(l)} \mathbf{s}_l \end{cases}$$

6.3.2.2 辐射源参数捕获阶段

目标函数 $f(\boldsymbol{\theta})$ 非凸且存在多个局部最优点，跟踪阶段提出的下降类算法对初值敏感，所以良好的初值对提高估计精度尤为重要。本小节根据第五章的研究，提出一种基于快速证据下界最大化稀疏贝叶斯学习的辐射源参数快速捕获算法。

首先，当 n_{ik} 足够小时，由泰勒级数展开有 $10^{\frac{n_{ik}}{10}} \approx 1 + \frac{\ln 10}{10} n_{ik}$ 。在该近似下，

式(6-4)可被表示成

$$r_i = \sum_{k=1}^K P_k d_{ik}^{-\gamma} + n_i, \quad n_i = \sum_{k=1}^K P_k d_{ik}^{-\gamma} \frac{\ln 10}{10} n_{ik} \quad (6-19)$$

其次，对辐射源位置空间进行网格化，设网格集合为 $\mathcal{G} = \{\mathbf{g}_j = (u_j, v_j), j = 1, 2, \dots, N\}$ ，并假设辐射源位置集合 $\mathcal{T}$ 是 $\mathcal{G}$ 的真子集。令 $\mathbf{y} = [r_1, r_2, \dots, r_M]^T$ ， $[\Phi]_{ij} = d_{ij}^{-\gamma}$ ， $\mathbf{n} = [n_1, n_2, \dots, n_M]^T$ ， $d_{ij} = \|\mathbf{s}_i - \mathbf{g}_j\|_2$ ，则模型(6-19)的矩阵-向量形式为

$$\mathbf{y} = \Phi \mathbf{x} + \mathbf{n}, \quad x_j = \begin{cases} 0, & \forall k \in 1, 2, \dots, K, \text{ 均有 } \mathbf{g}_j \neq \mathbf{e}_k \\ P_k & \exists k \in 1, 2, \dots, K, \text{ 满足 } \mathbf{g}_j = \mathbf{e}_k \end{cases} \quad (6-20)$$

可以发现，模型(6-20)和无障环境中的多源定位模型具有相同的表示，而第三章到第五章中已对无障环境中的多源定位问题做了较为深入的研究，所以，可以用第三章到第五章的相关算法来求解模型(6-20)对应的如下稀疏恢复问题

$$\min_{\mathbf{x}} \|\mathbf{y} - \Phi \mathbf{x}\|_2 + \lambda \|\mathbf{x}\|_1 \quad (6-21)$$

因为模型(6-19)仅在 σ_s^2 足够小的情况下成立，所以对该模型进行字典学习无显著意义。其次，密集划分下 $\mathcal{G}$ 中的网格点数目可达数千到数万个，因而稀疏恢复算法的计算复杂度和系统辨识能力的重要性凸显。基于以上两点，本文采用第五章提出的快速证据下界最大化稀疏贝叶斯学习算法 FEMSBL 算法来求解问题(6-20)。

由于在阴影衰落方差 σ_s^2 较大的情况下，模型(6-20)与真实模型(6-4)存在一定偏差，所以在 FEMSBL 算法求解的稀疏向量 $\mathbf{x}$ 中，辐射源能量将被分散到真实辐射源位置附近的网格点上。因此，本文对 FEMSBL 的模型网格点进行 K-means 聚类，对每一个聚类按照估计的功率对其中的网格点进行加权平均获得聚类中心 $\mathbf{c}_k = (u_k^c, v_k^c)$ ，并将该聚类中所有网格点的功率和作为该聚类中心的功率 P_k^c 。令 $\hat{\mathbf{x}}$ 为 FEMSBL 算法的估计结果(非模型网格点的值为 0)， $\Pi_k, k = 1, 2, \dots, K$ 为 K-means 算法对 FEMSBL 算法的模型网格点划分的 K 个聚类，则 u_k, v_k, P_k^c 可表达为

$$u_k^c = \frac{\sum_{j \in \Pi_k} \hat{x}_j u_j}{\sum_{j \in \Pi_k} \hat{x}_j}, \quad v_k^c = \frac{\sum_{j \in \Pi_k} \hat{x}_j v_j}{\sum_{j \in \Pi_k} \hat{x}_j}, \quad P_k^c = \sum_{j \in \Pi_k} \hat{x}_j \quad (6-22)$$

最后，捕获的向量 $\boldsymbol{\theta}^{(0)} = [u_1^c, v_1^c, P_1^c, \dots, u_K^c, v_K^c, P_K^c]^T$ 将作为跟踪阶段算法的初值。




图 6-2 基于聚类加权的辐射源位置捕获结果

设 $\gamma = 2.5, \sigma_s = 5 \text{ dB}, K = 3, M = 100, \underline{P} = 10 \text{ KW}, \bar{P} = 20 \text{ KW}$, 定位区域为 $40 \text{ Km} \times 20 \text{ Km}$ 的矩形区域, 网格 $\mathcal{G}$ 为 100×50 的均匀网格, 图6-2显示了对 FEMSBL 算法的模型网格点进行聚类的结果, 其中所有点的大小表示其估计 (或接收) 的功率的相对大小。从图6-2可见, 所提方法提供了一种较好的辐射源参数快速捕获方法。

6.3.3 算法流程

Algorithm 6.1: 两阶段最大似然多源定位算法 (TSML)

Input: 观测 $\mathbf{y}$, 辐射源数 K , 路损指数 γ , 衰落标准差 σ_s , 下界 $\underline{\theta}$ 、上界 $\bar{\theta}$, 网格 $\mathcal{G}$

- 1 选择参数 $\eta \in (0, 0.5), \rho \in (0, 1)$, 容许误差 $0 \leq \epsilon_1, \epsilon_2 \ll 1$, 最大迭代次数 L ;
- 2 // 辐射源参数捕获阶段
- 3 由 $\mathcal{G}, \gamma$ 构造字典 Φ ;
- 4 根据 $\mathbf{y}$ 和 Φ 用 FEMSBL 算法获得模型网格点和 $\hat{\mathbf{x}}$;
- 5 对模型网格点用 K-means 算法聚类, 并依据式(6-22)计算辐射源参数的捕获初值 $\boldsymbol{\theta}^{(0)}$;
- 6 // 辐射源参数跟踪阶段
- 7 令 $l = 0, \mathbf{d}^{(0)} = \mathbf{1}_{3K}, \mathbf{B}^{(0)} = \mathbf{I}_{3K}$;
- 8 **while** $\|\mathbf{d}^{(l)}\|_1 > \epsilon_1$ 且 $\|\mathbf{h}(\boldsymbol{\theta}^{(l)})\|_1 > \epsilon_2$ 且 $l \leq L$ **do**
- 9 求解严格凸二次规划问题(6-15), 得到最优解 $\mathbf{d}^{(l)}$;
- 10 按 Armijio 准则求满足式(6-16)的最小非负整数 m_l , 令 $\alpha_l = \rho^{m_l}, \boldsymbol{\theta}^{(l+1)} = \boldsymbol{\theta}^{(l)} + \alpha_l \mathbf{d}^{(l)}$;
- 11 依式(6-17)更新拉格朗日乘子向量 $\boldsymbol{\lambda}^{(l+1)}$;
- 12 根据 BFGS 算法依式(6-18)校正矩阵 $\mathbf{B}^{(l)}$, 得到 $\mathbf{B}^{(l+1)}$;
- 13 $l = l + 1$;

Output: 辐射源参数 $\hat{\boldsymbol{\theta}} = \boldsymbol{\theta}^{(l+1)}$

算法6.1总结了基于稀疏表征和 F-W 逼近方法的两阶段最大似然多源定位算法 (Two-Stage Maximum Likelihood, TSML)。

步骤 (4) 中 FEMSBL 算法的具体细节参考5.2.3小节。步骤 (8) 中收敛条件能保证跟踪算法能得到原问题(6-12)的一个近似 KKT 点。步骤 (10) 中, 本文选择 ℓ_1 价值函数, 即

$$\phi(\boldsymbol{\theta}, \sigma) = f(\boldsymbol{\theta}) + \sigma^{-1} \|\mathbf{h}(\boldsymbol{\theta})\|_1 \quad (6-23)$$

并令 $\tau = \|\boldsymbol{\lambda}\|_2$, 任取 $\delta > 0$, 罚参数 σ 的修正规则为

$$\sigma_{l+1} = \begin{cases} \sigma_l, & \sigma_l^{-1} \geq \tau + \delta \\ (\tau + 2\delta)^{-1}, & \sigma_l^{-1} < \tau + \delta \end{cases} \quad (6-24)$$

在步骤 (12) 中, BFGS 算法用秩 2 矩阵校正 $\mathbf{B}^{(l)}$, 得到 $\mathbf{B}^{(l+1)}$ 。定理6.1表明若初始矩阵 $\mathbf{B}^{(0)}$ 是对称正定的, 且在迭代过程中恒满足 $\mathbf{y}_l^T \mathbf{s}_l > 0$, 则由 BFGS 校正公式(6-18)得到的矩阵序列 $\{\mathbf{B}^{(l)}\}$ 是对称正定的, 从而问题(6-15)恒为严格凸二次规划问题, 能够在多项式时间内获得下降方向 $\mathbf{d}^{(l)}$ 。

定理 6.1 (文献^[230]) 设 $\mathbf{B}^{(l)}$ 对称正定, $\mathbf{B}^{(l+1)}$ 由 BFGS 校正公式(6-18)确定, 则 $\mathbf{B}^{(l+1)}$ 对称正定的充要条件为 $\mathbf{y}_l^T \mathbf{s}_l > 0$ 。

最后, 算法6.1需提供目标函数 $f(\boldsymbol{\theta})$ 关于辐射源参数的梯度 $\nabla_{\boldsymbol{\theta}} f(\boldsymbol{\theta})$ 、约束函数 $h(\boldsymbol{\theta})$ 关于 $\boldsymbol{\theta}$ 的 Jacobi 矩阵 $\mathbf{A}(\boldsymbol{\theta})$ 。6.5.2小节给出了 $\nabla_{\boldsymbol{\theta}} f(\boldsymbol{\theta})$ 和 $\mathbf{A}(\boldsymbol{\theta})$ 的具体计算公式。

6.3.4 算法复杂度和收敛性分析

由第五章中对 FEMSBL 算法的分析可知, FEMSBL 算法的复杂度为 $\mathcal{O}(MN)$ 。K-means 算法的复杂度为 $\mathcal{O}(KM)$ 。由文献^[231]的分析可知, 跟踪阶段的 SQP 算法复杂度为 $\mathcal{O}(K^4)$ 。所以, TSML 算法的时间复杂度为 $\mathcal{O}(MN + KM + K^4)$ 。通常有 $K < M < N, K \ll N$, 所以 TSML 的算法复杂度由 FEMSBL 算法主导, 当 $K \ll M$ 时, TSML 的渐进复杂度为 $\mathcal{O}(MN)$ 。

捕获阶段仅提供一个较好的初值, TSML 算法的收敛性取决于跟踪阶段。在一定条件下, 可以证明跟踪阶段算法的全局收敛性。定理6.2给出了相应结果。

定理 6.2 对于约束的非线性优化问题(6-12), 设目标函数 $f(\boldsymbol{\theta})$ 和约束函数 $h(\boldsymbol{\theta})$ 均连续可微, 且存在常数 $0 < m_1 \leq m_2$, 使得跟踪算法中的对称正定矩阵 $\mathbf{B}^{(l)}$ 满足

$$m_1 \|\mathbf{d}\|_2^2 \leq \mathbf{d}^T \mathbf{B}^{(l)} \mathbf{d} \leq m_2 \|\mathbf{d}\|_2^2, \quad \forall \mathbf{d} \in \mathbb{R}^{3K}, l = 1, 2, \dots \quad (6-25)$$

若罚参数 $\sigma_l > 0$, 严格凸二次规划子问题(6-15)的拉格朗日乘子向量 $\boldsymbol{\lambda}^{(l+1)} \succeq \mathbf{0}$ 且满足

$$\sigma_l \|\boldsymbol{\lambda}^{(l)}\|_{\infty} \leq 1, \quad \forall l = 1, 2, \dots, \quad (6-26)$$

则步骤 (7)-步骤 (13) 的跟踪阶段算法生成的辐射源参数序列 $\{\boldsymbol{\theta}^{(l)}\}$ 的任何聚点均是问题(6-12)的 KKT 点。

证明: 见文献^[232]。 □

6.4 算法性能仿真

6.4.1 仿真设置

设在 $5\text{Km} \times 5\text{Km}$ 的全开放有障区域中随机分布着 M 个能量定位节点和 3 个辐射源, 参考距离 $d_0 = 1\text{m}$, $c_{ik} = 1$, 在 d_0 处的辐射源有效全向辐射功率的上界 $\bar{P} = 3\text{W}$, 下界为 $P = 2\text{W}$, 路损指数 $\gamma = 2.5$ 。测试的算法为提出的 TSML 算法, 对比算法为 MMSE 算法^[228]和 TSML 算法中的捕获算法。同时, 因文献^[228]中没有为 MMSE 算法提供恰当的辐射源参数初值, 所以在仿真中我们将 TSML 算法捕获的辐射源参数初值提供给 MMSE 算法, 来验证 ML 算法较 MMSE 算法带来的性能提升, 仿真中将该方法称为“捕获+MMSE”算法。捕获阶段的网格 $\mathcal{G}$ 为 25×25 的均匀矩形网格, 相邻网格间距为 200m 。评价指标为归一化均方根估计误差 (Normalized RMSE, NRMSE) 距离 d_{NRMSE} , 定义为

$$d_{\text{NRMSE}} = \frac{1}{\sqrt{S}} \sqrt{\frac{1}{K} \sum_{k=1}^K (\mathbf{e}_k - \hat{\mathbf{e}}_k)^2} \quad (6-27)$$

其中, $\hat{\mathbf{e}}_k$ 为第 k 个真实辐射源位置 $\mathbf{e}_k$ 的估计, S 为定位区域的面积。

接下来分别考察不同阴影衰落标准偏差和定位节点数目对定位性能的影响。蒙特卡洛仿真次数为 10000 次。仿真的硬件环境为：Intel Core i7-9750H 处理器，主频 3.5GHz，16G 内存；软件环境为：Windows 10 + Matlab R2019b。

6.4.2 仿真结果和分析




图 6-3 不同阴影衰落标准差下的辐射源定位误差 ($M = 100$)

6.4.2.1 阴影衰落深度的影响

令 $M = 100$ ，图 6-3 显示了不同阴影衰落标准差下的归一化均方根定位误差距离。从图 6-3 可以看出，定位误差随阴影衰落标准差的增大而增大，但在不同的阴影衰落标准差下，提出的 TSML 算法均显示出最低的定位误差。图 6-3(a) 显示，当 $\sigma_s = 4$ dB 时，TSML 算法的定位误差在 MMSE 的基础上降低了 53%。有意思的是，仅用捕获算法来进行定位就已经显示出比 MMSE 算法更高的定位精度，当把捕获算法的估计结果作为 MMSE 算法的初值时，能显著降低 MMSE 算法的定位误差，这验证了初值捕获算法的有效性，同时也说明 MMSE 算法对初值较为敏感，文献 [228] 中未能提供一种合理的初值捕获算法。图 6-3(b) 显示，当 $\sigma_s = 4$ dB 时，提出的 TSML 算法的归一化均方根定位误差小于 4% (绝对误差为 200m) 的概率高达 80%，而 MMSE 算法的概率仅为 25%。

6.4.2.2 定位节点数目的影响

令 $\sigma_s = 4$ dB，图 6-4 显示了不同定位节点数下的归一化均方根定位误差距离。从图 6-4(a) 可以看出，加入更多的定位节点可以有效降低定位误差，在不同的定位节点数目下，提出的 TSML 算法的定位精度均高于对比算法，且随着定位节点数目的增加，该增益不断增大。当定位节点个数为 140 时，TSML 算法的定位误差在 MMSE 算法的基础上降低了 71%。此时，从图 6-4(b) 可以看出，TSML 算法的归一化均方根定位误差小于 4% (绝对误差为 200m) 的概率高达 87%，而传统的 MMSE 算法的概率




图 6-4 不同定位节点数目下的辐射源定位误差

仅为 31%。

综上，可以看出提出的 TSML 方法能够更充分地利用观测数据和逼近分布提供的信息，从而有效提升传统 MMSE 方法的估计性能，实现更高的定位精度。

6.5 推导过程

6.5.1 式(6-6)的推导

首先， r_{ik} 的 l 阶中心矩 $\mathbb{E}\{r_{ik}^l\}$ 为

$$\begin{aligned}\mathbb{E}\{r_{ik}^l\} &= \mathbb{E}\left\{\left(P_k d_{ik}^{-\gamma} 10^{\frac{n_{ik}}{10}}\right)^l\right\} = (P_k d_{ik}^{-\gamma})^l \mathbb{E}\left\{10^{\frac{n_{ik}l}{10}}\right\} \\ &= (P_k d_{ik}^{-\gamma})^l \mathbb{E}\left\{e^{\ln 10 \frac{n_{ik}l}{10}}\right\} = (P_k d_{ik}^{-\gamma})^l \mathbb{E}\left\{e^{\frac{n_{ik}l \ln 10}{10}}\right\}\end{aligned}\quad (6-28)$$

由于 $n_{ik} \sim \mathcal{N}(0, \sigma_s^2)$ ，所以 $\frac{n_{ik}l \ln 10}{10} \sim \mathcal{N}(0, \frac{\sigma_s^2 l^2 (\ln 10)^2}{100})$ 。根据(6-5)可得， $\mathbb{E}\{e^{\frac{n_{ik}l \ln 10}{10}}\} = e^{\frac{\sigma_s^2 l^2 (\ln 10)^2}{200}}$ 。令 $\beta = \exp\{\frac{(\ln 10)^2 \sigma_s^2}{200}\}$ ，代入式(6-28)，得

$$\mathbb{E}\{r_{ik}^l\} = (P_k d_{ik}^{-\gamma})^l e^{\frac{\sigma_s^2 l^2 (\ln 10)^2}{200}} = (P_k d_{ik}^{-\gamma})^l \beta^{l^2}\quad (6-29)$$

最后，令 $\bar{\beta} = \beta^2 (\beta^2 - 1)$ ，有

$$\mathbb{E}\{r_i\} = \mathbb{E}\left\{\sum_{k=1}^K r_{ik}\right\} = \sum_{k=1}^K \mathbb{E}\{r_{ik}\} = \beta \sum_{k=1}^K P_k d_{ik}^{-\gamma}\quad (6-30a)$$

$$\mathbb{D}\{r_i\} = \mathbb{D}\left\{\sum_{k=1}^K r_{ik}\right\} = \sum_{k=1}^K \mathbb{D}\{r_{ik}\} = \sum_{k=1}^K (\mathbb{E}\{r_{ik}^2\} - \mathbb{E}\{r_{ik}\}^2) = \bar{\beta} \sum_{k=1}^K (P_k d_{ik}^{-\gamma})^2\quad (6-30b)$$

6.5.2 目标函数梯度和约束函数 Jacobi 矩阵的推导

$$\begin{aligned}\nabla_{\theta} f(\theta) &= \sum_{i=1}^M \left[\frac{1}{\sigma_i^2} \frac{\partial \sigma_i^2}{\partial \theta} - \frac{1}{\sigma_i^4} \left(2 (\ln r_i - \mu_i) \sigma_i^2 \frac{\partial \mu_i}{\partial \theta} + (\ln r_i - \mu_i)^2 \frac{\partial \sigma_i^2}{\partial \theta} \right) \right] \\ &= \sum_{i=1}^M \frac{1}{\sigma_i^2} \left[\left(1 - \frac{(\ln r_i - \mu_i)^2}{\sigma_i^2} \right) \frac{\partial \sigma_i^2}{\partial \theta} - 2 (\ln r_i - \mu_i) \frac{\partial \mu_i}{\partial \theta} \right]\end{aligned}\quad (6-31)$$

$$\frac{\partial \mu_i}{\partial \theta} = -\frac{1}{2 (\mathbb{E}^2\{r_i\} + \mathbb{D}\{r_i\})} \frac{\partial \mathbb{D}\{r_i\}}{\partial \theta} + \frac{\mathbb{E}^2\{r_i\} + 2\mathbb{D}\{r_i\}}{\mathbb{E}\{r_i\} (\mathbb{E}^2\{r_i\} + \mathbb{D}\{r_i\})} \frac{\partial \mathbb{E}\{r_i\}}{\partial \theta} \quad (6-32a)$$

$$\frac{\partial \sigma_i^2}{\partial \theta} = \frac{1}{\mathbb{E}^2\{r_i\} + \mathbb{D}\{r_i\}} \frac{\partial \mathbb{D}\{r_i\}}{\partial \theta} - \frac{2\mathbb{D}\{r_i\}}{\mathbb{E}\{r_i\} (\mathbb{E}^2\{r_i\} + \mathbb{D}\{r_i\})} \frac{\partial \mathbb{E}\{r_i\}}{\partial \theta} \quad (6-32b)$$

$$\frac{\partial \mathbb{E}\{r_i\}}{\partial \theta} = \left[\frac{\partial \mathbb{E}\{r_i\}}{\partial u_1^t}, \frac{\partial \mathbb{E}\{r_i\}}{\partial v_1^t}, \frac{\partial \mathbb{E}\{r_i\}}{\partial P_1}, \dots, \frac{\partial \mathbb{E}\{r_i\}}{\partial u_K^t}, \frac{\partial \mathbb{E}\{r_i\}}{\partial v_K^t}, \frac{\partial \mathbb{E}\{r_i\}}{\partial P_K} \right]^T \quad (6-33a)$$

$$\frac{\partial \mathbb{D}\{r_i\}}{\partial \theta} = \left[\frac{\partial \mathbb{D}\{r_i\}}{\partial u_1^t}, \frac{\partial \mathbb{D}\{r_i\}}{\partial v_1^t}, \frac{\partial \mathbb{D}\{r_i\}}{\partial P_1}, \dots, \frac{\partial \mathbb{D}\{r_i\}}{\partial u_K^t}, \frac{\partial \mathbb{D}\{r_i\}}{\partial v_K^t}, \frac{\partial \mathbb{D}\{r_i\}}{\partial P_K} \right]^T \quad (6-33b)$$

$$\frac{\partial \mathbb{E}\{r_i\}}{\partial u_k^t} = \gamma \beta P_k \frac{u_i^s - u_k^t}{d_{ik}^{\gamma+2}}, \quad \frac{\partial \mathbb{E}\{r_i\}}{\partial v_k^t} = \gamma \beta P_k \frac{v_i^s - v_k^t}{d_{ik}^{\gamma+2}}, \quad \frac{\partial \mathbb{E}\{r_i\}}{\partial P_k} = \beta d_{ik}^{-\gamma} \quad (6-34a)$$

$$\frac{\partial \mathbb{D}\{r_i\}}{\partial u_k^t} = 2\gamma \bar{\beta} P_k^2 \frac{u_i^s - u_k^t}{d_{ik}^{2\gamma+2}}, \quad \frac{\partial \mathbb{D}\{r_i\}}{\partial v_k^t} = 2\gamma \bar{\beta} P_k^2 \frac{v_i^s - v_k^t}{d_{ik}^{2\gamma+2}}, \quad \frac{\partial \mathbb{D}\{r_i\}}{\partial P_k} = 2\bar{\beta} P_k d_{ik}^{-2\gamma} \quad (6-34b)$$

$$\mathbf{A}(\theta) = [\mathbf{I}_{3K}, -\mathbf{I}_{3K}]^T \quad (6-35)$$

6.6 本章小结

本章基于“逼近-推理”范式研究了阴影衰落下的能量域多源定位问题，提出了一种新颖的两阶段最大似然多源定位算法 TSML。该算法利用 FEMSBL 算法和 K-means 聚类技术快速捕获辐射源参数的合理初值，然后利用 SQP 原理基于最大似然估计准则跟踪优化捕获的辐射源参数，最后估计出多个辐射源的位置和功率。此外，本章对 TSML 算法的时间复杂度和全局收敛性作出了理论分析。最后，仿真验证了所提算法有效性和优越性。

第七章 总结与展望

7.1 本文工作总结

本文针对基于稀疏表征的多源定位中存在的结构信息挖掘问题、基不匹配问题、维数灾难问题及阴影衰落信道下的多源定位问题等四个方面展开深入研究。本文的主要工作和创新点如下：

第一，通过分析能量域、角度域、时间域多源定位模型及相应多源定位问题，归纳出广义多源定位模型，抽象出广义多源定位问题。通过对辐射源参数域进行网格离散化，引出基于稀疏表征的广义多源定位问题。详细介绍了基于贪婪、优化、概率推理的稀疏恢复算法，并总结了各类算法的优缺点，为后续算法研究奠定基础。

第二，针对多源定位中的结构信息挖掘的问题，通过分析多源定位中的聚簇结构信息，提出了一种新颖的层级贪婪匹配算法 **HGMP**，证明了文献中广泛采用的正交化预处理操作降低信噪比。**HGMP** 算法首先在全局估计层中利用残差投影聚簇结构分离出信号子空间，降低了观测噪声的影响，然后稀疏恢复层在信号子空间中利用正交匹配追踪算法实现鲁棒性贪婪定位。理论分析表明，**HGMP** 定位算法具有渐进线性复杂度 $\mathcal{O}(KMN)$ ，具有比 **OMP** 更强的噪声鲁棒性。仿真表明，提出的 **HGMP** 算法以远低于 **BP** 算法的计算复杂度，实现了比 **BP** 算法和 **OMP** 算法更优越的定位性能。

第三，针对多源定位中由网格失配和模型参数误差带来的基不匹配问题，提出了一种参数化稀疏贝叶斯字典学习算法 **PSBDL**。我们将基不匹配下的多源定位问题建模成参数化字典学习和稀疏恢复的联合优化问题，然后从稀疏贝叶斯学习的角度对联合优化问题进行求解。相比传统基于稀疏表征的多源定位算法，**PSBDL** 算法完成了字典学习和稀疏恢复的闭环优化逻辑。针对实信号/复信号、**SMV/MMV** 观测模型下的多源定位问题，我们详细推导了 **PSBDL** 算法的四种表现形式：**PSBDL-ReSMV**、**PSBDL-ReMMV**、**PSBDL-ComSMV**、**PSBDL-ComMMV**。理论分析表明，**PSBDL** 算法的复杂度为 $\mathcal{O}(MN^2)$ 。仿真表明所提算法具有比传统算法更优越的参数估计性能，有效解决了基不匹配下的多源定位问题。

第四，针对大规模高维场景中的“维数灾难”问题，提出了一种快速证据下界最大化稀疏贝叶斯学习算法 **FEMSBL**。我们详细分析了维数灾难问题给稀疏重建算法在计算效率、存储需求、系统辨识能力上带来的挑战。通过对稀疏贝叶斯学习中证据下界关于超参数更新的性质进行深入分析，我们基于“网格甄别”思想提出了证据下界快速最大化方法。理论分析表明，**FEMSBL** 算将传统的 **EMSBL** 算法的计算复杂度从 $\mathcal{O}(MN^2)$ 降低到 $\mathcal{O}(MN)$ 。数值仿真表明 **FEMSBL** 能够高效可靠地求解大规模稀疏恢复问题，有效缓解“维数灾难”问题带来的挑战。将 **FEMSBL** 算法与 **PSBDL** 算法结合，我们提出一种参数化稀疏贝叶斯字典学习快速算法 **FPSBDL**。理论分析表

明, FPSBDL 算法将 PSBDL 算法的计算复杂度从 $\mathcal{O}(MN^2)$ 降低到 $\mathcal{O}(MN)$ 。仿真验证了 FPSBDL 算法相对于 PSBDL 算法在计算复杂度和系统辨识能力上的显著提升。

第五, 针对阴影衰落信道下的多源定位问题, 我们基于“逼近-推理”研究范式提出了一种两阶段最大似然多源定位算法 TSML。TSML 算法包含辐射源参数捕获阶段和辐射源参数跟踪阶段。在辐射源参数捕获阶段, 我们对观测模型进行泰勒级数展开, 将初值捕获问题转化为稀疏恢复问题, 并对恢复系数进行聚类加权, 快速捕获辐射源参数的初值。在辐射源参数跟踪阶段, 我们采用 Fenton-Wilkinson 方法对观测变量的分布进行逼近, 提出一种最大似然估计器并采用贯序二次规划方法 (SQP) 进行求解。我们对 TSML 算法的时间复杂度和全局收敛性作出了理论分析, 并通过数值仿真验证了 TSML 算法的相对传统的 MMSE 算法的性能提升。

最后, 本文提出的广义多源定位模型不仅能够表示具体的多源定位模型, 也能够表示信道估计、频谱感知、MIMO 雷达、语音信号处理等诸多应用中的相关模型, 因此本文所提的算法也能够求解这些应用中的相关问题, 具有一定的普适性。

7.2 本文工作展望

实现高精度多源定位是一个极具挑战的课题, 本文主要从基于无线传感器网络的多源定位场景出发, 对基于稀疏表征的多源定位技术进行了较为深入的研究。毫无疑问, 本文的研究内容均可进一步深化和完善, 多源定位的相关理论和算法仍有大量问题有待解决。在已有研究基础上, 下面列举一些有待进一步解决的问题。

(1) 相关接收信号下的多源定位。本文假设各辐射源信号、各定位节点的测量噪声、各快拍的测量信号均是统计独立的, 但在某些实际场景中, 各辐射源信号之间、各节点的测量噪声之间, 各快拍之间可能不是严格统计独立, 展现出一定的关联性。下一步可在本文的研究基础上, 研究相关接收信号下的共信道多源定位问题。

(2) 非视距 (Non Line of Sight, NLOS) 传播和多径传播下的多源定位。众所周知, TDOA 和 DOA 测量对 NLOS 传播和多径传播非常敏感。针对 TDOA 测量和 DOA 测量, 下一步可以基于稀疏表征方法研究 NLOS 判定和消除技术, 以及多径估计技术。

(3) 混合定位技术。本文主要针对基于单种测量的多源定位展开研究, 下一步可在此基础上研究基于多种测量的 (RSS、DOA、TDOA、FDOA 等) 的混合定位技术。

(4) 阴影衰落下的多源定位理论误差下界。由于对数求和正态随机变量的概率分布无显式表达, 因而无法推导阴影衰落信道下多源定位问题的 CRLB。下一步研究可以通过合适的建模和松弛方法, 探讨阴影衰落下的多源定位理论误差下界。

(5) 基于移动通信网的外辐射源定位问题。基于移动通信基站组网而形成的外辐射源定位网络具有多频段、多方位、布局广的优势, 微多普勒特征是低空目标分类和定位的重要依据。下一步可以研究基于移动通信信号的外辐射源低空目标微多普勒特征提取和定位技术。

参考文献

- [1] SKOLNIK M I, et al. Introduction to radar systems: volume 3[M]. McGraw-hill New York, 1980.
- [2] HODGES R P. Underwater acoustics: Analysis, design and performance of sonar [M]. John Wiley & Sons, 2011.
- [3] HOFMANN-WELLENHOF B, LEGAT K, WIESER M. Navigation[M]. Springer Science & Business Media, 2003.
- [4] CAMPBELL J B, WYNNE R H. Introduction to remote sensing[M]. Guilford Press, 2011.
- [5] BURKE B F, GRAHAM-SMITH F, WILKINSON P N. An introduction to radio astronomy[M]. Cambridge University Press, 2019.
- [6] GOLDSMITH A. Wireless communications[M]. Cambridge University Press, 2005.
- [7] XIAO Y, HU F. Cognitive radio networks[M]. CRC Press, 2008.
- [8] RAGHAVENDRA C S, SIVALINGAM K M, ZNATI T. Wireless sensor networks [M]. Springer, 2006.
- [9] 田中成, 刘聪锋. 无源定位技术[M]. 国防工业出版社, 2015.
- [10] ZEKAVAT R, BUEHRER R M. Handbook of position location: Theory, practice and advances: volume 27[M]. John Wiley & Sons, 2011.
- [11] 田孝华, 周义建. 无线电定位理论与技术[M]. 国防工业出版社, 2011.
- [12] 朱旭东. 一种有源和无源综合探测系统的研究[J]. 现代雷达, 2003, 25(6):8-11.
- [13] COLLIER T C, KIRSCHER A N, TAYLOR C E. Acoustic localization of antbirds in a mexican rainforest using a wireless sensor network[J]. The Journal of the Acoustical Society of America, 2010, 128(1):182-189.
- [14] 郁春来, 张元发, 万方. 无源定位技术体制及装备的现状与发展趋势[J]. 空军雷达学院学报, 2012, 26(2):79-85.

- [15] JEAN O, WEISS A J. Passive localization and synchronization using arbitrary signals [J]. IEEE Transactions on Signal Processing, 2014, 62(8):2143-2150.
- [16] LIU C, FANG D, YANG Z, et al. RSS distribution-based passive localization and its application in sensor networks[J]. IEEE Transactions on Wireless Communications, 2015, 15(4):2883-2895.
- [17] MILNE P H. Underwater acoustic positioning systems[M]. Gulf Publishing Co., Houston, TX, 1983.
- [18] 尹洁昕. 基于阵列信号的目标直接定位方法研究[D]. 战略支援部队信息工程大学, 2018.
- [19] WAX M, KAILATH T. Optimum localization of multiple sources by passive arrays [J]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1983, 31(5): 1210-1217.
- [20] OISPUU M, NICKEL U. 3D passive source localization by a multi-array network: Noncoherent vs. coherent processing[C]//2010 International ITG Workshop on Smart Antennas (WSA). IEEE, 2010: 300-305.
- [21] AKYILDIZ I F, POMPILI D, MELODIA T. Underwater acoustic sensor networks: research challenges[J]. Ad hoc networks, 2005, 3(3):257-279.
- [22] WANG H, WAN L, DONG M, et al. Assistant vehicle localization based on three collaborative base stations via SBL-based robust DOA estimation[J]. IEEE Internet of Things Journal, 2019, 6(3):5766-5777.
- [23] LUO J A, SHAO X H, PENG D L, et al. A novel subspace approach for bearing-only target localization[J]. IEEE Sensors Journal, 2019, 19(18):8174-8182.
- [24] LUO J A, SHI Y F, SHEN-TU H, et al. Bearing-only multi-target localization for wireless array networks: A spatial sparse representation approach[C]//2018 21st International Conference on Information Fusion (FUSION). IEEE, 2018: 1726-1731.
- [25] GHOLAMI M R, GEZICI S, STROM E G. A concave-convex procedure for TDOA based positioning[J]. IEEE Communications Letters, 2013, 17(4):765-768.
- [26] 陈志猛. 外辐射源雷达联合误差校正和无源定位方法研究[D]. 杭州电子科技大学, 2019.

- [27] 左燕, 周夏磊, 蒋陶然. 传感器位置误差下外辐射源雷达三维定位代数解算法[J]. 电子与信息学报, 2020, 42(3):555-562.
- [28] 舒益群, 陈启德. 基于 C-CKF 的单站外辐射源定位方法[J]. 舰船电子工程, 2019, 39(7):49-53.
- [29] PENG T, ZUO P, YOU K, et al. Bounds and methods for multiple directional sources localization based on RSS measurements[J]. IEEE Access, 2019, 7:131395-131406.
- [30] ZUO P, PENG T, YOU K, et al. RSS-based localization of multiple directional sources with unknown transmit powers and orientations[J]. IEEE Access, 2019, 7:88756-88767.
- [31] LI D, HU Y H. Energy-based collaborative source localization using acoustic microsensor array[J]. EURASIP J. Appl. Signal Process., 2003, 2003(4):3990-4003.
- [32] SHENG X, HU Y H. Maximum likelihood multiple-source localization using acoustic energy measurements with wireless sensor networks[J]. IEEE Transactions on Signal Processing, 2005, 53(1):44-53.
- [33] BANDIERA F, COLUCCIA A, RICCI G. A cognitive algorithm for received signal strength based localization[J]. IEEE Transactions on Signal Processing, 2015, 63(7):1726-1736.
- [34] GODARA L C. Application of antenna arrays to mobile communications. ii. beam-forming and direction-of-arrival considerations[J]. Proc. IEEE, 1997, 85(8):1195-1245.
- [35] KAPLAN L M, LE Q, MOLNAR N. Maximum likelihood methods for bearings-only target localization[C]//Proc. IEEE Int. Conf. Acoust. Speech Signal Process. (ICASSP). 2001: 3001-3004 vol.5.
- [36] KUMAR L, TRIPATHY A, HEGDE R M. Robust multi-source localization over planar arrays using MUSIC-group delay spectrum[J]. IEEE Transactions on Signal Processing, 2014, 62(17):4627-4636.
- [37] STEIN S, YAIR O, COHEN D, et al. Cascade: Compressed carrier and doa estimation [J]. IEEE Transactions on Signal Processing, 2017, 65(10):2645-2658.
- [38] WANG Y, HO K C. TDOA positioning irrespective of source range[J]. IEEE Transactions on Signal Processing, 2017, 65(6):1447-1460.

- [39] HUANG Y, BENESTY J, ELKO G W, et al. Real-time passive source localization: a practical linear-correction least-squares approach[J]. IEEE Transactions on Speech and Audio Processing, 2001, 9(8):943-956.
- [40] HO K C, LU X, KOVAVISARUCH L. Source localization using TDOA and FDOA measurements in the presence of receiver location errors: Analysis and solution[J]. IEEE Transactions on Signal Processing, 2007, 55(2):684-696.
- [41] QU X, XIE L, TAN W. Iterative constrained weighted least squares source localization using TDOA and FDOA measurements[J]. IEEE Transactions on Signal Processing, 2017, 65(15):3990-4003.
- [42] 李明哲, 李小将, 李志亮. 基于 FDOA 的无源定位算法研究现状与展望[J]. Ordnance Industry Automation, 2019, 4(38):04.
- [43] PALATTELLA M R, DOHLER M, GRIECO A, et al. Internet of things in the 5G era: Enablers, architecture, and business models[J]. IEEE Journal on Selected Areas in Communications, 2016, 34(3):510-527.
- [44] 骆吉安. 无线传感器阵列网络高精度被动目标定位方法研究[D]. 浙江大学, 2013.
- [45] 朱红松, 孙利民. 无线传感器网络技术发展现状[J]. 中兴通讯技术, 2009(5):1-5.
- [46] ADEEL A, GOGATE M, FAROOQ S, et al. A survey on the role of wireless sensor networks and IoT in disaster management[M]//Geological disaster monitoring based on sensor networks. Springer, 2019: 57-66.
- [47] RAZA M, HUSSAIN S, ASLAM N, et al. Industrial wireless sensor networks and 5g connected industries[J]. Enabling 5G Communication Systems to Support Vertical Industries, 2019:23-40.
- [48] SRBINOVSKA M, DIMCEV V, GAVROVSKI C. Energy consumption estimation of wireless sensor networks in greenhouse crop production[C]//IEEE EUROCON 2017-17th international conference on smart technologies. IEEE, 2017: 870-875.
- [49] LIU Y, DING Z, ELKASHLAN M, et al. Cooperative non-orthogonal multiple access with simultaneous wireless information and power transfer[J]. IEEE Journal on Selected Areas in Communications, 2016, 34(4):938-953.
- [50] NIU R, VEMPATY A, VARSHNEY P K. Received-signal-strength-based localization in wireless sensor networks[J]. Proceedings of the IEEE, 2018, 106(7):1166-1182.

- [51] PATWARI N, ASH J N, KYPEROUNTAS S, et al. Locating the nodes: cooperative localization in wireless sensor networks[J]. IEEE Signal processing magazine, 2005, 22(4):54-69.
- [52] MAO G, FIDAN B, ANDERSON B D. Wireless sensor network localization techniques[J]. Computer networks, 2007, 51(10):2529-2553.
- [53] MENG W, XIAO W. Energy-based acoustic source localization methods: a survey [J]. Sensors, 2017, 17(2):376.
- [54] MAZUELAS S, BAHILLO A, LORENZO R M, et al. Robust indoor positioning provided by real-time RSSI values in unmodified wlan networks[J]. IEEE Journal of selected topics in signal processing, 2009, 3(5):821-831.
- [55] MANOLAKIS D E. Efficient solution and performance analysis of 3D position estimation by trilateration[J]. IEEE Transactions on Aerospace and Electronic systems, 1996, 32(4):1239-1248.
- [56] LI D, HU Y H. Energy-based collaborative source localization using acoustic microsensor array[J]. EURASIP J. Appl. Signal Process., 2003, 2003(4):3990-4003.
- [57] LI D, HU Y H. Least square solutions of energy based acoustic source localization problems[C]//Workshops on Mobile and Wireless Networking/High Performance Scientific, Engineering Computing/Network Design and Architecture/Optical Networks Control and Management/Ad Hoc and Sensor Networks/Compil. IEEE, 2004: 443-446.
- [58] MEESOOKHO C, MITRA U, NARAYANAN S. On energy-based acoustic source localization for sensor networks[J]. IEEE Transactions on Signal Processing, 2007, 56(1):365-377.
- [59] PATWARI N, HERO A O, PERKINS M, et al. Relative location estimation in wireless sensor networks[J]. IEEE Transactions on Signal Processing, 2003, 51(8):2137-2148.
- [60] COLUCCIA A, RICCIATO F. On ML estimation for automatic RSS-based indoor localization[C]//Proc. IEEE Int. Symp. Wireless Pervas.Comput. 2010: 495-502.
- [61] WANG G, YANG K. A new approach to sensor node localization using RSS measurements in wireless sensor networks[J]. IEEE transactions on wireless communications, 2011, 10(5):1389-1395.

- [62] BEKO M. Energy-based localization in wireless sensor networks using semidefinite relaxation[C]//2011 IEEE Wireless Communications and Networking Conference. IEEE, 2011: 1552-1556.
- [63] MENG C, DING Z, DASGUPTA S. A semidefinite programming approach to source localization in wireless sensor networks[J]. IEEE signal processing letters, 2008, 15: 253-256.
- [64] BLATT D, HERO A O. Energy-based sensor network source localization via projection onto convex sets[J]. IEEE Transactions on Signal Processing, 2006, 54(9): 3614-3619.
- [65] GHOLAMI M R, WYMEERSCH H, STROM E G, et al. Wireless network positioning as a convex feasibility problem[J]. Eurasip Journal on Wireless Communications and Networking, 2011, 2011(1):161.
- [66] BEKO M. Energy-based localization in wireless sensor networks using second-order cone programming relaxation[J]. Wireless personal communications, 2014, 77(3): 1847-1857.
- [67] NIU R, VARSHNEY P. Target location estimation in wireless sensor networks using binary data[C]//38th Annual Conference on Information Sciences and Systems. 2004.
- [68] NIU R, VARSHNEY P K. Target location estimation in sensor networks with quantized data[J]. IEEE Transactions on Signal Processing, 2006, 54(12):4519-4528.
- [69] KATENKA N, LEVINA E, MICHAELIDIS G. Robust target localization from binary decisions in wireless sensor networks[J]. Technometrics, 2008, 50(4):448-461.
- [70] SHI H, LI X, SHANG Y, et al. Cramer-rao bound analysis of quantized RSSI based localization in wireless sensor networks[C]//11th International Conference on Parallel and Distributed Systems (ICPADS'05): volume 2. IEEE, 2005: 32-36.
- [71] SELVARATNAM D D, SHAMES I, MANTON J H, et al. Source localisation using binary measurements[J]. arXiv preprint arXiv:1711.10153, 2017.
- [72] MASAZADE E, NIU R, VARSHNEY P K, et al. Energy aware iterative source localization for wireless sensor networks[J]. IEEE Transactions on Signal Processing, 2010, 58(9):4824-4835.
- [73] HU Y, LEUS G. Self-estimation of path-loss exponent in wireless networks and applications[J]. IEEE Transactions on Vehicular Technology, 2014, 64(11):5091-5102.

-
- [74] SARI R, ZAYYANI H. RSS localization using unknown statistical path loss exponent model[J]. IEEE Communications Letters, 2018, 22(9):1830-1833.
- [75] VAGHEFI R M, GHOLAMI M R, BUEHRER R M, et al. Cooperative received signal strength-based sensor localization with unknown transmit powers[J]. IEEE Transactions on Signal Processing, 2012, 61(6):1389-1403.
- [76] GHOLAMI M R, VAGHEFI R M, STRÖM E G. RSS-based sensor localization in the presence of unknown channel parameters[J]. IEEE Transactions on Signal Processing, 2013, 61(15):3752-3759.
- [77] AMPELIOTIS D, BERBERIDIS K. Sorted order-K voronoi diagrams for model-independent source localization in wireless sensor networks[J]. IEEE Transactions on Signal Processing, 2009, 58(1):426-437.
- [78] AMPELIOTIS D, BERBERIDIS K. Energy-based model-independent source localization in wireless sensor networks[C]//2008 16th European Signal Processing Conference. IEEE, 2008: 1-5.
- [79] RABBAT M, NOWAK R, BUCKLEW J. Robust decentralized source localization via averaging[C]//Proceedings.(ICASSP'05). IEEE International Conference on Acoustics, Speech, and Signal Processing, 2005.: volume 5. IEEE, 2005: v-1057.
- [80] SHENG X, HU Y H. Maximum likelihood multiple-source localization using acoustic energy measurements with wireless sensor networks[J]. IEEE Transactions on Signal Processing, 2004, 53(1):44-53.
- [81] SHENG X, HU Y H, RAMANATHAN P. Distributed particle filter with gmm approximation for multiple targets localization and tracking in wireless sensor network [C]//IPSN 2005. Fourth International Symposium on Information Processing in Sensor Networks, 2005. IEEE, 2005: 181-188.
- [82] CHEN X, TURELI U. Underwater source localization based on energy measurement with randomly distributed sensor array[C]//Unattended Ground, Sea, and Air Sensor Technologies and Applications IX: volume 6562. International Society for Optics and Photonics, 2007: 65620L.
- [83] ZHANG Z, XU Y, YANG J, et al. A survey of sparse representation: algorithms and applications[J]. IEEE access, 2015, 3:490-530.

- [84] LU X, LI X. Group sparse reconstruction for image segmentation[J]. *Neurocomputing*, 2014, 136:41-48.
- [85] ELAD M, FIGUEIREDO M A, MA Y. On the role of sparse and redundant representations in image processing[J]. *Proceedings of the IEEE*, 2010, 98(6):972-982.
- [86] STARCK J L, MURTAGH F, FADILI J M. Sparse image and signal processing: wavelets, curvelets, morphological diversity[M]. Cambridge university press, 2010.
- [87] MALLAT S. A wavelet tour of signal processing: The sparse way, 832 pp[J]. Academic, Burlington, Mass, 2008.
- [88] ELAD M. Sparse and redundant representations: from theory to applications in signal and image processing[M]. Springer Science & Business Media, 2010.
- [89] BRUCKSTEIN A M, DONOHO D L, ELAD M. From sparse solutions of systems of equations to sparse modeling of signals and images[J]. *SIAM review*, 2009, 51(1): 34-81.
- [90] WRIGHT J, MA Y, MAIRAL J, et al. Sparse representation for computer vision and pattern recognition[J]. *Proceedings of the IEEE*, 2010, 98(6):1031-1044.
- [91] CEVHER V, DUARTE M F, BARANIUK R G. Distributed target localization via spatial sparsity[C]//2008 16th European Signal Processing Conference. IEEE, 2008: 1-5.
- [92] ZHANG B, CHENG X, ZHANG N, et al. Sparse target counting and localization in sensor networks based on compressive sensing[C]//2011 Proceedings IEEE INFOCOM. IEEE, 2011: 2255-2263.
- [93] 何风行, 余志军, 刘海涛. 基于压缩感知的无线传感器网络多目标定位算法[J]. *电子与信息学报*, 2012.
- [94] LIN X, YOU K, GUO W. Delaunay triangulation and mesh grid combining algorithm for multiple targets localization using compressive sensing[C]//2016 19th International Symposium on Wireless Personal Multimedia Communications (WPMC). IEEE, 2016: 25-30.
- [95] 孙保明, 郭艳, 李宁, 等. 无线传感器网络中基于压缩感知的动态目标定位算法[J]. *电子与信息学报*, 2016, 38(8):1858-1864.

- [96] CANDÈS E J, WAKIN M B. An introduction to compressive sampling[J]. IEEE signal processing magazine, 2008, 25(2):21-30.
- [97] SUN B, YAN G, NING L, et al. An efficient counting and localization framework for off-grid targets in wsns[J]. IEEE Communications Letters, 2016, PP(99):1-1.
- [98] SUN B, GUO Y, LI N, et al. Multiple target counting and localization using variational bayesian em algorithm in wireless sensor networks[J]. IEEE Transactions on Communications, 2017, 65(7):2985-2998.
- [99] GIROD L, LUKAC M, TRIFA V, et al. The design and implementation of a self-calibrating distributed acoustic sensing platform[C]//Proceedings of the 4th international conference on Embedded networked sensor systems. 2006: 71-84.
- [100] YIP L, COMANOR K, CHEN J C, et al. Array processing for target DOA, localization, and classification based on AML and SVM algorithms in sensor networks[C]//Information Processing in Sensor Networks. Springer, 2003: 269-284.
- [101] ALLEN M, GIROD L, NEWTON R, et al. Voxnet: An interactive, rapidly-deployable acoustic monitoring platform[C]//2008 International Conference on Information Processing in Sensor Networks (ipsn 2008). IEEE, 2008: 371-382.
- [102] KAPLAN L M, LE Q, MOLNAR N. Maximum likelihood methods for bearings-only target localization[C]//2001 IEEE International Conference on Acoustics, Speech, and Signal Processing. Proceedings (Cat. No. 01CH37221): volume 5. IEEE, 2001: 3001-3004.
- [103] KAPLAN L M, LE Q. On exploiting propagation delays for passive target localization using bearings-only measurements[J]. Journal of the Franklin Institute, 2005, 342(2): 193-211.
- [104] KRIM H, VIBERG M. Two decades of array signal processing research: the parametric approach[J]. IEEE signal processing magazine, 1996, 13(4):67-94.
- [105] 王永良. 空间谱估计理论与算法[M]. 清华大学出版社有限公司, 2004.
- [106] CAPON J. High-resolution frequency-wavenumber spectrum analysis[J]. Proceedings of the IEEE, 1969, 57(8):1408-1418.
- [107] SCHMIDT R. Multiple emitter location and signal parameter estimation[J]. IEEE transactions on antennas and propagation, 1986, 34(3):276-280.

- [108] 张贤达. 矩阵分析与应用[M]. 清华大学出版社有限公司, 2004.
- [109] RAO B D, HARI K S. Performance analysis of root-MUSIC[J]. IEEE Transactions on Acoustics, Speech, and Signal Processing, 1989, 37(12):1939-1949.
- [110] ROY R, PAULRAJ A, KAILATH T. ESPRIT—a subspace rotation approach to estimation of parameters of cisoids in noise[J]. IEEE transactions on acoustics, speech, and signal processing, 1986, 34(5):1340-1342.
- [111] OTTERSTEN B, VIBERG M, KAILATH T. Analysis of subspace fitting and ML techniques for parameter estimation from sensor array data[J]. IEEE Transactions on Signal Processing, 1992, 40(3):590-600.
- [112] BOHME J. Estimation of source parameters by maximum likelihood and nonlinear regression[C]//ICASSP'84. IEEE International Conference on Acoustics, Speech, and Signal Processing: volume 9. IEEE, 1984: 271-274.
- [113] WAX M. Detection and localization of multiple sources in noise with unknown covariance[J]. IEEE Transactions on Signal Processing, 1992, 40(1):245-249.
- [114] MALIOUTOV D, CETIN M, WILLSKY A S. A sparse signal reconstruction perspective for source localization with sensor arrays[J]. IEEE transactions on signal processing, 2005, 53(8):3010-3022.
- [115] ELDAR Y C, RAUHUT H. Average case analysis of multichannel sparse recovery using convex relaxation[J]. IEEE Transactions on Information Theory, 2009, 56(1): 505-519.
- [116] YIN J, CHEN T. Direction-of-arrival estimation using a sparse representation of array covariance vectors[J]. IEEE Transactions on Signal Processing, 2011, 59(9): 4489-4493.
- [117] HYDER M M, MAHATA K. Direction-of-arrival estimation using a mixed $\ell_{2,0}$ norm approximation[J]. IEEE Transactions on Signal processing, 2010, 58(9):4646-4655.
- [118] COTTER S F, RAO B D, ENGAN K, et al. Sparse solutions to linear inverse problems with multiple measurement vectors[J]. IEEE Transactions on Signal Processing, 2005, 53(7):2477-2488.
- [119] ELDAR Y C, KUPPINGER P, BOLCSKEI H. Block-sparse signals: Uncertainty relations and efficient recovery[J]. IEEE Transactions on Signal Processing, 2010, 58(6):3042-3054.

- [120] WIPF D P, RAO B D. An empirical bayesian strategy for solving the simultaneous sparse approximation problem[J]. IEEE Transactions on Signal Processing, 2007, 55(7):3704-3716.
- [121] STOICA P, BABU P, LI J. SPICE: A sparse covariance-based estimation method for array processing[J]. IEEE Transactions on Signal Processing, 2010, 59(2):629-638.
- [122] YANG Z, XIE L, ZHANG C. Off-grid direction of arrival estimation using sparse bayesian inference[J]. IEEE Transactions on Signal Processing, 2012, 61(1):38-43.
- [123] CHEN F, DAI J, HU N, et al. Sparse bayesian learning for off-grid DOA estimation with nested arrays[J]. Digital Signal Processing, 2018, 82:187-193.
- [124] CHEN P, CAO Z, CHEN Z, et al. Off-grid DOA estimation using sparse bayesian learning in MIMO radar with unknown mutual coupling[J]. IEEE Transactions on Signal Processing, 2018, 67(1):208-220.
- [125] DAI J, BAO X, XU W, et al. Root sparse bayesian learning for off-grid DOA estimation[J]. IEEE Signal Processing Letters, 2016, 24(1):46-50.
- [126] WANG Q, ZHAO Z, CHEN Z, et al. Grid evolution method for DOA estimation[J]. IEEE Transactions on Signal Processing, 2018, 66(9):2374-2383.
- [127] CUI W, SHEN Q, LIU W, et al. Low complexity DOA estimation for wideband off-grid sources based on re-focused compressive sensing with dynamic dictionary[J]. IEEE Journal of Selected Topics in Signal Processing, 2019, 13(5):918-930.
- [128] CHANDRASEKARAN V, RECHT B, PARRILO P A, et al. The convex geometry of linear inverse problems[J]. Foundations of Computational mathematics, 2012, 12(6):805-849.
- [129] YANG Z, XIE L, STOICA P. Vandermonde decomposition of multilevel toeplitz matrices with application to multidimensional super-resolution[J]. IEEE Transactions on Information Theory, 2016, 62(6):3685-3701.
- [130] TANG G, BHASKAR B N, SHAH P, et al. Compressed sensing off the grid[J]. IEEE transactions on information theory, 2013, 59(11):7465-7490.
- [131] BHASKAR B N, TANG G, RECHT B. Atomic norm denoising with applications to line spectral estimation[J]. IEEE Transactions on Signal Processing, 2013, 61(23):5987-5999.

- [132] YANG Z, XIE L. Enhancing sparsity and resolution via reweighted atomic norm minimization[J]. IEEE Transactions on Signal Processing, 2015, 64(4):995-1006.
- [133] PAL P, VAIDYANATHAN P P. A grid-less approach to underdetermined direction of arrival estimation via low rank matrix denoising[J]. IEEE Signal Processing Letters, 2014, 21(6):737-741.
- [134] YANG Z, XIE L, ZHANG C. A discretization-free sparse and parametric approach for linear array signal processing[J]. IEEE Transactions on Signal Processing, 2014, 62(19):4959-4973.
- [135] YANG Z, XIE L. On gridless sparse methods for line spectral estimation from complete and incomplete data[J]. IEEE Transactions on Signal Processing, 2015, 63(12): 3139-3153.
- [136] 盛丹, 王国宏, 于洪波. 基于 Hough 变换的测向交叉定位系统多目标跟踪技术[J]. 中国科学: 信息科学, 2016(5):8.
- [137] STANSFIELD R. Statistical theory of df fixing[J]. Journal of the Institution of Electrical Engineers-Part IIIA: Radiocommunication, 1947, 94(15):762-770.
- [138] DOĞANÇAY K. Bearings-only target localization using total least squares[J]. Signal processing, 2005, 85(9):1695-1710.
- [139] CHAN Y, RUDNICKI S. Bearings-only and doppler-bearing tracking using instrumental variables[J]. IEEE Transactions on Aerospace and Electronic Systems, 1992, 28(4):1076-1083.
- [140] HO K, CHAN Y T. An asymptotically unbiased estimator for bearings-only and doppler-bearing target motion analysis[J]. IEEE Transactions on Signal Processing, 2006, 54(3):809-822.
- [141] VAGHEFI R M, GHOLAMI M R, STRÖM E G. Bearing-only target localization with uncertainties in observer position[C]//2010 IEEE 21st international symposium on personal, indoor and mobile radio communications workshops. IEEE, 2010: 238-242.
- [142] REED J D, DA SILVA C R, BUEHRER R M. Multiple-source localization using line-of-bearing measurements: Approaches to the data association problem[C]//MILCOM 2008-2008 IEEE Military Communications Conference. IEEE, 2008: 1-7.

- [143] KLEIN L A. Sensor and data fusion: a tool for information assessment and decision making: volume 138[M]. SPIE press, 2004.
- [144] BLACKBURN T R. A practical correlation test for cooperative passive optical sensors[J]. Journal of Guidance, Control, and Dynamics, 1983, 6(1):62-64.
- [145] 汪望松, 修建娟, 修建华. 基于倾斜角的多目标测向无源定位技术[J]. 海军航空工程学院学报, 2014, 29(3):275-279.
- [146] BISHOP A N, PATHIRANA P N. Localization of emitters via the intersection of bearing lines: A ghost elimination approach[J]. IEEE Transactions on Vehicular Technology, 2007, 56(5):3106-3110.
- [147] 刘梅, 权太范, 姚天宾, 等. 多传感器多目标无源定位跟踪算法研究[J]. 电子学报, 2006, 34(6):991-995.
- [148] YANG K, WANG G, LUO Z Q. Efficient convex relaxation methods for robust target localization by a sensor network using time differences of arrivals[J]. IEEE Transactions on Signal Processing, 2009, 57(7):2775-2784.
- [149] BECK A, STOICA P, LI J. Exact and approximate solutions of source localization problems[J]. IEEE Transactions on Signal Processing, 2008, 56(5):1770-1778.
- [150] LUI K W K, CHAN F K W, SO H C. Semidefinite programming approach for range-difference based source localization[J]. IEEE Transactions on Signal Processing, 2008, 57(4):1630-1633.
- [151] HO K, LU X, KOVAVISARUCH L O. Source localization using TDOA and FDOA measurements in the presence of receiver location errors: Analysis and solution[J]. IEEE Transactions on Signal Processing, 2007, 55(2):684-696.
- [152] LIN L, SO H C, CHAN F K, et al. A new constrained weighted least squares algorithm for TDOA-based localization[J]. Signal Processing, 2013, 93(11):2872-2878.
- [153] QU X, XIE L. An efficient convex constrained weighted least squares source localization algorithm based on TDOA measurements[J]. Signal Processing, 2016, 119: 142-152.
- [154] XIU J J, WANG W S, SUN P. Multiple target passive location of TDOA based on bidirectional elect and nearest neighbor method[J]. Journal of Astronautics, 2015, 36: 483-488.

- [155] SUNDAR H, SREENIVAS T V, SEELAMANTULA C S. TDOA-based multiple acoustic source localization without association ambiguity[J]. IEEE/ACM Transactions on Audio, Speech, and Language Processing, 2018, 26(11):1976-1990.
- [156] YANG L, HO K. An approximately efficient TDOA localization algorithm in closed-form for locating multiple disjoint sources with erroneous sensor positions[J]. IEEE Transactions on Signal Processing, 2009, 57(12):4598-4615.
- [157] COMSA C R, HAIMOVICH A M, SCHWARTZ S C, et al. Time difference of arrival based source localization within a sparse representation framework[C]//2011 45th Annual Conference on Information Sciences and Systems. IEEE, 2011: 1-6.
- [158] JAMALI-RAD H, LEUS G. Sparsity-aware multi-source TDOA localization[J]. IEEE Transactions on Signal Processing, 2013, 61(19):4874-4887.
- [159] HO K, XU W. An accurate algebraic solution for moving source location using TDOA and FDOA measurements[J]. IEEE Transactions on Signal Processing, 2004, 52(9): 2453-2463.
- [160] WEI H W, PENG R, WAN Q, et al. Multidimensional scaling analysis for passive moving target localization with TDOA and FDOA measurements[J]. IEEE Transactions on Signal Processing, 2009, 58(3):1677-1688.
- [161] YANG K, JIANG L, LUO Z Q. Efficient semidefinite relaxation for robust geolocation of unknown emitter by a satellite cluster using TDOA and FDOA measurements [C]//2011 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2011: 2584-2587.
- [162] WANG G, LI Y, ANSARI N. A semidefinite relaxation method for source localization using TDOA and FDOA measurements[J]. IEEE Transactions on Vehicular Technology, 2012, 62(2):853-862.
- [163] WANG Y, WU Y. An efficient semidefinite relaxation algorithm for moving source localization using TDOA and FDOA measurements[J]. IEEE communications Letters, 2016, 21(1):80-83.
- [164] HAO W, WEI-MIN S, HONG G. A novel taylor series method for source and receiver localization using TDOA and FDOA measurements with uncertain receiver positions [C]//Proceedings of 2011 IEEE CIE International Conference on Radar: volume 2. IEEE, 2011: 1037-1040.

- [165] YU H, HUANG G, GAO J, et al. An efficient constrained weighted least squares algorithm for moving source location using TDOA and FDOA measurements[J]. IEEE transactions on wireless communications, 2011, 11(1):44-47.
- [166] ZHU G H, FENG D Z, XIE H, et al. An approximately efficient bi-iterative method for source position and velocity estimation using TDOA and FDOA measurements [J]. Signal Processing, 2016, 125:110-121.
- [167] YANG B, YANG Z, WANG D. A lagrangian multiplier method for TDOA and FDOA positioning of multiple disjoint sources with distance and velocity correlation constraints[J]. Mathematical Problems in Engineering, 2020, 2020.
- [168] CONG L, ZHUANG W. Hybrid TDOA/AOA mobile user location for wideband CDMA cellular systems[J]. IEEE Transactions on Wireless Communications, 2002, 1(3):439-447.
- [169] LIU C, YANG J, WANG F. Joint TDOA and AOA location algorithm[J]. Journal of Systems Engineering and Electronics, 2013, 24(2):183-188.
- [170] BISHOP A N, FIDAN B, DOĞANÇAY K, et al. Exploiting geometry for improved hybrid AOA/TDOA-based localization[J]. Signal Processing, 2008, 88(7):1775-1791.
- [171] YIN J, WAN Q, YANG S, et al. A simple and accurate TDOA-AOA localization method using two stations[J]. IEEE Signal Processing Letters, 2015, 23(1):144-148.
- [172] WANG Y, HO K. Unified near-field and far-field localization for AOA and hybrid AOA-TDOA positionings[J]. IEEE Transactions on Wireless Communications, 2017, 17(2):1242-1254.
- [173] WANG S, JACKSON B R, INKOL R. Hybrid RSS/AOA emitter location estimation based on least squares and maximum likelihood criteria[C]//2012 26th Biennial Symposium on Communications (QBSC). IEEE, 2012: 24-29.
- [174] GAZZAH L, NAJJAR L, BESBES H. Selective hybrid RSS/AOA weighting algorithm for NLOS intra cell localization[C]//2014 IEEE Wireless Communications and Networking Conference (WCNC). IEEE, 2014: 2546-2551.
- [175] BISWAS P, AGHAJAN H, YE Y. Semidefinite programming algorithms for sensor network localization using angle information[C]//Conference Record of the Thirty-Ninth Asilomar Conference on Signals, Systems and Computers, 2005. IEEE, 2005: 220-224.

- [176] TOMIC S, BEKO M, DINIS R. Distributed RSS-AoA based localization with unknown transmit powers[J]. IEEE Wireless Communications Letters, 2016, 5(4):392-395.
- [177] TOMIC S, BEKO M, TUBA M. A linear estimator for network localization using integrated RSS and AOA measurements[J]. IEEE Signal Processing Letters, 2019, 26(3):405-409.
- [178] CHANG S, LI Y, YANG X, et al. A novel localization method based on RSS-AOA combined measurements by using polarized identity[J]. IEEE Sensors Journal, 2018, 19(4):1463-1470.
- [179] TOMIC S, BEKO M. A robust NLOS bias mitigation technique for RSS-TOA-based target localization[J]. IEEE Signal Processing Letters, 2018, 26(1):64-68.
- [180] TOMIC S, BEKO M, TUBA M, et al. Target localization in NLOS environments using RSS and TOA measurements[J]. IEEE Wireless Communications Letters, 2018, 7(6):1062-1065.
- [181] CHI Y, SCHARF L L, PEZESHKI A, et al. Sensitivity to basis mismatch in compressed sensing[J]. IEEE Transactions on Signal Processing, 2011, 59(5):2182-2195.
- [182] 李航. 统计学习方法[M]. 清华大学出版社, 2012.
- [183] KAY S M. Fundamentals of statistical signal processing[M]. Prentice Hall PTR, 1993.
- [184] KINSLER L E, FREY A R, COPPENS A B, et al. Fundamentals of acoustics[M]. 1999.
- [185] 张贤达. 现代信号处理[M]. 清华大学出版社有限公司, 2002.
- [186] NATARAJAN B K. Sparse approximate solutions to linear systems[J]. SIAM journal on computing, 1995, 24(2):227-234.
- [187] 陈拉明. 基于非凸优化的稀疏重建理论与算法[D]. 清华大学, 2016.
- [188] TROPP J A, GILBERT A C. Signal recovery from random measurements via orthogonal matching pursuit[J]. IEEE Transactions on information theory, 2007, 53(12):4655-4666.
- [189] CHEN S S, DONOHO D L, SAUNDERS M A. Atomic decomposition by basis pursuit[J]. SIAM review, 2001, 43(1):129-159.

- [190] TIPPING M E. Sparse bayesian learning and the relevance vector machine[J]. *Journal of machine learning research*, 2001, 1(Jun):211-244.
- [191] ST'EPHANE MALLAT Z Z. Matching pursuit with time-frequency dictionaries[C]// *IEEE Transactions on signal processing*. Citeseer, 1993.
- [192] WANG J. Support recovery with orthogonal matching pursuit in the presence of noise: a new analysis[J]. *arXiv preprint arXiv:1501.04817*, 2015.
- [193] WANG J, KWON S, SHIM B. Generalized orthogonal matching pursuit[J]. *IEEE Transactions on signal processing*, 2012, 60(12):6202-6216.
- [194] NEEDELL D, VERSHYNIN R. Uniform uncertainty principle and signal recovery via regularized orthogonal matching pursuit[J]. *Foundations of computational mathematics*, 2009, 9(3):317-334.
- [195] NEEDELL D, TROPP J A. CoSaMP: Iterative signal recovery from incomplete and inaccurate samples[J]. *Applied and computational harmonic analysis*, 2009, 26(3): 301-321.
- [196] DONOHO D L, TSAIG Y, DRORI I, et al. Sparse solution of underdetermined systems of linear equations by stagewise orthogonal matching pursuit[J]. *IEEE transactions on Information Theory*, 2012, 58(2):1094-1121.
- [197] BLUMENSATH T, DAVIES M E. Iterative hard thresholding for compressed sensing [J]. *Applied and computational harmonic analysis*, 2009, 27(3):265-274.
- [198] DAUBECHIES I, DEFRISE M, DE MOL C. An iterative thresholding algorithm for linear inverse problems with a sparsity constraint[J]. *Communications on Pure and Applied Mathematics: A Journal Issued by the Courant Institute of Mathematical Sciences*, 2004, 57(11):1413-1457.
- [199] FIGUEIREDO M A, NOWAK R D, WRIGHT S J. Gradient projection for sparse reconstruction: Application to compressed sensing and other inverse problems[J]. *IEEE Journal of selected topics in signal processing*, 2007, 1(4):586-597.
- [200] WRIGHT S J, NOWAK R D, FIGUEIREDO M A. Sparse reconstruction by separable approximation[J]. *IEEE Transactions on signal processing*, 2009, 57(7):2479-2493.
- [201] GORODNITSKY I F, RAO B D. Sparse signal reconstruction from limited data using focuss: A re-weighted minimum norm algorithm[J]. *IEEE Transactions on signal processing*, 1997, 45(3):600-616.

- [202] BISHOP C M, TIPPING M. Variational relevance vector machines[J]. arXiv preprint arXiv:1301.3838, 2013.
- [203] TIPPING M E, FAUL A C, et al. Fast marginal likelihood maximisation for sparse bayesian models.[C]//AISTATS. 2003.
- [204] JI S, XUE Y, CARIN L. Bayesian compressive sensing[J]. IEEE Transactions on signal processing, 2008, 56(6):2346-2356.
- [205] BABACAN S D, MOLINA R, KATSAGGELOS A K. Bayesian compressive sensing using laplace priors[J]. IEEE Transactions on image processing, 2009, 19(1):53-63.
- [206] FENG C, VALAEE S, TAN Z. Multiple target localization using compressive sensing [C]//GLOBECOM 2009-2009 IEEE Global Telecommunications Conference. IEEE, 2009: 1-6.
- [207] NEEDELL D, VERSHYNIN R. Signal recovery from incomplete and inaccurate measurements via regularized orthogonal matching pursuit[J]. IEEE Journal of selected topics in signal processing, 2010, 4(2):310-316.
- [208] CANDÈS E J, et al. Compressive sampling[C]//Proceedings of the international congress of mathematicians: volume 3. Madrid, Spain, 2006: 1433-1452.
- [209] RAUHUT H, SCHNASS K, VANDERGHEYNST P. Compressed sensing and redundant dictionaries[J]. IEEE Transactions on Information Theory, 2008, 54(5):2210-2219.
- [210] YANG S, GUO Y, LIU X, et al. A localization algorithm based on compressive sensing by k-nearest neighbor classification[C]//2016 IEEE 13th International Conference on Signal Processing (ICSP). IEEE, 2016: 863-867.
- [211] ATAEE M, ZAYYANI H, BABAIE-ZADEH M, et al. Parametric dictionary learning using steepest descent[C]//2010 IEEE International Conference on Acoustics, Speech and Signal Processing. IEEE, 2010: 1978-1981.
- [212] YOU K, GUO W, LIU Y, et al. Grid evolution: Joint dictionary learning and sparse bayesian recovery for multiple off-grid targets localization[J]. IEEE Communications Letters, 2018, 22(10):2068-2071.
- [213] YOU K, GUO W, PENG T, et al. Parametric sparse bayesian dictionary learning for multiple sources localization with propagation parameters uncertainty[J]. IEEE Transactions on Signal Processing, 2020, 68:4194-4209.

- [214] HEYDE C C. On a property of the lognormal distribution[J]. Journal of the Royal Statistical Society: Series B (Methodological), 1963, 25(2):392-393.
- [215] FENTON L. The sum of log-normal probability distributions in scatter transmission systems[J]. IRE Transactions on communications systems, 1960, 8(1):57-67.
- [216] MARLOW N. A normal limit theorem for power sums of independent random variables[J]. The Bell System Technical Journal, 1967, 46(9):2081-2089.
- [217] SCHWARTZ S C, YEH Y S. On the distribution function and moments of power sums with log-normal components[J]. Bell System Technical Journal, 1982, 61(7): 1441-1462.
- [218] BEAULIEU N C, XIE Q. An optimal lognormal approximation to lognormal sum distributions[J]. IEEE Transactions on vehicular technology, 2004, 53(2):479-489.
- [219] MITCHELL R L. Permanence of the log-normal distribution[J]. JOSA, 1968, 58(9): 1267-1272.
- [220] DUFRESNE D. The log-normal approximation in financial and other computations [J]. Advances in Applied Probability, 2004:747-773.
- [221] WU J, MEHTA N B, ZHANG J. Flexible lognormal sum approximation method[C]// GLOBECOM'05. IEEE Global Telecommunications Conference, 2005.: volume 6. IEEE, 2005: 3413-3417.
- [222] MEHTA N B, WU J, MOLISCH A F, et al. Approximating a sum of random variables with a lognormal[J]. IEEE Transactions on Wireless Communications, 2007, 6(7): 2690-2699.
- [223] LIU Z, ALMHANA J, MCGORMAN R. Approximating lognormal sum distributions with power lognormal distributions[J]. IEEE Transactions on Vehicular Technology, 2008, 57(4):2611-2617.
- [224] BEAULIEU N C, RAJWANI F. Highly accurate simple closed-form approximations to lognormal sum distributions and densities[J]. IEEE Communications letters, 2004, 8(12):709-711.
- [225] RACHED N B, KAMMOUN A, ALOUINI M S, et al. On the efficient simulation of outage probability in a log-normal fading environment[J]. IEEE Transactions on Communications, 2017, 65(6):2583-2593.

- [226] ASMUSSEN S, JENSEN J L, ROJAS-NANDAYAPA L. Exponential family techniques for the lognormal left tail[J]. Scandinavian Journal of Statistics, 2016, 43(3): 774-787.
- [227] ZANDI E, MATHAR R. RSS-based location and transmit power estimation of multiple co-channel targets[C]//2018 15th International Symposium on Wireless Communication Systems (ISWCS). IEEE, 2018: 1-6.
- [228] ZANDI E, MATHAR R. Multi-node RSS-based localization with the aid of compressed sensing: An 11-localization approach[C]//WSA 2019; 23rd International ITG Workshop on Smart Antennas. VDE, 2019: 1-8.
- [229] MOLISCH A F. Wireless communications: volume 34[M]. John Wiley & Sons, 2012.
- [230] 马昌凤, 柯艺芬, 谢亚君. 最优化计算方法及其 MATLAB 程序实现[M]. 国防工业出版社, 2015.
- [231] YE Y, TSE E. An extension of karmarkar's projective algorithm for convex quadratic programming[J]. Mathematical Programming, 1989, 44(1-3):157-179.
- [232] 袁亚湘, 孙文瑜. 最优化理论与方法[M]. 科学出版社, 1997.

附录一 缩略语列表

ADC	Analog-to-Digital Convention	模数转换
AWGN	Additive White Gaussian Noise	加性高斯白噪声
BCQP	Bound-constrained Quadratic Programming	边界约束二次优化
BCS	Bayesian compressive sensing	贝叶斯压缩感知
BOTL	Bearings-Only Target Localization	纯方位角定位
BPDN	Basis Pursuit Denoising	基追踪降噪
CLS	Constrained Least Squares	约束最小二乘法
CoSaMP	Compressed Sampling Matching Pursuit	压缩采样匹配追踪
CRLB	Cramér–Rao Lower Bound	克拉美罗下界
CS	Compressive Sensing	压缩感知
CWLS	Constrained Weighted Least Squares	约束加权最小二乘法
DA	Data Association	数据关联
DOA	Direction of Arrival	波达方向
DML	Deterministic Maximum Likelihood	确定最大似然方法
DTSG	Delaunay Triangulation Spatial Gridding	基于德劳内三角剖分的空间网格化
EH	Energy Harvesting	能量采集
ELOB	Evidence Lower Bound	证据下界
EM	Expectation-Maximum	期望最大化
ESPRIT	Estimating Signal Parameter via Rotational Invariance Techniques	基于旋转不变技术的信号参数估计方法
FDOA	Frequency Difference of Arrival	波达频率差
FEMSBL	Fast EM for SBL	快速证据下界最大化稀疏贝叶斯字典学
FIM	Fisher Information Matrix	Fisher 信息矩阵
FOCUSS	Focal Undetermined System Solver	欠定系统局灶解法
FPSBDL	Fast PSBDL	参数稀疏贝叶斯快速算法
gOMP	Generalized OMP	广义正交匹配追踪
GPSR	Gradient Projection for Sparse Reconstruction	梯度投影稀疏重

建

HGMP	Hierarchical Greedy Matching Pursuit	层级贪婪匹配追踪
IHT	Iterative Hard Thresholding	迭代硬阈值
IoT	Internet of Things	物联网
IST	Iterative Soft Thresholding	迭代软阈值
IV	Instrumental Variable	工具变量法
JLZA	Joint $\ell_{2,0}$ Approximation	联合 $\ell_{2,0}$ 范数逼近
LASSO	Least Absolute Shrinkage and Selection Operation	最小的绝对收缩选择操作
LSM	Least-Squares Method	最小二乘方法
MAP	Maximum a Posteriori	最大后验
MAR	Minimum-to-Average Ratio	最小平均比
MLAR	Mean Localization Accuracy Rate	平均定位正确率
M-FOCUSS	MMV Focal Underdetermined System Solution	MMV 欠定系统局灶解法
MLE	Maximum Likelihood Estimate	最大似然估计
MLED	Mean Localization Error Distance	平均定位误差距离
MMV	Multiple Measurement Vector	多测量向量
MMSE	Minimum Mean Square Error	最小均方估计误差
MP	Matching Pursuit	匹配追踪
MRT	Mean Run Time	平均运行时间
MSL	Multiple Sources Localization	多源定位
MUSIC	Multiple Signal Classification Algorithm	多重信号分类
NLOS	Non Line of Sight	非视距
NOMA	Non-orthogonal Multiple Access	非正交多址接入
NRMSE	Normalized RMSE	归一化均方根误差 E
OGSBI	Off-grid Sparse Bayesian Inference	Off-grid 稀疏贝叶斯学习
OMP	Orthogonal Matching Pursuit	正交匹配追踪
OV	Orthogonal Vector	正交向量
PDF	Probability Density Function	概率密度函数
POCS	Projection onto Convex Sets	凸集投影

PLE	Path Loss Exponent	路径损耗指数
PSBDL	Parametric Sparse Bayesian Dictionary Learning	参数化稀疏贝叶斯字典学习
RIP	Restricted Isometry Property	有限等距性质
RMSE	Root-Mean-Square Error	均方根误差
ROMP	Regularized OMP	正则化正交匹配追踪
RSS	Received Signal Strength	接收信号强度
WSN	Wireless Sensor Network	无线传感器网络
SBL	Sparse Bayesian Learning	稀疏贝叶斯学习
SDP	Semidefinite Programmming	半定规划
SDR	Semidefinite Relaxation	半定松弛
SLN	Sum-of-log-normal	求和对数正态
SOCP	Second-Order Cone Programming	二阶锥规划
SPA	Sparse and Parametric Approach	稀疏与参数化方法
SpaRSA	Sparse Reconstruction by Separable Approximation	基于可分离逼近的稀疏重建
SPICE	Sparse Iterative Covariance-based Estimation	基于协方差的稀疏迭代估计
SQP	Sequential Quadratic Programming	贯序二次规划算法
SML	Stochastic Maximum Likelihood	随机最大似然方法
SNR	Signal-to-Noise Ratio	信噪比
StOMP	Stagewise OMP	分段正交匹配追踪
SVD	Singular Value Decomposition	奇异值分解
TDOA	Time Difference of Arrival	波达时间差
TLS	Total Least Square	总体最小二乘法
TOA	Time of Arrival	波达时间
TSML	Two-Stage Maximum Likelihood	两阶段最大似然
TSWLS	Two-Step Weighted Least Squares	两步加权最小二乘法
ULA	Uniform Linear Array	均匀线性阵列

致 谢

转眼间，已在北京邮电大学度过了近十个年头。回首过往，看到了自己从幼稚到成熟的成长过程。从本科阶段到博士阶段，终究是一个自我修炼的过程。在这片校园里，发生了许多难忘的事，遇到了许多优秀的人，这一切为我的青春时光镀上了一层厚重而丰富的底色，使我终身难忘。

首先，谨向我的导师郭文彬教授致以崇高的敬意和由衷的感谢。郭老师治学严谨、精益求精，具有开阔的学术视野和高尚的师德师风。自始至终，郭老师为我营造了一个良好的科研环境，在生活上对我关怀备至，学术上对我言传身教，引领我走上科研的道路。感谢郭老师多年来对我循循善诱的教诲和不断的鼓励。本论文的完成，离不开郭老师的悉心指导和一如既往的支持。即将毕业远去，心中倍觉依依，这一生里，仍念吾师。愿有足迹处，尽是桃李。

其次，感谢杨立山、朱燊师兄，左珮良、刘玥良同学，与你们的合作让我受益匪浅。感谢林小斐、张乾、徐子健、王宇昆、李新慧同学，很荣幸能和你们一起度过在实验室的愉快的时光。感谢李珊珊、汪绍俊、张远、王丹、王悦师弟师妹们，在和你们的讨论中我学到了很多。

最后，感谢我的母亲对我一直以来的教育、支持、理解和无私的爱。感谢祖国提供的公平教育环境和越来越好的教育条件。愿今后能为祖国的繁荣昌盛富强作出贡献。

攻读学位期间发表的学术论文目录

本人攻读学位期间共发表论文 18 篇，其中第一作者 5 篇，其他合作论文 13 篇。

已发表论文：

1. **You Kangyong***, Guo Wenbin, Peng Tao, Liu Yueliang, Zuo Peiliang, Wang Wenbo, Parametric Sparse Bayesian Dictionary Learning for Multiple Sources Localization With Propagation Parameters Uncertainty. *IEEE Transactions on Signal Processing*, vol. 68, Jul. 2020, pp. 4194-4209. (IF = 5.028)
2. **You Kangyong***, Guo Wenbin, Liu Yueliang, Wang Wenbo, Sun Zhuo. Grid Evolution: Joint Dictionary Learning and Sparse Bayesian Recovery for Multiple Off-grid Targets Localization. *IEEE Communications Letters*, vol. 22, Oct. 2018, pp. 2068-2071. (IF = 3.419)
3. **You Kangyong***, Guo Wenbin, Zuo Peiliang, Liu Yueliang, Wang Wenbo. Sparse Bayesian Learning for Multiple Sources Localization with Unknown Propagation Parameters. *IEEE International Symposium on Personal, Indoor and Mobile Radio Communications*, Istanbul, Turkey, Sep. 2019.
4. 游康勇*, 杨立山, 郭文彬. 无线传感器网络下基于压缩感知的多目标分层贪婪匹配定位. *自动化学报*, 2019, 45(3): 480-489.
5. 游康勇*, 杨立山, 刘玥良, 郭文彬, 王文博. 基于稀疏贝叶斯学习的网格自适应多源定位. *电子与信息学报*, 2018, 40(9): 2150-2157.
6. Liu Yueliang, Guo Wenbin, **You Kangyong***, Zhao Lei, Peng Tao, Wang Wenbo. Graph Learning for Spatiotemporal Signals with Long- and Short-Term Characterization. *IEEE Transactions on Signal and Information Processing over Networks*. Early Access, Nov. 2020. (IF = 3.153)
7. Zuo Peiliang, Peng Tao, Wu Hao, **You Kangyong***, Jing Hanbo, Guo Wenbin, Wang Wenbo. Directional Source Localization Based on RSS-AOA Combined Measurements. *China Communications*, vol. 17, Nov. 2020, pp. 181-193. (IF = 2.024)
8. Peng Tao, Zuo Peiliang, **You Kangyong***, Jing Hanbo, Guo Wenbin, Wang Wenbo. Bounds and Methods for Multiple Directional Sources Localization Based on RSS Measurements. *IEEE Access*, vol. 7, Sep. 2019 pp. 131395-131406. (IF = 3.745)
9. Zuo Peiliang, Peng Tao, **You Kangyong***, Guo Wenbin, Wang Wenbo. RSS-Based Localization of Multiple Directional Sources With Unknown Transmit Powers and Orientations. *IEEE Access*, vol. 7, Jul. 2019, pp. 88756-88767. (IF = 3.745)
10. Liu Yueliang, Yang Lishan, **You Kangyong***, Guo Wenbin, Wang Wenbo. Graph

- Learning Based on Spatiotemporal Smoothness for Time-Varying Graph Signal. *IEEE Access*, vol. 7, May, 2019, pp. 62372-62386. (IF = 3.745)
11. Zuo PeiLiang, Peng Tao, Wang Xinyue, **You Kangyong***, Jing Hanbo, Guo Wenbin, Wang Wenbo. Spectrum Prediction for Frequency Bands with High Burstiness: Analysis and Method. *IEEE Vehicular Technology Conference*, Antwerp, Belgium, May, 2020.
 12. Zuo PeiLiang, Peng Tao, Wu Hao, **You Kangyong***, Jing Hanbo, Guo Wenbin, Wang Wenbo. Suppression of 802.11 Transmission in 2. 4GHz ISM band: Method and Experimental Verification. *IEEE Vehicular Technology Conference*, Antwerp, Belgium, May, 2020.
 13. Wang Dan, **You Kangyong***, Zuo Peiliang, Guo Wenbin, Peng Tao. Grid Adaptive Sparse Bayesian Learning for 2D-DOA Estimation with L-shape Array. *IEEE International Symposium on Personal, Indoor and Mobile Radio Communications*, Istanbul, Turkey, Sep. 2019.
 14. Liu Yueliang, **You Kangyong***, Guo Wenbin, Peng Tao, Wang Wenbo. Graph Learning for Spatiotemporal Dynamic Signal. *IEEE International Conference on Communications*, Shanghai, China, May, 2019.
 15. Wang Yue, **You Kangyong***, Wang Dan, Guo Wenbin. Grid Adaptive DOA Estimation Method in Monostatic MIMO Radar Using Sparse Bayesian Learning. *International Conference in Communications, Signal Processing, and Systems*, Urumqi, China, Jul. 2019.
 16. Yang Lishan, **You Kangyong***, Guo Wenbin. Bandlimited Graph Signal Reconstruction by Diffusion Operator. *EURASIP Journal on Advances in Signal Processing*, vol.12, Nov. 2016, pp. 1-17. (IF = 1.14)
 17. 杨立山, 游康勇*, 郭文彬. 基于扩散算子的带限图信号加权重建策略. *电子与信息学报*, 2017, 39(12): 2937-2944.
 18. Lin Xiaofei, **You Kangyong***, Guo Wenbin. Delaunay Triangulation and Mesh Grid Combining Algorithm for Multiple Targets Localization Using Compressive Sensing. *International Symposium on Wireless Personal Multimedia Communications*, Shenzhen China, Nov. 2016.