

密级：公开

北京邮电大学

硕士学位论文（学术学位）



题目： 面向视频重构任务的信道自适应语义
通信关键技术研究

学 号： 2023110065

姓 名： 祁治鑫

学科专业： 信息与通信工程

培养方式： 全日制

导 师： 黄丹蓝

学 院： 信息与通信工程学院

2026 年 3 月 16 日

Secret Level: Publication

Beijing University of Posts and Telecommunications



Master Degree

Key Technologies for Channel-Adaptive Semantic Communication in Video Reconstruction

Student ID: 2023110065

Author: Zhixin Qi

Subject: Information and Communication

Engineering

Supervisor: Danlan Huang

Institute: School of Information and

Communication Engineering

March 16, 2026

答辩委员会名单

职务	姓 名	职 称	工 作 单 位
答辩日期			

独创性（或创新性）声明

本人声明所呈交的论文是本人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢中所罗列的内容以外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京邮电大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

申请学位论文与资料若有不实之处，本人承担一切相关责任。

本人签名：_____ 日期：_____

关于论文使用授权的说明

本人完全了解并同意北京邮电大学有关保留、使用学位论文的规定，即：北京邮电大学拥有以下关于学位论文的无偿使用权，具体包括：学校有权保留并向国家有关部门或机构送交学位论文，有权允许学位论文被查阅和借阅；学校可以公布学位论文的全部或部分内容，有权允许采用影印、缩印或其它复制手段保存、汇编学位论文，将学位论文的全部或部分内容编入有关数据库进行检索。（保密的学位论文在解密后遵守此规定）

本人签名：_____ 日期：_____

导师签名：_____ 日期：_____

摘 要

随着信息技术的发展，语义通信已经成为 6G 通信的重要组成部分，它的应用前景十分广泛。深度学习驱动的信源信道编码联合编码（DeepJSCC）带来的视频语义通信为视频语义通信开辟了新途径。针对此，本文在视频 DeepJSCC 框架基础上提出了面向视频重建任务的信道自适应语义通信相关技术，主要贡献有：

首先，针对加性高斯白噪声信道、瑞利信道等常见时变信道，提出面向无线视频传输的信道自适应 DeepJSCC 框架。该模型引入了基于提示调优的动态信道适配模块，动态适配模块可根据信道语义动态调整卷积核和调制系数，在信道状态信息不充分或不完整的情况下能够有效工作。实验表明该方案在不同信道变化环境下均能有效工作，并且在 AWGN 信道、SNR=4 dB 时，AdaJSCCV 在 BVI-DVC 数据集上相较于 H.264 的方法 PSNR 提升 6.4 dB。

其次，面向空间维度复杂的 MIMO 信道，本文提出一种面向 MIMO 信道的语义感知自适应无线视频传输方案。本方案探讨了理想与非理想信道状态信息两种信道条件下的自适应视频传输。针对理想信道状态信息场景，本方案设计了针对 MIMO 信道的信道语义提取模块，该模块通过联合考虑特征通道域和空间域中的信道状态信息，生成信道表征。在信道表征的引导下，动态信道自适应模块使得系统能够适应变化的信道条件。在非理想信道状态信息情况下，提出了信道去噪模块，用于从含噪观测中恢复近似准确的信道状态信息。实验结果表明，所提出的方案能够有效适应 MIMO 信道变化，在 SNR=20dB 时，PSNR 比其他深度联合信源信道编码方法提升 3.7dB。

进一步，为探索超越物理层信息的自适应能力，提出了基于多模态交叉注意力的自适应无线视频传输模型。该模型创新性地引入文本模态作为信道的高层语义描述，通过设计的多模态交叉注意力模块，将基于变换器的双向编码器（BERT）编码的文本语义与视觉特征进行深度对齐与融合，从而实现对抽象语义信道变化的有效适应。实验证明了该方法的显著性能增益。

关键词：信源信道联合编码；无线视频传输；无线信道表征；动态信道自适应；多模态交叉注意力

ABSTRACT

With the development of information technology, semantic communication has become an important component of 6G communication, and its application prospects are very broad. Deep learning-driven joint source-channel coding (DeepJSCC) provides a new approach for video semantic communication. In view of this, this thesis proposes channel-adaptive semantic communication-related technologies for video reconstruction tasks based on the video DeepJSCC framework, with the main contributions being:

First, for common time-varying channels such as additive Gaussian white noise channels and Rayleigh channels, a channel-adaptive DeepJSCC framework oriented towards wireless video transmission is proposed. This model introduces a prompt-tuning-based dynamic channel adaptation module, which can dynamically adjust convolution kernels and modulation coefficients according to channel semantics and can operate effectively even when the channel state information is insufficient or incomplete. Experiments show that this scheme can work effectively under different channel variation environments, and on the AWGN channel with SNR=4 dB, AdaJSCCV improves PSNR by 6.4 dB on the BVI-DVC dataset compared to the H.264 method.

Secondly, for MIMO channels with complex spatial dimensions, this thesis proposes a semantic-aware adaptive wireless video transmission scheme designed for MIMO channels. This scheme explores adaptive video transmission under both perfect and imperfect channel state information conditions. For the scenario with perfect channel state information, the scheme designs a channel semantics extraction module for MIMO channels. This module generates channel representations by jointly considering the channel state information in both the feature channel domain and the spatial domain. Guided by the channel representations, the dynamic channel adaptation module enables the system to adapt to changing channel conditions. In the case of imperfect channel state

information, a channel denoising module is proposed to recover nearly accurate channel state information from noisy observations. Experimental results demonstrate that the proposed scheme can effectively adapt to MIMO channel variations, achieving a PSNR improvement of 3.7 dB over other deep joint source-channel coding methods at an SNR of 20 dB.

Furthermore, to explore adaptive capabilities beyond the physical layer information, an adaptive wireless video transmission model based on multimodal cross-attention is proposed. This model innovatively introduces the text modality as a high-level semantic description of the channel. Through the designed multimodal cross-attention module, the text semantics encoded by the transformer-based bidirectional encoder (BERT) are deeply aligned and fused with visual features, thereby achieving effective adaptation to abstract semantic channel variations. Experiments demonstrate the significant performance gains of this method.

KEY WORDS: Deep Joint Source-Channel Coding; Wireless Video Trans-mission; Wireless Channel Characterization; Dynamic Channel Adaptation; Multimodal Cross-Attention

目录

摘 要.....	I
ABSTRACT.....	III
第一章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状与发展趋势.....	3
1.2.1 基于深度学习的视频信源信道联合编码.....	3
1.2.2 传统加性高斯白噪声、瑞利信道的信道自适应技术.....	4
1.2.3 复杂 MIMO 信道的信道自适应技术.....	5
1.2.4 多模态模型驱动的信道自适应视频语义通信.....	6
1.3 本文研究内容与结构安排.....	7
1.3.1 主要研究内容.....	7
1.3.2 结构安排.....	8
第二章 视频语义通信以及信道自适应的相关技术.....	11
2.1 相关的深度学习模型.....	11
2.1.1 卷积神经网络.....	11
2.1.2 Vision Transformer.....	12
2.2 传统视频传输算法.....	14
2.3 基于深度学习的视频语义通信算法.....	16
2.4 相关评估指标.....	17
第三章 基于自适应提示调优的语义视频传输方案.....	21
3.1 引言.....	21
3.2 基于自适应提示调优的语义视频传输系统.....	22
3.2.1 动态信道自适应方法.....	26
3.2.2 基于无网络熵编码的变长编码模块.....	27
3.2.3 条件编码器和条件解码器.....	28
3.3 仿真实验设置.....	29
3.3.1 数据集.....	29
3.3.2 训练设置.....	30
3.3.3 对比方案与评估指标.....	30
3.4 结果性能分析.....	31
3.5 消融实验.....	34

3.6 本章小结	37
第四章 面向 MIMO 信道语义感知的自适应无线视频传输	38
4.1 引言	38
4.2 面向 MIMO 信道的语义感知自适应无线视频传输系统建模.....	40
4.2.1 MIMO 信道语义提取模块	43
4.2.2 信道去噪模块.....	45
4.2.3 运动-外观特征提取模块	46
4.2.4 JSCC 编码器、解码器与帧重建模块	47
4.3 仿真实验设置	48
4.3.1 数据集.....	48
4.3.2 训练设置.....	48
4.3.3 对比方案与评估指标.....	48
4.4 结果性能分析	49
4.5 结论	54
第五章 基于多模态交叉注意力的自适应无线视频传输.....	55
5.1 引言	55
5.2 基于多模态交叉注意力的自适应视频传输方法	56
5.2.1 多模态交叉注意力模块.....	58
5.3 仿真实验设置	59
5.3.1 数据集.....	59
5.3.2 训练设置.....	59
5.3.3 对比方案与评估指标.....	60
5.4 结果性能分析	62
5.5 本章总结	65
第六章 总结与展望.....	66
6.1 总结	66
6.2 展望	67
参考文献.....	69
缩略词.....	74
致谢.....	76
攻读学位期间发表的学术论文目录.....	77
作者学习经历.....	78

符号说明

符号	意义
$\mathbf{x}_t$	视频帧
$\mathbf{m}_t$	运动适量
$\mathbf{y}_t$	视频帧的语义表征
$\mathbf{c}_t$	视频帧的上下文信息
$f_c(\cdot; \phi)$	上下文信息提取器
$f_e(\cdot; \psi)$	语义信息编码器
$\mathbf{s}_t$	传输的码字
k_t	码字的长度
P_c	信道参数集
$\mathbf{r}$	信道语义表征
$\hat{\mathbf{s}}_t$	接收端的码字
$\check{\mathbf{y}}_t$	接收端恢复的视频帧语义表征
$\hat{\mathbf{y}}_t$	接收端去噪的视频帧语义表征
$f_e(\cdot; \theta)$	语义信息解码器
$\hat{\mathbf{x}}_t$	接收端恢复的视频帧

第一章 绪论

1.1 研究背景与意义

随着移动通信技术从第五代（5 Generation, 5G）向第六代（6 Generation, 6G）迈进，全球无线通信正经历从连接万物到万物智联的范式演进^[1]。在未来 6G 通信愿景下，全场景、全维度的智能化交互业务将呈现爆发式增长。这不仅涵盖了面向人类感知的极致体验业务，如元宇宙（Metaverse）、沉浸式在线会议、扩展现实（Extended Reality, XR）、多感官远程协作及全息通信等；亦包括面向机器类通信（Machine-Type Communication, MTC）的高精尖应用，如精准工业动作控制、车辆编队协同、无人机群自主控制及远程医疗手术等^[2]。此类新兴应用对网络传输的性能提出了近乎苛刻的异构需求，主要体现为极高的吞吐量、确定性的低时延、超高连接稳定性以及海量数据处理能力^[3]。特别是在视频业务领域，随着超高清视频、点云视频及多视角交互视频的普及，其产生的数据流规模呈几何级数增长，在频谱资源日益稀缺且空间分布极不均匀的无线网络环境中，如何保障无处不在且高质量的视频业务传输，已成为当前无线通信领域亟待解决的重大技术难题。




图 1-1 语义通信架构图

在长达数十年的通信发展史中，视频传输系统主要遵循香农分离定理^[4]，即信源编码与信道编码独立进行处理。信源编码通过消除原始视频中的空间、时间及统计冗余来提升压缩效率，而信道编码则通过引入可控冗余来增强抗噪声干扰能力。尽管该范式在无限长码块假设下展现了卓越的理论性能，但在实际的宽带无线交互场景中，其局限性日益凸显。首先，分离架构下的视频传输对带宽具有极高的依赖性，当业务负载激增时，系统难以根据内容的重要程度对比特流进行动态优先级分配，导致频谱效率的边际效益递减。其次，在复杂多变的无线信道中，传统通信系统极易遭遇“悬崖效应（cliff effect）”^[5]，一旦信道信噪比（Signal-to-Noise Ratio, SNR）低于预设解调门限，视频重构质量将发生断崖式下跌，甚至

导致接收端完全无法解码，这种非线性劣化严重影响了用户的感知体验（Quality of Experience, QoE）。

针对传统通信架构在处理海量视频数据时的乏力，语义通信（Semantic Communication, SemCom）^[6]作为一种突破传统香农限界的新兴范式，为解决资源受限下的传输难题提供了全新思路。语义通信架构图如图 1-1 所示，语义通信不再执着于物理层比特序列的精确无误传输，而是聚焦于数据背后的语义含义表达。通过深度学习模型提取视频数据中的核心语义特征并剔除任务无关的冗余信息，语义通信能够在极低带宽占用的前提下，确保关键信息的准确传递与重构^[6]。这种从数据传输向信息传递的跨越，极大地优化了数据压缩效率和频谱资源利用率。在此趋势下，视频语义通信技术应运而生，通过构建端到端的深度信源信道联合编码（Deep Joint Source-Channel Coding, DeepJSCC）框架，该技术能够将视频的深层语义表征直接映射到信道符号空间，为未来高效视频传输提供了极具竞争力的解决方案。

然而，视频语义通信在实际应用中仍面临诸多技术问题，其中最重要的问题是如何实现复杂信道环境下的鲁棒重构。视频语义的语义信息对信道噪声具有敏感性，而无线信道具有时变性、多径衰落和多普勒频移等非平稳性。首先，码率控制在语义空间中的映射尚不完备，如何根据瞬时带宽动态调整视频特征的压缩率是保证传输连续性的关键所在。其次，要具有强大的信道自适应性能，以应对复杂的加性高斯白噪声信道（Additive White Gaussian Noise, AWGN）信道到复杂的瑞利衰落信道信号的失真，尤其是在大规模多入多出（Multiple-Input Multiple-Output, MIMO）信道等超高维度信道中，信号衰减和多径干扰会导致语义特征在传输过程中出现不可逆的非线性畸变，从而降低视频重构的质量和稳定性^[8]。

因此，本文重点研究面向视频重构任务的基于深度学习的信源信道联合编码技术，旨在系统性地解决已知信噪比条件下的可变长编码、信道自适应以及系统鲁棒性等核心问题。本文将探讨在 AWGN、瑞利衰落以及更复杂的大规模 MIMO 信道模型下，如何通过优化神经网络架构提升信道估计的精度与特征映射的鲁棒性，从而在恶劣信道条件下维持高水平的视频重构性能。进一步地，考虑到大规模预训练模型在跨模态理解与泛化能力上的巨大优势，本文将探索多模态大参数模型在信道感知与自适应领域的应用路径，试图通过引入先验语义知识库，增强系统对未知信道环境的泛化能力，为构建下一代高效、智能、鲁棒的无线视频传输系统提供坚实的理论支撑与技术演进方案。

1.2 国内外研究现状与发展趋势

1.2.1 基于深度学习的视频信源信道联合编码

在过去数十年中，无线视频传输架构的设计深度耦合了香农的分离定理，即信源编码与信道编码被视为两个独立的优化维度。信源编码阶段主要致力于消除视频数据内部的统计冗余、空间冗余与时间冗余，其演进路线从早期的 H.264^[9] 跨越到高效视频编码标准 H.265^[10]，直至最新的多功能视频编码（Versatile Video Coding, VVC），不断逼近有损压缩的率失真极限。与此同时，信道编码通过引入前向纠错（Forward Error Correction, FEC）机制，如低密度奇偶校验码（Low-Density Parity-Check, LDPC）^[11] 和极化码，以确保比特流在噪声信道中的传输可靠性。

然而，随着超高清（Ultra High Definition, UHD）、交互式实时流媒体等业务的迅速增长，在资源受限场景下，这种基于比特流精确传输的分离架构的弊端日益凸显。首先，分离架构往往会忽略视频不同内容对任务目标的不同贡献度，导致有限的频谱资源被平均分配给关键语义、次要语义甚至是冗余背景，会导致频谱资源的高度浪费。其次，由于信源编码后的信息流对误码极其敏感，当信道质量跌破译码门限时，重建视频质量将发生非线性的剧烈下降，甚至导致解码器完全失效。在高清无线会议等高带宽、低延迟场景中，传统方法对带宽的分配缺乏灵活性，以及计算资源的高消耗，已成为限制其性能进一步突破的核心障碍。

鉴于传统范式的局限，语义通信作为一种突破香农限制的新型架构，在文本^[12] 与图像传输^{[13][14]} 领域率先取得了理论突破。不同于传统的比特流传输，语义通信旨在提取并传递数据中与特定任务相关的深层特征，为解决复杂动态环境下的视频传输难题开辟了新路径。针对视频序列所特有的空时维度耦合性，国内外学者开展了大量极具启发性的探索工作。

在视频语义通信端到端联合优化方面，Tung 等人^[15] 率先打破了编码模块与解码模块的边界，提出了一种将视频压缩、信道编码与调制过程完全整合的深度神经网络（Deep Neural Network, DNN）架构。该研究通过引入强化学习（Reinforcement Learning, RL）算法^[16] 构建动态带宽分配网络，实现了在信道变化场景下视觉重构质量的最大化，验证了端到端系统在非平稳环境下的优越性。随后，Wang 等人^[17] 针对视频帧间的相关性特征，利用非线性变换与条件编码架构，在特征域实现了高效的语义冗余消除。该方法通过深度联合信源信道编码，将提取出的视频语义特征直接映射至物理信道符号，显著增强了系统对比特误码的鲁棒性。

在视频语义通信的表征学习与码率控制方面，当前的工作试图通过更精细的特征建模来平衡传输效率与质量。Bao 等人^[18]提出了一种基于潜在空间映射的视频传输方案，利用模型分割多址接入技术有效捕获了跨视频帧的帧间语义关联，并结合基于神经网络的熵模型实现了变长编码。这一创新使得系统能按照用户的需求精确控制压缩码长，从而在极低码率下依然能恢复出完整、清晰的视频。在架构设计与自适应决策方面，Gong 等人^[19]充分利用了 Swin Transformer^[20] 在捕获长程空间依赖关系上的优势，设计的语义编解码器能高效提取视频帧的语义信息，并配合 Actor-Critic^[21] 强化学习框架实现了码率的自适应调节。该模型能够根据实时信道状态与任务需求做出最优传输策略，极大地提升了视频语义传输在真实复杂场景中的环境感知能力与重构保真度。

1.2.2 传统加性高斯白噪声、瑞利信道的信道自适应技术

在无线视频传输系统中，信道自适应是保证传输可靠性和资源利用率的基础环节，其理论依据在于香农第二准则，即信道容量 C 与带宽 W 以及信噪比 SNR 之间的对数关系：

$$C = W \log_2(1 + S/N). \quad (1-1)$$

由于无线信道具有时变性和随机性，即使是 AWGN 或瑞利衰落等基础信道模型，信号的瞬时信噪比也会因多径效应、阴影衰落及终端移动性而剧烈变化。在瑞利衰落信道中，一辆高速行驶的汽车，其接收信号的瞬时信噪比会在毫秒级内发生超过 10dB 的剧烈波动。为了在有限的带宽资源下保持最佳的用户感知体验，系统必须能根据瞬时信道状态动态地调节信息的冗余度与压缩率。传统的自适应调制编码（Adaptive Modulation and Coding, AMC）技术^[22] 主要依靠查询表作为基础，但在端到端的语义通信框架中，离散的调整方式难以捕捉深层语义特征以及物理信道损伤之间的非线性映射关系。因此，研究具有连续信道感知能力的深度自适应架构，对于突破传统通信系统的性能瓶颈具有重要的理论与实践意义。




图 1-2 SNR 与语义信息拼接处理方案图

针对简单信道环境下的自适应传输,学术界开展了系列探索。Xu 等人^[23]率先提出了一种基于信道的软注意力机制,该机制通过学习信道状态信息,在不同 SNR 条件下实时调整源编码的压缩比率与信道编码的保护强度。随后, Niu 等人^[24]进一步深化了这一思路,通过引入信道与空间双重注意力机制^[25],实现了对视频语义特征的多维度加权。这种方法不仅能够根据信道噪声水平过滤无效特征,还能在空间维度上对关键视觉语义进行增强保护,有效减轻了物理信道衰落对重构任务的影响。然而,尽管上述方法在一定程度上提升了系统的灵活性,但其内在的融合机制仍存在明显的局限性。

目前的流行方案通常将标量 SNR 或信道增益信息通过简单的串联操作与高维视觉特征进行初步整合,并输入静态神经网络,如图 1-2 所示。从信息论与表征学习的角度分析,这种粗粒度的特征融合策略存在以下深层问题。这种方法存在特征交互深度不足的问题,简单的拼接操作仅在输入层实现了数值上的叠加,未能充分挖掘物理层信道参数与感知层语义特征之间的深层非线性关联。由于信道噪声对不同频率和重要性的语义特征损伤程度各异,缺乏动态互补机制会导致网络难以对关键语义信息进行精准的处理。静态网络的参数存在泛化局限,现有的自适应模型大多采用静态神经网络,其权重参数在训练完成后即被冻结。这意味着模型必须利用一组固定的参数去逼近涵盖极低到极高 SNR 的全量映射空间,这种一对多的训练模式限制了系统在极端或非平稳信道环境下的适应上限。由于信噪比信息与视觉内容未能实现语义信息级别的深度融合,网络往往只能学习到一种宏观的增益补偿,而忽略了复杂信道条件下视频帧内局部区域的语义演进关系,从而降低了系统在多变环境下的鲁棒性。因此,现有方法在提升信道适应性与系统性能方面存在明显不足,亟需设计更灵活、高效的动态融合机制与自适应网络结构。

1.2.3 复杂 MIMO 信道的信道自适应技术

在复杂的无线通信环境中 MIMO 技术作为提升系统容量与传输可靠性的核心手段,已成为未来 6G 移动通信不可或缺的基石。相比于 AWGN 或瑞利衰落等基础信道模型, MIMO 信道的自适应技术面临着更为严峻的挑战。首先, MIMO 系统引入了高维度的矩阵运算,信号在空间维度上存在强耦合性,导致严重的层间干扰;其次,在大规模 MIMO 场景下,信道具有显著的空间相关性与时频非平稳性,传统的线性估计方法难以精准捕获复杂的信道特征;此外,语义信息在经过高维信道矩阵映射时,其特征结构易受到多径时延扩展与多普勒频移的双重破坏。因此,研究 MIMO 环境下的自适应语义通信具有极其重要的必要性,只有攻克高维度信道下的特征鲁棒映射,才能发挥语义通信在海量数据流传输中的巨大潜力,使之真正具备商用价值。

针对这一前沿领域,学术界开展了系列具有代表性的研究。Xie 等人^[26]提出了一种面向 MIMO 系统的语义传输框架,该方案基于导频信号获取信道状态信息 (Channel State Information, CSI),并独创性地设计了非侵入式 CSI 融合多头注意力模块。在该架构中,CSI 被视为关键的边信息,辅助语义提取器在特征编码阶段动态规避信道深度衰落的影响,从而显著增强了语义流传输的鲁棒性。Wu 等人^[27]则通过引入视觉变换器 (Vision Transformer, ViT)^[28]模型,利用其强大的自注意力机制协同处理图像语义特征与 CSI 矩阵。该方法不仅实现了语义空间与物理信道状态的高维对齐,还展现出对异构天线配置与多变信道拓扑的非凡灵活性。此外,针对正交频分复用 (Orthogonal Frequency Division Multiplexing, OFDM) 架构下的 MIMO 传输,Wang 等人^[29]利用 Transformer^[30]捕获子载波间的长程相关性,通过动态调整子载波权重来提取信道矩阵的全局特征,在提升信道估计精度的同时,优化了特征在频域上的分配策略。

然而,通过分析目前的研究成果可以发现,复杂信道场景下的视频语义通信仍存在很多需要解决的学术问题。首先,理想化信道条件与真实信道环境的脱节,大多数现有模型假设接收端和发送端能够获得完美的、完全已知的 CSI 矩阵,但在实际非平稳无线环境中,由于有限的带宽与设备的移动性,获取高精度 CSI 及其困难。其次,现有方法在实现 MIMO 信道场景下的自适应时,往往采用简单的拼接方式,也就是将 CSI 矩阵与视觉语义信息进行拼接,忽略了 MIMO 信道中的空间、时间相关性等信息。

因此,开发能够在非理想 CSI 的情况下,利用 CSI 空间和时间相关性信息进行 MIMO 信道自适应的创新解决方案,已成为当前提升语义通信系统实用性的关键。本文后续章节将探讨如何在无需精确 CSI 先验的条件下,利用 MIMO 信道的空间和时间相关性实现信道自适应。

1.2.4 多模态模型驱动的信道自适应视频语义通信

随着语义通信研究的深入,学术界开始意识到单模态信息在表征复杂物理环境时的局限性,进而转向探索利用多模态先验信息提升系统自适应能力。多模态感知通过融合文本、图像、传感器数据等异构信息,能够为通信系统提供更全面的上下文关联,已成为实现智能自适应传输的前沿路径。

在利用外部先验辅助通信决策方面,已有研究尝试引入非通信模态数据来增强信道感知。例如,部分研究探讨了利用摄像头、激光雷达等感知设备捕获的视觉场景信息来辅助毫米波束预测,证明了跨模态特征在刻画物理传播环境方面具有显著优势^{[30][31][32]}。随后,研究者开始尝试将自然语言处理领域的成熟技术引入语义通信架构。在跨模态特征融合机制上,现有的相关工作主要聚焦于如何建立非对称模态间的有效映射。一些先进的语义通信框架借鉴了计算机视觉中的注

意力机制，通过引入自注意力或融合注意力模块，尝试在特征编码阶段将环境参数与源语义进行整合。

尽管利用多模态模型进行信道自适应的方式工作还没有大规模应用于视频语义传输，但这种语义辅助通信的方法，证明了利用强大的预训练语言模型来捕捉通信场景与数据特征之间复杂非线性关系的潜力。因此，如何构建高性能的多模态信道表征模型以深层刻画信道环境，并设计高效的跨模态特征交互机制实现信道语义与视觉信息的深度结合，已成为提升无线视频语义传输系统自适应能力的关键问题。

1.3 本文研究内容与结构安排

1.3.1 主要研究内容




图 1-3 研究内容与技术路线图

本文主要研究内容为基于信源信道联合编码的无线视频传输算法研究，研究内容与技术路线如图 1-3 所示。本文研究端到端视频传输网络的设计方法，重点解决传统 AWGN、瑞利信道等信道条件下的码率自适应、信道自适应以及抗干扰优化问题。具体来说，本文提出基于提示调优的动态信道适应方法，在细致或者粗略的信道状态信息，能根据信道语义信息动态调整卷积核与调制系数，以动态适应信道变化。进一步探讨在大规模 MIMO 信道条件下，基于信源信道联合优化的端到端视频编码与传输策略。针对 MIMO 信道设计了信道语义提取模块，通过联合分析信道特征通道域与空间域的信道状态信息，构建具有语义意义的信道表征。针对非理想信道状态信息场景，提出了基于 Transformer 结构的信道去

噪模块，有效提升了信道估计精度。最后，探讨多模态模型在信道自适应视频传输上的应用。研究内容具体如下：

(1) 本研究围绕传统信道条件下自适应无线视频传输展开，提出了一种基于提示学习的深度联合信源信道编码方法。该方法的主要创新点在于构建了信道状态信息条件调制机制：通过信道语义提取模块将 CSI 编码为多粒度提示向量，并以提示向量作为条件指导动态信道适应模块实时生成卷积核参数与调制系数，实现对时变信道进行不同的编码。同时，本文设计了一种无网络熵模型的变长编码模块，通过高斯分布建模语义特征的概率分布，并基于显式码率约束自适应选择最重要的语义维度进行传输，在保证重构质量的同时显著降低了计算复杂度。实验结果表明所提方案有效克服了传统静态网络架构在特征融合深度与自适应能力方面的局限。通过将 CSI 信息深度融入语义提取与编码过程，实现了视频内容与信道自适应能力的有机统一，显著提升了系统在动态无线信道环境下的传输鲁棒性与带宽利用效率，为视频语义通信的信道自适应提供了重要技术路径。

(2) 本研究针对 MIMO 信道视频传输中动态自适应能力不足的核心问题，提出了一种针对 MIMO 信道的语义感知自适应传输模型 (Semantic-Aware Adaptive Wireless Video Transmission over MIMO Channels, SAWV-MIMO)。通过设计 MIMO 信道语义提取模块，在特征通道和空间双维度生成可学习的 CSI 提示向量，驱动动态信道适应模块实现网络参数的实时精准调制；针对非理想信道条件，创新性构建基于 Transformer-U-Net 架构的信道去噪模块，通过多头自注意力机制实现多层次特征融合，有效提升 CSI 估计精度。实验验证表明，该方案通过注意力机制加权聚合的多维度提示向量，显著增强了对 MIMO 信道时空特性的感知能力，解决了传统静态网络在复杂信道环境下自适应能力僵化的问题。相较于现有方法，SAWV-MIMO 在非理想 CSI 条件下仍能保持优异的传输性能，为 MIMO 信道视频传输提供了创新解决方案。

(3) 针对视频信道自适应传输系统难以融合视频语义信息与信道信息的核心问题，本文提出了一种多模态模型驱动的信道自适应视频语义通信架构。该方法创新的核心意义在于：首先，通过引入信道环境的文本描述并利用预训练的文本模型进行特征提取，将原本零散、高频波动的物理层信道参数转化为高维、抽象的环境语义表征，实现了对通信场景先验知识的深度挖掘；其次，利用交叉注意力机制在特征域构建了信道语义与视觉语义的深层交互链路，使网络能够根据环境衰落特性动态、非线性地调节视频特征的权重分布，从而在保障关键语义传输的同时抑制噪声干扰。

1.3.2 结构安排

本论文共分为六章，具体的组织结构如下：

第一章是绪论,该章节主要阐述了面向视频重建任务的信道自适应语义通信技术研究的背景与意义、国内外相关技术的研究现状与发展趋势,包括基于深度学习的视频信源信道联合编码、简单信道的信道自适应技术、MIMO 信道的信道自适应技术以及多模态模型的信道自适应的研究现状。然后阐述了本文的主要研究内容,并提供了本篇论文的整体组织架构。

第二章是视频语义通信以及信道自适应技术的相关技术,该章分为四部分。其中,第一部分介绍本论文涉及的相关的深度学习模型;第二部分介绍传统视频编码算法,包括 H.264、H.265 等视频编码算法;第三部分介绍基于深度学习的视频语义通信算法,包括视频语义通信的框架以及每一个模块的功能和作用;第四部分介绍相关的评价指标,包括视频的重建质量的评价指标以及模型复杂度的评价指标。

第三章介绍了基于自适应提示调优的语义视频传输方法。本章首先对现有的视频传输信道自适应算法进行梳理,指出目前算法存在的问题。然后,提出了一种新颖的深度联合信源信道的信道自适应视频编码模型 (Adaptive Deep Joint Source-Channel Coding for Wireless Video Transmission, AdaJSCCV),以实现信道与内容自适应的无线视频语义通信。该模型通过联合信源信道编码器与上下文条件编码器高效提取语义信息。本章设计了动态信道自适应模块,从物理信道中提取出信道语义信息,并与视频语义信息进行融合,从而提升其应对多样化信道条件的能力。另外,本章提出了一种低复杂度的基于无网络熵模型的变长编码模块,以实现编码码长的精确控制。然后介绍了模型的训练目标以及参数设置。最后,通过实验证明了 AdaJSCCV 在视频传输中的有效性。

第四章介绍了面向 MIMO 信道的语义感知自适应无线视频传输。本章首先对现有 MIMO 信道自适应视频传输的方法进行了总结,发现目前方法存在的问题。在此基础上,本章提出了一种 MIMO 信道的深度联合信源信道编码模型——SAWV-MIMO,以实现 MIMO 信道自适应的无线视频语义通信。本章设计了 MIMO 信道语义信息提取模块,从信道状态信息以及接收端信号的空间与特征维度进行建模,提取出 MIMO 信道的语义信息,从而将变化的信道噪声条件与语义信息进行深度融合,从而提升系统应对多样化信道环境的能力。此外,针对非理想信道条件,本章提出了信道去噪模块,能够从含噪的信道状态信息中估计出准确的信道状态,为后续重建提供可靠的信道先验。实验结果表明,SAWV-MIMO 能够有效适应 MIMO 信道的变化,在多种信噪比与码率条件下均取得优越的重建性能,验证了动态信道自适应模块与信道去噪模块的有效性。

第五章围绕多模态模型在无线视频传输的信道自适应方面展开讨论。本章提出了一种基于多模态交叉注意力的自适应视频传输模型 (Multimodal Cross-

Attention for Channel-Adaptive Video Transmission, MCAJSCCV), 以实现信道与内容自适应的无线视频语义通信。本章设计了多模态交叉注意力模块, 首先使用预训练的 BERT 对信道描述文本进行编码, 然后将其映射到视觉特征领域, 进而将信道语义信息与视觉特征进行融合, 提高了模型的抗干扰能力。实验结果表明, MCAJSCCV 在重建质量与鲁棒性方面均优于传统的无线视频通信方案及其他深度联合信源信道编码方法, 有效验证了所提出的多模态交叉注意力模块的有效性。

第六章是总结部分, 对全文的研究内容进行总结。

第二章 视频语义通信以及信道自适应的相关技术

2.1 相关的深度学习模型

2.1.1 卷积神经网络

卷积神经网络（Convolutional Neural Network, CNN）^[33] 作为计算机视觉领域的基石模型，其设计灵感源于生物视觉系统的局部感受野机制——生物视网膜上的神经节细胞仅对特定局部区域的光刺激产生响应，这种特性被抽象为 CNN 的核心操作逻辑，通过局部卷积核在输入特征图上滑动，仅关注相邻像素的空间相关性，再借助权值共享大幅压缩参数规模，使得同一卷积核在不同空间位置重复使用。同时通过池化层，如最大池化、平均池化等池化模块，对特征图进行下采样，逐步扩大感受野并抽象出高层语义特征，并且往往在 CNN 中使用激活函数引入非线性结构。这种局部感知、层次化抽象的设计范式，使 CNN 在处理高维图像数据时，既保持了较高的计算效率，又能精准捕捉空间结构信息，如物体的边缘轮廓、纹理细节、形状特征等，因此成为空间语义提取的基础工具。




图 2-1 CNN 结构图

CNN 的结构包括卷积层、池化层和激活函数等，如图 2-1 所示。卷积层是 CNN 的核心组件，它通过卷积操作将输入图像与一组可学习的卷积核进行逐元素相乘，并对相乘结果求和，从而生成输出特征图。卷积操作能够捕捉图像中的局部特征。池化层用于降低卷积层生成特征图的空间维度，减少参数数量和计算量。池化层能够提取特征的空间不变性，对输入特征进行平移、缩放等操作，具有一定的鲁棒性。激活函数引入了非线性变换，增加了模型的表达能力。全连接层用于将提取的特征映射与输出进行关联，进行最终的分类或回归。全连接层通常位于卷积层和输出层之间。卷积神经网络还可能包含其他组件，如批归一化层^[34] 用于加速网络收敛和增强模型的鲁棒性；Dropout 层^[35] 用于随机丢弃一定比例的神经元，以减少模型过拟合。通过多个卷积层、池化层和全连接层的堆叠，卷积神经网络能够逐渐提取和组合图像中的高层次特征，实现对图像的语义理解和高级推理。

从模型演进脉络看，CNN 的发展按照网络深度增加以及结构优化进行发展的。1998 年 LeNet-5^[33] 的提出开启了 CNN 在计算机视觉中的应用先河，LeNet-5 包含 2 个卷积层、2 个池化层和 3 个全连接层，主要用于手写数字识别；2012

年, AlexNet^[36] 在 ImageNet 竞赛中的突破, 首次证明深层 CNN 的特征表达能力远超传统方法, AlexNet 包含 5 个卷积层、3 个全连接层, 并且引入激活函数、Dropout 正则化以及 GPU 加速的技巧; 2014 年 VGGNet^[37] 通过堆叠 3×3 小卷积核, 进一步加深网络深度, 提升了特征的细粒度表达能力, 可以捕捉物体的微小纹理; 2015 年 ResNet^[38] 针对深层网络的梯度消失问题, 提出残差连接, 使网络深度突破 100 层, 显著增强了对复杂语义的提取能力。这些演进不仅提升了 CNN 的特征表达能力, 也为其在视频处理中的应用提供了更丰富的选择。例如, ResNet-50 常用于云端服务器的高精度空间语义提取, 而轻量化的 MobileNet^[39] 通过深度可分离卷积将参数数量减少至标准 CNN 的 12% 左右, 适合边缘设备的实时语义提取, 满足视频语义通信中低延迟、低功耗的需求。

在视频语义通信的具体场景中, CNN 的核心价值在于空间语义的精准编码, 视频的每一帧本质是一张静态图像, CNN 能高效捕捉帧内的空间结构信息。这些空间特征是视频语义的基础载体, 后续的语义压缩、信道传输均需基于此展开。在视频语义通信的编码端, 常用 CNN 提取视频帧的空间特征图, 再通过语义编码器将特征图压缩为低维语义向量, 减少传输带宽需求。然而, CNN 的局部感受野特性也带来了固有局限性, 它难以捕捉长距离空间依赖, 且对时序信息的处理能力较弱。视频的语义不仅包含空间结构, 还包含时序演化, 而 CNN 的单帧独立处理模式无法直接建模时序关系, 需结合循环神经网络^[40] 或 3D CNN 扩展时序维度。尽管如此, CNN 凭借计算效率高、硬件适配性好、空间特征提取成熟等优势, 仍是视频语义通信中不可或缺的基础模型, 尤其在边缘设备的轻量级部署场景中, 其地位尚未被其他模型完全取代。

2.1.2 Vision Transformer

Vision Transformer (ViT) 的提出是 Transformer 架构从自然语言处理 (Natural Language Processing, NLP) 向计算机视觉领域跨模态迁移的标志性成果, 其核心创新在于用全局自注意力机制突破卷积神经网络的局部感受野限制, 为视觉处理中的长距离语义关联建模提供了全新的技术范式。2020 年, Dosovitskiy 等人首次将 Transformer 架构应用于图像分类任务, 证明了无卷积的序列化处理方式在视觉任务中的有效性, 当预训练数据规模足够大时, ViT 的性能可超越同期最优的 CNN 模型, 这一结论彻底改变了计算机视觉领域卷积主导的技术格局, 也为视频语义通信中的全局语义提取奠定了理论基础。




图 2-2 ViT 核心架构图

ViT 的核心架构遵循 Transformer 编码器的框架，但针对视觉数据的特性进行了针对性改造，其流程可概括为图像块序列化、特征嵌入、位置编码、Transformer 编码器和任务头五大步骤，如图 2-2 所示。首先，图像块分割与嵌入将输入的 $224 \times 224 \times 3$ RGB 图像分割为固定大小的非重叠图像块，如 16×16 像素，每个块被展平为 $16 \times 16 \times 3 = 768$ 维的一维向量，再通过线性嵌入层映射到高维特征空间，这一步类似于 NLP 中将文本分割为 Token 的操作，将连续的视觉信号转化为离散的序列数据，使 Transformer 能像处理文本一样处理图像。由于 Transformer 的自注意力机制对序列顺序不敏感，需为每个图像块添加可学习的位置编码，通过正弦函数或随机初始化的向量保留图像块的空间位置信息，确保模型能区分不同 Patch 的空间关系，这是 ViT 适配视觉数据的关键设计。

Transformer 编码器是 ViT 的核心组件，由多头自注意力（Multi-Head Self-Attention, MSA）与前馈神经网络（Feed-Forward Network, FFN）堆叠而成。自注意力机制的数学本质是通过查询（Query, Q）、键（Key, K）、值（Value, V）三个矩阵的点积计算不同图像块间的相关性权重，公式为：

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V, \quad (2-1)$$

其中 d_k 是键的维度， $\sqrt{d_k}$ 用于缩放点积结果以避免梯度消失。多头自注意力中的每个头捕捉不同子空间的语义关联，再通过线性层融合多头输出，增强特征的多样性与判别性。前馈网络则由两层全连接层与 GELU 激活函数组成，对注意力输出进行非线性变换，提升特征的抽象能力。此外，ViT 沿用了 Transformer 的残差连接与层归一化策略，处理过程可以表示为：

$$\text{Output} = \text{LN}(X + \text{MSA}(X)). \quad (2-2)$$

与 CNN 相比, ViT 的全局自注意力机制是其主要优势, CNN 通过局部卷积核只能捕捉相邻像素的空间相关性, 而 ViT 的自注意力可以计算任意两个图像块间的相关性。此外, ViT 的序列化处理方式使其能够适应视频数据的时序性, 因此只需将视频帧序列视为时间维度的图像块序列, 即可通过 TimeSformer^[41] 等变体实现时空联合注意力建模。

ViT 的演进方向与视觉语义通信的需求高度契合, 轻量化 ViT 通过深度可分离卷积、稀疏注意力等技术降低计算复杂度, 适配边缘设备的实时处理; 视频专用 ViT 变体通过分时空注意力、掩码自编码器等机制, 强化对视频时序语义的建模能力。这些演进进一步拓展了 ViT 在视频语义通信中的应用边界, 使其成为连接视觉感知与语义通信的关键技术桥梁。

2.2 传统视频传输算法

传统视频传输系统遵循香农提出的信源-信道分离定理, 将传输过程解耦为信源编码、信道编码、信道译码、信源译码四个独立模块, 信源编码聚焦去除冗余信息, 以最小化传输带宽; 信道编码聚焦抵抗信道噪声, 以最大化传输可靠性。这种分离架构是过去几十年视频通信的技术基石, 但也因模块分离优化导致在动态信道环境下的性能瓶颈。传统视频传输方法各模块追求局部最优, 导致端到端传输的性能只能达到次优的结果。其次, 传统视频传输系统会存在“悬崖效应”, 当信道质量低于特定阈值时, 重建质量会突然下降而非平滑下降。

传统视频传输的信源编码以冗余最小化为核心目标, 通过分层去除空间、时间与统计冗余, 将高维视频数据压缩为低带宽比特流, 其技术框架以 H.264/AVC、H.265/HEVC、H.266/VVC^[42] 等经典标准为代表, 采用预测编码、变换编码和熵编码的混合架构。空间冗余去除依赖帧内预测技术, 将当前编码块与相邻已编码块的空间相关性建模, 通过水平、垂直等预测模式生成预测值, 仅传输预测残差。时间冗余去除则通过帧间预测实现, 这种方法利用视频时序连贯性, 通过运动估计寻找参考帧中的匹配块, 生成运动向量并通过运动补偿生成预测帧, 仅传输运动向量与残差。统计冗余去除依托熵编码, 对残差、运动向量、预测模式等符号进行变长或算术编码, 利用概率分布压缩比特数。此外, 离散余弦变换将空间域残差转换为频率域, 通过量化去除高频冗余。

信道编码遵循香农信道容量定理, 通过添加可控冗余提升传输可靠性, 核心是利用纠错码的汉明距离或绝对距离抵抗误码。经典技术包括卷积码^[43]、Turbo 码^[44]、LDPC 码^[45]与 Polar 码^[46]。卷积码通过移位寄存器生成连续码字, 维特比译码利用网格图实现最大似然序列估计, 适合实时传输但纠错能力有限; Turbo 码采用并行级联卷积码和迭代译码, 通过交织器分散突发误码; LDPC 码基于稀

疏校验矩阵，置信传播译码复杂度线性于码长，是 5G 数据信道的标准码，适合长码长高清视频传输；Polar 码通过信道极化理论区分可靠和不可靠信道，连续抵消译码适合短码长控制信道。在视频编码中，往往视频的参考帧更重要，针对视频的不等重要性，传统系统采用不等错误保护，避免参考帧误码导致的帧间预测漂移。

信道译码是信道编码的一个逆过程，它的主要目的是利用编码时加进去的冗余信息，从一个被噪声污染了的接收序列中，把原始的信息比特恢复出来。这一过程的理论基础是最大似然估计或者最大后验概率，需要在译码能达到的性能和它所需要的计算复杂度之间做一个权衡。具体来说，对于卷积码，人们通常会采用维特比译码的方式，这种算法会在一个网格图上做动态的路径搜索，每一步都会以汉明距离或者欧氏距离作为度量的标准，把距离最小的那条幸存路径给保留下来，它的复杂度会随着约束长度的增加而呈现指数级的增长，但也正是因为这样一步步地往前推进，译码的延迟能做到比较低，所以它就能很好地适用于那些对实时性要求比较高的传输场景。另一方面，Turbo 码采用的则是一种迭代译码的结构，它是通过两个基于最大后验概率（Bahl-Cocke-Jelinek-Raviv, BCJR）准则的译码器，中间再经过一个交织器来交换彼此手里的软信息，这样循环往复，经过 6 到 8 次的迭代，译码的性能就能逐步得到提升；不过，迭代的次数越多，引入的延迟自然也就越大，所以在视频会议这种实时的应用里，通常会把迭代的次数限制在 4 次以内。LDPC 码采用置信传播译码（Belief Propagation, BP）算法，在因子图上完成变量节点与校验节点之间的迭代消息传递，其译码复杂度与码长呈线性关系，同时支持软输入软输出，便于与信源译码进行联合优化。Polar 码则主要采用连续消除译码（Successive Cancellation, SC）或带列表的连续消除译码（Successive Cancellation List, SCL），前者是根据信道极化的顺序，逐个估计出比特信息，后者则是通过同时维护好几条候选的路径，用一点复杂度的代价去换更好的性能，特别是在码长比较短的时候，效果会特别明显。

信源译码本质上就是信源编码的逆过程，其中会包含熵解码、反量化、反变换、预测补偿重建视频帧这些关键流程，还能通过错误隐藏技术把未纠正的误码给掩盖掉。熵解码会根据编码类型与上下文信息来恢复符号，像上下文自适应可变长编码（Context-Adaptive Variable Length Coding, CAVLC）会借助相邻块非零系数的数量去调整解码表，而上下文自适应二进制算术编码（Context-Adaptive Binary Arithmetic Coding, CABAC）则会通过二进制定化与上下文建模的方式来恢复算术码。反量化会依据量化参数（Quantization Parameter, QP）来恢复残差的近似值，反变换又能把频率域的残差转换到空间域的像素上。预测补偿会基于解码出来的运动向量与参考帧生成预测块，或者基于帧内预测模式来生成当前块的预

测值。一方面当存在未纠正的误码时，错误隐藏技术会利用空间和时间上的冗余来掩盖错误，另一方面空间隐藏会通过相邻正确块的复制或边缘插值来填充错误块，时间隐藏则会通过前一帧对应块的复制或运动向量外推来生成预测块。

2.3 基于深度学习的视频语义通信算法




图 2-3 视频语义通信架构图

基于深度学习的视频语义通信系统突破了传统信源-信道分离的理论框架，构建了以语义保真度为核心优化目标的端到端传输架构。该系统以图像组(Group of Pictures, GoP)为基本处理单元，通过深度神经网络实现从视频输入到语义重建的全流程映射。如图 2-3 所示，整个模型由语义编码器、信道编码器、信道解码器、语义解码器四大核心模块组成，各模块通过可微的神经网络层连接，支持基于梯度下降的端到端联合训练。

在视频输入端，系统首先将连续视频流切分为多个 GoP，每个 GoP 包含一组连续的视频帧。遵循视频编码的经典分层策略，GoP 内部指定一帧为关键帧，其余帧为预测帧。作为语义传输的重要参考，关键帧包含场景的全局语义信息，采用类似于图像语义通信的方式进行传输，即通过 ViT 或 CNN 提取高维全局语义特征，经信道编码后传输。由于关键帧数量少，其带宽占用可控。预测帧往往作为系统的核心研究对象，预测帧利用视频的时序强相关性，不直接传输像素或全局语义，而是传输相对于参考帧的语义残差。这种机制极大地降低了冗余度，是实现视频语义通信高压缩比的关键。

语义编码器的核心任务是从当前待传输帧中提取紧凑的语义表征，其设计遵循参考帧条件下的残差提取原则，而非传统的像素级预测。具体而言，编码器以 GoP 的参考帧作为先验条件，通过多尺度特征融合网络捕捉帧间的语义关联性。该过程通常包含两个子流，空间语义流和时序运动流。空间语义流利用 CNN 或 ViT 提取当前帧与参考帧的空间特征，计算特征空间的差异。时序运动流引入光流估计网络或可变形卷积，显式建模物体的运动轨迹与形变，提取参考帧和当前帧的运动语义信息。最终，语义编码器输出的并非像素残差，而是语义特征图或语义向量，所输出的信息包含维持语义完整性所需的关键信息，而剔除了背景、光照等无关冗余。

信道编码器的目标是将语义表征映射到可以在物理信道传输的符号序列，关键技术是联合信源信道编码（Joint Source-Channel Coding, JSCC）。与传统分离编码不同，JSCC 不区分信源编码与信道编码，而是通过深度学习模型根据损失函数端到端优化模型参数。为了减少传输的信息量，采用矢量量化或自编码器结构，将高维语义特征压缩为低维潜变量，或者通过熵编码进一步利用符号的统计特性减少比特数。并且信号在进入信道前，会进行信道鲁棒性增强的操作，在映射过程中引入功率归一化层与冗余添加机制，使输出符号满足信道功率约束，并具备一定的抗噪能力。

信道解码器接收经过物理信道传输后的失真信号，其目标是从含有噪声的信号中最大程度地恢复原始语义表征。为应对动态变化的无线信道环境，如 5G/6G 中的多普勒频移、阴影衰落，该模块集成了信道自适应机制。在信道状态感知机制中，通过辅助导频或历史信号，利用轻量级网络实时估计信道状态信息，包括信噪比、信道矩阵等。另外，动态译码策略根据估计的 CSI，自适应调整译码算法的参数。例如，在高信噪比场景下，采用低复杂度的线性译码以降低延迟；在低信噪比场景下，切换至基于深度学习的迭代译码算法，利用神经网络的非线性拟合能力从强噪声中提取微弱语义特征。

语义解码器是系统的视频帧生成器，其功能是利用已恢复的语义表征和参考帧重建出当前帧。该过程本质上是语义编码器的逆操作，但更强调上下文一致性与视觉真实性。在这个模块中，会使用特征融合与上采样操作对特征进行处理。通过转置卷积或上采样层将低维语义特征恢复至空间分辨率，并利用跳跃连接融合参考帧的高频细节，避免语义漂移导致的画面模糊。另外，还可以采用生成式重建的方式。近年来，基于生成对抗网络或扩散模型的解码器成为研究热点。这类模型以语义特征为条件引导，能够生成符合自然图像统计规律的细节。针对特定下游任务，语义解码器可直接输出任务所需的特征，而无需重建全分辨率视频帧，进一步降低计算开销。

2.4 相关评估指标

峰值信噪比^[47]（Peak Signal-to-Noise Ratio, PSNR）是当下最常被用到的客观图像质量评价指标之一，它基于像素之间的均方误差^[47]（Mean Squared Error, MSE）来量化重建信号与原始信号之间的误差。PSNR 计算时，要求取两幅图像之间的均方误差，即所有像素点灰度值之差平方的均值。MSE 的计算公式为：

$$\text{MSE} = \frac{1}{H \times W \times C} \sum_{i=1}^H \sum_{j=1}^W \sum_{k=1}^C [I(i,j,k) - \hat{I}(i,j,k)]^2, \quad (2-3)$$

其中, H 、 W 、 C 分别代表图像的高度、宽度和通道数, I 和 $\hat{I}$ 则分别代表了原始图像与重建图像。随后, PSNR 通过对 MSE 进行对数变换得到, 其计算公式为:

$$\text{PSNR} = 10 \cdot \log_{10} \left(\frac{\text{MAX}_I^2}{\text{MSE}} \right), \quad (2-4)$$

其中 MAX_I 表示图像像素值的最大可能取值, 比如 8 位图像为 255。PSNR 值越高, 表明重建图像与原始图像的像素级误差越小。虽然 PSNR 计算简单、物理意义明确, 但它主要反映了数值的保真度, 不能反映与人眼主观视觉感知的相关性, 也无法有效衡量高层语义信息的保持程度。

多尺度结构相似性指数 (Multi-Scale Structural Similarity, MS-SSIM) [48] 是结构相似性指数 (Structural Similarity, SSIM) [49] 的多尺度扩展, 旨在更精确地模拟人眼视觉系统在观察图像时, 对不同尺度下结构信息的综合感知过程。人眼在观察场景时, 会自然地整合从粗到细多个尺度的信息。MS-SSIM 通过构建图像金字塔, 在多个尺度上分别计算 SSIM 指数, 再进行加权融合, 从而提供了比单尺度 SSIM 更稳定、更符合人眼主观评价的质量度量。在单一尺度上, SSIM 从亮度、对比度和结构三个维度比较图像 x 和 y , 其定义为:

$$\text{SSIM}(x, y) = [l(x, y)]^\alpha \cdot [c(x, y)]^\beta \cdot [s(x, y)]^\gamma, \quad (2-5)$$

其中, 亮度比较函数 $l(x, y)$ 、对比度比较函数 $c(x, y)$ 和结构比较函数 $s(x, y)$ 的计算公式如下:

$$l(x, y) = \frac{2\mu_x\mu_y + C_1}{\mu_x^2 + \mu_y^2 + C_1}, \quad c(x, y) = \frac{2\sigma_x\sigma_y + C_2}{\sigma_x^2 + \sigma_y^2 + C_2}, \quad s(x, y) = \frac{\sigma_{xy} + C_3}{\sigma_x\sigma_y + C_3}, \quad (2-6)$$

式中, μ_x 、 μ_y 分别为图像 x 和 y 的均值, σ_x 、 σ_y 分别为其标准差, σ_{xy} 为它们的协方差, C_1 、 C_2 、 C_3 为小的常数, 用以稳定除法运算。MS-SSIM 在 M 个尺度上进行上述计算。设原始尺度为尺度 1, 通过逐级低通滤波和下采样得到尺度 2 至尺度 M 的图像。MS-SSIM 的最终值是各尺度比较结果的乘积, 通常对最高尺度的亮度比较进行加权, 而对所有尺度的对比度和结构比较进行乘积:

$$\text{MS-SSIM}(x, y) = [l_M(x, y)]^{\alpha_M} \cdot \prod_{j=1}^M ([c_j(x, y)]^{\beta_j} \cdot [s_j(x, y)]^{\gamma_j}), \quad (2-7)$$

其中，下标 j 表示尺度， α_M 、 β_j 、 γ_j 为各分量的权重。MS-SSIM 的值域为 $[0, 1]$ ，值越接近 1 表示两幅图像的视觉感知质量越相似。由于其多尺度特性，MS-SSIM 能更好地评价图像的模糊、失真等降质，是当前评估视觉质量比 PSNR 和单尺度 SSIM 更为可靠的指标，广泛用于衡量语义通信系统的视觉保真度。

学习感知图像块相似性（Learned Perceptual Image Patch Similarity, LPIPS）是一种数据驱动的图像感知相似度量方法，它的主要思路是通过在预训练的卷积神经网络的特征空间中，计算两幅图像归一化特征图之间的加权距离，来量化人类视觉系统所感知的差异，它的计算公式为：

$$d(x, x_0) = \sum_l \frac{1}{H_l W_l} \sum_{h,w} \|w_l \odot (\hat{y}_{hw}^l - \hat{y}_{0hw}^l)\|_2^2, \quad (2-8)$$

其中， $\hat{y}_{hw}^l$ 和 $\hat{y}_{0hw}^l$ 分别为输入图像在网络第 l 层的归一化特征图， w_l 是通过在大规模人类感知数据集上训练学习得到的逐通道权重向量，用于强调人类对图像的重要特征维度。LPIPS 通过聚合多层特征差异，克服了传统的像素级指标与主观评价不一致的局限，已成为评估图像生成、超分辨率等任务感知质量的重要基准。在本文中，为了展示不同方法之间 LPIPS 的差异，对其进行对数变换，计算公式如下：

$$\text{LogLPIPS}(\mathbf{x}, \hat{\mathbf{x}}) = -10 \cdot \log_{10} \text{LPIPS}(\mathbf{x}, \hat{\mathbf{x}}), \quad (2-9)$$

其中， $\mathbf{x}$ 表示原图像， $\hat{\mathbf{x}}$ 表示模型重建后的图像。

浮点运算次数（Floating Point Operations Per Second, FLOPs）是衡量模型计算复杂度和潜在功耗的核心动态指标。它特指完成一次模型前向传播过程中所执行的浮点数加法和乘法操作的总次数，通常以 GFLOPs 为单位。对于模型中的关键操作，其 FLOPs 可以进行估算。以二维卷积层为例，其 FLOPs 可近似计算为：

$$\text{FLOPs}_{\text{conv2d}} \approx 2 \times H_{\text{out}} \times W_{\text{out}} \times C_{\text{in}} \times K_h \times K_w \times C_{\text{out}}, \quad (2-10)$$

其中， H_{out} 和 W_{out} 是输出特征图的高度和宽度， C_{in} 表示输入特征的通道数， K_w 和 K_h 是卷积核的高度和宽度， C_{out} 是输出特征的通道数。因子 2 来源于一次乘积累加运算包含一次乘法和一次加法。

FLOPs 的实际大小会直接影响到模型在特定设备上的推理速度和能耗情况，对于那些需要进行实时处理的视频语义通信应用来说，过高的 FLOPs 很可能会导致帧率和功耗的要求得不到满足。首先，在模型设计的过程中，除了要追求模型的高性能之外，还得对 FLOPs 进行针对性的优化，这样才能在效率与性能之间达到平衡；二是通过这样的优化操作，能确保模型在实际的应用场景中具备足

够的可行性, 高效的性能表现以及合理的资源消耗都是实际应用里不可或缺的条件。

第三章 基于自适应提示调优的语义视频传输方案

本章主要介绍针对加性高斯白噪声、瑞利衰落等简单信道提出的面向无线视频传输的自适应深度信源信道联合编码方案 (Adaptive Deep Joint Source-Channel Coding for Wireless Video Transmission, AdaJSCCV)。首先, 本章介绍当前方法在信道自适应方面的缺点; 然后, 介绍本章提出的视频语义传输模型, 并详细阐述模型的主要模块, 包括信道语义提取模块、动态信道自适应模块以及编解码器部分。最后, 通过实验证明 AdaJSCCV 模型在多个信道场景的有效性。

3.1 引言

当前视频无线传输方案在信道自适应方面已显示出巨大潜力, 但仍存在对动态无线环境适应性不足的问题, 具体主要表现在下面两个方面。首先, 当前的信道自适应方案通常依赖于参数固定的静态神经网络。这些方法通常采用简单的融合策略, 例如直接将信噪比估计值与视觉特征进行拼接以生成融合表征^[23]。这种范式未能捕捉信道特征与视觉语义之间细微的相互依赖关系, 特别是在多径衰落导致的信道复杂性下。另外, 简单的信噪比数值难以建模信道的语义信息, 不能充分体现出不同信道的语义特性, 丢失了频率选择性、时变性等关键结构信息。将其与丰富的语义特征直接拼接, 未能建立一种结构化的指导关系, 信道信息在后续非线性变换中容易被淹没或扭曲, 利用率低。另外, 这种显式拼接是一种浅层、静态的前馈耦合范式, 其根本局限在于网络结构具有静态刚性, 自适应能力完全依赖于固定参数网络对组合输入的隐式学习, 从而难以建模信道条件与视觉语义间复杂的非结构化关联。与之相对, 隐式参数化范式通过从信道状态中推导出可学习的结构化指令能够对网络计算图实现前驱式、结构化的因果干预。这种机制使网络具备了动态重构其内部计算的能力, 实现了信道状态与网络行为间更深刻、更本质的耦合, 从而在理论上提供了更强的表达能力, 并能从根本上突破静态网络在面对动态无线环境时的架构性约束与泛化瓶颈。另外, 隐式空间包含更加丰富的信息, 可以更加精确地建模出不同信道, 这实现了信道状态与网络内部计算之间的高效对齐, 使得有限的网络容量能更精准地分配于应对不同的信道情况。

其次, 在目前的视频语义通信方法中, 大部分变长编码方法通过使用神经网络估计语义特征的均值、方差等统计特性来实现熵建模^[17]。这种基于神经网络的熵模型通常基于卷积或局部自回归上下文构建, 感受野有限, 难以有效捕捉语义特征中至关重要的长程和全局依赖, 导致对联合概率分布的估计存在偏差, 并

产生次优的压缩效率。另一方面，此类模型计算过程复杂，会引入较高的编码延迟与实现开销，不利于实时低功耗应用。

针对上面的问题，本章提出了一种面向无线视频传输的自适应深度信源信道联合编码方案（Adaptive Deep Joint Source-Channel Coding for Wireless Video Transmission, AdaJSCCV）。AdaJSCCV 的最大的特点是实现了一种从“显式特征融合”到“隐式参数调制”的范式转换，在编码过程中利用可学习提示的方法实现对动态无线环境的信道状态感知和信道自适应。具体而言，AdaJSCCV 提出了一种 CSI 条件化的参数调制机制，将信道状态信息表示为一组稠密的可学习提示向量，这组向量可以通过与视觉特征进行交互，动态生成卷积核的权重参数，通过在推理过程中变化神经网络参数使网络能适配当前信道条件，从而让模型能够根据信道状态信息，隐式并结构化地调整其内部网络，而不是简单地根据信道信息拼接的标量拼接。该框架对信道状态信息的精度具有很强的鲁棒性，只需要粗略的甚至是瞬时的信道估计即可保持稳定的信道估计性能，降低了对理想信道信息的依赖度，使其在复杂传播环境中具有较强的实用性。本章的主要贡献如下：

（1）本章提出了一个信道语义提取模块（Channel Semantic Extraction Module, CSEM），它将 CSI 编码为紧凑的提示向量，并能从不同精度的信道估计中提取出有效的信道语义信息。这些提示向量驱动动态信道自适应模块（Dynamic Channel Adaptation Module, DCAM）以信道感知的方式实时调制卷积参数，实现对波动无线环境的实时适应。

（2）本章针对视频语义通信中的变长编码方法，提出了一种基于无网络熵模型的变长编码方法，这种方法通过建立语义信息的重要性度量准则，直接在语义特征空间中筛选出重要性最高的信息进行传输，并依据预设的带宽约束实现精准的码率分配。这种轻量级策略在保持高编码灵活性的同时，显著降低了计算开销。

（3）实验结果表明，在峰值信噪比（Peak Signal-to-Noise Ratio, PSNR）和多尺度结构相似性指数（Multi Scale Structural Similarity Index Measure, MS-SSIM）的视频重建指标上，AdaJSCCV 优于采用 LDPC 信道编码的传统 H.264、H.265 编解码方法，以及 DeepJSCC 方法 DeepWive^[15] 和 WITT^[23]，同时能有效适应多种信道变化。

3.2 基于自适应提示调优的语义视频传输系统

本节详细阐述系统模型、信道语义提取模块、动态信道自适应模块以及模型训练流程等。




图 3-1 AdaJSCCV 的架构图

如图 3-1 所示，本文提出的 AdaJSCCV 框架分为运动路径和主路径。本章考虑将一个视频序列 $\mathbf{X} \in \mathbb{R}^{N \times C \times H \times W}$ 划分为若干图像组 (Groups of Pictures, GoPs)，每个图像组表示为 $\mathbf{X}_G = \{\mathbf{x}_1, \dots, \mathbf{x}_i, \dots, \mathbf{x}_T\}$ ，其中 $\mathbf{x}_i \in \mathbb{R}^{C \times H \times W}$ 是 $\mathbf{X}_G$ 中的第 i 帧视频。此处， N 表示视频总帧数， T 表示一个 GoP 中包含的视频帧数， C 、 H 、 W 分别表示视频帧的通道数、高度和宽度。AdaJSCCV 的输入是一个图像组 $\mathbf{X}_G$ 。

在运动路径中，编码器的运动估计模块^[50]对连续帧间的时空相关性进行建模，它利用当前帧 $\mathbf{x}_t$ 和前一帧 $\mathbf{x}_{t-1}$ 计算运动向量 $\mathbf{m}_t \in \mathbb{R}^{(C-1) \times H \times W}$ 。随后， $\mathbf{m}_t$ 由一个 JSCC 编码器进行编码，在压缩其空间冗余的同时引入适度的信道容错性，生成运动向量的语义表示 $\mathbf{y}_t^{mv} \in \mathbb{R}^{C_M \times H/16 \times W/16}$ 。同时，在主路径中，为了更好地利用时空上下文，一个上下文特征提取器^[50] f_c 从 $\mathbf{x}_{t-1}$ 和 $\mathbf{m}_t$ 中融合并提取上下文信息 $\mathbf{c}_t \in \mathbb{R}^{C_c \times H \times W}$ 。该过程可表示为：

$$\mathbf{c}_t = f_c(\mathbf{m}_t, \mathbf{x}_{t-1}; \phi), \quad (3-1)$$

其中 ϕ 表示 f_c 的可学习参数。该上下文信息作为先验，用于指导当前帧的语义编码，从而减少帧间冗余，提升整体压缩效率。

上下文条件编码器 f_e 以时序先验上下文信息 $\mathbf{c}_t$ 作为条件对当前帧 $\mathbf{x}_t$ 进行编码，生成高度压缩的语义信息 $\mathbf{y}_t \in \mathbb{R}^{C_N \times H/16 \times W/16}$ ，处理过程如下：

$$\mathbf{y}_t = f_e(\mathbf{x}_t | \mathbf{c}_t; \psi), \quad (3-2)$$

其中 ψ 表示 f_e 的可学习参数。该条件编码机制能够有效利用帧间相关性，在保持语义完整性的同时显著提升压缩效率。

经过熵编码后，语义信息 $\mathbf{y}_t$ 和 $\mathbf{y}_t^{mv}$ 被进一步压缩为适合在物理信道中传输的符号 $\mathbf{s}_t \in \mathbb{R}^{k_t}$ 和 $\mathbf{s}_t^{mv} \in \mathbb{R}^{k_t^{mv}}$ ，其中 k_t 和 k_t^{mv} 分别表示变长码字 $\mathbf{s}_t$ 和 $\mathbf{s}_t^{mv}$ 的长度。在本章中，考虑了一个通用的无线信道模型，该模型综合考虑加性高斯白噪声、大尺度衰落和小尺度衰落，在大尺度衰落中，包含信道的路径损耗和阴影衰落。假设符号在传输前经过了功率归一化，则接收端对应的含有噪声的符号可以表示为：

$$\begin{aligned}\hat{\mathbf{s}}_t &= \sqrt{P_L(d) \cdot S_\sigma} \cdot h \cdot \mathbf{s}_t + \mathbf{n}_t, \\ \hat{\mathbf{s}}_t^{mv} &= \sqrt{P_L(d) \cdot S_\sigma} \cdot h \cdot \mathbf{s}_t^{mv} + \mathbf{n}_t,\end{aligned}\quad (3-3)$$

其中, $P_L(d)$ 表示路径损耗, 该参数和传输距离 d 相关, S_σ 表示阴影衰落系数, 这两个参数共同构成大尺度衰落效应; h 表征多径传输的小尺度衰落系数。在公式(3-3)中, $\mathbf{n}_t \sim \mathcal{N}(0, \sigma^2 \mathbf{I}_{k_t})$ 表示功率为 σ^2 的加性高斯白噪声向量。在本章中, 把上面的信道参数集合记为 $P_c = \{P_L(d), S_\sigma, h, \mathbf{n}_t\}$ 。在真实场景中, 往往难以获取完美的信道状态信息 P_c 。然而, 值得注意的是, 即使只能获得部分或粗略的信道状态信息, AdaJSCCV 模型凭借其强大的信道语义信息提取能力与自适应机制, 依然能够实现高质量的视频重建, 从而降低系统对理想信道信息的依赖。

在解码器中, 接收到信道符号 $\hat{\mathbf{s}}_t$ 和 $\hat{\mathbf{s}}_t^{mv}$ 经过熵模型和零填充处理, 恢复为受损的语义特征表示 $\check{\mathbf{y}}_t \in \mathbb{R}^{C_N \times H/16 \times W/16}$ 和 $\check{\mathbf{y}}_t^{mv} \in \mathbb{R}^{C_M \times H/16 \times W/16}$ 。为了有效抑制无线信道噪声和衰落效应对语义特征的干扰, 本文提出了动态信道自适应模块 (Dynamic Channel Adaptation Module, DCAM)。该模块通过信道感知的特征调整机制, 为语义信息在动态信道下的可靠传输与恢复提供了更为灵活、鲁棒的自适应解决方案。具体而言, 信道语义提取模块 (Channel Semantic Extraction Module, CSEM) 被设计用于从一个特定的信道参数集 P_c 中, 提取出一个低维、稠密的可学习信道语义表示 $\mathbf{r} \in \mathbb{R}^{C_N}$ 。此过程可表述为:

$$\mathbf{r} = f_{\text{CSEM}}(P_c; \alpha), \quad (3-4)$$

其中 α 表示 CSEM 中的可学习参数。该模块的功能在于将物理层的多维信道状态参数, 如大尺度衰落、小尺度衰落与噪声统计特性等信道特征映射为一个紧凑的、富含语义的向量表示, 从而为后续的特征自适应恢复提供结构化的信道状态指导。

经过语义提取模块后, 提取出的信道语义表征 $\mathbf{r}$ 作为多个级联的特征调整模块 (Feature Adjustment Module, FAM) 的输入。在 FAM 中, $\mathbf{r}$ 与接收到含有噪声的视觉特征 $\check{\mathbf{y}}_t$ 和 $\check{\mathbf{y}}_t^{mv}$ 进行动态交互。具体来说, 信道语义表示 $\mathbf{r}$ 被用作条件控制信号, 动态地生成 FAM 内部卷积层的权重参数与特征调制系数, 从而对含有噪声的特征进行特定的处理。此条件化过程可形式化表示为:

$$\begin{aligned}\hat{\mathbf{y}}_t &= f_{\text{FAMs}}(\check{\mathbf{y}}_t | \mathbf{r}; \beta), \\ \hat{\mathbf{y}}_t^{mv} &= f_{\text{FAMs}}(\check{\mathbf{y}}_t^{mv} | \mathbf{r}; \beta),\end{aligned}\quad (3-5)$$

其中 β 表示 FAMs 中的可学习参数。通过这种机制, 网络能够依据实时信道状态主动调整特征恢复策略, 有效抑制噪声与衰落引入的失真。

随后，经过 DCAM 处理后的运动语义表征 $\hat{\mathbf{y}}_t^{mv}$ 被输入到 JSCC 解码器中进行视频帧的重建。JSCC 解码器恢复解码后的运动向量 $\hat{\mathbf{m}}_t$ ， $\hat{\mathbf{m}}_t$ 以先前已重建的视频帧 $\hat{\mathbf{x}}_{t-1}$ 作为参考，两者一起输入到上下文特征提取器 f_c 中，通过融合时空信息生成当前帧的上下文先验 $\hat{\mathbf{c}}_t$ ，其过程可表示为：

$$\hat{\mathbf{c}}_t = f_c(\hat{\mathbf{m}}_t, \hat{\mathbf{x}}_{t-1}; \phi). \quad (3-6)$$

此上下文信息承载了连续的时序结构与运动规律，为当前帧的重建提供了关键的时空约束。在上下文先验 $\hat{\mathbf{c}}_t$ 的引导下，条件解码器 f_d 对去噪后的主路径语义表示 $\hat{\mathbf{y}}_t$ 进行条件化解码，最终重构出当前视频帧 $\hat{\mathbf{x}}_t$ ，该计算过程可表述为：

$$\hat{\mathbf{x}}_t = f_d(\hat{\mathbf{y}}_t | \hat{\mathbf{c}}_t; \theta), \quad (3-7)$$

其中 θ 表示主路径中条件解码器 f_d 的待优化参数。该条件化解码机制有效利用了帧间的时空相关性，从而在抑制信道噪声的同时，实现了高质量的视频序列重建。

AdaJSCCV 框架的设计目标旨在严格的比特率约束下，实现视频帧的高质量重建，并最小化感知失真。为达成此目标，在训练过程中，本章采用了一个多目标的率失真损失函数来联合优化整个系统。系统的编码码率由每个 GoP 内所有帧的语义信息所决定。具体而言，主路径与运动路径的变长码字长度 k_t 和 k_t^{mv} 共同决定了传输每帧所需要的符号数量。一个 GoP 内每帧平均传输的符号数 k 计算如下：

$$k = \frac{1}{T} \sum_{t=1}^T [k_t + k_t^{mv}]. \quad (3-8)$$


为量化信道带宽的使用效率，本文使用信道带宽比（Channel Bandwidth Ratio, CBR）作为主要的指标，其定义为传输符号的总量与原始视频帧总像素数的比值，即 $\text{CBR} = k/(H \times W \times C)$ 。基于 CBR，AdaJSCCV 模型训练的最终目标函数可以表示为：

$$\mathcal{L}_{\phi, \psi, \theta, \alpha, \beta} = \lambda_1 \cdot \sum_{t=1}^T (\|\mathbf{x}_t - \hat{\mathbf{x}}_t\|_2^2) + \lambda_2 \cdot \sum_{t=1}^T \mathcal{L}_{\text{MS-SSIM}}(\mathbf{x}_t, \hat{\mathbf{x}}_t) + \lambda_3 \text{CBR}, \quad (3-9)$$


其中 $\mathcal{L}_{\text{MS-SSIM}} = 1 - \text{MS-SSIM}(\mathbf{x}_t, \hat{\mathbf{x}}_t)$ 用于度量感知相似度。该损失函数整合了三项关键优化目标：像素级的均方误差失真、多尺度结构相似性的感知损失以及对带宽消耗的直接约束。超参数 λ_1 、 λ_2 和 λ_3 用于精确调控这三者之间的权衡。在此公式中， ϕ 、 ψ 、 θ 、 α 和 β 表示待优化的参数。

3.2.1 动态信道自适应方法

本章提出的动态信道自适应模块的网络架构如图 3-2 所示。该模块由两个核心组件构成：信道语义提取模块与特征调整模块，二者协同工作，实现了编码网络对动态无线环境的智能、高效适配。如图 3-2(a)所示，信道语义提取模块负责将物理层的多维信道参数 P_c 转换为一组富含语义信息的、可学习的 CSI 提示向量 $\mathbf{p}_i \in \mathbb{R}^{C_p}$ 。CSEM 包含一个可训练的提示缓存，该缓存由 N_c 个可学习的基向量 $\{\mathbf{p}_1, \dots, \mathbf{p}_i, \dots, \mathbf{p}_{N_c}\}$ 构成。此设计旨在灵活支持粗粒度与细粒度两种信道状态估计场景。在粗粒度估计下，如仅能判别信道类型为 AWGN 或瑞利衰落信道的场景，系统从缓存中检索出对应于该信道分布原型的提示向量；而在细粒度估计下，如可获得具体的 SNR 与衰落参数的场景，则通过一个轻量的映射网络，将连续的精确 CSI 数值适配到缓存中最相关的提示向量上，从而实现与具体信道实现细节的精确关联。



(a) 信道语义提取模块结构图



(b) 特征调整模块结构图

图 3-2 动态信道自适应模块结构图

在模型训练阶段，提示缓存中的所有向量 $\mathbf{p}_i$ 均被随机初始化，并随网络主体参数进行端到端的联合优化。这一过程使得每个提示向量能够以数据驱动的方式，隐式地捕获其对应信道状态下的信道语义信息，从而内化了物理信道的上下文知识。这种学习到的表征能力超越了依赖显式、理想化信道模型或精确瞬时测量的传统范式，增强了对不完美或部分 CSI 的鲁棒性。在推理阶段，训练完备的提示缓存保持冻结，系统根据实时获取准确或者粗略的信道观测，从缓存中检索出最匹配的提示向量 $\mathbf{p}_i$ ，作为后续自适应处理的条件指令。

随后，提示向量 $\mathbf{p}_i$ 经过多层感知机（Multilayer Perceptron, MLP）的维度变化和特征的映射得到信道语义表示 $\mathbf{r} \in \mathbb{R}^{C_N}$ 。 $\mathbf{r}$ 作为连接物理信道状态与语义层处

理的结构化控制信号，产生随信道状态不断改变的卷积核和调制系数，这些参数在 DCAM 中作用在视觉语义信息上，使得信道语义信息与视觉语义信息深度融合。在 CSEM 与 DCAM 两个模块端到端联合训练的同时，CSEM 学习到的信道语义表示可以完全反映 DCAM 进行特征调制所需要的控制信息。CSEM 和 DCAM 联合训练保证了系统能够有效地捕获和内化 CSI 在端到端语义传输中的影响，超越了传统基于显式信道估计和固定纠错编码的被动适应过程。

在 DCAM 中，学习到一组动态可调节的卷积核参数和信道调制系数，该参数均以信道语义表示 $\mathbf{r}$ 为条件产生，并专门用于响应物理噪声和无线信道的多径衰落、阴影衰落等时变特性，并将信道语义表示 $\mathbf{r}$ 与输入的受损视觉特征 $\check{\mathbf{y}}_t$ 在多个级联的 FAM 块中进行交互，系统实现了上下文感知的特征调制。FAM 的详细结构如图 3-2(b)所示，FAM 采用残差结构以确保训练的稳定性，使用特征自适应卷积层（Feature Adaptive Convolutional module, FAC）与标准卷积层来对视觉特征进行处理。FAC 层是实现信道感知调制的主要模块，信道语义表示 $\mathbf{r}$ 通过 MLP 动态生成空间自适应卷积核 $\omega \in \mathbb{R}^{C_N \times 1 \times 3 \times 3}$ 。该卷积核根据现有信道语义特征调整感受野，对视觉特征 $\mathbf{F}_{in}$ 进行深度卷积操作，产生中间特征 $\mathbf{F}_1 \in \mathbb{R}^{C_N \times H/16 \times W/16}$ 。这一过程是信道条件驱动下的动态特征变化，不同于将信道状态信息与视觉特征进行拼接的静态特征处理过程，其中显式 CSI 提示在结构上动态调整网络的卷积核参数。为了进一步减轻在信道维度上的噪声和衰落影响， $\mathbf{r}$ 通过 MLP 层和 sigmoid 激活函数生成信道可扩展调制系数 $\nu \in \mathbb{R}^{C_N \times 1 \times 1}$ 。该系数根据 CSI 的影响重新调整 $\mathbf{F}_{in}$ 中的不同特征分量，保留关键语义信息，同时抑制受噪声影响最大的视觉特征，生成 $\mathbf{F}_2 \in \mathbb{R}^{C_N \times H/16 \times W/16}$ 。最后，将 $\mathbf{F}_1$ 和 $\mathbf{F}_2$ 相加以获得去噪后的特征，然后通过额外的卷积层产生输出特征 $\mathbf{F}_{out}$ ，其计算方式如下面的公式：

$$\mathbf{F}_{out} = \text{Conv}_{3 \times 3}(\text{Conv}_{1 \times 1}(\text{Conv}(\mathbf{F}_{in}, \text{MLP}(\mathbf{r}))) + \text{Sigmoid}(\text{MLP}(\mathbf{r})) \odot \mathbf{F}_{in}). \quad (3-10)$$

因此，输出的视觉特征 $\mathbf{F}_{out}$ 结合了动态卷积核带来的空间自适应去噪效果与特征调制系数提供的精细化特征重组优势。通过级联多个这样的 FAM 块，DCAM 能够对受扰的语义特征进行由粗到精的逐步恢复与增强，最终输出高质量的去噪语义表示，为后续的视频帧重建奠定坚实基础。

3.2.2 基于无网络熵编码的变长编码模块

为在严格带宽限制下实现最优传输性能，本章提出一种基于无网络熵模型的显式码长控制方案。如图 3-3 所示，由于运动路径和主路径控制码率的方法相同，本章聚焦于编码主路径的码率控制机制，其核心流程如下：首先，通过条件编码器 f_e 对输入信号进行高效压缩，输出其低维语义表示 $\mathbf{y}_t$ ；随后，为建立精确的码率估计与控制，采用高斯分布对语义表示 $\mathbf{y}_t$ 的概率特性进行建模：

$$p(\mathbf{y}_t) = \prod_i (\mathcal{N}(\mu_{\mathbf{y}_{t,i}}, \sigma_{\mathbf{y}_{t,i}}) * \mathcal{U}(-\frac{1}{2}, \frac{1}{2}))(\mathbf{y}_{t,i}), \quad (3-11)$$

其中 $*$ 表示卷积运算, i 代表 $\mathbf{y}_t$ 通道维度的索引, $\mu_{\mathbf{y}_{t,i}}$ 和 $\sigma_{\mathbf{y}_{t,i}}$ 分别是 $\mathbf{y}_{t,i}$ 的均值和方差。基于上述概率分布, 可进一步推导出熵图, 用以量化语义表示 $\mathbf{y}_t$ 中每个元素的信息重要性。具体而言, 熵值越高的维度, 表明其承载的信息越具价值, 对重建质量的影响也越显著。为满足预设的码率约束 R , 本方案采用一种显式的维度选择机制, 首先依据熵值对语义表示的所有维度进行重要性排序, 随后仅选取排名前 C_R 个最重要的维度用于传输。为标识所选维度, 系统生成一个对应的二进制掩码 $\mathbf{M} \in \mathbb{R}^{C_N \times H/16 \times W/16}$ 。在该掩码中, 仅在所选的 C_R 个关键维度位置上值为 1, 其余位置均为 0。随后, 语义表示 $\mathbf{y}_t$ 与二进制掩码 $\mathbf{M}$ 通过逐元素相乘进行滤波, 得到稀疏化的表示 $\mathbf{s}_t$, 该过程可表示为:

$$\mathbf{s}_t = \mathbf{y}_t \odot \mathbf{M}, \quad (3-12)$$

其中 $\odot$ 表示逐元素相乘。最终, $\mathbf{s}_t$ 通过无线信道进行传输。此机制通过对高信息熵维度的选择性保留与编码, 在严格满足给定码率上限的同时, 最大限度地保留了输入信号的关键信息, 从而实现了约束条件下的率-失真性能优化。




图 3-3 变长编码模块结构图

3.2.3 条件编码器和条件解码器

本章所提出的框架中, 条件编码器 f_e 、条件解码器 f_d 与上下文特征提取器 f_c 构成了核心的编解码结构, 其详细的网络配置如表 3-1 所示。其中, Conv 与 DeConv 分别表示标准卷积与转置卷积操作, 用于实现特征的下采样与上采样; 广义除法归一化 (Generalized Divisive Normalization, GDN) 及逆广义除法归一化 (Inverse Generalized Divisive Normalization, IGDN) 是一类可学习的非线性归一化与反归一化模块, 能够有效模拟视觉感知特性并促进特征的稀疏表示; 残差块

(Residual Block, ResBlock) 通过引入跳跃连接以缓解深层网络中的梯度消失问题, 提升训练的稳定性与性能。

表 3-1 条件编解码器与上下文特征提取器结构表

模型	模型结构
条件编码器	$(\text{Conv}(s=2, k=5) + \text{GDN} + \text{ResBlock}) \times 3$
条件解码器	$(\text{DeConv}(s=2, k=3) + \text{IGDN} + \text{ResBlock}) \times 3$
	$\text{DeConv}(s=2, k=3) + \text{ResBlock} \times 2$
上下文特征提取器	$\text{Conv}(s=2, k=3) + \text{ResBlock}$
	Flow Wrap
	$\text{ResBlock} \times 3 + \text{Conv}(s=2, k=3)$

具体而言, 在编码之前, 上下文特征提取器 f_c 提取上下文信息 $\mathbf{c}_t$, 该模块包含下采样卷积层、结构化残差块和特征扭曲操作, 对当前帧中与之相关的时空上下文特征逐步地进行处理。在条件编码过程中, 当前帧中的输入表示 $\hat{\mathbf{x}}_t$ 以及提取的上下文信息 $\mathbf{c}_t$ 沿通道进行拼接后输入到条件编码器 f_e 。条件编码器 f_e 通过由多个下采样卷积层、GDN 层及残差模块进行层联, 逐步将融合后的特征进行压缩和抽象, 最终得到紧凑的语义表示 $\hat{\mathbf{y}}_t$ 。

在解码过程中, 条件解码器 f_d 从语义表示 $\hat{\mathbf{y}}_t$ 中重建出原始信号, 解码过程首先通过多个由上采样卷积、IGDN 归一化层及残差块组成的子模块逐步恢复特征的空间分辨率和数值范围; 其次, 上采样后的语义特征与对应的上下文信息 $\hat{\mathbf{c}}_t$ 沿通道进行拼接, 并通过后续一系列的上采样卷积和残差块进一步融合和细化, 最终得到当前帧的优质估计 $\hat{\mathbf{x}}_t$ 。编解码结构在不破坏信息完整的基础上, 明显引入上下文依赖和分级特征处理机制, 增强了压缩表示的表达能力和重建性。

3.3 仿真实验设置

3.3.1 数据集

本章使用 UCF101^[51] 数据集进行模型训练。该数据集包含 13,320 段视频, 涵盖 101 个人体动作类别, 具有良好的多样性与代表性。为保障训练的有效性与评估的可靠性, 按照 0.8:0.1:0.1 的比例将其随机划分为训练集、验证集和测试集, 以确保模型在未见数据上性能评估的统计意义。在训练阶段, 本章采用大小为 6 的 GoP 作为基本时序单元, 以建模帧间的时空依赖性。为进一步提升模型的泛化能力并满足计算效率的要求, 所有输入帧在训练时均被随机裁剪为 256×256 像素的分辨率, 并施以随机的水平翻转等数据增强策略, 以增强模型对空间变换的鲁棒性。

为全面评估所提方法的性能，本章在两个数据集上进行了测试。首先，在 UCF101 的独立测试集上进行内部评估，以检验模型在已知分布数据上的压缩效率与重建质量。其次，为验证模型对高分辨率内容的适应性与泛化能力，进一步在高分辨率视频数据集 BVI-DVC^[52] 上进行了外部评估。该数据集提供全高清 1920×1080 和 4K 高清 3840×2160 两种分辨率的视频序列，为评估算法在高分辨率、高保真需求下的性能提供了严谨的基准。通过在不同分辨率与内容特性的数据集上进行综合测试，本章旨在全面验证所提框架的有效性与鲁棒性。

3.3.2 训练设置

在本章中，AdaJSCCV 模型的核心架构参数经仔细设计与优化，具体配置如下：主路径特征通道数 C_N 设为 96，运动路径通道数 C_M 设为 128，上下文信息提取器维度 C_C 设为 64，以平衡模型的表达能力和计算复杂度。在变长编码模块中，所保留的特征维度将根据预设的信道带宽约束进行动态选择，实现码率的精确控制。在动态信道自适应模块中，表示的初始维度 C_P 设为 48，随后通过一个多层感知机映射至主路径通道数 C_N ，以进行特征对齐与增强。该模块由 5 个级联的特征调整模块构成，以逐步提炼多尺度时空上下文信息。

为评估模型在不同信道环境下的鲁棒性与泛化性能，训练过程中涵盖了四种典型的无线信道模型，包括加性高斯白噪声信道、瑞利衰落信道、莱斯衰落信道以及大规模衰落信道。信噪比在 1dB 至 13dB 范围内均匀分布，以模拟从较差到较好的实际通信条件。训练采用 Adam 优化器^[53]，初始学习率设为 1×10^{-4} ，并配合适当的学习率衰减策略以保证训练稳定收敛。整个 AdaJSCCV 模型在一块 NVIDIA RTX 3090 GPU 上进行训练，批量大小设为 4，完整的训练周期约为 1.5 周，确保了模型在多种信道条件下的充分优化与性能饱和。


3.3.3 对比方案与评估指标

为全面评估所提方法的性能，本章将 AdaJSCCV 与两类基准方案进行比较：一类是基于传统分离的编码调制方案，另一类是近期的深度联合信源信道编码方案，包括 DeepWive 与 WITT。此外，本章引入了所提方法的一种变体，即粗粒度自适应设置下的视频传输方案，记为 AdaJSCCV-C，用于分析不同自适应粒度对性能的影响。在传统分离式方案中，信源编码分别采用广泛应用的 H.264 与 H.265 标准；信道编码采用低密度奇偶校验码 (Low-Density Parity-Check, LDPC)；调制解调方案则选用二进制相移键控 (Binary Phase Shift Keying, BPSK) 与正交相移键控 (Quadrature Phase Shift Keying, QPSK)。BPSK 使用两个相位来表示数字 0 和 1，QPSK 使用四个相位表示两个比特，即 00、01、10、11。在相同的带宽条件下，QPSK 比 BPSK 可以传输更多的信息；在相同的信道噪声条件下，QPSK 比 BPSK 具有更强的抗噪声能力，这些特点使得 QPSK 在现代通信系统中


更为常用。上述这些方案代表了当前工程实践中成熟的技术路线，其性能比较有助于定位所提端到端方案的优势与适用场景。

为客观量化重建视频的质量，本章采用三项广泛认可的指标进行评估：峰值信噪比、多尺度结构相似性指数和学习感知图像块相似度。峰值信噪比（Peak Signal-to-Noise Ratio, PSNR）基于均方误差计算，直接反映重建图像与原始图像在像素强度上的绝对差异，其值越高表明失真越小。多尺度结构相似性指数（Multi-Scale Structural Similarity Index, MS-SSIM）则通过模拟人眼视觉系统对图像结构的感知，从亮度、对比度和结构三个维度，在多分辨率下评估两幅图像之间的感知相似性，其值越接近 1 表示视觉质量越高。学习感知图像块相似度（Learned Perceptual Image Patch Similarity, LPIPS）通过对比不同图像在深度学习网络中的特征差异来评估图像的感知相似度，因此它能更好的反映人对图像的主观感受。PSNR、MS-SSIM 和 LPIPS 分别从数值保真度、感知保真度以及主观评价指标三个互补的维度，共同构成了本次实验的质量评估体系。

3.4 结果性能分析



(a)




(b)


图 3-4 AdaJSCCV 在 UCF101 数据集上测得的失真性能随信噪比变化曲线图

图 3-4、图 3-5 展示了在 AWGN 信道、 $\text{CBR}=0.031$ 的条件下，AdaJSCCV 与其他方法在 UCF101 数据集和 BVI-DVC 数据集上，PSNR 与 MS-SSIM 随 SNR 变化的性能曲线。图 3-4(a) 是 AdaJSCCV 在 UCF101 数据集上 PSNR 随 SNR 变化曲线图，图 3-4(b) 是 AdaJSCCV 在 UCF101 数据集上 MS-SSIM 随 SNR 变化曲线图。图 3-5(a) 是 AdaJSCCV 在 BVI-DVC 数据集上 PSNR 随 SNR 变化曲线图，图 3-5(b) 是 AdaJSCCV 在 BVI-DVC 数据集上 MS-SSIM 随 SNR 变化曲线图。对于传统分离架构的 H.264 与 H.265 方法，本章测试了多种调制方式与信道编码率的组合，以构建其完整的性能边界。实验结果表明，所提出的 AdaJSCCV 方法在客观质量与主观视觉质量上均一致优于传统方案及深度学习方法 WITT，并在恶劣信道条件下展现出显著的鲁棒性。具体而言，在 $\text{SNR}=4\text{ dB}$ 时，AdaJSCCV 在 UCF101 与 BVI-DVC 两个数据集上相较于基于 H.264 的方案，分别实现了 3.8 dB 与 6.4 dB 的峰值信噪比提升。此外，AdaJSCCV 在 PSNR 指标上显著优于 DeepWive 方案，同时在 MS-SSIM 指标上取得了相当的性能。这一方面在信道条件更好时更加明显，尤其是在高分辨率数据集 BVI-DVC 上。在 $\text{SNR}=13\text{ dB}$ 时，在 BVI-DVC 测试集上，在 PSNR 指标上 AdaJSCCV 比 DeepWive 高出 5.1 dB 。尽管 AdaJSCCV-C 版本采用了粗粒度的信道状态信息提示机制，其性能仍始终优于所有传统的分离式编码方案，这证明了即使在不精确的信道信息下，所提出的自适应机制依然具有显著的有效性。

在图 3-6、图 3-7 中，展示了 AdaJSCCV 模型在不同码率约束与多种信道条件下的性能对比。图 3-6(a) 是 AWGN 信道下，AdaJSCCV 在不同码率下，性能变化曲线图；图 3-6(b) 为瑞利信道下，AdaJSCCV 在不同码率下，性能变化曲线图。图 3-7(a) 是大尺度衰落信道下，AdaJSCCV 在不同码率下，性能变化曲线图，图 3-7(b) 是莱斯信道下，AdaJSCCV 在不同码率下，性能变化曲线图。基于无网络熵模型的变长编码模块能够根据预设的码率约束灵活分配比特。随着 CBR 降低，可用于传输的信息总量减少，视频重建性能随之呈现缓慢下降的趋势，这符合率失真理论的基本规律。另外，即使信道带宽有限，在极低的码率下，AdaJSCCV 仍能保持令人满意的重建质量。例如，在瑞利衰落信道下，当 $\text{CBR}=0.012$ 、 $\text{SNR}=1\text{ dB}$ 的恶劣条件下，AdaJSCCV 在 UCF101 数据集上 PSNR 指标仍能达到约 29 dB 。在所有测试的信道条件下，只有粗略信道状态信息的 AdaJSCCV-C，其性能与 AdaJSCCV 相当。尽管 AdaJSCCV-C 仅使用单一可学习参数来表征信道状态，但其内置的自适应机制仍能有效驱动编码策略根据当前信道条件进行动态调整，从而实现了优异的视频重建质量。这一结果进一步证实了所提框架在反馈信息有限场景下的实用性与鲁棒性。



(a)




(b)

图 3-5 AdaJSCCV 在 BVI-DVC 数据集上测得的失真性能随信噪比变化曲线图


图 3-8 展示了在 AWGN 信道、 $\text{CBR} = 0.031$ 且 $\text{SNR} = 4 \text{ dB}$ 条件下，不同视频传输方法在相同传输条件下的视频重建结果可视化对比图。图中子标题标注了对应方案的 PSNR(dB)/MS-SSIM 数值，H.264 与 H.265 方案采用码率为 1/2 的 LDPC 信道编码与 QPSK 调制。从主观视觉质量上可以明显观察到，传统分离框架的 H.264 和 H.265 方法所重建的帧存在明显的模糊现象，尤其是在纹理复杂区域和面部细节部分，其高频信息有较大幅度的丢失。相比之下，未集成 DCAM 的 AdaJSCCV 模型虽然在人物和物体的结构轮廓上保持相对清晰，但其重建结果中引入了可见的块效应与随机噪声，影响了视觉一致性。AdaJSCCV 模型所重建的帧则在保持清晰度的同时，显著抑制了伪影与噪声，恢复了更真实、自然的纹理细节。AdaJSCCV 模型的优势在人物面部区域尤为突出，其能够更好地还原肤色过渡、五官轮廓及细微表情特征。这个优势主要来自所提出的 DCAM 对信道噪声的有效补偿，以及端到端联合编码对语义信息的保护机制，从而使模型在低码率与有限信道容量的约束下，仍能实现高层语义与底层视觉细节的共同优化。

图 3-9 展示了在 AWGN 信道、 $\text{CBR}=0.031$ 条件下，LogLPIPS 指标随信道 SNR 变化曲线图。在全部 SNR 条件下，AdaJSCCV 模型在信道条件较差以及信道条件较好时，性能显著领先于其他对比模型。没有 DCAM 模块的 AdaJSCCV w/o DCAM 模型性能的下降，验证了 DCAM 模块对于应对信道变化的关键作用。

而使用粗略信道条件的 AdaJSCCV-C 模型，在某些信道条件下具有最优的性能表现，表明了 DCAM 模块在非理想信道条件下具备鲁棒性。整体来看，本章提出的 AdaJSCCV 模型，其性能在各 SNR 下优于 WITT 模型，验证了 AdaJSCCV 在视频重建上具有有效性。



(a)



(b)

图 3-6 在不同码率与信道条件下，失真性能随信噪比的变化关系图


3.5 消融实验

表 3-2 展示了图像组 GoP 内视频帧的数量对视频重建质量的影响分析。AdaJSCCV 模型主要传输 P 帧，而 I 帧的处理方式与图像语义通信处理方式类似。当 GoP 包含的帧数较少时，由于需要传输更多的 I 帧，导致整体带宽消耗增加。当 GoP 过长时，则可能导致误差在时间维度上的累积传播，进而降低重建质量。为了平衡视频重建质量与带宽消耗，本研究采用包含 6 个视频帧的 GoP 设


置, 此时 AdaJSCCV 的视频重建质量符合用户的需求, 并且可以有效减少视频传输的带宽开销, 从而在压缩视频流系统中实现性能与效率的均衡优化。

表 3-2 在 UCF101 数据集上, SNR = 7 dB 条件下, 基于不同 GoP 配置的视频重建分析表

GoP 帧数	4	6	8	12	14
PSNR(dB)	36.23	36.23	36.17	36.04	36.01
MS-SSIM	0.9912	0.9912	0.9911	0.9910	0.9910
CBR	0.039	0.036	0.035	0.034	0.033



(a)



(b)

图 3-7 在不同码率与信道条件下, 失真性能随信噪比的变化关系图

表 3-3 呈现了针对 AdaJSCCV 模型进行的消融研究结果, 旨在评估其不同组成模块对系统性能的影响。在该表中, NFVLC 表示基于无网络熵编码的变长编码方案, 而 NBVLC 则指代在 DVST^[17] 中采用的基于神经网络的变长编码方

法。所有模型均在 UCF101 数据集上进行了评估,评价指标包括 PSNR、MS-SSIM、单帧推理时间以及浮点运算次数。测试在 SNR=7 dB 的 AWGN 信道条件下进行。


对比结果表明,所提出的 DCAM 能够有效适应变化的信道条件,可将 PSNR 平均提升约 0.8 dB。尽管未使用变长编码的模型取得了最佳的重建性能与最短的推理时间,但其所需的传输带宽超过了其他模型的四倍,在实际带宽受限场景中应用受限。在完整配置下,AdaJSCCV 在单张 RTX 3090 GPU 上实现了平均 52.12 毫秒的推理时间,对应的编码速率约为 114 帧/秒。与之相比,传统 H.264 编码器在类似测试条件下的典型编码速率通常在 10-20 帧/秒之间,表明所提方法在编码效率上具有显著优势。

表 3-3 在 UCF101 数据集、AWGN 信道且信噪比为 7 dB 的条件下,各方案的复杂度与推理时间对比表


模型	PSNR(dB)	MS-SSIM	CBR	推理时间(ms)	FLOPs(G)
AdaJSCCV	36.16	0.991	0.031	52.12	423.1
w/o DCAM	35.35	0.983	0.031	49.90	421.5
w/o DCAM & NFVLC	38.01	0.992	0.145	25.00	421.5
w/ NBVLC	35.87	0.990	0.031	87.59	527.6



(a)原始视频帧



(b)H.264 28.2/0.93



(c)H.265 30.6/0.95



(d)AdaJSCCV w/o DCAM
31.3/0.96



(e)AdaJSCCV 33.4/0.98

图 3-8 视觉对比示例图

此外,基于无网络熵模型的变长编码模块能够有效捕捉语义表示中的全局信息,在视频的重建性能上和基于神经网络的熵模型相当,然而推理速度比基于网络的熵模型提升了 40.5%,并且计算资源消耗降低了 19.8%。这验证了基于无网

络熵模型的变长编码模块维持了码率控制的性能,并且在效率与复杂度方面也具有优势,为在资源受限的实际系统中部署高质量的端到端视频传输方案提供了可能。




图 3-9 不同模型 LPIPS 指标随 SNR 变化曲线图

3.6 本章小结

本章提出了一种基于深度学习的信源信道联合编码模型 AdaJSCCV, 以实现物理信道与内容自适应的无线视频语义通信。该模型能够从联合信源信道编码器与上下文条件编码器中高效地提取视频的语义信息。本章设计了动态信道自适应模块, 以融合时变的物理噪声与视频的语义信息, 从而提升其应对多样化信道条件的能力。此外, 本章提出了一种低复杂度的基于无网络熵模型的变长编码模块, 以实现编码码长的精确控制。实验结果表明, AdaJSCCV 在重建质量与鲁棒性方面均优于传统的无线视频传输方法及其他深度联合信源信道编码方法, 有效验证了所提出的动态信道自适应模块与基于无网络熵模型的变长编码机制的高效性与先进性。

第四章 面向 MIMO 信道语义感知的自适应无线视频传输

本章主要介绍针对多输入多输出信道提出的面向 MIMO 信道语义感知的自适应无线视频传输方案 (Semantic-Aware Adaptive Wireless Video Transmission over MIMO Channels, SAWV-MIMO)。首先,本章总结了相对于 SISO 信道,MIMO 信道存在着更严峻的挑战,随后介绍了当前方法在 MIMO 信道自适应方面的缺点;然后,重点介绍了本章提出的针对 MIMO 信道的视频语义通信模型,并详细阐述了模型主要模块的功能和结构。最后,介绍了模型的参数设置、训练方式,并且通过实验证明了本方法的有效性。

4.1 引言

现有的 DeepJSCC 研究主要集中于单输入单输出 (Single Input, Single Output, SISO) 信道,对多输入多输出 (Multi-User Multiple-Input Multiple-Output, MIMO) 信道等更贴近实际的信道条件研究较少。和 SISO 信道相比, MIMO 信道有着更为恶劣与动态的信道条件,因对系统的实时自适应能力提出了更高的要求。在近期的一项研究^[26]中,为了避免简单地将信道状态信息与语义信息拼接,作者提出了一种非侵入式的 CSI 融合多头注意力模块将 CSI 嵌入到 Swin Transformer 中。Wu 等人^[54]提出了一种语义融合网络将 CSI 语义与图像语义相融合,使模型能够更好地适应不断变化的语义特征。此外, Wu 等人^[55]提出了一种信道感知方法,将用户的 CSI 同时嵌入到联合信源信道编码器和特征融合模块中,使系统能够响应信道动态。以上的工作虽然为在编码过程中引入 CSI 提供了新颖的思路,但多数方法仍然是在特征层的简单拼接或相加融合,未能从信息论和编码原理的深度进行处理,还没有显式地建模出 CSI 与信源统计特征和信道传输可靠性的联合影响机制。尤其是对于视频这类具有较强时空冗余、复杂率失真特性的信源,如何实现在 MIMO 信道中将 CSI 与视频内容语义的双重自适应编码仍然是一个开放且有挑战的难题。因此,探索一种能够深度、灵活、高效地融合 CSI,并实现动态码率控制与抗损伤传输的端到端视频通信框架,对于推动下一代自适应语义通信系统的发展具有重要意义。

然而,现有的无线视频传输方法在面向复杂、动态的实际无线环境时,仍面临若干亟待解决的关键局限。首先,多数现有研究基于信道状态信息完全已知的理想化假设。在自适应机制的设计上,现有方法如文献所述,通常采用简单的特征拼接操作,或将 CSI 的低维嵌入向量直接叠加至语义特征之上。此类浅层融合策略虽能通过静态的神经网络参数实现一定程度的信道条件映射,但本质上未能

建模动态信道变化与视频内容语义之间复杂、非线性的深度交互依赖关系——这种依赖在具有空间复用、干扰与衰落特征的复杂 MIMO 信道条件下尤为关键。静态网络的固定参数本质限制了其对信道状态快速、连续变化的实时适应能力，而融合策略的单一性与架构的刚性，则进一步削弱了系统在时变、多径、干扰等复杂无线环境下的鲁棒性与性能上限，难以实现真正意义上的语义级动态自适应编码。

其次，绝大多数方案在探讨信道自适应时，均默认接收端可获取完美、无噪的 CSI。然而，在实际通信系统中，信道估计模块所获取的 CSI 不可避免地受到噪声污染、量化误差、时延及反馈链路不完善等因素的影响，其本质上是一个不完美的估计值。若直接将含有噪声的 CSI 输入编码网络，不仅无法提供准确的引导，反而会引入额外干扰，导致编码策略失配，严重降低传输可靠性。因此，设计一个能够从带噪的 CSI 观测中有效提取准确、鲁棒的状态表征的信道去噪与提纯模块，已成为提升自适应编码系统实用化能力的关键一环。该模块需具备从非完美估计中恢复信道本质特征的能力，从而为后续的联合编码与调制提供可靠的信道状态先验，确保系统在真实、不完美的信道信息下仍能保持优越性能。

为解决上述挑战，本章提出了一种面向 MIMO 信道的新型自适应深度联合信源信道编码方法，称之为面向 MIMO 信道的语义感知自适应无线视频传输（Semantic-Aware Adaptive Wireless Video Transmission over MIMO Channels, SAWV-MIMO）。SAWV-MIMO 能够动态适应无线 MIMO 信道中的物理噪声，并能够从非理想的信道状态信息中估计出更为准确的 CSI。

本章的主要贡献概括如下：

（1）本章针对 MIMO 信道提出了一个 MIMO 信道语义提取模块（Channel Semantic Extraction Module for MIMO, CSEM-MIMO），该模块综合考虑 MIMO 信道下 CSI 空间维度与特征通道维度的特性，生成了一个可学习的 CSI 语义提示。该语义提示作为指导信号，生成随信道变化的网络参数，动态信道自适应模块中卷积网络的参数将受 CSI 提示的动态调制，从而实现时对变信道条件的灵活适应，突破了传统静态网络在复杂信道环境下适应能力不足的限制。

（2）在更符合实际信道情况的不完美 CSI 条件下，本章提出了一个信道去噪模块（Channel Denoising Module, CDM）。CDM 采用了 Transformer 网络搭建的 U-Net^[56] 架构，能够从含有噪声或非完美的 CSI 估计中提取出更为准确、鲁棒强的信道状态表征，从而有效降低了不完美 CSI 估计对编码性能的影响，提升了系统的实用性与鲁棒性。

（3）实验结果表明，SAWV-MIMO 在 PSNR 与 MS-SSIM 上均优于现有的深度联合信源信道编码方案 DVSC^[24]，并能够有效适应 MIMO 信道的动态变化。

这充分验证了所提动态自适应机制与信道状态提纯模块的有效性。

4.2 面向 MIMO 信道的语义感知自适应无线视频传输系统建模

考虑一个视频序列 $\mathbf{X} \in \mathbb{R}^{N_v \times C \times H \times W}$ ，其中 N_v 表示视频总帧数， C 、 H 和 W 分别代表每一帧的通道数、高度和宽度。与第三章的模型相同，SAWV-MIMO 模型以 GoP $\mathbf{X}_G$ 作为基本输入单元，其整体处理流程如图 4-1 所示。




图 4-1 SAWV-MIMO 架构图

在发送端，运动-外观特征提取器 $f_{ma}(\cdot)$ ^[57] 用于从当前帧 $\mathbf{x}_t$ 中提取相对于参考帧 $\mathbf{x}_0$ 的运动特征 $\mathbf{f}_t^m \in \mathbb{R}^{C_m \times H_m \times W_m}$ 与外观特征 $\mathbf{f}_t^a \in \mathbb{R}^{C_a \times H_a \times W_a}$ 。该提取过程可表述为：

$$\mathbf{f}_t^m, \mathbf{f}_t^a = f_{ma}(\mathbf{x}_t, \mathbf{x}_0; \phi), \quad (4-1)$$

其中 ϕ 表示 $f_{ma}(\cdot)$ 的可学习参数。该模块通过卷积网络结合注意力机制，分别捕捉帧间的位移变化与帧内结构信息。

接着，运动估计模块利用提取出的外观特征 $\mathbf{f}_t^a$ 与运动特征 $\mathbf{f}_t^m$ 计算出运动矢量 $\mathbf{m}_t \in \mathbb{R}^{(C-1) \times H \times W}$ ， $\mathbf{m}_t$ 表征了参考帧到当前帧的像素级运动场。该运动矢量随后通过一个联合信源信道编码器进行维度压缩和信道适配，以便在信道中进行传输。经过编码后，生成运动矢量的语义表征 $\mathbf{y}_t^{mv} \in \mathbb{R}^{C_M \times H/16 \times W/16}$ 。为进一步减少传输过程中带宽的使用，语义表征 $\mathbf{y}_t^{mv}$ 经过熵编码模块进行信息的压缩，最终编码为适于无线传输的符号序列 $\mathbf{s}_t^{mv} \in \mathbb{R}^{N_t \times k_t^{mv}}$ 。其中， N_t 表示发送端发射天线的数量， k_t^{mv} 为熵编码控制下的传输符号长度，其取值由预先设定的码率约束决定。发送端的处理实现了运动信息的高效提取，并且将运动信息编码为更适合信道传输的语义符号，为后续在动态信道条件下的传输奠定基础。

在本章中，采用一个通用的多输入多输出无线信道模型。在该模型中，接收端获得的含噪符号可表示为：

$$\hat{\mathbf{s}}_t^{mv} = \mathbf{H} \cdot \mathbf{s}_t^{mv} + \mathbf{n}_t, \quad (4-2)$$

其中, $\hat{\mathbf{s}}_t^{mv} \in \mathbb{R}^{N_r \times k_t^{mv}}$ 表示接收端获取的信号, 其维度由接收天线数量 N_r 和当前运动信息编码长度 k_t^{mv} 共同决定。 $\mathbf{H} \in \mathbb{R}^{N_r \times N_t}$ 为 MIMO 信道矩阵, 其元素建模了从 N_t 根发射天线到 N_r 根接收天线之间的复信道增益, 包含了路径损耗、阴影衰落与多径传播等综合效应。 $\mathbf{n}_t \sim \mathcal{N}(0, \sigma^2 \mathbf{I}_{k_t})$ 表示加性高斯白噪声, 其各分量均为独立同分布的零均值循环对称复高斯随机变量, 方差为 σ^2 , 反映了信道中的热噪声及其他宽频带干扰。该模型描述了平坦衰落 MIMO 信道下信号传输的基本关系。

在解码器端, 接收到的信号首先通过一个线性层进行处理, 该层对接收到的表示进行维度变换, 从而得到接收语义信息 $\check{\mathbf{y}}_t^{mv} \in \mathbb{R}^{C_M \times H/16 \times W/16}$ 。这一变换旨在将接收符号映射回与编码端语义表示相匹配的维度, 为后续的重建过程提供适配的特征输入。为了有效抑制无线信道噪声与衰落效应对语义信息造成的干扰, 本章使用第三章提出的动态信道自适应模块。该模块旨在利用信道状态信息, 为解码过程提供一种更灵活、更具适应性的特征增强机制。具体而言, 在假设信道矩阵 $\mathbf{H}$ 已知的条件下, MIMO 信道语义提取模块 (Channel Semantic Extraction Module for MIMO, CSEM-MIMO) 被用于从 $\mathbf{H}$ 中提取一个可学习的信道语义表征 $\mathbf{r} \in \mathbb{R}^{C_N}$ 。该过程可形式化表示为:

$$\mathbf{r} = f_{\text{CSEM-MIMO}}(\mathbf{H}; \alpha), \quad (4-3)$$

其中 α 表示 CSEM 中的可学习参数。CSEM-MIMO 的设计目标并非直接使用原始信道矩阵, 而是使用神经网络在 CSI 中提取出与当前传输的视觉特征及信道条件最为相关的、紧凑的信道语义提示, 这个信道语义提示将作为指导解码器进行自适应特征校正与增强的条件信息。

然而, 在实际通信系统中, 通过估计获得的信道矩阵 $\hat{\mathbf{H}}$ 不可避免地包含噪声、量化误差及可能存在的反馈延迟, 是一种不完美的信道状态信息。为了克服不完美 CSI 对系统性能造成的负面影响, 本章提出信道去噪模块 (Channel Denoising Module, CDM), CDM 对 $\hat{\mathbf{H}}$ 进行进一步处理, 从而得到一组更精确、更鲁棒的信道参数估计 $\hat{\hat{\mathbf{H}}}$ 。该过程可形式化表示为:

$$\hat{\hat{\mathbf{H}}} = f_{\text{CDM}}(\hat{\mathbf{H}}; \psi), \quad (4-4)$$

其中 ψ 表示 CDM 中的可学习参数。CDM 的核心目标是, 基于大量信道数据的统计特性, 学习从带噪声的估计值 $\hat{\mathbf{H}}$ 到更接近真实信道 $\mathbf{H}$ 的映射。因此, 在更符合实际的不完美 CSI 条件下, 最终用于指导自适应解码的信道语义表示 $\mathbf{r}$ 并非直接来源于原始估计 $\hat{\mathbf{H}}$, 而是从经过 CDM 提纯后的 $\hat{\hat{\mathbf{H}}}$ 中, 通过 CSEM-MIMO 处

理得到，即

$$\mathbf{r} = f_{\text{CSEM}}(\hat{\mathbf{H}}; \alpha). \quad (4-5)$$

随后，在 DCAM 中，信道语义表示 $\mathbf{r}$ 指导神经网络对视觉特征 $\check{\mathbf{y}}_t^{mv}$ 进行编码。在这个过程中， $\mathbf{r}$ 经过 MLP 生成一组卷积核权重和特征调制系数，这组系数会指导 FAM 块对视觉特征进行编码，从而使网络能够适应信道条件的变化，并最终生成经过信道失真校正的语义表示 $\hat{\mathbf{y}}_t^{mv}$ 。上述过程可用公式表述为：

$$\hat{\mathbf{y}}_t^{mv} = f_{\text{DCAM}}(\check{\mathbf{y}}_t^{mv} | \mathbf{r}; \beta), \quad (4-6)$$

其中 β 表示 DCAM 中的可学习参数。

接着，调整后的语义表示 $\hat{\mathbf{y}}_t^{mv}$ 被送入联合信源信道解码器，以解码出重建的运动矢量 $\hat{\mathbf{m}}_t$ 。在已解码的参考帧 $\hat{\mathbf{x}}_0$ 的指导下，帧重建模块（Frame Reconstruction Module, FRM） $f_r(\cdot)$ 利用运动矢量 $\hat{\mathbf{m}}_t$ 进行运动补偿与纹理合成，最终重建出当前帧 $\hat{\mathbf{x}}_t$ 。该过程可表述为：

$$\hat{\mathbf{x}}_t = f_r(\hat{\mathbf{m}}_t | \hat{\mathbf{x}}_0; \theta), \quad (4-7)$$

其中 θ 表示 $f_r(\cdot)$ 中可优化的参数，它的主要任务是根据运动矢量所提供的位移场，将参考帧的像素与特征扭曲至当前帧的坐标系，并进一步修复因遮挡、光照变化等造成的残差信息，从而生成视觉质量高、时序连贯性强的重建帧。

本章对 SAWV-MIMO 采用两阶段训练策略。在第一阶段，该框架旨在在严格的码率约束下，实现重建视频帧的感知失真最小化。SAWV-MIMO 的优化通过一个率失真损失函数来完成。编码码率受整个图像组内传输符号 $\mathbf{s}_t^{mv}$ 的长度影响。每帧传输符号的平均数量 k 定义为：

$$k = \frac{1}{T} \sum_{t=1}^T k_t^{mv}. \quad (4-8)$$

本章使用 CBR 来描述图像组 $\mathbf{X}_G$ 的平均编码效率，其计算公式为：

$$\text{CBR} = \frac{k \times N_t}{H \times W \times C}. \quad (4-9)$$

在第一阶段的训练中，SAWV-MIMO 不集成 CDM 模块，训练 SAWV-MIMO 模型的视频重建能力，第一阶段训练的总体目标函数形式化如下：

$$\mathcal{L}_{\phi, \theta, \alpha, \beta} = \lambda_1 \cdot \sum_{t=1}^T (||\mathbf{x}_t - \hat{\mathbf{x}}_t||_2^2) + \lambda_2 \cdot \text{CBR}, \quad (4-10)$$

其中, λ_1 和 λ_2 为加权系数, 用于权衡失真损失与码率约束之间的平衡。失真项采用均方误差 (Mean-Square Error, MSE) 度量重建帧 $\hat{\mathbf{x}}_t$ 与原始帧 $\mathbf{x}_t$ 之间的像素级差异; 码率项则直接对传输开销进行正则化, 鼓励模型学习高效的压缩表示。在该损失函数中, ϕ 、 θ 、 α 、 β 分别对应于运动-外观特征提取器、帧重建模块、信道语义提取模块以及动态信道自适应模块中待优化的参数集合。此联合优化过程驱使模型在有限的无线资源下, 自主探索视觉保真度与编码效率之间的最优权衡。

在第二阶段训练中, 冻结 SAWV-MIMO 框架其余组件的参数, 单独训练 CDM 模块。CDM 的目标是对含噪声的信道矩阵估计值 $\hat{\mathbf{H}}$ 进行去噪, 从而恢复出对原始洁净信道矩阵 $\mathbf{H}$ 的更准确估计 $\hat{\mathbf{H}}$ 。该阶段训练的损失函数定义为:

$$\mathcal{L}_{\psi} = ||\mathbf{H} - \hat{\mathbf{H}}||_2^2, \quad (4-11)$$

其中 ψ 表示 CDM 中待优化的参数。此 MSE 函数直接约束去噪后的信道估计 $\hat{\mathbf{H}}$ 逼近真实的信道矩阵 $\mathbf{H}$, 驱使 CDM 学习从带噪声观测中恢复信道本质特征的映射。

4.2.1 MIMO 信道语义提取模块

表 4-1 注意力模块、特征维度注意力模块以及空间注意力模块结构表

模型名称	模型结构
Attention Module	AveragePooling
	Conv(s = 1, k = 1) + GELU
	Conv(s = 1, k = 1) + Sigmoid
Feature Dimension Attention Module	AveragePooling
	Conv(s = 1, k = 1) + ReLU
	Conv(s = 1, k = 1) + Sigmoid
Spatial Attention Module	Conv(s = 1, k = 1) + ReLU
	Conv(s = 1, k = 1) + Sigmoid

CSEM-MIMO 的整体网络架构如图 4-2 所示。其核心子模块包括注意力模块 (Attention Module, AM)、特征维度注意力模块 (Feature Dimension Attention Module, FDAM) 与空间注意力模块 (Spatial Attention Module, SAM), 这些模块的详细结构参数与层级配置见表 4-1。

由于无线 MIMO 信道矩阵 $\mathbf{H}$ 本质为复数值矩阵，并且神经网络更适合进行实数的运算，将 $\mathbf{H}$ 拆分为实部与虚部，并沿一个新的维度进行拼接，从而构成一个实值的张量 $\mathbf{H}_2$ 。为了充分利用物理信道的信道状态信息和接收端解调后的语义特征，SAWV-MIMO 将接收信号 $\tilde{\mathbf{y}}_t^{mv}$ 与信道张量 $\mathbf{H}_2$ 沿通道维度进行拼接，共同作为 CSEM-MIMO 模块的输入特征 $\mathbf{y}_{in} \in \mathbb{R}^{C_I \times H_I \times W_I}$ 。这个设计保证了后续的信道语义提取能同时感知信道条件与当前传输的视觉内容。




图 4-2 MIMO 信道语义提取模型架构图

在 CSEM-MIMO 内部，沿特征通道维度和空间维度分别定义了两组可学习的参数基，用以建模信道状态在不同维度的潜在影响：特征维度提示基 $\mathbf{P}_F \in \mathbb{R}^{N \times 1 \times 1 \times C_I}$ 与空间维度提示基 $\mathbf{P}_S \in \mathbb{R}^{N \times H_I \times W_I \times 1}$ 。每个基包含 N 组原型参数，共同编码了 MIMO 信道在各种典型状态下的多维语义特征。为实现动态自适应，AM 对输入特征 $\mathbf{y}_{in}$ 进行分析，输出一组注意力权重 $\mathbf{W} \in \mathbb{R}^{1 \times N}$ ，该权重反映了当前输入与各原型参数的关联程度。随后，利用 $\mathbf{W}$ 对两个参数基进行加权聚合，生成与当前上下文高度相关的复合特征维提示 $\mathbf{P}_{F1} \in \mathbb{R}^{C_I \times 1 \times 1}$ 与复合空间维提示 $\mathbf{P}_{S1} \in \mathbb{R}^{1 \times H_I \times W_I}$ 。由于权重 $\mathbf{W}$ 由包含信道信息的 $\mathbf{H}_2$ 和信号 $\tilde{\mathbf{y}}_t^{mv}$ 共同决定，因此生成的提示能够自适应地感知并表征当前信道的瞬时特性。

为进一步深化信道语义与视觉特征的融合，将得到的提示向量与原始输入特征进行条件化调制。具体而言，特征维提示 $\mathbf{P}_{F1}$ 与空间维提示 $\mathbf{P}_{S1}$ 分别通过逐元素乘法，对输入特征在通道和空间上进行缩放，得到条件化特征表示 $\hat{\mathbf{P}}_{F1}$ 与 $\hat{\mathbf{P}}_{S1}$ 。此后，这两个条件化特征进入一个交叉精炼过程， $\hat{\mathbf{P}}_{F1}$ 经由 FDAM 处理，其输出用于在通道维度上增强 $\hat{\mathbf{P}}_{S1}$ 的表示；同时， $\hat{\mathbf{P}}_{S1}$ 经由 SAM 处理，其输出用于在空间维度上增强 $\hat{\mathbf{P}}_{F1}$ 的细节。这种相互精炼的机制使得信道信息在特征的空间相关性与通道依赖性上都得到了充分利用和强化。最后，将两路精炼后的特征进行融合，并通过一个 1×1 卷积层进行信息整合与降维，动态生成一个紧凑而丰富的语义表示 $\mathbf{r}$ 。该表示 $\mathbf{r}$ 综合编码了当前 MIMO 信道的状态及其对语义传输的影响，将作为控制信号，指导解码器网络对受损特征进行自适应校正与重建，从而有效对抗信道衰落与噪声。

随后,使用前面提出的 DCAM 根据信道状态动态调整模型参数。具体来说,信道表示 $\mathbf{r}$ 通过一个 MLP, 实时产生适用于当前信道状态的卷积权重与偏置。同时, $\mathbf{r}$ 也用于计算空间与通道维度上的自适应调制系数, 对特征图进行重加权。这种设计使得网络能够针对不同的信道质量实时调整其特征变换行为, 从而实现对信道引入的失真进行针对性的补偿与抑制。通过多个 FAM 的级联处理, 信道状态信息被逐步、深层地融入到特征修复的每一步中, 最终输出一个对信道干扰不敏感、更具鲁棒性的语义表示 $\hat{\mathbf{y}}_t^{mv}$, 为后续的高质量视频帧重建奠定基础。

4.2.2 信道去噪模块




图 4-3 信道去噪模块结构图

为应对不完美的信道条件,本章提出的信道去噪模块对含噪声的信道矩阵 $\tilde{\mathbf{H}}$ 进行提纯, 以生成一个接近于理想信道 $\mathbf{H}$ 的精确估计 $\hat{\mathbf{H}}$ 。如图 4-3 所示, CDM 首先将输入 $\tilde{\mathbf{H}}$ 送入一系列 Transformer 块中进行深层特征提取与信息融合。受 Resformer^[58] 的启发, 在每个 Transformer 块内部, 本章对标准 Transformer 中的前馈线性层进行了关键性改进, 使用卷积操作替代传统的全连接层。这一设计不仅增强了模型捕获局部特征关联与空间结构的能力, 同时显著提升了模型的计算效率与参数效率, 使其更适用于处理具有网格结构特性的信道矩阵数据。通过多级 Transformer 块的级联处理, 模型能够逐步分离噪声、学习信道的内在规律, 最终输出高质量的去噪信道估计 $\hat{\mathbf{H}}$, 为后续的自适应编码与解码提供可靠的信道状态先验。

针对输入特征 $\mathbf{F}_H$, 首先通过一组独立的卷积层将其分别投影为查询矩阵 $\mathbf{Q}$ 、键矩阵 $\mathbf{K}$ 与值矩阵 $\mathbf{V}$ 。与传统的线性投影相比, 采用卷积操作能够在进行维度变换的同时, 有效保留并利用特征图的局部空间相关性, 这对于具有结构化特性的信道矩阵处理尤为重要。随后, 采用多头自注意力机制 来计算不同位置特征之间的交互关系。具体而言, 多头自注意力机制 (Multi-Head Self-Attention, MSA) 将 $\mathbf{Q}$ 、 $\mathbf{K}$ 、 $\mathbf{V}$ 沿特征维度分割为多个注意力头, 使模型能够并行地从不同子空间

学习多样化的依赖关系。注意力权重的计算遵循缩放点积注意力公式：

$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{Softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right)\mathbf{V}, \quad (4-12)$$

其中 d_k 为 $\mathbf{Q}$ 和 $\mathbf{K}$ 的特征维度， $\sqrt{d_k}$ 的缩放因子用于防止点积结果过大导致 Softmax 函数进入梯度饱和区。该机制使模型能够动态地聚焦于 CSI 中相关性最强的部分，从而在全局感受野内捕捉复杂的内部依赖，实现从带噪声观测中区分信道固有模式与随机干扰的细粒度特征提取。注意力输出通过一个残差连接与输入特征 $\mathbf{F}_H$ 相加，得到初步融合全局信息的特征 $\mathbf{y}_H$ ：

$$\mathbf{y}_H = \text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) + \mathbf{F}_H. \quad (4-13)$$

残差结构确保了梯度在深层网络中的有效传播，并保留了原始的局部特征信息。

接着， $\mathbf{y}_H$ 经过层归一化后，馈入一个 MLP 进行进一步的非线性变换与特征整合：

$$\mathbf{y}_H^o = \text{MLP}(\text{LN}(\mathbf{y}_H)) + \mathbf{y}_H, \quad (4-14)$$

其中 $\text{LN}(\cdot)$ 表示 Layer Normalization 层归一化^[59] 处理，MLP 由两个全连接层与一个非线性激活函数构成，对注意力机制提取的全局特征进行精细化加工与维度调整。

具体来说，一组 Transformer 模块被叠加堆叠，使得 CDM 实现了不同层级、不同尺度特征的融合，可以实现由粗到细的特征提取层次，其中浅层模块主要抓取信道矩阵的局部噪声与短期相关性，深层模块可以融合更多的上下文信息学习信道衰落的结构化和全局统计。不同层级的特征通过跳跃连接与注意力机制进行交互、融合，实现多尺度信息的互补。外部全局残差连接可以将原始带噪输入 $\hat{\mathbf{H}}$ 直接接收到网络的末端，再与深度网络提取的“噪声残差”或“信道校正量”相加。这种“恒等映射”结构可以使得网络只需要学习从带噪输入到理想信道的残差映射，大大简化了学习目标，加速了训练收敛同时也提高了去噪性能的稳定性和输出 $\hat{\mathbf{H}}$ 精度。

4.2.3 运动-外观特征提取模块

运动与外观特征提取模块的关键在于通过帧间注意力机制一同建模帧间运动和传递外观信息，实现了判别性运动特征 $\mathbf{f}_t^m$ 与外观特征 $\mathbf{f}_t^a$ 的统一提取，这种机制通过单一的注意力计算，提高连续帧之间外观特征一致性的同时捕获帧间运动变化特征。

具体而言,对于当前帧 $\mathbf{x}_t$ 中的任一图像块,将其视为查询向量,并将参考帧 $\mathbf{x}_0$ 中对应的图像块作为键与值向量,通过计算查询与键之间的相似度,生成一个表征时序相关性的注意力权重图。该权重图随后用于两方面:首先,通过对参考帧的外观特征进行加权聚合,从而融合跨帧上下文信息,增强当前区域的外观表示 $\mathbf{f}_t^a$;其次,利用同一注意力权重对当前帧相对于参考帧的位移场进行加权,从而估计并提取从当前帧到参考帧的判别性运动特征 $\mathbf{f}_t^m$ 。这种基于注意力的统一提取架构不仅避免了传统方法中运动估计与特征提取分离所带来的误差累积问题,还能够通过端到端的学习,使运动与外观特征在共同的表示空间中相互协同与增强。

4.2.4 JSCC 编码器、解码器与帧重建模块

JSCC 编码器从运动矢量 $\mathbf{m}_t$ 中获取紧凑的语义特征,经过层层下采样减小其空间维度,进而实现特征提取和特征压缩。JSCC 编码器由三个相同的模块组成。每个模块均包含一个步长 2 为的 5×5 卷积层,一个广义可分离归一化层 (Generalized Divisive Normalization, GDN) 和一个残差块。卷积层进行特征空间下采样与特征变换, GDN 使用可学习的非线性归一化描述视觉感知,实现特征的稀疏表示;残差块用于增加特征表达能力以及保障梯度传播的稳定性。

JSCC 解码器将从收端潜在特征 $\hat{\mathbf{y}}_t^m$ 中重建运动矢量 $\hat{\mathbf{m}}_t$,其主体结构同样由 3 个模块组成,并进行与编码器相反的操作。每个模块均包含一个步长为 2 的 3×3 转置卷积层,逆广义可分离归一化层 (Inverse Generalized Divisive Normalization, IGDN) 以及一个残差块,逐步重构特征的空间分辨率和数值分布。为完成解码过程以及提高输出质量,在上述结构后添加一个最终的转置卷积层和两个残差块用以对重建的运动矢量进行细粒度优化和修饰。

在 JSCC 解码器恢复出运动矢量 $\hat{\mathbf{m}}_t$ 后,模型在接收端利用其对已重建的参考帧 $\hat{\mathbf{x}}_0$ 进行运动补偿扭曲,生成一个初步的、相对粗糙的视频帧估计 $\hat{\mathbf{x}}_t$ 。为了进一步提升重建帧的视觉质量,本章采用了一个基于 U-Net 模型的帧细化模块,把拼接后的 $\hat{\mathbf{m}}_t$ 、 $\hat{\mathbf{x}}_0$ 和 $\hat{\mathbf{x}}_t$ 作为帧细化模块的输入。U-Net 模型的编码器使用四个连续的卷积层进行处理,在逐步下采样的同时增加通道深度以提取多尺度特征。U-Net 的解码器路径则利用转置卷积逐步上采样特征图。在每一个上采样阶段,通过跳跃连接将解码器特征与编码器对应阶段的特征进行拼接,从而有效整合不同尺度的上下文信息,保留细节并抑制伪影。整个过程以一个最终的卷积层结束,输出经过精细重建的高质量视频帧 $\hat{\mathbf{x}}_t$ 。该设计确保了最终重建帧在保持时序一致性的同时,具备优异的视觉保真度。

4.3 仿真实验设置

4.3.1 数据集

在模型训练中,本章采用 UCF101 数据集对 SAWV-MIMO 进行训练和测试,按照 0.8:0.1:0.1 的比例将 UCF101 数据集划分为训练集、验证集和测试集。输入序列的构建采用 GoP 的方式,每组由连续 6 个视频帧组成;所有视频帧均统一处理到 256×256 分辨率,并以序列中的第一帧作为参考帧 $\mathbf{x}_0$ 。在评估 SAWV-MIMO 模型时,为了测试模型的通用性,除了 UCF101 数据集测试集外,使用高分辨率视频数据集 BVI-DVC 上进行外部评估。

4.3.2 训练设置

在实验设置中,外观特征与运动特征的维度分别配置为 $256 \times 16 \times 16$ 与 $512 \times 16 \times 16$,其中运动向量通道 C_M 设置为 128。对于 CSEM-MIMO,可学习参数 N 设为 5,中间特征维度 C_I 设为 64,空间尺寸 H_I 与 W_I 均设为 16。DCAM 由五个 FAM 串联构成。

在基于无网络熵编码的变长编码模块中,上下文特征维度 R 设定为 64。针对非理想信道条件,采用两阶段训练策略,首先在理想信道下对联合信源信道编码网络进行预训练;随后固定该编码网络参数,仅对信道去噪模块进行独立训练。信道训练阶段基于 16×16 的 MIMO 系统,其信噪比在 $[-10 \text{ dB}, 20 \text{ dB}]$ 区间内均匀采样生成。为模拟 MIMO 信道的不完美性,在信道矩阵中引入加性噪声:

$$\tilde{\mathbf{H}} = \mathbf{H} + \mathbf{H}_{\sigma_N}, \quad (4-15)$$


其中噪声项 $\mathbf{H}_{\sigma_N}$ 服从方差为 σ_N 的正态分布。优化器选用 Adam 优化器,初始学习率设为 10^{-4} 。在单张 RTX 4090 GPU 上,以批次大小为 4 进行训练,完整 SAWV-MIMO 模型的训练周期约为 1.5 周。

4.3.3 对比方案与评估指标


本章将 SAWV-MIMO 与基于深度学习的联合信源信道编码方法 DVSC 进行性能比较。在评估两个模型的性能时,分别采用 PSNR 与 MS-SSIM 作为模型的评价指标。PSNR 定量反映重建图像与原始图像在像素强度上的差异;MS-SSIM 从亮度、对比度和结构信息等多个方面,衡量两幅图像在视觉感知上的相似程度。两种指标互为补充,分别从数值精度与感知质量两个层面对视频的重建效果进行全面评估。

4.4 结果性能分析

图 4-4、4-5 展示了在 UCF101 数据集上，MIMO 信道条件下，不同模型的失真性能与 SNR 之间的变化关系。采用 PSNR 与 MS-SSIM 两种评估指标，对以下五种方法的性能进行了系统比较与分析：(i) 本文提出的 SAWV-MIMO 模型，即包含完整设计的基准模型；(ii) “Only S-Prompt” 模型，其 CSEM-MIMO 仅使用空间维度提示信息；(iii) “Only FD-Prompt” 模型，其 CSEM-MIMO 仅使用特征通道维度提示信息；(iv) “SAWV-MIMO w/o DCAM” 模型，即移除了 DCAM-MIMO 的简化版本模型。(v) 基于深度学习的联合信源信道编码方法 DVSC。该对比实验旨在验证模型中各关键组件对最终重建性能的贡献，并探讨不同提示策略与结构模块在 MIMO 信道环境下的有效性与鲁棒性。



(a)




(b)

图 4-4 在 UCF101 数据集上，MIMO 信道中失真性能随 SNR 变化曲线图


如图 4-4 所示，随着 SNR 的提升，SAWV-MIMO 模型展现出显著优势，其 PSNR 与 MS-SSIM 指标在所有 SNR 条件下均优于其他四种对比方法。具体而

言，在 PSNR 指标上，SAWV-MIMO 显著优于 DVSC 方法，在 $\text{SNR} = 0 \text{ dB}$ 时较 DVSC 提升达 3.7 dB。在低信噪比环境下，SAWV-MIMO 在 MS-SSIM 指标上也较 DVSC 具有明显优势。以上结果表明，在 MIMO 信道场景中，SAWV-MIMO 相比 DVSC 模型具备更优的综合性能。

在图 4-4 中，“SAWV-MIMO w/o DCAM”模型性能显著低于其余各模型。在 $\text{SNR} = 0 \text{ dB}$ 时，其 PSNR 依次低于其他模型 0.59 dB、0.22 dB 与 0.13 dB，这充分说明 DCAM 对提升模型性能具有关键作用。此外，SAWV-MIMO 表现优于仅使用单一提示集的模型，这表明 CSEM-MIMO 能够有效融合空间与特征通道维度的提示信息，从而更充分地实现信道特征提取。



(a)




(b)

图 4-5 在 BVI-DVC 数据集上，MIMO 信道中失真性能随 SNR 变化曲线图


在高分辨率视频数据集 BVI-DVC 上，图 4-5 展示了 MIMO 信道中不同方法的失真性能随 SNR 变化的对比结果。与 UCF101 数据集上的结论相似，SAWV-MIMO 在全部信噪比范围内均保持最优性能，仅使用单一提示策略的变体模型性能次之，而移除 DCAM 的模型性能相对最弱，该结果直观验证了模型在高分辨率数据集上多维度提示融合与动态信道自适应模块的有效性。

图 4-6 展示了在 UCF101 数据集上, 不同信道状态信息条件下模型失真性能与信噪比的关系。图 4-6 通过对比 PSNR 和 MS-SSIM 两项指标, 对比了三种模型设置的性能表现, 这三种模型分别是: 在完美信道状态信息下的 SAWV-MIMO 模型、基于非理想信道状态信息的“Imperfect CSI”模型, 以及采用 CDM 进行信道估计的“Estimated CSI”模型。

随着 SNR 提升, 采用完美 CSI 的 SAWV-MIMO 模型在所有信噪比水平下均保持最优性能, 这表明其在理想信道条件下具备恢复高质量图像的能力。与之相对, 在信道条件非理想时, 模型性能出现明显下降。例如, SNR=-10 dB 时, 当噪声方差分别为 $\sigma_N^2 = 300$ 与 $\sigma_N^2 = 500$ 时, PSNR 相较理想条件分别下降 1.12 dB 与 4.11 dB。然而, 引入 CDM 模块进行信道估计的模型能够部分弥合这一性能差距, 其重建结果接近理想信道条件下的表现。由于在两种噪声水平下估计得到的信道矩阵较为接近, 该模型在不同噪声环境下呈现出稳定的性能。这一结果验证了 CDM 模块在信道估计方面的有效性, 表明其能够在一定程度上克服非理想信道信息带来的性能损失, 提升系统在实际信道环境中的鲁棒性。




(a)




(b)

图 4-6 UCF101 数据集上 MIMO 信道中失真性能随 SNR 变化曲线图

图 4-7 展示了在 BVI-DVC 数据集上，不同信道状态信息条件下模型失真性能与信噪比的变化关系。如图所示，采用理想 CSI 的 SAWV-MIMO 模型始终拥有最好的性能，表明在信道状态信息完美的条件下，该模型能够充分利用信道容量，实现最优的图像重建质量。与之相比，当信道状态信息存在误差时，分别对应噪声方差为 $\sigma_N^2 = 300$ 与 $\sigma_N^2 = 500$ 的情况，模型性能出现显著下降。具体而言，在 SNR=-10dB 的低信噪比条件下，两种非理想 CSI 场景对应的 PSNR 值较理想情况分别降低了 1.34 dB 与 5.03 dB，显示出信道误差对重建性能的明显影响。然而，通过引入信道去噪模块进行估计后的 CSI，模型性能得到了有效恢复。如图 4-7 所示，基于估计 CSI 的模型输出结果与理想 CSI 下的性能曲线十分接近，且在两种不同噪声水平下表现出良好的一致性，这表明 CDM 模块能够有效抑制信道噪声干扰，获得准确稳健的信道状态估计。该结果从客观上验证了 CDM 模块在非理想信道条件下的有效性与鲁棒性，表明所提方法能够显著缓解因信道状态信息不准确而导致的性能损失，从而提升系统在实际无线环境中的适应能力。



(a)



(b)

图 4-7 BVI-DVC 数据集上 MIMO 信道中失真性能随 SNR 变化曲线图

图 4-8 展示了在 MIMO 信道、低信噪比与低码率条件下，不同视频传输方法重建帧的视觉对比结果。图中标注为 PSNR(dB)/MS-SSIM，此处展示了在 MIMO 信道、CBR=0.031、SNR=-10 dB 条件下的结果。从主观视觉质量上可以发现不同方法之间存在明显的差异，DVSC 方法的重建结果整体模糊，边缘与纹理细节丢失严重，尤其是在面部五官、头发纹理等高频区域缺乏清晰的物体结构。相比之下，SAWV-MIMO w/o DCAM 虽然在一定程度上恢复了部分轮廓信息，但在平坦区域与边缘处引入了可见的块效应与物体伪影，影响了视觉连贯性。与上面两种方法形成鲜明对比的是，完整的 SAWV-MIMO 模型在视觉保真度上表现优异。其在人脸关键区域，如眼睛和嘴唇部分，恢复了更丰富的纹理细节，背景中的物体轮廓也更为清晰自然，整体图像在结构一致性和视觉舒适度上均显著优于其他对比方法。该视觉对比结果与前述 PSNR、MS-SSIM 客观指标的变化趋势一致，共同验证了所提出模型中各组件在提升重建质量、抑制失真与伪影方面的有效性。



(a) 原图像



(b) DVSC 29.34/0.950

(c) SAWV-MIMO w/o
DCAM-MIMO 33.21/0.984(d) SAWV-MIMO w S-
Prompt 33.59/0.985(e) SAWV-MIMO w FD-
Prompt 33.88/0.984(f) SAWV-MIMO
34.39/0.987

图 4-8 可视化结果对比示例图

表 4-2 展示了在 NVIDIA RTX 4090 设备上，不同视频传输模型在 UCF101 测试集上的推理时间、模型参数量与浮点运算量的具体情况。在测试时，每个视频依次进行推理。尽管 SAWV-MIMO 在参数量和计算复杂度上稍高于其他视频传输模型，但在视频重建质量方面有着明显的优势。上面的结果显示了模型在计

算复杂度与重建性能之间存在的权衡关系,SAWV-MIMO 在可控的计算开销内,实现了更为卓越的重建质量,体现了其良好的设计效率与实用性。

表 4-2 UCF101 数据集、SNR = 0 dB 的条件下,模型复杂度与推理时间对比表

模型名称	模型参数量(M)	推理时间(ms)	FLOPs(G)
SAWV-MIMO	41.52	32.30	391.584
w/o CDM	21.42	28.07	391.584
w/o DCAM-MIMO	20.55	24.69	391.046
w S-Prompt	21.41	25.78	391.579
w FD-Prompt	21.41	26.87	391.579
DVSC	19.41	32.23	837.658

4.5 结论

本章提出了一种面向 MIMO 信道的深度联合信源信道编码模型——SAWV-MIMO,以实现信道自适应的无线视频语义通信。该模型能够通过运动-外观特征高效提取视频帧的特征。本章设计了 MIMO 信道语义信息提取模块,从信道状态信息以及接收端信号的空间与特征维度进行建模,提取出 MIMO 信道的语义信息,从而将变化的信道噪声条件与语义信息进行深度融合,从而提升系统应对多样化信道环境的能力。此外,针对非理想信道条件,本章提出了信道去噪模块,能够从含噪的信道状态信息中估计出准确的信道状态,为后续重建提供可靠的信道先验。实验结果表明,SAWV-MIMO 能够有效适应 MIMO 信道的变化,在多种信噪比与码率条件下均取得优越的重建性能,验证了动态信道自适应模块与信道去噪模块的有效性。

第五章 基于多模态交叉注意力的自适应无线视频传输

本章主要介绍了基于多模态交叉注意力的自适应无线视频传输方法（Multimodal Cross-Attention for Channel-Adaptive Video Transmission, MCAJSCCV）。首先，本章指出了当前信道自适应方法中信道语义表示不足的问题；然后，重点介绍了本章提出的基于多模态交叉注意力的自适应无线视频传输方法的模型，并详细介绍了模型的主要模块。最后，阐述了模型的参数设置、训练方式，并通过实验证明了 MCAJSCCV 模型的有效性。

5.1 引言

在前两章，本文主要讨论了在加性高斯白噪声信道、瑞利信道等简单信道以及 MIMO 等复杂信道的信道自适应方法。然而，现有的语义通信视频传输方案大多存在信道自适应能力不足的问题，多数方法将信道状态信息视为简单的标量或固定维度的向量，这种处理方式存在关键局限。首先，简单的数值向量难以刻画信道的衰落类型、多普勒频移等复杂物理特性及其对语义传输的非线性影响。另外，在进行信息交互时，信源特征与信道特征之间缺乏显式的交互机制，编码器难以根据信道状态动态调整语义特征的重要性，导致在恶劣信道下对不同语义信息进行相同的处理，浪费了宝贵的传输资源。

为系统性解决上述问题，本章创新性地提出一种基于多模态交叉注意力机制的信道自适应视频传输框架（Multimodal Cross-Attention for Channel-Adaptive Video Transmission, MCAJSCCV）。本研究的核心思想在于，将信道自适应从传统的物理层参数优化问题，转变为跨模态的语义融合与条件编码问题。具体而言，本研究的主要创新点包括：第一，本章提出了一种语义化的信道状态表征方法，引入自然语言描述，如信道的基础参数、信道衰落类型与干扰、信道的统计与信息以及通信网络的意图，均可以作为信道条件的通用接口。相对于使用单一 SNR 数值，文本描述可以融合多维度、跨层信息，形成一个综合的信道描述，为模型进行信道自适应提供了更丰富的信道信息。通过预训练语言模型进行编码，该方法能够融合更丰富的信道语义与上下文信息，为自适应决策提供远超传统标量参数的先验知识。第二，本章设计了一种层级式的跨模态特征融合架构。该架构首先通过视觉编码器提取视频帧的深度时空特征，随后利用一个专用的对齐网络，将文本化信道表征映射至视觉特征空间。另外，在后续的交叉注意力模块中，本文为视觉和文本序列中的每个特征单元设计了独立的线性投影层，这样的设计赋予了模型为不同空间位置、不同语义重要性的视觉内容，学习差异化融合策略的

能力，实现了从“帧级”、“块级”到“特征级”的粒度革新，极大增强了模型的条件编码容量与灵活性。在该交叉注意力机制中，以视觉特征为查询，以文本化信道特征为键和值，使模型能够动态地依据信道条件，对视觉特征进行重要性重加权与内容感知的增强或压缩。本章的贡献可概括如下：

(1) 提出了一种基于文本描述的信道语义建模新范式，为复杂、动态的信道环境提供了表达能力更强、更易于与高层语义对接的表征方式。

(2) 设计了一个新颖的信道编码模块—多模态交叉注意力模块 (Multimodal Cross-Attention Module, MCAM)，其中每个 Token 分配一个 MLP (Per-token FFN, PFFN) 的细粒度投影机制与以视觉为查询的交叉注意力机制相结合，实现了视频内容与信道状态的深度融合与精准的条件化编码。

(3) 在 AWGN 信道上进行训练和验证，MCAJSCCV 在 UCF101 数据集上进行训练、测试和验证，在 PSRN 和 MS-SSIM 指标上均优于传统传输方法以及其他 DeepJSCC 方法，验证了多模态交叉注意力模块的有效性。

5.2 基于多模态交叉注意力的自适应视频传输方法




图 5-1 MCAJSCCV 模型架构图

考虑一个视频序列 $\mathbf{X} \in \mathbb{R}^{N_v \times C \times H \times W}$ ，其中 N_v 表示视频总帧数， C 、 H 和 W 分别代表每一帧的通道数、高度和宽度。MCAJSCCV 模型以 GoP $\mathbf{X}_G$ 作为基本输入单元，模型的整体处理流程如图 5-1 所示。

对于视频的编码过程，MCAJSCCV 首先对 GoP 进行时空特征分析，使用运动-外观特征提取器捕获当前帧 $\mathbf{x}_t$ 与参考帧 $\mathbf{x}_0$ 帧间的动外观信息和静态外观信息，利用运动估计模块获得描述当前帧与参考帧间像素位移的运动矢量 $\mathbf{m}_t$ ，并使 JSCC 编码器将高维运动矢量 $\mathbf{m}_t$ 表示为紧凑的潜在特征表示 $\mathbf{y}_t^{mv}$ ，其目的在于通过深度神经网络实现对信源冗余的非线性压缩，并将视频语义表示为符合信道

传输的特征形式。为提高抗干扰性，将信号平稳的传输给信道，采用基于多模态交叉注意力的信道编码模块对语义表征 $\mathbf{y}_t^{mv}$ 进行处理。

发送端的处理始于对视频序列的时空特征分析与压缩。对于一个 GoP，模型首先利用一个运动-外观特征提取器。该模块接收当前帧 $\mathbf{x}_t$ 与一个已编码的参考帧 $\mathbf{x}_0$ ，通过深度卷积网络并行捕捉帧间的动态运动信息与静态外观纹理。随后，一个运动估计模块对这些特征进行集成与分析，生成描述像素级位移的稠密运动矢量场 $\mathbf{m}_t$ 。为实现高效率的带宽利用，高维的运动矢量 $\mathbf{m}_t$ 被送入一个联合信源信道编码器。该编码器是一个深度神经网络，其作用在于执行非线性变换，将具有空间相关性的运动信息映射为一个低维、紧凑的潜在语义表征 $\mathbf{y}_t^{mv}$ 。此过程不仅移除了信源冗余，更将视频内容转换为一组有利于在噪声信道中传输和保护的特征形式。

多模态交叉注意力模块（Multimodal Cross-Attention Module, MCAM）摒弃了传统固定信道编码算法的思路，引入了基于无线信道环境语义感知的增强机制。该模块首先接收描述当前物理信道状态的文本信息 C_{text} ，如该信道是 AWGN，SNR=10 dB。并利用预训练的大型语言模型对该文本进行编码，提取出富含环境语义的嵌入向量 $\mathbf{P}_s$ 。随后，模块通过交叉注意力机制实现数据特征 $\mathbf{y}_t^{mv}$ 与语义嵌入 $\mathbf{P}_s$ 的交互，得到信道编码后的信号 $\tilde{\mathbf{y}}_t^{mv}$ ，MCAM 模块的处理过程可以表示为：

$$\tilde{\mathbf{y}}_t^{mv} = f_{\text{MCAM}}(\mathbf{y}_t^{mv}; \alpha), \quad (5-1)$$

其中 α 表示 MCAM 中的可学习参数。

为了使得信号满足带宽的要求，通过基于无网络的熵编码模块对 $\tilde{\mathbf{y}}_t^{mv}$ 进行编码得到 $\mathbf{s}_t^{mv}$ ，码字通过 AWGN 无线信道进行传输，得到含有噪声的信号 $\hat{\mathbf{s}}_t^{mv}$ ，该过程可以表述为：

$$\hat{\mathbf{s}}_t^{mv} = \mathbf{s}_t^{mv} + \mathbf{n}_t, \quad (5-2)$$

其中， $\mathbf{n}_t \sim \mathcal{N}(0, \sigma^2 \mathbf{I}_{k_t})$ 表示功率为 σ^2 的加性高斯白噪声向量。接收端最终接收的是受到噪声污染的信号 $\hat{\mathbf{s}}_t^{mv}$ 。

在接收端，系统首先对受损码字 $\hat{\mathbf{s}}_t^{mv}$ 进行预处理，通过填充等操作将其恢复至与发送端潜在特征 $\tilde{\mathbf{y}}_t^{mv}$ 相同的维度，得到估计值 $\check{\mathbf{y}}_t^{mv}$ 。该信号随后被馈入 JSCC 解码器。解码器作为编码器的逆变换，其目标是尽可能准确地从含噪特征中重建出原始的运动矢量，输出估计值 $\hat{\mathbf{m}}_t$ 。最后，在帧重建模块中，利用接收端已成功恢复的参考帧 $\hat{\mathbf{x}}_0$ 以及解码得到的运动矢量 $\hat{\mathbf{m}}_t$ ，通过运动补偿操作，最终合成出当前帧的恢复版本 $\hat{\mathbf{x}}_t$ ，完成整个视频通信流程。

5.2.1 多模态交叉注意力模块




图 5-2 MCAM 架构图

多模态交叉注意力模块的架构如图 5-2 所示，MCAM 模块的输入由两部分组成，原始特征序列 $\mathbf{y}_t^{mv} \in \mathbb{R}^{L \times C}$ 和用于描述信道环境信息的文本 C_{text} 。MCAM 首先利用预训练的 BERT^[61] 模型对文本 C_{text} 进行语义编码，随后通过线性投影层将其映射到视觉的特征空间，得到信道语义嵌入向量 $\mathbf{P}_s$ ，该过程可以表示为：

$$\mathbf{P}_s = \mathbf{W}_p \cdot \text{BERT}(S) + \mathbf{b}_p, \quad (5-3)$$

其中， $\mathbf{W}_p$ 和 $\mathbf{b}_p$ 分别表示投影层的权重矩阵和偏移项， $\text{BERT}(\cdot)$ 表示使用的预训练的大参数模型 BERT 对输入的信道文本信息进行处理，在模型训练过程中，冻结 BERT 模型的参数，训练投影层使得能将文本信息对齐到视觉特征。这一步骤实现了从离散文本语义到连续向量空间的跨模态对齐，以得到描述信道信息的语义表征向量。

语义导引的交互注意力机制在交互阶段，模块通过注意力机制将环境先验信息 $\mathbf{P}_s$ 注入 $\mathbf{y}_t^{mv}$ 中。具体而言，系统利用三个独立的线性变换层分别生成查询（Query, Q）、键（Key, K）和值（Value, V）的变体。注意力权重矩阵 $\mathbf{A}$ 的计算过程如下：

$$\mathbf{A} = \text{Softmax} \left(\frac{L_1(\mathbf{y}_t^{mv}) \cdot L_2(\mathbf{P}_s)^T}{\sqrt{d_k}} \right), \quad (5-4)$$

其中， $L_1(\cdot)$ 和 $L_2(\cdot)$ 分别表示处理视觉特征以及信道文本特征的线性层，分别得到对应的 Q 和 K， d_k 为视觉特征的维度。随后，通过矩阵乘法将权重应用于由语义信息生成的特征向量 $L_3(\mathbf{P}_s)$ ，实现特征的深度融合，这个计算过程是：

$$\mathbf{z} = \mathbf{A} \cdot L_3(\mathbf{P}_s), \quad (5-5)$$

其中 $L_3(\cdot)$ 是处理信道文本信息的线性层，得到计算过程的向量 V。受大模型缩放定律的启发^[60]，融合后的特征 $\mathbf{z}$ 进入逐令牌前馈网络（Per-token FFN, PFFN）进行局部精炼。对于序列中的每一个 token $\mathbf{z}_i$ ，其非线性变换过程可表示为：

$$\mathbf{f}_i = \text{MLP}_{ffn}(\mathbf{z}_i), \quad (5-6)$$

其中, $\text{MLP}_{ffn}(\cdot)$ 表示处理每个 token 的线性层。

为了在保留原始特征信息的同时实现自适应增强, 模块引入了基于动态系数 β 的残差连接。该系数由原始输入通过一个专门的 MLP 支路学习得到, 反映了模型对原始特征与增强特征之间权衡的自适应控制:

$$\beta = \sigma(\text{MLP}_{\beta}(\mathbf{y}_t^{mv})), \quad (5-7)$$

其中 σ 为 Sigmoid 激活函数, 确保增益系数处于合理区间。最终, 增强后的输出特征 $\tilde{\mathbf{y}}_t^{mv}$ 通过以下公式合成:

$$\tilde{\mathbf{y}}_t^{mv} = \beta \odot \mathbf{y}_t^{mv} + \mathbf{f}, \quad (5-8)$$

此处 $\odot$ 表示元素级乘法。动态残差结构使得模型能够在不同的 SNR 环境下, 通过调节 β 值来灵活控制特征补偿的强度。

5.3 仿真实验设置

5.3.1 数据集

在模型训练阶段, 本章采用 UCF101 数据集对提出的 MCAJSCCV 模型进行训练与验证。该数据集共包含 101 个动作类别的约 13,000 个视频片段, 按照 8:1:1 的比例将数据集随机分割为训练集、验证集和测试集, 以确保模型评估的可靠性。为构建模型输入, 本章采用 GoP 结构。具体而言, 从每个训练视频中采样得到多个由 6 个连续帧组成的子序列。所有帧均被统一缩放至 256×256 像素分辨率。在每个 GoP 中, 第一帧被指定为参考帧 $\mathbf{x}_0$, 其通过无损方式传输至接收端, 后续 5 帧则作为待编码的预测帧。

在模型评估部分, 本章进行了内部与外部两项测试。内部测试在 UCF101 自有测试集上进行, 以评估模型在已知分布数据上的性能。为进一步检验模型的泛化能力与鲁棒性, 额外在一个高分辨率视频数据集 BVI-DVC 上进行了外部评估。该数据集包含不同场景和运动复杂度的视频序列, 有助于全面分析模型在不同视觉内容与分辨率条件下的表现。

5.3.2 训练设置

本模型核心架构的参数设置秉承了设计的一致性与可比性原则。视频编码端的特征提取模块中, 外观特征被编码为维度为 $256 \times 16 \times 16$ 的张量, 旨在捕获帧内的纹理与结构信息; 运动特征则被编码为维度 $512 \times 16 \times 16$ 的张量, 以更充分

地建模帧间复杂的时空动态特性。其中，运动矢量估计通道数 C_M 设定为 128，以平衡运动场表示的精细度与模型计算复杂度。

在 MCAM 中，所提出的 PFFN 采用了并行化的设计，共使用 128 个独立的 MLP，对输入序列中的每个令牌进行细粒度的非线性变换与特征增强，此举显著提升了模型对信道状态的自适应容量。此外，为满足带宽约束并实现高效传输，基于神经网络的变长熵编码模块中的上下文特征维度 R 被设定为 48。该维度经过充分验证，能够在压缩效率与重构质量之间取得良好平衡。

表 5-1 信道文本描述的示例表

模型	MCAJSCCV	MCAJSCCV-C
信道的文本描述形式	信道是 AWGN 信道，SNR=10dB，发送端和接收端的距离 $d = 5$ 千米。	信道是 AWGN 信道。

MCAJSCCV 模型的训练过程以端到端方式进行，目的是优化接收端的视频重建质量。为了模拟真实无线通信环境中信噪比的动态变化，并使模型具备在多种信道条件下的鲁棒性能，信道的文本描述会随着训练过程不断改变。信道文本描述的形式如表 5-1 所示，在训练 MCAJSCCV 模型时，信道信息较为全面，信噪比在[1,13] dB 区间内进行均匀分布的随机采样，发送端和接收端的距离在[5,20]千米的区间内随机采样。在训练 MCAJSCCV-C 时，本章假设只能得知信道在 AWGN 信道中进行传输。优化算法选用 Adam 优化器，其初始学习率设置为 1×10^{-4} 。所有实验在一张 NVIDIA GeForce RTX 4090 GPU 的计算平台上进行。受到模型深度与复杂多模态注意力机制的限制，训练时的批次大小设置为 4。在这个实验设置下，MCAJSCCV 模型需要训练大约 1.5 周的时间才能够达到收敛。此资源配置与耗时情况为相关研究的复现提供了明确的参考基准。

5.3.3 对比方案与评估指标

为系统验证所提方法的有效性，本章将所构建的 MCAJSCCV 模型与两类代表性基线方案进行综合性能对比。第一类为基于分离设计的传统编码调制方案，该方案遵循香农定理的经典架构，分别独立优化信源编码与信道编码模块。具体而言，信源编码端采用广泛应用的视频编码标准 H.264 与 H.265；信道编码采用 LDPC，调制方式选用 BPSK 和 QPSK，以构成不同码率可靠性的组合。第二类为前沿的深度联合信源信道编码方案，包括 DeepWive、WITT 以及本课题组前期工作所提出的 AdaJSCCV 模型，此类方案旨在通过端到端训练探索超越分离定理的编码增益。

此外，为了探究信道状态信息粒度对自适应性能的影响，本章引入一个模型变体 MCAJSCCV-C。该变体在信道信息不完全精确的场景下，利用本章提出的

文本描述方法对信道进行粗粒度表征,在信道信息完全精确时,可以采用具体的信道信息进行描述,例如:“当前信道是 AWGN 信道, SNR=10dB, 信道快速波动, 主要受多径效应和突发干扰影响, 需优先保障关键预警画面的低延迟高清传输”。而当信道信息不完全精确时,可以采用“当前信道是 AWGN 信道”进行信道的描述。通过在信道信息不完全精确的场景进行实验,以分析与对比不同精细化程度的信道感知对最终重建质量的作用机制。

传统方法使用单一的 SNR 值表征信道状态,这种方法仅能告知信号与噪声的功率比值,无法表征信道的波动情况、干扰类型、业务需求等。而使用信道的文本描述不仅可以包含 SNR 的范围,还可以解释信道的动态特性、业务意图等多维的信道信息。




图 5-3 在 AWGN 信道下, CBR = 0.031 时, MCAJSCCV 在 UCF101 数据集上测得的失真性能随信噪比变化曲线图

为客观、全面地量化视频重建质量,本章实验从像素级数值保真度与人类视觉感知保真度两个互补维度构建评估体系。具体采用 PSNR 作为数值保真度的客观指标,采用 MS-SSIM 作为感知保真度的衡量标准,同时采用 LPIPS 作为主观质量的评价指标。三者结合,共同构成评估视频传输系统性能的综合质量度量。

5.4 结果性能分析

图 5-3、图 5-4 给出了在 AWGN 信道环境下, MCAJSCCV 方法与其他对比方案在 UCF101 与 BVI-DVC 数据集上 PSNR 与 MS-SSIM 随信噪比变化的性能曲线。图 5-3(a)是 MCAJSCCV 在 UCF101 数据集上 PSNR 随 SNR 变化曲线图, 图 5-3(b)是 MCAJSCCV 在 UCF101 数据集上 MS-SSIM 随 SNR 变化曲线图。图 5-4(a)MCAJSCCV 在 BVI-DVC 数据集上 PSNR 随 SNR 变化曲线图, 图 5-4(b)是 MCAJSCCV 在 BVI-DVC 数据集上 MS-SSIM 随 SNR 变化曲线图。对于基于传统分离的 H.264 和 H.265 的视频传输方法, 测试了不同的调制方式和信道编码率配置, 得到了相对完整的结果。结果表明所提出的 MCAJSCCV 在客观质量指标 PSNR、MS-SSIM 和主观视觉质量方面都强于分离方案、基于深度学习的 WITT 方法和第三章所提出的 AdaJSCCV, 并且在低信噪比恶劣信道下具有相对的鲁棒性。在信噪比为 4dB 时, MCAJSCCV 比基于 H.264 的编码方案分别在 UCF101 与 BVI-DVC 上 PSNR 提高了 6.8 dB 和 8.8 dB。

同时, 在 PSNR 上 MCAJSCCV 比 AdaJSCCV 要优, 并且在 MS-SSIM 上表现更好。在信道条件较差的情况下, 这种情况尤其能表现出来, 在 UCF101 数据集上这个情况尤其明显。例如, 在 SNR=0 dB 的情况下, 在 UCF101 测试集上, MCAJSCCV 的 PSNR 比 AdaJSCCV 高出 4.1 dB。

值得注意的是, 即使 MCAJSCCV-C 模型采用了不精确的信道状态信息提示机制, 其性能仍然始终优于所有传统分离式编码方案。这表明, 即使在不精确的信道信息条件下, 本章所设计的自适应机制依然具备显著的有效性。另外, MCAJSCCV 模型采用了更加详细的信道文本描述信息, 使其性能优于 AdaJSCCV 模型。

图 5-5 以可视化方式对比了在相同传输条件下不同方案的重建效果。图中子标题标注了对应方案的 PSNR(dB)/MS-SSIM 数值。H.264 与 H.265 方案采用码率为 1/2 的 LDPC 信道编码与 QPSK 调制。本图展示了在 AWGN 信道、CBR = 0.031、SNR=4dB 的情况下, 各方案的重建结果进行可视化对比。从主观视觉效果来看, 传统 H.264/H.265 恢复的视频帧较为模糊, 并且高频信息在纹理复杂度较高的区域及面部细节部位丢失严重; 而没有 MCAM 的 MCAJSCCV 模型可以保持一定的结构轮廓, 但重建图像中出现了块效应与随机噪声, 视觉一致性较差。完整的 MCAJSCCV 模型在保持图像清晰的同时, 在避免图像产生伪影、噪声的同时, 能够使纹理细节更真实、自然的再现, 这方面体现在人物的面部部分更为明显, MCAJSCCV 模型可以更好地还原皮肤的色泽变化, 五官的形态以及细微

的表情特征。AdaJSCCV 模型虽然取得了较好的重建效果，但是头发区域依旧存在较多的不足。




图 5-4 在 AWGN 信道下， $\text{CBR} = 0.031$ 时，MCAJSCCV 在 BVI-DVC 数据集上测得的失真性能随信噪比变化曲线图

图 5-6 展示了不同模型的主观质量的差异，结果表明 MCAJSCCV 和 MCAJSCCV-C 具有相当的性能，并且性能明显优于 AdaJSCCV 模型和 WITT 模型，展示出了多模态交叉注意力模块的有效性。

表 5-2 为 UCF101 数据集、AWGN 信道、信噪比为 10dB 稳定传输下，所提 MCAJSCCV 模型及其两种消融变体的性能和效率对比。从数据上可以看出完整的 MCAJSCCV 具有最好的重建质量，其 PSNR 为 38.24 dB，MS-SSIM 为 0.993，远优于没有 MCAM 及没有 PFFN 的模型。上面的数据说明了所提模型核心组件的有效性，MCAM 模块将视觉信息与信道状态信息进行融合，提高了编码的鲁棒性、适应性。同时，PFFN 模块提升了视频帧复杂的时空特征的建模与重建能力。

然而，性能的提升伴随着计算复杂度的增加。在模型参数量方面，完整模型达到 110.57M，其中 MCAM 模块引入了主要的参数增量，这体现了其为捕获动态信道状态所设计的复杂结构。在推理效率上，完整模型的单帧处理时间为 45.91

ms，低于未集成 PFFN 版本但高于高度简化的未集成 MCAM 版本。这一结果揭示了一个关键的权衡：未集成 MCAM 模型虽具有最快的推理速度和最少的参数量，但其重建质量下降最为明显；未集成 PFFN 模型在参数量与完整模型相近的情况下，因结构简化导致了推理速度与重建质量的双重折中。




图 5-5 视觉对比示例图




图 5-6 不同模型 LPIPS 指标随 SNR 变化曲线图

表 5-2 在 UCF101 数据集、AWGN 信道且 SNR=10dB 的条件下，各方案的参数量与推理时间对比表

模型	PSNR(dB)	MS-SSIM	CBR	推理时间(ms)	Params (M)
MCAJSCCV	38.24	0.993	0.031	45.91	110.57
w/o MCAM	37.20	0.990	0.031	28.69	20.55
w/o PFFN	37.52	0.991	0.031	35.79	106.36

5.5 本章总结

本章提出了一种深度联合信源信道编码模型 MCAJSCCV，以实现信道与内容自适应的无线视频语义通信。本章设计了多模态交叉注意力模块，首先使用预训练的 BERT 对信道描述文本进行编码，然后将其映射到视觉特征领域，进而将信道语义信息与视觉特征进行融合，提高了模型的抗干扰能力。实验结果表明，MCAJSCCV 在重建质量与鲁棒性方面均优于传统的无线视频通信方案及其他深度联合信源信道编码方法，有效验证了所提出的多模态交叉注意力模块的有效性。

第六章 总结与展望

6.1 总结




图 6-1 研究内容总结图

本文聚焦于无线视频语义通信中的核心挑战——动态信道适应性问题，旨在提升系统在复杂多变无线环境下的重建质量与传输鲁棒性。传统通信系统将信源与信道编码分离，难以实现语义层面的联合优化与信道自适应。为此，本文从深度联合信源信道编码框架出发，围绕信道与内容自适应这一主线，展开了三项递进式的研究工作，如图 6-1 所示，主要贡献总结如下：

（1）针对通用简单时变信道与码率控制问题，提出了 AdaJSCCV 模型。本研究点构建了一个基础的深度联合信源信道编码框架，其核心创新在于设计了动态信道自适应模块，能够显式地建模并融合时变物理信道噪声与视频语义信息，从而实现了对于多样化信道条件的初步自适应能力。同时，引入了一种低复杂度的基于无网络熵模型的变分编码机制，实现了对输出码长的精确、灵活控制，在保证性能的前提下提升了系统的实用性。实验表明，该模型在重建质量与鲁棒性上均超越了传统分离式方案及同期深度联合编码方法。

（2）针对多天线 MIMO 信道特性，提出了 SAWV-MIMO 模型。本研究点将信道自适应研究深化至空间维度丰富的 MIMO 场景。通过设计 MIMO 信道语义信息提取模块，系统性地从信道状态信息及接收信号的空间、特征维度中提取与语义相关的信道表征，实现了语义信息与 MIMO 信道空时特性的深度融合。此外，针对实际系统中不可避免的非理想信道估计，专门设计了信道去噪模块，

有效提升了信道先验信息的可靠性。实验验证了该模型在多种 MIMO 信道条件与码率配置下均具有卓越且稳定的性能。

(3) 探索多模态信息融合增强信道自适应, 提出了 MCAJSCCV 模型。本研究点突破了仅依赖物理层信道信息的局限, 创新性地引入文本模态作为信道条件的补充描述。通过设计多模态交叉注意力模块, 利用预训练语言模型 BERT 编码信道描述文本, 并将其语义与视觉特征进行对齐与深度融合, 使系统能够理解并适应更抽象、更高维的“语义信道”变化。该方法为利用先验知识或用户反馈增强通信系统智能性提供了新思路, 实验证明了其显著的性能增益。

本文通过三项研究工作, 由基础信道到复杂信道, 由单模态到多模态, 逐步构建并深化了视频语义通信中的信道自适应技术体系。从 AdaJSCCV 的通用动态自适应与码率控制, 到 SAWV-MIMO 面向 MIMO 信道的空时语义融合, 再到 MCAJSCCV 利用多模态信息的增强自适应, 层层递进地提升了系统对复杂、动态、非理想无线环境的智能感知与鲁棒传输能力。

本文提出的算法体系可直接运行在无线视频通信系统的发送端和接收端, 作为视频语义通信的编解码器, 实现对信道状态及多模态的感知和融合, 实现语义的动态自适应编码和视频的鲁棒传输。具体应用部署可以在以下场景:

(1) 通用自适应编码模型 AdaJSCCV: 支持将 AdaJSCCV 应用于无人机巡检、车载视频回传等信道时变较大的边缘设备中, 通过感知和融合物理层信噪比, 实现在有限带宽下视频重建的清晰度和稳定性。

(2) 针对高维 MIMO 信道的视频传输模型 SAWV-MIMO: 针对 5G 和 6G 基站和用户终端之间的多天线视频通信, 将高维 MIMO 通信通过空时语义融合和信道去噪, 充分利用 MIMO 信道容量, 实现蜂窝网络中超高清视频流的高鲁棒传输和低延迟。

(3) 信道知识增强自适应的视频传输模型 MCAJSCCV: 适用于对信道具有先验知识或可文本描述的专业信道, 如卫星通信, 通过融合文本指令使系统能够智能预判、适应复杂的视频通信场景, 大幅提升在极端或非理想环境下的传输成功率和视觉质量。

6.2 展望

尽管本文视频语义通信的信道自适应得到了一定程度的进步, 但仍处于发展的快车道上, 后续可从以下方面进行深入的研究:

(1) 计算和部署优化问题: 本文模型特别是涉及多模态融合或复杂注意力机制的模型, 其计算复杂度较高, 可进一步加强模型的轻量化、知识蒸馏或设计具有通信场景相适应的有效神经网络, 以满足终端设备或时延敏感的应用需求。

(2) 多模态融合的扩展与深化: MCAJSCCV 初步验证了文本-视觉融合的可能性,可进一步开发多元模态(音频、传感器数据、知识图谱)的引入,探索更有效、更灵活的跨模态对齐和融合机制,以提供对通信环境和用户意图理解更为深入的通信系统。

(3) 面向复杂场景和跨层优化:将该课题扩展到更复杂的实际通信场景(超高速移动、大规模用户接入、异构网络融合等),探索语义通信与网络协议其他层次(资源分配、路由、拥塞控制等)的跨层优化,进而从语义感知升级到语义使能。

(4) 安全和隐私问题:语义通信高度压缩传输核心语义,可能引发新的安全与隐私问题,例如语义信息被恶意窃取或篡改。未来研究面向语义通信的加密、认证、隐私保护机制。

参考文献

- [1] Giordani M, Polese M, Mezzavilla M, et al. Toward 6G networks: Use cases and technologies[J]. IEEE communications magazine, 2020, 58(3): 55-61.
- [2] Luo X, Chen H H, Guo Q. Semantic communications: Overview, open issues, and future research directions[J]. IEEE Wireless Communications, 2022, 29(1): 210-219.
- [3] 赵亚军, 郁光辉, 徐汉青. 6G 移动通信网络: 愿景, 挑战与关键技术[J]. 中国科学: 信息科学, 2019, 49(8): 963-987.
- [4] Nalewajski R F. Elements of information theory[M]//Perspectives in Electronic Structure Theory. Berlin, Heidelberg: Springer Berlin Heidelberg, 2011: 371-395.
- [5] Gündüz D, Qin Z, Aguerri I E, et al. Beyond transmitting bits: Context, semantics, and task-oriented communications[J]. IEEE Journal on Selected Areas in Communications, 2022, 41(1): 5-41.
- [6] Weaver W. Recent contributions to the mathematical theory of communication[J]. ETC: a review of general semantics, 2017, 74(1/2): 136-157.
- [7] Dai J, Zhang P, Niu K, et al. Communication beyond transmitting bits: Semantics-guided source and channel coding[J]. IEEE Wireless Communications, 2022, 30(4): 170-177.
- [8] Kountouris M, Pappas N. Semantics-empowered communication for networked intelligent systems[J]. IEEE Communications Magazine, 2021, 59(6): 96-102.
- [9] Wiegand T, Sullivan G J, Bjontegaard G, et al. Overview of the H. 264/AVC video coding standard[J]. IEEE Transactions on circuits and systems for video technology, 2003, 13(7): 560-576.
- [10] Ohm J R, Sullivan G J. High efficiency video coding: the next frontier in video compression [standards in a nutshell][J]. IEEE Signal Processing Magazine, 2012, 30(1): 152-158.
- [11] Richardson T, Kudekar S. Design of low-density parity check codes for 5G new radio[J]. IEEE Communications Magazine, 2018, 56(3): 28-34.
- [12] Peng X, Qin Z, Tao X, et al. A robust semantic text communication system[J]. IEEE Transactions on Wireless Communications, 2024, 23(9): 11372-11385.
- [13] Yang K, Wang S, Dai J, et al. WITT: A wireless image transmission transformer for semantic communications[C]//ICASSP 2023-2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). IEEE, 2023: 1-5.
- [14] Xie H, Qin Z, Li G Y, et al. Deep learning enabled semantic communication systems[J]. IEEE Transactions on Signal Processing, 2021, 69: 2663-2675.

- [15] Tung T Y, Gündüz D. DeepWiVe: Deep-learning-aided wireless video transmission[J]. IEEE Journal on Selected Areas in Communications, 2022, 40(9): 2570-2583.
- [16] Mnih V, Kavukcuoglu K, Silver D, et al. Human-level control through deep reinforcement learning[J]. nature, 2015, 518(7540): 529-533.
- [17] Wang S, Dai J, Liang Z, et al. Wireless deep video semantic transmission[J]. IEEE Journal on Selected Areas in Communications, 2022, 41(1): 214-229.
- [18] Bao Z, Liang H, Dong C, et al. Mdvsc—wireless model division video semantic communication for 6g[C]//2023 IEEE Globecom Workshops (GC Wkshps). IEEE, 2023: 1572-1578.
- [19] Gong W, Tong H, Wang S, et al. Adaptive bitrate video semantic communication over wireless networks[C]//2023 International Conference on Wireless Communications and Signal Processing (WCSP). IEEE, 2023: 122-127.
- [20] Liu Z, Lin Y, Cao Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF international conference on computer vision. 2021: 10012-10022.
- [21] Konda V, Tsitsiklis J. Actor-critic algorithms[J]. Advances in neural information processing systems, 1999, 12.
- [22] Keller T, Hanzo L. Adaptive modulation techniques for duplex OFDM transmission[J]. IEEE Transactions on Vehicular Technology, 2002, 49(5): 1893-1906.
- [23] Xu J, Ai B, Chen W, et al. Wireless image transmission using deep source channel coding with attention modules[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2021, 32(4): 2315-2328.
- [24] Niu H, Wang L, Lu Z, et al. Deep Learning Enabled Video Semantic Transmission Against Multi-Dimensional Noise[C]//2023 IEEE Globecom Workshops (GC Wkshps). IEEE, 2023: 1267-1272.
- [25] Woo S, Park J, Lee J Y, et al. Cbam: Convolutional block attention module[C]//Proceedings of the European conference on computer vision (ECCV). 2018: 3-19.
- [26] Xie B, Wu Y, Shi Y, et al. Robust Image Semantic Coding with Learnable CSI Fusion Masking over MIMO Fading Channels[J]. arXiv preprint arXiv:2406.07389, 2024.
- [27] Wu H, Shao Y, Bian C, et al. Vision transformer for adaptive image transmission over MIMO channels[C]//ICC 2023-IEEE International Conference on Communications. IEEE, 2023: 3702-3707.
- [28] Dosovitskiy A, Beyer L, Kolesnikov A, et al. An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale[C]//International Conference on Learning Representations.

- 2020.
- [29] Wang Y, Gao Z, Zheng D, et al. Transformer-empowered 6G intelligent networks: From massive MIMO processing to semantic communication[J]. IEEE Wireless Communications, 2022, 30(6): 127-135.
 - [30] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need[J]. Advances in neural information processing systems, 2017, 30.
 - [31] Liu Z , Chen X , Wu H ,et al.Integrated Sensing and Edge AI: Realizing Intelligent Perception in 6G[J].IEEE Communications Surveys & Tutorials, 2026, 28: 2725-2770. DOI: 10.1109/COMST.2025.3592989.
 - [32] Liu P, Zhu G, Wang S, et al. Toward ambient intelligence: Federated edge learning with task-oriented sensing, computation, and communication integration[J]. IEEE journal of selected topics in signal processing, 2022, 17(1): 158-172.
 - [33] LeCun Y, Bottou L, Bengio Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 2002, 86(11): 2278-2324.
 - [34] Ioffe S, Szegedy C. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]//International conference on machine learning. pmlr, 2015: 448-456.
 - [35] Srivastava N, Hinton G, Krizhevsky A, et al. Dropout: a simple way to prevent neural networks from overfitting[J]. The journal of machine learning research, 2014, 15(1): 1929-1958.
 - [36] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25.
 - [37] Simonyan K, Zisserman A. Very deep convolutional networks for large-scale image recognition[J]. arXiv preprint arXiv:1409.1556, 2014.
 - [38] He K, Zhang X, Ren S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 770-778.
 - [39] Howard A G, Zhu M, Chen B, et al. Mobilenets: Efficient convolutional neural networks for mobile vision applications[J]. arXiv preprint arXiv:1704.04861, 2017.
 - [40] Medsker L R, Jain L. Recurrent neural networks[J]. Design and applications, 2001, 5(64-67): 2.
 - [41] Bertasius G, Wang H, Torresani L. Is space-time attention all you need for video understanding?[C]//Icml. 2021, 2(3): 4.
 - [42] 万帅 霍俊彦 马彦卓 杨付正.新一代通用视频编码标准 H.266/VVC:现状与发展[J].西安交通大学学报, 2024(004):058.DOI:10.7652/xjtuxb202404001.
 - [43] ELIAS P. List Decoding for Noisy Channels[C]//IRE WESCON Convention Record, 1957. 1957, 2: 94-104.

- [44] Berrou C, Glavieux A, Thitimajshima P. Near Shannon limit error-correcting coding and decoding: Turbo-codes. 1[C]//Proceedings of ICC'93-IEEE International Conference on Communications. IEEE, 1993, 2: 1064-1070.
- [45] Gallager R. Low-density parity-check codes[J]. IRE Transactions on information theory, 2003, 8(1): 21-28.
- [46] Arikan E. Channel polarization: A method for constructing capacity-achieving codes for symmetric binary-input memoryless channels[J]. IEEE Transactions on information Theory, 2009, 55(7): 3051-3073.
- [47] Jähne B. Digital image processing[M]. Berlin, Heidelberg: Springer Berlin Heidelberg, 2005.
- [48] Wang Z, Simoncelli E P, Bovik A C. Multiscale structural similarity for image quality assessment[C]//The thirty-seventh asilomar conference on signals, systems & computers, 2003. Ieee, 2003, 2: 1398-1402.
- [49] Wang Z, Bovik A C, Sheikh H R, et al. Image quality assessment: from error visibility to structural similarity[J]. IEEE transactions on image processing, 2004, 13(4): 600-612.
- [50] Li J, Li B, Lu Y. Deep contextual video compression[J]. Advances in Neural Information Processing Systems, 2021, 34: 18114-18125.
- [51] Soomro K, Zamir A R, Shah M. Ucf101: A dataset of 101 human actions classes from videos in the wild[J]. arXiv preprint arXiv:1212.0402, 2012.
- [52] Ma D, Zhang F, Bull D R. BVI-DVC: A training database for deep video compression[J]. IEEE Transactions on Multimedia, 2021, 24: 3847-3858.
- [53] Adam K D P B J. A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014, 1412(6).
- [54] Wu M, Gao Z, Wang Z, et al. Deep joint semantic coding and beamforming for near-space airship-borne massive MIMO network[J]. IEEE Journal on Selected Areas in Communications, 2024, 43(1): 260-278.
- [55] Tong W, Zhiyong C, Meixia T, et al. Multi-user semantic fusion for semantic communications over degraded broadcast channels[J]. China Communications, 2024, 21(10): 1-15.
- [56] Ronneberger O, Fischer P, Brox T. U-net: Convolutional networks for biomedical image segmentation[C]//International Conference on Medical image computing and computer-assisted intervention. Cham: Springer international publishing, 2015: 234-241.
- [57] Zhang G, Zhu Y, Wang H, et al. Extracting motion and appearance via inter-frame attention for efficient video frame interpolation[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 5682-5692.
- [58] Tian R, Wu Z, Dai Q, et al. Resformer: Scaling vits with multi-resolution

- training[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 22721-22731.
- [59] Ba J L, Kiros J R, Hinton G E. Layer normalization[J]. arXiv preprint arXiv:1607.06450, 2016.
- [60] Zhu J, Fan Z, Zhu X, et al. Rankmixer: Scaling up ranking models in industrial recommenders[C]//Proceedings of the 34th ACM International Conference on Information and Knowledge Management. 2025: 6309-6316.
- [61] Devlin J, Chang M W, Lee K, et al. Bert: Pre-training of deep bidirectional transformers for language understanding[C]//Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers). 2019: 4171-4186.

缩略词

缩写	英文全称	中文名称
XR	Extended Reality	扩展现实
MTC	Machine-Type Communication	面向机器类通信
SNR	Signal-to-Noise Ratio	信噪比
QoE	Quality of Experience	体验质量
SemCom	Semantic Communication,	语义通信
DeepJSCC	Deep Joint Source-Channel Coding	深度信源信道联合编码
AWGN	Additive White Gaussian Noise	加性高斯白噪声信道
MIMO	Multiple-Input Multiple-Output	多入多出
VVC	Versatile Video Coding	多功能视频编码
FEC	Forward Error Correction	前向纠错
LDPC	Low-Density Parity-Check	低密度奇偶校验码
DNN	Deep Neural Network	深度神经网络
RL	Reinforcement Learning,	强化学习
CSI	Channel State Information	信道状态信息
ViT	Vision Transformer	视觉变换器
OFDM	Orthogonal Frequency Division Multiplexing	正交频分复用
AdaJSCCV	Adaptive Deep Joint Source-Channel Coding for Wireless Video Transmission	深度联合信源信道的信道自适应视频编码模型
SAWV-MIMO	Semantic-Aware Adaptive Wireless Video Transmission over MIMO Channels	MIMO 信道的深度联合信源信道编码模型
MCAJSCCV	Multimodal Cross-Attention for Channel- Adaptive Video Transmission	多模态交叉注意力的自适应视频传输模型
CNN	Convolutional Neural Network	卷积神经网络
NLP	Natural Language Processing	自然语言处理
MSA	Multi-Head Self-Attention	多头自注意力
FFN	Feed-Forward Network	前馈神经网络
BCJR	Bahl-Cocke-Jelinek-Raviv	最大后验概率
BP	Belief Propagation	置信传递
SC	Successive Cancellation	连续消除译码
SCL	Successive Cancellation List	带序列的连续消除译码
CAVLC	Context-Adaptive Variable Length Coding	上下文自适应可变长编码
QP	Quantization Parameter	量化参数
GoP	Group of Pictures	图像组
JSCC	Joint Source-Channel Coding	联合信源信道编码

PSNR	Peak Signal-to-Noise Ratio	峰值信噪比
MSE	Mean Squared Error	均方误差
Multi-Scale		
Structural Similarity	MS-SSIM	多尺度结构相似性指数
Structural Similarity	SSIM	结构相似性指数
FLOPs	Floating Point Operations Per Second	浮点运算次数
CSEM	Channel Semantic Extraction Module	信道语义提取模块
DCAM	Dynamic Channel Adaptation Module	动态信道自适应模块
FAM	Feature Adujstment Module	特征调整模块
CBR	Channel Bandwidth Ratio	信道带宽比
MLP	Multilayer Perceptron	多层感知器
FAC	Feature Adaptive Convolutional module	特征自适应卷积层
GDN	Generalized Divisive Normalization	广义除法归一化
IGDN	Inverse Generalized Divisive Normalization	逆广义除法归一化
ResBlock	Residual Block	残差块
BPSK	Binary Phase Shift Keying	二进制相移键控
QPSK	Quadrature Phase Shift Keying	正交相移键控
SISO	Single Input, Single Output	单输入单输出
SAWV-MIMO	Semantic-Aware Adaptive Wireless Video Transmission over MIMO Channels	面向 MIMO 信道的语义感知自适应无线视频传输
CSEM-MIMO	Channel Semantic Extraction Module for MIMO	MIMO 信道语义提取模块
CDM	Channel Denoising Module	信道去噪模块
FRM	Frame Reconstruction Module	帧重建模块
AM	Attention Module	注意力模块
FDAM	Feature Dimension Attention Module	特征维度注意力模块
SAM	Spatial Attention Module	空间注意力模块
MCAJSCCV	Multimodal Cross-Attention for Channel-Adaptive Video Transmission	多模态交叉注意力机制的信道自适应视频传输框架
MCAM	Multimodal Cross-Attention Module	多模态交叉注意力模块
PFFN	Per-token FFN	逐令牌前馈网络

致谢

三年时间，如白驹过隙，转眼走到求学之路的最终章。回首这段在北京邮电大学的岁月，百感交集，心中充满了感激。

首先，感谢我的导师黄丹蓝教授。从研究内容的选择、模型构建，到帮我反复修改小论文以及大论文的完成，每一个环节都倾注了您大量的心血。您严谨的治学态度、深厚的学术造诣与敏锐的洞察力，不仅为我的研究指明了方向，更深刻地影响了我看待问题的方式。感谢您在学业上的悉心指导，亦感谢您在生活与人生规划上给予的宝贵建议，使我受益终生。

感谢组内师兄、师姐以及科研楼 204 的同学在日常生活钟的温暖陪伴，那些共同探讨、相互鼓励的日子，是我求学生涯中无比珍贵的记忆。

感谢我的父母与挚爱的家人。你们是最坚实的后盾，二十余载无私的奉献、全力的支持与无条件的信任，是我面对一切挑战时最大的勇气来源。你们的爱与包容，是我前行路上不竭的动力。

最后，感谢一直坚持、未曾放弃的自己。感谢这段旅程中所有的收获、迷茫、顿悟与成长。学海无涯，研究生学习的结束是另一个新征程的开始。我将怀揣所有的感恩，继续前行。

前路虽远，愿赤忱永在心间，远征星辰大海，归来仍是少年，以滚烫年华，这一世满腔热烈，愿千帆过境，仍是此间青年，愿青年如画，不负年华，胸怀青年志，不忘赤子心，青春正向上，梦想有光芒！

攻读学位期间发表的学术论文目录

已录用以及中搞文章:

1. Qi Z, Huang D, Zhou X, et al. Semantic-Aware Adaptive Wireless Video Transmission over MIMO Channels, // the 3rd International Conference on Networks, Communications and Intelligent Computing (NCIC), 2025.
2. Huang D, Qi Z, Zhou X, et al. AdaJSCCV: Adaptive Prompt-Tuning for Semantic Video Transmission //2026 IEEE Wireless Communications and Networking Conference (WCNC).
3. Zhou X, Huang D, Qi Z, et al. Efficient Wireless Video Transmission via Adaptive Spatio-Temporal Token Merging[C], //2025 IEEE Global Communications Conference (GLOBECOM), IEEE, 2025.
4. Zhou X, Huang D, Qi Z, et al. A Multi-Scale Spatial-Temporal Network for Wireless Video Transmission[C]//2024 IEEE Globecom Workshops (GC Wkshps). Cape Town, South Africa: IEEE, 2024: 1-6. doi: 10.1109/GCWkshp64532.2024.11100995.
5. Zhou X, Huang D, Qi Z, et al. ST-VJSCC: Spatio-Temporal Video DeepJSCC Scheme for Adaptive Wireless Transmission //IEEE Transactions on Cognitive Communications and Networking.

作者学习经历

起止年月	类别	学习单位名称	学科/专业名称
2016.9-2019.7	高中	齐河县第一中学	
2019.9-2023.7	本科	中国石油大学（华东）	通信工程
2023.9-2026.7	硕士	北京邮电大学	信息与通信工程