密级：公开

北京郵電大學

X 士学位论文（XX 学位）

题目：

基于低成本无人机平台的非法低轨卫星终端定位识别算法研究

学　　号：20XXXXXXXX

姓　　名：匿名作者

学科专业：通信工程

学习方式：全日制

导　　师：匿名导师

学　　院：信息与通信工程学院

2026 年 3 月 11 日

BEIJING UNIVERSITY OF POSTS AND TELECOMMUNICATIONS

Anonymous Degree Thesis

Research on Localization and Identification Algorithms for Illega

Student ID: 20XXXXXXXX

Author: Anonymous Student

Subject: Communication Engineering

Supervisor: Anonymous Supervisor

Institute: School of Information and Communication Engineering

Date 11 Month 3 Year 2026

答辩委员会名单

职务	姓　名	职　称	工　作　单　位
主席			
委员			
委员			
委员			
委员			
秘书			
答辩日期	2026 年 3 月 11 日		

摘 要

北京邮电大学研究生学位论文 LaTeX 模板

关键词：LaTeX 模板；北京邮电大学；研究生学位论文

ABSTRACT

LaTeX Template

KEY WORDS: LaTeXTemplate; BUPT; PhD Dissertation

目 录

摘 要 I
ABSTRACT II
第一章 绪论 1
1.1 研究背景与意义 1
1.1.1 天地一体化网络与低轨卫星通信发展现状 1
1.1.2 复杂城市环境下非法终端安全威胁与排查需求 1
1.1.3 低成本无人机平台在频谱感知与定位中的应用优势 1
1.2 国内外研究现状 1
1.2.1 非法低轨卫星终端监测与定位研究现状 1
1.2.2 传统测距与谱估计定位研究现状 1
1.2.3 多源异构信息融合与强化学习定位研究现状 1
1.2.4 多目标无线定位与跨模态检测研究现状 1
1.2.5 复杂环境传播建模与无线电地图研究现状 1
1.3 现有研究存在的主要问题 1
1.4 本文主要研究内容 1
1.5 本文主要创新点 1
1.6 论文结构安排 1
第二章 低成本无人机定位系统模型与定位理论基础 2
2.1 系统任务场景与总体架构 2
2.1.1 非法低轨卫星终端排查任务描述 2
2.1.2 低成本无人机平台组成与数据处理链路 3
2.2 复杂城市环境下的低轨卫星传播机理 4
2.2.1 Ku/Ka 波段星地链路传播特性 4
2.2.2 城市峡谷效应与非视距传播机理 5
2.2.3 多径效应、时延扩展与信号衰落机制 5
2.3 低轨卫星系统背景与典型信号体制说明 6
2.3.1 Starlink 系统与星地链路基本特征 6
2.3.2 本文研究对象与典型体制的关系说明 7
2.4 经典定位观测量与定位模型 7
2.4.1 RSSI 定位模型与误差来源 8
2.4.2 AoA 定位模型与几何约束关系 8

2.4.3 TOA 定位模型与同步误差分析 9
2.4.4 TDOA 定位模型与双曲线定位机理 10
2.5 基于多观测量的定位性能分析基础 10
2.5.1 统一观测模型与误差传播关系 10
2.5.2 克拉美罗下界分析基础 11
2.5.3 几何精度因子分析基础 11
2.5.4 多观测量方法的适用场景比较 12
2.6 本章小结 12
第三章 基于物理感知深度强化学习的单目标自适应融合定位方法 13
3.1 问题描述与总体框架 13
3.1.1 单目标定位任务定义与场景约束 13
3.1.2 多源异构定位信息加权融合模型 13
3.1.3 面向动态信道的马尔可夫决策过程建模 14
3.2 复杂环境观测构造与物理先验信息提取 16
3.2.1 射线追踪场景建模与环境先验获取 16
3.2.2 多源观测量生成与特征表达 17
3.2.3 RMS 时延扩展与几何一致性特征构造 18
3.3 基于 Q-Learning 的 RL-IFA 基线自适应融合算法 19
3.3.1 状态空间设计 19
3.3.2 动作空间设计 20
3.3.3 奖励函数设计 21
3.3.4 权重更新机制 22
3.4 融合物理先验知识的 PA-DQN 智能体设计 24
3.4.1 物理感知状态空间设计 25
3.4.2 抑制轨迹锯齿的增量式连续动作空间设计 26
3.4.3 兼顾短时抗扰与长时纠偏的奖励函数设计 27
3.4.4 物理感知深度 Q 网络结构设计 28
3.5 实验结果分析 29
3.5.1 实验设置 29
3.5.2 总体性能比较 30
3.5.3 典型轨迹结果分析 32
3.5.4 不同信噪比条件下的鲁棒性分析 32
3.5.5 消融实验分析 33
3.5.6 本节小结 35

3.5.7 不同信噪比条件下的鲁棒性分析 35
3.5.8 消融实验分析 35
3.5.9 本节小结 36
第四章 基于无人机信号成像与跨模态视觉检测的多目标并发定位方法 37
4.1 基于无人机空间扫描的多目标定位问题描述与信号成像建模 37
4.1.1 多目标并发定位场景与任务定义 37
4.1.2 无人机稀疏采样、噪声扰动与局部多峰问题分析 38
4.1.3 多径鬼影干扰下传统峰值判定方法的局限性 40
4.1.4 基于射线追踪的复杂城市传播场建模 41
4.1.5 无人机 RSSI 空间映射与高斯重构方法 42
4.1.6 从离散观测到信号成像的跨模态建模思路 44
4.2 面向多目标定位的 Radio Map 重构方法 46
4.2.1 基于射线追踪的复杂城市传播场建模 46
4.2.2 基于空间扫描观测的 RSSI 栅格映射方法 48
4.2.3 OSM 场景建模与 MATLAB 工具链实现 49
4.3 基于知识蒸馏的鲁棒多无人机协同多目标定位方法 51
4.3.1 多无人机掉点场景下的协同定位背景与问题引入 51
4.3.2 知识蒸馏基本原理与掉点鲁棒定位建模 52
4.3.3 教师—学生网络架构设计 55
4.4 实验结果与分析 57
4.4.1 实验设置 57
4.4.2 结果与分析 59
4.5 本章小结 64
第五章 结论与展望 65
5.1 全文工作总结 65
5.2 主要研究结论 66
5.3 后续研究展望 67
参考文献 69
附 录 70
攻读学位期间发表的创新成果目录 71

符号说明

符　号	代表意义	单　位
A	截面积	m^2

第一章　绪论

1.1　研究背景与意义

1.1.1　天地一体化网络与低轨卫星通信发展现状

1.1.2　复杂城市环境下非法终端安全威胁与排查需求

1.1.3　低成本无人机平台在频谱感知与定位中的应用优势

1.2　国内外研究现状

1.2.1　非法低轨卫星终端监测与定位研究现状

1.2.2　传统测距与谱估计定位研究现状

1.2.3　多源异构信息融合与强化学习定位研究现状

1.2.4　多目标无线定位与跨模态检测研究现状

1.2.5　复杂环境传播建模与无线电地图研究现状

1.3　现有研究存在的主要问题

1.4　本文主要研究内容

1.5　本文主要创新点

1.6　论文结构安排

第二章　低成本无人机定位系统模型与定位理论基础

2.1　系统任务场景与总体架构

2.1.1　非法低轨卫星终端排查任务描述

天地一体化网络集成了地面通信、空中通信与卫星通信，正在成为新一代移动通信体系的重要发展方向。在该体系中，低轨卫星通信由于覆盖范围广、链路时延低、部署灵活等特点，已逐渐成为支撑广域接入和应急通信的重要基础设施。以 Starlink 为代表的低轨卫星星座快速发展，在推动全球宽带接入能力提升的同时，也带来了新的安全风险。非法终端可能通过恶意占用卫星资源、干扰通信链路、发送非法信息甚至伪造信号等方式，对个人信息安全、网络安全和国家安全造成威胁。因而，面向非法低轨卫星终端的快速定位与识别，已经成为无线电安全监管中的关键技术问题。

与传统地面蜂窝网络中的常规定位任务不同，非法低轨卫星终端排查具有明显的非合作性、场景复杂性和实时性要求。首先，目标终端并不向监测系统主动提供同步信息、协议配置信息或位置辅助信息，定位系统只能依赖其辐射信号及相关传播特征实现位置估计，因此该问题从体制上属于非合作式无源定位。其次，非法终端往往部署于高层建筑密集区域、临街建筑群内部或复杂街区边缘，信号传播过程中普遍存在遮挡、反射、绕射和散射等效应，导致传统视距假设难以成立。再次，在实际排查任务中，目标终端可能呈现临时出现、动态移动甚至多目标并发工作的特征，这对系统的响应速度、连续跟踪能力和抗虚警能力提出了更高要求。中期报告指出，现有方法主要存在两方面不足：一是依赖专用地面站和高性能天线等昂贵基础设施，部署成本较高；二是在复杂城市环境中定位精度不足，难以满足实际应用需求。

针对上述问题，本文将非法低轨卫星终端排查任务抽象为如下过程：无人机平台在目标区域上空执行巡检飞行任务，机载接收链路获取与非法终端相关的辐射信号，随后在机载或地面处理端提取观测量或高维特征，并依据传播模型、定位模型或后续章节中的数据驱动方法完成位置估计。该任务并非仅仅依赖某一种单一定位技术，而是包含系统建模、信号传播分析、观测量构造和误差抑制等多个环节。也正因此，在方法论层面，有必要首先建立适用于低成本无人机平台与复杂城市环境的统一系统模型，并在此基础上讨论典型定位观测量的数学特性与适用边界。

2.1.2　低成本无人机平台组成与数据处理链路

本文所考虑的低成本无人机定位系统主要由飞行平台、机载射频感知模块、数据处理模块和结果回传模块构成。飞行平台负责在目标区域内执行机动巡检任务，为空间采样提供轨迹基础；机载射频感知模块负责完成信号接收、下变频和采样；数据处理模块负责从接收信号中提取观测量或深层特征，并进一步完成定位解算；结果回传模块用于将关键特征、定位结果或状态信息传输至地面监测端。中期报告给出的系统框图表明，当前技术链路已经覆盖了从 Ku/Ka 基带信号生成、城市信道仿真、特征提取到位置预测的完整流程，这为本文建立定位系统总体架构提供了直接依据。

为更直观地说明系统组成及数据流向，图 2-1为本文低成本无人机定位系统的总体架构示意图。图中可包含目标终端、低轨卫星背景、无人机平台、机载接收链路、数据处理模块以及地面监测终端等关键单元。

图 2-1 低成本无人机定位系统总体架构示意图

从数学上看，若将目标状态记为 $\mathbf{x}_k$，平台控制输入记为 $\mathbf{u}_k$，机载观测向量记为 $\mathbf{z}_k$，则系统可抽象为离散时间状态空间模型：

$$\mathbf{x}_k = f(\mathbf{x}_{k-1}, \mathbf{u}_{k-1}) + \mathbf{w}_{k-1} \tag{2-1}$$

$$\mathbf{z}_k = h(\mathbf{x}_k) + \mathbf{v}_k \tag{2-2}$$

其中，$f(\cdot)$ 表示状态演化函数，$h(\cdot)$ 表示观测映射函数，$\mathbf{w}_{k-1}$ 与 $\mathbf{v}_k$ 分别表示过程噪声和观测噪声。式 (2-1) 和式 (2-2) 给出了本文后续讨论定位问题的统一数学框架：一方面，目标状态可随时间变化；另一方面，接收观测值是状态经非线性传播与测量过程映射后的结果。对于非法终端排查而言，由于观测量会受到复杂传播环境影响，函数 $h(\cdot)$ 往往并不具有理想视距条件下的简单形式，这也是后续需要单独讨论传播机理与观测误差来源的原因。

从工程实现角度看，“低成本”并非仅意味着设备价格较低，更意味着系统在阵列规模、载荷重量、续航时间、机载算力和通信带宽等方面均存在明显约束。

与高成本大型监测系统相比，低成本无人机平台更强调快速部署、灵活侦测和边缘处理能力，因此在算法设计中必须兼顾复杂度、时延和鲁棒性。中期材料指出，传统基于子空间分解的超分辨谱估计算法在多目标场景中的计算复杂度往往随着阵元数和搜索网格数增加呈立方增长，不适合直接部署在无人机等边缘平台上。由此可见，本文在第二章中建立系统模型的目的，不仅在于描述任务流程，更在于为后续方法选择给出约束条件。

2.2 复杂城市环境下的低轨卫星传播机理

2.2.1 Ku/Ka 波段星地链路传播特性

低轨卫星系统通常工作于 Ku/Ka 等较高频段。与较低频段通信系统相比，Ku/Ka 波段在频谱资源和带宽利用上具有明显优势，但同时对遮挡、表面反射和气象扰动更为敏感。对于星地链路而言，电磁波在自由空间中的基本损耗可写为：

$$L_{\mathrm{fs}}(d) = \left(\frac{4\pi d f_c}{c}\right)^2 \tag{2-3}$$

其分贝形式为：

$$PL_{\mathrm{fs}}(d) = 20\log_{10} d + 20\log_{10} f_c + 20\log_{10}\left(\frac{4\pi}{c}\right) \tag{2-4}$$

其中，d 为传播距离，f_c 为载波频率，c 为光速。由式 (2-4) 可知，在传播距离和其他条件相同的情况下，载波频率越高，自由空间路径损耗越大。因此，Ku/Ka 波段信号在复杂城市环境中更容易受到建筑遮挡和环境扰动影响。中期报告也明确指出，Ku/Ka 波段卫星信号在城市环境中将面临严重的多径效应、阴影衰减和非视距传播干扰。

此外，低轨卫星高速运动会引入明显的多普勒效应。若目标与接收端之间的径向相对速度为 v_r，则对应的多普勒频移可近似表示为：

$$f_d = \frac{v_r}{c} f_c \tag{2-5}$$

则接收端的基带观测信号可抽象为：

$$y(t) = h(t) * s(t)e^{j2\pi f_d t} + w(t) \tag{2-6}$$

其中，$s(t)$ 为发射信号，$h(t)$ 为等效信道响应，$w(t)$ 为加性噪声。式 (2-6) 表明，在星地链路中，接收端观测不仅受到传播路径影响，还会叠加卫星高速运动引起的频偏效应。对于本文研究的非法终端定位问题而言，多普勒项不是第二章的讨论重点，但该项说明低轨卫星相关信号本身具有时变性，这也要求后续的信号建模和特征提取过程不能简单沿用静态地面通信系统中的理想化假设。

2.2.2　城市峡谷效应与非视距传播机理

城市环境中的高层建筑、密集街道和复杂立面会形成典型的城市峡谷效应。信号在该环境中的传播路径不再由单一直达径主导，而是经由建筑物立面反射、边缘绕射和局部散射共同构成。对于非法终端排查任务而言，这意味着机载接收端往往无法稳定观测到理想视距链路，而只能观测到被环境结构重新塑造后的多径组合信号。中期报告指出，城市高楼和密集街道构成了强散射环境，使无线信号在传播过程中遭受严重的多径效应、阴影衰减与非视距干扰，这正是单一传统定位技术在复杂场景中性能恶化的根源。

若设接收端接收到的信号由 L 条传播路径构成，则接收信号可表示为：

$$r(t) = \sum_{l=1}^{L} \alpha_l s(t - \tau_l) e^{-j2\pi f_c \tau_l} + n(t) \tag{2-7}$$

其中，α_l 和 τ_l 分别表示第 l 条路径的复衰落系数和传播时延，$n(t)$ 为噪声项。当直达径存在时，$l = 1$ 通常对应 LOS 分量；而在 NLOS 条件下，直达径可能完全消失，此时接收端观测到的主要能量可能来自若干条强反射路径。由此可见，NLOS 传播并不仅仅造成噪声增大，更会从根本上改变测量值的几何含义。例如，在 AoA 定位中，反射径到达方向并不等于真实目标方向；在 TOA/TDOA 定位中，额外反射路径会导致传播距离被系统性高估。

为更清晰地说明城市峡谷中的典型传播模式，图 2-2展示了低轨卫星相关信号或终端辐射信号在复杂城市场景中的 LOS、反射径和绕射径。

图 2-2 复杂城市环境下星地链路传播机理示意图

2.2.3　多径效应、时延扩展与信号衰落机制

多径传播是复杂城市环境中最具代表性的信道特征之一。由于信号沿多条路径同时到达接收端，不同路径在幅度、相位和到达时延上存在差异，接收端将观测到频率选择性衰落、时延展宽、相位混叠和功率波动等现象。若采用时变信

道脉冲响应表示，则有：

$$h(t,\tau)=\sum_{l=1}^{L}\alpha_l(t)e^{-j\phi_l(t)}\delta\Big(\tau-\tau_l(t)\Big) \tag{2-8}$$

其中，$\alpha_l(t)$、$\phi_l(t)$ 和 $\tau_l(t)$ 分别表示第 l 条路径在时刻 t 的幅度、相位和时延。由式 (2-8) 可知，复杂城市环境中的信道本质上是由多条动态变化路径共同叠加形成的。

在多径环境中，平均时延与均方根时延扩展是刻画信道离散程度的两个重要参数。设第 l 条路径功率为 P_l，则平均时延为：

$$\bar{\tau}=\frac{\sum_l P_l\tau_l}{\sum_l P_l} \tag{2-9}$$

均方根时延扩展为：

$$\sigma_\tau=\sqrt{\frac{\sum_l P_l(\tau_l-\bar{\tau})^2}{\sum_l P_l}} \tag{2-10}$$

σ_τ 越大，表明信号能量在时域上的离散程度越高，接收端越难对“最早到达分量”或“主路径分量”作出稳定判定。在定位问题中，这一量直接影响 TOA 和 TDOA 观测精度，也会在后续融合方法中作为物理环境状态的重要描述量。你的中期报告已经明确指出，接收信号中可记录接收功率、到达角、时延扩展等多维参数，并由此生成覆盖 27,546 个网格点的高分辨率 CIR 与 I/Q 双路数据集。

从统计视角看，城市传播环境中的功率起伏还可由路径损耗与阴影衰落共同描述。常用的对数距离损耗模型为：

$$P_r(d)=P_t-PL(d_0)-10n\log_{10}\frac{d}{d_0}+X_\sigma \tag{2-11}$$

其中，P_t 为发射功率，$PL(d_0)$ 为参考距离 d_0 处的路径损耗，n 为路径损耗指数，X_σ 为阴影衰落项。该模型说明，即使在相同几何距离下，接收功率也会随着环境结构和遮挡状态发生显著变化。正是由于这种强环境依赖性，RSSI 等观测量在复杂城市环境中往往表现出较强随机性和非平稳性。中期报告中对 RSSI 的评价与这一点一致，即其极易受多径叠加和环境噪声影响，难以建立稳定的信号—距离映射关系。

2.3 低轨卫星系统背景与典型信号体制说明

2.3.1 Starlink 系统与星地链路基本特征

Starlink 是当前低轨宽带卫星系统中的典型代表之一。相较于传统蜂窝网络，其工作场景具有更强的广域覆盖属性和更复杂的星地传播特征。中期报告已将

Starlink 作为本文研究中的典型对象，并指出以其为代表的低轨卫星星座部署数量快速增长，给天地一体化网络应用带来重要支撑的同时，也增加了非法终端利用相关链路开展异常活动的风险。将 Starlink 相关信号作为本文建模对象，主要是为了使研究场景与低轨卫星非法终端排查任务相一致，从而保证后续信号建模和传播仿真具有明确的工程指向。

在基带层面，复包络信号通常可写为：

$$s(t) = I(t) + jQ(t) \tag{2-12}$$

其中，$I(t)$ 与 $Q(t)$ 分别表示同相分量和正交分量。对于本文而言，复基带序列既承载了原始通信体制信息，也记录了传播过程中的路径、相位和频偏影响。因此，从定位角度看，I/Q 信号并非仅仅是通信解调对象，更是环境传播特征的重要载体。后续若从 I/Q 序列中提取射频指纹，本质上就是在学习“信号体制特征”和“场景传播结构”的联合表征。中期报告明确指出，后续单模态定位模型将直接从 I/Q 双路信号中提取深层特征。

2.3.2　本文研究对象与典型体制的关系说明

需要说明的是，第二章的任务是建立系统模型与定位理论基础，因此本章仅对 Starlink 及其星地链路作对象说明，而不在此处展开具体帧结构、同步字段、协议解析和 I/Q 样本生成流程。中期报告已经表明，后续研究将利用 MATLAB 相关工具依据 Starlink 帧结构生成 Ku 波段基带信号，并结合射线追踪模块输出带有环境特征的 I/Q 序列，用于深度模型训练。相关内容与本文第三章中的单目标高精度定位方法直接相关，因此将在第三章中作集中展开。

因此，本章对信号建模范围作如下限定：第一，第二章只将 Starlink 视为本文所研究低轨卫星通信场景的代表性对象；第二，第二章中不重复展开信号结构与协议细节；第三，第三章将在单目标定位方法框架下，进一步讨论基带信号生成、射线追踪注入、I/Q 指纹构造与深度特征学习过程。这样的安排能够避免章节之间内容交叉，使第二章保持“理论基础章”的结构完整性。

2.4　经典定位观测量与定位模型

不同定位方法本质上依赖于不同的观测量构造目标位置的几何约束。对于非法低轨卫星终端排查问题，经典观测量主要包括接收信号强度、到达角、到达时间以及到达时间差等。本节将对 RSSI、AoA、TOA 和 TDOA 四类典型观测量进行统一说明，并分析其在复杂城市环境中的适用边界。

为便于说明各类观测量对应的几何关系，图 2-3展示了 RSSI、AoA、TOA 和 TDOA 的典型定位几何示意。

图 2-3 经典定位观测量几何关系示意图（含 RSSI、AoA、TOA、TDOA）

2.4.1 RSSI 定位模型与误差来源

RSSI 定位方法通过接收信号功率与传播距离之间的统计关系反推目标位置。若采用式 (2-11) 所示的对数距离损耗模型，则目标到接收端的距离估计值可写为：

$$\hat{d} = d_0 \cdot 10^{\frac{P_t - PL(d_0) - P_r(d)}{10n}} \tag{2-13}$$

在理想传播环境中，该方法实现简单，对硬件要求较低，适合作为低成本平台上的基础观测量。然而，在复杂城市环境下，RSSI 的主要问题在于其对环境极度敏感。建筑遮挡、多径叠加、天线方向图变化以及噪声扰动都会导致接收功率出现显著波动，使同一几何距离对应多个可能的功率值。你的中期报告对 RSSI 的描述也指出，其在城市峡谷环境中呈现出剧烈的随机波动与非平稳性，难以建立稳定的信号—距离映射关系。

从误差构成上看，RSSI 定位误差可分为模型误差、随机误差和环境结构误差三类。模型误差来源于对数距离模型与真实传播过程之间的偏差；随机误差来自热噪声和阴影衰落；环境结构误差则由 NLOS 和多径传播导致的系统性偏移造成。由于这三类误差在复杂城市场景中往往同时存在，RSSI 通常难以单独支撑高精度定位，但其获取简便、计算量低，因而仍然是后续多观测量融合中不可忽略的重要观测量。

2.4.2 AoA 定位模型与几何约束关系

AoA（Angle of Arrival）定位方法通过测量信号到达方向构建位置几何约束。设第 i 个接收机坐标为 (x_i, y_i)，目标坐标为 (x, y)，则第 i 个方位角观测可表示为：

$$\theta_i = \arctan \frac{y - y_i}{x - x_i} \tag{2-14}$$

等价地，也可写为直线约束：

$$y - y_i = \tan(\theta_i)(x - x_i) \tag{2-15}$$

当存在两个或更多空间分离的接收点时，理论上可通过多条方位线交会求得目标位置。AoA 方法的优点在于对绝对时间同步要求较低，并且在视距条件下几何意义直观、求解效率较高。但该方法高度依赖主径方向能够真实反映目标方位，而在城市峡谷环境中，这一条件往往并不满足。

中期报告指出，AoA 技术高度依赖视距传播路径，在建筑物遮挡的 NLOS 场景下，接收机往往只能捕获到经反射或绕射到达的信号，从而导致测角结果与真实目标方向产生显著偏差。也就是说，AoA 的主要问题不只是噪声方差增大，而是观测模型本身的几何含义会被环境结构破坏。因此，在复杂城市环境中，AoA 更适合作为多观测量系统中的一类方向性约束，而不宜单独作为高精度定位的唯一依据。

2.4.3　TOA 定位模型与同步误差分析

TOA（Time of Arrival）定位方法通过测量信号从发射端传播到接收端的绝对到达时间，实现对传播距离的估计。设第 i 个接收机测得传播时延为 t_i，则距离满足：

$$d_i = ct_i \tag{2-16}$$

对应的几何约束为：

$$\sqrt{(x - x_i)^2 + (y - y_i)^2} = ct_i \tag{2-17}$$

这意味着每个 TOA 观测对应一条以接收机为圆心的等距圆，多个接收机的圆交点构成目标位置解。TOA 在理想条件下具有清晰的距离物理意义，且理论定位精度较高，但其前提是系统能够获得高精度绝对时间同步。

若接收端存在时钟偏差 Δt_i，则观测时延为：

$$\tilde{t}_i = t_i + \Delta t_i \tag{2-18}$$

对应的距离误差为：

$$\Delta d_i = c\Delta t_i \tag{2-19}$$

由于光速极大，即使很小的时钟偏差也会转化为显著的距离误差。对于非法终端排查任务而言，目标通常是非合作的，无法向监测端提供发射时刻基准；低成本无人机平台也难以配置昂贵的高精度同步系统。因此，尽管 TOA 是经典定位理论中的重要方法，但在本文场景中更适合作为理论分析基线，而非首选实施路径。除此之外，在 NLOS 条件下，首达径可能并非真实最短路径，进一步放大 TOA 测距误差。

2.4.4 TDOA 定位模型与双曲线定位机理

TDOA（Time Difference of Arrival）定位方法通过不同接收机之间的到达时间差消除未知发射时刻的影响。设目标到第 i 个接收机和参考接收机 1 的传播距离分别为 d_i 和 d_1，则有：

$$d_i - d_1 = c\Delta t_{i1} \tag{2-20}$$

进一步展开为几何方程，可得：

$$\sqrt{(x-x_i)^2+(y-y_i)^2} - \sqrt{(x-x_1)^2+(y-y_1)^2} = c\Delta t_{i1} \tag{2-21}$$

式 (2-21) 对应一条双曲线，因此 TDOA 的定位本质是利用多条双曲线的交会确定目标位置。相较于 TOA，TDOA 不需要知道目标的绝对发射时刻，因此在非合作定位中具有更强的工程实用性。不过，该方法仍要求不同接收机之间具有较高相对同步精度，同时对接收机几何布局较为敏感。当基站分布不合理、双曲线交角过小时，定位误差会被显著放大。

对于复杂城市环境而言，TDOA 仍然会受到多径和 NLOS 传播的强烈影响。若不同接收机接收到的“首达分量”来源于不同反射路径，则时间差观测将不再对应真实距离差，双曲线约束也随之偏离真实目标位置。因此，TDOA 虽然适合被动非合作场景，但在复杂城市环境中单独使用时同样难以保证稳定性能，这也是本文后续转向指纹特征、场景建模和多源融合的重要原因。

2.5 基于多观测量的定位性能分析基础

2.5.1 统一观测模型与误差传播关系

为了统一分析 RSSI、AoA、TOA 和 TDOA 等不同观测量的定位性能，可将其抽象为一般非线性观测模型：

$$\mathbf{z} = \mathbf{h}(\mathbf{p}) + \mathbf{n} \tag{2-22}$$

其中，$\mathbf{p} = [x, y]^T$ 为待估计的位置参数，$\mathbf{z}$ 为观测向量，$\mathbf{h}(\mathbf{p})$ 为位置到观测空间的映射函数，$\mathbf{n}$ 为观测噪声。不同方法的差异，本质上体现在 $\mathbf{h}(\mathbf{p})$ 的具体形式不同。对该模型在参考点 $\mathbf{p}_0$ 处进行一阶线性化，可得：

$$\mathbf{z} \approx \mathbf{h}(\mathbf{p}_0) + \mathbf{H}(\mathbf{p} - \mathbf{p}_0) + \mathbf{n} \tag{2-23}$$

其中，$\mathbf{H}$ 为雅可比矩阵，即：

$$\mathbf{H} = \left.\frac{\partial \mathbf{h}(\mathbf{p})}{\partial \mathbf{p}}\right|_{\mathbf{p}=\mathbf{p}_0} \tag{2-24}$$

在线性近似成立的条件下，位置误差与观测误差之间满足：

$$\Delta\mathbf{p} \approx (\mathbf{H}^T\mathbf{H})^{-1}\mathbf{H}^T\mathbf{n} \tag{2-25}$$

若观测噪声协方差矩阵为 $\mathbf{R}$，则位置估计误差协方差可近似表示为：

$$\mathrm{Cov}(\Delta\mathbf{p}) \approx (\mathbf{H}^T\mathbf{R}^{-1}\mathbf{H})^{-1} \tag{2-26}$$

式 (2-26) 表明，定位精度由两方面共同决定：一方面是观测量本身的噪声水平，另一方面是观测模型的几何敏感度。对于复杂城市环境而言，即便观测噪声水平相近，不同观测量在 NLOS 和多径条件下的几何解释能力仍可能存在显著差异，这也是单一定位方法性能差异较大的根本原因。

2.5.2　克拉美罗下界分析基础

克拉美罗下界（Cramér-Rao Lower Bound, CRLB）是无偏估计器协方差所能达到的理论下界，可用于衡量在给定观测模型和噪声条件下系统的理论最优定位性能。对于式 (2-22) 所示模型，若噪声近似服从高斯分布，则 Fisher 信息矩阵可写为：

$$\mathbf{J}(\mathbf{p}) = \left(\frac{\partial\mathbf{h}}{\partial\mathbf{p}}\right)^T \mathbf{R}^{-1} \left(\frac{\partial\mathbf{h}}{\partial\mathbf{p}}\right) \tag{2-27}$$

则无偏估计量 $\hat{\mathbf{p}}$ 的协方差满足：

$$\mathrm{Cov}(\hat{\mathbf{p}}) \geq \mathbf{J}^{-1}(\mathbf{p}) \tag{2-28}$$

进一步地，二维定位问题中的均方根误差下界可表示为：

$$\mathrm{RMSE} \geq \sqrt{\mathrm{tr}\left(\mathbf{J}^{-1}(\mathbf{p})\right)} \tag{2-29}$$

CRLB 的意义在于，它不依赖具体求解算法，而只由观测模型和噪声统计决定。因此，可利用 CRLB 比较不同观测量组合在理想条件下的理论可达精度。需要说明的是，在复杂城市环境中，由于 NLOS 和模型失配普遍存在，实际误差通常会高于理想 CRLB，但该下界仍然是分析系统上限能力的重要工具。

2.5.3　几何精度因子分析基础

除了噪声水平外，定位系统性能还受到观测几何布局的显著影响。几何精度因子（Geometric Dilution of Precision, GDOP）用于描述观测几何对位置误差的放大程度。设线性化后的几何矩阵为 $\mathbf{G}$，则 GDOP 可表示为：

$$\mathrm{GDOP} = \sqrt{\mathrm{tr}\left((\mathbf{G}^T\mathbf{G})^{-1}\right)} \tag{2-30}$$

GDOP 越小，说明观测几何越有利，定位结果对噪声扰动越不敏感；反之，当观测方向近似平行、双曲线交角过小或平台采样轨迹分布不合理时，GDOP 将

显著增大，位置误差被放大。在 AoA 定位中，若多个方向线夹角过小，则交点区域会被拉长；在 TDOA 定位中，若接收机布局不利，则双曲线交会稳定性下降。这说明良好的定位性能不仅依赖观测量本身，还依赖观测几何是否合理。

对于低成本无人机平台而言，GDOP 分析还具有航迹设计意义。由于无人机位置是可控的，合理的飞行路径与采样点布局有望改善观测几何，从而在不增加硬件成本的条件下提升整体定位能力。虽然本文后续主要关注数据驱动定位与融合方法，但第二章给出 GDOP 的分析基础，能够为后续讨论观测布局与性能关系提供统一工具。

2.5.4 多观测量方法的适用场景比较

综合前述分析可知，RSSI、AoA、TOA 和 TDOA 各有其适用条件与局限性。RSSI 获取最为简单，对硬件要求最低，但对环境波动最为敏感；AoA 在视距场景中能够提供清晰方向信息，但在 NLOS 条件下易产生系统性偏差；TOA 具有明确的距离物理意义，但对绝对同步要求高；TDOA 更适合非合作被动定位，但仍依赖多站同步并受到几何布局和多径环境的双重制约。对于复杂城市环境中的非法低轨卫星终端排查任务而言，单一观测量通常难以同时满足低成本、强鲁棒和高精度三项要求。

你的中期报告已经明确指出，复杂城市环境中的 RSSI、AoA 与轨迹推算三类信息源各自存在物理瓶颈：RSSI 难以稳定映射距离，AoA 对 NLOS 传播敏感，轨迹推算则会因缺少外部校正而累积漂移。正因如此，后续研究才在单模态指纹定位基础上引入多源异构信息的动态融合机制。因而，第二章对经典观测量的讨论，其目的并不是在这些方法中直接选出唯一最优方案，而是说明：在低成本无人机平台和复杂城市传播环境共同约束下，定位问题已无法依赖单一经典观测量解决，而需要进一步结合高保真场景建模、深层特征学习和多源融合策略。

2.6 本章小结

第三章　基于物理感知深度强化学习的单目标自适应融合定位方法

3.1　问题描述与总体框架

3.1.1　单目标定位任务定义与场景约束

本文研究的场景是在复杂城市环境下，利用低成本无人机平台对地面非法低轨卫星终端进行非合作式无源单目标连续定位。与常规通信系统中的合作式定位不同，目标终端通常不提供同步辅助、位置信息或协议配合，无人机平台只能依赖接收到的目标相关多源观测信息对其位置进行估计。因此，本章所讨论的问题本质上属于复杂环境约束下的非合作式无源定位问题，其定位输出采用二维平面坐标形式，重点关注单目标连续轨迹的定位精度、轨迹平滑性以及对环境扰动的鲁棒性。

复杂城市环境中的高层建筑、狭窄街道以及大量反射界面会引起显著的非视距传播和多径效应，使得不同观测量的有效性随时间和空间持续变化。一方面，RSSI 易受局部遮挡、阴影衰落和快衰落影响，导致其与传播距离之间的映射关系失稳；另一方面，AoA 在强反射环境中容易偏离真实来波方向，而 PDR 虽然具有较好的短时平滑性，却会因惯性误差累积而在长时间尺度上逐渐偏离真实轨迹。上述现象表明，在复杂城市环境中，不同观测量之间并不存在固定不变的优劣关系，其可靠性会随着传播条件、遮挡状态和目标运动过程动态波动。因此，采用固定权重或静态融合规则难以适应复杂场景中的快速状态切换，这也是传统融合方法在实际排查任务中性能受限的重要原因。

基于上述分析，本章不再将单目标定位问题简单地视为多个观测量的线性组合问题，而是将其归结为一个面向动态环境的自适应融合决策问题。具体而言，本章关注的是：在复杂传播环境和多源异构观测条件下，如何根据信道状态和观测质量的实时变化，自适应地调整不同信息源的融合权重，从而获得稳定、连续且高精度的定位结果。围绕这一目标，本文后续将引入物理感知状态空间与深度强化学习决策机制，对单目标非法终端的动态融合定位进行研究。图 3-1 给出了本章所针对的单目标定位场景示意图。

3.1.2　多源异构定位信息加权融合模型

为充分利用不同观测量之间的互补性，本文采用多源异构信息融合框架，将 RSSI、AoA 和 PDR 三类定位结果作为基础输入。之所以选择这三类观测，是因为它们分别从不同层面刻画目标位置特征：RSSI 反映信号功率层面的空间变化

图 3-1 复杂城市环境下基于低成本无人机平台的单目标非法终端定位场景示意图

信息，AoA 提供几何方向约束，而 PDR 则利用惯性测量信息表征目标运动过程中的短时连续性。三者在信息来源和误差机理上具有明显差异，能够形成较强互补；但与此同时，其可靠性也会随着传播环境和运动状态变化而动态波动。因而，如何在不同场景下合理利用三类观测的优势，是实现稳定定位的关键。

为统一不同观测来源的输出形式，本文首先将各模块原始观测转换为对应的位置估计结果，再在位置层面进行加权融合。设在时刻 t，RSSI、AoA 和 PDR 模块分别给出位置估计 $\boldsymbol{P}_t^{\mathrm{RSSI}}$、$\boldsymbol{P}_t^{\mathrm{AoA}}$ 和 $\boldsymbol{P}_t^{\mathrm{PDR}}$，则最终融合结果可建模为

$$\boldsymbol{P}_t^{\mathrm{Fused}} = \omega_t^{\mathrm{RSSI}} \boldsymbol{P}_t^{\mathrm{RSSI}} + \omega_t^{\mathrm{AoA}} \boldsymbol{P}_t^{\mathrm{AoA}} + \omega_t^{\mathrm{PDR}} \boldsymbol{P}_t^{\mathrm{PDR}}, \tag{3-1}$$

其中，$\omega_t = [\omega_t^{\mathrm{RSSI}}, \omega_t^{\mathrm{AoA}}, \omega_t^{\mathrm{PDR}}]^T$ 为时刻 t 的权重向量，并满足归一化约束

$$\omega_t^{\mathrm{RSSI}} + \omega_t^{\mathrm{AoA}} + \omega_t^{\mathrm{PDR}} = 1. \tag{3-2}$$

上述模型的优势在于形式直观、实现简单，并且能够显式体现不同信息源在不同环境下的贡献差异。然而，该模型真正的难点并不在于融合形式本身，而在于权重 ω_t 的动态确定机制。若采用固定权重，则模型难以适应复杂城市环境中瞬时变化的多径、遮挡和观测退化；若采用传统滤波器，则仍需依赖较强的噪声模型假设和先验统计条件，难以准确刻画非平稳环境中的观测质量波动。

进一步地，权重分配不仅依赖当前时刻不同观测量的质量，还与前一时刻的融合状态、轨迹连续性以及环境变化趋势相关。因此，该问题本质上并非一个静态参数估计问题，而是一个面向动态环境的序列决策问题。基于这一认识，本文不采用静态权重或人工规则，而是将权重生成过程交由智能体动态决策，并在下一小节中进一步将其建模为马尔可夫决策过程，为后续强化学习求解奠定基础。

3.1.3 面向动态信道的马尔可夫决策过程建模

由式 (3-1) 可知，多源异构定位信息融合的关键在于权重向量 ω_t 的动态确定。然而，在复杂城市环境中，这一权重分配过程并不是一个静态参数优化问题，而是一个具有显著时序性的动态决策问题。其原因在于：当前时刻的融合决

策不仅依赖于当前环境状态和观测质量，还会进一步影响下一时刻的融合结果、误差传播以及轨迹连续性。换言之，在单目标连续定位过程中，系统的决策具有明显的“当前状态—当前动作—未来结果”链式关联，这使得多源融合过程天然具备序列决策特征。

具体而言，在复杂城市环境下，目标终端在运动过程中会不断经历视距（LOS）与非视距（NLOS）条件切换，RSSI、AoA 和 PDR 三类观测的可靠性也会随之动态变化。当智能体在某一时刻提高某一观测源的融合权重时，该动作不仅会改变当前时刻的融合位置输出，还会通过影响轨迹连续性、误差累积和后续状态演化，对下一时刻的决策产生作用。例如，在强反射环境下若仍赋予 AoA 过高权重，则会导致当前定位偏差增大，并使得下一时刻的几何一致性特征和轨迹误差进一步恶化；相反，若在 RSSI 波动显著且 RMS 时延扩展快速升高时提前降低无线观测权重，则有助于抑制误差扩散并维持轨迹平滑性。因此，本章所研究的问题不是单步最优加权，而是在动态环境中根据状态演化持续更新最优策略的问题。

基于上述分析，本文将该动态融合过程抽象为马尔可夫决策过程（Markov Decision Process, MDP）。在这一框架下，智能体在每一时刻观测系统状态 S_t，并据此选择动作 a_t，动作执行后产生即时奖励 r_t，同时系统演化到下一状态 S_{t+1}。其中，状态用于刻画当前时刻的环境与观测条件，动作对应融合权重的更新策略，奖励则用于衡量当前决策在定位精度和轨迹平滑性方面的综合效果。只要当前决策所需的主要信息能够由当前状态向量近似表征，就可以将该问题视为一个近似满足马尔可夫性的序列决策问题。

为了形式化描述上述过程，本文将该问题表示为一个五元组

$$\mathcal{M} = \langle \mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma \rangle, \tag{3-3}$$

其中，$\mathcal{S}$ 表示状态空间，$\mathcal{A}$ 表示动作空间，$\mathcal{P}$ 表示状态转移概率，$\mathcal{R}$ 表示奖励函数，$\gamma \in [0, 1]$ 为折扣因子。对于本文而言，状态空间 $\mathcal{S}$ 用于描述复杂传播环境下的物理信道状态、观测统计特征及融合历史信息；动作空间 $\mathcal{A}$ 用于表示不同的权重更新策略；奖励函数 $\mathcal{R}$ 则用于刻画当前融合决策对定位效果的优劣。

在该建模下，智能体的目标是学习一个最优策略 π^*，使得从任意状态出发时的长期累计回报最大化。对应的状态—动作价值函数可表示为

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi}\left[\sum_{k=0}^{\infty} \gamma^k r_{t+k} \,\middle|\, S_t = s,\ a_t = a\right]. \tag{3-4}$$

式 (3-4) 表明，当前动作的优劣不仅由即时奖励决定，还取决于该动作对未来一系列状态演化和奖励累积的长期影响。这一点与本文所研究的连续轨迹定位任

务高度一致，因为单次权重更新往往会影响后续多个时刻的定位误差和轨迹平滑性。

依据 Bellman 最优性原理，最优状态—动作价值函数满足

$$Q^*(s,a) = \mathbb{E}\left[r_t + \gamma \max_{a'} Q^*(s',a') \,\middle|\, s,a\right]. \tag{3-5}$$

在实际求解中，本文采用深度 Q 网络对 $Q^*(s,a)$ 进行近似。其核心思想是利用神经网络建立从状态到动作价值的映射，并通过经验回放和目标网络机制实现稳定训练。对应的参数更新损失可写为

$$L(\theta) = \mathbb{E}_{(s,a,r,s')\sim D}\left[\left(y_i - Q(s,a;\theta)\right)^2\right], \quad y_i = r + \gamma \max_{a'} Q(s',a';\theta^-), \tag{3-6}$$

其中，D 为经验回放池，θ 为当前网络参数，θ^- 为目标网络参数。

需要指出的是，本文并非将强化学习作为一般性的权重调节工具，而是将复杂城市环境下的多源定位融合过程视为一个随环境状态演化而不断更新的序列决策问题。在该问题中，传播条件具有明显的时变特性，不同观测量的可靠性会随遮挡、多径和目标运动过程发生变化，当前时刻的权重分配不仅决定当前定位结果，也会影响后续轨迹误差的传播特性。基于上述特点，采用马尔可夫决策过程对融合定位问题进行建模具有明确的合理性。在此基础上，后文将进一步分别构建 RL-IFA 基线算法与 PA-DQN 物理感知强化学习方法，并比较基于后验误差驱动的决策机制与引入物理先验后的决策机制在定位性能上的差异。图 3-2 给出了本章单目标自适应融合定位问题的 MDP 建模示意图。

图 3-2 单目标自适应融合定位问题的马尔可夫决策过程建模示意图

3.2 复杂环境观测构造与物理先验信息提取

3.2.1 射线追踪场景建模与环境先验获取

为了建立观测波动与环境成因之间的对应关系，本文引入基于射线追踪的高保真场景建模方法，用于构造复杂城市环境中的传播先验信息。对于本章所研究的单目标连续定位任务而言，强化学习模型的训练与评估不仅需要大量可重复的交互样本，还要求在不同轨迹、不同信噪比以及不同视距/非视距切换条

件下获得可控且带有真值标注的数据。然而，在真实城市环境中，大规模采集同时满足“多轨迹、可控环境切换、精确位置真值和多种信道状态”的连续定位数据代价较高，且实验可重复性有限。因此，本文采用“真实地理数据建模 + 射线追踪传播仿真”的方式构建复杂城市环境下的训练与测试场景，以兼顾物理一致性、样本规模和实验可控性。

在场景建模阶段，本文首先利用 OpenStreetMap（OSM）导出的真实地理信息数据，获取目标区域内建筑物的平面轮廓、高度信息及空间分布关系，并在 MATLAB Site Viewer 环境中完成三维城市几何场景重建。为了尽可能逼近真实传播条件，建模区域选取北京市典型建筑密集街区作为原型场景，通过将建筑物几何轮廓映射到三维坐标系中，形成包含高层建筑、街道走廊和开阔区域的城市峡谷环境。该建模过程为后续电磁传播仿真提供了几何基础，也使得不同位置的传播差异能够与真实城市结构建立对应关系。

图 3-3 基于 OSM 数据的复杂城市三维场景建模示意图

3.2.2　多源观测量生成与特征表达

在本章所构建的自适应融合定位框架中，系统并不直接以原始射频观测作为最终输入，而是将不同来源的观测信息分别转化为可用于定位的初步估计结果，并在此基础上完成后续的动态加权融合。关于 RSSI、AoA 以及 PDR 等观测量的获取方式、基本测量机理和定位模型，前文第二章已经进行了讨论。因此，本节不再重复展开各类观测的底层测量过程，而是在前述理论基础上，重点说明 RSSI、AoA 和 PDR 三类异构观测在本章中的生成形式、表达方式及其在融合框架中的作用。

结合当前研究基础，本文选取 RSSI、AoA 和 PDR 三类观测作为主要输入源。其原因在于：RSSI 能够反映信号功率层面的空间变化特征，AoA 提供几何方向约束，而 PDR 则利用惯性信息表征目标短时运动连续性。三者分别对应功率域、几何域和运动域信息，具有较强互补性，能够共同描述复杂城市环境下单目标定位所需的多维特征。然而，这三类观测在可靠性上并不存在固定不变的优劣关系，而是会随着传播条件、遮挡状态和目标运动过程持续变化，因此需要在

统一框架下对其进行动态融合。

需要指出的是，本文对三类观测的使用包含两条并行数据链路。第一条为定位输出链，即 RSSI、AoA 和 PDR 模块分别根据各自观测模型输出初步位置估计 $\boldsymbol{P}_t^{\mathrm{RSSI}}$、$\boldsymbol{P}_t^{\mathrm{AoA}}$ 和 $\boldsymbol{P}_t^{\mathrm{PDR}}$，并作为后续加权融合模块的直接输入。第二条为状态构造链，即各模块在生成初步位置估计的同时，保留其原始观测数据或中间统计量，并与上一节得到的环境先验共同送入物理感知特征提取器，用于构造强化学习智能体的状态向量。也就是说，本节中的多源观测不仅服务于位置解算，还承担了状态感知输入的功能，这是本章区别于传统静态融合方法的重要特点。

图 3-4 多源观测生成与融合输入构造流程示意图

图 3-5 定位输出链与状态构造链的并行结构关系示意图

3.2.3 RMS 时延扩展与几何一致性特征构造

为了使强化学习智能体能够在定位误差显著累积之前感知环境变化，本文并未仅依赖后验定位误差或当前融合结果构造状态空间，而是进一步引入能够反映传播机理、观测稳定性和系统几何一致性的多层状态特征。基于这一认识，本文构建由物理层特征、统计层特征、几何层特征以及历史决策信息共同组成的分层状态表示。

首先，本文选取 RMS 时延扩展 σ_τ 作为表征多径复杂度的核心物理层特征。该特征来源于上一节射线追踪场景建模得到的路径级传播参数，能够反映接收信号在时延域上的离散程度。RMS 时延扩展定义为

$$\sigma_\tau = \sqrt{\frac{\sum_{n=1}^{N} |\alpha_n|^2 (\tau_n - \bar{\tau})^2}{\sum_{n=1}^{N} |\alpha_n|^2}}, \tag{3-7}$$

其中，N 为有效多径分量数，α_n 和 τ_n 分别表示第 n 条路径的幅度和绝对时延，$\bar{\tau}$ 为功率加权平均时延。

其次，为刻画接收功率在时间上的波动程度，本文引入 RSSI 方差 σ^2_{RSSI} 作为统计层特征。设在长度为 W 的滑动窗口内，接收功率序列为 $\{RSSI_k\}$，则其方差定义为

$$\sigma^2_{\mathrm{RSSI}} = \frac{1}{W}\sum_{k=t-W+1}^{t}\left(RSSI_k - \overline{RSSI}_t\right)^2, \tag{3-8}$$

其中，$\overline{RSSI}_t$ 为窗口内平均接收功率。

进一步地，为利用轨迹连续性对无线观测结果进行系统层约束，本文构造几何一致性特征 $D_{\mathrm{RF-PDR}}$。其中，P_{RF} 表示当前时刻由无线电侧得到的位置估计结果，P_{PDR} 表示由惯性递推获得的 PDR 位置估计。两者之间的欧氏距离定义为

$$D_{\mathrm{RF-PDR}} = \|P_{\mathrm{RF}} - P_{\mathrm{PDR}}\|_2 = \sqrt{(x_{\mathrm{RF}} - x_{\mathrm{PDR}})^2 + (y_{\mathrm{RF}} - y_{\mathrm{PDR}})^2}, \tag{3-9}$$

在上述基础上，本文将物理层特征、统计层特征、几何层特征与上一时刻权重向量共同组合，形成当前时刻的物理感知状态向量

$$S_t = \left[\sigma_\tau, \sigma^2_{\mathrm{RSSI}}, D_{\mathrm{RF-PDR}}, \omega_{t-1}\right]^T, \tag{3-10}$$

其中，ω_{t-1} 表示上一时刻的融合权重。图 3-6 给出了物理感知状态空间构成示意图。

图 3-6 物理感知状态空间构成示意图

3.3　基于 Q-Learning 的 RL-IFA 基线自适应融合算法

3.3.1　状态空间设计

为考察物理感知状态构造对融合定位性能的影响，本文首先构建一种不显式引入传播环境先验的强化学习信息融合算法，记为基于强化学习的信息融合算法（Reinforcement Learning-based Information Fusion Algorithm, RL-IFA），并将其作为后续 PA-DQN 方法的基线模型。RL-IFA 的基本思想是：在多源观测融合

过程中，将当前融合结果的定位误差作为状态反馈量，利用 Q-Learning 学习不同观测量之间的权重调整策略，从而实现自适应融合定位。

与后续 PA-DQN 的物理感知状态空间不同，RL-IFA 并不对多径结构、观测稳定性或几何一致性进行显式建模，而仅依据当前融合结果与真实位置之间的偏差来刻画系统状态。设时刻 t 的融合定位结果为 $\boldsymbol{P}_t^{\mathrm{Fused}} = (x_t^{\mathrm{Fused}}, y_t^{\mathrm{Fused}})$, 对应真实位置为 $\boldsymbol{P}_t^{\mathrm{GT}} = (x_t^{\mathrm{GT}}, y_t^{\mathrm{GT}})$, 则当前时刻的融合误差定义为

$$\varepsilon_t = \left\| \boldsymbol{P}_t^{\mathrm{Fused}} - \boldsymbol{P}_t^{\mathrm{GT}} \right\|_2 = \sqrt{\left(x_t^{\mathrm{GT}} - x_t^{\mathrm{Fused}}\right)^2 + \left(y_t^{\mathrm{GT}} - y_t^{\mathrm{Fused}}\right)^2}. \tag{3-11}$$

式 (3-11) 所定义的误差量直接反映了当前融合策略下的定位效果，因此可作为强化学习决策的后验反馈依据。考虑到经典 Q-Learning 通常在离散状态空间中实现，为控制状态空间规模并提高训练可行性，本文对连续误差 ε_t 进行离散化处理。参考相关研究中对融合误差状态化的处理方式，本文将误差区间 $[0, 1)$ m 均匀划分为 100 个离散状态，并将大于等于 1 m 的误差统一映射为终端状态。于是，时刻 t 的状态 s_t 定义为

$$s_t = \begin{cases} \mathrm{round}(100\,\varepsilon_t), & 0 \le \varepsilon_t < 1, \\ 100, & \varepsilon_t \ge 1. \end{cases} \tag{3-12}$$

上述状态定义方式具有两方面特点。其一，状态的构造仅依赖融合结果与真实位置之间的后验误差，因而实现简单，便于形成标准 Q-Learning 基线；其二，状态编号随误差大小单调变化，从而能够较直接地反映当前融合效果的优劣。图 3-7 给出了 RL-IFA 基线算法中基于融合误差的状态空间设计示意图。

图 3-7 RL-IFA 基线算法中基于融合误差的状态空间设计示意图

3.3.2 动作空间设计

在 RL-IFA 基线算法中，动作空间的作用是根据当前状态对多源观测的融合权重进行更新。由于本文采用 Q-Learning 进行求解，为保证动作集合有限且便于训练实现，本文对权重调整过程进行离散化处理。具体而言，动作并不直接给出新的连续权重值，而是规定在当前时刻对各观测源权重执行“增加”“减小”或

“保持不变”三类基本操作。通过这种方式，多源融合权重优化问题可被转化为有限动作空间下的离散决策问题。

考虑到三类观测的融合权重满足归一化约束

$$\omega_t^{\mathrm{RSSI}} + \omega_t^{\mathrm{AoA}} + \omega_t^{\mathrm{PDR}} = 1, \tag{3-13}$$

因此，在动作设计中无须对三个权重同时独立更新。为降低动作空间维数并避免冗余组合，本文仅对 ω_t^{RSSI} 和 ω_t^{AoA} 施加离散动作，第三个权重 ω_t^{PDR} 由归一化约束自动确定。

设权重更新步长参数为 κ，则对任一可调权重 ω_t^x（其中 $x \in \{\mathrm{RSSI}, \mathrm{AoA}\}$），其更新规则定义为

$$\omega_{t+1}^x = \begin{cases} (1+\kappa)\omega_t^x, & \text{若执行增加动作,} \\ (1-\kappa)\omega_t^x, & \text{若执行减小动作,} \\ \omega_t^x, & \text{若执行保持动作.} \end{cases} \tag{3-14}$$

在得到 $\omega_{t+1}^{\mathrm{RSSI}}$ 和 $\omega_{t+1}^{\mathrm{AoA}}$ 后，由式 (3-13) 可进一步计算

$$\omega_{t+1}^{\mathrm{PDR}} = 1 - \omega_{t+1}^{\mathrm{RSSI}} - \omega_{t+1}^{\mathrm{AoA}}. \tag{3-15}$$

基于上述定义，本文将 RL-IFA 的动作空间构造为 9 个离散动作，即对 ω^{RSSI} 和 ω^{AoA} 分别执行“增加 / 减小 / 保持”三类操作后形成的组合集合：

$$\mathcal{A} = \left\{a_1, a_2, \ldots, a_9\right\}. \tag{3-16}$$

这 9 个动作的具体定义如表 3-1 所示。

图 3-8 给出了 RL-IFA 基线算法中动作空间与权重更新关系的示意图。

图 3-8 RL-IFA 基线算法中动作空间与权重更新关系示意图

3.3.3　奖励函数设计

在 RL-IFA 中，状态用于描述当前融合结果的误差水平，动作用于调整各观测分支的权重分配，而奖励函数则负责评价该次权重调整是否有利于定位结果

表 3-1 RL-IFA 基线算法中离散动作空间定义

动作编号	ω^{RSSI} 更新	ω^{AoA} 更新	ω^{PDR} 更新方式
a_1	增加	增加	由归一化约束计算
a_2	增加	减小	由归一化约束计算
a_3	增加	保持	由归一化约束计算
a_4	减小	增加	由归一化约束计算
a_5	减小	减小	由归一化约束计算
a_6	减小	保持	由归一化约束计算
a_7	保持	增加	由归一化约束计算
a_8	保持	减小	由归一化约束计算
a_9	保持	保持	由归一化约束计算

改善。由于基线算法的目标是验证强化学习在多源异构观测融合中的有效性，因此本节奖励设计首先围绕定位精度展开，即将融合输出与真实位置之间的偏差作为策略优劣的直接判据。

设第 k 个时刻获取的三类定位观测分支经加权融合后计算得到的位置估计为 $\hat{\mathbf{p}}_k^{\mathrm{Fused}} = [\hat{x}_k^{\mathrm{Fused}}, \hat{y}_k^{\mathrm{Fused}}]^T$, 对应真实位置为 $\mathbf{p}_k^{\mathrm{GT}} = [x_k^{\mathrm{GT}}, y_k^{\mathrm{GT}}]^T$, 则融合定位误差可写为

$$e_k = \left\|\hat{\mathbf{p}}_k^{\mathrm{Fused}} - \mathbf{p}_k^{\mathrm{GT}}\right\|_2 = \sqrt{\left(\hat{x}_k^{\mathrm{Fused}} - x_k^{\mathrm{GT}}\right)^2 + \left(\hat{y}_k^{\mathrm{Fused}} - y_k^{\mathrm{GT}}\right)^2}. \tag{3-17}$$

考虑到 Q-Learning 采用表格式价值迭代进行策略更新，奖励函数不宜设计得过于复杂。本文采用与定位误差倒数相关的分段奖励形式：

$$r_k = \begin{cases} 100, & e_k = 0, \\ \mathrm{round}\left(\dfrac{100}{e_k}\right), & 0 < e_k < 1, \\ -100, & e_k \geq 1. \end{cases} \tag{3-18}$$

式 (3-18) 的设计与前述状态离散方式保持一致。当融合误差较小时，奖励值取正，且误差越小，奖励越大；当误差达到或超过 1 m 后，给予固定负奖励。

3.3.4 权重更新机制

在完成状态空间、动作空间与奖励函数定义后，RL-IFA 的核心问题可进一步归结为：智能体如何依据当前误差状态选择合适动作，并将该动作映射为对融合权重的实际更新，从而在连续交互过程中逐步学习得到更优的加权融合策略。

与固定权重方法不同，RL-IFA 并不预先假设 RSSI、AoA 和 PDR 三类观测在全局范围内具有恒定的重要性，而是将其权重分配过程建模为一个随时间滚动更新的离散序列决策过程。对于时刻 t，智能体首先根据当前融合误差对应的离散状态 s_t 查询动作价值，再执行相应的权重调整动作，随后由新的融合结果产生下一时刻状态与即时奖励，并进一步用于 Q 表更新。由此，整个系统形成“状态观测—动作选择—权重更新—结果反馈—价值迭代”的闭环学习机制。

具体而言，设上一时刻的融合权重向量为

$$\boldsymbol{\omega}_t = \left[\omega_t^{\mathrm{RSSI}}, \omega_t^{\mathrm{AoA}}, \omega_t^{\mathrm{PDR}}\right]^T, \tag{3-19}$$

其中各分量满足非负性与归一化约束。根据前文 3.3.2 中的动作空间设计，智能体在状态 s_t 下从动作集合 $\mathcal{A} = \{a_1, a_2, \ldots, a_9\}$ 中选取一个动作 a_t，并对 ω_t^{RSSI} 和 ω_t^{AoA} 实施“增加 / 减小 / 保持”三类基本操作，再由归一化约束计算 ω_t^{PDR}。因此，RL-IFA 的权重更新并不是连续优化求解，而是通过有限动作集合对当前权重向量进行离散修正。

设比例更新步长为 κ，对于可调权重分量 ω_t^x（其中 $x \in \{\mathrm{RSSI}, \mathrm{AoA}\}$），在动作 a_t 的作用下，其更新结果可写为

$$\omega_{t+1}^x = \begin{cases} (1+\kappa)\omega_t^x, & \text{若动作规定该分量增加,} \\ (1-\kappa)\omega_t^x, & \text{若动作规定该分量减小,} \\ \omega_t^x, & \text{若动作规定该分量保持不变.} \end{cases} \tag{3-20}$$

在得到 $\omega_{t+1}^{\mathrm{RSSI}}$ 和 $\omega_{t+1}^{\mathrm{AoA}}$ 之后，第三个分量由归一化关系确定为

$$\omega_{t+1}^{\mathrm{PDR}} = 1 - \omega_{t+1}^{\mathrm{RSSI}} - \omega_{t+1}^{\mathrm{AoA}}. \tag{3-21}$$

将更新后的权重代入位置级融合模型，可得下一时刻的融合位置输出

$$\boldsymbol{P}_{t+1}^{\mathrm{Fused}} = \omega_{t+1}^{\mathrm{RSSI}} \boldsymbol{P}_{t+1}^{\mathrm{RSSI}} + \omega_{t+1}^{\mathrm{AoA}} \boldsymbol{P}_{t+1}^{\mathrm{AoA}} + \omega_{t+1}^{\mathrm{PDR}} \boldsymbol{P}_{t+1}^{\mathrm{PDR}}. \tag{3-22}$$

由式 (3-22) 进一步计算融合误差 ε_{t+1}，即可依据 3.3.1 中的离散映射规则获得下一状态 s_{t+1}，并依据 3.3.3 中定义的奖励函数获得即时奖励 r_t。由此，动作 a_t 对系统的影响被完整地传递到“新状态—新奖励”这一强化学习更新环节中。

在策略执行阶段，RL-IFA 采用 ε-greedy 机制在“探索”与“利用”之间进行平衡。具体来说，在状态 s_t 下，智能体以概率 ε 从动作集合 $\mathcal{A}$ 中随机选择一个动作，以概率 $1-\varepsilon$ 选择当前 Q 值最大的动作，即

$$a_t = \begin{cases} \text{random action}, & \text{with probability } \varepsilon, \\ \arg\max\limits_{a \in \mathcal{A}} Q(s_t, a), & \text{with probability } 1-\varepsilon. \end{cases} \tag{3-23}$$

引入该策略的原因在于，若始终选择当前最优动作，则智能体在训练初期容易陷入局部最优的权重配置；而适当保留随机探索能力，则有助于其在不同误差状态下遍历更多的动作组合，从而更充分地学习各观测源在不同条件下的相对贡献。

在获得动作执行后的即时奖励 r_t 与下一状态 s_{t+1} 后，RL-IFA 采用标准 Q-Learning 规则对状态—动作价值函数进行迭代更新。设 $Q(s_t, a_t)$ 表示在状态 s_t 下执行动作 a_t 的价值估计，则其更新公式为

$$Q(s_t, a_t) \leftarrow Q(s_t, a_t) + \alpha \left[r_t + \gamma \max_{a \in \mathcal{A}} Q(s_{t+1}, a) - Q(s_t, a_t) \right], \tag{3-24}$$

其中，α 为学习率，γ 为折扣因子。式 (3-24) 表明，RL-IFA 对当前动作优劣的判断并不只取决于其带来的单步误差变化，还取决于执行该动作后系统未来可能获得的长期累计回报。也就是说，智能体在更新权重时并不是简单地“哪个动作让当前误差更小就选哪个”，而是在多步交互意义下逐步逼近能够带来更优长期融合效果的动作选择策略。

从算法流程上看，RL-IFA 的单步权重更新可概括为如下过程：首先，根据当前融合结果与真实位置之间的误差 ε_t，由式 (3-12) 将其映射为离散状态 s_t；其次，基于当前 Q 表和 ε-greedy 策略，从动作空间中选择动作 a_t；随后，依据式 (3-20) 和式 (3-21) 对权重向量进行更新，并计算新的融合位置 P_{t+1}^{Fused}；接着，根据新的融合误差生成奖励 r_t 和下一状态 s_{t+1}；最后，利用式 (3-24) 对 Q 表进行迭代修正，并进入下一轮决策。随着轨迹样本不断积累，Q 表中不同状态—动作对的价值差异将逐步拉开，最终形成从误差状态到权重更新动作的经验映射关系。

综上，RL-IFA 通过 Q-Learning 实现了对融合权重的闭环在线更新，其核心机制在于：将当前后验误差映射为离散状态，通过 ε-greedy 选择调权动作，并依据即时奖励与下一状态对 Q 表进行价值迭代，从而逐步学习得到不同误差等级下的最优权重更新策略。该机制为后续 PA-DQN 的改进提供了统一基线。

3.4 融合物理先验知识的 PA-DQN 智能体设计

在前述小节中，本文已经分别给出了 PA-DQN 的物理感知状态空间、增量式动作空间以及奖励函数设计。至此，单目标自适应融合定位问题的序列决策描述已经基本完成。在前述小节中，智能体在每一时刻根据环境感知状态 $\mathbf{S}_t$ 选择权重调整动作 a_t，并依据奖励反馈不断修正决策策略。进一步需要解决的问题在于，如何在高维连续状态空间条件下有效逼近状态–动作价值函数，并据此实现对最优融合策略的学习。

对于 RL-IFA 基线算法而言，其状态和动作均经过离散化处理，因此可以采用表格式 Q-Learning 直接对状态–动作值函数进行存储与更新。然而，PA-DQN

中的状态空间已不再是单一误差驱动的低维离散状态，而是扩展为包含物理层、统计层、几何层和历史决策信息的连续高维向量。若仍采用表格式方法，不仅会导致状态划分过粗、信息表达不足，还会使状态规模随特征维数增加而迅速膨胀，无法满足复杂城市环境下连续定位任务的求解需求。因此，本文采用深度 Q 网络（Deep Q-Network, DQN）对状态–动作价值函数进行近似表示，在 RL-IFA 序列决策框架基础上构建物理感知深度 Q 网络模型。

3.4.1　物理感知状态空间设计

RL-IFA 将融合定位误差离散化后作为智能体状态输入，其优点在于建模形式简单，便于采用表格式 Q-Learning 完成权重学习。但对于复杂城市环境下的单目标连续定位任务，这种状态定义仍然存在明显局限。首先，误差状态属于后验反馈，只有当融合结果已经偏离真实位置后，智能体才会通过奖励变化感知当前权重配置存在问题。其次，不同环境条件下产生的定位误差在数值上可能相近，但其成因并不一致。例如，RSSI 波动增强、AoA 主径偏置和 PDR 累积漂移都可能导致误差上升，仅凭误差大小本身，智能体无法区分当前失真主要来源于哪一路观测。这样得到的策略更接近于事后修正，而不是面向环境变化的主动调节。

为提高权重决策对复杂传播条件的适应性，本文在状态层显式引入能够反映传播复杂度、信号稳定性、跨模态一致性以及历史决策信息的物理感知特征。这里的“物理感知”并不是重新构造新的定位观测量，而是将前文 3.2.3 已提取的环境相关特征引入决策过程，使智能体在更新融合权重之前，先对当前观测质量和环境状态形成更有针对性的描述。

基于上述考虑，本文将第 t 个时刻的状态向量定义为

$$\mathbf{S}_t = \left[\sigma_{\tau,t},\ \sigma^2_{\mathrm{RSSI},t},\ \boldsymbol{D}_{\mathrm{RF\text{-}PDR},t},\ \boldsymbol{\omega}_{t-1}\right]^T, \tag{3-25}$$

其中，$\sigma_{\tau,t}$ 为 RMS 时延扩展，$\sigma^2_{\mathrm{RSSI},t}$ 为 RSSI 方差，$\boldsymbol{D}_{\mathrm{RF\text{-}PDR},t}$ 为无线观测定位结果与轨迹推算结果之间的几何一致性特征，$\boldsymbol{\omega}_{t-1}$ 为上一时刻的融合权重向量。

式 (3-25) 的关键不在于状态维数增加，而在于状态信息由“结果误差”转向“环境表征”。其中，$\sigma_{\tau,t}$ 反映当前传播路径在时延域上的离散程度。当多径成分增多、主导路径不再稳定时，该特征通常会增大，对应场景往往偏离理想视距传播条件。将其引入状态后，智能体可以在误差尚未明显扩大之前，先对当前传播环境的复杂程度作出响应。

$\sigma^2_{\mathrm{RSSI},t}$ 用于表征接收信号强度在局部时间窗口内的波动情况。当遮挡、深衰落或局部散射增强时，RSSI 序列通常会出现更明显的起伏，此时若仍维持较高的 RSSI 融合权重，往往会降低最终定位结果的稳定性。因此，RSSI 方差进入状态空间后，智能体能够对功率观测的可信度作出更细致的区分。

$\boldsymbol{D}_{\text{RF-PDR},t}$ 则用于描述不同定位分支之间的几何协调关系。与单独观察某一路观测质量不同，该特征反映的是无线观测侧位置估计与轨迹推算结果之间的一致程度。将这一特征纳入状态后，智能体不仅能感知单路观测是否稳定，还能进一步判断不同信息源之间是否相互支持。

除环境和观测特征外，本文还将上一时刻的权重向量 $\boldsymbol{\omega}_{t-1}$ 作为状态的一部分。引入 $\boldsymbol{\omega}_{t-1}$ 后，智能体在进行当前决策时能够保留必要的历史上下文，这也为后续增量式动作设计提供了基础。从方法层看，PA-DQN 的状态空间重构使权重分配不再只是对已发生误差的被动修正，而更接近于依据当前环境特征进行前置调节。

图 3-9 PA-DQN 物理感知状态空间及其与融合决策关系示意图

3.4.2 抑制轨迹锯齿的增量式连续动作空间设计

在 RL-IFA 基线算法中，动作用于对融合权重执行固定步长的离散增减操作。该设计虽然便于采用表格式 Q-Learning 实现，但其更新粒度较粗，且相邻时刻的动作切换容易导致权重向量发生突变。对于单目标连续定位任务而言，这种权重突变会进一步传递到位置级融合结果中，表现为融合轨迹局部不连续、拐点处抖动增强以及短时间尺度内的锯齿现象。

针对这一问题，本文在 PA-DQN 中引入增量式连续动作空间。其基本思想是：智能体不再直接从有限离散动作集合中选择粗粒度操作，而是根据当前物理感知状态输出一个连续动作增量向量，用于对上一时刻的融合权重进行小幅修正。

设时刻 t 的连续动作向量定义为

$$\mathbf{a}_t = \left[\Delta\omega_t^{\text{RSSI}}, \Delta\omega_t^{\text{AoA}}\right]^T, \tag{3-26}$$

其中，$\Delta\omega_t^{\text{RSSI}}$ 和 $\Delta\omega_t^{\text{AoA}}$ 分别表示当前时刻对 RSSI 和 AoA 融合权重的连续增量调整量。在给定上一时刻权重向量 $\boldsymbol{\omega}_{t-1}$ 的条件下，当前时刻的中间权重更新可写为

$$\tilde{\omega}_t^{\text{RSSI}} = \omega_{t-1}^{\text{RSSI}} + \Delta\omega_t^{\text{RSSI}}, \qquad \tilde{\omega}_t^{\text{AoA}} = \omega_{t-1}^{\text{AoA}} + \Delta\omega_t^{\text{AoA}}, \tag{3-27}$$

并进一步由归一化关系得到 $\tilde{\omega}_t^{\mathrm{PDR}} = 1 - \tilde{\omega}_t^{\mathrm{RSSI}} - \tilde{\omega}_t^{\mathrm{AoA}}$。

为了保证更新后的权重向量满足非负性和归一化约束，本文进一步引入投影算子 $\Pi(\cdot)$，将中间权重映射到可行域内，即

$$\boldsymbol{\omega}_t = \Pi\left(\tilde{\boldsymbol{\omega}}_t\right). \tag{3-28}$$

与离散动作空间相比，增量式连续动作空间使控制量天然具有连续性，更适合单目标轨迹跟踪场景下的时序决策需求。为了进一步限制权重突变幅度，本文对连续动作增量的取值范围设置边界约束，即 $\Delta\omega_t^x \in [-\delta, \delta]$。这种“缓变更新、持续纠偏”的特性，显著抑制了由策略突变带来的轨迹锯齿现象。

图 3-10 PA-DQN 增量式连续动作空间与权重更新机制示意图

3.4.3　兼顾短时抗扰与长时纠偏的奖励函数设计

在强化学习框架中，奖励函数决定了智能体对策略优劣的判断标准。对于单目标连续定位任务而言，若奖励仅由当前时刻的定位误差决定，则智能体往往会倾向于频繁调整权重，从而在连续轨迹上产生明显的抖动。

本文将 PA-DQN 的奖励设计为“精度驱动项 + 平滑约束项”的双重形式。设时刻 t 的定位误差为 ε_t，则基础精度奖励项为

$$r_t^{(1)} = -\varepsilon_t. \tag{3-29}$$

为了约束相邻时刻的权重变化幅度，引入平滑惩罚项：

$$r_t^{(2)} = -\lambda \left\|\boldsymbol{\omega}_t - \boldsymbol{\omega}_{t-1}\right\|_2, \tag{3-30}$$

其中，$\lambda > 0$ 为平滑惩罚系数。最终总奖励函数定义为

$$r_t = r_t^{(1)} + r_t^{(2)} = -\varepsilon_t - \lambda \left\|\boldsymbol{\omega}_t - \boldsymbol{\omega}_{t-1}\right\|_2. \tag{3-31}$$

式 (3-31) 使智能体在策略学习过程中同时面对两类约束：尽可能降低当前时刻的定位偏差，同时抑制不必要的控制震荡。这种联合驱动机制使 PA-DQN 的策略学习不再局限于“局部最优”，而是逐步形成兼顾即时精度和长期稳定性的融合决策。

图 3-11 PA-DQN 奖励函数中精度项与平滑项协同作用机理示意图

3.4.4 物理感知深度 Q 网络结构设计

PA-DQN 采用深度 Q 网络（DQN）对状态–动作价值函数进行近似表示。网络以物理感知状态向量 $\mathbf{S}_t$ 作为输入，通过多层非线性映射输出各候选动作对应的 Q 值估计：

$$\mathbf{Q}(\mathbf{S}_t;\theta) = \left[Q(\mathbf{S}_t, a_1;\theta), \ldots, Q(\mathbf{S}_t, a_{|\mathcal{A}|};\theta)\right]^T. \tag{3-32}$$

从结构上看，PA-DQN 采用全连接前馈神经网络架构。网络目标值依据 Bellman 最优性原理计算：

$$y_t = r_t + \gamma \max_{a'} Q(\mathbf{S}_{t+1}, a';\theta^-), \tag{3-33}$$

并采用均方误差损失函数进行优化：

$$L(\theta) = \mathbb{E}_{(\mathbf{S}_t, a_t, r_t, \mathbf{S}_{t+1})\sim\mathcal{D}}\left[\left(y_t - Q(\mathbf{S}_t, a_t;\theta)\right)^2\right]. \tag{3-34}$$

为了提升训练过程的稳定性，本文在 PA-DQN 中引入经验回放机制和目标网络机制。经验回放用于打破样本间的时序相关性，而目标网络则减弱了目标值随训练同步波动带来的震荡问题。图 3-12 给出了 PA-DQN 智能体网络结构与训练流程示意图。

图 3-12 PA-DQN 智能体网络结构与训练流程示意图

3.5　实验结果分析

为验证本文所提出 PA-DQN 方法在复杂城市环境下单目标连续定位任务中的有效性，本节结合仿真平台上的实验结果，从实验设置、总体性能、典型轨迹表现、不同信噪比条件下的鲁棒性以及消融结果五个方面进行分析。与前文方法设计相对应，本节重点考察三个问题：其一，物理感知状态空间是否能够提升整体定位精度；其二，增量式动作更新与稳定性约束是否能够改善轨迹连续性；其三，所提出方法在低信噪比和环境切换条件下是否仍能保持较好的鲁棒性。

3.5.1　实验设置

本文实验基于 Python 搭建的高保真定位仿真平台开展。为尽量贴近复杂城市环境中的单目标连续定位过程，仿真场景以前文构建的射线追踪传播环境为基础，在此基础上生成多类具有代表性的测试轨迹。具体而言，测试轨迹包括对角线路径、反对角线路径、矩形路径以及随机游走路径四种类型，总测试里程超过 200m。为模拟用户进出城市峡谷或街道拐角区域时的传播状态变化，部分轨迹中显式设置了 LOS→NLOS→LOS 的环境切换过程。信号传播采用射线追踪模型刻画多径效应，PDR 漂移则通过累积高斯噪声进行建模。

在网络训练配置方面，PA-DQN 采用离线训练、在线推理的方式完成参数学习。状态输入由 RMS 时延扩展、RSSI 方差、几何一致性特征以及上一时刻权重共同构成，动作采用增量式离散更新方式，步长统一设置为 $\Delta = 0.05$。训练过程中，经验回放池容量设置为 1×10^5，小批量采样大小设置为 64，折扣因子 γ 设置为 0.95，优化器采用 Adam，初始学习率设置为 1×10^{-3}。目标网络采用周期性更新策略，更新周期设置为 200 个训练步。探索策略采用 ε-greedy 机制，初始 ε 设为 1.0，并在训练过程中逐步衰减至 0.05。最大训练轮数设置为 800，以保证智能体在多类轨迹和多种传播条件下完成充分交互。为防止后期过拟合，在训练中同时采用学习率衰减与验证集性能监控策略。对于物理感知特征中的 RSSI 方差，滑动窗口长度设置为 $W = 20$；奖励函数中精度项和稳定性项的权重参数分别记为 k 和 λ，并在预实验基础上进行统一设定。表 3-2 给出了网络训练过程中所采用的主要参数设置。

在对比算法方面，本文选取单源定位方法与多种融合方法共同作为基准。单源方法包括 AoA-only 和 PDR-only，用于反映单一路径观测条件下的性能下界；传统融合方法采用扩展卡尔曼滤波（EKF）作为代表，其噪声参数通过离线调优获得；强化学习方法则包括标准 Q-Learning 基线算法 RL-IFA，以及本文提出的 PA-DQN。上述方法覆盖了单源定位、模型驱动融合以及强化学习驱动融合三类典型技术路线，能够较完整地反映 PA-DQN 相对不同方法的性能差异。具体参

表 3-2 PA-DQN 网络训练参数配置

参数名称	参数取值
状态输入	σ_τ，σ^2_{RSSI}，$D_{\text{RF-PDR}}$，$\boldsymbol{\omega}_{t-1}$
动作更新方式	增量式离散更新
权重更新步长 Δ	0.05
经验回放池容量	1×10^5
小批量采样大小	64
折扣因子 γ	0.95
优化器	Adam
初始学习率	1×10^{-3}
目标网络更新周期	200 个训练步
探索策略	ε-greedy
初始探索率 $\varepsilon_{\text{init}}$	1.0
最终探索率 $\varepsilon_{\text{final}}$	0.05
最大训练轮数	800
RSSI 方差滑动窗口长度 W	20

数如下表 3-2 所示。

在评价指标方面，本文采用均方根误差（RMSE）和 95% 分位误差（P95）作为核心量化指标。RMSE 用于反映预测轨迹与真实轨迹之间的平均欧氏距离偏差，体现整体定位精度；P95 用于描述误差分布尾部特性，从而刻画偶发性大误差和定位跳变现象。除数值指标外，本文还通过轨迹可视化结果、SNR 变化曲线以及消融对比表，对各算法的输出结果进行进一步分析。

为便于后续补充实验图像，图 3-13 预留为训练阶段收敛曲线图，建议展示奖励值、训练损失或平均误差随训练轮数变化的趋势；图 3-14 预留为四类典型轨迹与场景设置示意图。

3.5.2 总体性能比较

首先，对所有测试轨迹上的平均性能进行统计，结果如表 3-3 所示。可以看出，单源方法中，PDR-only 和 AoA-only 的误差均明显偏大，说明单一路径观测在复杂城市环境下难以稳定支撑连续定位任务。EKF 作为传统融合方法，相较单源方法已有一定改善，但在环境切换和观测退化条件下，其性能仍受限于固定模型假设。RL-IFA 通过强化学习实现了融合权重的自适应调整，整体精度进一步提高，但由于其状态构造仍主要依赖后验误差反馈，因此提升幅度有限。相比

图 3-13 PA-DQN 训练阶段的收敛过程示意图

图 3-14 复杂城市环境下典型测试轨迹与场景设置示意图

之下，PA-DQN 在总体测试集上取得了最低的 RMSE 和 P95，表明其在整体精度和尾部误差控制方面均优于对比方法。

表 3-3 不同算法在总体测试集上的性能对比

方法	RMSE (m)	P95 (m)
PDR-only	12.83	21.45
AoA-only	15.21	25.88
EKF	7.34	13.02
RL-IFA	5.91	10.56
PA-DQN	2.15	3.87

从相对提升幅度看，PA-DQN 相较 EKF 和 RL-IFA 的定位精度分别提升约 70.7% 和 63.6%。这一结果表明，在复杂城市环境中，仅依赖固定模型假设的传统融合方法或仅依赖后验误差反馈的强化学习方法，都难以充分适应传播条件和观测质量的动态变化；在状态空间中引入物理感知特征后，智能体能够更准确地识别当前环境状态并及时调整融合策略，从而在整体上获得更低的定位误差。

3.5.3 典型轨迹结果分析

为了进一步分析不同算法在连续定位任务中的轨迹表现，本文选取矩形路径、对角线路径、反对角线路径以及随机游走路径四类典型测试轨迹进行可视化比较，结果如图 3-20 所示。为便于后续插入论文中的原始结果图，本图建议采用四幅子图形式，分别对应四类典型轨迹。

从整体趋势看，单源方法在不同轨迹条件下均存在较明显的局部偏离。PDR-only 由于误差随时间累积，其轨迹在长距离运动过程中逐渐偏离真实路径；AoA-only 则在非视距和强反射条件下更容易出现局部跳变。EKF 的轨迹相较单源方法更平滑，但在环境快速切换区段仍可观察到较明显的偏移。RL-IFA 通过动态权重更新在一定程度上改善了上述问题，但在局部区段仍存在由权重切换引起的折线化现象。

相比之下，PA-DQN 在四类轨迹上的输出整体更接近真实轨迹。在矩形路径中，转角位置的偏移较小；在对角线和反对角线路径中，穿越 LOS/NLOS 切换区段时轨迹保持较好的连续性；在随机游走路径中，其局部轨迹抖动相对较弱。该结果说明，物理感知状态空间与增量式动作更新机制能够在连续定位场景中有效抑制由观测突变和权重震荡引起的轨迹不连续问题。

图 3-15 不同算法在典型测试轨迹下的连续定位结果对比

此外，为进一步突出环境切换区段的局部行为，图 3-16 预留为典型轨迹局部放大图，可重点展示 LOS/NLOS 边界附近不同算法的局部偏移与轨迹平滑性差异。

3.5.4 不同信噪比条件下的鲁棒性分析

除典型轨迹分析外，本文进一步考察不同算法在多种信噪比条件下的鲁棒性表现。结果如图 3-21 所示，其中横轴表示信噪比，纵轴表示对应条件下的 RMSE。

可以看出，随着信噪比降低，各算法的定位误差均呈上升趋势，但不同方法的退化速率存在明显差异。AoA-only 对噪声最为敏感，在低信噪比条件下误差增大最为明显；EKF 和 RL-IFA 的性能也随信噪比降低而逐步下降。相比之下，

图 3-16 典型轨迹局部区段的定位结果放大对比图

PA-DQN 的误差曲线整体更平缓，在低信噪比区间仍保持较低 RMSE，说明其对观测退化具有更强的适应能力。

这一结果与前文方法设计是一致的。由于 PA-DQN 在决策过程中不仅利用后验误差，还引入了 RMS 时延扩展、RSSI 方差和几何一致性等状态特征，因此在信道质量下降时，智能体能够更早地感知观测退化趋势，并通过权重调整减弱不可靠观测对融合结果的影响。由此，其在低信噪比条件下仍能保持较稳定的性能输出。

图 3-17 不同算法在多种信噪比条件下的 RMSE 对比曲线

为补充说明不同算法在尾部误差上的变化，图 3-18 预留为不同信噪比条件下的 P95 对比曲线图，用于展示各算法在恶劣信道条件下的尾部鲁棒性差异。

3.5.5　消融实验分析

为分析 PA-DQN 各关键模块的独立作用，本文进一步开展消融实验。具体而言，分别移除物理感知状态空间、增量式动作空间以及稳定性奖励项，并比较其性能变化，结果如表 3-5 所示。

从结果看，移除物理感知状态空间后，RMSE 由 2.15 m 上升至 6.89 m，说明状态空间中引入的传播与观测特征对整体精度具有决定性作用。移除增量式动作空间后，RMSE 上升至 4.52 m，同时稳定性指标由 0.04 恶化至 0.28，表明动作更新方式直接影响连续轨迹中的权重震荡程度。移除稳定性奖励项后，RMSE

图 3-18 不同算法在多种信噪比条件下的 P95 对比曲线

表 3-4 PA-DQN 各关键模块的消融实验结果

模型变体	RMSE (m)	稳定性指标
Full PA-DQN	2.15	0.04
w/o Physics-Aware State	6.89	0.09
w/o Incremental Action	4.52	0.28
w/o Stability Reward	2.48	0.17

虽仅小幅上升至 2.48 m，但稳定性指标明显恶化，说明奖励函数中的平滑约束主要作用于轨迹连续性而非单步误差本身。

综合来看，物理感知状态空间主要决定了智能体对环境变化的辨识能力，是精度提升的主要来源；增量式动作空间与稳定性奖励项则主要作用于权重更新过程，能够抑制局部震荡并改善轨迹平滑性。三者共同作用，构成了 PA-DQN 在复杂城市环境下取得较优连续定位性能的主要原因。

为便于后续补充更加直观的图形结果，图 3-19 预留为消融实验柱状图，可分别展示不同模块移除后 RMSE 和稳定性指标的变化情况。

图 3-19 PA-DQN 消融实验结果的图形化对比

3.5.6　本节小结

本节通过实验设置说明、总体性能统计、典型轨迹可视化、不同信噪比条件下的误差曲线以及消融实验，对 PA-DQN 的实验表现进行了分析。结果表明，PA-DQN 在总体精度、尾部误差控制、低信噪比条件下的稳定性以及连续轨迹平滑性方面均优于对比方法。实验现象与前文方法设计保持一致，说明在强化学习融合决策中引入物理感知状态空间、增量式动作更新机制和联合奖励函数后，能够更好地适应复杂城市环境中的观测退化与状态切换过程。

图 3-20 不同算法在典型测试轨迹下的连续定位结果对比

3.5.7　不同信噪比条件下的鲁棒性分析

除典型轨迹分析外，本文进一步考察不同算法在多种信噪比条件下的鲁棒性表现。结果如图 3-21 所示，其中横轴表示信噪比，纵轴表示对应条件下的 RMSE。

可以看出，随着信噪比降低，各算法的定位误差均呈上升趋势，但不同方法的退化速率存在明显差异。AoA-only 对噪声最为敏感，在低信噪比条件下误差增大最为明显；EKF 和 RL-IFA 的性能也随信噪比降低而逐步下降。相比之下，PA-DQN 的误差曲线整体更平缓，在低信噪比区间仍保持较低 RMSE，说明其对观测退化具有更强的适应能力。

这一现象与前文方法设计是一致的。由于 PA-DQN 在决策过程中不仅利用后验误差，还引入了 RMS 时延扩展、RSSI 方差和几何一致性等状态特征，因此在信道质量下降时，智能体能够更早地感知观测退化趋势，并通过权重调整减弱不可靠观测对融合结果的影响。由此，其在低信噪比条件下仍能保持较为稳定的性能输出。

3.5.8　消融实验分析

为分析 PA-DQN 中各关键模块的独立作用，本文进一步开展消融实验。具体而言，分别移除物理感知状态空间、增量式动作空间以及稳定性奖励项，并比较其性能变化，结果如表 3-5 所示。

从结果看，移除物理感知状态空间后，RMSE 由 2.15 m 上升至 6.89 m，说明

图 3-21 不同算法在多种信噪比条件下的 RMSE 对比曲线

表 3-5 PA-DQN 各关键模块的消融实验结果

模型变体	RMSE (m)	稳定性指标
Full PA-DQN	2.15	0.04
w/o Physics-Aware State	6.89	0.09
w/o Incremental Action	4.52	0.28
w/o Stability Reward	2.48	0.17

状态空间中引入的传播与观测特征对整体精度具有决定性作用。移除增量式动作空间后，RMSE 上升至 4.52 m，同时稳定性指标由 0.04 恶化至 0.28，表明动作更新方式直接影响连续轨迹中的权重震荡程度。移除稳定性奖励项后，RMSE 虽仅小幅上升至 2.48 m，但稳定性指标明显恶化，说明奖励函数中的平滑约束主要作用于轨迹连续性而非单步误差本身。

综合来看，物理感知状态空间主要决定了智能体对环境变化的辨识能力，是精度提升的主要来源；增量式动作空间与稳定性奖励项则主要作用于权重更新过程，能够抑制局部震荡并改善轨迹平滑性。三者共同作用，构成了 PA-DQN 在复杂城市环境下取得较优连续定位性能的主要原因。

3.5.9 本节小结

本节通过总体性能统计、典型轨迹可视化、不同信噪比条件下的误差曲线以及消融实验，对 PA-DQN 的实验表现进行了分析。结果表明，PA-DQN 在总体精度、尾部误差控制、低信噪比条件下的稳定性以及连续轨迹平滑性方面均优于对比方法。实验现象与前文方法设计保持一致，说明将物理感知状态空间、增量式动作更新机制和联合奖励函数引入强化学习融合决策后，能够更好地适应复杂城市环境中的观测退化与状态切换过程。

第四章　基于无人机信号成像与跨模态视觉检测的多目标并发定位方法

4.1　基于无人机空间扫描的多目标定位问题描述与信号成像建模

4.1.1　多目标并发定位场景与任务定义

本章研究的对象为复杂城市环境下地面非法低轨卫星终端的多目标并发定位问题。与第三章中面向单目标连续跟踪的定位任务不同，本章关注的是：在同一观测时刻或同一空间区域内，存在多个非法终端同时活动时，如何依托低成本无人机平台完成对多个被定位目标的联合识别与位置判定。这里，无人机平台并不是被定位对象，而是承担空间扫描、信号采集和定位解算任务的机动观测平台；地面非法终端则是定位系统需要识别和估计位置的辐射源目标。

从任务形式上看，多目标并发定位与单目标定位存在本质差异。单目标场景下，系统主要关注单个目标位置的连续估计，其核心问题通常表现为轨迹误差抑制与状态更新稳定性；而在多目标场景下，系统不仅需要判断目标是否存在，还需要同时回答“有多少个目标”和“每个目标位于何处”两个问题。设在给定观测区域内共有 K 个同时活动的地面非法终端，其真实位置集合记为

$$\mathcal{P} = \{\mathbf{p}_1, \mathbf{p}_2, \dots, \mathbf{p}_K\}, \qquad \mathbf{p}_k = [x_k, y_k]^T,\ k = 1, 2, \dots, K, \tag{4-1}$$

其中，K 表示当前区域内真实目标数量，$\mathbf{p}_k$ 为第 k 个目标的二维平面坐标。多目标并发定位的目标是：无人机平台根据在空间扫描过程中获得的无线观测数据，对集合 $\mathcal{P}$ 进行估计，并给出目标数目及其对应位置。

在本文场景中，无人机平台通过飞行观测方式对目标区域执行空间扫描。受飞行航迹、驻留时间、传感器视场和载荷能力等因素限制，无人机不可能在整个区域内连续、同步地获得全域信号场，而是只能在有限位置获取离散观测样本。也就是说，本章所处理的多目标定位问题，从观测层面上首先表现为基于无人机机动采样的空间离散感知问题。与固定基站阵列或密集地面测量不同，这种观测方式具有较强的灵活性和区域覆盖能力，但同时也引入了采样稀疏、观测不均匀和局部信息缺失等问题。

进一步地，复杂城市环境中的高层建筑、街道走廊、玻璃幕墙以及其他反射界面，会使无人机接收到的信号同时包含真实目标响应、多径反射分量和背景噪声扰动。对于单目标场景，这些因素主要表现为位置估计偏差；而在多目标场景中，上述因素还会对目标数量判定产生直接影响。当多个地面终端同时存在时，不同目标的空间响应可能发生局部重叠，噪声扰动可能造成局部伪峰，多径反射

还可能在非真实位置形成附加热点。由此可见，多目标并发定位不再是若干单目标定位结果的简单叠加，而是一个同时涉及目标检测、目标区分和目标定位的联合问题。

从工程实现角度看，传统多目标无线定位方法通常依赖逐目标搜索、逐目标分离或迭代残差消除等串行处理方式。该类方法在目标数量较少时仍可工作，但当目标并发数增加时，其计算负担通常随目标数上升而增加，同时在强多径和高噪声条件下容易出现漏检与虚警并存的情况。对于低成本无人机平台而言，这种处理方式难以同时满足复杂环境下的实时性和稳定性要求。因此，本章的任务并不只是提高单个目标的位置估计精度，更重要的是建立一种适合无人机机动观测场景的多目标联合判定方法，使系统能够在有限计算开销下，对目标区域内多个非法终端的空间分布进行有效识别。

基于上述认识，本文将第四章的问题进一步表述为：无人机平台在目标区域上空或周边执行空间扫描任务，通过采集由多个地面非法终端共同形成的离散无线观测，构建目标区域的空间信号分布表征，并在此基础上完成多目标的并发识别与定位。后续章节将表明，针对这一问题，若仍直接在离散观测点或局部峰值层面进行判定，容易受到稀疏采样、噪声和多径干扰影响；因此，有必要先将无人机采集到的离散观测转换为具有区域结构的信号图像，再借助视觉检测方法在图像域内完成多目标定位。图 4-1 给出了本章所对应的多目标并发定位场景示意图。

图 4-1 基于低成本无人机平台的地面多目标非法终端并发定位场景示意图

4.1.2 无人机稀疏采样、噪声扰动与局部多峰问题分析

在基于无人机平台的多目标并发定位任务中，目标区域的空间信号分布并不是以连续场形式被直接观测，而是由无人机沿飞行航迹对不同空间位置进行离散采样后间接获得。受飞行高度、航迹长度、悬停时间、采样周期以及平台载荷能力等因素约束，无人机通常只能在有限观测点处获取接收信号强度信息，而无法对目标区域完成高密度、全覆盖的连续测量。因此，从观测形式上看，本章所处理的问题首先表现为一种空间稀疏采样条件下的多目标定位问题。

设无人机在目标区域内共获取 N 个采样点，其空间坐标与对应观测值记为

$$\mathcal{D} = \left\{(\mathbf{s}_i, r_i)\right\}_{i=1}^{N}, \qquad \mathbf{s}_i = [x_i, y_i]^T, \tag{4-2}$$

其中，$\mathbf{s}_i$ 表示第 i 个采样点的位置，r_i 表示对应位置处的接收信号强度观测值。对于包含 K 个目标的场景，r_i 一般可写为

$$r_i = \sum_{k=1}^{K} h_k(\mathbf{s}_i; \mathbf{p}_k) + n_i, \tag{4-3}$$

其中，$h_k(\mathbf{s}_i; \mathbf{p}_k)$ 表示第 k 个真实目标在位置 $\mathbf{s}_i$ 处产生的空间响应，$\mathbf{p}_k$ 为第 k 个目标的真实位置，n_i 为观测噪声项。式 (4-3) 表明，每一个离散采样值实际上都是多个目标响应与噪声扰动的叠加结果，而非某一单独目标的纯净观测。

若进一步考虑理想路径损耗模型，则单个目标的空间响应可近似表示为

$$h_k(\mathbf{s}_i; \mathbf{p}_k) = P_k - 10\eta \log_{10}\left(d_{ik}\right), \qquad d_{ik} = \|\mathbf{s}_i - \mathbf{p}_k\|_2, \tag{4-4}$$

其中，P_k 表示第 k 个目标的等效发射强度，η 为路径损耗指数，d_{ik} 为采样点与目标之间的欧氏距离。式 (4-4) 仅描述了理想条件下目标响应随距离衰减的基本趋势，而在复杂城市环境中，受遮挡、散射和局部反射影响，实际观测通常会偏离这一理想关系。

从空间形态上看，若仅存在单一真实目标且噪声较弱，则其在连续空间内的响应一般应表现为围绕目标中心逐渐衰减的单峰结构。设理想连续响应记为 $f(\mathbf{x})$，噪声扰动记为 $n(\mathbf{x})$，则实际观测场可表示为

$$\tilde{f}(\mathbf{x}) = f(\mathbf{x}) + n(\mathbf{x}). \tag{4-5}$$

在理想条件下，$f(\mathbf{x})$ 往往仅在目标附近存在单一主极值点；但当 $n(\mathbf{x})$ 在局部区域内产生较强波动时，$\tilde{f}(\mathbf{x})$ 的梯度和 Hessian 结构可能发生变化，使得原本围绕单一目标形成的连续响应在局部上分裂为多个相邻极值点。对于离散采样情形，这一现象可进一步表示为

$$\hat{r}_i = r_i + \delta_i, \tag{4-6}$$

其中，δ_i 表示由测量抖动、采样误差和随机噪声引入的附加扰动。当部分采样点的 δ_i 明显偏大时，原本应由单一目标形成的局部能量团簇，可能在离散观测图中表现为多个分裂高点。

为了说明这一点，可将局部极值集合记为

$$\mathcal{M} = \left\{\mathbf{m}_1, \mathbf{m}_2, \ldots, \mathbf{m}_L\right\}, \qquad \mathbf{m}_l \in \Omega, \tag{4-7}$$

其中，Ω 为观测区域，$\mathbf{m}_l$ 表示第 l 个局部极大值位置，L 为局部极值点总数。在理想单目标条件下，通常有 $L \approx 1$；而在稀疏采样和噪声扰动作用下，可能出现 $L > 1$ 的情况，即同一真实目标对应多个局部峰值。这说明局部极值点数与真实目标数之间并不总是保持一致。

对于无人机机动采样平台而言，上述问题会因采样分布不均匀而进一步加剧。无人机沿既定航迹飞行时，不同区域的采样密度与相对观测角度并不完全相同，局部样本缺失会降低对真实空间响应边界的刻画能力，从而使观测场的局部形态更容易受个别异常样本支配。换言之，稀疏采样不仅意味着测量点较少，更意味着空间响应的区域结构难以仅依赖离散数值点稳定恢复。

在多目标并发场景中，这种局部多峰现象具有更直接的工程影响。传统方法往往默认“一个显著峰值对应一个真实目标”，并据此通过峰值个数估计目标数量、通过峰值位置估计目标坐标。然而在式 (4-7) 所表示的局部极值集合中，多个峰值未必对应多个不同终端，它们也可能来自同一目标在噪声和采样扰动下形成的分裂响应。若系统直接依据峰值点数完成目标判定，则会将同一真实目标误识别为多个目标候选点，从而导致虚警率升高。

因此，在基于无人机的多目标并发定位任务中，问题的关键并不只是如何寻找空间高值点，而是如何判断若干局部高值之间是否属于同一连续响应区域。对后续方法设计而言，这意味着判定单元不能继续停留在单点极值层面，而应进一步转向区域结构层面的聚合表达与判别。图 4-2 给出了无人机稀疏采样与噪声扰动条件下局部多峰现象的示意图。

图 4-2 无人机稀疏采样与噪声扰动条件下的局部多峰现象示意图

4.1.3 多径鬼影干扰下传统峰值判定方法的局限性

除噪声诱发的局部多峰问题外，复杂城市环境中的多径传播还会进一步引入鬼影干扰，使传统峰值判定方法面临更严重的虚警风险。对于无人机平台而言，由于观测对象位于地面区域，而建筑外立面、玻璃幕墙、街道峡谷和金属设施等反射体普遍存在，目标信号在传播过程中往往会经历反射、绕射和散射等过程。无人机接收到的并非仅有来自真实终端的主路径信号，而是多条传播路径叠

加后的复合响应。

若将第 k 个目标在空间位置 $\mathbf{x}$ 处的接收响应记为 $g_k(\mathbf{x})$。

4.1.4　基于射线追踪的复杂城市传播场建模

为构建能够反映复杂城市环境传播机理的 Radio Map，本文并未直接将无人机采集到的离散 RSSI 样本视为纯插值问题处理，而是首先引入基于射线追踪的城市传播场建模方法，对目标区域内的电磁传播过程进行高保真刻画。这样做的原因在于，多目标非法终端定位场景中的信号分布并不仅由目标位置决定，还同时受到建筑物遮挡、街道走廊效应、玻璃幕墙反射以及非视距传播等多种环境因素影响。若缺乏对这些传播机理的显式建模，仅依赖简单插值方法构建 Radio Map，则难以准确再现真实目标响应与多径鬼影之间的空间结构差异。

基于上述考虑，本文首先利用 OpenStreetMap（OSM）地理信息数据获取目标区域内建筑物的平面轮廓、高度信息及其空间分布关系，并在 MATLAB Site Viewer 环境中完成三维场景重建。通过将建筑物几何边界、街道走向和开阔区域映射到统一空间坐标系，构建出适用于无线传播分析的城市数字场景。设目标区域为

$$\Omega \subset \mathbb{R}^2, \tag{4-8}$$

其对应的三维建筑集合记为

$$\mathcal{B} = \left\{ \boldsymbol{B}_1, \boldsymbol{B}_2, \ldots, \boldsymbol{B}_M \right\}, \tag{4-9}$$

其中，$\boldsymbol{B}_m$ 表示第 m 个建筑物在三维空间中的几何实体，$\boldsymbol{M}$ 为场景内建筑物总数。基于集合 $\mathcal{B}$，可进一步定义目标区域内的可视距传播区、遮挡区以及强反射区，为后续射线传播分析提供几何基础。

在传播建模阶段，本文采用 MATLAB Antenna Toolbox 与 RF Propagation Toolbox 提供的射线追踪模块，对目标终端至无人机观测平台之间的传播路径进行计算。对于给定目标位置 $\mathbf{p}_k$ 与无人机观测位置 $\mathbf{q}_i$，接收信号可视为多条有效传播路径的叠加，即

$$r_{ik}(t) = \sum_{\ell=1}^{L_{ik}} \alpha_{ik}^{(\ell)} s_k\left(t - \tau_{ik}^{(\ell)}\right) e^{-j2\pi f_c \tau_{ik}^{(\ell)}} + n_{ik}(t), \tag{4-10}$$

其中，L_{ik} 表示从目标 k 到观测点 i 的有效传播路径数，$\alpha_{ik}^{(\ell)}$ 和 $\tau_{ik}^{(\ell)}$ 分别表示第 ℓ 条路径的复增益和传播时延，f_c 为载波频率，$s_k(t)$ 为目标发射信号，$n_{ik}(t)$ 为噪声项。式 (4-22) 表明，接收信号不仅包含主路径分量，还显式包含由建筑反射、散射与绕射产生的附加路径分量，这些分量共同决定了最终空间信号场的分布结构。

在路径级传播结果基础上，本文进一步计算各观测位置处的接收功率，并将其作为后续 Radio Map 重构的原始输入。若记第 i 个观测点处来自第 k 个目标的接收功率为 $P_{r,ik}$，则其可写为

$$P_{r,ik} = \sum_{\ell=1}^{L_{ik}} \left|\alpha_{ik}^{(\ell)}\right|^2 P_{t,k}, \tag{4-11}$$

其中，$P_{t,k}$ 为第 k 个目标的发射功率。对于多目标场景，若目标区域内存在 K 个同时活动的地面非法终端，则无人机在位置 $\mathbf{q}_i$ 处的总接收功率可进一步表示为

$$P_r(\mathbf{q}_i) = \sum_{k=1}^{K} P_{r,ik} + \varepsilon_i, \tag{4-12}$$

其中，ε_i 表示背景噪声与测量误差项。式 (4-24) 给出了后续热力图构建所需的空间功率观测基础。

与仅依据经验路径损耗公式或简单空间插值构建信号场相比，基于射线追踪的传播建模具有两方面作用。第一，它能够在场景层面显式引入建筑几何结构、非视距遮挡和反射路径等环境因素，使得到的空间功率分布具有明确的物理依据。第二，它能够为多目标场景中的鬼影分析提供路径级解释。具体而言，若某一位置处出现显著高值，但其主贡献来自反射路径而非真实目标直达路径，则该高值区域在后续 Radio Map 中更可能表现为鬼影响应，而非真实终端中心。这一点对于后续的抗鬼影检测具有直接意义。

需要说明的是，本文在第四章中采用射线追踪建模，并不意味着最终的多目标定位仍停留在传统数值求解框架中。相反，射线追踪的主要作用在于构建具有物理一致性的底层空间传播场，为后续 RSSI 栅格映射与 Radio Map 生成提供可靠输入。也就是说，射线追踪负责回答“空间中信号如何传播”的问题，而后续的信号成像与目标检测则负责回答“如何从空间响应中识别真实目标”的问题。二者的在本章中分别对应传播场建模层与跨模态识别层，共同构成多目标并发定位方法的前端表征基础。

基于上述建模结果，本文后续将不直接对式 (4-24) 中的离散功率观测进行逐点判定，而是进一步将其映射到二维规则网格中，构建适合视觉检测网络处理的无线电热力图。下一小节将给出基于空间扫描观测的 RSSI 栅格映射方法，并说明如何在射线追踪生成的空间响应基础上完成 Radio Map 的图像化表达。

4.1.5 无人机 RSSI 空间映射与高斯重构方法

□ 值位置与目标位置近似一致，峰值个数可以作为目标数目的代理量。然而在复杂城市环境下，该前提往往不成立。前一小节已经说明，噪声与采样扰动会使同一目标附近出现多个局部高值；而本节进一步表明，多径传播还会在真实目

图 4-3 基于 OSM 数据与 MATLAB 工具链的复杂城市射线追踪传播场建模示意图

标之外生成额外的伪响应区域。这样一来，峰值集合中同时混杂了三类不同来源的结构：真实目标主峰、同源分裂峰以及多径鬼影峰。若仅依据峰值幅度或局部邻域极大关系进行判定，则难以准确区分这三类结构。

为了说明这一局限，可设传统峰值判定规则为

$$\mathbf{x} \in \mathcal{T} \quad \Longleftrightarrow \quad r(\mathbf{x}) > \tau \text{ 且 } r(\mathbf{x}) = \max_{\mathbf{y}\in\mathcal{N}(\mathbf{x})} r(\mathbf{y}), \tag{4-13}$$

其中，τ 为幅值阈值，$\mathcal{N}(\mathbf{x})$ 表示 $\mathbf{x}$ 的局部邻域，$\mathcal{T}$ 为被判定为目标候选点的集合。该规则本质上只利用了“是否超过阈值”和“是否为局部极大值”两类信息，而没有刻画高值点所属区域的整体纹理、扩散结构和空间连续性。因此，只要鬼影峰或噪声峰满足式 (4-13)，便会被纳入候选目标集合，导致虚警产生。

对于无人机平台的多目标扫描任务，这一问题还具有两个进一步特点。其一，鬼影位置和强度与无人机相对观测视角、建筑布局以及目标分布共同相关，因此不同飞行位置下鬼影的空间表现并不完全稳定；其二，当多个真实目标同时存在时，不同目标的主响应与鬼影响应可能发生局部重叠，使得单纯依赖峰值强度排序的方法更难完成正确区分。这表明，在无人机多目标并发定位场景下，传统峰值方法不仅难以解决虚警问题，也难以在高并发条件下保持稳定的目标数量估计能力。

从空间结构角度看，真实辐射源与鬼影响应之间的差异并不主要体现在单个峰值幅度上，而更多体现在区域层面的形态特征上。真实目标通常对应更集中、更连续的局部能量团簇，而鬼影响应往往表现为位置偏移、扩散不均匀或边界不规则的次级响应。若判定机制仍以“点”为单位，则这些区域性差异无法被有效利用；只有当目标表示由“局部峰值”扩展为“区域结构”后，真实目标、同源多峰与多径鬼影之间的差异才有可能在统一框架下得到区分。

因此，本节分析表明，在复杂城市环境中，传统峰值判定方法的局限并不仅仅体现在阈值设置困难，而在于其判定单元过于局部，无法充分利用空间响应的整体形态信息。这一结论也进一步说明，后续方法设计应当从逐峰检测转向区域

级判别，通过对空间信号场进行成像重构和结构化分析，提高多目标并发定位中的抗虚警能力。图 4-4 给出了多径鬼影干扰下传统峰值判定方法失效机理的示意图。

图 4-4 多径鬼影干扰下传统峰值判定方法失效机理示意图

4.1.6 从离散观测到信号成像的跨模态建模思路

由前两小节分析可知，在基于无人机平台的多目标并发定位场景中，直接基于离散观测点或局部峰值进行目标判定存在两类突出问题：其一，稀疏采样与噪声扰动会使同一真实目标附近出现多个局部极值，从而破坏“一个峰值对应一个目标”的基本假设；其二，多径传播会在真实目标位置之外生成鬼影响应，使局部高值点集合中混入与真实目标无关的伪候选点。由此，若仍将目标判定建立在局部极值搜索和逐峰判别的基础上，则系统需要同时解决同源多峰聚合、伪峰剔除和鬼影识别等多个问题，且这些问题彼此耦合，处理过程对阈值设置和局部规则设计较为敏感。

针对上述困难，本文不再将多目标并发定位问题视为离散观测点上的峰值搜索问题，而是将其重构为一个面向区域信号分布的跨模态识别问题。其基本思想是：首先利用无人机在空间扫描过程中获得的离散 RSSI 观测，在二维空间网格上重构连续信号场表示；随后将该连续场进一步表征为可供视觉网络处理的无线电热力图（Radio Map）；最后在图像域内完成真实目标区域的检测与定位。这样处理后，原本需要在数值域内分别处理的局部多峰聚合、虚警抑制和目标分离问题，便可在统一的区域结构判别框架下得到处理。

具体而言，设无人机在观测区域 Ω 内获得的离散观测集合为

$$\mathcal{D} = \left\{(\mathbf{s}_i, r_i)\right\}_{i=1}^{N}, \qquad \mathbf{s}_i = [x_i, y_i]^T, \tag{4-14}$$

其中，$\mathbf{s}_i$ 和 r_i 的含义与前文相同。本文首先在目标区域上建立二维规则网格

$$\mathcal{G} = \left\{\mathbf{g}_{u,v} \mid u = 1, 2, \ldots, U,\ v = 1, 2, \ldots, V\right\}, \tag{4-15}$$

其中，$\mathbf{g}_{u,v}$ 表示第 (u, v) 个网格单元对应的空间位置，U 和 V 分别为网格在两个方向上的离散分辨率。在此基础上，通过空间映射、插值和平滑操作，将离散观

测集合 $\mathcal{D}$ 转换为定义在网格 $\mathcal{G}$ 上的连续场近似

$$\hat{R}(u,v) = \mathcal{F}\left(\mathcal{D}, \mathbf{g}_{u,v}\right), \tag{4-16}$$

其中，$\mathcal{F}(\cdot)$ 表示由离散采样到连续场重构的映射过程，$\hat{R}(u,v)$ 为第 (u,v) 个网格位置处的重构信号强度值。于是，整个观测区域的无线空间响应可进一步表示为二维矩阵

$$\mathbf{R} = \left[\hat{R}(u,v)\right]_{U\times V}, \tag{4-17}$$

式 (4-17) 即构成了本章后续所使用的 Radio Map 表征。

与原始离散采样点集合相比，Radio Map 的作用并不只是完成数值上的插值补全，更重要的是将目标响应从离散点提升为具有空间邻域关系的区域结构。对于同一真实目标而言，噪声诱发的若干局部高值点在重构后的热力图中通常会落入同一连续响应区域，其空间相关性可以通过区域纹理和能量扩散结构得到体现；对于多径鬼影而言，尽管其在局部上也可能形成高亮斑块，但其空间形态、边界特征和邻域衰减方式通常与真实目标存在差异。因此，在 Radio Map 上，目标判定问题不再等价于“寻找多少个局部最大值”，而更接近于“识别多少个具有真实目标特征的响应区域”。

从这一角度看，将离散无线观测映射为 Radio Map，本质上完成了从数值域到图像域的跨模态表征转换。转换前，系统面对的是离散观测点、局部峰值和阈值判据；转换后，系统面对的是区域结构、纹理分布和目标检测问题。二者的差异在于：前者依赖局部单点的幅值大小，容易受噪声和多径干扰；后者则利用空间邻域信息、区域连续性和结构特征完成目标识别，更适合处理同源多峰聚合和鬼影抑制问题。

进一步地，若记传统峰值判定的目标候选集合为

$$\mathcal{T}_{\text{peak}} = \left\{ \mathbf{x} \in \Omega \mid r(\mathbf{x}) > \tau,\ r(\mathbf{x}) = \max_{\mathbf{y}\in\mathcal{N}(\mathbf{x})} r(\mathbf{y}) \right\}, \tag{4-18}$$

则本文所采用的图像域判定思路可表述为：在 Radio Map $\mathbf{R}$ 上寻找满足目标区域特征约束的响应子区域集合

$$\mathcal{T}_{\text{region}} = \left\{\mathcal{B}_1, \mathcal{B}_2, \ldots, \mathcal{B}_{\hat{K}}\right\}, \tag{4-19}$$

其中，$\mathcal{B}_m$ 表示第 m 个检测到的候选目标区域，$\hat{K}$ 为检测输出的目标数量。与式 (4-18) 相比，式 (4-19) 的判定单元由点集扩展为区域集合，这意味着目标识别过程不再只关注单个位置处的局部极值，而是同时考虑区域范围、局部纹理和邻域结构等多种信息。

基于上述建模思路，本章将多目标并发定位问题进一步转化为 Radio Map 上的目标检测问题。具体做法是：首先将无人机采集到的离散 RSSI 观测映射为二维无线电热力图；然后利用改进的 Anchor-Free YOLOv7 检测网络在图像域内识别真实目标响应区域，并输出目标中心位置及其空间范围；最后，根据检测结果完成多目标位置估计。该技术路线的意义在于，它将原本在数值域内难以稳定处理的局部多峰与鬼影问题，转化为更适合由深度视觉网络处理的区域结构识别问题，从而为后续的多目标并发定位提供统一的输入表征和求解框架。

因此，本节给出的跨模态建模思路，不仅是对离散观测形式的一种表征转换，更是本章整体方法设计的起点。后续 4.2 节将首先讨论如何从无人机空间扫描所得的离散 RSSI 样本出发，构建具有连续性和纹理可分性的 Radio Map；在此基础上，4.3 节再进一步给出面向 Radio Map 场景的改进 Anchor-Free YOLOv7 检测网络设计。图 4-5 给出了本章从无人机离散观测到 Radio Map 成像，再到跨模态视觉检测的整体流程示意图。

图 4-5 从无人机离散观测到 Radio Map 成像及跨模态视觉检测的整体流程示意图

4.2 面向多目标定位的 Radio Map 重构方法

4.2.1 基于射线追踪的复杂城市传播场建模

为构建能够反映复杂城市环境传播机理的 Radio Map，本文并未直接将无人机采集到的离散 RSSI 样本视为纯插值问题处理，而是首先引入基于射线追踪的城市传播场建模方法，对目标区域内的电磁传播过程进行高保真刻画。这样做的原因在于，多目标非法终端定位场景中的信号分布并不仅由目标位置决定，还同时受到建筑物遮挡、街道走廊效应、玻璃幕墙反射以及非视距传播等多种环境因素影响。若缺乏对这些传播机理的显式建模，仅依赖简单插值方法构建 Radio Map，则难以准确再现真实目标响应与多径鬼影之间的空间结构差异。

基于上述考虑，本文首先利用 OpenStreetMap（OSM）地理信息数据获取目标区域内建筑物的平面轮廓、高度信息及其空间分布关系，并在 MATLAB Site Viewer 环境中完成三维场景重建。通过将建筑物几何边界、街道走向和开阔区

域映射到统一空间坐标系，构建出适用于无线传播分析的城市数字场景。设目标区域为

$$\Omega \subset \mathbb{R}^2, \tag{4-20}$$

其对应的三维建筑集合记为

$$\mathcal{B} = \left\{ \boldsymbol{B}_1, \boldsymbol{B}_2, \ldots, \boldsymbol{B}_M \right\}, \tag{4-21}$$

其中，$\boldsymbol{B}_m$ 表示第 m 个建筑物在三维空间中的几何实体，$\boldsymbol{M}$ 为场景内建筑物总数。基于集合 $\mathcal{B}$，可进一步定义目标区域内的可视距传播区、遮挡区以及强反射区，为后续射线传播分析提供几何基础。

在传播建模阶段，本文采用 MATLAB Antenna Toolbox 与 RF Propagation Toolbox 提供的射线追踪模块，对目标终端至无人机观测平台之间的传播路径进行计算。对于给定目标位置 $\mathbf{p}_k$ 与无人机观测位置 $\mathbf{q}_i$，接收信号可视为多条有效传播路径的叠加，即

$$r_{ik}(t) = \sum_{\ell=1}^{L_{ik}} \alpha_{ik}^{(\ell)} s_k\left(t - \tau_{ik}^{(\ell)}\right) e^{-j2\pi f_c \tau_{ik}^{(\ell)}} + n_{ik}(t), \tag{4-22}$$

其中，L_{ik} 表示从目标 k 到观测点 i 的有效传播路径数，$\alpha_{ik}^{(\ell)}$ 和 $\tau_{ik}^{(\ell)}$ 分别表示第 ℓ 条路径的复增益和传播时延，f_c 为载波频率，$s_k(t)$ 为目标发射信号，$n_{ik}(t)$ 为噪声项。式 (4-22) 表明，接收信号不仅包含主路径分量，还显式包含由建筑反射、散射与绕射产生的附加路径分量，这些分量共同决定了最终空间信号场的分布结构。

在路径级传播结果基础上，本文进一步计算各观测位置处的接收功率，并将其作为后续 Radio Map 重构的原始输入。若记第 i 个观测点处来自第 k 个目标的接收功率为 $P_{r,ik}$，则其可写为

$$P_{r,ik} = \sum_{\ell=1}^{L_{ik}} \left| \alpha_{ik}^{(\ell)} \right|^2 P_{t,k}, \tag{4-23}$$

其中，$P_{t,k}$ 为第 k 个目标的发射功率。对于多目标场景，若目标区域内存在 K 个同时活动的地面非法终端，则无人机在位置 $\mathbf{q}_i$ 处的总接收功率可进一步表示为

$$P_r(\mathbf{q}_i) = \sum_{k=1}^{K} P_{r,ik} + \varepsilon_i, \tag{4-24}$$

其中，ε_i 表示背景噪声与测量误差项。式 (4-24) 给出了后续热力图构建所需的空间功率观测基础。

与仅依据经验路径损耗公式或简单空间插值构建信号场相比，基于射线追踪的传播建模具有两方面作用。第一，它能够在场景层面显式引入建筑几何结构、非视距遮挡和反射路径等环境因素，使得到的空间功率分布具有明确的物理依据。第二，它能够为多目标场景中的鬼影分析提供路径级解释。具体而言，若某一位置处出现显著高值，但其主贡献来自反射路径而非真实目标直达路径，则该高值区域在后续 Radio Map 中更可能表现为鬼影响应，而非真实终端中心。这一点对于后续的抗鬼影检测具有直接意义。

需要说明的是，本文在第四章中采用射线追踪建模，并不意味着最终的多目标定位仍停留在传统数值求解框架中。相反，射线追踪的主要作用在于构建具有物理一致性的底层空间传播场，为后续 RSSI 栅格映射与 Radio Map 生成提供可靠输入。也就是说，射线追踪负责回答“空间中信号如何传播”的问题，而后续的信号成像与目标检测则负责回答“如何从空间响应中识别真实目标”的问题。二者在本章中分别对应传播场建模层与跨模态识别层，共同构成多目标并发定位方法的前端表征基础。

基于上述建模结果，本文后续将不直接对式 (4-24) 中的离散功率观测进行逐点判定，而是进一步将其映射到二维规则网格中，构建适合视觉检测网络处理的无线电热力图。下一小节将给出基于空间扫描观测的 RSSI 栅格映射方法，并说明如何在射线追踪生成的空间响应基础上完成 Radio Map 的图像化表达。

图 4-6 基于 OSM 数据与 MATLAB 工具链的复杂城市射线追踪传播场建模示意图

4.2.2 基于空间扫描观测的 RSSI 栅格映射方法

在完成复杂城市传播场建模之后，本文进一步将无人机平台在空间扫描过程中获取的离散 RSSI 观测映射到二维规则网格上，为后续 Radio Map 连续化表达提供统一输入。对于本章所研究的多目标并发定位任务而言，射线追踪建模给出了具有物理一致性的空间传播响应，而目标检测网络所需要的则是尺寸统一、坐标明确且能够直接输入卷积网络的二维灰度图像。因此，在射线追踪生成的离散空间响应与后续热力图表达之间，有必要建立一层栅格化映射过程。

本文采用 OpenStreetMap 导出的北京市典型街区真实地理数据作为场景基

础，在 MATLAB Site Viewer 环境下完成三维场景重建，并结合 Antenna Toolbox 与 RF Propagation Toolbox 进行射线追踪仿真。场景模型中包含建筑物高度、材质以及几何轮廓等信息，能够较为准确地反映城市峡谷环境中的遮挡、反射与散射特性。在此基础上，本文已生成覆盖目标区域 27,546 个网格点的高分辨率传播数据，用于构建后续多目标定位所需的 Radio Map 输入。

在多目标定位部分，无人机作为机动观测平台，对目标区域执行空间扫描任务。扫描过程中，无人机搭载多通道接收机，在不同空间位置采集地面非法终端产生的 RSSI 响应。设无人机共获取 N 个观测样本，第 i 个观测点在二维平面内的坐标记为 $\mathbf{q}_i = [x_i, y_i]^T$，对应 RSSI 观测值记为 r_i，则全部观测样本可写为

$$\mathcal{D} = \left\{(\mathbf{q}_i, r_i)\right\}_{i=1}^{N}. \tag{4-25}$$

为了将无人机沿航迹获取的无序离散观测组织成适合图像处理的规则表示，本文在目标区域上建立二维规则网格。结合当前多目标验证场景，本文以 500 m× 500 m 的室外复杂街区作为成像区域，并将该区域按照固定空间分辨率划分为规则栅格。每个栅格单元对应一个确定的空间位置，所有观测样本均根据其平面坐标投影到对应网格内。

在映射过程中，若某一栅格内仅包含一个观测点，则直接将其 RSSI 值赋给该栅格；若同一栅格内包含多个观测样本，则采用均值融合方式生成该栅格的初始信号强度值。对于未被无人机直接扫描到的网格单元，在本阶段不进行强行估计，而是保留为空值或零值，并在后续高斯平滑步骤中统一完成连续化补全。经过这一处理后，原始散点观测被统一组织为二维矩阵

$$\mathbf{S} = [S(u, v)]_{H \times W}, \tag{4-26}$$

其中，H 和 W 分别表示栅格在两个方向上的离散尺度，$S(u, v)$ 表示第 (u, v) 个栅格单元上的初始 RSSI 值。

4.2.3　OSM 场景建模与 MATLAB 工具链实现

本文采用 OpenStreetMap（OSM）导出的北京市典型街区地理信息数据作为底层场景来源，并结合 MATLAB Site Viewer、Antenna Toolbox 与 RF Propagation Toolbox 完成复杂城市环境下的传播场构建与仿真计算。

OpenStreetMap 是一种开放式地理信息数据源，能够提供道路、建筑物轮廓、地物边界以及部分建筑属性信息。与人工构造的规则街区模型相比，OSM 数据能够较好保留真实城市环境中的道路走向、楼宇布局和街区几何特征。对于本章研究的多目标非法终端定位任务而言，这一点十分重要。因为多径鬼影、遮挡效应以及局部空间响应的非均匀性，本质上都与建筑物的真实分布密切相关。若场

景模型仅采用理想化规则网格，则难以反映城市峡谷环境中由玻璃幕墙、高层建筑和街道走廊共同引起的传播异常。本文首先从 OSM 中导出目标区域的建筑物平面轮廓与空间分布信息，并结合已有建筑高度、材质和几何边界数据，构建三维建筑集合。随后，在 MATLAB Site Viewer 中完成场景导入与可视化检查。Site Viewer 的主要作用并不是直接参与传播计算，而是为整个建模流程提供统一的三维场景展示与校验环境。通过该工具，可以直观检查建筑物位置、道路边界、观测区域范围以及无人机平台与目标区域之间的空间关系，从而保证后续传播仿真所使用的场景与实际研究区域保持一致。

在传播建模方面，本文主要使用 MATLAB Antenna Toolbox 与 RF Propagation Toolbox。Antenna Toolbox 负责天线相关参数与辐射特性的建模，包括发射端和接收端的天线方向图、工作频段以及阵列结构等；RF Propagation Toolbox 则负责基于射线追踪方法计算电波在复杂场景中的传播路径，包括视距路径、反射路径以及由建筑边界引起的附加传播分量。对本文而言，二者并不是相互独立的两个模块，而是共同构成三维城市环境下的传播仿真工具链：前者负责描述“用什么天线发、用什么天线收”，后者负责描述“信号在什么环境里如何传播”。

结合目标场景任务需求，本文在 MATLAB 工具链中重点完成了以下几项工作。第一，确定了目标区域的空间范围，并利用 OSM 数据建立对应的三维建筑场景；第二，在 Site Viewer 中对场景几何结构进行可视化检查，确保楼宇轮廓、街道走向和观测范围设置正确；第三，在 Antenna Toolbox 中设定发射端与接收端的基本参数，用于描述地面终端与无人机平台之间的无线链路；第四，在 RF Propagation Toolbox 中调用射线追踪传播模型，计算不同空间位置上的接收功率分布。基于这一流程，本文最终获得了覆盖目标区域 27,546 个网格点的高分辨率传播数据，为后续 RSSI 栅格映射和 Radio Map 重构提供了基础输入。

图 4-7 基于 OSM 与 MATLAB 工具链的复杂城市场景建模流程示意图

4.3　基于知识蒸馏的鲁棒多无人机协同多目标定位方法

4.3.1　多无人机掉点场景下的协同定位背景与问题引入

在复杂城市环境和强电磁干扰条件下，利用多无人机集群对地面终端进行协同感知与联合定位，具有较高的应用价值。然而，上述优势建立在无人机集群能够稳定工作这一前提之上。在实际任务中，空地协同网络的运行条件远比理想环境复杂。无人机节点可能受到恶劣天气、电池续航耗尽、硬件或通信模块故障、障碍物遮挡以及局部电磁干扰等多种不可控因素影响，从而在任务执行过程中发生随机失效或链路中断。对于协同定位系统而言，这种现象可进一步表现为部分无人机节点观测缺失，即原本由多节点共同构成的完整 RSSI 观测矩阵在某一时刻出现不规则残缺。由于掉点位置和掉点数量通常难以提前确定，因此系统面临的是一种动态拓扑退化条件下的定位问题，而不是固定传感器规模下的静态估计问题。

从数据形式上看，掉点会直接破坏多无人机协同定位中输入特征的完整性。设系统在理想状态下由 N 架无人机共同执行感知任务，则对于任一地面终端，其完整观测应由 N 个节点联合给出；而当其中部分节点失效后，系统可获得的有效观测仅剩下一个规模可变的子集。这样一来，原本固定维度的输入特征会退化为维数随掉点数量动态变化的不规则残缺输入。对于传统基于多层感知机或卷积神经网络的定位架构而言，其网络结构和参数学习过程通常建立在固定维度输入假设之上，一旦观测中出现节点级缺失，模型往往只能依赖补零、截断或直接丢弃样本等方式进行处理。

这类刚性处理方式在工程上存在明显局限。首先，补零或简单缺失填充只能在形式上维持输入维度一致，并不能恢复掉点节点原本提供的空间感知信息；其次，直接丢弃含缺失样本的做法会显著降低有效数据利用率，并进一步削弱模型在复杂场景中的泛化能力；最后，也是更为关键的一点，传统模型在面对局部观测失效时，通常难以有效挖掘残存节点之间仍然存在的空间相关性与协同约束关系，因此定位性能往往会随着掉点数量增加而快速下降。对于面向实际部署的多无人机协同系统而言，这种对节点完整性的高度依赖意味着一旦局部故障出现，整个定位链路的鲁棒性将受到明显削弱。

因此，本章所关注的问题并不只是在完整无人机网络下如何提高定位精度，而是进一步考虑：当多无人机协同网络在执行任务过程中发生随机掉点时，如何在残缺观测条件下尽可能保持接近完整网络的定位能力。换言之，本章需要解决的是一种面向动态节点失效场景的鲁棒定位问题，其核心目标是在不增加额外硬件部署成本的前提下，利用已有完整网络中蕴含的空间感知规律，对掉点条件

下的信息缺失进行有效补偿。

从方法选择上看，仅依靠能够接收不规则输入的自适应网络结构，并不能从根本上突破掉点导致的信息缺失瓶颈。其原因在于，残缺观测本身所包含的信息量已经低于完整网络条件下的观测上限，若仅依赖硬标签从头训练学生模型，则其学习过程仍然容易受限于局部最优和有限观测视角，最终性能往往停留在残缺数据本身所对应的较低上界附近。基于这一认识，本文引入知识蒸馏思想，将完整无人机网络条件下形成的全量观测视为一种更高质量的监督来源。

具体而言，本文考虑构建一个教师—学生协同定位框架。教师模型以完整无人机网络生成的 Radio Map 或完整射频指纹图作为输入，在全量节点观测条件下学习目标位置与空间观测之间的全局映射关系；学生模型则以随机掉点后的残缺 Radio Map 作为输入，在真实掉点场景下完成定位推断。与仅使用硬标签监督不同，学生模型在训练过程中不仅接受真实地理栅格标签的常规约束，还通过模仿教师模型输出的软标签分布，学习完整网络在无掉点条件下形成的空间判别逻辑。这样一来，学生模型即使在局部观测缺失的情况下，仍有可能通过蒸馏得到的特权信息，逼近完整网络的判别能力。

4.3.2 知识蒸馏基本原理与掉点鲁棒定位建模

针对上一小节所述的多无人机随机掉点问题，本文引入知识蒸馏（Knowledge Distillation）思想，对残缺观测条件下的协同定位模型进行鲁棒性增强。我们认为，虽然掉点后的无人机网络只能获得部分节点观测，但在离线训练阶段，系统仍然可以利用完整无人机网络所形成的全量观测数据，学习更充分的空间几何映射关系。若能够将这种由完整网络学得的判别能力迁移到掉点网络中，则有望在不增加额外硬件部署成本的前提下，缓解节点缺失所带来的性能退化。

从一般意义上看，知识蒸馏是一种教师—学生学习框架。教师模型通常具有更完整的输入视角或更强的表征能力，其输出不仅包含最终类别信息，还隐含了不同类别之间的相对相似性；学生模型则在输入受限或结构更轻量的条件下，通过模仿教师模型的输出分布来获得额外监督。与仅使用硬标签训练相比，蒸馏学习所利用的软标签能够保留类别间的细粒度关系，因此更适合在信息不完整条件下指导模型逼近高质量决策边界。

结合本章问题，本文考虑一个由 N 架无人机组成的协同感知网络，集合表示为

$$\mathcal{U} = \{u_1, u_2, \dots, u_N\}. \tag{4-27}$$

在某一定位时刻，第 i 架无人机的空间位置记为

$$\boldsymbol{P}_i = (x_i, y_i, z_i). \tag{4-28}$$

对于地面终端 j，无人机 u_i 测得的 RSSI 值记为 $R_{i,j}$。为了同时表征测量值及其空间来源，本文将单节点感知特征定义为

$$X_{i,j} = [x_i, y_i, z_i, R_{i,j}]. \tag{4-29}$$

进一步地，假设待定位区域被均匀划分为 M 个离散栅格

$$\mathcal{G} = \{g_1, g_2, \dots, g_M\}, \tag{4-30}$$

则终端定位问题可由连续坐标估计转化为多分类问题。对于任一目标终端，系统最终输出其位于各栅格的概率分布向量

$$Y = [y_1, y_2, \dots, y_M]^T, \qquad Y \in \mathbb{R}^M, \tag{4-31}$$

其中，y_m 表示目标位于栅格 g_m 的预测概率，最终定位结果由最大概率对应的栅格标签给出。

在理想状态下，所有无人机节点均正常工作，此时系统可获得完整观测集合

$$\mathcal{X}_{\text{complete}} = \{X_{1,j}, X_{2,j}, \dots, X_{N,j}\}. \tag{4-32}$$

该完整观测经过前文的空间扫描、栅格映射与 Radio Map 重构后，能够形成无掉点条件下的完整射频指纹图，并作为教师网络的输入基础。对应地，教师模型可表示为

$$\mathbf{p}^T = f_T(\mathcal{X}_{\text{complete}}), \tag{4-33}$$

其中，$f_T(\cdot)$ 表示教师网络，$\mathbf{p}^T \in \mathbb{R}^M$ 为教师网络输出的栅格概率分布。

在实际任务中，由于部分无人机可能掉点，系统可获得的有效观测仅为一个残缺子集。为描述该过程，本文引入节点状态指示变量

$$S_i \in \{0, 1\}, \tag{4-34}$$

其中，$S_i = 1$ 表示第 i 架无人机工作正常，$S_i = 0$ 表示该节点已掉点。于是，掉点条件下的残缺观测集合可表示为

$$\mathcal{X}_{\text{missing}} = \{X_{i,j} \mid S_i = 1\}, \tag{4-35}$$

其输入维度由原本固定的 N 动态退化为 $N - k$，其中 k 为掉点节点数。对应的学生网络输出记为

$$\mathbf{p}^S = f_S(\mathcal{X}_{\text{missing}}), \tag{4-36}$$

其中，$f_S(\cdot)$ 表示学生网络，$\mathbf{p}^S \in \mathbb{R}^M$ 为学生网络对各栅格的预测概率分布。

在仅使用真实标签监督的情况下，学生网络通过交叉熵损失完成训练。设真实栅格标签对应的 one-hot 向量为 $\mathbf{y}$，则常规监督损失可写为

$$\mathcal{L}_{\mathrm{ce}} = -\sum_{m=1}^{M} y_m \log p_m^S. \tag{4-37}$$

然而，当输入仅由残缺观测构成时，学生网络可利用的信息量显著低于教师网络，若仍仅依赖硬标签训练，则其学习过程容易受限于局部最优解，难以逼近完整网络条件下的判别性能。

为此，本文引入蒸馏监督。具体地，教师网络输出经过温度系数 T_d 软化后，可得到软标签分布

$$q_m^T = \frac{\exp(z_m^T/T_d)}{\sum_{n=1}^{M}\exp(z_n^T/T_d)}, \tag{4-38}$$

其中，z_m^T 为教师网络在第 m 个栅格上的 logits 输出。类似地，学生网络的软化输出为

$$q_m^S = \frac{\exp(z_m^S/T_d)}{\sum_{n=1}^{M}\exp(z_n^S/T_d)}. \tag{4-39}$$

相比于 one-hot 标签，软标签分布不仅保留了最优类别信息，还反映了目标在不同栅格之间的相对相似性。对于本章所研究的地理栅格定位任务而言，这种信息尤为重要，因为相邻栅格之间往往具有空间连续性和几何相关性，而完整教师网络正是通过全量节点观测学习到了这种全局空间映射规律。

基于此，本文采用 Kullback–Leibler 散度度量教师与学生输出分布之间的差异，其蒸馏损失定义为

$$\mathcal{L}_{\mathrm{kd}} = T_d^2 \sum_{m=1}^{M} q_m^T \log \frac{q_m^T}{q_m^S}. \tag{4-40}$$

最终，学生网络的训练目标由硬标签监督与蒸馏监督共同组成，即

$$\mathcal{L} = \alpha\mathcal{L}_{\mathrm{ce}} + \beta\mathcal{L}_{\mathrm{kd}}, \tag{4-41}$$

其中，α 和 β 分别表示两类损失项的权重系数。

式 (4-41) 所对应的训练目标可以作如下理解：$\mathcal{L}_{\mathrm{ce}}$ 保证学生网络能够利用真实栅格标签完成基本分类定位任务，$\mathcal{L}_{\mathrm{kd}}$ 则进一步迫使学生网络在面对残缺观测时，去模仿完整教师网络所形成的全局判别逻辑。这样一来，学生模型学习到的就不再只是残缺输入条件下如何拟合硬标签，而是在完整观测视角下，该目标更可能位于哪些栅格、不同栅格之间的概率关系如何变化。这正是知识蒸馏能够用于掉点鲁棒定位的根本原因。

综上所述，本文将多无人机掉点场景下的协同定位问题建模为一个基于知识迁移的多分类学习问题：教师网络利用完整无人机网络构建的 Radio Map 学习全局空间几何映射，学生网络则在随机掉点条件下通过模仿教师输出分布，提高残缺观测条件下的定位鲁棒性。基于上述建模，下一小节将进一步给出教师网络与学生网络的具体架构设计。

4.3.3　教师—学生网络架构设计

为实现完整无人机网络知识向掉点网络的有效迁移，本文构建了一个面向多无人机协同定位任务的教师—学生蒸馏架构。该架构以图神经网络为基础，将多无人机空间观测组织为动态图输入，并分别在完整节点条件和残缺节点条件下完成全局特征提取与栅格分类。其核心目标在于：教师网络在全量节点观测下学习完整的空间几何映射规律，学生网络在随机掉点条件下利用残存节点信息完成定位推断，并通过蒸馏损失逼近教师网络的输出分布。

从输入形式上看，教师网络与学生网络对应两类不同的观测状态。教师网络接收完整无人机网络所形成的全量节点特征集合

$$\mathcal{X}_{\text{complete}} = \{X_{1,j}, X_{2,j}, \ldots, X_{N,j}\}, \tag{4-42}$$

其中，单节点特征 $X_{i,j} = [x_i, y_i, z_i, R_{i,j}]$ 由无人机空间位置与对应 RSSI 测量值共同构成。学生网络接收随机掉点条件下的残缺节点集合

$$\mathcal{X}_{\text{missing}} = \{X_{i,j} \mid S_i = 1\}, \tag{4-43}$$

其中，$S_i \in \{0, 1\}$ 表示节点状态，掉点后有效节点数由 N 退化为 $N - k$。两类输入在观测完整性上存在显著差异，这也是后续蒸馏学习的基础。

考虑到多无人机协同定位问题中各节点之间天然存在空间拓扑关系，本文不采用简单的向量拼接方式组织输入，而是将观测数据建模为图结构。具体而言，每一架无人机对应图中的一个节点，节点特征由其三维坐标与 RSSI 测量共同给出。对于教师网络，图中包含全部 N 个节点；对于学生网络，图中仅保留当前未掉点的 $N - k$ 个有效节点。为充分利用节点间的协同关系，本文在图构建阶段采用全连接策略，使任意两个有效节点之间都建立边连接。这样处理的目的在于避免人为限制节点间的信息传播范围，使网络能够在训练过程中自主学习不同空间位置之间的相关性强弱。

在图结构建立后，教师网络与学生网络均采用多层图注意力网络作为核心特征提取模块。图注意力层的作用在于，根据节点之间的特征相关性自适应分配邻域权重，从而在特征传播过程中突出更有判别价值的节点贡献。对于教师网络而言，多层图注意力结构能够在全量节点条件下学习完整的协同感知关系，

并形成对全局空间布局较为充分的表征；对于学生网络而言，同样的结构则能够在残缺拓扑条件下挖掘剩余节点之间仍然存在的空间补偿关系，从而缓解局部观测缺失带来的信息损失。

设经过图注意力层堆叠后，第 i 个节点的高层表示记为 $\mathbf{h}_i$，则教师网络在图级读出阶段采用全局平均池化，将全部节点特征汇聚为固定维度的图表示

$$\mathbf{h}_G^T = \frac{1}{N}\sum_{i=1}^{N}\mathbf{h}_i. \tag{4-44}$$

对应地，学生网络在残缺节点条件下得到的图级表示为

$$\mathbf{h}_G^S = \frac{1}{N-k}\sum_{i\in\mathcal{V}_{\text{act}}}\mathbf{h}_i, \tag{4-45}$$

其中，$\mathcal{V}_{\text{act}}$ 表示当前有效节点集合。采用全局平均池化的原因在于，该读出方式能够在保持输出维度固定的同时，自然适应输入节点数量的变化，为后续分类头提供统一形式的图级特征。

在读出层之后，教师网络与学生网络均采用多层感知机完成最终的栅格分类。教师网络的输出 logits 记为

$$\mathbf{z}^T = \text{MLP}(\mathbf{h}_G^T), \tag{4-46}$$

学生网络的输出 logits 记为

$$\mathbf{z}^S = \text{MLP}(\mathbf{h}_G^S). \tag{4-47}$$

两者的输出维度均为 $\boldsymbol{M}$，对应目标区域离散后的 $\boldsymbol{M}$ 个地理栅格类别。教师网络在完整输入条件下生成全局判别分布，学生网络则在残缺输入条件下给出对应的栅格概率预测。

在训练阶段，教师网络的 logits 经过温度系数 $\boldsymbol{T_d}$ 的 softmax 变换后，生成软标签分布，用于向学生网络提供额外监督；学生网络则同时保留两类输出，一类用于与真实栅格标签计算交叉熵损失，另一类用于与教师网络输出进行蒸馏匹配。由此，整个架构形成了完整观测指导残缺观测、教师网络监督学生网络的训练闭环。需要强调的是，这里教师模型与学生模型在总体结构上保持一致，但二者的输入视角不同：前者对应完整图输入，后者对应掉点后的残缺图输入。正是这种输入不对称性，使蒸馏学习能够在不增加额外硬件成本的情况下，将完整网络中学得的全局空间判别能力迁移到掉点网络中。

从结构设计角度看，本文所构建的教师—学生网络具有三点特点。其一，采用图结构建模多无人机观测，避免了固定维度输入对节点完整性的严格依赖；其

二，利用图注意力机制增强节点间空间相关性的自适应建模能力，使网络在掉点条件下仍可充分利用残存节点信息；其三，通过图级读出和统一分类头，将不同规模的节点输入映射为一致的栅格分类输出，从而为后续蒸馏训练提供了结构基础。

图 4-8 给出了本文教师—学生网络架构示意图。图中左侧为完整无人机网络输入下的教师模型，右侧为随机掉点后的学生模型，中间为蒸馏损失与监督关系。该图对应展示了完整图输入、残缺图输入、动态建图、图注意力特征提取、全局池化读出以及分类输出等关键模块之间的连接关系。

图 4-8 教师—学生网络架构示意图

综上，本文教师—学生网络架构并不是两个独立分类器的简单并列，而是一个围绕完整观测知识向残缺观测迁移而构建的协同学习框架。教师网络负责在全量节点条件下学习完整的空间几何映射规律，学生网络则在随机掉点条件下，通过图注意力传播、图级特征读出和蒸馏监督，尽可能恢复完整网络条件下的定位能力。基于该架构，下一小节将进一步给出面向残缺观测的蒸馏训练策略。

4.4　实验结果与分析

4.4.1　实验设置

为验证本文所提出的基于知识蒸馏的掉点鲁棒多无人机协同定位方法的有效性，本文在复杂城市环境下构建了多无人机协同定位实验平台，并围绕完整网络、随机掉点网络以及蒸馏增强网络三种条件开展对比实验。实验流程主要包括场景建模、数据集构建、掉点样本生成、教师网络训练、学生网络蒸馏训练以及测试分析六个环节。

在实验场景方面，本文采用基于真实地理信息数据构建的复杂城市场景作为验证环境。目标区域设置为 $500\,\mathrm{m} \times 500\,\mathrm{m}$ 的二维水平区域，并将其均匀划分为 20×20 个离散栅格，对应 $M = 400$ 个空间类别。通过这种方式，地面终端定位问题被转化为多分类问题，模型输出为终端位于 400 个候选栅格中的概率分

布。

在无人机网络配置方面，本文部署 $N = 16$ 架无人机组成协同感知网络。每架无人机在特定时刻具有已知三维空间坐标，并能够对地面终端发射信号进行 RSSI 测量。对于任一目标终端，单节点特征由无人机坐标与对应 RSSI 观测共同构成，即

$$X_{i,j} = [x_i, y_i, z_i, R_{i,j}]. \tag{4-48}$$

在完整网络条件下，系统能够获得全部 16 架无人机共同形成的完整观测；在掉点条件下，仅保留部分有效节点观测，形成残缺输入样本。

在数据集构建方面，本文首先基于复杂城市传播场建模结果生成全量观测数据，并进一步完成 RSSI 栅格映射与 Radio Map 重构。随后，以完整无人机网络生成的 Radio Map 作为教师网络输入，以随机掉点后的残缺 Radio Map 作为学生网络输入，并将对应地理栅格标签作为监督信息。为系统评估模型在拓扑退化条件下的鲁棒性，本文设置五种掉点比例，分别为 0%、12.5%、25%、37.5% 和 50%，对应掉点节点数分别为 0、2、4、6 和 8。通过随机采样不同掉点组合，构造训练与测试阶段所需的残缺观测样本。

在网络结构方面，教师模型与学生模型均采用三层图注意力网络作为核心特征提取模块。每层隐藏维度设置为 64，注意力头数设置为 4，激活函数采用 ReLU，Dropout 系数设置为 0.2。图级读出阶段采用全局平均池化，将变长节点集合映射为固定维度的图表示；分类头采用两层多层感知机，其结构设置为 $64 \rightarrow 128 \rightarrow 400$，最终输出 400 维栅格分类 logits。

在训练参数设置方面，本文采用 Adam 优化器对网络进行训练，初始学习率设为 1×10^{-3}，权重衰减系数设为 1×10^{-4}，批大小设置为 64。考虑到教师网络与学生网络的联合训练过程相对复杂，且学生模型需要在不同掉点比例下学习教师模型的输出分布，本文将最大训练轮数设为 800。为避免训练后期出现过拟合，同时提高收敛稳定性，本文采用 StepLR 学习率衰减策略，每 200 个 epoch 将学习率衰减为原来的 0.5，并设置 early stopping 机制，当验证集性能在连续 50 个 epoch 内无明显提升时终止训练。

在知识蒸馏参数方面，本文将温度系数设置为 $T_d = 4$，交叉熵损失与蒸馏损失的权重分别设为 $\alpha = 1.0$ 和 $\beta = 0.7$。其中，交叉熵损失用于保证学生网络能够根据真实栅格标签完成基本定位任务，蒸馏损失用于引导学生网络在残缺观测条件下逼近教师网络在完整观测条件下形成的输出分布。这样的参数设置既保证了真实标签监督的主导作用，也使教师网络的软标签信息能够对学生模型产生足够有效的约束。

在数据集划分方面，本文按照 70%、15%、15% 的比例将样本划分为训练集、

验证集和测试集。训练集用于教师网络与学生网络参数优化，验证集用于模型选择与早停判断，测试集则用于最终性能评估。为保证结果的稳定性，训练和测试阶段均在不同随机掉点组合下重复采样，以降低偶然拓扑分布对实验结果的影响。

在评价指标方面，本文主要从定位精度与掉点鲁棒性两个角度对模型进行评估。定位精度方面，采用分类准确率和平均定位误差作为核心指标；鲁棒性方面，则重点关注在不同掉点比例下学生网络性能的衰减程度，以及引入知识蒸馏后相对于未蒸馏学生网络的性能恢复幅度。通过上述实验设置，本文希望回答两个问题：其一，完整网络所学习到的全局空间知识能否通过蒸馏有效迁移到掉点网络中；其二，在不同掉点条件下，所提出方法是否能够保持更稳定的定位性能。

图 4-9 预留为实验总体流程示意图，用于展示数据集构建、掉点样本生成、教师训练、学生蒸馏训练以及测试分析之间的关系。

图 4-9 实验总体流程示意图

表 4-1 给出了本文实验所采用的主要参数设置。

4.4.2　结果与分析

在完成教师网络与学生网络训练后，本文分别从完整网络、随机掉点网络以及蒸馏增强网络三个角度对模型性能进行分析。实验关注的重点包括：完整观测条件下教师模型的定位能力、掉点条件下学生模型的性能退化情况，以及知识蒸馏对残缺观测定位性能的恢复效果。为便于展示，本文以下结果主要通过整体性能对比图、不同掉点比例下的鲁棒性曲线、典型样本可视化结果以及消融对比图进行说明。

首先，图 4-10 预留为教师网络、未蒸馏学生网络和蒸馏后学生网络的整体性能对比图。建议该图采用柱状图形式，横轴表示不同模型，纵轴表示分类准确率或平均定位误差。该图主要用于从整体层面说明完整网络、残缺网络以及蒸馏增强网络之间的性能差异。

表 4-1 实验参数设置表

参数名称	参数取值
目标区域大小	$500\,\mathrm{m} \times 500\,\mathrm{m}$
栅格类别数 $\boldsymbol{M}$	400
无人机数量 $\boldsymbol{N}$	16
掉点比例	0%, 12.5%, 25%, 37.5%, 50%
GAT 层数	3
隐藏维度	64
注意力头数	4
激活函数	ReLU
Dropout	0.2
图级读出方式	Global Average Pooling
分类头结构	$64 \rightarrow 128 \rightarrow 400$
最大训练轮数	800
批大小	64
初始学习率	1×10^{-3}
优化器	Adam
权重衰减	1×10^{-4}
学习率衰减策略	StepLR
衰减步长	200 epoch
衰减系数	0.5
Early stopping patience	50
温度系数 $\boldsymbol{T_d}$	4
损失权重 $\boldsymbol{\alpha}$	1.0
损失权重 $\boldsymbol{\beta}$	0.7
数据集划分	70% / 15% / 15%

图 4-10 教师网络、未蒸馏学生网络与蒸馏后学生网络的整体性能对比图

从整体结果看，教师网络在完整无人机观测条件下始终具有最优性能，这与其能够接收全量节点信息的输入条件一致。未蒸馏学生网络由于输入中存在随机掉点，其可利用的空间观测信息明显减少，因此在定位精度上出现较为明显的退化。相比之下，蒸馏后学生网络在相同残缺输入条件下能够获得更优的预测结果，说明教师网络在完整拓扑条件下学习到的全局空间判别规律，能够通过蒸馏监督有效迁移到学生网络中。该结果表明，知识蒸馏不仅改善了学生模型在训练阶段的收敛质量，更提高了其在残缺观测条件下的空间判别能力。

其次，为分析掉点比例对模型性能的影响，图 4-11 预留为不同掉点比例下的性能变化曲线。建议横轴表示掉点比例，纵轴表示分类准确率或平均定位误差，同时给出未蒸馏学生网络与蒸馏后学生网络两条曲线，以直观比较二者在拓扑退化条件下的鲁棒性差异。

图 4-11 不同掉点比例下的定位性能变化曲线

由该图可以看出，随着掉点比例逐步增大，两类学生网络的性能都会出现不同程度下降，这与有效观测节点数量减少所导致的信息损失相一致。然而，蒸馏后学生网络的性能曲线下降更缓，说明其对节点失效的敏感性明显低于未蒸馏学生网络。特别是在中高掉点比例条件下，蒸馏方法所带来的性能提升更为明显，这表明教师网络输出的软标签分布在残缺输入条件下发挥了补偿作用，使学

生模型能够在局部观测缺失的情况下仍维持较为稳定的全局判别能力。

进一步地，为更直观地展示模型在空间上的定位效果，图 4-12 预留为典型测试样本的栅格预测可视化结果。建议该图采用多子图形式，分别给出真实栅格位置、教师网络预测结果、未蒸馏学生网络预测结果以及蒸馏后学生网络预测结果，从而比较三类模型在空间位置判定上的差异。

图 4-12 典型测试样本的栅格预测可视化结果

从空间可视化结果可以看出，教师网络的预测通常与真实终端所在栅格最为接近，说明完整观测条件下其空间判别能力较强。未蒸馏学生网络在掉点条件下更容易出现栅格偏移和相邻类别混淆，尤其在目标位于边界区域或观测视角不足时，这种偏差更为明显。相比之下，蒸馏后学生网络虽然仍受到输入残缺的影响，但其预测结果整体上更接近教师网络和真实标签，说明蒸馏学习确实增强了学生模型对全局空间分布的恢复能力。

为进一步分析网络在不同无人机规模下的适应能力，图 4-13 预留为不同无人机数量条件下的性能对比图。建议横轴表示无人机数量，纵轴表示分类准确率或平均定位误差。该图主要用于说明协同节点规模对完整网络、未蒸馏学生网络以及蒸馏后学生网络性能的影响趋势。

图 4-13 不同无人机数量条件下的定位性能对比图

从该类结果中通常可以观察到，随着无人机节点数量增加，完整网络的观测覆盖能力持续提升，教师模型的整体性能随之提高。对学生网络而言，更多的初

始节点也意味着在掉点后仍可保留更多有效观测，因此整体定位精度也会得到改善。在相同节点规模下，蒸馏后学生网络始终优于未蒸馏学生网络，说明知识迁移机制并不依赖于某一固定网络规模，而具有较好的普适性。

此外，为反映模型在误差分布层面的表现，图 4-14 预留为不同模型的定位误差累计分布曲线。建议该图同时给出教师网络、未蒸馏学生网络和蒸馏后学生网络的误差 CDF 曲线，以比较不同模型在低误差区间和高误差区间的分布差异。

图 4-14 不同模型的定位误差累计分布曲线

误差累计分布曲线能够更直观地反映模型在整体测试样本上的误差稳定性。若蒸馏后学生网络的曲线整体向左上方偏移，则说明其在更多样本上能够取得更小的定位误差；若其在高误差尾部明显优于未蒸馏学生网络，则说明知识蒸馏不仅提高了平均性能，也降低了大误差样本出现的概率。对于实际部署而言，这种高误差尾部的抑制具有更强的工程意义，因为它意味着系统在极端掉点条件下仍具备一定的可用性。

最后，为验证各组成部分的有效性，表 4-2 预留为消融实验结果表。建议至少比较以下几种模型设置：仅使用交叉熵监督的学生模型、引入知识蒸馏监督的学生模型，以及不同温度系数或不同损失权重设置下的学生模型。该表用于从定量角度说明蒸馏机制与参数设置对最终性能的影响。

表 4-2 消融实验结果表

模型设置	准确率 / %	平均误差 / m	备注
仅交叉熵监督	[待补充]	[待补充]	无蒸馏
交叉熵 + 蒸馏监督	[待补充]	[待补充]	本文方法
不同温度系数设置	[待补充]	[待补充]	参数分析
不同损失权重设置	[待补充]	[待补充]	参数分析

综合上述结果可以看出，完整无人机网络能够为定位模型提供最充分的空间观测视角，而随机掉点会显著削弱传统学生模型的定位性能。通过引入知识蒸

馏机制，学生网络在面对残缺观测时不再仅依赖有限的硬标签监督，而是能够进一步学习教师模型在完整观测条件下形成的全局空间判别规律。实验结果表明，该机制能够有效减缓掉点条件下的性能退化，提升多无人机协同定位系统在复杂场景中的鲁棒性与工程可用性。

4.5 本章小结

本章面向复杂城市环境下的多无人机协同定位任务，围绕随机掉点条件下的鲁棒定位问题，提出了一种基于信号成像与知识蒸馏的协同定位方法。与传统依赖固定维度输入和完整节点观测的定位方法不同，本文重点考虑了多无人机网络在实际部署过程中可能出现的节点失效、链路中断和局部观测缺失现象，并在此基础上构建了面向残缺观测条件的鲁棒定位框架。

首先，针对复杂城市环境中射频传播机理复杂、离散观测难以直接用于定位的问题，本文基于真实地理信息数据和 MATLAB 工具链完成了复杂城市场景建模，并通过射线追踪获得了具有物理一致性的空间传播响应。在此基础上，进一步采用 RSSI 栅格映射与高斯平滑连续化表达方法，将无人机空间扫描获得的离散观测转化为具有区域结构的 Radio Map，为后续定位模型提供了统一输入表征。

其次，针对多无人机协同网络在随机掉点条件下输入维度不规则、传统刚性网络难以稳定处理的问题，本文将完整无人机网络生成的 Radio Map 作为教师输入，将掉点后的残缺 Radio Map 作为学生输入，构建了面向掉点鲁棒定位的教师—学生蒸馏框架。在该框架中，教师模型利用全量节点观测学习完整的空间几何映射关系，学生模型则在真实标签监督与软标签蒸馏监督的共同作用下，尽可能逼近完整网络条件下的定位能力。通过这种方式，本文在不增加额外硬件成本的前提下，实现了对缺失观测信息的有效补偿。

最后，实验结果表明，完整无人机网络能够为定位模型提供最充分的观测视角，而随机掉点会显著削弱未蒸馏学生网络的定位性能。相比之下，引入知识蒸馏后，学生模型在不同掉点比例条件下均表现出更稳定的分类精度和更小的定位误差，说明教师模型中学习到的全局空间判别规律能够有效迁移到残缺观测条件下的学生模型中。相关结果表明，本文方法能够在复杂场景中提升多无人机协同定位系统对节点失效的适应能力，增强系统的工程鲁棒性。

综上，本章从空间信号成像、残缺观测建模和知识迁移学习三个层面出发，完成了多无人机掉点条件下协同鲁棒定位方法的设计与验证。该方法为复杂环境中面向实际部署的多无人机协同定位提供了新的解决思路，也为后续进一步研究更大规模节点协同、更复杂掉点模式以及在线自适应蒸馏策略奠定了基础。

第五章　结论与展望

5.1　全文工作总结

本文面向复杂城市环境下非法低轨卫星终端的定位识别需求，围绕低成本无人机平台条件下的非合作式感知与定位问题，系统开展了单目标自适应融合定位与多无人机协同鲁棒定位两方面研究。论文以复杂城市环境中的遮挡、多径、非视距传播以及无人机协同网络不稳定等实际问题为背景，针对传统方法在动态环境适应性、信息融合能力和工程鲁棒性方面的不足，构建了从传播场建模、观测构造、智能决策到实验验证的完整研究链路。

首先，在单目标定位问题上，本文针对复杂城市环境中 RSSI、AoA 和 PDR 等多源观测可靠性随环境变化而动态波动的特点，提出了基于物理感知深度强化学习的自适应融合定位方法。该方法将单目标连续定位问题建模为马尔可夫决策过程，在此基础上构建了包含 RMS 时延扩展、RSSI 方差、几何一致性特征以及历史权重信息的物理感知状态空间，并通过增量式动作空间和联合奖励设计，实现了多源观测融合权重的自适应调整。相较于仅依赖后验误差反馈的强化学习基线方法，所提出方法能够更有效地感知环境变化趋势，并在复杂传播条件下保持更稳定的轨迹输出和更高的定位精度。

其次，在多目标场景下，本文针对复杂城市环境中多目标终端并发存在、空间采样稀疏、多径鬼影干扰显著以及传统峰值判定方法易产生虚警的问题，研究了基于空间信号成像的 Radio Map 构建方法。论文首先依托真实地理信息数据与 MATLAB 工具链完成复杂城市三维传播场建模，并在此基础上将无人机空间扫描得到的离散 RSSI 观测映射到规则网格中，进一步通过高斯平滑实现连续化表达，从而将原始射频观测转化为具有区域结构的二维 Radio Map 表征。该处理过程使离散观测中的局部多峰现象能够在区域层面得到聚合，也为真实目标与多径鬼影之间的结构区分提供了表征基础。

再次，考虑到实际多无人机协同网络中存在节点掉点、失效和链路中断等问题，本文进一步研究了基于知识蒸馏的掉点鲁棒协同定位方法。针对多无人机网络在随机掉点条件下输入维度动态变化、传统固定结构模型难以有效处理残缺观测的问题，本文构建了教师—学生蒸馏框架：以完整无人机网络生成的全量观测作为教师输入，以掉点后的残缺观测作为学生输入，通过教师模型输出的软标签分布对学生模型进行指导。该方法在不增加额外硬件成本的前提下，实现了对缺失观测信息的有效补偿，提高了学生网络在拓扑退化条件下的定位稳定性和工程适应能力。

最后，本文围绕上述方法开展了较为系统的实验验证。实验结果表明，所提出的单目标自适应融合方法能够在复杂城市环境中实现更高精度和更强鲁棒性的连续定位；所提出的多无人机协同蒸馏方法能够在不同掉点比例下有效减缓学生网络的性能退化，提升残缺观测条件下的栅格定位精度。相关结果说明，本文研究工作从单目标动态融合到多无人机协同鲁棒定位形成了较为完整的技术路线，为低成本无人机平台条件下非法低轨卫星终端定位识别问题提供了具有一定工程价值的解决思路。

5.2 主要研究结论

围绕本文的研究内容，可以归纳出以下几个主要结论。

第一，复杂城市环境下的非法终端定位问题不能简单地视为静态参数估计问题，而应被视为一个随传播环境动态变化而不断演化的序列决策问题。在单目标场景中，不同观测源的可靠性会随着遮挡、多径和目标运动过程持续变化，固定权重融合或静态规则难以满足复杂环境中的定位需求。将定位问题建模为动态决策过程，并引入强化学习进行自适应权重调整，是提高系统环境适应能力的有效途径。

第二，物理先验信息对于提升单目标强化学习定位性能具有重要作用。本文在强化学习状态空间中引入 RMS 时延扩展、RSSI 方差和几何一致性等特征后，智能体不再仅依赖后验误差进行被动修正，而能够结合传播环境特征、观测波动特征和跨模态一致性信息进行更具前瞻性的决策。实验结果表明，这种物理感知状态设计能够有效提升复杂环境下的定位精度和轨迹稳定性。

第三，在多目标场景中，直接基于离散峰值进行目标判定存在明显局限。复杂城市环境中的稀疏采样、噪声扰动和多径反射会导致同源多峰和鬼影响应并存，使传统逐峰判定方法难以准确区分真实目标与伪响应。通过将离散射频观测构建为具有区域结构的 Radio Map，可以将原本难以在数值域内稳定处理的问题转化为更适合区域判别的空间表征问题，从而为后续定位提供更稳定的输入基础。

第四，多无人机协同定位系统的实际应用能力不仅取决于完整网络条件下的定位精度，还取决于在节点失效和网络拓扑退化条件下的性能保持能力。随机掉点会导致输入特征维度不规则、可用观测减少，传统固定输入模型在此条件下容易出现明显性能退化。基于知识蒸馏的教师—学生框架能够将完整网络中学得的全局空间判别规律迁移到残缺观测条件下的学生模型中，从而提高系统在掉点条件下的鲁棒性。

第五，低成本无人机平台条件下的非法终端定位识别研究，应当更加重视传

播环境建模、输入表征构造和模型鲁棒性设计之间的协同关系。仅依赖某一单独模块的改进通常难以从根本上解决复杂环境中的定位问题，而从传播场、观测层和决策层进行联合设计，更有利于形成面向实际部署条件的系统性解决方案。本文从这一角度出发所形成的研究路线，验证了物理建模、信号成像与智能学习方法结合的有效性。

5.3　后续研究展望

尽管本文围绕复杂城市环境下非法低轨卫星终端的定位识别问题开展了较为系统的研究，并取得了一定结果，但仍有若干问题值得在后续工作中进一步深入。

第一，本文当前的研究主要建立在仿真环境和半实物条件下完成，后续仍需进一步加强真实场景实验验证。复杂城市环境中的传播条件、目标行为模式以及无人机平台运行状态均具有较强的不确定性，仿真模型虽然能够较好地重现主要传播机理，但仍难以完全覆盖真实环境中的全部复杂因素。后续可进一步结合实地飞行实验、真实街区测量数据和多源传感器记录，对本文方法在真实应用条件下的泛化能力与鲁棒性进行更充分评估。

第二，本文在单目标定位部分重点研究了二维平面条件下的自适应融合问题，后续可进一步向三维空间定位拓展。对于实际非法终端定位任务而言，无人机平台本身处于三维空间中飞行，目标区域也可能存在地形起伏、楼层差异等因素。如何将当前方法扩展到三维定位框架，并同时考虑高度信息、俯仰角观测以及更复杂的空间几何约束，是后续值得进一步研究的问题。

第三，本文在多无人机协同定位部分主要考虑了随机掉点条件下的节点失效问题，后续可进一步研究更复杂的动态协同网络场景。例如，实际任务中可能出现掉点与恢复交替发生、通信链路质量随时间变化、部分节点观测出现严重失真但并未完全失效等情况。如何在更一般的动态拓扑条件下实现在线自适应协同定位，并同时保持系统的鲁棒性与实时性，是后续工作的重要方向。

第四，本文采用知识蒸馏实现完整网络知识向残缺网络的迁移，后续仍可进一步探索更丰富的蒸馏机制。当前研究主要集中于输出层分布的蒸馏监督，后续可以进一步考虑中间特征蒸馏、关系蒸馏以及面向图结构的拓扑蒸馏等方式，以更充分地利用教师网络在空间结构建模方面的优势。同时，针对不同掉点比例、不同网络规模和不同任务场景设计自适应蒸馏策略，也有望进一步提升学生模型性能。

第五，本文的研究对象主要聚焦于非法低轨卫星终端定位识别问题，但相关方法在更广泛的无线感知与协同定位任务中也具有潜在应用价值。后续可以考

虑将本文所提出的物理感知强化学习融合方法、Radio Map 构建方法以及掉点鲁棒蒸馏框架拓展到其他复杂场景下的射频感知任务，如应急通信保障、复杂环境下的无线电源定位、低空协同感知网络管理等方向，从而进一步丰富其工程应用前景。

综上所述，围绕低成本无人机平台条件下非法终端定位识别问题，复杂环境传播建模、动态自适应决策、多节点协同鲁棒学习以及真实场景验证仍然是后续研究中值得持续深入的几个方向。随着无人机平台能力提升、无线感知技术发展以及智能学习方法不断演进，该方向仍具有较大的研究空间和应用潜力。

参考文献

附　录

BUPT	Beijing University of Posts and Telecommunications 北京邮电大学

攻读学位期间发表的创新成果目录

本人攻读学位期间共发表论文 X 篇，其中，第一作者 X 篇，学生一作 X 篇，第二作者 X 篇，其他参与论文共 X 篇：

1. AuthorA, Author B, Author C, Paper Title, *Conference/Transactions*, May. 2021, pp. 1-15. (IF = 999.99)

发明专利 0 项